# Messdatenauswertung und Messunsicherheit (MDA)

Dr. habil. Dorothee Hüser und Dr.-Ing. Gerd Ehret
Physikalisch-Technische Bundesanstalt
Modulverantwortlicher: Prof. Dr.-Ing. R. Tutsch
iprom, TU Braunschweig

17. Oktober 2026

# Inhaltsverzeichnis


**1 Einführung: Messtechnik und Statistik** **1**

1.1 Grundlegende Begriffe . . . . . 2

1.2 Modelle und Statistik . . . . . 7

1.3 Ko-Varianzen von Zufallsgrößen . . . . . 14

1.4 Beispiel zur Methode der kleinsten Quadrate zum Selbststudium . . . . . 20

**2 Lineare Regression (Ausgleichsrechnung)** **21**

2.1 Die Idee der linearen Regression . . . . . 22

2.2 Lineare Regression als Methode der kleinsten Abweichungsquadrate . . . . . 23

2.2.1 Polynomansatz ohne Matrixschreibweise . . . . . 24

2.2.2 Regressionsgerade ohne Matrixschreibweise . . . . . 25

2.3 Matrixformalismus zur allgemeinen Lösung der linearen Regression . . . . . 26

2.3.1 Matrixformalismus anhand der Regressionsgeraden . . . . . 26

2.3.2 Matrixansatz als allgemeiner Ansatz für lineare Regression . . . . . 30

2.4 Das Bestimmtheitsmaß und der empirische Korrelationskoeffizient . . . . . 33

2.5 Beispiele zur linearen Regression . . . . . 36

2.5.1 Modellwahl: Gerade oder Polynom . . . . . 36

2.5.2 Beispiel: Bestimmung eines Ohmschen Widerstands . . . . . 36

2.5.3 Fit einer Geraden mittels linearer Regression . . . . . 38

2.5.4 Fit einer kubischen Funktion (Polynom 3. Ordnung) mittels linearer Regression 43

2.6 Aufgaben zum Selbststudium . . . . . 46

2.6.1 1. Aufgabe zur Linearen Regression . . . . . 46

**3 Parameter nichtlinearer Modelle schätzen 49**

3.1 Konzepte von Optimierungsverfahren für nichtlineare Modelle . . . . . 50

3.2 Gradientenverfahren für nichtlineare Kostenfunktionen . . . . . 53

3.3 Beispiel zum Gauß-Newton-Verfahren bei gleichen Varianzen . . . . . 57

3.4 Levenberg-Marquardt-Verfahren . . . . . 62

3.5 Matlabfunktionen zur Berechnung nichtlinearer Fits . . . . . 72

3.6 Gradientenverfahren mit unterschiedlichen Varianzen . . . . . 74

3.7 Unsicherheit der geschätzten Modellparameter . . . . . 75

3.8 Robuste Schätzverfahren . . . . . 78

**4 Konzepte der Statistik für die Messdatenanalyse 83**

4.1 Vorwärtsmodell und inverses Problem . . . . . 84

4.2 Zufällige Abweichungen, Residuen und Modellabweichungen . . . . . 86

4.3 Wahrscheinlichkeitsdichte und bedingte Wahrscheinlichkeit . . . . . 88

4.4 Von der Likelihood zur Methode der kleinsten Quadrate . . . . . 89

4.5 Frequentistische Auswertung: Standardunsicherheiten und Residuen . . . . . 91

4.5.1 Wiederholte Messung einer einzelnen Größe . . . . . 92

4.5.2 Lineare Regression als Beispiel . . . . . 95

4.6 Vektorielle Beobachtungen und gewichtete kleinste Quadrate . . . . . 98

4.7 Streuende Koordinaten und gewichtete Geradenanpassung . . . . . 99

4.8 Bayesische Auswertung: vom Vorwissen zur Parameterverteilung . . . . . 103

4.8.1 Aktualisierung durch die Bayes-Regel . . . . . 104

4.8.2 Frühere Messungen: gemeinsame Auswertung oder Aktualisierung . . . . . 105

4.8.3 Wann beide Ansätze dieselben Zahlen liefern . . . . . 106

4.9 Vollständiges Lehrbeispiel: Widerstand und unbekannte Streuung . . . . . 107

4.9.1 Daten, Beobachtungsmodell und Priorverteilungen . . . . . 108

4.9.2 Gemeinsame Posteriorverteilung . . . . . 108

4.9.3 Randverteilung, Schätzwert und Standardunsicherheit . . . . . 109

4.9.4 Kredibilitätsintervall und Vergleich mit dem Konfidenzintervall . . . . . 110

4.10 Einordnung, Nutzen und Grenzen . . . . . 111

**5 Wahrscheinlichkeiten und Hypothesentests 115**

5.1 Konzept der statistischen Erwartung . . . . . 116

5.2 Kolmogorow-Smirnow- und Lilliefors-Tests . . . . . 117

5.3 Wahrscheinlichkeitsdichtefunktionen und ihre Parameter . . . . . 122

5.4 Verteilung für kleine Stichproben: t-Verteilung . . . . . 126

5.5 *t*-Test - Mittelwerttest . . . . . 135

5.6 $\chi^2$-Verteilung und Test einer Varianz . . . . . 138

5.7 Fisherverteilung und Vergleich zweier empirischer Varianzen . . . . . 142

5.8 Anwendung von Hypothesentests . . . . . 145

5.8.1 Entscheidung bei Vergleich zweier Stichproben . . . . . 145

5.9 Übungsaufgaben zum Selbststudium . . . . . 147

5.10 Anhang: Erwartungswerte zur $\chi^2$-Verteilung . . . . . 150

**6 Konformitätsbewertung 151**

6.1 Toleranz und Konformität . . . . . 152

6.2 Konformitätswahrscheinlichkeit und Risiko . . . . . 154

6.3 ISO 17025, Entscheidungsregeln für die Konformitätsbewertung . . . . . 163

**7 Auswertung von Mess- und Ringvergleichen 171**

7.1 Auswertung von Messvergleichen mit Referenzlabor . . . . . 172

7.2 Auswertung von Ringvergleichen ohne Referenzlabor . . . . . 174

7.2.1 Vorgehensweise . . . . . 174

7.2.2 Beispiel . . . . . 177

7.2.3 Identifikation von Ausreißern und Konsistenzcheck . . . . . 178

7.2.4 Paule-Mandel Methode zur Anpassung von Gewichtsfaktoren . . . . . 180

**8 Infrastrukturen der Metrologie 189**

8.1 Internationale Metrologieorganisationen (BIPM,NMIs) . . . . . 190
8.2 Akkreditierung, Zertifzierung, DAkkS . . . . . 190
8.2.1 Messen, Prüfen, Lehren . . . . . 190
8.2.2 Akkreditierung (Wirtschaft) . . . . . 190
8.2.3 Zertifizierung . . . . . 196
8.2.4 Konfirmitätsbewertung . . . . . 198
8.2.5 Audit . . . . . 199
8.2.6 DAkkS . . . . . 200

**9 Messunsicherheitsfortpflanzung: Konzepte und Methoden 203**
9.1 Konzepte der Messunsicherheitsfortpflanzung: GUM-Reihe . . . . . 204
9.1.1 Messmodell, Eingangsgrößen und Ausgangsgrößen . . . . . 204
9.1.2 Modelle zur Unsicherheit direkter Messgrößen . . . . . 206
9.1.3 Ansätze zur Unsicherheitsfortpfanzung im GUM . . . . . 209
9.1.4 Weitere Dokumente der GUM-Reihe . . . . . 217
9.2 Numerische Werkzeuge für Messunsicherheitsberechnungen . . . . . 219
9.2.1 Numerische Integrationsverfahren . . . . . 219
9.2.2 Zufallszahlen und Wahrscheinlichkeitsverteilungen . . . . . 222

**10 Messunsicherheit – linearisierbare, explizite Modelle 225**
10.1 Exakte Fortpflanzung für lineare Modelle . . . . . 228
10.2 Linearisierung eines nichtlinearen Modells . . . . . 234
10.3 Grenzen des Linearisierungsansatzes . . . . . 236
10.4 Von der Standardunsicherheit zum Überdeckungsintervall . . . . . 239
10.5 Beispiel: Beugung am Spalt im Fernfeld . . . . . 248
10.5.1 Messmodell und Näherungen . . . . . 248
10.5.2 Erste Stufe: Minimumsposition aus Detektordaten . . . . . 249
10.5.3 Zweite Stufe: Sensitivitäten und Unsicherheitsbudget . . . . . 249
10.5.4 Zwei verschiedene Näherungen prüfen . . . . . 251

10.6 Aufgabe zum Selbststudium: Kalibrierung eines Wegaufnehmers . . . . . 252

10.6.1 Lösungshinweise und Kontrollwerte . . . . . 253

10.7 Übergang zu Supplement 1 . . . . . 254

**11 Monte-Carlo Methoden für M.U.-Berechnungen 255**

11.1 Fortpflanzung durch Kombination der Verteilungen . . . . . 256

11.1.1 Gemeinsame Verteilung der Eingangsgrößen . . . . . 256

11.1.2 Vom Eingangsbereich zum Ausgangsintervall . . . . . 257

11.1.3 Anwendung auf die Spaltbreitenmessung . . . . . 260

11.2 Integration der Wahrscheinlichkeitsdichte mittels Klassierung . . . . . 262

11.3 Monte-Carlo Integration . . . . . 270

**12 M.U.-Berechnung mit bayesischer Statistik 275**

12.1 Bayes-Theorem . . . . . 276

12.1.1 Einleitung: Klassische und Bayessche Statistik . . . . . 276

12.1.2 Das Bayes-Theorem . . . . . 276

12.2 Parameterschätzung mit Bayesscher Statistik . . . . . 278

12.2.1 Einführung . . . . . 278

12.2.2 Beispiel: Schätzung einer physikalischen Konstante . . . . . 278

12.2.3 Priorverteilungen . . . . . 287

12.2.4 Posteriorverteilungen von Modellparametern . . . . . 290

12.3 MU-Bestimmung mittels Posterior aus Bayesansatz . . . . . 291

12.3.1 Bayessche Intervallschätzung . . . . . 291

12.3.2 MU-Bestimmung mit der Bayesschen Statisktik . . . . . 292

12.4 Regression mit Vorkenntnis (Prior) . . . . . 294

12.5 Median einer Verteilung . . . . . 297

12.6 Übungsaufgaben . . . . . 301

12.7 Vergleich der klassischen mit der bayesischen Methode . . . . . 304

12.8 Anhang: Beispiel indirekte Größe aus Produkt zweier direkter Größen . . . . . 309

**13 Anhang: Quantiltabellen** **313**

13.1 Quantile der Normalverteilung . . . . . 314

13.2 Quantile der t-Verteilung . . . . . 315

13.3 Quantile der $\chi^2$-Verteilung . . . . . 316

13.4 Quantile der Fisher-Verteilung für $\alpha = 5\%$ . . . . . 317

13.5 Grenzwerte für Lilliefors-Test und Zweistichproben-KS-Test . . . . . 318

**14 Lösungen zu den Aufgaben** **319**

14.1 Lösung zur Aufgabe aus Vorl 1 . . . . . 320

14.1.1 Lösung zum Beispiel zur Methode der der kleinsten Quadrate . . . . . 320

14.2 Lösungen zu den Aufgaben aus Vorl 2 . . . . . 322

14.2.1 Lösung zur 1. Aufgabe: Lineare Regression . . . . . 322

14.3 Hilfe zu den Übungsaufgaben zum Selbststudium . . . . . 328

14.4 Lösung . . . . . 336

# Kapitel 1

# Einführung: Messtechnik und Statistik

## 1.1 Grundlegende Begriffe

Um über einen Sachverhalt kommunizieren zu können, müssen seine Gegenstände, Inhalt und Vorgänge **bezeichnet** werden. Damit die Kommunikationspartner sich gegenseitig verstehen, muss zuvor festgelegt sein, welcher Begriff / welcher Bezeichner / welche Vokabel welchen Bedeutungsinhalt darstellt. Deshalb müssen wir auch die Begrifflichkeiten der Bereiche Messtechnik und Statistik lernen und ihren Bedeutungsinhalt verstehen.

Die statistischen Begriffe und Sprachkonventionen sind nicht einheitlich. Beim Literaturstudium wird man feststellen, dass verschiedene Fachgebiete dieselben statistischen und systemtheoretischen Sachverhalte unterschiedlich darstellen und auch mit teilweise recht unterschiedlichen Ansätzen behandeln.

Im folgenden werden die Vokabeln der in Messtechnik und Statistik verwendeten Sprache aufgeführt:

1. Messen - vergleichen; Messvorgang

   - **Messung** (engl. *measurement*): Prozess, bei dem ein Größenwert oder mehrere Größenwerte, die vernünftigerweise einer Größe zugewiesen werden können, experimentell ermittelt werden. [VIM2.1]
   - Messprinzip (engl. *measuerement principle*): Phänomen, das als Grundlage einer Messung dient. [VIM2.4]

   Beispiele: Länge eines Werkstücks mit Maßstab vergleichen, Temperatur darstellen über die Ausdehnung einer Quecksilbersäule in einem Röhrchen

   Die Abkürzung VIM steht für *Vocabulaire international de métrologie* und bezeichnet das internationale Wörterbuch der Metrologie *International vocabulary of metrology - Basic and general concepts and associated terms* [VIM08], das auf folgender Webseite als zweisprachige Version (Englisch und Französisch) frei erhältlich ist:

   `https://www.bipm.org/documents/20126/2071204/JCGM_200_2012.pdf`

   Die nachstehende Zahl, hier 2.1 und 2.4, gibt den jeweiligen Absatz an. Die deutschsprachige Version ist kostenpflichtig im Beuthverlag erschienen.

2. Physikalische Größe und Größengleichung

   - Eine **physikalische Größe** ist eine quantitativ bestimmbare Eigenschaft eines physikalischen Objektes, Vorgangs oder Zustands. Ihr Wert (Größenwert) wird als Produkt aus einem Zahlenwert (der Maßzahl) und einer Maßeinheit angegeben. Vektorgrößen werden durch Größenwert und Richtung angegeben.
   - Eine **Größengleichung** ist die mathematische Darstellung eines physikalischen Gesetzes, das Zustände eines physikalischen Systems und deren Änderungen beschreibt.
     Sie stellt den dabei geltenden Zusammenhang zwischen verschiedenen physikalischen Größen dar, wobei in der Regel für jede dieser Größen ein Formelzeichen steht.
     Größengleichungen gelten unabhängig von den gewählten Maßeinheiten.

- Diejenigen physikalischen Größen, die als Basis eines Größensystems festgelegt sind, heißen **Basisgrößen**.
- Im Jahr 1960 wurde das Internationale Einheitenystem SI (franz. *Système international d'unités*) basierend auf dem metrischen System von der Generalkonferenz für Maß und Gewicht eingeführt. Dieses liefert die Struktur für die Einheiten im (gesetzlichen) Messwesen.
- Das *Bureau international des poids et mesures* (BIPM) ist eine internationale Organisation, die vom internationalen Metervertrags-Bündnis, der Meterkonvention (*Metre Convention*), eingerichtet wurde. Durch das BIPM können die Mitgliederstaaten gemeinsam in Angelegenheiten des Messwesens und Standardisierung im Messwesen handeln.
- Die Basisgrößen im SI-System sind folgende
  1.) **Zeit**: Einheit **Sekunde**, Formelzeichen der Einheit: s
     - von 1983 bis 2019:
       Die Sekunde ist das 9 192 631 770fache der Periodendauer der dem Übergang zwischen den beiden Hyperfeinstrukturniveaus des Grundzustandes von Atomen des Nuklids $^{133}$Cs entsprechenden Strahlung.
     - seit Mai 2019:
       Die Sekunde ist definiert, indem für die Cäsiumfrequenz $\Delta\nu_{\mathrm{Cs}}$, der Frequenz des ungestörten Hyperfeinübergangs des Grundzustandes der Zahlenwert 9 192 631 770 festgelegt wird, ausgedrückt in der Einheit **Hertz**, die gleich Sekunde$^{-1}$ ist.

  2.) **Länge**: Einheit **Meter**, Formelzeichen der Einheit: m
     - von 1983 bis 2019:
       Der Meter ist die Länge der Strecke, die Licht im Vakuum während der Dauer von (1/299 792 458) Sekunden durchläuft.
     - seit Mai 2019:
       Der Meter ist definiert, indem für die Lichtgeschwindigkeit in Vakuum $c$ der Zahlenwert 299 792 458 festgelegt wird, ausgedrückt in der Einheit Meter · Sekunde$^{-1}$, wobei die Sekunde mittels der Cäsiumfrequenz $\Delta\nu_{\mathrm{Cs}}$ definiert ist.

  3.) **Masse**: Einheit **Kilogramm**, Formelzeichen der Einheit: kg
     - von 1983 bis 2019:
       Das Kilogramm ist die Einheit der Masse; es ist gleich der Masse des Internationalen Kilogrammprototyps.
     - seit Mai 2019:
       Das Kilogramm ist definiert, indem für die Planckkonstante $h$ der Zahlenwert $6{,}62607015 \cdot 10^{-34}$ festgelegt wird, ausgedrückt in der Einheit Joule · Sekunde, die gleich der Einheit Kilogram · Meter$^2$ · Sekunde$^{-1}$ ist, wobei der Meter mittels der Lichtgeschwindigkeit und die Sekunde mittels der Cäsiumfrequenz definiert sind.

  4.) **elektrische Stromstärke**: Einheit **Ampere**, Formelzeichen der Einheit: A
     - von 1983 bis 2019:
       Das Ampere ist die Stärke eines konstanten elektrischen Stromes, der, durch zwei parallele, geradlinige, unendlich lange und im Vakuum im Abstand von einem

Meter voneinander angeordnete Leiter von vernachlässigbar kleinem, kreisförmigem Querschnitt fließend, zwischen diesen Leitern je einem Meter Leiterlänge die Kraft $2 \cdot 10^{-7}$ Newton hervorrufen würde.

- seit Mai 2019:
  Das Ampere ist definiert, indem für die Elementarladung $e$ der Zahlenwert $1{,}602176634 \cdot 10^{-19}$ festgelegt wird, ausgedrückt in der Einheit Coulomb, gleich dem Produkt Ampere · Sekunde ist, wobei die Sekunde über die Cäsiumfrequenz definiert ist.

5.) **Temperatur**: Einheit **Kelvin**, Formelzeichen der Einheit: K

- von 1983 bis 2019:
  Das Kelvin, die Einheit der thermodynamischen Temperatur, ist der 273,16te Teil der thermodynamischen Temperatur des Tripelpunktes des Wassers. Diese Definition bezieht sich auf Wasser, dessen Isotopenzusammensetzung durch folgende Stoffmengenverhältnisse definiert ist: 0,000 155 76 Mol $^{2}$H pro Mol $^{1}$H, 0,000 379 9 Mol $^{17}$O pro Mol $^{16}$O und 0,002 005 2 Mol $^{18}$O pro Mol $^{16}$O
- seit Mai 2019:
  Das Kelvin ist die SI Einheit der thermodynamischen Temperatur.
  Das Kelvin ist definiert, indem für die Boltzmannkonstante $k_{\mathrm{B}}$ der Zahlenwert $1{,}380649 \cdot 10^{-23}$ festgelegt wird, ausgedrückt in der Einheit Joule · Kelvin$^{-1}$, die gleich dem Produkt Kilogram · Meter$^{2}$ · Sekunde$^{-2}$ · Kelvin$^{-1}$ ist und wobei das Kilogram über die Planckkonstante, der Meter über die Lichtgeschwindigkeit und die Sekunde über die Cäsiumfrequenz definiert sind.

6.) **Stoffmenge**: Einheit **Mol**, Formelzeichen der Einheit: mol

- von 1983 bis 2019:
  Das Mol ist die Stoffmenge eines Systems, das aus ebenso vielen Einzelteilchen besteht, wie Atome in 0,012 Kilogramm des Kohlenstoffnuklids $^{12}$C enthalten sind. Bei Benutzung des Mol müssen die Einzelteilchen spezifiziert sein und können Atome, Moleküle, Ionen, Elektronen sowie andere Teilchen oder Gruppen solcher Teilchen genau angegebener Zusammensetzung sein.
- seit Mai 2019:
  Das Mol ist die SI Einheit für Stoffmenge. Ein mol enthält genau $6{,}02214076 \cdot 10^{23}$ elementare Entitäten (Einzelteilchen). Dieser Zahlenwert entspricht dem für die Avogadrokonstante $N_{\mathrm{A}}$ festgelegten Zahlenwert, ausgedrückt in der Einheit mol$^{-1}$ und wird als Avogadrozahl bezeichnet.
  Die Stoffmenge, Formelzeichen $n$, eines Systems ist ein Maß für die Anzahl der spezifizierten Einzelteilchen. Bei einem Einzelteilchen kann es sich um ein Atom, ein Molekül, ein Ion, ein Elektron oder irgend eine andere Teilchenart oder eine spezifizierte Gruppe von Teilchen mit genau angegebener Zusammensetzung handeln.

7.) **Lichtstärke**: Einheit **Candela**, Formelzeichen der Einheit: cd

- von 1983 bis 2019:
  Die Candela ist die Lichtstärke in einer bestimmten Richtung einer Strahlungsquelle, die monochromatische Strahlung der Frequenz $540 \cdot 10^{12}$ Hertz

aussendet und deren Strahlstärke in dieser Richtung (1/683) Watt durch Steradiant beträgt.

– seit Mai 2019:
Die Candela ist die die SI Einheit der Lichtstärke in einer bestimmten Richtung. Die Candela ist definiert, indem für das photometrische Strahlungsäquivalent $K_{\mathrm{Cd}}$ der monochromatischen Strahlung der Frequenz $540 \cdot 10^{12}$ Hertz der Zahlenwert 683 festgelegt wird, ausgedrückt in der Einheit Kandela · Steradiant · Watt$^{-1}$ oder Kandela · Steradiant · Kilogramm$^{-1}$ · Meter$^{-2}$ · Sekunde$^3$, wobei das Kilogramm mittels der Planckkonstanten, der Meter mittels der Lichtgeschwindigkeit und die Sekunde mittels der Cäsiumfrequenz definiert sind.

`https://en.wikipedia.org/wiki/2019_redefinition_of_the_SI_base_units`

`https://www.ptb.de/cms/fileadmin/internet/presse_aktuelles/broschueren/intern_einheitensystem/Die_gesetzlichen_Einheiten.pdf`

`https://eur-lex.europa.eu/legal-content/DE/TXT/PDF/?uri=CELEX:32019L1258&from=EN`

- Durch Verknüpfung der Basisgrößen gewonnene Größen sind beispielsweise
  – **Frequenz**: Einheit **Hertz**, Formelzeichen der Einheit: Hz
  Sie ist der Kehrwert der Zeit. Die Größengleichung ist

$$f \;=\; \frac{1}{t} \tag{1.1}$$

  mit den Formelzeichen $t$ für die Größe Zeit und $f$ für die Frequenz
  – **Kraft**: Einheit **Newton**, Formelzeichen der Einheit: N
  Sie ist die Verknüpfung von den Größen Masse $m$, Länge $L$ und Zeit $t$ gemäß folgender Größengleichung (physikalischen Zusammenhangs):

$$F \;=\; m\,\frac{L}{t^2} \tag{1.2}$$

  wobei $F$ das Formelzeichen für die Größe Kraft ist.
  Anmerkung: Die Größe $\frac{L}{t^2}$ hat einen eigenen Namen, sie heißt Beschleunigung und hat häufig das Formelzeichen $a$, aber ihre Einheit hat keinen eigenen Namen, die Einheit bleibt eine Verknüfung aus Basiseinheiten: $\frac{\mathrm{m}}{\mathrm{s}^2}$.
- Die **Werte** von physikalischen **Größen** (Naturkonstanten) und von Umrechnungsfaktoren zwischen unterschiedlichen Einheitensystemen werden vom *Committee on Data for Science and Technology* (CODATA) festgelegt. Die Werte basieren auf Anpassungsberechnungen nach der Methode der kleinsten Quadrate. Der im Bericht von 2015, der über den folgenden Link zugänglich frei zugänglich ist beruht auf Daten, die bis zum 31. Dezember 2014 verfügbar waren.

`https://zenodo.org/record/22826#.W8bufN0zZhE`

Die Daten werden aus internationalen Vergleichsmessungen gewonnen.

3. Messgröße - Zufallsgröße
   Beispiel Länge des Werkstücks wiederholt vergleichen
   → Beobachtungen

   - Beobachtungen = Messwerte
     Erfassen von Werten durch einen Messvorgang
   - Streuung der beobachteten Werte
     - Die einzelnen beobachteten Werte streuen aufgrund des Mangels einer genauen Kenntnis des Entstehungsprozesses, weshalb man die Methoden der Statistik anwendet.
     - Die Statistik ist das mathematische Framework für den Umgang mit **Zufallsgrößen**.
   - Zufallsgrößen - Wahrscheinlichkeit
     Die Beobachtungen zu Größen werden in der Wahrscheinlichkeitstheorie mit dem Begriff **Ereignis** bezeichnet.
     - **Zufallsgrößen** sind dadurch gekennzeichnet, dass sie verschiedene Werte annehmen können, wobei jeder dieser Werte ein zufälliges Ereignis darstellt und mit einer bestimmten **Wahrscheinlichkeit** auftritt.
     - Die **Wahrscheinlichkeit** ist ein Maß für die Möglichkeit (engl. *likelihood*), dass ein Ereignis eintritt.
     - **Wahrscheinlichkeitsverteilung** wird die mathematische Funktion genannt, die jedem Wert einer Zufallsgröße die Wahrscheinlichkeit für sein Eintreten zuordnet.

     Andrej Nikolaevic Kolmogorow, russischer Mathematiker, hat in den 1930er Jahren die axiomatische Begründung der Wahrscheinlichkeitstheorie entwickelt und damit den Formalismus wie wir ihn heutzutage verwenden. Der aus der kyrillischen Schrift in die lateinische Schrift umgeschriebene Name ist in der Literatur in unterschiedlicher Schreibweise zu finden, beispielsweise auch als Kolmogorov oder Kolmogoroff. Der kolmogorow'schen Wahrscheinlichkeitstheorie liegen folgende drei Axiome zugrunde:

     (a) Für jedes Ereignis ist die Wahrscheinlichkeit eine reelle Zahl zwischen 0 und 1.
     (b) Das sichere Ereignis (damit ist dasjenige gemeint, das immer eintritt) hat die Wahrscheinlichkeit 1.
     (c) Für Ereignisse, die sich gegenseitig ausschließen (disjunkte Ereignisse), gilt, dass die Summe der Wahrscheinlichkeiten jedes einzelnen dieser Ereignisse gleich der Wahrscheinlichkeit der Summe der Ereignisse ist.

     Aus diesen drei Axiomen werden die Regeln, wie man mit Wahrscheinlichkeiten rechnen kann, hergeleitet. Im Formalismus der Mathematik nennt man die aus Axiomen hergeleiteten Folgerungen **Satz**. Dies sind die **Sätze** der kolmogorow'schen Wahrscheinlichkeitstheorie, die wir im Laufe dieser Vorlesungsreihe verwenden werden:

     (a) Satz: Aus Axiom 3, d.h. aus der Additivität der Wahrscheinlichkeiten, folgt, dass komplementäre Ereignisse (Gegenereignisse) komplementäre Wahrscheinlichkeiten (Gegenwahrscheinlichkeiten) haben.
     Anmerkung zum Begriff **komplementär**: Das Komplement $\bar{A}$ zu einer Menge $A$ bezüglich des Grundbereichs $G$ ist die Menge aller Elemente aus $G$, die nicht Elemente von $A$ sind. $A$ und $\bar{A}$ sind Komplementärmengen bezüglich $G$. (Die

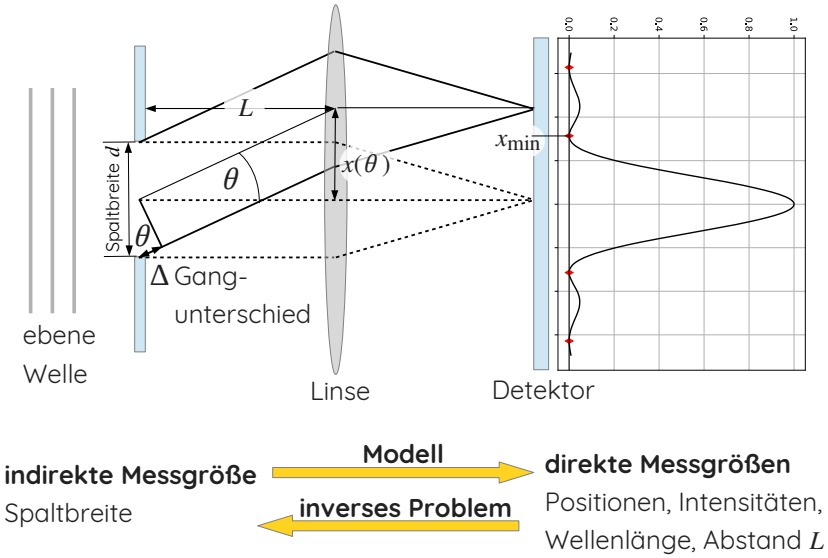



Abbildung 1.1: Veranschaulichung der Lösung eines inversen Problems anhand der Bestimmung einer Spaltbreite basierend auf dem Modell zur Beugung am Spalt in der Fraunhofernäherung.

Vereinigungsmenge von $A$ und $\bar{A}$ ist dann $G$ und die Schnittmenge ist die leere Menge).

(b) Satz: Das unmögliche Ereignis (die leere Menge) hat die Wahrscheinlichkeit 0.

(c) Für die Vereinigung nicht notwendig disjunkter Ereignisse gilt, dass die Wahrscheinlichkeit der Vereinigung nicht notwendig disjunkter Ereignisse gleich der Summe der Wahrscheinlichkeiten der einzelnen Ereignisse abzüglich der Wahrscheinlichkeit der Schnittmenge der nicht notwendig disjunkten Ereignisse ist.

## 1.2 Modelle und Statistik

Hinter jedem Messvorgang und jeder Messgröße stehen physikalische Prinzipien und Naturgesetze, die als Modell beschrieben werden. Ein Modell wird dargestellt durch eine Vorstellung darüber wie die indirekten Messgrößen und die direkten Messgrößen miteinander verknüpft sind. Liegen Werte für indirekte Messgrößen vor, beispielsweise aus älteren Experimenten oder aus heuritischen Annahmen, so liefert das Modell als Ergebnis modellierte Werte für die direkten Größen (Modellannahmen über die direkten Größen):

$$(Y_1, \ldots, Y_M) \xrightarrow{\text{Modell}} (X_1, \ldots, X_N) \tag{1.3}$$

Die Modellrechnung ist vorwärts gerichtet und wird direkt berechnet.

In der messtechnischen Realität liegen Beobachtungen zu den direkten Messgrößen vor, aus denen die Werte für die indirekten Messgrößen zu schätzen sind:

$$(X_1, \ldots, X_N) \xrightarrow{\text{inverses Problem}} (Y_1, \ldots, Y_M) \tag{1.4}$$

Abbildung 1.1 zeigt ein anschauliches Beispiel, das den Zusammenhang zwischen zwischen Modellie-

rung und dem Lösen inverser Probleme vermitteln soll:

> Ein Spalt wird mit kohärentem Licht beleuchtet. Das transmittierte Licht fällt auf eine CCD-Zeile, die die Intensitäten in Abhängigkeit von der Position auf dem CCD-Zeilendetektor aufnimmt. Es gibt dabei $N = 2$ direkte Größen: die Positionskoordinate $x$ auf dem Detektor und der dazugehörige Intensitätswert $I$. Die Anzahl der CCD-Pixel ist die Anzahl $J$ der Beobachtungen, $(x_1, I_1), \ldots, (x_J, I_J)$.
>
> Die gesuchte Information ist die Spaltbreite, sie ist die indirekte Größe.
>
> Zum Modell gehören die physikalischen Gesetze der Fraunhofer-Beugung, zudem auch weitere Größen, wie die Wellenlänge der Beleuchtung, der Abstand zwischen CCD-Chip und dem zu untersuchenden Gitters, der groß genug sein muss, damit die Gesetze der Fernfeldoptik gelten (der Einfachheit halber mal ohne Linsensysteme gedacht). Um die Abstände der Intensitätsmaxima genau zu lokalisieren, werden die Zusammenhänge für die Wellenoptik des Beugungphänomens gebraucht.

Ein Schätzvorgang besteht darin, die Modellparameter (das sind die indirekten Messgrößen) auszuprobieren, d.h. viele unterschiedliche Werte vorzugeben, und das Ergebnis der Modellrechnungen (1.3) mit den beobachteten Werten zu vergleichen, solange, bis das Ergebnis „gut zu den beobachteten Werten passt“. Die Methode des Variierens und Vergleichens „bis es passt“ nennen wir Schätzverfahren.

Die Methoden der Statistik dienen als Werkzeug zur Auswertung der Daten in der Messtechnik.

- In den Naturwissenschaften, den Ingenieurwissenschaften und der Statistik wird teilweise eine unterschiedliche Nomenklatur verwendet.
- In der Messdatenanalyse im Bereich Metrologie ist von *direkten* und *indirekten Messgrößen* die Rede. Sind die indirekten Messgrößen durch Schätzverfahren zu ermitteln, wird auch von **Daten** und **Modellparametern** gesprochen. In der Systemtheorie wird von **Eingangsgrößen** und **Ausgangsgrößen** und im Zusammenhang mit zeitabhängigen Größen (z.B. in der Elektrotechnik und in der Akustik) wird von **Eingangssignalen** und **Ausgangssignalen** gesprochen.
- Die Regressionsrechnung als Teilgebiet der Statistik kennt Eingangsgrößen als **Regressoren** und Ausgangsgrößen als **Regressanden**. Es handelt sich in beiden Fällen um Daten: Die an Geräten eingestellten Werte für die Eingangsgrößen werden als vorgegebene Werte ohne Streuung behandelt, und als Regressoren bezeichnet. Die mittels Messinstrument beobachteten Werte für die Ausgangsgrößen werden als Beobachtungen behandelt, die einer zufälligen Streuung unterliegen, und als Regressoren bezeichnet. Die Regressionsrechnung schätzt Modellparameter, die in der Systemtheorie auch **Zustandsgrößen** genannt werden können.
- Je nach Betrachtungsweise nehmen die indirekten Messgrößen entweder die Rolle der „Ausgangsgrößen“ $(A_1, \ldots, A_{n_A})$ oder der „Zustandsgrößen“ $(Z_1, \ldots, Z_{n_Z})$ oder der „Eingangsgrößen“ $(E_1, \ldots, E_{n_E})$ ein.

  $$(E_1, \ldots, E_{n_E}) \xrightarrow{\text{System}(Z_1,\ldots,Z_{n_Z})} (A_1, \ldots, A_{n_A}) \tag{1.5}$$

  Für das inverse Problem (1.4) sind die direkten Messgrößen die Eingangsgrößen und die indirekten Messgrößen die Ausgangsgrößen. Für das Modell (1.3) der indirekten Messgrößen sind

die indirekten Größen die Eingangsgrößen und die direkten Messgrößen die Ausgangsgrößen. Das bedeutet, dass in der Messtechnik beides, die Regressoren und Regressanden die direkten Messgrößen sind und die Modellparameter dann die indirekten Messgrößen darstellen.

Gängiges Verfahren der Statistik zum Schätzen von Modellparametern ist die **Maximum-Likelihood**-Methode. Bei diesem Verfahren werden die Modellparameter einzig aus den Beobachtungen der direkten Messgrößen bestimmt. Auf dieses Teilgebiet der Statistik wird auch mit der Bezeichnung *frequentistische* Statistik Bezug genommen, um es von den statistischen Verfahren abzugrenzen, bei denen Vorwissen einbezogen wird. Es geht dabei um Vorwissen über die zu schätzenden Parameter sowie über die Wahrscheinlichkeitsverteilungen der beteiligten Größen. Das Vorwissen über die Wahrscheinlichkeitsverteilungen von direkten Messgrößen wird bei der Modellbildung einer konkreten Problemstellung eingebaut. Im Falle der *frequentistischen* Methoden wird beim Schätzverfahren nach der **Maximum-Likelihood**-Methode bereits vorausgesetzt, dass alle beteiligten Zufallsgrößen, die direkten und die indirekten, normalverteilt sind. Um bei den *frequentistischen* Methoden andere Verteilungen für die Schätzer (indirekten Größen) zulassen zu können wird entweder eine Umgewichtung der Abweichungen vorgenommen oder es wird anstelle der Normalverteilung die Laplaceverteilung verwendet. Darauf kommen wir im Laufe der Vorlesungreihe zurück. Die statistischen Verfahren, bei denen die Wahrscheinlichkeitsdichten und die Vorkenntnisse über Schätzparameter direkt eingearbeitet werden, nennt man *bayesische* Methoden.

Die Idee der Maximum-Likelihood-Methode wollen wir hier anhand eines kleinen Regressionsbeispiels illustrieren:

- Präzisionsstromquelle mit genau einstellbarer Stromstärke $I$;
- Messung der Spannung $U$ mit Voltmeter;
- physikalisches Modell: Ohmsches Gesetz: $R = \frac{U}{I}$; Spannung Null, wenn Strom Null (kein Offset!);
- Schätzung des Modellparameters Widerstand $R$: Suchen eines Wertes für $R$, für den das Ergebnis der Modellrechnung „gut zu den beobachteten Werten passt“.

Wir tragen die experimentellen Werte in eine Tabelle ein und zeichnen sie in ein Diagramm, Abb. 1.2:

| $I$ in mA | 4.0 | 6.0 | 8.0 | 10.0 | 12.0 | 14.0 | 16.0 | 18.0 | 20.0 |
|---|---|---|---|---|---|---|---|---|---|
| $U$ in mV | 62.5 | 51.5 | 96.0 | 140.2 | 138.9 | 195.1 | 225.8 | 207.8 | 223.7 |

Ob die Spannungswerte zu dem Modell „passen“ wird bewertet, wobei das Modell besagt, dass die Spannungswerte gleich dem Widerstand, der genau eine konstante Größe sein soll, multipliziert mit den eingestellten Werten der Stromstärke seien. Das Bewertungskriterium ist „die Treffer-Wahrscheinlichkeit Spannungswert liegt auf Widerstand mal Strom“. Wir gehen davon aus, dass die Abweichungen $\varepsilon_i = U_i - RI_i$ normalverteilt sind, also

$$p(U_i, I_i|R) \propto e^{-\frac{1}{2}\left(\frac{\varepsilon_i}{\sigma_\varepsilon}\right)^2} \tag{1.6}$$

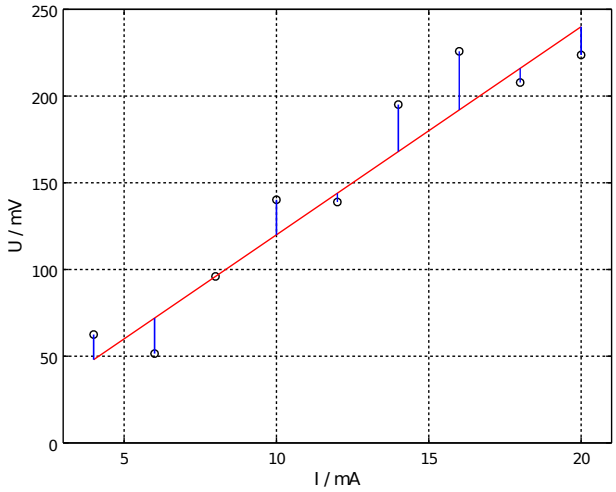



Abbildung 1.2: Regressionbeispiel: Modellparameter finden, dessen Wert am besten zu den Daten passt

wobei $\sigma_\varepsilon$ ein Maß für die Streuung der Residuen, hier in Millivolt, ist. Wir haben die Werte der Abweichungen $\varepsilon_i$. Man nennt sie **Residuen**. Das Produkt aller Wahrscheinlichkeiten $p(U_i, I_i|R)$ heißt **Likelihood**.

$$L((U_1, \ldots, U_J), (I_1, \ldots, I_J)|R) \;=\; \prod_{i=1}^{J} p(U_i, I_i|R) \tag{1.7}$$

Unsere Modellparameter bzw. der Modellparameter, die bzw. den wir ermitteln wollen, ist $R$ und für die Streuung der Werte des Parameters $R$ verwenden wir das Formelzeichen $\sigma_R$.

In der frequentistischen Statistik wird von der Vorstellung ausgegangen, dass es einen wahren Wert für $R$ gibt, dem man sich nähert, je mehr und genauer man misst, der aber wegen der Streuung der Spannungswerte $U$ nur annähernd bestimmbar ist. Wenn wir die Präzisionsstromquelle unverändert auf einen festen Wert einstellen und nicht durchfahren und dann mehrfach die Spannungen ablesen, so beobachten wir dennoch leicht unterschiedliche Werte für die Spannung. Dies ist der Grund dafür dass die Wertepaare bei durchgefahrenem Strom $(I_j, U_j)$ nicht exakt auf einer Geraden liegen.

Am besten passt das ganze für einen Wert für $R$, für den $L((U_1, \ldots, U_J), (I_1, \ldots, I_J)|R)$ maximal wird. Die Zielfunktion unseres Optimierungsvorgangs ist also:

$$\max_R \; L((U_1, \ldots, U_J), (I_1, \ldots, I_J)|R) \tag{1.8}$$

Solch eine Optimierungsaufgabe heißt **Maximum-Likelihood**-Verfahren.

$$\max_R \prod_{i=1}^{J} e^{-\frac{1}{2}\left(\frac{\varepsilon_i}{\sigma_\varepsilon}\right)^2} \tag{1.9}$$

d.h. nach den Gesetzen der Potenzrechnung

$$\max_R \; e^{-\frac{1}{2}\sum\limits_{i=1}^{J}\left(\frac{\varepsilon_i}{\sigma_\varepsilon}\right)^2}. \tag{1.10}$$

Das Maximum der Gaußfunktion liegt an der Stelle, an der der Exponent minimal wird. Wir maxi-

mieren die Likelihood, wenn wir ihren Logarithmus minimieren:

$$\min_R \sum_{i=1}^{J} \left(\frac{\varepsilon_i}{\sigma_\varepsilon}\right)^2 \tag{1.11}$$

dazu suchen wir die Nullstelle der Ableitung nach dem Modellparameter. Auf die Suche des Minimums wird auch mit dem Terminus *Methode der kleinsten Abweichungsquadrate* oder *Least Mean Square Method* Bezug genommen. Hätten wir nicht nur den einen Parameter $R$ sondern viele Modellparameter, dann würden wir den Gradienten bilden.

$$\frac{\partial}{\partial R} \sum_{i=1}^{J} \left(\frac{\varepsilon_i}{\sigma_\varepsilon}\right)^2 \;=\; 0 \tag{1.12}$$

d.i. in unserem Beispiel

$$\frac{\partial}{\partial R} \sum_{i=1}^{J} \left(\frac{U_i \,-\, R\, I_i}{\sigma_\varepsilon}\right)^2 \;=\; 0 \tag{1.13}$$

Wir multiplizieren mit dem Faktor $\sigma_\varepsilon$

$$\frac{\partial}{\partial R} \sum_{i=1}^{J} (U_i \,-\, R\, I_i)^2 \;=\; 0 \tag{1.14}$$

und führen die Differentiation durch

$$\sum_{i=1}^{J} 2\,(U_i \,-\, R\, I_i)\; I_i \;=\; 0. \tag{1.15}$$

Für viele Modellparameter gäbe es entsprechend viele solche Gleichungen wie es Modellparameter gibt mit den jeweiligen Ableitungen, so dass dann hier ein lineares Gleichungssystem stünde, das zu lösen wäre. Dazu mehr im nächsten Kapitel. Ein numerisches Verfahren zur Lösung linearer Gleichungssysteme ist das Gauß-Jordan-Eliminationsverfahren. Nun wir nur diese eine Gleichung haben, können wir einfach nach $R$ auflösen.

$$\sum_{i=1}^{J} U_i\, I_i \;=\; \sum_{i=1}^{J} R\, I_i\, I_i \tag{1.16}$$

d.h.

$$R \;=\; \frac{\sum\limits_{i=1}^{N} U_i\, I_i}{\sum\limits_{i=1}^{N} I_i^2} \tag{1.17}$$

Der ermittelte Wert für $R$ mit den Daten aus der Tabelle ist 12.34 Ω, siehe Abb. 1.2

Zuvor haben wir die Likelihood ohne Normierungsfaktor aufgeschrieben. Eine Wahrscheinlichkeitsdichteverteilung ist so definiert, dass die Fläche unter ihrer Kurve 1 ist, also die Wahrscheinlichkeit für das Beobachten jedes beliebigen Wertes immer voll eintritt.

$$p(\varepsilon) \;=\; \frac{1}{\sqrt{2\pi}\sigma_\varepsilon}\, e^{-\frac{1}{2}\left(\frac{\varepsilon}{\sigma_\varepsilon}\right)^2} \tag{1.18}$$

Ein Maß für die Breite der Gaußglocke ist das $\sigma_\varepsilon$ bei etwa 60 Prozent der Höhe ($e^{-\frac{1}{2}} \approx 0.6$). Ihr

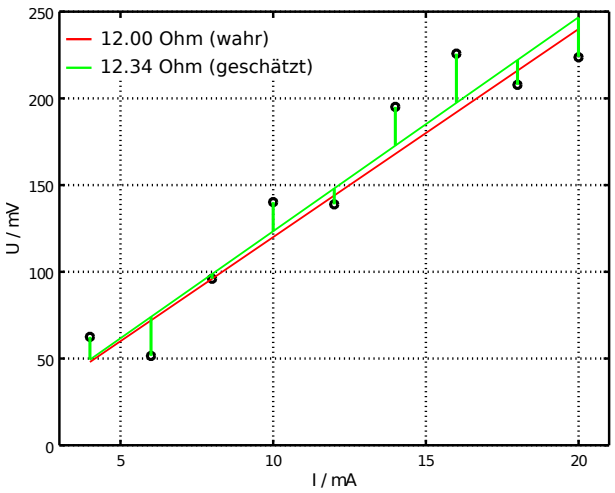



Abbildung 1.3: Regressionsbeispiel: Der geschätze Wert des Modellparameters im Vergleich zum wahren.

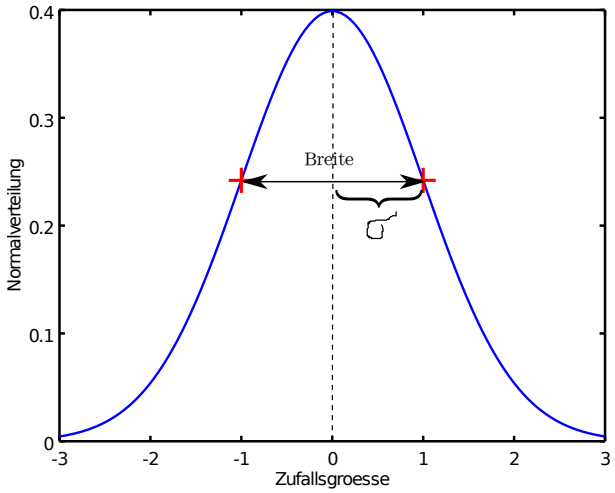



Abbildung 1.4: Breite der Normalverteilung.

Quadrat wird **Varianz** genannt. Das zweite statistische Moment dieser Verteilung

$$\int_{-\infty}^{\infty} \varepsilon^2 \, p(\varepsilon) \, \mathrm{d}\varepsilon \tag{1.19}$$

ist gleich dem Quadrat von $\sigma_\varepsilon$, also der Varianz der Gaußverteilung

$$\int_{-\infty}^{\infty} \varepsilon^2 \, \frac{1}{\sqrt{2\pi}\sigma_\varepsilon} \, e^{-\frac{1}{2}\left(\frac{\varepsilon}{\sigma_\varepsilon}\right)^2} \mathrm{d}\varepsilon \;=\; \sigma_\varepsilon^2. \tag{1.20}$$

Diskretisiert entspricht dies

$$\frac{1}{\sqrt{2\pi}\sigma_\varepsilon} \, e^{-\frac{1}{2}\left(\frac{\varepsilon}{\sigma_\varepsilon}\right)^2} \mathrm{d}\varepsilon \tag{1.21}$$

einer relativen Häufigkeit $\frac{n_k}{J-1}$ in der $k$-ten Klasse der Breite $\mathrm{d}\varepsilon$. Wenn wir nun kein Histogramm mit gleichgroßen Klassenbreiten bilden, sondern zu jedem $\varepsilon_i$ eine Klasse mit der relativen Häufigkeit $\frac{1}{J-1}$

betrachten, dann haben wir so ungefähr für das $\sigma_\varepsilon^2$

$$\sum_{i=1}^{J} \varepsilon_i^2 \frac{1}{J-1} \approx \sigma_\varepsilon^2. \tag{1.22}$$

Wir nennen diese Breite wegen der Näherung nicht $\sigma_\varepsilon^2$. Diese Näherung ist nur ein ungefährer Schätzwert und wird **empirische Varianz** genannt:

$$s_\varepsilon^2 = \frac{1}{J-1} \sum_{i=1}^{J} \varepsilon_i^2 \tag{1.23}$$

Wir unterscheiden zwischen der Varianz und der empirischen Varianz durch die Verwendung der unterschiedlichen Formelzeichen $\sigma$ und $s$.

Uns interessiert aber nicht so sehr die Varianz der Residuen $\varepsilon$, die direkt der Varianz der Spannungsmessung entspricht, als viel mehr die Varianz des Modellparameters $R$. Betrachte die Modellgleichung $R = \frac{U}{I}$, wie empfindlich reagiert die Größe $R$ auf Veränderung der Größe $U$. Wählt man anstelle eines Wertes $U$ einen Wert $U + \Delta U$, so reagiert die Größe $R$ über die Modellgleichung wie folgt

$$R + \Delta R = \frac{1}{I} (U + \Delta U) \tag{1.24}$$

d.i. mit $R = \frac{U}{I}$

$$\Delta R = \frac{1}{I} (\Delta U) \tag{1.25}$$

Der Differenzenquotient ist also

$$\frac{\Delta R}{\Delta U} = \frac{1}{I} \tag{1.26}$$

was bei diesem linearen Zusammenhang direkt hinkommt. Allgemein passt es für stetige Modelle auch bei nichtlinearem Zusammenhang für genügend kleine Änderungen. Deshalb wird die Empfindlichkeit, die **Sensitivität**, definiert als die lokale Steigung

$$c = \frac{\partial R}{\partial U} \tag{1.27}$$

Die Varianz ist eine quadratische Veränderung, so dass

$$s_R^2 = \left(\frac{\partial R}{\partial U}\right)^2 s_\varepsilon^2 = \frac{1}{I^2} s_\varepsilon^2 \tag{1.28}$$

Hier hätte ich auch direkt $s_R$ aufschreiben können, aber die quadratische Schreibweise wird erforderlich, wenn es um mehrere Größen geht. In den folgenden Vorlesungen werden wir das Konzept der Fortpflanzung der Varianzen kennen lernen.

Die Varianzen sind ein Maß für die Unsicherheit von Messungen. Die **Messunsicherheit** ist zentrales Thema in der Messtechnik. Im Wörterbuch der Metrologie (VIM)

`https://www.bipm.org/documents/20126/2071204/JCGM_200_2012.pdf`

wird sie wie folgt definiert:

> **Messunsicherheit; Unsicherheit** (engl. *measurement uncertainty; uncertainty*): nichtnegativer Parameter, der die Streuung der Werte kennzeichnet, die der Messgröße auf der Grundlage der benutzten Information beigeordnet ist. [VIM2.26]

Sie drückt den Mangel einer genauen Kenntnis des Wertes der Messgröße aus. Selbst wenn systematische Effekte korrigiert werden, bleibt der **Messwert** lediglich ein **Schätzwert der Messgröße**, siehe auch GUM:2008, Abschnitt 3.3.1 .

Im Bereich der Metrologie wird zum Thema Messunsicherheitsberechnung eine Richtlinie verwendet, um die Auswerteverfahren im gesetzlichen Messwesen zu vereinheitlichen und die Resultate besser vergleichbar zu machen. Die Richtlinie wurde von der *Working Group* 1 des *Joint Committee for Guides in Metrology* (JCGM/WG 1) entwickelt. Sie hat den Titel *Evaluation of measurement data - Guide to the expression of uncertainty in measurement* und wird mit GUM abgekürzt. Die derzeit gültige Version ist *JCGM 100:2008 GUM 1995 with minor corrections* und ist in englischer Fassung auf der Webseite des *Bureau international des poids et mesures* (BIPM) unter folgendem Link frei erhältlich:

`https://www.bipm.org/documents/20126/2071204/JCGM_100_2008_E.pdf`

In vielen Fällen reicht es, die Varianzen der einzelnen direkten Messgrößen zu untersuchen sowie den Zusammenhang zwischen der Variation einer direkten Messgröße und die dadurch verusachte Veränderung der indirekten, also die Empfindlichkeit/Sensitivität. Dieser Zusammenhang ist zentrales Thema der Bestimmung von Messunsicherheiten und wird im Laufe dieser Vorlesung eingehend beleuchtet. Vielfach gibt es nicht nur einen Zusammenhang zwischen einer direkten mit einer indirekten Messgröße, sondern auch einen Zusammenhang zwischen den direkten Messgrößen untereinander.

In dieser Vorlesungsreihe liegt das Hauptaugenmerk auf linearen Zusammenhängen zwischen Messgrößen. Für viele Anwendungen greifen lineare Ansätze. Wenn die betrachteten Bereiche der Variation von Größen genügend klein sind, so lassen sich auch nichtlineare Modelle durch eine Linearisierung in einer gewissen Umgebung approximieren.

Das Maß für den linearen Zusammenhang wird **Korrelation** genannt. Bei der linearen Regression geht es um Modelle mit indirekten Messgrößen, die als Koeffizienten eines Polynoms auftreten. Um den Grad des Polynoms zu ermitteln, wird untersucht mit welchem Potenzgesetz ein Paar direkter Messgrößen zu verknüpfen ist (welchen Grad das Polynom hat), so dass die Korrelation groß ist.

## 1.3 Ko-Varianzen von Zufallsgrößen

Bei dem Beispiel mit dem Ohm'schen Gesetz hatten wir uns mit der Modellgleichung $U = RI$ befasst. Dabei waren $U$ und $I$ die beiden physikalischen Größen, die proportional unterschiedliche Werte annehmen. Sie sind direkt über einen linearen Zusammenhang verknüpft. Der lineare Zusammenhang wird durch eine Gerade, ein Polynom vom Grad 1, dargestellt.

Für die Charakterisierung *linearer* Zusammenhänge ist der **Korrelationskoeffizient** $\rho$ ein Maß, mit dem quantifiziert wird, wie stark zwei Größen linear miteinander verknüpft sind. Der Korrelationskoef-

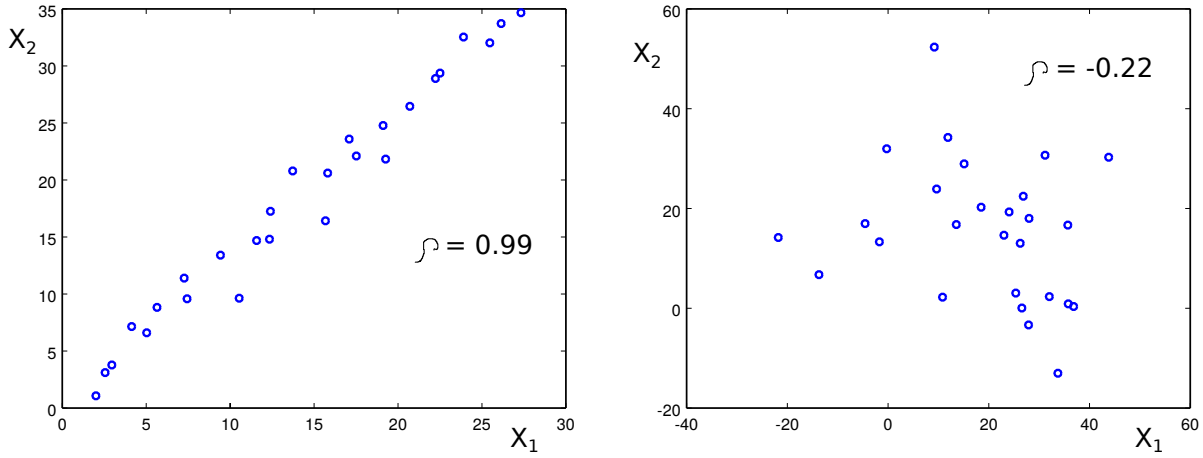



Abbildung 1.5: Wenn es einen linearen Zusammenhang zwischen zwei Zufallsgrößen $X_1$ und $X_2$ gibt, so sagt man, dass sie korreliert sind und der Korrelationskoeffizient $\rho$ liegt bei Eins (*links*) oder bei minus Eins. Wenn es keinen Zusammenhang zwischen zwei Zufallsgrößen $X_1$ und $X_2$ gibt, so sagt man, dass sie unkorreliert sind und der Korrelationskoeffizient $\rho$ liegt bei Null (*rechts*).

fizient ist so definiert, dass er Werte zwischen $-1$ und 1 annehmen kann. Gibt es einen direkten linearen Zusammenhang zwischen zwei Zufallsgrößen $X_1$ und $X_2$, so wird man zu einer Beobachtung der einen Größe mit kleinem Wert auch einen kleinen Wert bei der anderen Größe beobachten und wenn die eine Größe einen großen Wert annimmt, so wird die andere auch einen großen Wert annehmen, und $\rho$ wird in der Nähe von 1 liegen. Haben zwei Zufallsgrößen einen ebenso direkten Zusammenhang, aber in umgekehrter Weise, dass zu kleinen Werten von der ersten Größe große Werte zur zweiten Größe auftreten und umgekehrt, so liegt $\rho$ in der Nähe von $-1$. In beiden Fällen sagt man, dass die Größen **korreliert** seien.

Gibt es überhaupt gar keinen Zusammenhang zwischen dem, was an Werten zu der einen Größe beobachtet wird mit dem, was an Werten zur anderen Größe beobachtet wird, so ist $\rho = 0$ und man sagt: Die beiden Größen seien **unkorreliert**.

Die Erwartungswerte zu jeder der Größen $X_1$ und $X_2$ sind jeweils $\mathrm{E}(X_1)$ und $\mathrm{E}(X_2)$. Sie werden aus den Mittelwerten der jeweiligen Stichproben geschätzt

$$\bar{x}_1 = \frac{1}{J}\sum_{j=1}^{J} X_{1,j} \qquad \bar{x}_2 = \frac{1}{J}\sum_{j=1}^{J} X_{2,j} \tag{1.29}$$

Dann ist

$$\bar{\mathbf{X}} = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \end{pmatrix} \tag{1.30}$$

der Schwerpunkt der Beobachtungen der Größen. Sind die Entfernungen der Beobachtungspärchen $(X_{1,j}, X_{2,j})$ vom Schwerpunkt so, dass die Entfernung der Größe $X_1$ in die gleiche Richtung weist wie die Entfernung der Größe $X_2$, so liefern die Produkte $(X_{1,j}-\bar{x}_1)(X_{2,j}-\bar{x}_2)$ gleiche Vorzeichen. Streuen diese aber unzusammenhängend, so mitteln sich die unterschiedlichen Terme $(X_{1,j}-\bar{x}_1)(X_{2,j}-\bar{x}_2)$ bei Summation weg.

Wir definieren die Größe

$$s_{1,2} := \frac{1}{J-1} \sum_{j=1}^{J} (X_{1,j} - \bar{x}_1)(X_{2,j} - \bar{x}_2) \tag{1.31}$$

und nennen sie die **empirische Kovarianz**. Allgemein ist die **Kovarianz** für Zufallsgrößen, deren gemeinsame Verteilung ihre Wahrscheinlichkeitsdichte $p(X_1, X_2)$ sei, wie folgt definiert

$$\mathrm{Cov}(X_1, X_2) := \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (X_1' - \mathrm{E}(X_1))(X_2' - \mathrm{E}(X_2))\, p(X_1', X_2')\, \mathrm{d}\, X_1'\, \mathrm{d}\, X_2'. \tag{1.32}$$

Wir sehen hier, dass die Kovarianz einer Zufallsgröße mit sich selbst die **Varianz** ist

$$\mathrm{Var}(X_1) := \mathrm{Cov}(X_1, X_1) = \int_{-\infty}^{\infty} (X_1' - \mathrm{E}(X_1))^2\, p(X_1')\, \mathrm{d}\, X_1' \tag{1.33}$$

und für die empirsche Varianz und Kovarianz gilt entsprechend

$$s_1^2 := s_{1,1} = \frac{1}{J-1} \sum_{j=1}^{J} (X_{1,j} - \bar{x}_1)^2. \tag{1.34}$$

Wir werden im nächsten Kapitel sehen, dass bei der Steigung der Regressionsgraden (Aufgabe 1) genau so ein Term $\sum_{j=1}^{J} (X_{1,j} - \bar{x}_1)(X_{2,j} - \bar{x}_2)$ im Zähler steht.

Für standardnormalverteilte Zufallsgrößen $Z_i$ mit $Z \sim \mathcal{N}(0, 1)$ und $i = 1, 2$ in die sich die Größen $X_i$ wie folgt umrechnen lassen

$$Z_i = \frac{X_i - \mathrm{E}(X_i)}{\sqrt{\mathrm{Var}(X_i)}} \tag{1.35}$$

ist die Kovarianz gleich dem Korrelationskoeffizienten

$$\rho_{i,k} = \mathrm{Cov}(Z_i, Z_k) \tag{1.36}$$

was äquivalent ist zu

$$\rho_{i,k} = \frac{\mathrm{Cov}(X_i, X_k)}{\sqrt{\mathrm{Var}(X_i)}\, \sqrt{\mathrm{Var}(X_k)}}. \tag{1.37}$$

Für das Verständnis der Gesamtzusammenhänge ist der Sprachgebrauch für Zufallsgrößen sowie der Sprachgebrauch des Erwartungswertes von Zufallgrößen von Bedeutung.

Verknüpfungen von Zufallsgrößen sind ihrerseits wieder Zufallsgrößen. Betrachten wir eine Größe $X$, die ganz abstrakt und allgemein eine Zufallsgröße ist, und $p(X)$ die Wahrscheinlichkeitsdichteverteilung dazu, so heißt

$$\mathrm{E}(X) := \int_{-\infty}^{\infty} X'\, p(X')\, \mathrm{d}\, X' \tag{1.38}$$

Erwartungswert der Zufallsgröße $X$.

Zur Berechnung der Varianz einer indirekten Messgröße, die linear abhängig ist von direkten Messgrößen, benötigen wir die algebraischen Grundregeln für Erwartungswerte: Addition, Multiplikation und

Skalierung.

- Summe: $X = X_1 + X_2$

$$\mathrm{E}(X_1 + X_2) \;:=\; \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} (X_1' + X_2')\, p(X_1', X_2')\; \mathrm{d}\, X_1'\; \mathrm{d}\, X_2' \tag{1.39}$$

d.h.

$$\begin{aligned} \mathrm{E}(X_1 + X_2) \;&=\; \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} X_1'\, p(X_1', X_2')\; \mathrm{d}\, X_1'\; \mathrm{d}\, X_2' \\ &\quad + \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} X_2'\, p(X_1', X_2')\; \mathrm{d}\, X_1'\; \mathrm{d}\, X_2' \end{aligned} \tag{1.40}$$

und mit der Randverteilung (engl. *marginal distribution*)

$$p(X_2) \;=\; \int_{-\infty}^{\infty} p(X_1', X_2)\; \mathrm{d}\, X_1' \tag{1.41}$$

erhalten wir

$$\mathrm{E}(X_1 + X_2) \;=\; \int_{-\infty}^{\infty} X_1'\, p(X_1')\; \mathrm{d}\, X_1' \;+\; \int_{-\infty}^{\infty} X_2'\, p(X_2')\; \mathrm{d}\, X_2' \tag{1.42}$$

also

$$\mathrm{E}(X_1 + X_2) \;=\; \mathrm{E}(X_1) \;+\; \mathrm{E}(X_2). \tag{1.43}$$

In Worten heißt dies: Der Erwartungswert einer Summe von Zufallsgrößen ist die Summe der Erwartungswerte der Zufallsgrößen.

- Produkt: $X = X_1 \cdot X_2$

$$\mathrm{E}(X_1 \cdot X_2) \;:=\; \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} X_1'\, X_2'\, p(X_1', X_2')\; \mathrm{d}\, X_2'\; \mathrm{d}\, X_1'. \tag{1.44}$$

Die Kovarianz ist der Erwartungswert folgenden Produktes $(X_1 - \mathrm{E}(X_1)) \cdot (X_2 - \mathrm{E}(X_2))$

$$\mathrm{E}((X_1 - \mathrm{E}(X_1)) \cdot (X_2 - \mathrm{E}(X_2))) \;=\; \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} (X_1' - \mathrm{E}(X_1)) \cdot (X_2' - \mathrm{E}(X_2))\, p(X_1', X_2')\; \mathrm{d}\, X_1'\; \mathrm{d}\, X_2' \tag{1.45}$$

also

$$\mathrm{Cov}(X_1, X_2) \;=\; \mathrm{E}\left((X_1 - \mathrm{E}(X_1)) \cdot (X_2 - E(X_2))\right). \tag{1.46}$$

und auch

$$\begin{aligned} \mathrm{Cov}(X_1, X_2) \;&=\; \mathrm{E}\left(X_1\, X_2 - X_2\; \mathrm{E}(X_1) - X_1\; \mathrm{E}(X_2) + \mathrm{E}(X_1)\; \mathrm{E}(X_2)\right) \\ &=\; \mathrm{E}(X_1\, X_2) - \mathrm{E}(X_2)\; \mathrm{E}(X_1) - \mathrm{E}(X_1)\; \mathrm{E}(X_2) + \mathrm{E}(X_1)\; \mathrm{E}(X_2)) \\ &=\; \mathrm{E}(X_1\, X_2) - \mathrm{E}(X_1)\; \mathrm{E}(X_2). \end{aligned} \tag{1.47}$$

Per Definitionem gilt

$$\mathrm{Var}(X) \;:=\; \mathrm{Cov}(X, X) \tag{1.48}$$

- Skalierung: Zufallsgröße $X$ mit einem konstanten, festen reellen Faktor $b$ multiplizieren

$$\begin{aligned} \mathrm{Var}(bX) &= \mathrm{E}((bX)^2) = \int_{-\infty}^{\infty} (bX')^2\, p(X')\, \mathrm{d}\, X' \\ &= \int_{-\infty}^{\infty} b^2\, (X')^2\, p(X')\, \mathrm{d}\, X' \\ &= b^2 \underbrace{\int_{-\infty}^{\infty} (X')^2\, p(X')\, \mathrm{d}\, X'}_{\mathrm{Var}(X)} \end{aligned} \tag{1.49}$$

$$\mathrm{Var}(bX) := b^2\, \mathrm{Var}(X) \tag{1.50}$$

Wenn wir die Varianz einer indirekten Messgröße, die linear von mehreren direkten Messgrößen abhängt, ermitteln wollen, so entspricht dies der Bestimmung der **Varianz einer Summe von Zufallsgrößen**. Sie ist gleich der Summe der paarweisen Kovarianzen aller Zufallsgrößen (hier der direkten Messgrößen)

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i\, X_i\right) = \sum_{i,j=1}^{N} \mathrm{Cov}(c_i X_i, c_j X_j) \tag{1.51}$$

Wir leiten jetzt her, weshalb Gl. (1.51) gilt: Die Varianz ist gemäß ihrer Definition

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i X_i\right) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \left[\left(\sum_{i=1}^{N} c_i X_i\right) - E(\sum_{i=1}^{N} c_i X_i)\right]^2 p(X_1, \ldots, X_N)\, \mathrm{d}\, X_1 \ldots \mathrm{d}\, X_N. \tag{1.52}$$

Da der Erwartungswert einer Summe von Zufallsgrößen gleich der Summe der Erwartungswerte jeder einzelnen dieser Zufallsgrößen ist, siehe Gl. (1.43), gilt

$$\left(\sum_{i=1}^{N} X_i\right) - E(\sum_{i=1}^{N} X_i) = \left(\sum_{i=1}^{N} X_i\right) - \sum_{i=1}^{N} E(X_i)$$

so dass gilt

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i X_i\right) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \left[\sum_{i=1}^{N} (c_i X_i - E(c_i X_i))\right]^2 p(X_1, \ldots, X_N)\, \mathrm{d}\, X_1 \ldots \mathrm{d}\, X_N \tag{1.53}$$

und mit $E(c_i X_i) = c_i E(X_i)$ also

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i X_i\right) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \left[\sum_{i=1}^{N} c_i\, (X_i - E(X_i))\right]^2 p(X_1, \ldots, X_N)\, \mathrm{d}\, X_1 \ldots \mathrm{d}\, X_N. \tag{1.54}$$

Mit Anwendung des Assoziativgesetzes

$$\begin{aligned} \left[\sum_{i=1}^{N} c_i\, (X_i - E(X_i))\right]^2 &= \left[\sum_{i=1}^{N} c_i\, (X_i - E(X_i))\right] \left[\sum_{k=1}^{N} c_k\, (X_k - E(X_k))\right] \\ &= \sum_{i=1}^{N} \sum_{k=1}^{N} c_i c_k\, (X_i - E(X_i))\, (X_k - E(X_k)) \end{aligned}$$

gilt

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i X_i\right) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \sum_{i=1}^{N}\sum_{k=1}^{N} c_i c_k \left(X_i - E(X_i)\right)\left(X_k - E(X_k)\right) p(X_1, \ldots, X_N)\, \mathrm{d}X_1 \ldots \mathrm{d}X_N. \tag{1.55}$$

Durch Berechnung der Marginalverteilungen und weil $\int p(X_j)\, \mathrm{d}X_j = 1$ für alle $j$, die weder $i$ noch $k$ sind, erhalten wir

$$\mathrm{Var}\left(\sum_{i=1}^{N} c_i X_i\right) = \sum_{i=1}^{N}\sum_{k=1}^{N} c_i c_k \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \left(X_i - E(X_i)\right)\left(X_k - E(X_k)\right) p(X_i, X_k)\, \mathrm{d}X_i\, \mathrm{d}X_k, \tag{1.56}$$

so dass

$$\begin{aligned} \mathrm{Var}\left(\sum_{i=1}^{N} c_i\, X_i\right) &= \sum_{i=1}^{N}\sum_{k=1}^{N} \mathrm{Cov}(c_i X_i, c_k X_k) \\ &= \sum_{i=1}^{N} c_i^2\ \mathrm{Var}(X_i) + \sum_{i,k=1, i\neq k}^{N} c_i c_k\ \mathrm{Cov}(X_i, X_k) \\ &= \sum_{i=1}^{N} c_i^2\, \mathrm{Var}(X_i) + 2\sum_{i=1}^{N-1}\sum_{k=i+1}^{N} c_i c_k\, \mathrm{Cov}(X_i, X_k). \end{aligned} \tag{1.57}$$

Die ist das **Gesetz der Fortpflanzung von Messunsicherheiten**, mit dem wir uns im Laufe dieser Vorlesungsreihe eingehend befassen werden.

## 1.4 Beispiel zur Methode der kleinsten Quadrate zum Selbststudium

Zu Bestimmen ist ein Ohmscher Widerstand $R$ sowie eine Offsetspannung $U_0$ bei gegebenen Werten einer Präzisionsstromquelle und eines Voltmeters:

| $I$ in mA | 4.0 | 6.0 | 8.0 | 10.0 | 12.0 | 14.0 | 16.0 | 18.0 | 20.0 |
|---|---|---|---|---|---|---|---|---|---|
| $U$ in mV | 62.5 | 51.5 | 96.0 | 140.2 | 138.9 | 195.1 | 225.8 | 207.8 | 223.7 |

Es wird angenommen, dass die Stromstärken ohne Streuung vorliegen (als Regressoren) und die Spannungen normalverteilt streuen (als Regressanden), so dass

$$\min_{R,U_0} \sum_{i=1}^{J} (U_i - R\,I_i - U_0)^2 \tag{1.58}$$

(a) Berechnen Sie den Korrelationskoeffizienten $\rho(I, U)$

(b) Lösen Sie das Gleichungssystem

$$\begin{pmatrix} \frac{\partial}{\partial R} \\ \frac{\partial}{\partial U_0} \end{pmatrix} \sum_{i=1}^{J} (U_i - R\,I_i - U_0)^2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{1.59}$$

(c) Berechnen Sie die aus der Lösung des Gleichungssystems aus (b) gewonnen Schätzwerte für $R$ und $U_0$.

# Kapitel 2

# Lineare Regression (Ausgleichsrechnung)

## 2.1 Die Idee der linearen Regression

Regression beschreibt den Zusammenhang zwischen vorgegebenen Eingangsgrößen und einer beobachteten Ausgangsgröße. In der Schreibweise dieses Kapitels heißen die Eingangsgrößen **Regressoren** und die Ausgangsgröße **Regressand**. Die Eingangsgrößen sind die unabhängigen Größen, die Ausgangsgröße is die abhängige Größe.

Für $J$ Beobachtungen schreiben wir allgemein

$$Y_j = f(X_{1,j}, \ldots, X_{i,j}, \ldots, X_{N,j}) + \varepsilon_j \quad \text{mit} \quad j = 1, 2, \ldots, J. \tag{2.1}$$

Dabei ist $Y_j$ der beobachtete Wert des Regressanden $Y$ zur $j$-ten Einstellung der Regressoren $X_{i,j}$. Die Abweichung $\varepsilon_j$ heißt **Residuum**. Sie fasst die Streuung der Beobachtung und die Abweichung des gewählten Modells vom realen Zusammenhang zusammen.

In diesem Kapitel betrachten wir die **univariate Regression**, also den Fall mit genau einer abhängigen Größe $Y$. Gibt es mehrere abhängige Größen, spricht man von **multivariater Regression**. Der Begriff **lineare Regression** bedeutet dabei nicht, dass das Modell als Funktion von $X$ immer eine Gerade sein muss. Linear heißt: Das Modell ist linear in den unbekannten Modellparametern. Deshalb sind auch Polynome wie

$$p_m(X) = \theta_0 + \theta_1 X + \theta_2 X^2 + \cdots + \theta_m X^m \tag{2.2}$$

lineare Regressionsmodelle, denn die Parameter $\theta_0, \theta_1, \ldots, \theta_m$ treten nur linear auf.

Im einfachsten Fall wird der funktionale Zusammenhang zwischen einem Regressor und einem Regressanden geschrieben als

$$Y = f(X). \tag{2.3}$$

Für Messdaten erhält man wegen der Streuung nicht exakt $Y_j = f(X_j)$, sondern

$$Y_j = f(X_j) + \varepsilon_j \quad \text{mit} \quad j = 1, 2, \ldots, J. \tag{2.4}$$

Für die klassische lineare Regression nehmen wir an:

- Die Regressoren (unabhängigen Größen) $X$ bzw. $X_i$ werden vorgegeben. Ihre Werte gelten im Modell als genau bekannt (engl. *exactly known values*) und werden nicht als Zufallsgrößen behandelt.
- Der Regressand (die abhängige Größe) $Y$ streut. Die Residuen sind **unabhängig und identisch verteilt** mit Erwartungswert Null und konstanter Varianz:

  $$\varepsilon_j \overset{u.i.v.}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2). \tag{2.5}$$

  Die Regressanden werden auf Grund ihrer Streuung als Zufallsgrößen betrachtet. Zu jedem beobachteten Wert des Regressanden wird jeweils ein Regressorwert zugeordnet (engl. *observed data corresponding to the known values*). Sie sind abhängig vom Regressor und werden deshalb auch *dependent variable* oder *response variable* genannt.

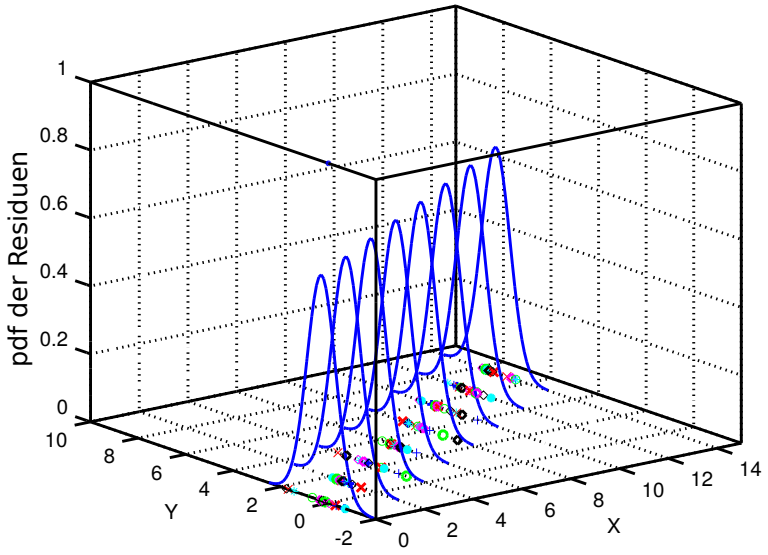



Abbildung 2.1: Lineare Regression für unabhängig und identisch verteilte Residuen.

- Die unbekannten Modellparameter sind feste, aber unbekannte Größen (*unknown parameters*). Ihre Schätzwerte $\hat{\theta}_i$ hängen von den Messdaten ab und sind deshalb Zufallsgrößen.

- Ferner gibt es zusätzliche unbekannte Parameter, und zwar die Varianzen der beteiligten Zufallsgrößen, *unknown additional parameters*.

- Für ein eindeutiges Ergebnis müssen die Regressoren im verwendeten Ansatz linear unabhängig sein. Bei Polynomen bedeutet dies praktisch: Es müssen genügend unterschiedliche $X$-Werte vorliegen, damit die Spalten der späteren Regressormatrix unabhängig sind.

Abb. 2.1 veranschaulicht die Annahme normalverteilter Residuen. Die vertikale Achse zeigt die Wahrscheinlichkeitsdichte der Residuen; der englische Begriff dafür ist *probability density function*, kurz pdf. Die unterschiedlichen Farben und Symbole stehen für wiederholte Durchläufe desselben Messvorgangs.

## 2.2 Lineare Regression als Methode der kleinsten Abweichungsquadrate

Die Modellparameter werden so bestimmt, dass die Summe der quadrierten **Residuen** möglichst klein wird. Mit dem Begriff **Residuum** wird die Abweichung eines Datenpunktes von dem Modell bezeichnet, das Formelsymbol dafür ist $\varepsilon_j$. Für ein Modell $f(X)$ lautet die **Kostenfunktion** bzw. **Zielfunktion**

$$Q := \sum_{j=1}^{J} \varepsilon_j^2 = \sum_{j=1}^{J} \left(Y_j - f(X_j)\right)^2 \;\longrightarrow\; \min\,. \tag{2.6}$$

Die Kostenfunktion ist ein Maß dafür, wie stark die Messwerte vom Modell abweichen. Werden die optimalen Schätzwerte eingesetzt, dient $Q$ als **Qualitätsmaß** der Anpassung. Bei normalverteilten Residuen entspricht die Minimierung von $Q$ dem Maximieren der Likelihood. Da diesem Verfahren die Annahme als Voraussetzung zugrunde liegt, dass die Likelihood gaußverteilt ist, spricht man in der ingenieurmäßigen Anwendung auch vom Ausgleichsverfahren nach Gauß.

### 2.2.1 Polynomansatz ohne Matrixschreibweise

Ein Polynom $m$-ten Grades hat die Form

$$p_m(X) = \theta_0 + \theta_1 X + \theta_2 X^2 + \cdots + \theta_m X^m = \sum_{i=0}^{m} \theta_i X^i. \tag{2.7}$$

Der Grad des Polynoms ist $m$, die Anzahl der Regressionsparameter ist $M = m + 1$. Unter Berücksichtigung der Streuung der Beobachtungen $Y_j$ lautet das Regerssionsmodell

$$Y_j = p_m(X_j) + \varepsilon_j = \sum_{i=0}^{m} \theta_i X_j^i + \varepsilon_j. \tag{2.8}$$

Die Kostenfunktion wird damit zu

$$Q(\theta_0, \theta_1, \ldots, \theta_m) = \sum_{j=1}^{J} \left( Y_j - \sum_{i=0}^{m} \theta_i X_j^i \right)^2 \longrightarrow \min. \tag{2.9}$$

Das Minimum erhält man, indem alle partiellen Ableitungen nach den Modellparametern gleich Null gesetzt werden:

$$\left. \frac{\partial Q}{\partial \theta_i} \right|_{\theta_i = \hat{\theta}_i} = 0, \quad i = 0, 1, \ldots, m. \tag{2.10}$$

So entstehen $m + 1$ lineare Gleichungen für die $m + 1$ unbekannten Parameter $\hat{\theta}_i$.

Für ein quadratisches Polynom

$$Y_j = \theta_0 + \theta_1 X_j + \theta_2 X_j^2 + \varepsilon_j \tag{2.11}$$

ergeben sich aus Gl. (2.10) folgendes lineare Gleichungssystem

$$\begin{aligned} J\hat{\theta}_0 + \hat{\theta}_1 \sum_{j=1}^{J} X_j + \hat{\theta}_2 \sum_{j=1}^{J} X_j^2 &= \sum_{j=1}^{J} Y_j, \\ \hat{\theta}_0 \sum_{j=1}^{J} X_j + \hat{\theta}_1 \sum_{j=1}^{J} X_j^2 + \hat{\theta}_2 \sum_{j=1}^{J} X_j^3 &= \sum_{j=1}^{J} X_j Y_j, \\ \hat{\theta}_0 \sum_{j=1}^{J} X_j^2 + \hat{\theta}_1 \sum_{j=1}^{J} X_j^3 + \hat{\theta}_2 \sum_{j=1}^{J} X_j^4 &= \sum_{j=1}^{J} X_j^2 Y_j. \end{aligned} \tag{2.12}$$

Dieses Beispiel zeigt den Übergang zur Matrixschreibweise bereits an: Die Matrixschreibweise fasst solche linearen Gleichungssysteme, wie wir später sehen werden, nur kompakter zusammen.

Sind die Schätzwerte eingesetzt, erhält man die geschätzte Modellfunktion

$$\hat{p}_m(X) = \hat{\theta}_0 + \hat{\theta}_1 X + \hat{\theta}_2 X^2 + \cdots + \hat{\theta}_m X^m. \tag{2.13}$$

Ein Schätzwert für die Varianz der Residuen ist

$$\hat{\sigma}_\varepsilon^2 = s^2 = \frac{Q(\hat{\theta}_0, \hat{\theta}_1, \ldots, \hat{\theta}_m)}{J - M} = \frac{Q(\hat{\theta}_0, \hat{\theta}_1, \ldots, \hat{\theta}_m)}{J - m - 1}. \tag{2.14}$$

### 2.2.2 Regressionsgerade ohne Matrixschreibweise

Die Gerade ist der Spezialfall $m = 1$:

$$Y = \theta_0 + \theta_1 X. \tag{2.15}$$

Hier ist $\theta_0$ der Achsenabschnitt und $\theta_1$ die Steigung. Für die Messwerte gilt

$$Y_j = \theta_0 + \theta_1 X_j + \varepsilon_j. \tag{2.16}$$

Die Kostenfunktion lautet

$$Q(\theta_0, \theta_1) = \sum_{j=1}^{J} (Y_j - (\theta_0 + \theta_1 X_j))^2 \;\longrightarrow\; \min. \tag{2.17}$$

Zum Auffinden des Minimums werden die partiellen Ableitungen nach $\theta_0$ und $\theta_1$ gleich Null gesetzt:

$$\begin{aligned} \left.\frac{\partial Q}{\partial \theta_0}\right|_{\theta_0=\hat{\theta}_0,\,\theta_1=\hat{\theta}_1} &= 0, \\ \left.\frac{\partial Q}{\partial \theta_1}\right|_{\theta_0=\hat{\theta}_0,\,\theta_1=\hat{\theta}_1} &= 0. \end{aligned} \tag{2.18}$$

Aus den Ableitungen folgen die Normalgleichungen

$$J\hat{\theta}_0 + \hat{\theta}_1 \sum_{j=1}^{J} X_j = \sum_{j=1}^{J} Y_j, \tag{2.19}$$

$$\hat{\theta}_0 \sum_{j=1}^{J} X_j + \hat{\theta}_1 \sum_{j=1}^{J} X_j^2 = \sum_{j=1}^{J} X_j Y_j. \tag{2.20}$$

Mit den Mittelwerten

$$\bar{X} = \frac{1}{J}\sum_{j=1}^{J} X_j \quad \text{und} \quad \bar{Y} = \frac{1}{J}\sum_{j=1}^{J} Y_j$$

ergibt die erste Normalgleichung

$$\hat{\theta}_0 = \bar{Y} - \hat{\theta}_1 \bar{X}. \tag{2.21}$$

Setzt man dies in die zweite Normalgleichung ein, erhält man für die Steigung

$$\hat{\theta}_1 = \frac{\sum_{j=1}^{J} (X_j - \bar{X})(Y_j - \bar{Y})}{\sum_{j=1}^{J} (X_j - \bar{X})^2}. \tag{2.22}$$

Damit lauten die Schätzgleichungen der Regressionsgeraden

$$\hat{\theta}_0 = \bar{Y} - \hat{\theta}_1 \bar{X} \quad \text{und} \quad \hat{\theta}_1 = \frac{s_{XY}}{s_X^2}, \tag{2.23}$$

wobei

$$s_X^2 = \frac{1}{J-1}\sum_{j=1}^{J} (X_j - \bar{X})^2 \quad \text{und} \quad s_{XY} = \frac{1}{J-1}\sum_{j=1}^{J} (X_j - \bar{X})(Y_j - \bar{Y})$$

die empirische Varianz von $X$ und die empirische Kovarianz von $X$ und $Y$ sind. Der Punkt $(\bar{X}, \bar{Y})$ liegt immer auf der Regressionsgeraden.

Für die Residuenvarianz der Geraden folgt aus Gl. (2.14) mit $M = 2$:

$$\hat{\sigma}_\varepsilon^2 = \frac{Q(\hat{\theta}_0, \hat{\theta}_1)}{J-2}. \tag{2.24}$$

## 2.3 Matrixformalismus zur allgemeinen Lösung der linearen Regression

### 2.3.1 Matrixformalismus anhand der Regressionsgeraden

Als Regressormatrix verwenden wir jetzt

$$\mathbf{X} = \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix} \tag{2.25}$$

Die Residuen berechnen sich wie folgt:

$$\begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} = \begin{pmatrix} Y_1 - (1\,\theta_0 + X_{1,1}\,\theta_1) \\ \vdots \\ Y_J - (1\,\theta_0 + X_{1,J}\,\theta_1) \end{pmatrix} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_J \end{pmatrix} - \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} \tag{2.26}$$

Die Summe der Quadrate der Residuen $\sum_{j=1}^{J} \varepsilon_j^2$ lässt sich ebenso mit der Rechenregel Zeile mal Spalte schreiben, als Zeilenvektor mal Spaltenvektor

$$\sum_{j=1}^{J} \varepsilon_j^2 = \begin{pmatrix} \varepsilon_1 & \dots & \varepsilon_J \end{pmatrix} \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} \tag{2.27}$$

Dabei heißt der Zeilenvektor der transponierte Vektor, also

$$\boldsymbol{\varepsilon}^\mathsf{T} = \begin{pmatrix} \varepsilon_1 & \dots & \varepsilon_J \end{pmatrix} \quad \text{und} \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} \tag{2.28}$$

und ferner führen wir ein

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} \quad \text{und} \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_J \end{pmatrix} \tag{2.29}$$

und Gl. (2.26) sieht in transponierter Schreibweise wie folgt aus

$$\boldsymbol{\varepsilon}^{\mathsf{T}} \;=\; \mathbf{Y}^{\mathsf{T}} \;-\; \boldsymbol{\theta}^{\mathsf{T}} \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix}^{\mathsf{T}} \tag{2.30}$$

d.h.

$$\boldsymbol{\varepsilon}^{\mathsf{T}} \;=\; \mathbf{Y}^{\mathsf{T}} \;-\; \begin{pmatrix} \theta_0 & \theta_1 \end{pmatrix} \begin{pmatrix} 1 & \dots & 1 \\ X_{1,1} & \dots & X_{1,J} \end{pmatrix}. \tag{2.31}$$

Die Summe der Quadrate der Residuen $\sum_{j=1}^{J} \varepsilon_j^2$ sieht damit wie folgt aus

$$\boldsymbol{\varepsilon}^{\mathsf{T}}\boldsymbol{\varepsilon} \;=\; \left(\mathbf{Y}^{\mathsf{T}} \;-\; \boldsymbol{\theta}^{\mathsf{T}}\mathbf{X}^{\mathsf{T}}\right)(\mathbf{Y} \;-\; \mathbf{X}\boldsymbol{\theta}) \tag{2.32}$$

d.h.

$$\boldsymbol{\varepsilon}^{\mathsf{T}}\boldsymbol{\varepsilon} \;=\; \mathbf{Y}^{\mathsf{T}}\mathbf{Y} \;-\; \boldsymbol{\theta}^{\mathsf{T}}\mathbf{X}^{\mathsf{T}}\mathbf{Y} \;-\; \mathbf{Y}^{\mathsf{T}}\mathbf{X}\boldsymbol{\theta} \;+\; \boldsymbol{\theta}^{\mathsf{T}}\mathbf{X}^{\mathsf{T}}\mathbf{X}\boldsymbol{\theta} \tag{2.33}$$

Für die Ableitungen nach den $\theta_0, \theta_1$ gilt

$$\frac{\partial}{\partial\theta_l}\sum_{j=1}^{J}\varepsilon_j^2 \;=\; 2\sum_{j=1}^{J}\varepsilon_j\frac{\partial}{\partial\theta_l}\varepsilon_j \;=\; 2\sum_{j=1}^{J}\varepsilon_j(-1)\frac{\partial}{\partial\theta_l}(1\,\theta_0 \;+\; X_{1,j}\,\theta_1) \;=\; 0 \tag{2.34}$$

wobei $l = 0, 1$ ist also

$$\sum_{j=1}^{J}\varepsilon_j\frac{\partial}{\partial\theta_0}(1\,\theta_0 \;+\; X_{1,j}\,\theta_1) \;=\; 0 \qquad \text{und} \qquad \sum_{j=1}^{J}\varepsilon_j\frac{\partial}{\partial\theta_1}(1\,\theta_0 \;+\; X_{1,j}\,\theta_1) \;=\; 0 \tag{2.35}$$

also

$$\sum_{j=1}^{J}\varepsilon_j(1) \;=\; 0 \qquad \text{und} \qquad \sum_{j=1}^{J}\varepsilon_j(X_{1,j}) \;=\; 0 \tag{2.36}$$

Dies sieht in Matrixschreibweise als Gleichungssystem mit zwei Gleichungen wie folgt aus

$$\mathbf{X}^{\mathsf{T}}\,\boldsymbol{\varepsilon} \;=\; \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{2.37}$$

d.h.

$$\mathbf{X}^{\mathsf{T}}\,(\mathbf{Y} \;-\; \mathbf{X}\boldsymbol{\theta}) \;=\; \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{2.38}$$

d.h.

$$\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\boldsymbol{\theta} \;=\; \mathbf{X}^{\mathsf{T}}\,\mathbf{Y}. \tag{2.39}$$

Die numerische Lösung des Gleichungssystems liefert dann die Schätzwerte zu den Regressionsparametern $\boldsymbol{\theta}$. Ein mögliches Verfahren zum Lösen des linearen Gleichungssystems ist das Gauß-Jordan-Eliminationsverfahren, zu dem im Anhang dieses Skripts der Quellcode gemäß den *Numerical Recipes* [Fla02] abgedruckt ist. Formal notieren wir die Schätzer (als solche kenntlich durch das Dach) wie folgt

$$\hat{\boldsymbol{\theta}} \;=\; \left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\mathbf{X}^{\mathsf{T}}\,\mathbf{Y} \tag{2.40}$$

wobei hoch minus Eins soviel bedeutet wie die Inverse der Matrix.

**Alternative Herleitung der Schätzparameter für den Linearen Least Square Gl.(2.40) in der Schreibweise mit Indizes**

Das j-te Residuum ist gegeben durch:

$$\varepsilon_j = Y_j - \sum_{k=1}^{M} \theta_k X_{jk} \quad \text{mit} \quad j = 1, \ldots, J \tag{2.41}$$

Das Qualitätsmaß $Q$, häufig auch als Zielfunktion $S$ bezeichnet, ist gegeben durch:

$$Q = \sum_{j=1}^{J} \varepsilon_j^2. \tag{2.42}$$

Die besten Schätzparameter $\hat{\boldsymbol{\theta}}$ erhält durch Aufsuchen des Minimums des Qualitätsmaßes $Q$. D. h. wir bilden die 1. Ableitung und setzen diese gleich Null:

$$\frac{\partial Q}{\partial \theta_k} = 2 \sum_{j=1}^{J} \varepsilon_j \frac{\partial \varepsilon_j}{\partial \theta_k} \quad \text{mit} \quad (k = 1, 2, \ldots, M) \tag{2.43}$$

Die partiellen Ableitungen lassen sich aus Gl.(2.41) bestimmen:

$$\frac{\partial \varepsilon_j}{\partial \theta_k} = -X_{jk} \tag{2.44}$$

Somit erhalten wir:

$$\frac{\partial Q}{\partial \theta_k} = 2 \sum_{j=1}^{J} \left( Y_j - \sum_{l=1}^{M} \theta_l X_{jl} \right) (-X_{jk}) \quad \text{mit} \quad (k = 1, 2, \ldots, M). \tag{2.45}$$

Diese erste Ableitung muss gleich Null sein, d.h.

$$2 \sum_{j=1}^{J} \left( Y_j - \sum_{l=1}^{M} \hat{\theta}_l X_{jl} \right) (-X_{jk}) = 0 \quad \text{mit} \quad (k = 1, 2, \ldots, M). \tag{2.46}$$

Durch Umformen erhalten wir die „Normalgleichung“:

$$\sum_{j=1}^{J} \sum_{l=1}^{M} X_{jk} X_{jl} \hat{\theta}_l = \sum_{j=1}^{J} X_{jk} Y_j \quad \text{mit} \quad (k = 1, 2, \ldots, M). \tag{2.47}$$

Die Normalgleichung kann dann in Matrixform geschrieben werden:

$$(\mathbf{X}^{\mathrm{T}} \mathbf{X}) \hat{\boldsymbol{\theta}} = \mathbf{X}^{\mathrm{T}} \mathbf{Y} \tag{2.48}$$

Wir erhalten auch über diese Herleitung die Gl.(2.40), deren Lösung uns die optimalen Fitparameter $\hat{\boldsymbol{\theta}}$ liefert.

Als nächstes ermitteln wir, um das **vollständige Messergebnis** zu erhalten, auch die Schätzwerte

der Kovarianzen. Die Hauptdiagonale der Kovarianzmatrix sind die Varianzen.

$$\mathrm{Cov}(\boldsymbol{\theta},\boldsymbol{\theta}) \;=\; \mathrm{Cov}\left(\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{Y}, \left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{Y}\right) \tag{2.49}$$

das ist

$$\mathrm{Cov}(\boldsymbol{\theta},\boldsymbol{\theta}) \;=\; \left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\,\mathrm{Cov}(\mathbf{Y},\mathbf{Y})\,\left(\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\right)^\mathsf{T} \tag{2.50}$$

und mit Einsetzen der aus den Schätzern $\hat{\boldsymbol{\theta}}$ erhaltenen empirischen Varianz der Residuen $\mathrm{Cov}(\mathbf{Y},\mathbf{Y}) = \mathrm{Var}(\varepsilon) = \hat{\sigma}_\varepsilon^2\,\mathbb{1}$, wobei $\mathbb{1}$ die Einheitsmatrix ist, bekommen wir die empirische Kovarianzmatrix

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}} \;=\; \hat{\sigma}_\varepsilon^2\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\,\left(\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\right)^\mathsf{T} \tag{2.51}$$

mit

$$\mathrm{Var}(\varepsilon) = \hat{\sigma}_\varepsilon^2 \;=\; \frac{1}{J-M}\,\hat{\boldsymbol{\varepsilon}}^\mathsf{T}\hat{\boldsymbol{\varepsilon}}$$

wobei $M$ die Anzahl der Regressionsparameter ist, also $M = 2$ im Fall der Geraden, für die beiden Parameter Achsenabschnitt und Steigung und

$$\hat{\boldsymbol{\varepsilon}} \;=\; \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}}.$$

Ferner gilt mit $\left(\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\right)^\mathsf{T} = \mathbf{X}\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}$

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}} \;=\; \hat{\sigma}_\varepsilon^2\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{X}\,\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1} \tag{2.52}$$

und mit $\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{X} \;=\; \mathbb{1}$ Einheitsmatrix

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}} \;=\; \hat{\sigma}_\varepsilon^2\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1} \tag{2.53}$$

Gleichung (2.53) liefert die Unsicherheit für die Regressionsparameter $\boldsymbol{\theta}$. Setzen wir dies nun für die Regressionsgerade ein, also setzen wir

$$\mathbf{X} \;=\; \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix}$$

ein, so erhalten wir für

$$\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1} \;=\; \left(\begin{pmatrix} 1 & \cdots & 1 \\ X_{1,1} & \cdots & X_{1,J} \end{pmatrix}\begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix}\right)^{-1} \tag{2.54}$$

d.h.

$$\left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1} \;=\; \begin{pmatrix} J & \sum\limits_{j=1}^{J} X_{1,j} \\ \sum\limits_{j=1}^{J} X_{1,j} & \sum\limits_{j=1}^{J} X_{1,j}^2 \end{pmatrix}^{-1} \tag{2.55}$$

d.h.

$$\left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1} = \frac{1}{J\sum\limits_{j=1}^{J} X_{1,j}^2 - \left(\sum\limits_{j=1}^{J} X_{1,j}\right)^2} \begin{pmatrix} \sum\limits_{j=1}^{J} X_{1,j}^2 & -\sum\limits_{j=1}^{J} X_{1,j} \\ -\sum\limits_{j=1}^{J} X_{1,j} & J \end{pmatrix} \tag{2.56}$$

so dass wir für den Achsenabschnitt $\theta_0$ und die Steigung $\theta_1$ folgende empirische Varianzen und Kovarianzen erhalten

$$\begin{pmatrix} \hat{\sigma}_{\theta_0}^2 & \hat{\sigma}_{\theta_0,\theta_1} \\ \hat{\sigma}_{\theta_0,\theta_1} & \hat{\sigma}_{\theta_1}^2 \end{pmatrix} = \frac{\hat{\sigma}_\varepsilon^2}{J\sum\limits_{j=1}^{J} X_{1,j}^2 - \left(\sum\limits_{j=1}^{J} X_{1,j}\right)^2} \begin{pmatrix} \sum\limits_{j=1}^{J} X_{1,j}^2 & -\sum\limits_{j=1}^{J} X_{1,j} \\ -\sum\limits_{j=1}^{J} X_{1,j} & J \end{pmatrix} \tag{2.57}$$

oder einzeln aufgeschrieben, die Varianz des Achsenabschnitts

$$\hat{\sigma}_{\theta_0}^2 = \frac{\hat{\sigma}_\varepsilon^2 \sum\limits_{j=1}^{J} X_{1,j}^2}{J\sum\limits_{j=1}^{J} X_{1,j}^2 - \left(\sum\limits_{j=1}^{J} X_{1,j}\right)^2} \tag{2.58}$$

die Kovarianz für Achsenabschnitt und Steigung

$$\hat{\sigma}_{\theta_0,\theta_1} = \frac{-\hat{\sigma}_\varepsilon^2 \sum\limits_{j=1}^{J} X_{1,j}}{J\sum_{j=1}^{J} X_{1,j}^2 - \left(\sum\limits_{j=1}^{J} X_{1,j}\right)^2} \tag{2.59}$$

und die Varianz der Steigung

$$\hat{\sigma}_{\theta_1}^2 = \frac{\hat{\sigma}_\varepsilon^2}{\sum\limits_{j=1}^{J} X_{1,j}^2 - \frac{1}{J}\left(\sum\limits_{j=1}^{J} X_{1,j}\right)^2}. \tag{2.60}$$

Die Standardabweichungen zu jedem Regressionsparameter $\theta_l$ mit $l = 0, \ldots, M-1$ sind die Wurzel aus den Varianzen, die auf der Hauptdiagonalen der Kovarianzmatrix $\left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\hat{\sigma}_\varepsilon^2$ stehen. In der üblichen englischsprachigen Literatur zur Regressionrechnung wird die Standardabweichung der Regressionsparameter *Standard Error* genannt.

### 2.3.2 Matrixansatz als allgemeiner Ansatz für lineare Regression

Die behandelten allgemeinen Formen von Problemstellungen zur Schätzung von Modellparametern werden wir in dieser Vorlesungsreihe nicht weiter vertiefen. Sie sollen lediglich einen Einblick und Überblick über die vielfältigen Möglichkeiten in diesem Bereich liefern.

Um die lineare Regression universeller einsetzen zu können, ob nun Polynome oder Ebenen oder Paraboloide zu fitten sind, ist es erforderlich den allgemeinen Ansatz zu verstehen und die unterschiedlichen

Anwendungen so formulieren zu können, dass sie darüber lösbar werden. Im Folgenden wollen wir den Übergang auf $M$ Modellparameter $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots \theta_M)$ vollziehen. Wir wollen also den Übergang von Gl. (2.26) mit

$$\begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} = \begin{pmatrix} Y_1 - (1\,\theta_0 + X_{1,1}\,\theta_1) \\ \vdots \\ Y_J - (1\,\theta_0 + X_{1,J}\,\theta_1) \end{pmatrix} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_J \end{pmatrix} - \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}$$

mit

$$\mathbf{X} = \begin{pmatrix} 1 & X_{1,1} \\ \vdots & \vdots \\ 1 & X_{1,J} \end{pmatrix}$$

zu einer allgemeinen Formulierung finden.

Für $M$ Regressoren wird die Regressormatrix zu einer $J \times M$-Matrix, also einer Matrix aus $M$ Spalten und $J$ Zeilen aufgestellt:

$$\mathbf{X} = \begin{pmatrix} X_{1,1} & \dots & X_{M,1} \\ \vdots & & \vdots \\ X_{1,J} & \dots & X_{M,J} \end{pmatrix} \tag{2.61}$$

Die Indexschreibweise ist hier relativ zur Schreibweise der Matrizenrechnung vertauscht, weil wir den Index für die Messgrößen vorne haben gefolgt von dem Index für die Beobachtungen, wir aber die Messgrößen als Spaltenvektoren verwenden und somit den Index für die Beobachtungen als Zeilenindex haben.

$$\boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} = \begin{pmatrix} Y_1 - (X_{1,1}\,\theta_1 + \dots + X_{M,1}\,\theta_M) \\ \vdots \\ Y_J - (X_{1,J}\,\theta_1 + \dots + X_{M,J}\,\theta_M) \end{pmatrix} = \mathbf{Y} - \mathbf{X}\,\boldsymbol{\theta} \tag{2.62}$$

Im Fall eines Polynoms kann jeder der Regressoren Funktion derselben Messgröße sein. Dies kann beispielsweise einfach durch folgenden Potenzansatz $X_{m,j} = X_{1,j}^{m-1}$ mit $m = 1, \dots, M$ als Polynom vom Grad $M - 1$ dargestellt werden

$$\begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_J \end{pmatrix} = \begin{pmatrix} Y_1 - (X_{1,1}^0\,\theta_1 + \dots + X_{1,1}^{M-1}\,\theta_M) \\ \vdots \\ Y_J - (X_{1,J}^0\,\theta_1 + \dots + X_{1,J}^{M-1}\,\theta_M) \end{pmatrix} \tag{2.63}$$

wobei $X_{1,j}^0 = 1$ ist.

Wird die Regressormatrix zu Beginn korrekt aufgestellt, so lassen sich die $M$ Regressionsparameter $\boldsymbol{\theta}$ schätzen durch numerische Lösung des folgenden Gleichungssystems:

$$\mathbf{X}^\mathsf{T}\,\mathbf{X}\,\boldsymbol{\theta} = \mathbf{X}^\mathsf{T}\,\mathbf{Y}. \tag{2.64}$$

Dass nach Lösen des Gleichungssystems Schätzwerte für die Parameter gewonnen wurden, wird durch

das Dach auf dem Symbol $\boldsymbol{\theta}$ gekennzeichnet.

$$\hat{\boldsymbol{\theta}} \;=\; \left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\mathbf{X}^{\mathsf{T}}\,\mathbf{Y} \tag{2.65}$$

wobei hoch minus Eins soviel bedeutet wie die Inverse der Matrix. Für Varianzen und Kovarianzen der $M$ Regressionsparameter $\theta_1, \ldots, \theta_M$ werden die Residuen gebraucht

$$\hat{\boldsymbol{\varepsilon}} \;=\; \begin{pmatrix} \hat{\varepsilon}_1 \\ \vdots \\ \hat{\varepsilon}_J \end{pmatrix} \;=\; \begin{pmatrix} Y_1 \;-\; (X_{1,1}\,\hat{\theta}_1 \;+\; \ldots \;+\; X_{M,1}\,\hat{\theta}_M) \\ \vdots \\ Y_J \;-\; (X_{1,J}\,\hat{\theta}_1 \;+\; \ldots \;+\; X_{M,J}\,\hat{\theta}_M) \end{pmatrix} \;=\; \mathbf{Y} \;-\; \mathbf{X}\,\hat{\boldsymbol{\theta}} \tag{2.66}$$

um deren empirische Varianz zu berechnen ($M$: Anzahl der Modellparameter; $J$: Anzahl der Messwertepaare)

$$\hat{\sigma}_\varepsilon^2 \;=\; \frac{1}{J-M}\,\hat{\boldsymbol{\varepsilon}}^{\mathsf{T}}\hat{\boldsymbol{\varepsilon}} \tag{2.67}$$

so dass wir die empirische Kovarianzmatrix der Parameter gemäß Gl. (2.53) erhalten:

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}} \;=\; \left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\,\hat{\sigma}_\varepsilon^2 \tag{2.68}$$

Um die Unsicherheit der einzelnen Regressionsparameter zu erhalten, führen wir Einheitsvektoren ein, die $M$-dimensional sind. Bei dem $l$-ten Einheitsvektor sind die ersten $l-1$ Vektorkomponenten Nullen, an der $l$-ten Stelle steht eine Eins und die $l+1$-te Komponente bis zur $M$-ten sind wieder Nullen.

$$\boldsymbol{e}_l \;=\; \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \tag{2.69}$$

Dann lässt sich durch folgende Multiplikation die $l$-te Varianz, d.h. das $l$-te Element der Hauptdiagonalen aus der Kovarianzmatrix herausholen

$$\hat{\sigma}_l^2 \;=\; \boldsymbol{e}_l^{\mathsf{T}}\,\left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\,\boldsymbol{e}_l\,\hat{\sigma}_\varepsilon^2. \tag{2.70}$$

Die Standardabweichung (*Standard Error*) wird daraus durch Ziehen der Wurzel gewonnen

$$\hat{\sigma}_l \;=\; \sqrt{\hat{\sigma}_l^2}. \tag{2.71}$$

In Kapitel 5 werden wir dann sehen, wie man mit Hilfe der Varianzen bzw. Standardabweichungen Vertrauensintervalle für die geschätzten Modellparameter bestimmt. Die Herleitung ist im Anhang aufgeschrieben.

## 2.4 Das Bestimmtheitsmaß und der empirische Korrelationskoeffizient

Die Güte des gewählten linearen Ansatzes kann mit dem **Bestimmtheitsmaß** $\rho_{XY}^2$ bzw. dem **empirischen Korrelationskoeffizienten** $\rho_{XY}$ beurteilt werden, aber nur dann wenn ein solcher Zusammenhang auch existiert. Der empirische Korrelationskoeffizient gibt den Grad der linearen Abhängigkeit zwischen den Messwerten $(X_1, \ldots, X_J)$ und $(Y_1, \ldots, Y_J)$ an.

Für den empirischen Korrelationskoeffizienten $\rho_{XY}$ gilt folgendes:

| | |
|---|---|
| $\rho_{XY} = \pm 1$ | 100% lineare Abhängigkeit |
| $\rho_{XY} = 0$ | keine lineare Abhängigkeit |
| $\rho_{XY} >$ bzw. $< 0$ | gleich-/gegenläufige lineare Abhängigkeit |

Für die Bestimmung des Bestimmtheitsmaßes oder des empirischen Korrelationskoeffizienten führt man eine Streuungs- bzw. Varianzanalyse durch. Man kann bei der linearen Regression 3 Arten von Streuungen unterscheiden:

$s_{\mathrm{T}}^2$ : die **totale empirische Varianz**

$s_{\mathrm{M}}^2$ : die **empirische Varianz auf Grund des Modells**

$s_{\mathrm{R}}^2$ : die **restliche empirische Varianz**

Die totale Streuung des Regressanden ist gegeben durch:

$$s_{\mathrm{T}}^2 = \frac{1}{J-1} \sum_{j=1}^{J} (Y_j - \bar{Y})^2 \quad \text{mit } Y_j : \text{Messwert zu } X_j \tag{2.72}$$

Die empirische Varianz auf Grund des Modells beschreibt die Streuung der Y-Werte auf der Regressionsgeraden in Bezug zum Mittelwert $\bar{Y}$, d. h.

$$s_{\mathrm{M}}^2 = \frac{1}{J-1} \sum_{j=1}^{J} (\hat{\theta}_0 + \hat{\theta}_1 X_j - \bar{Y})^2 \tag{2.73}$$

Die Differenzen zwischen $Y_j$ und $\hat{\theta}_0 + \hat{\theta}_1 X_j$ bleiben im Modell unerklärt; sie werden als restliche Streuung bezeichnet:

$$s_{\mathrm{R}}^2 = \frac{1}{J-1} \sum_{j=1}^{J} (Y_j - (\hat{\theta}_0 + \hat{\theta}_1 X_j))^2 \tag{2.74}$$

Man kann nun folgendes Bemerkenswerte zeigen:

$$s_{\mathrm{T}}^2 = s_{\mathrm{M}}^2 + s_{\mathrm{R}}^2 \tag{2.75}$$

Beweis von Gl.(2.75):

$$s_T^2 = \frac{1}{J-1}\sum_{j=1}^{J}(Y_j - \bar{Y})^2 \tag{2.76}$$

$$= \frac{1}{J-1}\sum_{j=1}^{J}\left[(Y_j - \hat{Y}_j) + (\hat{Y}_j - \bar{Y})\right]^2 \tag{2.77}$$

$$= \frac{1}{J-1}\left[\sum_{j=1}^{J}(Y_j - \hat{Y}_j)^2 + \sum_{j=1}^{J}(\hat{Y}_j - \bar{Y})^2 + 2\cdot\sum_{j=1}^{J}(Y_j - \hat{Y}_j)(\hat{Y}_j - \bar{Y})\right] \tag{2.78}$$

$$= s_R^2 + s_M^2 + \frac{1}{J-1}\cdot 2\cdot\sum_{j=1}^{J}(Y_j - \hat{Y}_j)(\hat{Y}_j - \bar{Y}) \tag{2.79}$$

Es ist jetzt noch zu zeigen, dass

$$\sum_{j=1}^{J}(Y_j - \hat{Y}_j)(\hat{Y}_j - \bar{Y}) \stackrel{!}{=} 0 \tag{2.80}$$

Für Punkte $\hat{Y}_j$ auf der Geraden gilt:

$$\hat{Y}_j = \hat{\theta}_0 + \hat{\theta}_1 X_j \tag{2.81}$$

Der y-Abschnitt $\hat{\theta}_0$ bei der Regressionsgeraden kann wie folgt berechnet werden (Hinweis: Schwerpunkt $(\bar{X}|\bar{Y})$ liegt auf der Regressionsgeraden):

$$\hat{\theta}_0 = \bar{Y} - \hat{\theta}_1\bar{X} \tag{2.82}$$

Daraus folgt:

$$\hat{Y}_j = \bar{Y} - \hat{\theta}_1\bar{X} + \hat{\theta}_1 X_j \tag{2.83}$$

Diese Gleichung etwas umstellen und sowohl links als auch rechts $Y_j$ addieren, ergibt:

$$Y_j - \hat{Y}_j = (Y_j - \bar{Y}) - \hat{\theta}_1(X_j - \bar{X}) \tag{2.84}$$

Zudem gilt:

$$(\hat{Y}_j - \bar{Y}) = \hat{\theta}_1(X_j - \bar{X}) \tag{2.85}$$

Gl.(2.84) und Gl.(2.85) eingesetzt, ergibt:

$$\sum_{j=1}^{J}(Y_j - \hat{Y}_j)(\hat{Y}_j - \bar{Y}) = \hat{\theta}_1\sum_{j=1}^{J}\left[\Big((Y_j - \bar{Y}) - \hat{\theta}_1(X_j - \bar{X})\Big)(X_j - \bar{X})\right] \tag{2.86}$$

$$= \hat{\theta}_1\left[\sum_{j=1}^{J}(Y_j - \bar{Y})(X_j - \bar{X}) - \hat{\theta}_1\sum_{j=1}^{J}(X_j - \bar{X})^2\right] \qquad = 0 \tag{2.87}$$

Da für das hintere $\hat{\theta}_1$ kann folgendes eingesetzt werden:

$$\hat{\theta}_1 = \frac{s_{XY}}{s_X^2} = \frac{\sum_{j=1}^{J}(X_j - \bar{X})(Y_j - \bar{Y})}{\sum_{j=1}^{J}(X_j - \bar{X})^2}$$

Damit wäre Gl.(2.75) bewiesen.

Das **Bestimmtheitsmaß** ist definiert als das Verhältnis von empirischer Varianz des Modells zu der totalen Varianz:

$$\rho_{XY}^2 = \frac{s_{\mathrm{M}}^2}{s_{\mathrm{T}}^2} = \frac{\sum_{j=1}^{J} (\hat{\theta}_0 + \hat{\theta}_1 X_j - \bar{Y})^2}{\sum_{j=1}^{J} (Y_j - \bar{Y})^2}$$

Mit dem Schwerpunkt $\bar{Y} = \hat{\theta}_0 + \hat{\theta}_1 \bar{X}$ ergibt sich:

$$\rho_{XY}^2 = \frac{\hat{\theta}_1^2 \cdot \sum_{j=1}^{J} (X_j - \bar{X})^2}{\sum_{j=1}^{J} (Y_j - \bar{Y})^2}$$

Mit den Regressionsparametern $\hat{\theta}_1 = \frac{\sum_{j=1}^{J} (X_j - \bar{X})(Y_j - \bar{Y})}{\sum_{j=1}^{J} (X_j - \bar{X})^2}$ (siehe Gl.(2.23)) erhält man für das Bestimmtheitsmaß:

$$\rho_{XY}^2 = \frac{\left[\sum_{j=1}^{J} (X_j - \bar{X})(Y_j - \bar{Y})\right]^2}{\sum_{j=1}^{J} (X_j - \bar{X})^2 \cdot \sum_{j=1}^{J} (Y_j - \bar{Y})^2}$$

$$= \frac{s_{XY}^2}{s_X^2 \cdot s_Y^2} \quad \text{mit } 0 \leq \rho_{XY}^2 \leq 1 \tag{2.88}$$

Den empirischen Korrelationskoeffizienten kann man somit wie folgt berechnen:

$$\rho_{XY} = \frac{s_{XY}}{s_X \cdot s_Y} \quad \text{mit } -1 \leq \rho_{XY} \leq 1 \tag{2.89}$$

## 2.5 Beispiele zur linearen Regression

### 2.5.1 Modellwahl: Gerade oder Polynom

Gegeben sei ein Ensemble von Wertepaaren $(X_j, Y_j)$, $j = 1, 2, \ldots, J$, mit einer vorgegebenen Eingangsgröße (Regressand) $X$ und einer streuenden Ausgangsgröße (Regressor) $Y$. Abb. 2.2 zeigt dieselben Daten mit einer Regressionsgeraden und einem Polynom 6. Grades.

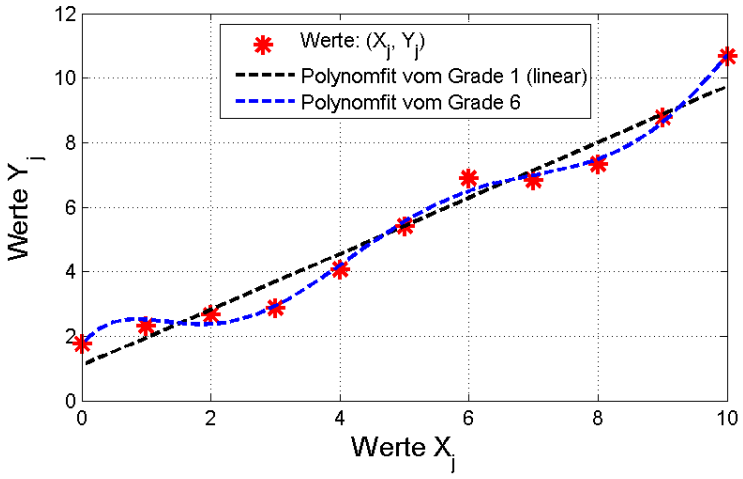



Abbildung 2.2: Beispiel für mögliche Fits: linearer Fit und Polynomfit vom Grad 6.

Vor der Regressionsrechnung muss festgelegt werden, welches Modell inhaltlich sinnvoll ist. Eine kleine Kostenfunktion allein beweist noch kein gutes physikalisches Modell: Ein Polynom hohen Grades kann Messdaten sehr eng folgen, aber außerhalb des betrachteten Bereichs schlecht oder sogar unsinnig extrapolieren. Die Modellwahl sollte deshalb aus dem physikalischen Zusammenhang, dem Messbereich und dem Zweck der Auswertung begründet werden.

### 2.5.2 Beispiel: Bestimmung eines Ohmschen Widerstands

Wir greifen das Beispiel aus der ersten Vorlesung wieder auf. Eine Präzisionsstromquelle gibt den Strom $I$ vor; diese Werte betrachten wir als Regressor und damit als nicht streuend. Ein Voltmeter misst die Spannung $U$; diese Werte betrachten wir als Regressand und damit als Zufallsgröße. Gesucht sind der Ohmsche Widerstand $R$ und eine Offsetspannung $U_0$.

| $I$ in mA | 4.0 | 6.0 | 8.0 | 10.0 | 12.0 | 14.0 | 16.0 | 18.0 | 20.0 |
|---|---|---|---|---|---|---|---|---|---|
| $U$ in mV | 62.5 | 51.5 | 96.0 | 140.2 | 138.9 | 195.1 | 225.8 | 207.8 | 223.7 |

Die Modellgleichung lautet mit den beiden Modellparameter $\theta_0 := U_0$ und $\theta_1 := R$

$$U = U_0 + R \cdot I. \tag{2.90}$$

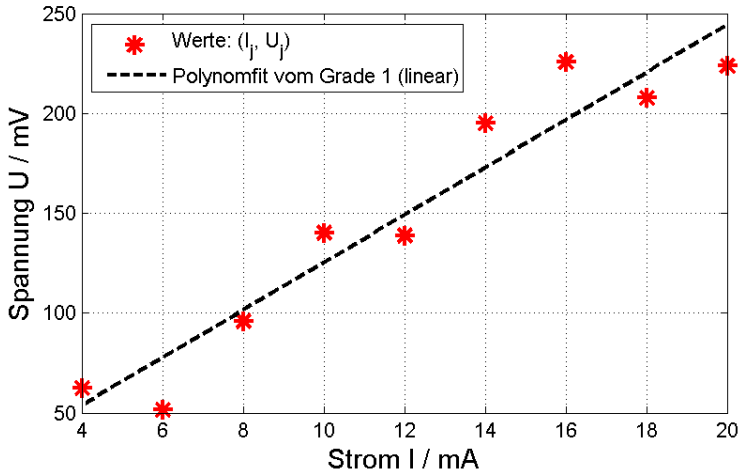



Abbildung 2.3: Bestimmung des Ohmschen Widerstands und einer Offsetspannung durch lineare Regression.

Nach Gl. (2.23) gilt

$$\hat{U}_0 = \bar{U} - \hat{R}\bar{I} \quad \text{und} \quad \hat{R} = \frac{s_{IU}}{s_I^2}. \tag{2.91}$$

Zunächst bestimmen wir die Mittelwerte:

$$\bar{I} = \frac{1}{J}\sum_{j=1}^{J} I_j = 12\,\text{mA}, \qquad \bar{U} = \frac{1}{J}\sum_{j=1}^{J} U_j = 149.0556\,\text{mV}. \tag{2.92}$$

Die empirische Kovarianz und die empirische Varianz des Regressors sind

$$s_{IU} = \frac{1}{J-1}\sum_{j=1}^{J}(I_j - \bar{I})(U_j - \bar{U}) = 357.0500\,\text{mA}\,\text{mV}$$

und

$$s_I^2 = \frac{1}{J-1}\sum_{j=1}^{J}(I_j - \bar{I})^2 = 30\,\text{mA}^2.$$

Damit ergeben sich

$$\hat{R} = \frac{s_{IU}}{s_I^2} = \frac{357.0500\,\text{mA}\,\text{mV}}{30\,\text{mA}^2} = 11.9017\,\frac{\text{mV}}{\text{mA}} = 11.9017\,\Omega$$

und

$$\hat{U}_0 = \bar{U} - \hat{R}\bar{I} = 149.0556\,\text{mV} - 11.9017\,\Omega \cdot 12\,\text{mA} = 6.2356\,\text{mV}.$$

Das Ergebnis für die Regressionsgerade lautet somit

$$U = 6.2356\,\text{mV} + (11.9017\,\Omega)\,I \tag{2.93}$$

und ist in Abb. 2.3 dargestellt.

### 2.5.3 Fit einer Geraden mittels linearer Regression

Gegeben sind 5 Messpunkte

| $X_i$ | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| $Y_i$ | 0.4 | 0.55 | 0.70 | 0.75 | 0.8 |

(a) Führen Sie eine lineare Regression durch, indem Sie den y-Abschnitt $\hat{\theta}_0$ und die Steigung $\hat{\theta}_1$ bestimmen. Geben Sie das Bestimmtheitsmaß $\rho^2_{XY}$ an.

(b) Bestimmen Sie die Residuen $\varepsilon_j$ und das Qualitätsmaß $Q(\hat{\theta}_0, \hat{\theta}_1)$ der Regression. Geben Sie die Varianz der Residuen $s^2(\hat{\theta}_0, \hat{\theta}_1)$ an?

(c) Geben Sie den Standardabweichung (standard error) der beiden Regressionsparameter $\hat{\theta}_0$ und $\hat{\theta}_1$ an?

**Lösung zu Teil (a):**

Gesucht:

$$Y = \hat{\theta}_1 \cdot X + \hat{\theta}_0$$

Mittelwert von $X$: $\bar{X} = 3$; Mittelwert von $Y$: $\bar{Y} = 0.64$;
Empirische Standardabweichung von $X$: $s_X = 1.5811$;
Empirische Standardabweichung von $Y$: $s_Y = 0.1636$;
Empirische Kovarianz: $s_{XY} = 0.25$
Schätzwerte $\hat{\theta}_1$ und $\hat{\theta}_0$:

$$\hat{\theta}_1 = \frac{s_{XY}}{s^2_X} = 0.100$$

$$\hat{\theta}_0 = \bar{Y} - \hat{\theta}_1 \bar{X} = 0.340$$

Bestimmtheitsmaß:

$$\rho^2_{XY} = \frac{s^2_{XY}}{s^2_X \cdot s^2_Y} = 0.9346$$

Mit der Gl.(2.40) können wir das Beispiel mit dem Matrixformalismus auch lösen. Die Regressormatrix $\boldsymbol{X}$ lautet:

$$\boldsymbol{X} = \begin{pmatrix} 1 & X_1 \\ 1 & X_2 \\ 1 & X_3 \\ 1 & X_4 \\ 1 & X_5 \end{pmatrix} \tag{2.94}$$

Die Regressandenmatrix $\boldsymbol{Y}$ lautet:

$$\boldsymbol{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \\ Y_5 \end{pmatrix} \tag{2.95}$$

Die gesuchten Modellparameter sind:

$$\boldsymbol{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}$$

Die optimalen Parameter $\hat{\boldsymbol{\theta}}$ ergeben sich durch Lösen des folgenden Gleichungssystems, siehe Gl.(2.65)

$$\hat{\boldsymbol{\theta}} = \left(\mathbf{X}^{\mathsf{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathsf{T}}\mathbf{Y}$$

Der Matlab/Octave-Code lautet:

```
close all; clear all;
% Eingabe der Messwertepaare
input = [...
1, 0.4;...
2, 0.55;...
3, 0.7;...
4, 0.75; ...
5, 0.8];
m = length(input);              % Anzahl der Messpunkte
X = [ones(m,1), input(:,1)];    % Aufstellen der X-Matrix
Y = input(:,2);                 % Aufstellen der Y-Matrix
% degree of freedom
df = 5-2;
% Berechung der Schaetzwerte \thetaHat;
% y-Abschnitt = \thetaHat(1); Steigung = \thetaHat(2)
thetaHat = (X' * X) \ (X' * Y);
% Anzeige der Schaetzwerte
disp(thetaHat);
% Plotten der Regressionsgeraden
xx = linspace(0,6,100);
yy = thetaHat(1) + thetaHat(2)*xx;
figure(10)
plot(xx, yy,'linewidth',1.5)
% Plotten der Datenwerte
hold on
plot(input(:,1), input(:,2), 'or','linewidth',2, 'MarkerSize',6)
hold off
grid on;
xlabel('Werte X_j','fontsize',14)
ylabel('Werte Y_j','fontsize',14)
set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 9;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' LinRegression.png
```

Als Lösung erhalten wir den Plot in Abb.2.4. Der y-Achsenabschnitt liegt bei 0.34 und die Steigung ist 0.1.

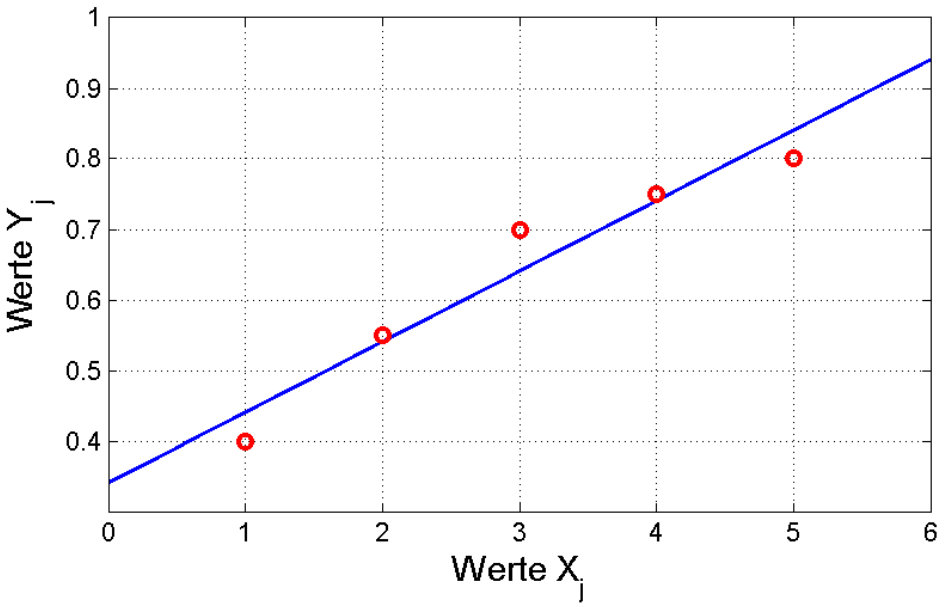



Abbildung 2.4: Lineare Regression. Als Schätzparameter erhält man $\hat{\boldsymbol{\theta}} = [0.3400, 0.1000]^T$

**Lösung zu Teil (b)**
Residuen: $\varepsilon_j = Y_j - (\hat{\theta}_0 + \hat{\theta}_1 \cdot X_j)$ mit $j = 1, \ldots, 5$

$$\varepsilon_1 = -0.0400; \quad \varepsilon_2 = 0.0100; \quad \varepsilon_3 = 0.0600; \quad \varepsilon_4 = 0.0100; \quad \varepsilon_5 = -0.0400$$

Qualitätsmaß:

$$Q(\hat{\theta}_0, \hat{\theta}_1) = \sum_{j=1}^{J} \varepsilon_j^2 = 0.0070$$

Varianz der Residuen:

$$s^2(\hat{\theta}_0, \hat{\theta}_1) = \frac{Q(\hat{\theta}_0, \hat{\theta}_1)}{J-2} = 0.0023 \quad \text{bzw.} \quad s(\hat{\theta}_0, \hat{\theta}_1) = 0.048$$

Die Varianz der Residuen ist wie folgt gegeben:

$$\mathrm{Var}(\varepsilon) = \frac{1}{J-M} \cdot \left(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}}\right)^T \left(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\theta}}\right) \tag{2.96}$$

Die Kovarianzen der Schätzerparameter $\boldsymbol{\theta}$ sind gegeben durch:

$$\mathrm{Cov}(\boldsymbol{\theta}) = \left(\mathbf{X}^T\mathbf{X}\right)^{-1} \mathrm{Var}(\varepsilon) \tag{2.97}$$

Matlab-Code zur Bestimmung des Qualitätsmaßes und der Varianz

```
% Qualitaetsmass Q
Q = (Y-X*thetaHat)' * (Y-X*thetaHat)
% Varianz der Residuen
```

```
Var_epsilon = 1/df *(Y-X*thetaHat)' * (Y-X*thetaHat)
% Wurzel aus Var_epsilon
RMSE = sqrt(Var_epsilon)
% Kovarianzen
Cov = Var_epsilon * inv(X'*X)
```

Als Ergebnis für unser Beispiel erhalten wir:
Q = 0.0070
Var_epsilon = 0.0023
RMSE = 0.0483
Cov =
0.0026 -0.0007
-0.0007 0.0002

**Lösung zu Teil (c)**
Die Standardabweichung für $X$ berechnet sich zu $s_X = 1.5811$.

Für die Varianz des y-Abschnitt $\hat{\theta}_0$ ergibt sich:

$$\begin{aligned}\hat{\sigma}^2_{\theta_0} &= s^2(\hat{\theta}_0, \hat{\theta}_1)\left[\frac{1}{J} + \frac{\bar{X}^2}{(J-1)s_x^2}\right] \\ &= 0.0023\left[\frac{1}{5} + \frac{3^2}{(5-1)\cdot 1.5811^2}\right] \\ &= 0.00257\end{aligned}$$

Damit ergibt sich die Standardabweichung für $\hat{\theta}_0$:

$$s_{\hat{\theta}_0} = \sqrt{\hat{\sigma}^2_{\theta_0}} = 0.0507$$

Für die Varianz der Steigung $\hat{\theta}_1$ ergibt sich:

$$\begin{aligned}\hat{\sigma}^2_{\theta_1} &= \frac{\hat{s}^2(\hat{\theta}_0, \hat{\theta}_1)}{s_X^2 \cdot (J-1)} \\ &= \frac{0.0023}{1.5811^2 \cdot (5-1)} \\ &= 0.00023\end{aligned} \tag{2.98}$$

Damit ergibt sich die Standardabweichung für $\hat{\theta}_1$

$$s_{\hat{\theta}_1} = \sqrt{\hat{\sigma}^2_{\theta_1}} = 0.0153$$

**Anmerkung: Lösung mit Matlab/Octave** Bei Matlab gibt es den Befehl „polyfit“ mit dem Polynomfits durchgeführt werden können. Matlab liefert hier dasselbe Ergebnis, auch für die Vertrauensbereiche, das Qualitätsmaß $Q$ (engl. SSE: Sum squared error) oder das Bestimmheitsmaß $\rho^2_{XY}$ (R-square), siehe Abb.2.5:

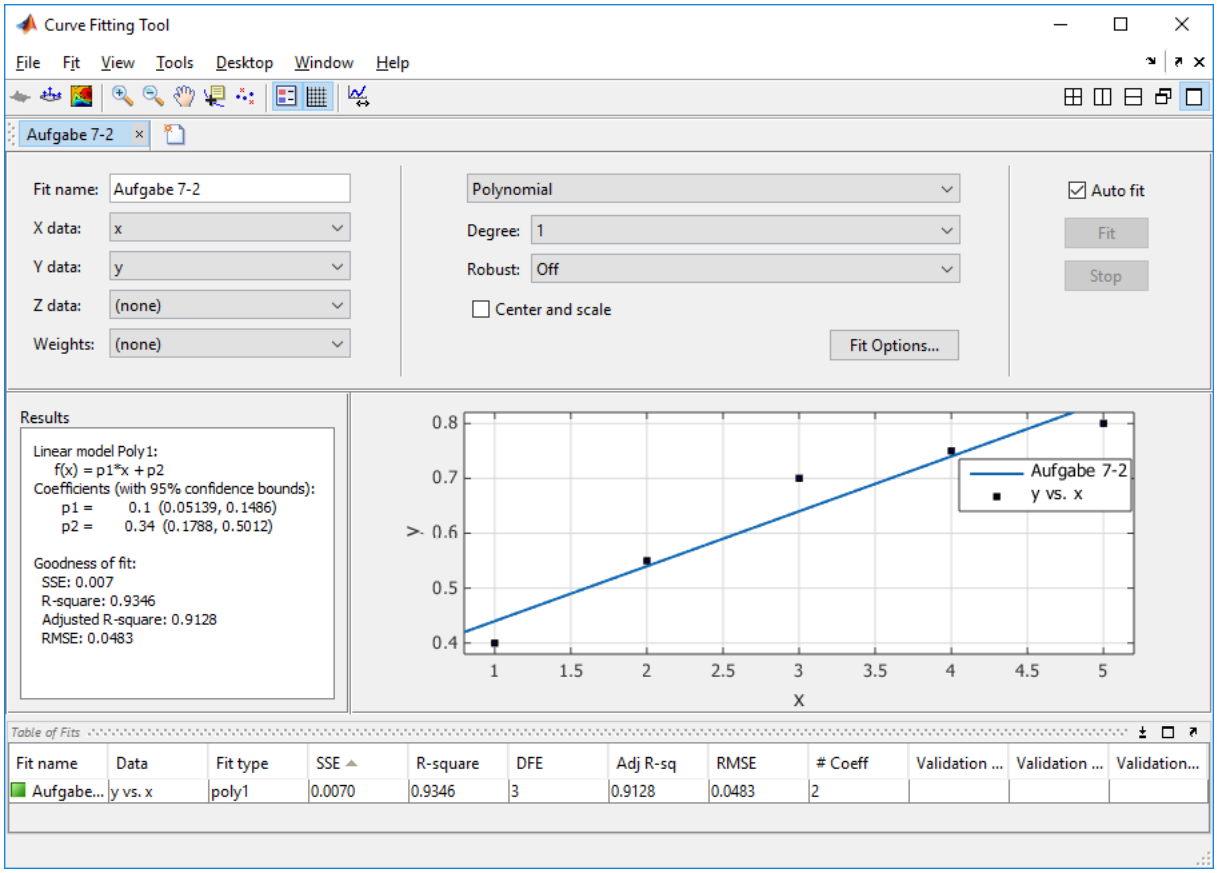



Abbildung 2.5: Lösung der Aufgabe mit dem polyfit Befehl von Matlab/Octave. Es wird hier u. a. der 95%ige Vertrauensbereich berechnet und angezeigt (siehe Mitte links in der Abbildung).

**Hinweis: Vertrauensbereich**

In einer der nächsten Vorlesungen werden wir sehen, wie man Vertrauensbereiche mit Hilfe der Varianzen bzw. Standardabweichungen berechnet. Dazu benötigt man noch die t-Verteilung. Da man hier 5 Messpunkte und 2 Modellparameter hat, wird die t-Verteilung mit dem Freiheitsgrad 5-2 = 3 benötigt. 95%iger Vertrauensbereich für $\hat{\theta}_1$ mit $t_3 = 3.182$:

$$\varepsilon_{\hat{\theta}_1} = t_3 \cdot \hat{\sigma}_{\theta_1} = \frac{t_3 \cdot s(\hat{\theta}_0, \hat{\theta}_1)}{s_X \cdot \sqrt{J-1}} = 0.0486$$

95%iger Vertrauensbereich für $\hat{\theta}_0$ errechnet sich durch:

$$\varepsilon_{\hat{\theta}_0} = t_3 \cdot \hat{\sigma}_{\theta_0} = t_3 \cdot s(\hat{\theta}_0, \hat{\theta}_1) \cdot \sqrt{\frac{1}{J} + \frac{\bar{X}^2}{(J-1)s_X^2}} = 0.1612$$

**Ergebnis:**

Der 95% Vertrauensbereich des Schätzwertes $\hat{\theta}_1$ ist somit gegeben durch:

$$\hat{\theta}_1 = 0.1000 \pm 0.0486 \quad \text{bzw.} \quad [0.0514; 0.1486] \tag{2.99}$$

Der 95% Vertrauensbereich des Schätzwertes $\hat{\theta}_0$ ist somit gegeben durch:

$$\hat{\theta}_0 = 0.3400 \pm 0.1612 \quad \text{bzw.} \quad [0.1788; 0.5012] \tag{2.100}$$

### 2.5.4 Fit einer kubischen Funktion (Polynom 3. Ordnung) mittels linearer Regression

Wir nehmen wieder die gleichen Messwertpaare wie eben. Jedoch fitten wir nun eine kubische Funktion durch die Messdaten, d.h.

$$Y = \hat{\theta}_3 X^3 + \hat{\theta}_2 X^2 + \hat{\theta}_1 X + \hat{\theta}_0 \tag{2.101}$$

Mit der Gl.(2.40) können wir das Beispiel mit dem Matrixformalismus auch lösen. Die Regressormatrix $\boldsymbol{X}$ lautet:

$$\boldsymbol{X} = \begin{pmatrix} 1 & X_1 & X_1^2 & X_1^3 \\ 1 & X_2 & X_2^2 & X_2^3 \\ 1 & X_3 & X_3^2 & X_3^3 \\ 1 & X_4 & X_4^2 & X_4^3 \\ 1 & X_5 & X_5^2 & X_5^3 \end{pmatrix} \tag{2.102}$$

Die Regressandenmatrix $\boldsymbol{Y}$ lautet:

$$\boldsymbol{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \\ Y_5 \end{pmatrix} \tag{2.103}$$

Die gesuchten Modellparameter sind:

$$\boldsymbol{\theta} = (\theta_0, \theta_1, \theta_2, \theta_3)^T$$

Die optimalen Parameter $\hat{\boldsymbol{\theta}}$ ergeben sich durch Lösen des folgenden Gleichungssystems, siehe Gl.(2.65)

$$\hat{\boldsymbol{\theta}} = \left(\mathbf{X}^\mathsf{T}\mathbf{X}\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{Y}$$

Als Ergebnis für die Schätzparameter erhalten wir dann:

$$\hat{\boldsymbol{\theta}} = (0.1900,\ \ 0.2286,\ \ -0.0214,\ \ -0.0000)^T$$

Für das Qualitätsmaß ergibt sich:

$$\mathrm{Q} = 5.7143e-04$$

Für die Streuung der Residuen ergibt sich:

$$\text{Var_epsilon} = 5.7143e-04$$

Standardabweichung der Residuen:

$$\text{RMSE} = 0.0239$$

Die Kovarianzmatrix ergibt sich zu:

$$\text{Cov} = \begin{bmatrix} 0.0138 & -0.0176 & 0.0063 & -0.0007 \\ -0.0176 & 0.0236 & -0.0087 & 0.0009 \\ 0.0063 & -0.0087 & 0.0033 & -0.0004 \\ -0.0007 & 0.0009 & -0.0004 & 0.0000 \end{bmatrix}$$

Der Matlab/Octave-Code lautet (Klicke hier für interaktive Session):

```
close all; clear all;
% Eingabe der Messwertepaare
input = [...
1, 0.4;...
2, 0.55;...
3, 0.7;...
4, 0.75; ...
5, 0.8];
m = length(input); % Anzahl der Messpunkte
x_Werte = input(:,1);
X = [ones(m,1), x_Werte, x_Werte.^2,x_Werte.^3];
Y = input(:,2);
% Aufstellen der X-Matrix % Aufstellen der Y-Matrix
% degree of freedom
df = 5-4;
% Berechung der Schaetzwerte \thetaHat;
% y-Abschnitt = \thetaHat(1); Steigung = \thetaHat(2)
thetaHat = (X' * X) \ (X' * Y);
% Anzeige der Schaetzwerte
disp(thetaHat);
% Plotten der Fitfunktion
xx = linspace(0,6,100);
yy = thetaHat(1) + thetaHat(2)*xx+ thetaHat(3)*xx.^2+thetaHat(4)*xx.^3;
figure(10)
plot(xx, yy,'linewidth',1.5)
% Plotten der Datenwerte
hold on
plot(input(:,1), input(:,2), 'or','linewidth',2, 'MarkerSize',6)
hold off
grid on;
```

```
xlabel('Werte X_j','fontsize',14)
ylabel('Werte Y_j','fontsize',14)
set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 9;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' kubischerFit.png
% Qualitaetsmass Q
Q = (Y-X*thetaHat)' * (Y-X*thetaHat)
% Varianzen der Residuen
Var_epsilon = 1/df *(Y-X*thetaHat)' * (Y-X*thetaHat)
% Wuzel aus Var_epsilon
RMSE = sqrt(Var_epsilon)
% Kovarianzen
Cov = Var_epsilon * inv(X'*X)
```

Wir können auch die Curve Fitting Toolbox von Matlab verwenden, die uns das gleiche Ergebnis anzeigt:

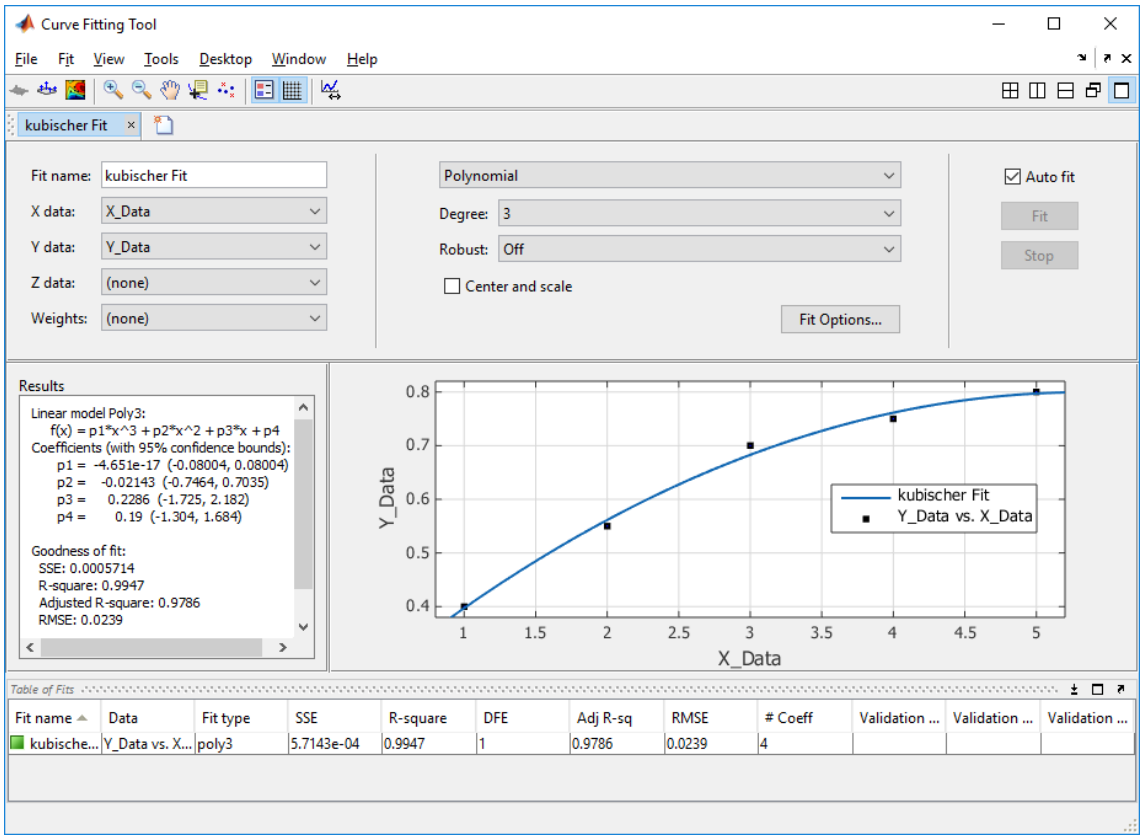
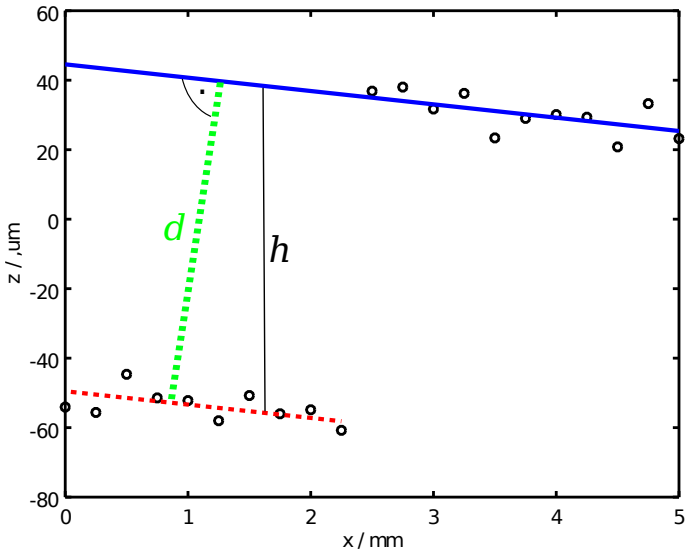



Abbildung 2.6: Kubischer Fit mit der Curve Fitting Toolbox von Matlab. Zum jedem geschätzten Parameter wird der 95%ige Vertrauensbereich angegeben. Zu sehen sind u.a. das Qualitätsmaß Q (engl. SSE: Sum squared error), das Bestimmtheitsmaß $\rho^2_{XY}$ (engl. R-square), Standardabweichung der Residuen (engl. RMSE: root mean square error) und die Anzahl der Freiheitsgrade (engl. DFE, degree of freedom)

## 2.6 Aufgaben zum Selbststudium

### 2.6.1 1. Aufgabe zur Linearen Regression

Es wurde eine Stufe vermessen, die nominal eine Höhe von 100 $\mu$m haben soll. Die laterale Achse $x$ wird eingestellt (mit Präzisionstisch positioniert) und als Regressor betrachtet, also nicht als Zufallsgröße. Die vertikale Achse $z$ wird gemessen, als Regressand und damit als Zufallsgröße betrachtet.




| $x$/mm | 0.00 | 0.25 | 0.50 | 0.75 | 1.00 | 1.25 | 1.50 | 1.75 | 2.00 | 2.25 |
|---|---|---|---|---|---|---|---|---|---|---|
| $z/\mu$m | -54.08 | -55.63 | -44.65 | -51.44 | -52.21 | -58.01 | -50.76 | -56.01 | -54.86 | -60.77 |

| $x$/mm | 2.50 | 2.75 | 3.00 | 3.25 | 3.50 | 3.75 | 4.00 | 4.25 | 4.50 | 4.75 | 5.00 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| $z/\mu$m | 36.85 | 38.02 | 31.71 | 36.21 | 23.39 | 29.01 | 30.11 | 29.35 | 20.81 | 33.27 | 23.19 |

Die Modellgleichung, mit der die Stufe beschrieben wird, ist

$$z_j \;=\; a\,x_j \;+\; c \;+\; h\,\delta_{j\in C} \;+\; \varepsilon_j$$

mit $C$ Menge der Indizes von 1 bis $J_C$. Hier sei $J_C = 10$:

$$C \;=\; \{\,j \,|\, j = 1, 2, \ldots, J_C\}$$

und

$$\delta_{j\in C} \;=\; \begin{cases} 1 & \text{falls } \; j \in C \;\; \text{d.h. } j = 1 \;\; \text{oder } j = 2 \text{ oder } \ldots \;\; j = J_C \\ 0 & \text{sonst} \end{cases}$$

Dabei ist $h$ noch nicht die Stufenhöhe, sondern deren Projektion auf die vertikale Achse. Die Stufenhöhe $d$ ist der senkrechte Abstand zwischen den beiden parallelen Geraden, die jeweils durch die Punkte auf dem oberen und dem unteren Niveau gehen.

(a) Stellen Sie das lineare Gleichungssystem auf, das sich durch partielles Ableiten für das Optimie-

rungsproblem

$$\min_{a,c,h} \left\{ \sum_{j=1}^{J_T} \varepsilon_j^2 \right\}$$

ergibt, mit $J_T = 21$.

(b) Schreiben Sie die Gleichung für die Stufenhöhe $d$ als Funktion von $h$ und $a$ auf.

(c) Schreiben Sie die Gleichung für die Varianz der Residuen auf.

(d) Schreiben Sie die Formel für die Kovarianzmatrix der Modellparameter $a, c, h$ auf.

(e) Verwenden Sie eine Programmierumgebung Ihrer Wahl, Matlab, Octave, Python, R, ..., die Ihnen einen Solver für lineare Gleichungssysteme zur Verfügung stellt, sowie eine Routine zur Matrixinversion und berechnen Sie die Zahlenwerte für die Modellparameter sowie deren Kovarianzmatrix.

Anmerkung: Die inverse Matrix brauchen Sie nicht analytisch zu berechnen, sondern lediglich $(\cdots)^{-1}$ zu notieren.

# Kapitel 3

# Parameter nichtlinearer Modelle schätzen

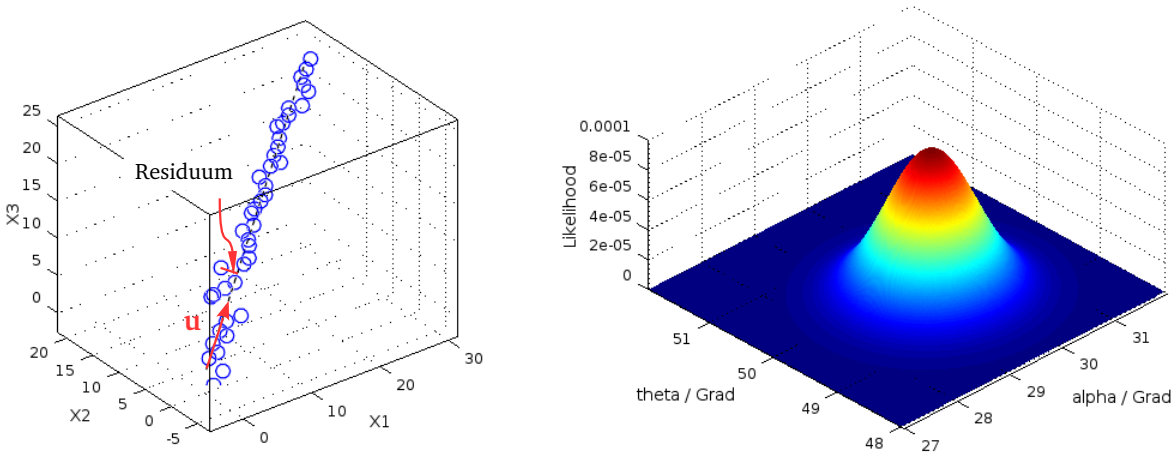



Abbildung 3.1: Modell mit 2 zu schätzenden Parametern (*links*) und der dazugehörigen Likelihood für normalverteilte Residuen (*rechts*).

## 3.1 Konzepte von Optimierungsverfahren für nichtlineare Modelle

Während dieser Vorlesungsreihe behandeln wir die Ermittlung physikalischer Größen, die nicht direkt zugänglich sind. Sie werden mithilfe eines Modells durch Modellparameter beschrieben und aus den Beobachtungen geschätzt. In den bisherigen Kapiteln haben wir Modellparameter linearer Modelle geschätzt. Die Besonderheit besteht darin, dass das Modell beziehungsweise die Residuen linear von den Modellparametern abhängen. Die *Kostenfunktion* $Q$ ist dann im Allgemeinen quadratisch in den Parametern, sodass die Schätzwerte im Fall der Ausgleichsrechnung nach der Methode der kleinsten Quadrate durch das Lösen eines linearen Gleichungssystems bestimmt werden können. Im vorangegangenen Kapitel wurde in Gl. (2.10), Gl. (2.18) und Gl. (2.64) gezeigt, dass dieses Gleichungssystem aus der Bedingung entsteht, dass der Gradient der Kostenfunktion nach den Modellparametern gleich null gesetzt wird. Bei einer Minimierungsaufgabe wird damit ein Minimum gesucht, nicht ein Maximum.

Wenn die Modellparameter nichtlinear in das Modell beziehungsweise in die Residuen der Kostenfunktion $Q$ (auch *Zielfunktion* genannt) eingehen, führt die Schätzaufgabe im Allgemeinen auf ein nichtlineares Optimierungsproblem. Die Parameter werden dann iterativ variiert, um ein Minimum von $Q$ zu finden.

Wir sind von normalverteilten Abweichungen ausgegangen und haben uns die Likelihoodverteilungen angeschaut. Als Beispiel nehmen wir ein Modell mit 2 Parametern, bei dem eine Gerade durch den Ursprung des Koordinatensystems eines dreidimensionalen Raums gehe und bei dem alle drei Achsen von der gleichen physikalischen Dimension seien. Die beiden zu schätzenden Parameter seien hier der Azimutalwinkel $\alpha$ und der Polarwinkel $\theta$, die die gesuchte Richtung der Geraden beschreiben. Ein Punkt $\mathbf{r}$, der exakt auf der Geraden liegt, erfülle

$$\mathbf{r} = \lambda \mathbf{u} \qquad \text{mit} \qquad \mathbf{u}(\alpha, \theta) = \begin{pmatrix} \cos(\alpha)\sin(\theta) \\ \sin(\alpha)\sin(\theta) \\ \cos(\theta) \end{pmatrix} \qquad \text{und} \qquad \lambda \in \mathbb{R}. \tag{3.1}$$

Abb. 3.1 zeigt das Modell als schwarz gestrichelte Gerade und die Beobachtungen als blaue Kreise sowie rechts die zugehörige Likelihoodverteilung. Die Suche nach dem Maximum der Likelihood kann als Suche nach dem Minimum der negativen Log-Likelihood formuliert werden. Gesucht ist die Geradenrichtung, für die die senkrechten Abstände der Messpunkte $\mathbf{r}_{\mathrm{Mess},j} = (X_{1,j}, X_{2,j}, X_{3,j})^{\mathsf{T}}$ minimal sind. Für dieses Anschauungsbeispiel nehmen wir isotrope, normalverteilte Abweichungen senkrecht zur Geraden an. Der Betrag des senkrechten Abstands ist

$$\varepsilon_j(\alpha,\theta) \;=\; \|\mathbf{r}_{\mathrm{Mess},j} \;-\; (\mathbf{r}_{\mathrm{Mess},j}\cdot\mathbf{u}(\alpha,\theta))\,\mathbf{u}(\alpha,\theta)\|_2 \tag{3.2}$$

mit $\|\mathbf{a}\|_2 = \sqrt{a_1^2+a_2^2+a_3^2}$. Die Größe $\varepsilon_j$ ist hier ein nichtnegativer Abstand. Für die in Abb. 3.1 dargestellte Likelihoodverteilung verwenden wir daher bis auf einen von $\alpha$ und $\theta$ unabhängigen Faktor

$$p(\varepsilon_1,\ldots,\varepsilon_J \mid \alpha,\theta) \propto e^{-\frac{1}{2}\sum\limits_{j=1}^{J}\left(\frac{\varepsilon(\alpha,\theta)_j}{\sigma}\right)^2}. \tag{3.3}$$

Für den Schätzvorgang wählen wir die Summe der Quadrate der Abstände, $Q = \sum_j \varepsilon_j^2$, also die Methode der kleinsten Quadrate beziehungsweise die Minimierung der Residuenquadratsumme (RQS):

$$\min_{\alpha,\theta} \sum_{j=1}^{J} \varepsilon(\alpha,\theta)_j^2. \tag{3.4}$$

Die Optimierungsrechnung bietet sehr unterschiedliche Methoden für eine Minimumsuche.

Wir können sie grob danach einteilen

- ob das nächste Modellparametertupel gemäß einer gewissen Strategie aus mehreren Vorgängertupeln mit den dazugehörigen Werten der Kostenfunktion $Q$ gewonnen wird
- oder ob nicht nur die Kostenfunktion $Q$ direkt, sondern auch deren Gradienten bestimmt werden.

Ein möglicher, vielfach genutzter Ansatz, bei dem mehrere bisherige Parametertupel mit den zugehörigen Werten der RQS verwendet werden, ist die **Simplexmethode nach Nelder und Mead** aus dem Jahr 1965. Sie wird als Bibliotheksfunktion `fminsearch` in GNU Octave und in Matlab zur Verfügung gestellt. Mit Simplex ist ein Vieleck gemeint, das für $M$ Parameter $M+1$ Ecken hat, in unserem Beispiel also drei Ecken für zwei Parameter. In Abb. 3.2 ist dies durch schwarz umrandete weiße Punkte, die mit schwarzen, durchgezogenen Linien verbunden sind, skizziert. Zum Aufbau eines Startsimplex wird ein Startwerttupel $\mathbf{p}_{0,0}$ des Modellparametervektors gewählt und zu jedem Parameter ein weiterer Vektor, der eine Variation $\Delta P_m$ repräsentiert:

$$\mathbf{p}_{0,1} \;=\; \mathbf{p}_{0,0} \;+\; \begin{pmatrix} \Delta P_1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \qquad \mathbf{p}_{0,m} \;=\; \mathbf{p}_{0,0} \;+\; \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \Delta P_m \\ 0 \\ \vdots \\ 0 \end{pmatrix} \qquad \mathbf{p}_{0,M} \;=\; \mathbf{p}_{0,0} \;+\; \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \Delta P_M \end{pmatrix} \tag{3.5}$$

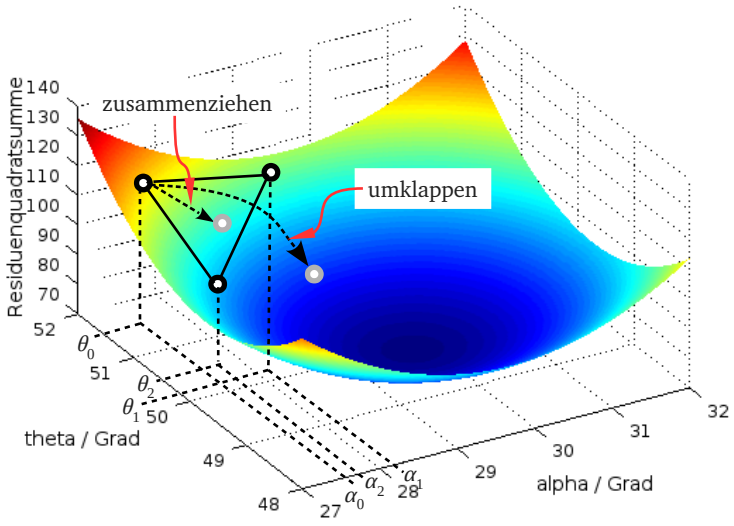



Abbildung 3.2: Residuenquadratsumme des Beispielmodells mit 2 zu schätzenden Parametern und Simplex für Optimierungsverfahren nach Nelder und Mead.

Die Strategie besteht darin, den Simplex durch Reflexion (Umklappen), Expansion, Kontraktion und gegebenenfalls Verkleinerung schrittweise in Richtung einer Minimumsmulde zu bewegen. Diese Operationen sind in Abb. 3.2 durch die hellgrau umrandeten Punkte und schwarze Pfeile angedeutet. Welche Operation ausgeführt wird, hängt von den Funktionswerten an den Simplex-Ecken ab. Der Algorithmus terminiert, wenn sich der Simplex und die Funktionswerte gemäß den vorgegebenen Toleranzen nur noch wenig ändern. Hierzu gibt es dann noch verschiedene Ansätze, wie überprüft wird, ob er zu weit über dem Tal waagerecht festhakt und eigentlich noch eine zu große Mulde darunter liegt und eines der Simplexbeine angezogen werden muss.

Dieses Verfahren benötigt keine Ableitungen und eignet sich daher auch für Zielfunktionen, die nicht glatt oder nur schwer differenzierbar sind. Für Messungen mit nicht normalverteilten Abweichungen kann beispielsweise eine Laplace-artige Verlustfunktion verwendet werden:

$$p(\varepsilon_1, \ldots, \varepsilon_J \mid \alpha, \theta) \propto \exp\left(-\frac{1}{b}\sum_{j=1}^{J} |\varepsilon_j(\alpha, \theta)|\right), \qquad b > 0, \tag{3.6}$$

was zu einer Minimierung der Absolutbeträge der Residuen führt. Bei dem zu minimierenden Ausdruck

$$\min_{\alpha,\theta} \sum_{j=1}^{J} |\varepsilon(\alpha, \theta)_j| \tag{3.7}$$

bildet sich durch die Betragsbildung eine ausgeprägt scharfe Spitze. Die Zielfunktion ist an solchen Stellen nicht differenzierbar; der Gradient[1] ist dort nicht definiert. Für das Simplexverfahren ist das unproblematisch. Ein Nachteil ist jedoch seine Empfindlichkeit gegenüber der Wahl des Startsimplex. Es kann im günstigen Fall lediglich langsam sein, im ungünstigen Fall aber an einer nicht optimalen Stelle stagnieren oder nicht konvergieren. Bei vielen Parametern kann dieses Verhalten zusätzlich

[1] Ein Gradient ist eine Steigung im mehrdimensionalen Raum

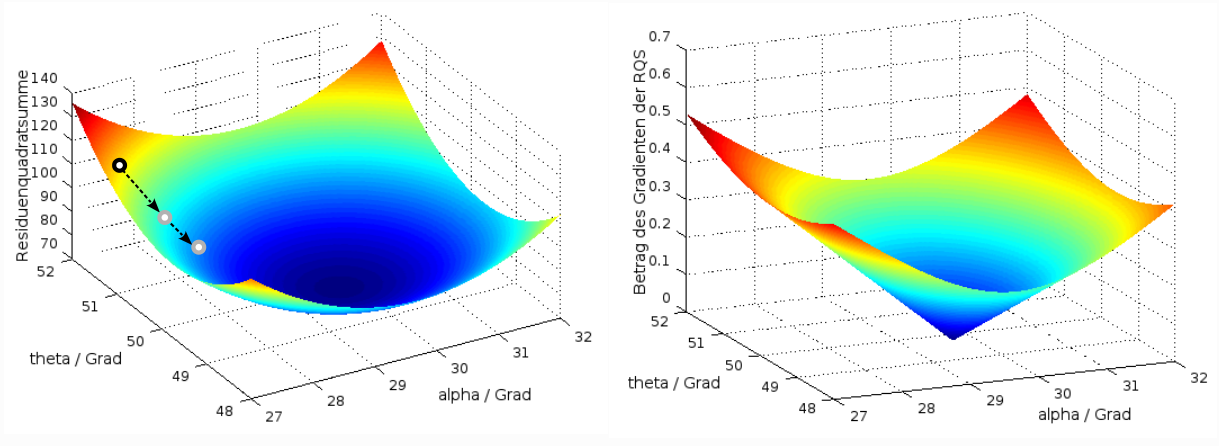



Abbildung 3.3: Residuenquadratsumme des Beispielmodells mit 2 zu schätzenden Parametern und Gradienten eingezeichnet als Pfeile (*links*) und Beträge der Gradienten als Funktion der 2 zu schätzenden Parameter (*rechts*).

problematisch werden.

Für Zielfunktionen wie die Residuenquadratsumme bei normalverteilten Residuen, die rundlich und stetig differenzierbar sind, können wir Verfahren einsetzen, die nicht nur die Kostenfunktion $Q$ direkt, sondern auch deren Gradienten $\nabla Q$ verwenden. Hierzu wird *ein* Startwertetupel (nicht wie bei der Simplexmethode $M+1$) für die Modellparameter festgelegt. Es wird der Gradient, also die Richtung des steilsten Abstiegs der Kostenfunktion, an der Position des Startwerttupels bestimmt. Dieses Verfahren wird im folgenden Abschnitt anhand des Beispiels erläutert.

## 3.2 Gradientenverfahren für nichtlineare Kostenfunktionen

Das Gradientenverfahren beziehungsweise das Gauß-Newton-Verfahren benötigt, wie andere iterative Verfahren zur Schätzung von Parametern, die nichtlinear in die Residuen eingehen, einen Startwertvektor der Parameter. Dieser ist in Abb. 3.3 als schwarz umrandeter weißer Punkt dargestellt. In Abb. 3.3 ist die Idee illustriert, wie sich die Position des Parametervektors während der Iteration verändert. Die Änderungsvektoren $\mathbf{\Delta p}$ werden so bestimmt, dass sich die Kostenfunktion verringert. Anschaulich erfolgt die Bewegung in Richtung der Talsohle der durch die Kostenfunktion gebildeten Mulde, wie durch die gestrichelten Pfeile skizziert.

Die Ableitung eines Residuums nach den Parametern an der Stelle des Startwertvektors $(\alpha_0, \theta_0)$ ist der Vektor der partiellen Ableitungen

$$\nabla_{\alpha,\theta}\varepsilon_j|_{\alpha_0,\theta_0} = \left.\begin{pmatrix} \dfrac{\partial \varepsilon_j}{\partial \alpha} \\ \dfrac{\partial \varepsilon_j}{\partial \theta} \end{pmatrix}\right|_{\alpha_0,\theta_0} . \tag{3.8}$$

Das auf die Spitze gestellte Dreieck heißt Nablaoperator. Die Schreibweise $\cdot|_{\alpha_0,\theta_0}$ lesen wir als „an der Stelle $(\alpha_0, \theta_0)$“.

Für die Minimierung bestimmen wir die Stelle $(\hat{\alpha}, \hat{\theta})$, an der sich die Talsohle der Mulde der RQS-Funktion befindet. Anders gesagt suchen wir die Position im Modellparameterraum, an der die Kostenfunktion minimal wird. Eine notwendige Bedingung für ein Minimum ist, dass der Gradient der Kostenfunktion verschwindet:

$$\nabla_{\alpha,\theta} \sum_{j=1}^{J} \varepsilon_j^2(\alpha,\theta)\Big|_{\hat{\alpha},\hat{\theta}} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}. \tag{3.9}$$

Dabei müssen wir beachten, dass ein verschwindender Gradient nur eine notwendige, aber keine hinreichende Bedingung für ein Minimum ist. Auch Sattelpunkte erfüllen diese Bedingung. Deshalb muss zusätzlich geprüft oder durch das Verfahren sichergestellt werden, dass tatsächlich ein Minimum der Kostenfunktion erreicht wird.

Wir ziehen den Nablaoperator in die Summe hinein und verwenden die Kettenregel:

$$\nabla_{\alpha,\theta} \sum_{j=1}^{J} \varepsilon_j^2(\alpha,\theta) = \sum_{j=1}^{J} \nabla_{\alpha,\theta} \varepsilon_j^2(\alpha,\theta) = 2 \sum_{j=1}^{J} \varepsilon_j(\alpha,\theta) \nabla_{\alpha,\theta} \varepsilon_j(\alpha,\theta) \stackrel{!}{=} \begin{pmatrix} 0 \\ 0 \end{pmatrix}. \tag{3.10}$$

Die beiden Parameter $\alpha$ und $\theta$ fassen wir nun in einem Parametervektor zusammen und betrachten den allgemeinen Fall mit $M$ Parametern

$$\mathbf{p} = (P_1, \ldots, P_M)^{\mathsf{T}}. \tag{3.11}$$

Die Residuen sind dann Funktionen dieses Parametervektors:

$$\boldsymbol{\varepsilon}(\mathbf{p}) = (\varepsilon_1(\mathbf{p}), \ldots, \varepsilon_J(\mathbf{p}))^{\mathsf{T}}. \tag{3.12}$$

Die Kostenfunktion $Q$ ist damit ebenfalls eine Funktion des Parametervektors:

$$Q(\mathbf{p}) = \boldsymbol{\varepsilon}^{\mathsf{T}}(\mathbf{p}) \boldsymbol{\varepsilon}(\mathbf{p}) = \sum_{j=1}^{J} \varepsilon_j^2(\mathbf{p}). \tag{3.13}$$

Gesucht ist das Minimum

$$\min_{\mathbf{p}} \{Q(\mathbf{p})\}. \tag{3.14}$$

Dazu suchen wir eine Nullstelle des Gradienten der Kostenfunktion,

$$\nabla_{\mathbf{p}} Q(\mathbf{p}) = 2\, \boldsymbol{J}^{\mathsf{T}}(\mathbf{p})\, \boldsymbol{\varepsilon}(\mathbf{p}), \tag{3.15}$$

für die $Q$ ein Minimum und nicht nur einen stationären Punkt annimmt. Dabei ist $\nabla_{\mathbf{p}}$ als Spaltenvektor der partiellen Ableitungsoperatoren $\partial/\partial P_m$ aufgefasst. Die Matrix $\boldsymbol{J}$ ist *Jacobi-Matrix* der Residuen.

$$\mathbf{J} = \begin{pmatrix} \vdots & \\ \cdots & \frac{\partial \varepsilon_j}{\partial P_m} \quad \cdots \\ \vdots & \end{pmatrix} \tag{3.16}$$

Für ein einzelnes Residuum gilt entsprechend

$$\frac{\partial}{\partial P_m}\varepsilon_j^2(\mathbf{p}) = 2\varepsilon_j(\mathbf{p})\frac{\partial \varepsilon_j(\mathbf{p})}{\partial P_m}. \tag{3.17}$$

Wir suchen also dasjenige $\hat{\mathbf{p}}$, für das

$$\nabla_{\mathbf{p}} Q(\hat{\mathbf{p}}) = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \tag{3.18}$$

gilt.

Bei der Suche nach dem Minimum wird mit einem Startwertvektor $\mathbf{p}_0$ begonnen. Dann wird ein *Inkrementvektor* $\Delta\mathbf{p}_0$ bestimmt, mit dem man zu einem Nachfolgepunkt im Raum der Modellparameter gelangt:

$$\mathbf{p}_1 = \mathbf{p}_0 + \Delta\mathbf{p}_0. \tag{3.19}$$

Dies wird iterativ fortgesetzt, bis der Parametervektor hinreichend nahe am Minimum von $Q$ liegt. Nach einer gewissen Anzahl $K$ von Iterationsschritten wird der Vektor $\mathbf{p}_K$ als Schätzwertvektor $\hat{\mathbf{p}}$ für die Modellparameter verwendet:

$$\hat{\mathbf{p}} \approx \mathbf{p}_K. \tag{3.20}$$

Die einzelnen Iterationsschritte $\kappa$ beschreiben jeweils eine Revision des Modellparametervektors:

$$\mathbf{p}_{\kappa+1} = \mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa. \tag{3.21}$$

Die zugehörigen *Inkrementvektoren* sind

$$\Delta\mathbf{p}_0, \ldots, \Delta\mathbf{p}_\kappa, \ldots, \Delta\mathbf{p}_{K-1}.$$

Wir nehmen nun eine Taylorreihenentwicklung vor, mit der wir die Residuen in linearer Näherung als Funktion eines Inkrementvektors $\Delta\mathbf{p}$ darstellen. Dazu entwickeln wir die Residuen $\varepsilon_j$ um die aktuelle Parameterposition $\mathbf{p}_\kappa$ bis zum linearen Term:

$$\begin{pmatrix} \varepsilon_1(\mathbf{p}_\kappa + \Delta\mathbf{p}) \\ \vdots \\ \varepsilon_j(\mathbf{p}_\kappa + \Delta\mathbf{p}) \\ \vdots \\ \varepsilon_J(\mathbf{p}_\kappa + \Delta\mathbf{p}) \end{pmatrix} \approx \begin{pmatrix} \varepsilon_1(\mathbf{p}_\kappa) + \nabla_{\mathbf{p}}^{\mathsf{T}}\varepsilon_1\big|_{\mathbf{p}_\kappa}\Delta\mathbf{p} \\ \vdots \\ \varepsilon_j(\mathbf{p}_\kappa) + \nabla_{\mathbf{p}}^{\mathsf{T}}\varepsilon_j\big|_{\mathbf{p}_\kappa}\Delta\mathbf{p} \\ \vdots \\ \varepsilon_J(\mathbf{p}_\kappa) + \nabla_{\mathbf{p}}^{\mathsf{T}}\varepsilon_J\big|_{\mathbf{p}_\kappa}\Delta\mathbf{p} \end{pmatrix}. \tag{3.22}$$

Die partiellen Ableitungen der einzelnen Residuen nach allen Parametern bilden eine $J \times M$-Matrix, die *Jacobi-Matrix*:

$$\boldsymbol{J}^{(\kappa)} = \begin{pmatrix} \left.\frac{\partial\varepsilon_1}{\partial P_1}\right|_{\mathbf{p}_\kappa} & \cdots & \left.\frac{\partial\varepsilon_1}{\partial P_M}\right|_{\mathbf{p}_\kappa} \\ \vdots & \ddots & \vdots \\ \left.\frac{\partial\varepsilon_J}{\partial P_1}\right|_{\mathbf{p}_\kappa} & \cdots & \left.\frac{\partial\varepsilon_J}{\partial P_M}\right|_{\mathbf{p}_\kappa} \end{pmatrix}, \qquad J_{jm}^{(\kappa)} = \left.\frac{\partial\varepsilon_j}{\partial P_m}\right|_{\mathbf{p}_\kappa}, \tag{3.23}$$

mit $j = 1, \ldots, J$ und $m = 1, \ldots, M$.

Der hochgestellte und in Klammern gesetzte Index $\kappa$ am Symbol der *Jacobi-Matrix* bedeutet, dass die Jacobi-Matrix an der aktuellen Parameterposition $\mathbf{p}_\kappa$ ausgewertet wird. Der Begriff Jacobi-Matrix bedeutet, dass es sich um eine Matrix erster partieller Ableitungen handelt. Die Jacobi-Matrix ist nach Carl Gustav Jacob Jacobi benannt und wird auch *Funktionalmatrix*, *Ableitungsmatrix* oder *Jacobische* genannt.

> Die Jacobi-Matrix einer differenzierbaren Funktion $f : \mathbb{R}^n \to \mathbb{R}^m$ ist die $m \times n$-Matrix sämtlicher erster partieller Ableitungen.

Einsetzen der Jacobi-Matrix in Gl. (3.22) liefert

$$\begin{pmatrix} \varepsilon_1(\mathbf{p}_\kappa + \Delta\mathbf{p}) \\ \vdots \\ \varepsilon_J(\mathbf{p}_\kappa + \Delta\mathbf{p}) \end{pmatrix} \approx \begin{pmatrix} \varepsilon_1(\mathbf{p}_\kappa) \\ \vdots \\ \varepsilon_J(\mathbf{p}_\kappa) \end{pmatrix} + \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}. \tag{3.24}$$

In Vektorschreibweise lautet diese linearisierte Residuenfunktion

$$\boldsymbol{\varepsilon}(\mathbf{p}_\kappa + \Delta\mathbf{p}) \approx \boldsymbol{\varepsilon}(\mathbf{p}_\kappa) + \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}. \tag{3.25}$$

Mit der Jacobi-Matrix kann der Gradient der Kostenfunktion geschrieben werden als

$$\frac{1}{2}\nabla_{\mathbf{p}} Q(\mathbf{p}) = \boldsymbol{J}^{\mathsf{T}}(\mathbf{p})\boldsymbol{\varepsilon}(\mathbf{p}). \tag{3.26}$$

Diese Gleichung ist die Vektorform der Beziehung

$$\frac{\partial Q}{\partial P_m} = 2\sum_{j=1}^{J} \varepsilon_j(\mathbf{p})\frac{\partial \varepsilon_j(\mathbf{p})}{\partial P_m}.$$

Für den Gauß-Newton-Schritt wird die linearisierte Residuenfunktion aus Gl. (3.25) in die Bedingung für einen verschwindenden Gradienten eingesetzt. Dabei wird die Jacobi-Matrix an der aktuellen Position $\mathbf{p}_\kappa$ ausgewertet und innerhalb dieses Schrittes als konstant betrachtet:

$$\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \left[\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) + \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}_\kappa\right] \stackrel{!}{=} \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}. \tag{3.27}$$

Daraus folgt

$$\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}_\kappa \stackrel{!}{=} -\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}_\kappa). \tag{3.28}$$

Dies sind die Normalgleichungen für den Gauß-Newton-Schritt. In der numerischen Praxis wird dieses System nicht durch die explizite Bildung einer Inversen gelöst, sondern beispielsweise mit einer QR- oder Cholesky-Zerlegung beziehungsweise mit einem geeigneten linearen Gleichungslöser. Die Lösung

liefert den Inkrementvektor $\Delta\mathbf{p}_\kappa$, mit dem die nächste Parameterposition bestimmt wird:

$$\mathbf{p}_{\kappa+1} = \mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa. \tag{3.29}$$

Die Iteration kann beendet werden, wenn die Norm des Gradienten der Kostenfunktion hinreichend klein ist. Da

$$\nabla_{\mathbf{p}} Q(\mathbf{p}_\kappa) = 2\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}_\kappa), \tag{3.30}$$

kann als Abbruchkriterium zum Beispiel verwendet werden:

$$\left\| \left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}_\kappa) \right\|^2 = \boldsymbol{\varepsilon}^{\mathsf{T}}(\mathbf{p}_\kappa) \boldsymbol{J}^{(\kappa)} \left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}_\kappa) < \eta. \tag{3.31}$$

Hierbei ist $\eta$ eine vorgegebene kleine positive Toleranz. Alternativ oder zusätzlich kann auch geprüft werden, ob sich der Parametervektor oder der Wert der Kostenfunktion zwischen zwei Iterationsschritten nur noch sehr wenig ändert.

Für Kostenfunktionen, die wie in Abb. 3.3 eine gut ausgeprägte Minimumsmulde haben, und für Startwerte der Modellparameter, die hinreichend nahe an diesem Minimum liegen, kann das Gauß-Newton-Verfahren das Minimum effizient bestimmen. Eine globale Konvergenz ist daraus jedoch nicht abzuleiten; bei ungünstigen Startwerten kann eine Schrittweitensteuerung oder ein gedämpftes Verfahren erforderlich sein.

## 3.3 Beispiel zum Gauß-Newton-Verfahren bei gleichen Varianzen

Gegeben ist die Gl.(3.28) mit

$$\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{J}^{(\kappa)}\, \Delta\mathbf{p}_\kappa \stackrel{!}{=} -\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}_\kappa)$$

zur Bestimmung der Modellparameter. Mit dieser Gleichung wird in jeder Iteration die Änderung $\Delta\mathbf{p}_\kappa$ des Parametervektors bestimmt. Anschließend erhält man den neuen Parametervektor

$$\mathbf{p}_{\kappa+1} = \mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa$$

Die Optimierung endet beispielsweise, wenn die Schrittweite, die Änderung der Kostenfunktion oder der Gradient hinreichend klein ist oder eine vorgegebene maximale Iterationsanzahl erreicht wurde. Die Jacobi-Matrix $J$ enthält die partiellen Ableitungen der Residuen nach den Modellparametern:

$$J_{jl}^{(\kappa)} = \left.\frac{\partial \varepsilon_j(\boldsymbol{p})}{\partial p_l}\right|_{\boldsymbol{p}=\boldsymbol{p}_\kappa}$$

Hierbei läuft der Index der Wertepaare von $j = 1, \ldots, J$ und der Index der gesuchten Modellparameter von $l = 1, \ldots, M$.

Die Gl. (3.28) kann in einen Programmiercode umgesetzt werden.

**Algorithmus des Gauß-Newton-Verfahrens**

Input: Startwert $\boldsymbol{p}_0$, Residuenvektor $F(\boldsymbol{p}_\kappa) := \boldsymbol{\varepsilon}(\boldsymbol{p}_\kappa)$ und Jacobi-Matrix $F'(\boldsymbol{p}_\kappa) := \boldsymbol{J}(\boldsymbol{p}_\kappa)$

*for* $\kappa = 0, 1, \ldots$

i) Berechne $F(\boldsymbol{p}_\kappa)$ und $F'(\boldsymbol{p}_\kappa)$.

ii) Bestimme den Korrekturvektor $s_\kappa$ aus $F'(\boldsymbol{p}_\kappa)^\mathsf{T} F'(\boldsymbol{p}_\kappa) s_\kappa = -F'(\boldsymbol{p}_\kappa)^\mathsf{T} F(\boldsymbol{p}_\kappa)$.

iii) Setze $\boldsymbol{p}_{\kappa+1} = \boldsymbol{p}_\kappa + s_\kappa$.

*end*

Eine einfache mögliche Realisierung in Octave-/Matlab ist nachfolgend dargestellt:

```
function p = gauss_newton(F,DF,p0,maxit,tol)
% F:      Residuenvektor
% DF:     Jacobi-Matrix des Residuenvektors
% p0:     Startwert des Parametervektors
% maxit:  maximale Anzahl von Iterationen
% tol:    relative Toleranz fuer die Schrittweite
p=p0;
for k=1:maxit
    r=F(p);
    J=DF(p);
    s=-(J'*J)\(J'*r);
    if norm(s)<=tol*(1+norm(p))
        break
    end
        p=p+s;
end
end
```

`F` muss dabei den $J$-dimensionalen Residuenvektor und `DF` seine $J \times M$-Jacobi-Matrix liefern; die skalare Kostenfunktion $Q = \boldsymbol{\varepsilon}^\mathsf{T}\boldsymbol{\varepsilon}$ darf nicht an die Stelle des Residuenvektors treten. Die Normalgleichungen werden in realen Anwendungen vorzugsweise mit einer stabilen Faktorisierung gelöst. Das Minimalbeispiel enthält außerdem noch keine Schrittweitensteuerung, sodass eine Konvergenz nicht für beliebige Startwerte garantiert ist.

**Nichtlinearer Fit eines Kreises mit dem Gauß-Newton-Verfahren**

Im Folgenden wird ein Kreisfit, also ein nichtlinearer Fit, mit dem Gauß-Newton-Verfahren durchgeführt. Gegeben sei die Punktwolke mit den Wertepaaren $(X_j, Y_j)$ für $j = 1, \ldots, J$. Alle Punkte sollen näherungsweise auf einem Kreis liegen. Geht man von einem Kreis mit Mittelpunkt $M = (x_\mathrm{c}, y_\mathrm{c})$ und einem Radius $r > 0$ aus, so müssten die Punkte die folgende Bedingung erfüllen:

$$\sqrt{(X_j - x_\mathrm{c})^2 + (Y_j - y_\mathrm{c})^2} \approx r; \quad j = 1, \ldots, J \tag{3.32}$$

Die Aufgabe besteht darin, den Mittelpunkt $M$ und den Radius $r$ so zu bestimmen, dass die Summe der Residuenquadrate minimal wird. Die Residuen sind

$$\varepsilon_j = \sqrt{(X_j - x_\mathrm{c})^2 + (Y_j - y_\mathrm{c})^2} - r, \qquad j = 1, \ldots, J \tag{3.33}$$

Das Problem lässt sich damit wie folgt formulieren:

$$Q(x_\mathrm{c}, y_\mathrm{c}, r) \;=\; \sum_{j=1}^{J} \left( \sqrt{(X_j - x_\mathrm{c})^2 + (Y_j - y_\mathrm{c})^2} - r \right)^2 \;\longrightarrow\; \min \tag{3.34}$$

Es besteht kein linearer Zusammenhang zwischen den Parametern $\boldsymbol{\theta} = (x_\mathrm{c}, y_\mathrm{c}, r)^\mathsf{T}$ und den Residuen.

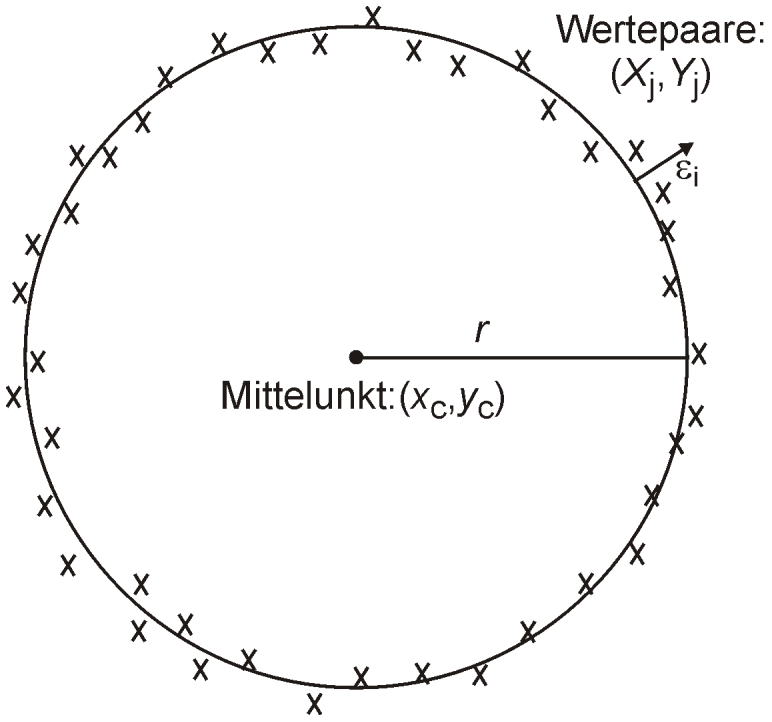



Abbildung 3.4: Skizze für den Fit eines Kreises

Zur Demonstration des Gauß-Newton-Verfahrens wird zunächst nur der erste Parameter, also der Mittelpunktparameter $x_\mathrm{c}$, geschätzt. Die beiden anderen Parameter werden zu $y_\mathrm{c} = 0$ und $r = 1$ gesetzt. Dann besteht die Jacobi-Matrix aus einer Spalte. Bei einer Schätzung aller drei Parameter müssten zusätzlich die Ableitungen nach $y_\mathrm{c}$ und $r$ verwendet werden.

Für die eingeschränkte Aufgabe ist der Residuenvektor

$$F(x_c)_j = \sqrt{(X_j - x_c)^2 + Y_j^2} - r, \qquad j = 1, \ldots, J. \tag{3.35}$$

Die zugehörige Jacobi-Matrix enthält die Ableitung jedes Residuums:

$$DF(x_c)_j = -\frac{X_j - x_c}{\sqrt{(X_j - x_c)^2 + Y_j^2}}. \tag{3.36}$$

Im dargestellten Beispiel ergibt sich für den Mittelpunktparameter näherungsweise $x_\mathrm{c} = -0.0067$. Das Octave-/Matlab-Skript lautet:

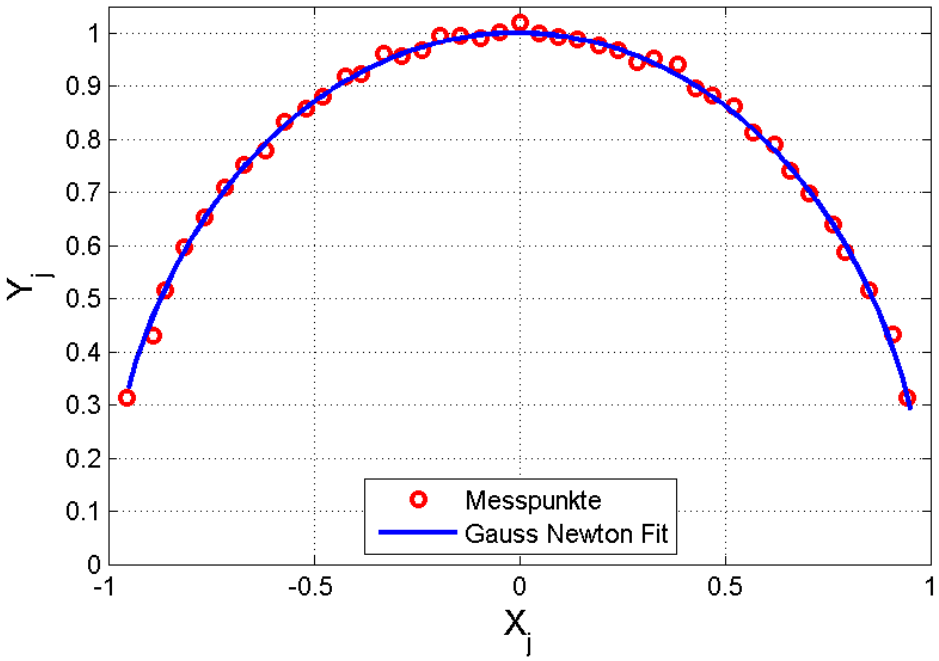



Abbildung 3.5: Ergebnis des Gauß-Newton-Fits

```
% Anzahl der Messpunkte
M = 41;
Xj=linspace(-0.95,0.95,M)';
r=1;
Yj = sqrt(r.^2-Xj.^2);

figure
plot(Xj,Yj,'*')

Xj_Noise = (1-0.01*randn(M,1)).*Xj;
Yj_Noise = (1-0.01*randn(M,1)).*Yj;

figure
plot(Xj_Noise,Yj_Noise,'ro','linewidth',2)
hold on
Xj=Xj_Noise;
Yj=Yj_Noise;
yc = 0;
r=1;
% F liefert den Residuenvektor, DF seine Jacobi-Matrix
F = @(xc) sqrt((Xj-xc).^2+(Yj-yc).^2)-r;
DF = @(xc) -(Xj-xc)./sqrt((Xj-xc).^2+(Yj-yc).^2);
% Startparameter
theta0 = 0.1;
```

```
maxit = 1000; % maximale Anzahl der Iterationen
tol = 1E-12; % relative Abbruchbedingung
xc_estimate = gauss_newton(F,DF,theta0,maxit,tol);
disp(xc_estimate);

Xjfit=linspace(-0.95,0.95,101);
%
Yjfit = sqrt(r.^2-(Xjfit-xc_estimate).^2)+ yc;
plot(Xjfit,Yjfit,'-','linewidth',2)
grid on;
xlim([-1,1])
ylim([0,1.05])
legend('Messpunkte','Gauss-Newton-Fit','Location','South')
xlabel('X_j','fontsize',14)
ylabel('Y_j','fontsize',14)
set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 10;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' Kreisfit_Gauss_Newton.png
```

## 3.4 Levenberg-Marquardt-Verfahren

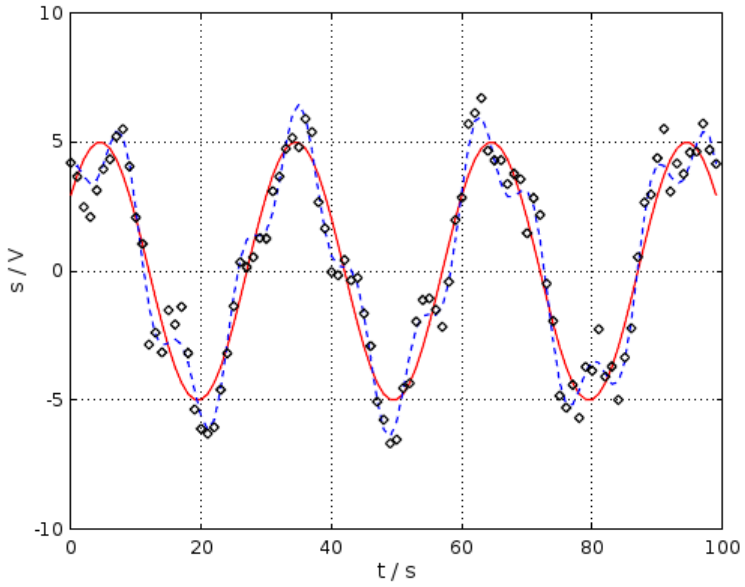



Abbildung 3.6: Beispiel eines sinusförmigen Signals.

Eine sinnvolle Konvergenz des Gauß-Newton-Verfahrens setzt häufig einen geeigneten Startvektor $\mathbf{p}_0$ voraus. Dieser ist in manchen Problemstellungen nur schwer zu bestimmen. Bei ungünstigen Startwerten kann ein Gauß-Newton-Schritt die Zielfunktion vergrößern oder in eine ungeeignete Minimumsmulde führen.

Gedämpfte Verfahren verbinden die lokale Gauß-Newton-Näherung mit einer robusteren Schrittweitensteuerung. Der *Levenberg-Marquardt*-Algorithmus ist ein solches Verfahren und steht in vielen numerischen Bibliotheken für nichtlineare Ausgleichsprobleme zur Verfügung. Die Grundidee wird im Folgenden skizziert. Die Möglichkeit, dass sich der Inkrementvektor $\Delta\mathbf{p}_\kappa$ verirrt, soll anhand eines Beispielsignals illustriert werden. Das Beispiel ist ein zeitabhängiges Spannungssignal mit sinusförmigem Verlauf, dem als Störung zum einen ein Signal mit höherer Frequenz und kleinerer Amplitude aufmoduliert ist und zum anderen ein normalverteiltes weißes Rauschen. Die Amplitude von 5 V sei fest vorgegeben, aber die zu schätzenden Modellparameter seien die Wellenlänge und die Phasenlage des Signals. Abb. 3.6 zeigt das Signal als schwarze Rauten und in Rot das gesuchte „wahre“ Signal und als blaue, gestrichelte Kurve das Signal superponiert mit der höherfrequenten Modulation.

Abb. 3.7 zeigt die Summe der Quadrate der Residuen (RQS) als Kostenfunktion in drei verschiedenen Ansichten. Neben einer ausgeprägten Minimumsmulde sind weitere lokale Strukturen erkennbar. Das Diagramm unten rechts zeigt den Betrag des Gradienten. Sowohl an lokalen Minima als auch an lokalen Maxima und Sattelpunkten kann der Gradient verschwinden; aus einer Nullstelle des Gradienten allein folgt daher noch kein Minimum.

Der *Levenberg-Marquardt*-Algorithmus ist ein Verfahren für nichtlineare Ausgleichsprobleme, bei dem das lineare Gleichungssystem (3.28) durch Einführen eines Dämpfungsterms erweitert wird.

Mit der Gauß-Newton-Methode kann die Kostenfunktion $Q$ bei einem Schritt größer werden. Wenn

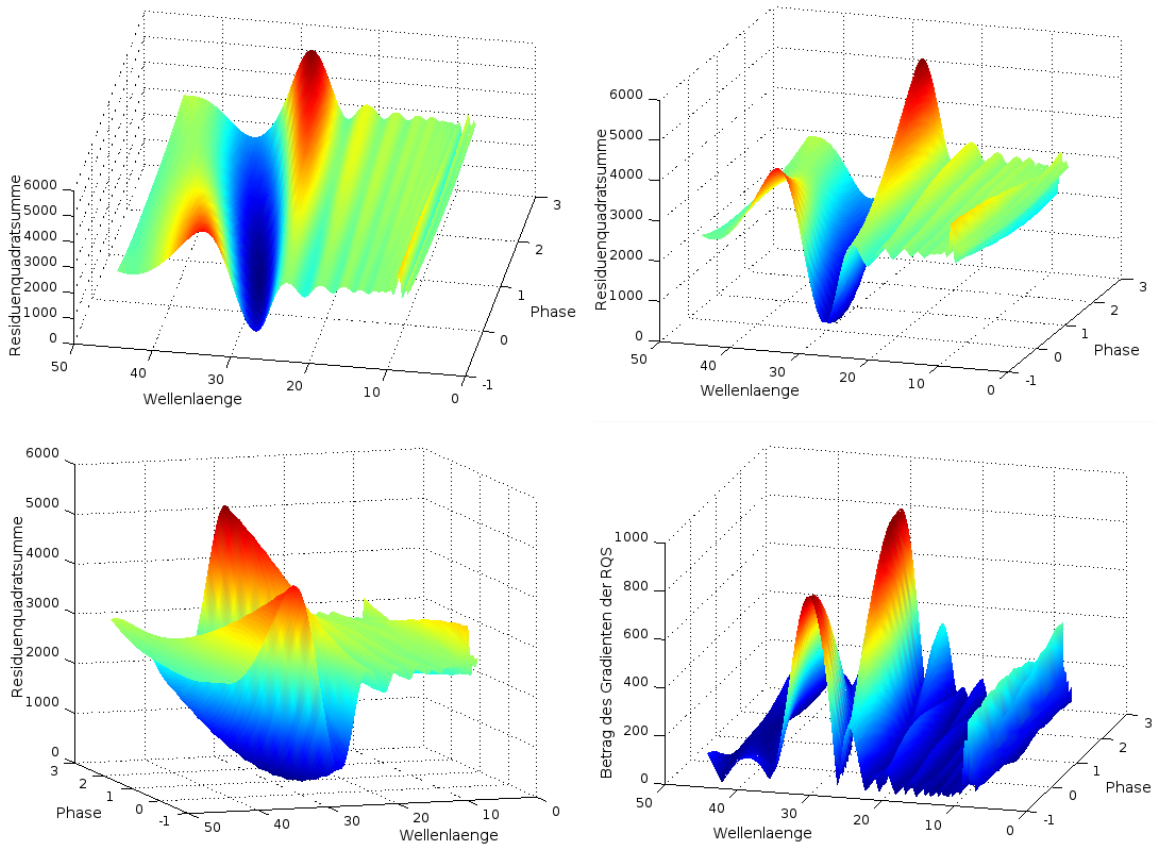



Abbildung 3.7: Residuenquadratsumme des Beispielmodells eines sinusförmigen Signals in drei verschiedenen Perspektiven dargestellt (*oben* und *unten links*) und die Beträge der Gradienten als Funktion der 2 zu schätzenden Parameter (*unten rechts*).

der Korrekturvektor $\Delta\mathbf{p}_\kappa$ jedoch grundsätzlich in eine abfallende Richtung zeigt, so kann auch nur ein Bruchteil $\alpha$ des Richtungsvektors gegangen werden, solange gilt:

$$Q(\mathbf{p}_\kappa + \alpha \cdot \Delta\mathbf{p}_\kappa) < Q(\mathbf{p}_\kappa) \tag{3.37}$$

D. h., bei einer Divergenz kann zunächst ein Bruchteil $\alpha$ des Korrekturvektors verwendet werden:

$$\mathbf{p}_{\kappa+1} = \mathbf{p}_\kappa + \alpha \cdot \Delta\mathbf{p}_\kappa \tag{3.38}$$

In anderen Worten, wenn der Inkrement-Vektor zu lang ist, dann muss man diesen eben kürzen. Das geht natürlich nur unter der Voraussetzung, dass die Richtung des Vektors auch die Summe der Residuen weiter verkleinert. Der Bruchteil $\alpha$ liegt zwischen

$$0 < \alpha < 1$$

Wenn der erforderliche Bruchteil $\alpha$ sehr klein ist, kann stattdessen eine Dämpfung verwendet werden. Beim **Levenberg-Marquardt**-Algorithmus wird die Normalgleichung so modifiziert, dass für große Dämpfung ein kurzer, skaliert gradientenähnlicher Schritt entsteht. Der Dämpfungsterm ist daher kein bloßer Schrittweitenfaktor, sondern verändert auch die Richtung des Schrittes. Dieser Algorithmus wurde unabhängig voneinander von Levenberg (1944), Girard (1958), Wynne (1959), Morrison (1960) und Marquardt (1963) vorgeschlagen. In der Literatur wird heutzutage meist vom Levenberg-Marquardt-Algorithmus gesprochen.

Wir schreiben hier nochmal zusammen das zu minimierende Zielfunktional $Q$ aus Gl. (3.15) links und die in Taylorreihe entwickelten Residuen $\boldsymbol{\varepsilon}(\mathbf{p})$ (Gl. 3.25) auf

$$Q \;=\; \boldsymbol{\varepsilon}(\mathbf{p})^\mathsf{T}\,\boldsymbol{\varepsilon}(\mathbf{p}) \qquad \boldsymbol{\varepsilon}(\mathbf{p}) \;=\; \boldsymbol{\varepsilon}(\mathbf{p}_\kappa) \;+\; \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}$$

und setzen diese ineinander ein, so dass die Kostenfunktion wie folgt aussieht

$$Q \;=\; \Big(\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) \;+\; \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}\Big)^\mathsf{T}\,\Big(\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) \;+\; \boldsymbol{J}^{(\kappa)}\Delta\mathbf{p}\Big)\,. \tag{3.39}$$

Damit hatten wir im vorigen Abschnitt einen Ansatz erhalten, der ein bezüglich des Inkrementvektors $\Delta\mathbf{p}_\kappa$ lineares Gleichungssystem geliefert hatte. Wir notieren Gl. (3.28) hier noch einmal

$$\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{J}^{(\kappa)}\,\Delta\mathbf{p}_\kappa \;\stackrel{!}{=}\; -\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{\varepsilon}(\mathbf{p}_\kappa).$$

Nun modifizieren wir das Gleichungssystem durch Hinzufügen eines Dämpfungsterms wie folgt

$$\left(\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{J}^{(\kappa)} + \mu\,\mathrm{diag}\left(\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{J}^{(\kappa)}\right)\right)\Delta\mathbf{p}_\kappa \;\stackrel{!}{=}\; -\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) \tag{3.40}$$

wobei $\mathrm{diag}\left(\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{J}^{(\kappa)}\right)$ die Diagonalmatrix bezeichnet, deren Hauptdiagonale mit den Diagonalelementen von $\Big(\boldsymbol{J}^{(\kappa)}\Big)^\mathsf{T}\,\boldsymbol{J}^{(\kappa)}$ besetzt ist und deren übrige Elemente null sind.

Der Parameter $\mu$ wird Dämpfungsparameter oder *Marquardtparameter* genannt. Für große Werte

von $\mu$ werden die Schritte klein; bei der hier verwendeten diagonal skalierten Dämpfung nähern sie sich einem skalierten Gradientenverfahren an. Die Dämpfungsstrategie bewirkt daher, dass die Länge $\sqrt{\Delta\mathbf{p}_\kappa^\mathsf{T}\,\Delta\mathbf{p}_\kappa}$ der Inkrementschritte $\Delta\mathbf{p}_\kappa$ entsprechend verringert wird.

Die Wahl und Anpassung des Dämpfungsparameters $\mu$ ist in vielen einfachen Implementierungen heuristisch. Es gibt dafür verschiedene Strategien; im Folgenden wird eine davon als anschauliches Beispiel vorgestellt.

Es wird eine Prüfgröße $\rho_\mu$ definiert. Sie vergleicht die tatsächliche Abnahme der Kostenfunktion mit der durch das linearisierte Residuenmodell vorhergesagten Abnahme:

$$\rho_\mu := \frac{Q(\mathbf{p}_\kappa) - Q(\mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa)}{Q(\mathbf{p}_\kappa) - \left(\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) + \mathbf{J}^{(\kappa)}\Delta\mathbf{p}_\kappa\right)^\mathsf{T}\left(\boldsymbol{\varepsilon}(\mathbf{p}_\kappa) + \mathbf{J}^{(\kappa)}\Delta\mathbf{p}_\kappa\right)} =: \frac{\Delta R(\mathbf{p}_\kappa, \Delta\mathbf{p}_\kappa)}{\Delta\tilde{R}(\mathbf{p}_\kappa, \Delta\mathbf{p}_\kappa)}. \tag{3.41}$$

Die Prüfgröße $\rho_\mu$ ist das Verhältnis

- der Differenz $\Delta R$ des Zielfunktionals $Q$ zwischen der Vorgängerposition $\mathbf{p}_\kappa$ und $Q$ an der Nachfolgerposition $\mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa$ des Parametervektors
- relativ zu der Differenz $\Delta\tilde{R}$ zwischen dem $Q$ an der Stelle der Vorgängerposition $\mathbf{p}_\kappa$ und dem Wert der Residuenquadratsumme an der Position auf der Tangentialfläche, die an der Stelle $\mathbf{p}_\kappa$ an die Kostenfunktion $Q$ angelegt wird,

um dort das Zielfunktional zu approximieren.

Jetzt wird noch eine Vergleichsgröße, ein Schwellwert gebraucht, mit der die Prüfgröße verglichen wird, oder auch mehrere Schwellwerte. Hier stellen wir eine Methode vor, bei der zwei Schwellwerte $\beta_0, \beta_1$ als Entscheidungsgrundlage für die Wahl des Wertes $\mu$ verwendet werden, um den Inkrementvektor geeignet zu manipulieren. Für diese beiden heuristischen Schwellwertparameter $\beta_0$, $\beta_1$ können wir beispielsweise die Werte $\beta_0 = 0.2$, $\beta_1 = 0.8$ wählen.

Tabelle 1: Entscheidungen zur Behandlung des Marquardtparameters

| | |
|---|---|
| $\rho_\mu \leq \beta_0$: | $\Delta\mathbf{p}_\kappa$ wird nicht akzeptiert; $\mu$ wird erhöht<br>$\mu$ wird vergrößert, z.B. durch Verdoppeln $\mu \to 2\mu$,<br>und die neue zugehörige Korrektur $\Delta\mathbf{p}_\kappa$ wird berechnet |
| $\beta_0 < \rho_\mu < \beta_1$: | $\Delta\mathbf{p}_\kappa$ wird akzeptiert<br>bei der Berechnung von $\Delta\mathbf{p}_{\kappa+1}$ wird als Anfangswert dasselbe $\mu$ gewählt |
| $\rho_\mu \geq \beta_1$: | $\Delta\mathbf{p}_\kappa$ wird akzeptiert; $\mu$ wird verringert<br>bei der Berechnung von $\Delta\mathbf{p}_{\kappa+1}$ wird<br>als Anfangswert ein kleinerer Wert für $\mu$ gewählt, z.B. durch Halbieren $\mu/2$ |

**Ein möglicher Algorithmus des Levenberg-Marquardt-Verfahrens**
Input: Startwert $\mathbf{p}_0$, Residuenvektor $\boldsymbol{\varepsilon}(\mathbf{p}_\kappa)$, Jacobi-Matrix $\boldsymbol{J}(\mathbf{p}_\kappa)$, Dämpfungsparameter $\mu$ und $0 < \beta_0 < \beta_1 < 1$

*for* $k = 0, 1, \ldots$

i) Berechne $\boldsymbol{\varepsilon}(\mathbf{p}_\kappa)$ und $\boldsymbol{J}(\mathbf{p}_\kappa)$.

ii) Bestimme $\Delta\mathbf{p}_\kappa$ aus Gl. (3.40).

iii) Berechne $\rho_\mu$. Falls $\rho_\mu \leq \beta_0$ gilt, erhöhe $\mu$ und berechne den Schritt in derselben Iteration erneut. Falls $\rho_\mu > \beta_0$ gilt, akzeptiere den Schritt; für $\rho_\mu \geq \beta_1$ kann $\mu$ für die nächste Iteration verringert werden.

iv) Setze bei akzeptiertem Schritt $\mathbf{p}_{\kappa+1} = \mathbf{p}_\kappa + \Delta\mathbf{p}_\kappa$.

*end*

Diese Methode wird nun auf das zuvor beschriebene Beispiel des in Abb. 3.6 dargestellten sinusförmigen Signals mit einem GNU-Octave-/Matlab-Skript getestet. Ziel ist es, durch die gegebenen Beobachtungspaare $(t_j, s_j)$ eine Sinusfunktion zu legen. Der Modellansatz für dieses Beispiel lautet:

$$s(t) \;=\; a\sin\!\left(2\pi\frac{t}{\lambda} + \varphi\right) \;+\; \varepsilon \qquad \text{mit} \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2) \tag{3.42}$$

wobei die Residuen in Richtung von $s$ streuen und die Abtastpunkte entlang der Zeitachse $t$ als Regressor vorgegeben sind, so dass wir einen Regressionsansatz der Gestalt

$$\varepsilon_j \;=\; Y_j \;-\; f(X_j, \boldsymbol{p}) \qquad \text{mit} \qquad j = 1, 2, \ldots, J \tag{3.43}$$

vorliegen haben. Der Vektor $\boldsymbol{p}$ enthält die gesuchten Modellparameter. Die Kostenfunktion lautet damit

$$Q(\boldsymbol{p}) \;=\; \sum_{j=1}^{J} \left(Y_j \;-\; f(X_j, \boldsymbol{p})\right)^2 . \tag{3.44}$$

In dem vorliegenden Fall haben wir zwei Modellparameter $p_1 = \lambda$ und $p_2 = \varphi$

$$\boldsymbol{p} = \begin{pmatrix} p_1 \\ p_2 \end{pmatrix} = \begin{pmatrix} \lambda \\ \varphi \end{pmatrix} \tag{3.45}$$

Die Residuen sind wie folgt gegeben:

$$\varepsilon_j = s_j - a \cdot \sin\left[\frac{2\pi}{p_1} t_j + p_2\right] \tag{3.46}$$

Für die Jacobi-Matrix benötigen wir die beiden partiellen Ableitungen nach den Modellparametern $p_1$ und $p_2$. Für $j = 1, \ldots, J$ gilt:

$$J_{j1} = \frac{\partial \varepsilon_j}{\partial p_1} = \frac{2a\pi t_j}{p_1^2} \cos\left[\frac{2\pi t_j}{p_1} + p_2\right], \tag{3.47}$$

$$J_{j2} = \frac{\partial \varepsilon_j}{\partial p_2} = -a \cos\left[\frac{2\pi t_j}{p_1} + p_2\right]. \tag{3.48}$$

$$\begin{aligned} J_{11} = \frac{\partial \varphi(\boldsymbol{p})}{\partial p_1} &= -a \cdot \cos\left[\frac{2\pi}{p_1} \cdot t + p_2\right] \cdot \left(\frac{-2\pi t}{p_1^2}\right) \\ &= \frac{4a \cdot \pi}{p_1^2} \cdot t \cdot \cos\left[\frac{2\pi}{p_1} t + p_2\right] \end{aligned} \tag{3.49}$$

$$J_{21} = \frac{\partial \varphi(\boldsymbol{p})}{\partial p_2} = -a \cos\left[\frac{2\pi}{p_1} t + p_2\right] \tag{3.50}$$

Das Octave/Matlab-Skript sieht wir folgt aus:

```
function fit_sin_LMAC(gen_new)
% Stand: 2019-11-05
% Laeuft unter Matlab und Octave
t = [0:99]'; % Sekunden
N = length(t);
a = 5; % Volt
lam = 30; % Sekunden
sigma = 0.13*a;
phi = 0.2*pi;
%
am = 0.3*a;
phim = 0.7*pi;
lamm = 0.3*lam;
%
st = a*sin(2*pi*t/lam + phi);
if gen_new
smod = st + am*sin(2*pi*t/lamm + phim);
s = smod + sigma*randn(N,1);
save('pltSS_nonlin_leastsquare_sin_zB2.mat','t','s','sigma','a');
else
load('pltSS_nonlin_leastsquare_sin_zB2.mat');
end
%
% Startwerte geraten
%
p0 = [33; 0.23*pi];
x = [t(:) s(:)];
%
% Residuen, muessen als Spaltenvektor vorliegen
%
epsi = @(x, p) (x(:,2) - a*sin(2*pi*x(:,1)/p(1) + p(2)));
%
```

```
% partielle Ableitungen der Residuen epsi
% muss M Spalten und J Zeilen haben, wobei M die Anzahl der Fitparameter
% und J die Anzahl der Messpunkte ist
%
```

siehe Gl.(3.49) und (3.50)

```
Jac = @(x, p) [(4*a*pi/p(1)^2)*x(:,1).*cos(2*pi*x(:,1)/p(1)+p(2)),...
-a*cos(2*pi*x(:,1)/p(1)+p(2))];
%
maxit = 5000; % Anzahl der Iterationen
tol = 1E-15; % Abbruchbedingung
beta0 = 0.2;
beta1 = 0.8;
%
% Startwert des Marquardtparameters
%
mu0 = 10;
%
% Optimierungsrechnung
%
p1=levenberg_marquardt(epsi,Jac,x,p0,mu0,beta0,beta1,maxit,tol);
%
% Ergebnisausgabe
%
disp(['gefittete Werte: lambda = ', ...
num2str(p1(1)),'; phi/pi =   ',num2str(p1(2)/pi)]);

sf = @(x, p) a*sin(2*pi*x/p(1) + p(2));
figure(1);
plot( t, s,'MarkerFaceColor',[0 0 1],'MarkerSize',8, ...
'Marker','diamond','LineStyle','none')
hold on;
plot(t, st, 'g-', 'linewidth', 3)
plot(t, sf(t,p0), 'b-', 'linewidth', 2);
plot(t, sf(t,p1), 'r--', 'linewidth', 2);
legend('Messwerte','Sollfunktion','Startwerte','Fit' )

xlabel('t / s','fontsize', 14);
ylabel('s / V','fontsize', 14);
set(gca,'fontsize',12);
grid on;
print('-dpng','pltSS_nonlin_leastsquare_sin_zB2.png');
end
%
```

```
function p=levenberg_marquardt(F,DF,x,p0,mu0,beta0,beta1,maxit,tol)
k = 0;
mu= mu0;
p = p0;
gradQabs = abbruchkrit(F,DF,x,p);
sflag = 1;

while (gradQabs>tol) && (k<maxit) && (mu>tol) && (sflag<2)
[s,mu,sflag] = korrektur(F,DF,x,p,mu,beta0,beta1,tol);
if sflag==1
p=p+s;
end
gradQabs = abbruchkrit(F,DF,x,p);
k=k+1;
end
        disp(['Anzahl Iterationen: ', num2str(k)]);
end
%
function [s,mu,sflag] = korrektur(F,DF,x,p,mu,beta0,beta1,tol)
s = Delta_p(F,DF,x,p,mu);
Q = F(x,p)'*F(x,p);
DR = Q - F(x,p+s)'*F(x,p+s);
DRtilde = Q - (F(x,p)+DF(x,p)*s)'*(F(x,p)+DF(x,p)*s);
sflag = 1;
if DRtilde > tol
if DR <= beta0*DRtilde
sflag = 0;
mu = 2*mu;
elseif DR >= beta1*DRtilde
mu = mu/2;
end
else
sflag = 2;
end
end
%
function s = Delta_p(F,DF,x,p,mu)
JTJ = DF(x,p)'*DF(x,p);
s = -(JTJ + mu*diag(diag(JTJ)))\(DF(x,p)'*F(x,p));
end
%
function gradQabs = abbruchkrit(F,DF,x,p)
gradQabs = ( F(x,p)'*DF(x,p) * DF(x,p)'*F(x,p) );
end
```

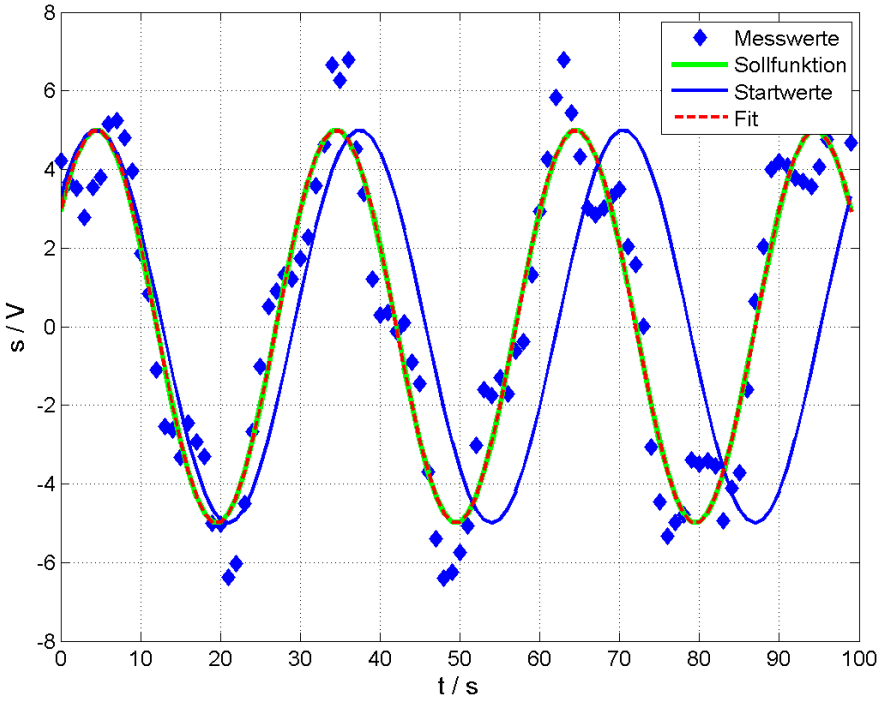



Abbildung 3.8: Beispiel eines sinusförmigen Signals mit Levenberg-Marquardt-Fit gemäß Gln. (3.40) und (3.41) zusammen mit den Entscheidungen aus Tabelle 1.

Ein Lauf des GNU-Octave-/Matlab-Skripts liefert das in Abb. 3.8 dargestellte Ergebnis. Die konkreten Iterationszahlen und Schätzwerte hängen bei der Datengenerierung vom Zufallszahlengenerator ab:

```
Anzahl Iterationen: 1878
gefittete Werte: lambda = 30.0505; phi/pi = 0.2051
```

geliefert.

Im GNU-Octave-Paket optim steht für die nichtlineare Regression beispielsweise folgende Funktion zur Verfügung:

```
[f, p, cvg, iter] =leasqr (x, y, init, F);
```

Angewendet auf unser Beispiel vom sinusförmigen Signal kann sie in folgender Weise verwendet werden

```
1 function fit_sin(gen_new)
2  % Stand: 2019-11-05
3  % Laeuft nur unter Octave, da leasqr nur unter Octave
4  % frei zur Verfuegung steht. Bei Matlab gibt es
5  % einen aehnlichen Befehl, der heisst nlinfit
6   load('pltSS_nonlin_leastsquare_sin_zB2.mat');
7   p0 = [34; 0.23*pi];
8   sf = @(x, p) a*sin(2*pi*x/p(1) + p(2));
```

```
 [f1, p1, kvg1, iter1, corp1, covp1, covr1, stdresid1, Z1, r21] = ...
 leasqr (t(:), s(:), p0, sf);
 fprintf(stdout,'gefittete Werte: lambda = %1.2f;  phi/pi = %1.2f\n', ...
 p1(1), p1(2)/pi );
 t = [0:99]'; % Sekunden
 N = length(t);
 %
 a = 5; % Volt
 lam = 30; % Sekunden
 sigma = 0.13*a;
 phi = 0.2*pi;
%
 am = 0.3*a;
 phim = 0.7*pi;
 lamm = 0.3*lam;
%
 st = a*sin(2*pi*t/lam + phi);
 figure(1);
 plot( t, s, 'kd', ...
 t, st, 'g-.;soll;', ...
 t, sf(t,p0), 'b--;Startwerte;', ...
 t, sf(t,p1), 'r-;gefittet;');
 xlabel('t / s','fontsize', 14);
 ylabel('s / V','fontsize', 14);
 set(gca,'fontsize',12);
 grid on;
 end
```

und wir erhalten folgendes Ergebnis

```
gefittete Werte: lambda = 30.0505;  phi/pi = 0.2051
```

## 3.5 Matlabfunktionen zur Berechnung nichtlinearer Fits

Es gibt eine Vielzahl von Matlab-Bibliotheksfunktionen, die nichtlineare Optimierungsverfahren implementieren. Nichtlineare Ausgleichsprobleme können beispielsweise mit lsqnonlin(fun,x0,lb,ub,options) gelöst werden. Der Algorithmus wird über options = optimoptions('lsqnonlin','Algorithm','levenberg-marquardt') ausgewählt. Die konkrete Verfügbarkeit von Randbedingungen und Optionen hängt von der gewählten Matlab-Version und dem Algorithmus ab. Für unser Beispiel mit dem Sinusfit verwenden wir beispielhaft die Funktion fminsearch(fun,x0,options), in der die Simplexmethode nach Nelder und Mead implementiert ist. Es muss ein Schätzwert für den Startwert x0 angegeben werden. Als ‚OPTIONS' können u.a. gewählt werden TolX (Toleranz, wann abgebrochen werden soll) oder MaxIter (Maximale Anzahl an Iterationen, die durchgeführt werden sollen). Die zu minimierende Kostenfunktion $Q$ ist für unser Beispiel mit dem Sinusfit gegeben durch:

$$Q(\boldsymbol{p}) = \sum_{j=1}^{J} (a \cdot \sin(2 \cdot \pi \cdot t(j)/p(1) + p(2)) - s(j))^2 \;\rightarrow\; \text{Min.} \tag{3.51}$$

Der dazugehörige Matlab-Code lautet:

```
load('pltSS_nonlin_leastsquare_sin_zB2.mat');
a = 5; % Volt
p0 = [34; 0.23*pi];
% Ziel-/ Kostenfunktion:
Q = @(p) sum((a*sin(2*pi*t/p(1) + p(2))-s).^2) ;
tol = 1E-15;
maxit =1000;
p1= fminsearch(Q, p0, optimset('TolX',tol, 'MaxIter', maxit));
disp(['gefittete Werte: lambda =', num2str(p1(1)),';  ', ...
num2str(p1(2)/pi)])
```

Als Ergebnis erhält man:

```
gefittete Werte: lambda =30.0505; phi/pi=0.2051
```

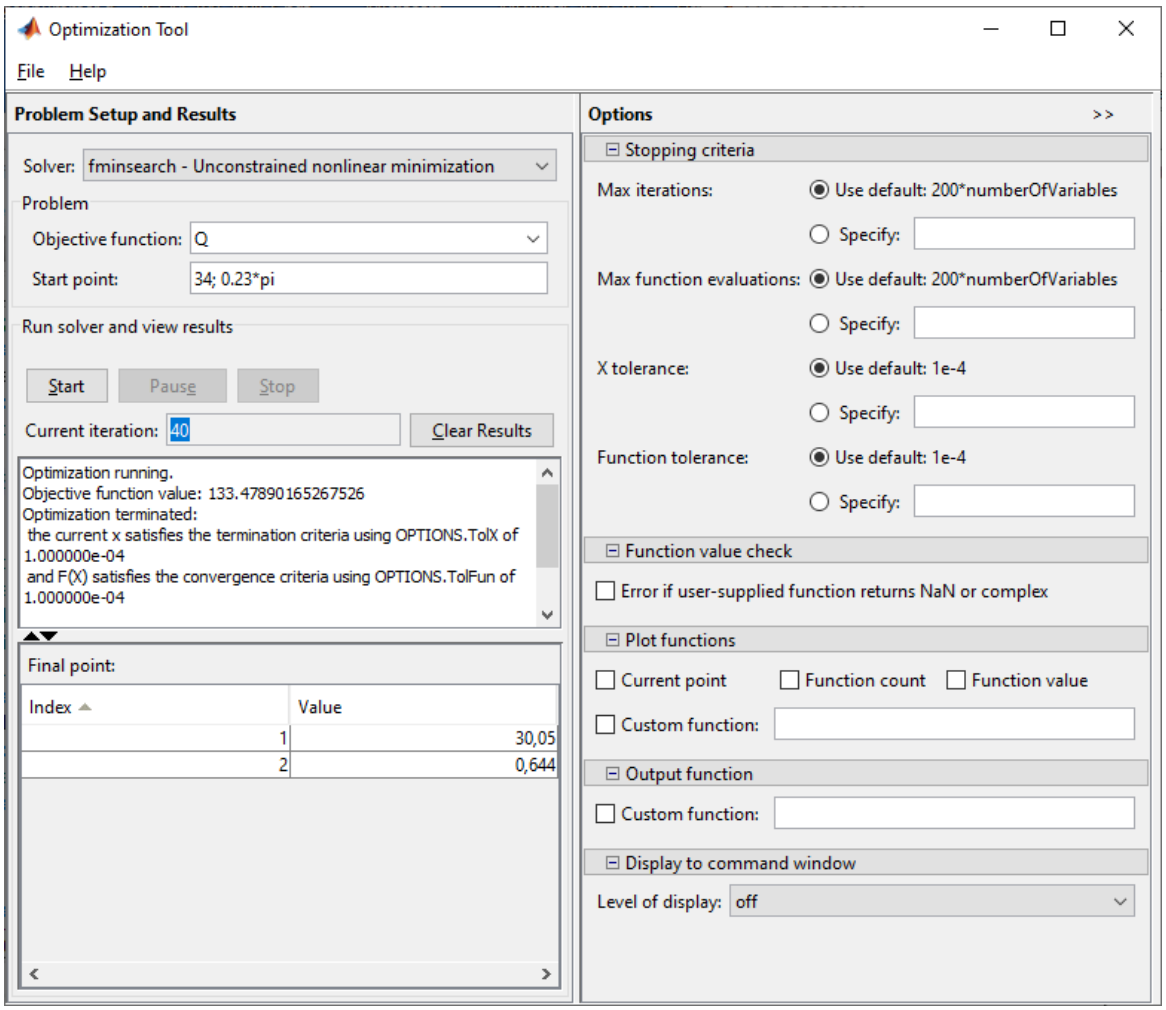



Abbildung 3.9: Historisches Matlab-Optimtool: Ergebnis $p_1 = 30{,}05$ und $p_2 = 0{,}644$

Tabelle 3.1 gibt einen Überblick über Matlabfunktionen bei Optimierungsproblemen, siehe dazu auch S. S. Rao [Rao09]. **lb** steht für ‚lower bound' und **ub** steht für ‚upper bound'

Tabelle 3.1: Optimierungsverfahren mit Matlab

| Problemtyp | Standardform unter Matlab | Matlab-Funktion |
|---|---|---|
| Skalare Minimierung | $\min f(x)$ mit $x_\mathrm{L} \le x \le x_\mathrm{U}$ | fminbnd |
| Unbeschränkte Minimierung | $\min f(\mathbf{x})$; bei glatten Funktionen fminunc, bei Ableitungsfreiheit fminsearch | fminunc, fminsearch |
| Lineare Optimierung | $\min \mathbf{f}^\mathsf{T}\mathbf{x}$ mit $A\mathbf{x} \le \mathbf{b}$, $A_\mathrm{eq}\mathbf{x} = \mathbf{b}_\mathrm{eq}$, $\mathbf{lb} \le \mathbf{x} \le \mathbf{ub}$ | linprog |
| Quadratische Optimierung | $\min \frac{1}{2}\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x} + \mathbf{f}^\mathsf{T}\mathbf{x}$ mit linearen Nebenbedingungen | quadprog |
| Nichtlineare Optimierung | $\min f(\mathbf{x})$ mit Gleichungs- und Ungleichungsnebenbedingungen | fmincon |
| Minimax-Problem | $\min_\mathbf{x} \max_i F_i(\mathbf{x})$ mit Nebenbedingungen | fminimax |

In älteren Matlab-Versionen gab es mit optimtool eine graphische Oberfläche, über die verschiedene Optimierungsverfahren ausgewählt werden konnten. In aktuellen Versionen übernimmt unter anderem die Optimize-Live-Editor- Aufgabe diese Funktion. Abb. 3.9 und Tab. 3.1 dienen daher als versions-

abhängige Orientierung; die genaue Auswahl und Bezeichnung der Algorithmen kann sich zwischen Matlab-Versionen ändern.

## 3.6 Gradientenverfahren mit unterschiedlichen Varianzen

Im Folgenden nehmen wir zunächst an, dass die Varianzen bekannt und unabhängig von den Modellparametern sind. Sind die Residuen aller Beobachtungen gleich verteilt, ist die Streuung durch einen gemeinsamen Faktor $\sigma^2$ beschrieben, also

$$Q(\mathbf{p}) \;=\; \frac{\boldsymbol{\varepsilon}(\mathbf{p})^{\mathsf{T}}\,\boldsymbol{\varepsilon}(\mathbf{p})}{\sigma^2}. \tag{3.52}$$

Damit gilt

$$\nabla_{\mathbf{p}} Q(\mathbf{p}) \;=\; \frac{2}{\sigma^2}\boldsymbol{J}^{\mathsf{T}}(\mathbf{p})\boldsymbol{\varepsilon}(\mathbf{p}) \stackrel{!}{=} \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \tag{3.53}$$

Der konstante Faktor $1/\sigma^2$ ändert die Lage des Minimums nicht. Daher kann für die Bestimmung der Parameter mit der ungewichteten RQS weitergearbeitet werden. Falls $\sigma$ von $\mathbf{p}$ abhängt, gilt diese Vereinfachung nicht; dann muss die Ableitung der Varianz beziehungsweise zusätzlich die logarithmische Normierung der Likelihood berücksichtigt werden.

Für den Fall, dass die verschiedenen Beobachtungen unterschiedliche, bekannte Standardunsicherheiten $\sigma_j$ besitzen, werden die Residuen standardisiert:

$$Q(\mathbf{p}) \;=\; \begin{pmatrix} \frac{\varepsilon_1(\mathbf{p})}{\sigma_1} & \cdots & \frac{\varepsilon_J(\mathbf{p})}{\sigma_J} \end{pmatrix} \begin{pmatrix} \frac{\varepsilon_1(\mathbf{p})}{\sigma_1} \\ \vdots \\ \frac{\varepsilon_J(\mathbf{p})}{\sigma_J} \end{pmatrix} \tag{3.54}$$

d.h. mit der Diagonalmatrix

$$Q(\mathbf{p}) \;=\; \boldsymbol{\varepsilon}^{\mathsf{T}} \begin{pmatrix} \frac{1}{\sigma_1^2} & \cdots & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_J^2} \end{pmatrix} \boldsymbol{\varepsilon} \tag{3.55}$$

Je größer die Varianz $\sigma_j^2$ einer Beobachtung $j$ ist, desto geringer fällt der Summand $\frac{\varepsilon_j^2}{\sigma_j^2}$ in der Kostenfunktion $Q$ ins Gewicht, weshalb man diese auch als Gewichte $w_j = \frac{1}{\sigma_j^2}$ bezeichnet und die Matrix als Gewichtsmatrix $\mathbf{W}$ also

$$Q(\mathbf{p}) \;=\; \boldsymbol{\varepsilon}^{\mathsf{T}}\,\mathbf{W}\,\boldsymbol{\varepsilon} \tag{3.56}$$

mit

$$\frac{1}{2}\nabla_{\mathbf{p}} Q(\mathbf{p}) \;=\; \boldsymbol{J}^{\mathsf{T}}\,\mathbf{W}\,\boldsymbol{\varepsilon}(\mathbf{p}) \tag{3.57}$$

sieht unser Optimierungsproblem wie folgt aus

$$\boldsymbol{J}^{\mathsf{T}}(\hat{\mathbf{p}})\,\mathbf{W}\,\boldsymbol{\varepsilon}(\hat{\mathbf{p}}) \;=\; \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}. \tag{3.58}$$

Die Gleichungen (3.28) und (3.40) werden damit zu

$$\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}}\,\mathbf{W}\,\boldsymbol{J}^{(\kappa)}\,\Delta\mathbf{p}_{\kappa} \;\stackrel{!}{=}\; -\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}}\,\mathbf{W}\,\boldsymbol{\varepsilon}(\mathbf{p}_{\kappa}). \tag{3.59}$$

und mit Dämpfungs- bzw. Marquardtparameter

$$\left(\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}}\mathbf{W}\boldsymbol{J}^{(\kappa)} + \mu\,\mathrm{diag}\left(\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}}\mathbf{W}\boldsymbol{J}^{(\kappa)}\right)\right)\Delta\mathbf{p}_{\kappa} \stackrel{!}{=} -\left(\boldsymbol{J}^{(\kappa)}\right)^{\mathsf{T}}\mathbf{W}\boldsymbol{\varepsilon}(\mathbf{p}_{\kappa}). \tag{3.60}$$

Wichtig ist die umgekehrte Beziehung: Je stärker die Kostenfunktion am Minimum gekrümmt ist, desto **kleiner** ist die Parameterunsicherheit. In flachen Richtungen ist die Unsicherheit dagegen groß.

## 3.7 Unsicherheit der geschätzten Modellparameter

Bei einer nichtlinearen Ausgleichsrechnung kann die Unsicherheit der geschätzten Modellparameter in erster Ordnung durch eine Linearisierung am gefundenen Minimum abgeschätzt werden. Die Quadrate $u^2(p_i)$ der Standardunsicherheiten sind die Diagonalelemente der Kovarianzmatrix.

Zur Einordnung werden zunächst die bekannten Beziehungen der linearen Regression wiederholt:

$$\hat{\boldsymbol{\theta}} \;=\; \left(\mathbf{X}^{\mathsf{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathsf{T}}\mathbf{Y}, \qquad \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}} \;=\; \hat{\sigma}_{\varepsilon}^{2}\left(\mathbf{X}^{\mathsf{T}}\mathbf{X}\right)^{-1}.$$

Die Regressormatrix $\mathbf{X}$ besteht aus den Spalten der Regressoren. In der linearen Regression entspricht sie der Jacobi-Matrix der Modellgleichung beziehungsweise der Residuen, bis auf ein mögliches Vorzeichen je nach Definition des Residuenvektors.

Bei der nichtlinearen Ausgleichsrechnung ist die Unsicherheit der geschätzten Modellparameter eng mit der Krümmung der Kostenfunktion in der Umgebung ihres Minimums verbunden. Diese Krümmung wird durch die Hesse-Matrix der Kostenfunktion beschrieben, deren Elemente die zweiten partiellen Ableitungen der Kostenfunktion nach den Modellparametern sind. Eine starke Krümmung bedeutet, dass bereits kleine Änderungen der Parameter zu einer deutlichen Zunahme der Kostenfunktion führen. Die betreffenden Parameter sind daher vergleichsweise genau bestimmt. Eine geringe Krümmung kennzeichnet dagegen eine flache Richtung der Kostenfunktion und damit eine größere Unsicherheit der entsprechenden Parameterkombination. Die Kovarianzmatrix ist deshalb näherungsweise proportional zur Inversen der Hesse-Matrix Kostenfunktion.

Für die Summe der quadrierten Residuen

$$Q(\mathbf{p}) = \boldsymbol{\varepsilon}^{\mathsf{T}}(\mathbf{p})\boldsymbol{\varepsilon}(\mathbf{p}) = \sum_{j=1}^{J} \varepsilon_j^2(\mathbf{p})$$

ist die Hesse-Matrix der Kostenfunktion definiert durch

$$\boldsymbol{H}_Q(\mathbf{p}) = \left( \frac{\partial^2 Q(\mathbf{p})}{\partial p_k \, \partial p_l} \right)_{k,l=1,\ldots,M} . \tag{3.61}$$

Ihre einzelnen Matrixelemente lauten

$$[\boldsymbol{H}_Q(\mathbf{p})]_{kl} = \frac{\partial^2 Q(\mathbf{p})}{\partial p_k \, \partial p_l} = 2 \sum_{j=1}^{J} \left[ \frac{\partial \varepsilon_j(\mathbf{p})}{\partial p_k} \frac{\partial \varepsilon_j(\mathbf{p})}{\partial p_l} + \varepsilon_j(\mathbf{p}) \frac{\partial^2 \varepsilon_j(\mathbf{p})}{\partial p_k \, \partial p_l} \right] .$$

Mit den Elementen der Jacobi-Matrix

$$[\boldsymbol{J}(\mathbf{p})]_{jk} = \frac{\partial \varepsilon_j(\mathbf{p})}{\partial p_k}$$

und der Hesse-Matrix des einzelnen Residuums

$$\boldsymbol{H}_{\varepsilon_j}(\mathbf{p}) = \left( \frac{\partial^2 \varepsilon_j(\mathbf{p})}{\partial p_k \, \partial p_l} \right)_{k,l=1,\ldots,M}$$

beziehungsweise explizit

$$\boldsymbol{H}_{\varepsilon_j}(\mathbf{p}) = \begin{pmatrix} \dfrac{\partial^2 \varepsilon_j}{\partial p_1^2} & \dfrac{\partial^2 \varepsilon_j}{\partial p_1 \partial p_2} & \cdots & \dfrac{\partial^2 \varepsilon_j}{\partial p_1 \partial p_M} \\ \dfrac{\partial^2 \varepsilon_j}{\partial p_2 \partial p_1} & \dfrac{\partial^2 \varepsilon_j}{\partial p_2^2} & \cdots & \dfrac{\partial^2 \varepsilon_j}{\partial p_2 \partial p_M} \\ \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial^2 \varepsilon_j}{\partial p_M \partial p_1} & \dfrac{\partial^2 \varepsilon_j}{\partial p_M \partial p_2} & \cdots & \dfrac{\partial^2 \varepsilon_j}{\partial p_M^2} \end{pmatrix}$$

lässt sich die Hesse-Matrix der Kostenfunktion kompakt schreiben als

$$\boldsymbol{H}_Q(\mathbf{p}) = 2\boldsymbol{J}^{\mathsf{T}}(\mathbf{p})\boldsymbol{J}(\mathbf{p}) + 2 \sum_{j=1}^{J} \varepsilon_j(\mathbf{p}) \, \boldsymbol{H}_{\varepsilon_j}(\mathbf{p}). \tag{3.62}$$

Bei der Gauß-Newton-Näherung wird der zweite Term vernachlässigt. Dies ist insbesondere dann gerechtfertigt, wenn die Residuen am Minimum klein sind oder die Nichtlinearität des Modells in dessen Umgebung nur schwach ausgeprägt ist. Damit ergibt sich

$$\boldsymbol{H}_Q(\hat{\mathbf{p}}) \approx 2\hat{\boldsymbol{J}}^{\mathsf{T}} \hat{\boldsymbol{J}}. \tag{3.63}$$

Für eine mit dem Faktor 1/2 definierte Kostenfunktion $Q(\mathbf{p})/2$ entfällt der Faktor 2.

Bei homoscedastischen[2] und unabhängigen Residuen gilt somit in linearer beziehungsweise Gauß-

[2]Homoscedastisch (auch: *homoskedastisch*) bedeutet, dass die Residuen für alle Messpunkte dieselbe Varianz besitzen.

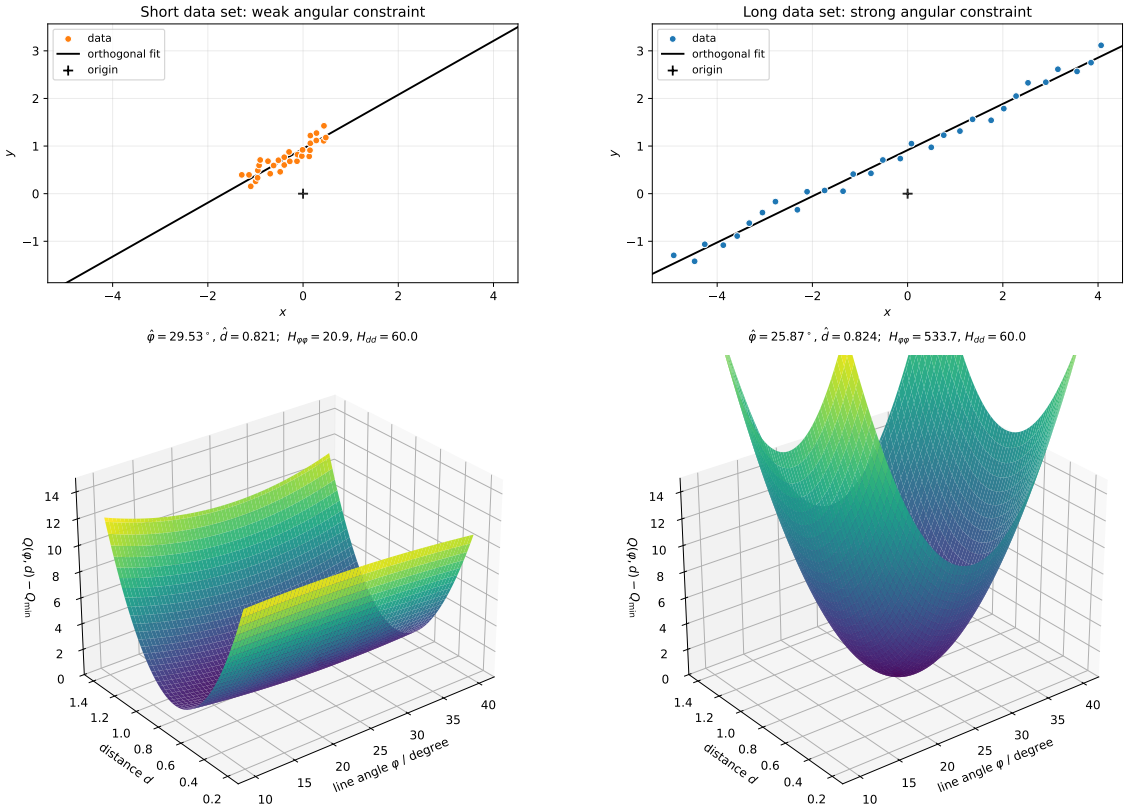



Abbildung 3.10: Veranschaulichung des Zusammenhangs zwischen der Krümmung der Kostenfunktion in der Umgebung ihres Minimums und der Unsicherheit des Modellparameters $\phi$

Newton-Näherung

$$\widehat{\mathrm{Cov}}(\hat{\mathbf{p}}) \approx \hat{\sigma}_\varepsilon^2 \left(\hat{\boldsymbol{J}}^\mathsf{T} \hat{\boldsymbol{J}}\right)^{-1}, \qquad \hat{\sigma}_\varepsilon^2 = \frac{Q(\hat{\mathbf{p}})}{J - M}, \tag{3.64}$$

sofern die gemeinsame Varianz aus den Residuen geschätzt wird. Dabei bezeichnet $J$ die Anzahl der Beobachtungen und $M$ die Anzahl der geschätzten Modellparameter.

Abbildung 3.10 veranschaulicht den Zusammenhang zwischen der Krümmung der Kostenfunktion und der Unsicherheit der Modellparameter am Beispiel einer Geraden. Diese wird in Normalform durch

$$-x \sin\varphi + y \cos\varphi = d$$

beschrieben. Dabei sind $x$ und $y$ die Koordinaten der Geraden (die direkten Messgrößen), $\varphi$ der Modellparameter „Steigungswinkel der Geraden“ und $d$ der Modellparameter „vorzeichenbehafteter senkrechter Abstand vom Koordinatenursprung“. Da $(-\sin\varphi, \cos\varphi)^\mathsf{T}$ ein Einheitsnormalenvektor ist, sind die Residuen

$$\varepsilon_j = -x_j \sin\varphi + y_j \cos\varphi - d$$

die vorzeichenbehafteten senkrechten Abstände der Beobachtungen / Messungen der Größen von der Geraden.

Im linken Teil der Abbildung erstrecken sich die Beobachtungspunkte nur über einen kurzen Abschnitt

Ihre zufällige Streuung hängt somit nicht systematisch von der unabhängigen Variablen, dem vorhergesagten Wert oder der Größe des Messsignals ab. In einem Residuenplot zeigt sich dies näherungsweise als ein über den gesamten Bereich gleich breites Streuband.

der Geraden. Aufgrund dieser geringen Basisbreite führt eine Änderung des Steigungswinkels $\varphi$ nur zu einer vergleichsweise geringen Zunahme der Kostenfunktion. Diese bildet daher in Richtung von $\varphi$ ein flaches Tal, und der Steigungswinkel ist nur mit einer vergleichsweise großen Unsicherheit bestimmt. Im rechten Teil der Abbildung sind die Beobachtungspunkte dagegen über einen längeren Abschnitt der Geraden verteilt. Der dadurch entstehende größere Hebelarm führt zu einer stärkeren Krümmung der Kostenfunktion und somit zu einer kleineren Unsicherheit des geschätzten Steigungswinkels.

Am jeweiligen Minimum ergeben sich für die Krümmung in Richtung von $\varphi$

$$\left.\frac{\partial^2 Q(\varphi, d)}{\partial \varphi^2}\right|_{(\hat{\varphi},\hat{d})} \approx \begin{cases} 20{,}9 & \text{geringe Basisbreite,} \\ 533{,}7 & \text{große Basisbreite.} \end{cases}$$

Dabei wird der Winkel $\varphi$ im Bogenmaß eingesetzt. In Richtung des Abstandsparameters $d$ ist die Krümmung in beiden Beispielen gleich:

$$\left.\frac{\partial^2 Q(\varphi, d)}{\partial d^2}\right|_{(\hat{\varphi},\hat{d})} = 60.$$

Dies folgt daraus, dass beide Datensätze aus jeweils $J = 30$ Beobachtungspunkten bestehen und $d$ mit $\partial \varepsilon_j / \partial d = -1$ linear in die Residuen eingeht. Daher gilt allgemein

$$\frac{\partial^2 Q}{\partial d^2} = 2J.$$

Sind die Standardunsicherheiten bekannt, wird bei $\mathbf{W} = \mathbf{\Sigma}^{-1}$ stattdessen näherungsweise $(\hat{\boldsymbol{J}}^{\mathsf{T}} \mathbf{W} \hat{\boldsymbol{J}})^{-1}$ verwendet; eine zusätzliche Schätzung von $\hat{\sigma}_\varepsilon^2$ ist dann nicht erforderlich. Diese Kovarianz ist eine lokale Linearisation und berücksichtigt weder starke Nichtlinearität noch mehrere getrennte Minima.

Die lokale Korrektur und die daraus abgeleiteten Standardunsicherheiten können zusammengefasst werden als:

| Parameter $\hat{\boldsymbol{\theta}}$ bzw. $\mathbf{p}$ | Kovarianz $\hat{\mathbf{\Sigma}}$ | Unsicherheit $u = \hat{\sigma}$ |
|---|---|---|

Regressionsrechnung:

$$\hat{\boldsymbol{\theta}} = \left(\mathbf{X}^{\mathsf{T}} \mathbf{X}\right)^{-1} \mathbf{X}^{\mathsf{T}} \mathbf{Y} \qquad \hat{\mathbf{\Sigma}}_{\boldsymbol{\theta}} = \left(\mathbf{X}^{\mathsf{T}} \mathbf{X}\right)^{-1} \hat{\sigma}_\varepsilon^2 \quad \hat{\sigma}_l = \sqrt{\boldsymbol{e}_l^{\mathsf{T}} \left(\mathbf{X}^{\mathsf{T}} \mathbf{X}\right)^{-1} \boldsymbol{e}_l \, \hat{\sigma}_\varepsilon^2}$$

Allgemeiner:

$$\Delta \mathbf{p} = -\left(\mathbf{J}^{\mathsf{T}} \mathbf{J}\right)^{-1} \mathbf{J}^{\mathsf{T}} \boldsymbol{\varepsilon}(\mathbf{p}) \quad \hat{\mathbf{\Sigma}}_{\mathbf{p}} = \left(\mathbf{J}^{\mathsf{T}} \mathbf{J}\right)^{-1} \hat{\sigma}_\varepsilon^2 \quad \hat{\sigma}_l = \sqrt{\boldsymbol{e}_l^{\mathsf{T}} \left(\mathbf{J}^{\mathsf{T}} \mathbf{J}\right)^{-1} \boldsymbol{e}_l \, \hat{\sigma}_\varepsilon^2}$$

## 3.8 Robuste Schätzverfahren

Mit Gl. (3.56) haben wir eine gewichtete Residuenquadratsumme kennengelernt. Bei der robusten Schätzung sind die Gewichte jedoch nicht als bekannte Varianzanteile vorgegeben, sondern werden aus den Residuen abgeleitet. Das Ziel besteht nicht darin, die Residuenverteilung formal in eine Normalver-

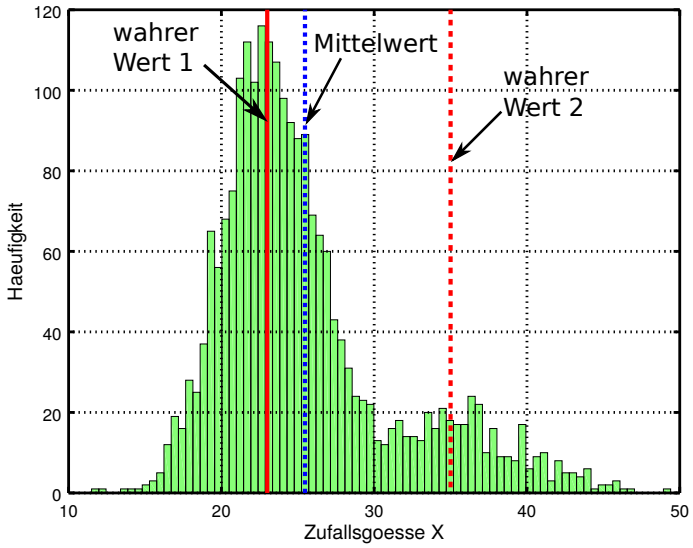



Abbildung 3.11: Beispiel für nicht erwartungsgemäße Beobachtungen

teilung zu transformieren. Vielmehr sollen Beobachtungen mit großen standardisierten Residuen einen geringeren Einfluss auf die Schätzung erhalten. Dies entspricht einer robusten Maximum-Likelihood- beziehungsweise M-Schätzung.

Für die robuste Iteration betrachten wir zunächst

$$Q^{(\kappa)}(\mathbf{p}) \;=\; \sum_{j=1}^{J} \delta_j^{(\kappa)} \varepsilon_j(\mathbf{p})^2, \tag{3.65}$$

wobei die Gewichte $\delta_j^{(\kappa)}$ während der jeweiligen Ausgleichsrechnung festgehalten werden. Nach der Parameteraktualisierung werden die Residuen neu berechnet und die Gewichte aktualisiert.

Zunächst werden die Parameter ungeachtet möglicher Ausreißer mit der ungewichteten Least-Squares-Methode

$$\min_{\mathbf{p}} Q(\mathbf{p}) \qquad \text{mit} \qquad Q(\mathbf{p}) \;=\; \sum_{j=1}^{J} \varepsilon_j(\mathbf{p})^2. \tag{3.66}$$

geschätzt mit $\mathbf{p}_0$.

Wir betrachten wieder ein einfaches Beispiel, in dem es nur einen Parameter $y$ gibt und eine Messgröße $X_1$ mit $J$ Beobachtungen $(X_{1,1}, \ldots, X_{1,J})$. Dabei wird davon ausgegangen, dass die Beobachtungen zu einer Grundgesamtheit, also zu einem Parameter gehören. Die Beobachtungswerte werden histogrammiert. Das Histogramm ist in Abb. 3.11 dargestellt. Für das Histogramm werden $K = 80$ Klassen (engl. *bins*) gewählt, die Anzahl der Beobachtungen umfasst $J = 2200$. Die Klassenbreite ist dann

$$\Delta\xi \;=\; \frac{1}{K}\left(\max\{X_{1,j}\} \;-\; \min\{X_{1,j}\}\right) \tag{3.67}$$

so dass $K+1$ Klassengrenzen $\xi_{\mathrm{G},k}$ vorliegen, deren Indizes wir von Null bis $K$ zählen:

$$\xi_{\mathrm{G},k} \;=\; k\,\Delta\xi \;+\; \min\{X_{1,j}\} \qquad k = 0, \ldots, K \tag{3.68}$$

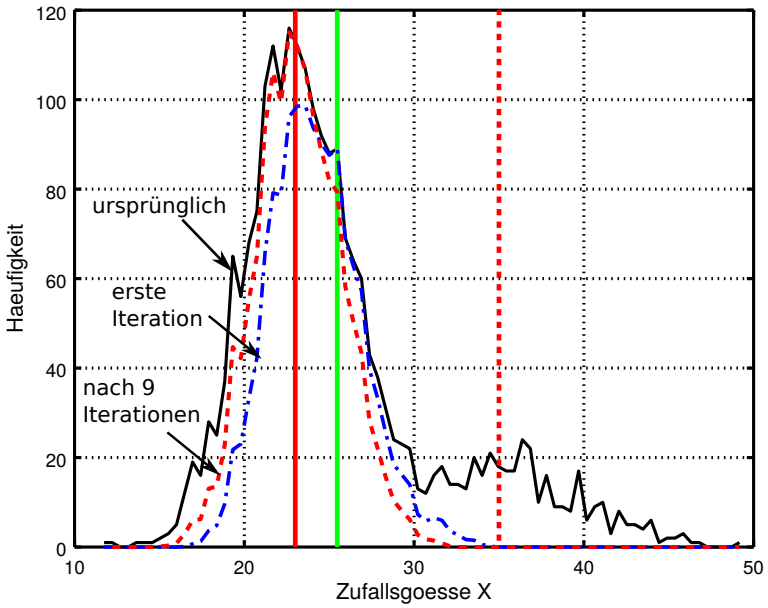



Abbildung 3.12: Iterative robuste Gewichtung der Beobachtungen

und die Mitte in der jeweiligen Klasse für den Wert der Klasse verwenden

$$\xi_k \;=\; \left(k - \frac{1}{2}\right)\Delta\xi \;+\; \min\{X_{1,j}\} \qquad k = 1, \ldots, K \tag{3.69}$$

wobei $k = 1, \ldots, K$ die jeweilige Klasse bezeichnet.

Die Anzahl der Einzelbeobachtungen, für die gilt

$$\xi_{\mathrm{G},k-1} \;\leq\; X_{1,j} \;< \xi_{\mathrm{G},k}, \tag{3.70}$$

nennen wir *Häufigkeit* $n_k$. Bei der letzten Klasse, also für $k = K$ wird auch bei der rechten Intervallgrenze ein $\leq$ verwendet. Damit ist die diskrete Funktion $n(\xi)$ die Häufigkeitsverteilung.

Der Schätzwert für den Parameter ist bei einer normalverteilten Lageverteilung der Mittelwert; im dargestellten Beispiel nimmt er den Wert 25.47 an. Die Beobachtungen stammen hier jedoch aus zwei überlagerten Gruppen: 1750 Werte gehören zur Lage $\mu_1 = 23.00$ und 450 Werte zur Lage $\mu_2 = 35.00$. Das Nebenmaximum im Histogramm weist auf diese Modellverletzung hin. Soll die dominante Gruppe geschätzt werden, kann der Einfluss der zweiten Gruppe durch eine robuste Gewichtung verringert werden.

Eine mögliche Wahl ist die *Tukey-Bisquare-* beziehungsweise *Tukey-Biweight*-Funktion. Für den standardisierten Residuenwert $u_j^{(\kappa)}$ lautet das Gewicht

$$\delta_j^{(\kappa)} \;=\; \begin{cases} \left(1 - \left(u_j^{(\kappa)}\right)^2\right)^2 & \text{falls } |u_j^{(\kappa)}| \leq 1, \\ 0 & \text{sonst} \end{cases} \tag{3.71}$$

mit

$$u_j^{(\kappa)} = \frac{X_{1,j} - y^{(\kappa)}}{c\, s^{(\kappa)}}, \qquad s^{(\kappa)} = 1.4826\, \mathrm{median}_j \left|X_{1,j} - \mathrm{median}_i(X_{1,i})\right|. \tag{3.72}$$

Der Faktor 1.4826 macht die Median-absolut-Abweichung für normalverteilte Residuen zu einem konsistenten Skalenwert. Ein häufig verwendeter Grenzwert ist $c = 4.685$; er kann an die gewünschte Robustheit angepasst werden. Wichtig ist, dass die Gewichte in der anschließenden gewichteten Ausgleichsrechnung als fest vorgegeben gelten. Die Gewichtsaktualisierung führt zu einer iterativ die Gewichte anpassender Methode der kleinsten Quadrate, dem *iteratively reweighted least-squares* (IRLS)-Verfahren:

$$\mathbf{p}_{\kappa+1} = \arg\min_{\mathbf{p}} \sum_{j=1}^{J} \delta_j^{(\kappa)} \varepsilon_j(\mathbf{p})^2. \tag{3.73}$$

Der Median der Absolutabweichungen wird durch Sortieren der Werte und Auswahl des mittleren Wertes bestimmt. Abb. 3.12 zeigt die ursprüngliche Häufigkeitsverteilung aus Abb. 3.11 als durchgezogene schwarze Kurve sowie die Verteilungen nach der ersten und nach mehreren Gewichtsaktualisierungen. Im dargestellten Beispiel verschiebt sich der Lageschätzwert dabei zunächst auf 24.20 und nach mehr als acht Iterationen auf 23.23. Diese Zahlen sind beispielabhängig und dienen der Illustration des IRLS-Verfahrens.

# Kapitel 4

# Konzepte der Statistik für die Messdaten-analyse

In den letzten drei Kapiteln haben wir die Grundidee der Maximum-Likelihood-Methode und wichtige Verfahren zur Parameterschätzung kennengelernt:

1. Wir haben erläutert, was ein *Modell* ist und was es bedeutet, *ein inverses Problem zu lösen*.
2. Für Modelle, deren zu schätzende Modellparameter linear in die Modellgleichung eingehen, haben wir die *lineare Regression* behandelt.
3. Für Modelle mit einer nichtlinearen Abhängigkeit von den Parametern haben wir einen Einblick in drei Verfahren der *nichtlinearen Optimierung* erhalten.

Dabei stand die Aufgabe im Mittelpunkt, gesuchte physikalische Größen aus Beobachtungen anderer, dem Messsystem unmittelbar zugänglicher Größen zu bestimmen. Ein *physikalisches Modell* beschreibt die Verknüpfung zwischen diesen Größen. Ein *statistisches Modell* beschreibt die *zufälligen Einflüsse* auf die Beobachtungen und gegebenenfalls deren Abhängigkeiten.

Das Beispiel der Beugung am Spalt in Abschnitt 1.2, Abb. 1.1, veranschaulichte diese Aufgabe: Aus den beobachteten Größen, der Position auf dem Zeilendetektor $x$ und dem dazugehörigen Intensitätswert $I(x)$, soll die Breite des Spaltes ermittelt werden. In diesem Beispiel sind $x$ und $I(x)$ die direkten Messgrößen und die Breite des Spaltes ist die indirekte Messgröße, d.h. die zu bestimmende Eigenschaft des physikalischen Systems,

Nachdem wir Verfahren zur Parameterschätzung kennengelernt haben, können wir das Konzept des inversen Problems nun genauer einordnen.

Wir entwickeln die statistische Auswertung in drei Schritten: Zunächst unterscheiden wir Vorwärtsmodell, zufällige Abweichungen und Residuen. Danach leiten wir aus dem Modell zur statistischen Beschreibung der direkten Messgrößen die Likelihood und die „Methode der kleinsten Quadrate“, also die Minimierung der Residuenquadratsumme, her und untersuchen die Streuung der Schätzverfahren. Darauf aufbauend führen wir die bayesische Verteilung der indirekten Messgrößen, die die Parameter des physikalischen Modells sind, ein, erläutern die Verwendung früherer Messungen und zeigen die bayesische Methodik anhand eines einfachen Lehrdatensatzes aus.

Die beiden Sichtweisen, frequentistisch und bayesisch, werden aufbauend auf den zuvor eingeführten Modellen und Rechenverfahren miteinander verglichen. In diesem Zusammenhang wird der Begriff *Frequenz* im Sinne von *Häufigkeit* verwendet.

## 4.1 Vorwärtsmodell und inverses Problem

Wir bezeichnen die gesuchten, hier indirekt bestimmten Größen mit $Y_1, \ldots, Y_M$ und die unmittelbar beobachteten Größen mit $X_1, \ldots, X_N$. Ein Vorwärtsmodell beschreibt schematisch die Richtung

$$(Y_1, \ldots, Y_M) \xrightarrow{\text{Vorwärtsmodell}} \text{Verteilung von } (X_1, \ldots, X_N). \tag{4.1}$$

Es umfasst eine physikalische Beziehung und ein statistisches Modell, in Abb. 4.1 schematisch dargestellt. Weitere bekannte Einflussgrößen oder Versuchsbedingungen werden dabei als gegeben voraus-

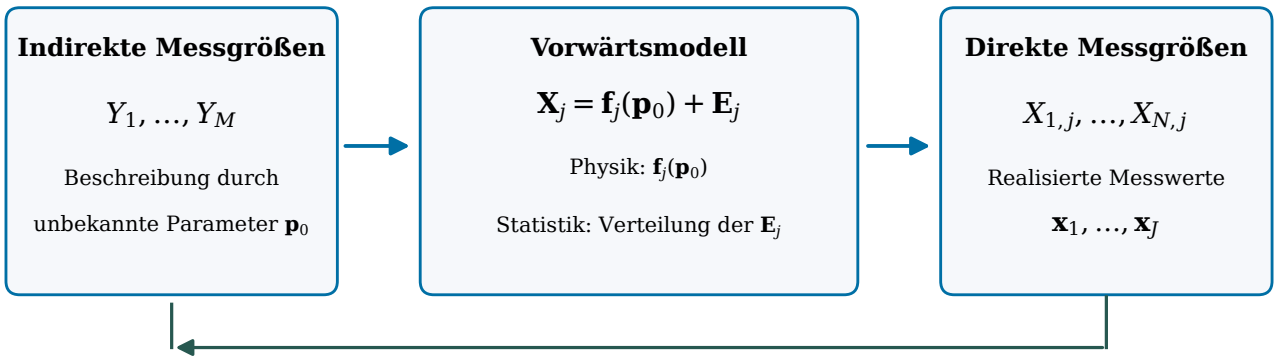



Abbildung 4.1: Vorwärtsmodell aus physikalischer Beziehung und statistischer Beschreibung der Beobachtungen. Das inverse Problem führt von den Beobachtungen zur Schätzung der Parameter und der gesuchten Größen. Dabei bezeichnen $\mathbf{p}_0$ die festen Werte der zu schätzenden Modellparameter und $\mathbf{E}_j$ die zufälligen Abweichungen im Beobachtungsmodell. Das dargestellte Modell enthält keine zusätzliche Modellabweichung.

gesetzt.

Die Modellparameter fassen die zu bestimmenden Eigenschaften des physikalischen Systems, also die indirekten Messgrößen, zusammen. Wir schreiben $\mathbf{p} = (P_1, \ldots, P_M)^\mathsf{T}$ und bezeichnen einen Schätzwert mit $\widehat{\mathbf{p}}$. Der Fettdruck unterscheidet den Parametervektor von einer Wahrscheinlichkeitsdichte $p$. Die Großbuchstaben $P_m$ dienen hier der Bezeichnung der Parameter; sie legen noch keine frequentistische oder bayesische Interpretation fest. Hier ist dies so gemeint, dass ein Parameter unmittelbar den Wert einer gesuchten Größe beschreibt und somit sein Schätzwert einen Schätzwert der indirekten Messgröße darstellt. Allgemeiner können die gesuchten Größen Funktionen der Parameter sein.

Großbuchstaben $X_{i,j}$ bezeichnen im Folgenden Zufallsgrößen; $x_{i,j}$ sind die beobachteten Werte. Der Index $i$ zählt die Größen, der Index $j = 1, \ldots, J$ die Beobachtungen.

Zunächst betrachten wir ein additives Modell ohne zusätzliche Modellabweichung:

$$\mathbf{X}_j = \mathbf{f}_j(\mathbf{p}_0) + \mathbf{E}_j, \qquad \mathbb{E}[\mathbf{E}_j] = \mathbf{0}. \tag{4.2}$$

Hier bezeichnet $\mathbf{p}_0$ die im frequentistischen Modell als fest angenommenen, unbekannten wahren Werte der zu schätzenden Modellparameter, also der indirekten Messgrößen. Der Parametervektor $\mathbf{p}$ ist dagegen das variable Argument bei der Parametersuche und $\widehat{\mathbf{p}}$ bezeichnet die aus den beobachteten Daten bestimmten Schätzwerte zu $\mathbf{p}$.

Der Vektor $\mathbf{E}_j$ beschreibt die zufälligen Abweichungen; $\mathbb{E}[\cdot]$ ist der Erwartungswertoperator. Die Funktion $\mathbf{f}_j$ kann auch von bekannten Versuchsbedingungen abhängen. Die Schätzung kehrt die Richtung des Vorwärtsmodells um:

$$\{\mathbf{x}_1, \ldots, \mathbf{x}_J\} \xrightarrow{\text{inverses Problem}} \widehat{\mathbf{p}} \longrightarrow (\widehat{y}_1, \ldots, \widehat{y}_M). \tag{4.3}$$

Diese Umkehrung ist nicht immer eindeutig oder stabil. Beispielsweise können unterschiedliche Pa-

rameterwerte nahezu dieselben Beobachtungen erzeugen. Dann sind zusätzliche Informationen oder geeignete Versuchsbedingungen erforderlich.

Zufällige Einflüsse, etwa elektronisches Rauschen oder Vibrationen, führen zu streuenden Beobachtungen und damit zu streuenden Schätzern. Unzureichende Modellannahmen können dagegen systematische Abweichungen verursachen. Solche zusätzlichen Modellabweichungen werden im Folgenden mit $\delta_j$ bezeichnet und vom zufälligen Term $E_j$ getrennt. Die aus einer Anpassung berechnete statistische Unsicherheit erfasst diese zusätzlichen Beiträge nicht automatisch.

Für vorgegebene Parameter berechnet das Modell zunächst

$$\mathbf{p} \xrightarrow{\text{Modell}} \mathbf{x}_{\text{Modell},j} = \mathbf{f}_j(\mathbf{p}). \tag{4.4}$$

Ein Schätzverfahren legt fest, wie aus den Daten (Beobachtungen der direkten Größen) Schätzwerte der Modellparameter (indirekten Größen) bestimmt werden. Die in den vorangegangenen Vorlesungen behandelten Anpassungsverfahren wählen die Parameter nach einem festgelegten Kriterium für die Übereinstimmung von Modell und Beobachtungen. Ein solches Kriterium ist beispielsweise die Minimierung der Residuenquadratsumme.

Je nach Modell lassen sich die Schätzwerte unmittelbar berechnen oder mithilfe eines iterativen Optimierungsverfahrens bestimmen. Für Aussagen über ihre Unsicherheit benötigen wir zusätzlich das statistische Beobachtungsmodell. Das statistische Beobachtungsmodell ergänzt die Modellvorhersage um Annahmen darüber, wie stark die möglichen Beobachtungen um die vorhergesagten Werte schwanken, durch welche Wahrscheinlichkeitsverteilungen diese zufälligen Abweichungen beschrieben werden und ob die Abweichungen verschiedener Beobachtungen unabhängig voneinander sind.

## 4.2 Zufällige Abweichungen, Residuen und Modellabweichungen

Für die Herleitung der gewöhnlichen „Methode der kleinsten Quadrate“(kurze Sprechweise für die Methode der Minimierung der Residuenquadratsumme) betrachten wir zunächst skalare Beobachtungen ohne zusätzliche Modellabweichung[1]:

$$X_j = f_j(\mathbf{p}_0) + E_j, \qquad E_j \overset{\text{u.i.v.}}{\sim} \mathcal{N}(0, \sigma^2). \tag{4.5}$$

Die Abkürzung u.i.v. steht für *unabhängig und identisch verteilt*. Die Symbolik $E_j \sim \mathcal{N}(0, \sigma^2)$ bedeutet „$E_j$ ist normalverteilt“.

Wir verwenden hier die Schreibweise $\mathcal{N}(\mu, \sigma^2)$ mit Erwartungswert $\mu$ und Varianz $\sigma^2$. Die Normalverteilung ist eine Modellannahme und keine allgemeine Eigenschaft von Messabweichungen. Die Begriffe Normalverteilung und Gaußverteilung sind synonym.

Die $E_j$ sind *zufällige Abweichungen* im Beobachtungsmodell. Ohne zusätzliche Modellabweichung beschreibt $e_j = x_j - f_j(\mathbf{p}_0)$ die Abweichung des beobachteten Werts $x_j$ vom Modellwert bei den wahren Werten $\mathbf{p}_0$ der Modellparamter (indirekten Messgrößen). Diese Beziehung definiert $e_j$ innerhalb des

[1] Mit Modellabweichung ist hier gemeint, dass das Modell selber die physikalischen Zusammenhänge nur näherungsweise beschreibt.

Modells. Sie ermöglicht im Allgemeinen keine unmittelbare Berechnung, weil $\mathbf{p}_0$ unbekannt ist. Setzt man stattdessen die aus den Daten bestimmten Schätzwerte $\widehat{\mathbf{p}}$ ein, erhält man die angepassten Residuen $\widehat{\varepsilon}_j = x_j - f_j(\widehat{\mathbf{p}})$. Diese sind im Allgemeinen nicht mit den Abweichungen $e_j$ identisch.

Wie in Vorlesung 3 nennen wir die Differenzen zwischen den beobachteten Werten und den jeweiligen Werten für die Modellarameter *Residuen*:

$$\varepsilon_j(\mathbf{p}) = x_j - f_j(\mathbf{p}), \qquad \boldsymbol{\varepsilon}(\mathbf{p}) = \big(\varepsilon_1(\mathbf{p}), \ldots, \varepsilon_J(\mathbf{p})\big)^{\mathsf{T}}. \tag{4.6}$$

Nach der Anpassung erhalten wir die *angepassten Residuen*

$$\widehat{\varepsilon}_j = \varepsilon_j(\widehat{\mathbf{p}}) = x_j - f_j(\widehat{\mathbf{p}}), \qquad \widehat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}(\widehat{\mathbf{p}}). \tag{4.7}$$

Der Zirkumflex kennzeichnet die Auswertung am geschätzten Parametervektor. Ohne zusätzliche Modellabweichung gilt

$$e_j = x_j - f_j(\mathbf{p}_0) = \varepsilon_j(\mathbf{p}_0). \tag{4.8}$$

Das angepasste Residuum $\widehat{\varepsilon}_j$ ist im Allgemeinen nicht gleich dieser unbekannten Realisierung $e_j$, da $\widehat{\mathbf{p}}$ im Allgemeinen von $\mathbf{p}_0$ abweicht. Die Verteilungsannahme in Gl. (4.5) gilt für die Zufallsgrößen $E_j$. Betrachtet man die angepassten Residuen für die verschiedenen Datensätze, die dieses Beobachtungsmodell liefern könnte, sind sie im Allgemeinen weder unabhängig noch identisch verteilt. Der Grund ist, dass dieselben Daten auch zur Parameterschätzung verwendet werden.

Die Abweichungen $E_j$ und die Residuen sind von der *Messunsicherheit* zu unterscheiden. Eine Abweichung kann ein Vorzeichen besitzen; eine Standardunsicherheit ist eine nichtnegative Kenngröße der zugeordneten Verteilung. Sind die $E_j$ ausschließlich messbedingt, sprechen wir von *Messabweichungen*. Ein zufälliger Term $E_j$ ist bereits Bestandteil des statistischen Modells und bedeutet für sich genommen keine Unzulänglichkeit dieses Modells.

**Zusätzliche Modellabweichung.** Mit $\delta_j$ bezeichnen wir eine *zusätzliche Abweichung aufgrund einer unzureichenden Modellvorhersage*. Beschreibt $f_j(\mathbf{p}_0)$ den Erwartungswert $\mu_j$ der Beobachtung nicht hinreichend genau, kann die Differenz $\delta_j = \mu_j - f_j(\mathbf{p}_0)$ gesondert berücksichtigt werden. Das erweiterte Beobachtungsmodell lautet dann

$$X_j = f_j(\mathbf{p}_0) + \delta_j + E_j, \qquad \mathbb{E}[E_j] = 0. \tag{4.9}$$

Dabei wird $\delta_j$ zunächst als feste, gegebenenfalls unbekannte Abweichung behandelt. Eine Wahrscheinlichkeitsverteilung für $\delta_j$ wäre eine zusätzliche Modellannahme. Für einen realisierten Datensatz folgt aus diesem erweiterten Modell

$$e_j = x_j - f_j(\mathbf{p}_0) - \delta_j, \qquad \varepsilon_j(\mathbf{p}_0) = \delta_j + e_j. \tag{4.10}$$

Somit gilt die Gleichsetzung $e_j = \varepsilon_j(\mathbf{p}_0)$ aus Gl. (4.8) nur für $\delta_j = 0$. Für das weiterhin gegenüber $f_j$ definierte angepasste Residuum ergibt sich

$$\widehat{\varepsilon}_j = \delta_j + e_j + f_j(\mathbf{p}_0) - f_j(\widehat{\mathbf{p}}). \tag{4.11}$$

Wird auch die Modellabweichung geschätzt und in die Vorhersage aufgenommen, lautet das Residuum des erweiterten Modells dagegen $x_j - f_j(\widehat{\mathbf{p}}) - \widehat{\delta}_j$. Die getrennte Bestimmung von $\mathbf{p}_0$ und $\delta_j$ erfordert zusätzliche Annahmen oder Information. Beliebige unbekannte $\delta_j$ lassen sich im Allgemeinen nicht gleichzeitig mit $\mathbf{p}_0$ eindeutig aus denselben Daten schätzen.

Man könnte $\delta_j$ und $E_j$ zu einem gemeinsamen Term zusammenfassen. Dann dürfte man für diesen Term jedoch nicht ohne weitere Begründung die Annahme einer Normalverteilung mit Erwartungswert null beibehalten. Bei festem $\delta_j$ und $E_j \sim \mathcal{N}(0, \sigma^2)$ gilt beispielsweise

$$\delta_j + E_j \sim \mathcal{N}(\delta_j, \sigma^2). \tag{4.12}$$

Der Erwartungswert ist somit $\delta_j$ und im Allgemeinen nicht null. Unterscheiden sich die $\delta_j$ zwischen den Beobachtungen, sind die zusammengefassten Terme außerdem nicht identisch verteilt. Deshalb verwenden wir für die zusätzliche Modellabweichung und die zufällige Abweichung unterschiedliche Symbole.

## 4.3 Wahrscheinlichkeitsdichte und bedingte Wahrscheinlichkeit

Für die folgenden Herleitungen kehren wir zum Modell ohne zusätzliche Modellabweichung, also mit $\delta_j = 0$, zurück. Die Dichte einer zufälligen Abweichung $E_j$ an einer möglichen Ausprägung $e$ lautet

$$p_E(e \mid \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{e^2}{2\sigma^2}\right), \qquad \sigma > 0. \tag{4.13}$$

Dies ist eine *Wahrscheinlichkeitsdichte*, keine Wahrscheinlichkeit für einen einzelnen Wert. Die Wahrscheinlichkeitsdichte an einer Stelle ist von der Wahrscheinlichkeit für einen einzelnen Wert zu unterscheiden. Wahrscheinlichkeiten ergeben sich durch Integration der Dichte über Wertebereiche.

$$\Pr(a \le E_j \le b \mid \sigma) = \int_a^b p_E(E' \mid \sigma)\,\mathrm{d}E'. \tag{4.14}$$

Hier ist Pr der Wahrscheinlichkeitsoperator. Erst ein Ausdruck wie $\Pr(a \le E_j \le b \mid \sigma)$ bezeichnet die Wahrscheinlichkeit eines bestimmten Ereignisses unter dem angegebenen Modell.

$E'$ ist die Integrationsvariable: Sie durchläuft mögliche Werte von $E_j$ und ist keine zusätzliche Zufallsgröße. Der Großbuchstabe mit Strich wird hier ausschließlich als Schreibweise für diese Integrationsvariable verwendet.

Die Wahrscheinlichkeits**dichte** an einer konkreten Stelle kann positiv (also echt größer Null) sein, aber die Wahrscheinlichkeit ist an einem einzelnen, exakt vorgegebenen Wert Null. Das liegt daran, dass wenn ein Intervall um einen vorgegebenen Wert immer schmaler wird, seine Wahrscheinlichkeit bei einer stetigen Verteilungsdichte gegen null geht.

Betrachten wir ein kleines Intervall einer kontinuierlichen, stetigen Wahrscheinlichkeitsdichteverteilung $p_X$ um einen Wert $x_0$

$$\Pr\left(x_0 - \frac{\Delta}{2} \le X \le x_0 + \frac{\Delta}{2}\right) \approx p_X(x_0)\,\Delta.$$

Mit abnehmender Intervallbreite $\Delta$ wird diese Wahrscheinlichkeit kleiner, obwohl der Wert der Wahrscheinlichkeitsdichte $p_X(x_0)$ unverändert bleibt. Mit $\Delta \to 0$ wird

$$\Pr\left(x_0 - \frac{\Delta}{2} \leq X \leq x_0 + \frac{\Delta}{2}\right) \approx p_X(x_0)\,\Delta \to 0.$$

Der senkrechte Strich in Gl. (4.14) bedeutet „gegeben“. Bei Ereignissen $A_1$ und $A_2$ ist die *bedingte Wahrscheinlichkeit* definiert durch

$$\Pr(A_1 \mid A_2) = \frac{\Pr(A_1 \cap A_2)}{\Pr(A_2)}, \qquad \Pr(A_2) > 0. \tag{4.15}$$

Zur Veranschaulichung betrachten wir das gleichwahrscheinliche Ziehen einer Karte aus einem Kartenspiel mit 52 Karten. Sei $B$ das Ereignis „Die gezogene Karte ist ein Bube“ und $F$ das Ereignis „Die gezogene Karte ist eine Bildkarte“ (Bube, Dame oder König). Da jeder Bube eine Bildkarte ist, gilt $B \subset F$ und damit

$$\Pr(B \mid F) = \frac{\Pr(B \cap F)}{\Pr(F)} = \frac{4/52}{12/52} = \frac{1}{3}. \tag{4.16}$$

Die Schreibweise $p_X(x_j \mid \mathbf{p}, \sigma)$ bezeichnet die Dichte der Beobachtung, ausgewertet am beobachteten Wert $x_j$, wenn bestimmte Werte für die Modellparameter $\mathbf{p}$ und die Beobachtungsstreuung $\sigma$ angenommen werden. Im betrachteten statistischen Beobachtungsmodell[2] mit normalverteilten zufälligen Abweichungen legt $f_j(\mathbf{p})$ den Erwartungswert fest; $\sigma$ ist die Standardabweichung der Beobachtung um diesen Erwartungswert. Sie ist nicht die Standardunsicherheit der geschätzten Modellparameter.

Der senkrechte Strich bedeutet hier somit: „unter der Annahme dieser Werte für $\mathbf{p}$ und $\sigma$“. Dazu muss den Modellparametern selbst keine Wahrscheinlichkeitsverteilung zugeordnet werden.

## 4.4 Von der Likelihood zur Methode der kleinsten Quadrate

Für einen einzelnen zu schätzenden Modellparameter $\theta$ und einen Vektor beobachteter Messwerte $\mathbf{x}$ schreiben wir

$$l(\theta; \mathbf{x}) = p(\mathbf{x} \mid \theta).$$

Wir betrachten hier Beobachtungen, deren Verteilung durch eine Wahrscheinlichkeitsdichte beschrieben wird. Der Ausdruck $p(\mathbf{x} \mid \theta)$ ist der Wert dieser gemeinsamen Dichte am beobachteten Datenvektor $\mathbf{x}$, unter der Annahme des Modellparameterwerts $\theta$. Er ist nicht die Wahrscheinlichkeit, genau diesen Datenvektor zu beobachten. Bei festgehaltenen Daten und veränderlichem $\theta$ wird derselbe Ausdruck als *Likelihood* $l(\theta; \mathbf{x})$ bezeichnet.

Der Strich in $p(\mathbf{x} \mid \theta)$ bedeutet hier „unter der Annahme des Parameterwerts $\theta$“. Das Semikolon in $l(\theta; \mathbf{x})$ trennt den betrachteten Parameter von den festgehaltenen Daten; es bezeichnet keine zusätzliche Rechenoperation.

Die Likelihood erlaubt einen relativen Vergleich verschiedener Parameterwerte: Bei welchen Werten

[2] d.h. die zur Beschreibung des Streuverhaltens der Beobachtungen bzw. Messdaten angesetzte Wahrscheinlichkeitsdichte

besitzt das Modell eine größere Dichte für die beobachteten Daten? Eine Likelihood ist jedoch **keine Wahrscheinlichkeitsdichte für den Parameter**. Sie muss über dem Parameterbereich nicht das Integral 1 besitzen. Auch eine nachträgliche Normierung allein rechtfertigt noch keine Wahrscheinlichkeitsaussage über den zu schätzenden Modellparameter.

Im Folgenden wenden wir diese Definition auf den Modellparametervektor $\mathbf{p}$ und die Beobachtungsstreuung $\sigma$ an. Das Symbol $\theta$ in der vorstehenden Definition stand lediglich für einen einzelnen Parameter; es führt kein anderes Schätzprinzip ein.

Die Maximum-Likelihood-Methode benötigt ein Modell für die gemeinsame Verteilung der Beobachtungen. Unabhängigkeit und identische Verteilung sind keine allgemeinen Voraussetzungen dieser Methode.

Für die folgende Herleitung betrachten wir das Modell aus Gl. (4.5). Wir nehmen an, dass die Beobachtungen bei gegebenen Modellparameterwerten unabhängig sind und dass keine zusätzliche Modellabweichung vorliegt ($\delta_j = 0$). Wegen der angenommenen Unabhängigkeit der Beobachtungen ist die gemeinsame Wahrscheinlichkeitsdichte der Beobachtungen das Produkt ihrer Einzeldichten:

$$\begin{aligned} p(\mathbf{x} \mid \mathbf{p}, \sigma) &= \prod_{j=1}^{J} p_X(x_j \mid \mathbf{p}, \sigma) \\ &= \frac{1}{(\sigma\sqrt{2\pi})^J} \exp\left[ -\frac{1}{2\sigma^2} \sum_{j=1}^{J} \big(x_j - f_j(\mathbf{p})\big)^2 \right]. \end{aligned} \tag{4.17}$$

Hier fasst $\mathbf{x} = (x_1, \ldots, x_J)^\mathsf{T}$ die beobachteten Werte zusammen. Die zweite Zeile folgt aus der zusätzlich angenommenen Normalverteilung der zufälligen Abweichungen $E_j$ mit Erwartungswert null und gemeinsamer Varianz $\sigma^2$. Die Beobachtungen besitzen damit dieselbe Varianz, können aber unterschiedliche Erwartungswerte $f_j(\mathbf{p})$ haben.

Hält man diese Werte fest und betrachtet den Ausdruck als Funktion der Parameter, erhält man die *Likelihood*

$$l(\mathbf{p}, \sigma; \mathbf{x}) = p(\mathbf{x} \mid \mathbf{p}, \sigma) = \frac{1}{(\sigma\sqrt{2\pi})^J} \exp\left[ -\frac{S(\mathbf{p})}{2\sigma^2} \right], \quad S(\mathbf{p}) = \sum_{j=1}^{J} \varepsilon_j(\mathbf{p})^2. \tag{4.18}$$

Die Likelihood ist damit eingeführt, ohne den zu schätzenden Modellparametern selbst eine Verteilung zuzuordnen. Eine solche Parameterverteilung führen wir erst in Abschnitt 4.8 ein.

**Wie die Beobachtungsstreuung in die Rechnung eingeht.** Die Annahme über die Streuung steht bereits im Beobachtungsmodell aus Gl. (4.5): Bei festen Modellparameterwerten $\mathbf{p}_0$ sind verschiedene Beobachtungen möglich, deren Abweichungen durch die Verteilung der $E_j$ beschrieben werden. Diese Annahme geht in Gl. (4.18) über $\sigma$ in die Likelihood ein. Ist $\sigma$ nicht bekannt, wird es mitgeschätzt. Es wird keine zusätzliche Streuung durch gedachte Wiederholungen eingeführt.

Wird $\sigma$ als fest vorgegeben betrachtet, ist die Maximierung der Likelihood bezüglich $\mathbf{p}$ gleichbedeutend mit der Minimierung von $S(\mathbf{p})$. Der so bestimmte Schätzwert $\widehat{\mathbf{p}}$ hängt hier nicht vom vorgegebenen Wert von $\sigma$ ab.

Soll auch $\sigma$ geschätzt werden, muss die vollständige Likelihood einschließlich des Vorfaktors $\sigma^{-J}$ bezüg-

lich $\sigma$ maximiert werden. Die Minimierung der Residuenquadratsumme allein liefert diesen Schätzwert noch nicht.

Für die Auswertung bleiben die beobachteten Werte $\mathbf{x}$ fest. Die Optimierung verändert nur die zu schätzenden Modellparameter, einschließlich einer gegebenenfalls mitgeschätzten Beobachtungsstreuung. Sie erzeugt keine neuen Messdaten und führt keine Wiederholungsmessungen durch. Der Ausdruck *gedachte Wiederholungen* erläutert lediglich, welche anderen Datensätze unter demselben Beobachtungsmodell bei unveränderten Parameterwerten und Versuchsbedingungen möglich wären. Die Likelihood und ihre Maximierung benötigen diese Vorstellung nicht als zusätzlichen Rechenschritt.

**Maximierung der Likelihood.** Wie im Beispiel zum ohmschen Gesetz in Abschnitt 1.2 führt die Maximum-Likelihood-Schätzung unter den genannten Annahmen zur Minimierung einer Residuenquadratsumme. Für ein festes, von $\mathbf{p}$ unabhängiges $\sigma$ gilt

$$\widehat{\mathbf{p}} = \arg\max_{\mathbf{p}} l(\mathbf{p}, \sigma; \mathbf{x}) = \arg\min_{\mathbf{p}} S(\mathbf{p}). \tag{4.19}$$

arg max bezeichnet den Parameterwert, an dem das Maximum angenommen wird; arg min entsprechend den Parameterwert am Minimum. Dabei wird der positive Ausdruck $S/(2\sigma^2)$ im negativen Exponenten minimiert.

Ist $\sigma$ ebenfalls unbekannt, muss auch der Normierungsfaktor $\sigma^{-J}$ berücksichtigt werden. Die negative Log-Likelihood lautet

$$-\log l(\mathbf{p}, \sigma; \mathbf{x}) = \frac{J}{2}\log(2\pi) + J\log\sigma + \frac{S(\mathbf{p})}{2\sigma^2}. \tag{4.20}$$

Bei einer gemeinsamen unbekannten Varianz, die nicht von $\mathbf{p}$ abhängt, ergeben sich weiterhin die Kleinstquadrateschätzung von $\mathbf{p}$ und, sofern $S(\widehat{\mathbf{p}}) > 0$,

$$\widehat{\sigma}^2_{\mathrm{ML}} = \frac{S(\widehat{\mathbf{p}})}{J}. \tag{4.21}$$

Davon zu unterscheiden ist der erwartungstreue Varianzschätzer $s^2 = S(\widehat{\mathbf{p}})/(J-M)$ im korrekt spezifizierten linearen Modell mit $M$ unabhängig bestimmbaren Parametern und $J > M$. Für nichtlineare Modelle ist diese Freiheitsgradkorrektur im Allgemeinen nur näherungsweise begründet. Bei exakt verschwindender Residuenquadratsumme wird die Likelihood für $\sigma \to 0$ unbeschränkt; es gibt dann kein endliches Maximum mit $\sigma > 0$.

## 4.5 Frequentistische Auswertung: Standardunsicherheiten und Residuen

Im *frequentistischen Ansatz* werden die zu schätzenden Modellparameter als feste Größen behandelt, deren Werte aus den Messdaten bestimmt werden sollen. Ein Modellparameter kann dabei den Wert einer indirekten Messgröße beschreiben. Die zufällige Streuung der Beobachtungen führt zu einer Streuung der daraus berechneten Parameterschätzwerte; sie bedeutet nicht, dass der zugrunde liegende Modellparameter selbst zufällig variiert.

Ein Schätzer ist eine Rechenvorschrift, die möglichen Beobachtungsdaten jeweils einen Schätzwert

zuordnet. Da die Beobachtungen als Zufallsgrößen modelliert werden, ist auch der daraus berechnete Schätzer eine Zufallsgröße. Für die konkret beobachteten Messwerte liefert die Rechenvorschrift einen bestimmten Schätzwert.

**Berechnung der Standardunsicherheiten.** Die Unsicherheit der geschätzten Modellparameter wird ermittelt, indem die im statistischen Beobachtungsmodell beschriebene Streuung der Beobachtungen auf die Parameterschätzung übertragen wird. Neben den Varianzen und Kovarianzen der Beobachtungen ist dafür entscheidend, wie die berechneten Parameterschätzwerte von den Beobachtungen abhängen. Die benötigten Varianzen und Kovarianzen werden als bekannt vorausgesetzt oder aus den Daten geschätzt. Die *Standardunsicherheit eines geschätzten Modellparameters* ergibt sich hier als Quadratwurzel des zugehörigen Diagonalelements der Parameterkovarianzmatrix. Wir schreiben dafür $u(\widehat{P}_m)$ und entsprechend $u(\widehat{\mu})$ oder $u(\widehat{R})$ in den Beispielen.

Eine Optimierung kann außer dem Schätzwert auch die Krümmung der Kostenfunktion beziehungsweise der negativen Log-Likelihood liefern. Dass sich daraus unter geeigneten Voraussetzungen eine Parameterkovarianzmatrix berechnen lässt, folgt aus dem statistischen Beobachtungsmodell und der Abhängigkeit der Schätzung von den Daten. Es ist keine Eigenschaft der Optimierung allein. Die entsprechende Herleitung wurde in Vorlesung 3 behandelt.

**Was mit gedachten Wiederholungen gemeint ist.** Die frequentistische Interpretation lässt sich durch eine Frage verdeutlichen: Welche Parameterschätzwerte würden wir erhalten, wenn andere, nach demselben Beobachtungsmodell mögliche Daten vorlägen und jeweils mit demselben Verfahren ausgewertet würden? Die so betrachtete Streuung der Schätzwerte wird durch die berechnete Parameterkovarianz beschrieben.

*Gedachte Wiederholungen sind keine zusätzliche Modellannahme und kein zusätzlicher Berechnungsschritt.* Sie veranschaulichen die bereits im Beobachtungsmodell beschriebene Variabilität und deren Auswirkung auf die Parameterschätzung. Die benötigten Datensätze müssen weder tatsächlich gemessen noch numerisch erzeugt werden. Die Standardunsicherheiten der geschätzten Modellparameter beschreiben hier die daraus abgeleitete Streuung der Schätzwerte, nicht eine zufällige Änderung der indirekten Messgrößen.

Die so berechneten Standardunsicherheiten berücksichtigen die im jeweiligen Modell erfassten Beiträge. Eine zusätzliche systematische Abweichung durch eine unzureichende Modellvorhersage wird dadurch nicht automatisch erfasst.

### 4.5.1 Wiederholte Messung einer einzelnen Größe

Ein besonders einfaches lineares Modell beschreibt wiederholte Beobachtungen derselben Größe. Der zu schätzende Modellparameter ist ihr Erwartungswert $\mu$:

$$X_j = \mu + E_j, \qquad E_j \overset{\text{u.i.v.}}{\sim} \mathcal{N}(0, \sigma^2), \qquad j = 1, \ldots, J. \tag{4.22}$$

Hier ist der Modellparametervektor eindimensional, $\mathbf{p} = (\mu)$, und die Residuenfunktion lautet

$$\varepsilon_j(\mu) = x_j - \mu. \tag{4.23}$$

Die Minimierung der Quadratsumme ergibt den beobachteten Mittelwert $\widehat{\mu} = \overline{x} = J^{-1}\sum_j x_j$ als Schätzwert für $\mu$. Der zugehörige Schätzer ist

$$\overline{X} = \frac{1}{J}\sum_{j=1}^{J} X_j = \mu + \frac{1}{J}\sum_{j=1}^{J} E_j.$$

Die Abweichungen haben den Erwartungswert null. Wegen ihrer Unabhängigkeit addieren sich ihre Varianzen; der Faktor $1/J$ geht quadratisch in die Varianz ein. Damit folgt

$$\mathbb{E}[\overline{X}] = \mu, \qquad \mathrm{Var}(\overline{X}) = \frac{1}{J^2}\sum_{j=1}^{J}\mathrm{Var}(E_j) = \frac{\sigma^2}{J}.$$

Eine Summe unabhängiger normalverteilter Zufallsgrößen ist wiederum normalverteilt. Deshalb gilt unter diesem Modell exakt

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{J}\right), \qquad u(\widehat{\mu}) = \frac{\sigma}{\sqrt{J}}. \tag{4.24}$$

Dies ist eine Verteilung möglicher Mittelwerte bei festem $\mu$, keine Verteilung für den zu schätzenden Modellparameter $\mu$. Die zugeordnete Standardunsicherheit $u(\widehat{\mu})$ wird hier aus der Standardabweichung dieser Mittelwertverteilung bestimmt.

Ist $\sigma$ unbekannt, schätzen wir die Varianz der Einzelbeobachtungen durch

$$S^2 = \frac{1}{J-1}\sum_{j=1}^{J}(X_j - \overline{X})^2, \qquad s^2 = \frac{1}{J-1}\sum_{j=1}^{J}(x_j - \overline{x})^2.$$

$S^2$ ist der Varianzschätzer als Zufallsgröße, $s^2$ sein aus den beobachteten Daten berechneter Wert. Bei geschätzter Beobachtungsstreuung verwenden wir $u(\widehat{\mu}) = s/\sqrt{J}$ als Standardunsicherheit des geschätzten Modellparameters.

**Konfidenzintervall als Aussage über ein Verfahren.** Ein Intervallschätzverfahren berechnet aus den Beobachtungsdaten eine untere und eine obere Grenze. Beim hier betrachteten Verfahren bedeutet ein Konfidenzniveau von 95 %: Unter dem angenommenen Beobachtungsmodell beträgt die Wahrscheinlichkeit 95 %, dass das aus den möglichen Daten berechnete Intervall den festen Modellparameterwert enthält.

Die Wahrscheinlichkeit bezieht sich auf die möglichen Datensätze und die daraus berechneten Intervalle. Dies lässt sich durch gedachte Wiederholungen derselben Messung und Auswertung veranschaulichen; solche Wiederholungen sind kein zusätzlicher Berechnungsschritt. Dem festen Modellparameter wird dabei keine Wahrscheinlichkeitsverteilung zugeordnet.

Für spätere Vergleiche geben wir hier bereits das Konfidenzintervall für den Erwartungswert $\mu$ bei unbekannter Beobachtungsstreuung $\sigma$ an. Wir setzen das Beobachtungsmodell aus Gl. (4.22) voraus: Die $J > 1$ Beobachtungen sind unabhängig und normalverteilt mit demselben Erwartungswert $\mu$ und

derselben Varianz $\sigma^2 > 0$.

Bezeichnet $S$ die Stichprobenstandardabweichung, deren Quadrat mit dem Nenner $J-1$ berechnet wird, so besitzt die Größe

$$T = \frac{\overline{X} - \mu}{S/\sqrt{J}} \sim p_t(J-1) \tag{4.25}$$

eine Student-$t$-Verteilung mit $J-1$ Freiheitsgraden. Die ausführliche Behandlung dieser Verteilung folgt in Vorlesung 5.

Das $\alpha$-Quantil $t_{\alpha,\nu}$ der Student-$t$-Verteilung mit $\nu$ Freiheitsgraden ist durch

$$\Pr(T \le t_{\alpha,\nu}) = \alpha, \qquad T \sim p_t(\nu),$$

definiert. Dabei ist $t_{\alpha,\nu}$ ein Quantilwert; der Index $\alpha$ gibt die Wahrscheinlichkeit links von diesem Wert an.

Wegen der Symmetrie der Student-$t$-Verteilung gilt

$$\Pr\bigl(-t_{1-\alpha/2,J-1} \le T \le t_{1-\alpha/2,J-1}\bigr) = 1-\alpha.$$

Unterhalb und oberhalb dieses Bereichs verbleibt jeweils die Wahrscheinlichkeit $\alpha/2$.

Einsetzen von $T$ aus Gl. (4.25) und Umstellen der Ungleichungen nach $\mu$ liefert

$$\Pr_{\mu,\sigma}\left(\overline{X} - t_{1-\alpha/2,J-1}\frac{S}{\sqrt{J}} \le \mu \le \overline{X} + t_{1-\alpha/2,J-1}\frac{S}{\sqrt{J}}\right) = 1-\alpha. \tag{4.26}$$

Die Vorschrift zur Berechnung dieser Intervallgrenzen ist festgelegt. Auch $\alpha$, $J$ und der daraus bestimmte Quantilwert sind fest. Die Größen $\overline{X}$ und $S$ hängen jedoch von den möglichen Beobachtungsdaten ab und sind deshalb Zufallsgrößen. Damit sind auch die aus ihnen berechneten Intervallgrenzen Zufallsgrößen: Andere mögliche Datensätze können zu anderen Grenzen führen. Mit einem *zufälligen Intervall* ist somit ein datenabhängiges Intervall gemeint, dessen Grenzen nach einer festen Vorschrift berechnet werden.

Der tiefgestellte Zusatz $\mu, \sigma$ kennzeichnet das Beobachtungsmodell bei festen Werten von $\mu$ und $\sigma$. Die Wahrscheinlichkeit $1-\alpha$ gehört zum Ereignis, dass die datenabhängigen Grenzen den festen Wert $\mu$ einschließen. Sie beschreibt die Überdeckung durch das Verfahren.

Für die konkret beobachteten Daten setzen wir die berechneten Werte $\overline{x}$ und $s$ ein und erhalten

$$\left[\overline{x} - t_{1-\alpha/2,J-1}\frac{s}{\sqrt{J}},\ \overline{x} + t_{1-\alpha/2,J-1}\frac{s}{\sqrt{J}}\right]. \tag{4.27}$$

Dieses Intervall hat feststehende Grenzen. Es enthält den festen Wert $\mu$ oder enthält ihn nicht; welche dieser beiden Möglichkeiten zutrifft, ist im Allgemeinen nicht bekannt. Die frequentistische Aussage von 95 % betrifft die Überdeckung durch das Verfahren, nicht eine nachträgliche Wahrscheinlichkeit für $\mu$ innerhalb dieses konkreten Intervalls.

Für ein Konfidenzniveau von 95 % ist $\alpha = 0{,}05$ und damit $1-\alpha/2 = 0{,}975$.

### 4.5.2 Lineare Regression als Beispiel

In Vorlesung 2 haben wir die lineare Regression behandelt. In der dort üblichen Bezeichnung ist $Y_j$ der Regressand und $x_{i,j}$ sind die vorgegebenen Regressorwerte:

$$Y_j = \sum_{i=1}^{M} \theta_i x_{i,j} + E_j, \qquad \varepsilon_j(\boldsymbol{\theta}) = y_j - \sum_{i=1}^{M} \theta_i x_{i,j}. \tag{4.28}$$

Das Symbol $Y$ bezeichnet in diesem Regressionsbeispiel eine beobachtete Größe; es hat hier eine andere Rolle als im Schema des inversen Problems. Die indirekten Messgrößen, die die Modellparameter sind, sind bei der linearen Regression die Regressionskoeffizienten und werden in diesem Vorlesungskript mit dem Formelsymbol $\theta$ bezeichnet. Ein konstanter Term lässt sich durch einen Regressor mit dem Wert 1 darstellen.

Die Regressorwerte werden in diesem Modell als feste, hinreichend genau bekannte Eingabewerte behandelt. Bei der Bestimmung eines Widerstands aus einer Strom-Spannungs-Kennlinie werden beispielsweise verschiedene Stromwerte eingestellt und die zugehörigen Spannungen gemessen. Der gewählte Strombereich soll eine zuverlässige Bestimmung der Geradensteigung ermöglichen, die den Widerstand beschreibt.

Bei der linearen Regression wird die Messunsicherheit der Stromwerte vernachlässigt. Diese Näherung ist gerechtfertigt, wenn ihr Einfluss auf den geschätzten Widerstand und dessen Standardunsicherheit hinreichend klein ist. Andernfalls muss die Messunsicherheit der Stromwerte zusätzlich zu derjenigen der Spannungswerte im statistischen Modell berücksichtigt werden. Dafür eignet sich beispielsweise eine Geradenanpassung nach der Methode der kleinsten Quadrate mit einer Kostenfunktion, die die Messunsicherheiten beider Größen berücksichtigt.

Die Annahme aus Abschnitt 2.1 ist präzise so zu verstehen: Die zufälligen Abweichungen $E_j$ sind bedingt auf die Regressorwerte unabhängig normalverteilt, haben den Erwartungswert null und dieselbe Varianz $\sigma^2$. Die Regressanden besitzen damit bedingt auf die Regressoren dieselbe Varianz, im Allgemeinen aber unterschiedliche Erwartungswerte. Sie sind also nicht identisch verteilt. Die lineare Kleinstquadrateschätzung stimmt unter diesen Annahmen mit der Maximum-Likelihood-Schätzung der Regressionsparameter überein. Als Optimierungsverfahren setzt die Methode der kleinsten Quadrate selbst keine Normalverteilung voraus.

**Anschluss an die Regressormatrix aus Vorlesung 2.** Wir verwenden weiterhin die dort eingeführte Regressormatrix $\mathbf{X} \in \mathbb{R}^{J \times M}$. Sie wird auch als *Designmatrix* bezeichnet. Jede Zeile gehört zu einer Beobachtung, jede Spalte stellt einen Regressor dar und ist einem Regressionskoeffizienten zugeordnet. Mit den oben verwendeten Indizes gilt $[\mathbf{X}]_{ji} = x_{i,j}$. Für eine Gerade mit Achsenabschnitt $\theta_0$ und Steigung $\theta_1$ lautet sie beispielsweise

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_J \end{pmatrix}, \qquad \boldsymbol{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}, \qquad M = 2. \tag{4.29}$$

Dabei ist $x_j$ der beobachtete Regressorwert; in Vorlesung 2 wurde hierfür auch $X_j$ bzw. $X_{1,j}$ geschrieben. Der Großbuchstabe in $\mathbf{X}$ bezeichnet hier die bekannte Matrix. Sie wird in dem Regressionsansatz als nicht zufällig betrachtet und unterscheidet sich damit vom Zufallsvektor $\mathbf{X}_j$ eines allgemeinen Beobachtungsmodells. Wir betrachten also eine feste Regressormatrix mit vollem Spaltenrang und gewöhnliche, ungewichtete kleinste Quadrate. Es gilt

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{E}, \qquad \mathbb{E}[\mathbf{E}] = \mathbf{0}, \qquad \mathrm{Cov}(\mathbf{E}) = \sigma^2 \mathbf{I}_J. \tag{4.30}$$

Hier enthält $\boldsymbol{\theta}$ die festen Werte der zu schätzenden Modellparameter, in diesem Fall die Regressionskoeffizienten. Eine zusätzliche Modellabweichung wird in dieser Herleitung nicht berücksichtigt. Der Vektor $\mathbf{y}$ enthält die beobachteten Werte der im Zufallsvektor $\mathbf{Y}$ zusammengefassten Größen.

Die folgenden Kovarianzen beschreiben, wie die berechneten Parameterschätzwerte, Modellwerte und Residuen mit den nach dem Beobachtungsmodell möglichen Daten variieren. Die Formeln für konkrete Schätzwerte verwenden $\mathbf{y}$; für die Berechnung ihrer Kovarianzen wird darin der Zufallsvektor $\mathbf{Y}$ eingesetzt. Den Zirkumflex verwenden wir wie in den vorangegangenen Vorlesungen sowohl beim Schätzer als auch bei seinem beobachteten Wert.

**Kovarianz der geschätzten Parameter.** Aus Vorlesung 2, Gl. (2.40), ist bekannt:

$$\widehat{\boldsymbol{\theta}} = (\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}\mathbf{y}. \tag{4.31}$$

Ferner hatten wir in Vorlesung 1 die Multiplikation einer Zufallsgröße $X$ mit einer festen skalaren Größe $b$ kennengelernt, Gl. (1.50) mit $\mathrm{Var}(bX) := b^2\,\mathrm{Var}(X)$.

Entsprechend gilt dies für eine feste Matrix $\mathbf{B}$, also $\mathrm{Cov}(\mathbf{BY}) = \mathbf{B}\,\mathrm{Cov}(\mathbf{Y})\mathbf{B}^\mathsf{T}$. Mit $\mathrm{Cov}(\mathbf{Y}) = \sigma^2\mathbf{I}_J$ erhalten wir daher

$$\begin{aligned}\mathrm{Cov}(\widehat{\boldsymbol{\theta}}) &= \sigma^2(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}\mathbf{X}(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1} \\ &= \sigma^2(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}.\end{aligned} \tag{4.32}$$

Dies ist die bekannte $M \times M$-Kovarianzmatrix der Schätzwerte der Modellparameter. Die Vereinfachung ist möglich, weil $(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}(\mathbf{X}^\mathsf{T}\mathbf{X}) = \mathbf{I}_M$ unmittelbar als Teilprodukt vorkommt[3]. Daraus folgt jedoch *nicht* $\mathbf{X}(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T} = (\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}$. Die linke Matrix ist $J \times J$, die rechte $M \times M$ groß. Die Reihenfolge der Faktoren darf nicht beliebig geändert werden.

Der Anschluss an Vorlesung 3 ergibt sich aus der Residuenfunktion $\boldsymbol{\varepsilon}(\boldsymbol{\theta}) = \mathbf{y} - \mathbf{X}\boldsymbol{\theta}$. Ihre Jacobi-Matrix bezüglich der Parameter ist

$$\mathbf{J} = -\mathbf{X}, \qquad \mathbf{J}^\mathsf{T}\mathbf{J} = \mathbf{X}^\mathsf{T}\mathbf{X}. \tag{4.33}$$

Damit lässt sich Gl. (4.32) auch als $\mathrm{Cov}(\widehat{\boldsymbol{\theta}}) = \sigma^2(\mathbf{J}^\mathsf{T}\mathbf{J})^{-1}$ schreiben. Im linearen Modell ist dies eine exakte Beziehung. Bei nichtlinearen Modellen liefert die entsprechende Formel unter den gleichen Varianzannahmen im Allgemeinen nur eine Näherung durch Linearisierung am geschätzten Parametervektor.

[3] Die Symbole $\mathbf{I}_M$ und $\mathbf{I}_J$ stehen für Einheitsmatrix, $\mathbf{I}_M$ für eine $M \times M$-Matrix mit $M$ Einsen auf der Hauptdiagonalen, Nullen sonst.

**Schätzwertewerte der Modellparameter und ihre Kovarianz.** Die Ausgleichsrechnung (Regression oder Optimierung) liefert die Schätzwertewerte der Modellparameter

$$\widehat{\mathbf{y}} = \mathbf{X}\widehat{\boldsymbol{\theta}} = \underbrace{\mathbf{X}(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}}_{\mathbf{P}_X}\mathbf{y}. \tag{4.34}$$

Die Matrix $\mathbf{P}_X$ bildet die Daten auf die durch die Anpassung geschätzten Werte der Modellparameter ab. Sie ist eine Projektionsmatrix; häufig wird sie auch mit $\mathbf{H}$ bezeichnet. Hier verwenden wir $\mathbf{P}_X$, um sie von der Hesse-Matrix der Kostenfunktion aus Vorlesung 3 zu unterscheiden. Die Kovarianzfortpflanzung von den Parameterschätzerwerten ergibt

$$\mathrm{Cov}(\widehat{\mathbf{y}}) = \mathbf{X}\,\mathrm{Cov}(\widehat{\boldsymbol{\theta}})\mathbf{X}^\mathsf{T} = \sigma^2\mathbf{P}_X. \tag{4.35}$$

Es gilt $\mathbf{P}_X^\mathsf{T} = \mathbf{P}_X$. Außerdem folgt direkt

$$\mathbf{P}_X^2 = \mathbf{X}(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}(\mathbf{X}^\mathsf{T}\mathbf{X})(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T} = \mathbf{P}_X. \tag{4.36}$$

Die erneute Projektion bereits geschätzer Modellparameterwerte ändert diese also nicht.

**Kovarianz der Residuen zu den Schätzwerten der Modellparameter.** Die Differenzen zwischen den Messwerten des Regressanden und dem Regressanden, der aus den Schätzwerten der Modellparameter (Regressionskoeffizienten) und den Regressoren gebildet wird, sind die Residuen nach der Ausgleichsrechnung (Parameteranpassung). Sie werden im Folgenden kurz *angepasste Residuen* genannt:

$$\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}(\widehat{\boldsymbol{\theta}}) = \mathbf{y} - \widehat{\mathbf{y}} = (\mathbf{I}_J - \mathbf{P}_X)\mathbf{y}. \tag{4.37}$$

Ihre Kovarianzmatrix hängt somit über eine andere Matrix von den Beobachtungen ab als die Kovarianzmatrix der Parameterschätzwerte. Aus der Regel zur Kovarianzfortpflanzung folgt

$$\begin{aligned}
\mathrm{Cov}(\widehat{\boldsymbol{\varepsilon}}) &= \sigma^2(\mathbf{I}_J - \mathbf{P}_X)(\mathbf{I}_J - \mathbf{P}_X)^\mathsf{T} \\
&= \sigma^2(\mathbf{I}_J - 2\mathbf{P}_X + \mathbf{P}_X^2) \\
&= \sigma^2(\mathbf{I}_J - \mathbf{P}_X) \\
&= \sigma^2\left[\mathbf{I}_J - \mathbf{X}(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}\right].
\end{aligned} \tag{4.38}$$

Diese $J \times J$-Matrix beschreibt die Residuen bezüglich der Parameterschätzwerte, nicht die $M$ Parameterschätzwerte selbst. Ihre Diagonalelemente sind $\mathrm{Var}(\widehat{\varepsilon}_j) = \sigma^2(1 - [\mathbf{P}_X]_{jj})$. Für $j \neq k$ gilt $\mathrm{Cov}(\widehat{\varepsilon}_j, \widehat{\varepsilon}_k) = -\sigma^2[\mathbf{P}_X]_{jk}$.

Die Residuen nach der Parameteranpassung, kurz *angepasste Residuen* bezeichnet, sind also im Allgemeinen korreliert, auch wenn die ursprünglichen Abweichungen $E_j$ unabhängig sind. Normalverteilung ist für diese Kovarianzformeln nicht erforderlich.

Anschaulich entsteht die Kopplung dadurch, dass dieselben Daten zur Schätzung aller Modellwerte verwendet werden. Die Normalgleichungen aus Vorlesung 2 verlangen $\mathbf{X}^\mathsf{T}\widehat{\boldsymbol{\varepsilon}} = \mathbf{0}$. Bei einer Geraden mit Achsenabschnitt bedeutet dies insbesondere $\sum_j \widehat{\varepsilon}_j = 0$ und $\sum_j x_j\widehat{\varepsilon}_j = 0$. Die Residuen können daher nicht unabhängig voneinander variieren.

**Bedeutung der aus den Residuen geschätzten Varianz.** Die in Vorlesung 2 verwendete Größe

$$\widehat{\sigma}_\varepsilon^2 = \frac{\widehat{\boldsymbol{\varepsilon}}^{\mathsf{T}}\widehat{\boldsymbol{\varepsilon}}}{J-M}, \qquad J > M, \tag{4.39}$$

ist ein Schätzergebnis der gemeinsamen Varianz $\sigma^2$ der ursprünglichen Abweichungen $E_j$. Sie ist weder die Kovarianzmatrix des angepassten Residuenvektors noch die Varianz jedes einzelnen angepassten Residuums. Bei unbekanntem $\sigma^2$ wird in den obigen Kovarianzformeln $\sigma^2$ durch $\widehat{\sigma}_\varepsilon^2$ ersetzt, um die jeweiligen Kovarianzmatrizen zu schätzen. Damit ergibt sich insbesondere wieder die empirische Parameterkovarianz aus Gl. (2.53) in Vorlesung 2.

## 4.6 Vektorielle Beobachtungen und gewichtete kleinste Quadrate

Für $N$ gemeinsam beobachtete Größen enthält die Matrix $\boldsymbol{\Sigma}_j$ die Varianzen und Kovarianzen der zufälligen Abweichungen:

$$\boldsymbol{\Sigma}_j = \begin{pmatrix} \sigma_{1,j}^2 & \cdots & \sigma_{1N,j} \\ \vdots & \ddots & \vdots \\ \sigma_{N1,j} & \cdots & \sigma_{N,j}^2 \end{pmatrix}. \tag{4.40}$$

Die Kovarianzen innerhalb einer Beobachtung sind von Abhängigkeiten zwischen verschiedenen Beobachtungen zu unterscheiden. Im Folgenden setzen wir weiterhin unabhängige Beobachtungen voraus.

Für das additive Modell aus Gl. (4.2) ohne zusätzliche Modellabweichung und mit $\mathbf{E}_j \sim \mathcal{N}_N(\mathbf{0}, \boldsymbol{\Sigma}_j)$ und positiv definiten Kovarianzmatrizen gilt

$$p(\mathbf{x}_j \mid \mathbf{p}, \boldsymbol{\Sigma}_j) = \frac{\exp\left[-\frac{1}{2}\boldsymbol{\varepsilon}_j(\mathbf{p})^{\mathsf{T}}\boldsymbol{\Sigma}_j^{-1}\boldsymbol{\varepsilon}_j(\mathbf{p})\right]}{(2\pi)^{N/2}\sqrt{\det \boldsymbol{\Sigma}_j}}. \tag{4.41}$$

Hier bezeichnet $\boldsymbol{\varepsilon}_j(\mathbf{p}) = \mathbf{x}_j - \mathbf{f}_j(\mathbf{p})$ den $N$-dimensionalen Residuenvektor der Beobachtung $j$. Für den gesamten Datensatz können die Vektoren zu $\boldsymbol{\varepsilon}(\mathbf{p}) = (\boldsymbol{\varepsilon}_1(\mathbf{p})^{\mathsf{T}}, \ldots, \boldsymbol{\varepsilon}_J(\mathbf{p})^{\mathsf{T}})^{\mathsf{T}}$ zusammengefasst werden. Wie im skalaren Fall gilt nach der Anpassung $\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}(\widehat{\mathbf{p}})$. Bei einer implizit beschriebenen Modellkurve müssen gegebenenfalls zusätzlich die Positionen der Modellpunkte bestimmt werden. Dies veranschaulicht anschließend das Geradenbeispiel in Abschnitt 4.7. Die Dichte bezieht sich auf die ursprünglichen Beobachtungen, nicht auf die bereits angepassten Residuen.

Die gemeinsame Dichte, englisch *joint probability density*, ist

$$p(\mathbf{x}_1, \ldots, \mathbf{x}_J \mid \mathbf{p}, \boldsymbol{\Sigma}_1, \ldots, \boldsymbol{\Sigma}_J) = \prod_{j=1}^{J} p(\mathbf{x}_j \mid \mathbf{p}, \boldsymbol{\Sigma}_j). \tag{4.42}$$

Wir fassen alle beobachteten Werte als Datensatz $\mathcal{D}$ zusammen. Sind die Kovarianzmatrizen bekannte Funktionen der Parameter, lautet die Likelihood für feste Daten

$$l(\mathbf{p}; \mathcal{D}) = \frac{\exp[-Q(\mathbf{p})/2]}{(2\pi)^{NJ/2}\prod_{j=1}^{J}\sqrt{\det \boldsymbol{\Sigma}_j(\mathbf{p})}}, \tag{4.43}$$

wobei die Daten als feste Werte in die Residuen und damit also Kostenfunktion eingehen

$$Q(\mathbf{p}) = \sum_{j=1}^{J} \boldsymbol{\varepsilon}_j(\mathbf{p})^\mathsf{T} \boldsymbol{\Sigma}_j(\mathbf{p})^{-1} \boldsymbol{\varepsilon}_j(\mathbf{p}). \tag{4.44}$$

Sind die Kovarianzmatrizen fest vorgegeben und parameterunabhängig, ist die Maximierung der Likelihood gleichbedeutend mit der Minimierung von $Q$. Dies ist die verallgemeinerte Methode der kleinsten Quadrate. Der Ausdruck $\boldsymbol{\varepsilon}^\mathsf{T} \boldsymbol{\Sigma}^{-1} \boldsymbol{\varepsilon}$ ist dimensionslos. Er erlaubt somit auch die gemeinsame Behandlung von Komponenten mit unterschiedlichen physikalischen Einheiten; ein gewöhnlicher euklidischer Abstand wäre in diesem Fall nicht sinnvoll.

Hängen die Kovarianzmatrizen dagegen von den zu schätzenden Parametern ab, muss auch ihre Determinante berücksichtigt werden:

$$-2 \log l(\mathbf{p}; \mathcal{D}) = NJ \log(2\pi) + \sum_{j=1}^{J} \log \det \boldsymbol{\Sigma}_j(\mathbf{p}) + Q(\mathbf{p}). \tag{4.45}$$

Hier sind alle Größen in fest gewählten Einheiten ausgedrückt. Eine Änderung der Einheiten verändert nur parameterunabhängige Konstanten in der Log-Likelihood. Zu schätzende Kovarianzparameter müssen in das Schätzproblem einbezogen werden. Die Verwendung von aus denselben Beobachtungen abgeleiteten Gewichten ist gesondert zu begründen; sie liefert nicht automatisch eine vollständige Maximum-Likelihood-Schätzung.

Sind verschiedene Beobachtungen korreliert, gilt die Produktdarstellung aus Gl. (4.42) nicht mehr. Dann werden alle Beobachtungen zu einem Vektor zusammengefasst. Sie müssen durch eine gemeinsame Wahrscheichlichkeitsdichte (*joint probability density*) beschrieben werden und entsprechend gemeinsam mit ihrer vollständigen Kovarianzmatrix modelliert werden.

## 4.7 Streuende Koordinaten und gewichtete Geradenanpassung

Die allgemeine Gewichtung wenden wir nun auf eine Geradenanpassung an. Häufig sind mehreren Komponenten einer Beobachtung Messunsicherheiten zugeordnet. Bei der Bestimmung eines elektrischen Widerstands können dies beispielsweise Strom und Spannung sein. Auch Größen gleicher physikalischer Dimension können unterschiedlich stark streuen, etwa die horizontale Position und die vertikale Höhe bei einer Oberflächenmessung. Die Form der Kostenfunktion muss diese Unterschiede berücksichtigen.

Für die geometrische Darstellung betrachten wir zunächst zwei Größen gleicher physikalischer Dimension, ausgedrückt in derselben Einheit und mit gleicher Achsenskalierung. Eine Gerade lässt sich durch ihren Steigungswinkel $\alpha$ und einen orientierten Abstand $d$ beschreiben. Mit dem Einheitsnormalenvektor $\mathbf{n}(\alpha) = (-\sin\alpha, \cos\alpha)^\mathsf{T}$ gilt $\mathbf{n}^\mathsf{T}\mathbf{z} = d$ für Punkte $\mathbf{z}$ auf der Geraden. Der geometrische Abstand zum Ursprung ist $|d|$. Für den Messpunkt $\mathbf{x}_j = (x_{1,j}, x_{2,j})^\mathsf{T}$ ist

$$\varepsilon_j(\alpha, d) = \mathbf{n}(\alpha)^\mathsf{T}\mathbf{x}_j - d = -x_{1,j}\sin\alpha + x_{2,j}\cos\alpha - d \tag{4.46}$$

der vorzeichenbehaftete senkrechte Abstand zur Geraden. Dabei bezeichnet $\mathbf{x}_j$ einen beobachteten

Messpunkt; $\mathbf{z}$ bezeichnet einen Punkt, der auf der betrachteten Geraden liegt. Die Messpunkte müssen nicht auf dieser Geraden liegen.

Sind die Messabweichungen sowohl zwischen verschiedenen Messpunkten als auch zwischen den beiden Koordinaten unabhängig normalverteilt und haben sie überall dieselbe Varianz $\sigma^2$, führt die Anpassung zur Minimierung der Summe der quadrierten senkrechten Abstände. Dies ist die gewöhnliche *Total-Least-Squares-Methode* (TLS) für die Gerade. Im Folgenden erweitern wir diese Anpassung auf unterschiedliche Varianzen und mögliche Korrelationen zwischen den beiden Koordinaten eines Messpunkts.

**Beobachtete Messpunkte und zu schätzende Punkte auf der Geraden.** Zu jedem beobachteten Messpunkt $\mathbf{x}_j$ suchen wir einen zugehörigen Punkt $\mathbf{z}_j$ auf der Geraden. Seine Koordinaten sind zusätzliche zu schätzende Größen. Für eine vorgegebene Gerade kann dieser Punkt nur noch entlang der Geraden verschoben werden; pro Messpunkt bleibt daher eine frei wählbare Koordinate entlang der Geraden. Die Geradenparameter fassen wir zum Vektor $\mathbf{p} = (\alpha, d)^\mathsf{T}$ zusammen.

Die Kovarianzmatrizen der Messabweichungen $\mathbf{\Sigma}_j$ seien bekannt, positiv definit und unabhängig von den zu schätzenden Größen. Die verschiedenen Beobachtungen seien statistisch unabhängig. Das Beobachtungsmodell lautet

$$\mathbf{X}_j = \mathbf{z}_j + \mathbf{E}_j, \qquad \mathbf{E}_j \sim \mathcal{N}_2(\mathbf{0}, \mathbf{\Sigma}_j), \qquad \mathbf{n}(\alpha)^\mathsf{T}\mathbf{z}_j = d. \tag{4.47}$$

$\mathcal{N}_2$ bezeichnet eine zweidimensionale Normalverteilung. Die Diagonalelemente von $\mathbf{\Sigma}_j$ sind die Varianzen der beiden Koordinatenabweichungen; die übrigen Elemente beschreiben ihre Kovarianz. Die Punkte $\mathbf{z}_j$ sind in diesem Modell die Erwartungswerte der möglichen Beobachtungen $\mathbf{X}_j$. Die vorliegenden Messwerte $\mathbf{x}_j$ bleiben während der gesamten Anpassung unverändert.

**Likelihood und gemeinsame Anpassungsaufgabe.** Für die beobachteten Messpunkte lautet die Likelihood

$$l(\mathbf{p}, \mathbf{z}_1, \ldots, \mathbf{z}_J; \mathbf{x}_1, \ldots, \mathbf{x}_J) = C \exp\left[-\frac{1}{2} W(\mathbf{z}_1, \ldots, \mathbf{z}_J)\right], \tag{4.48}$$

$$W(\mathbf{z}_1, \ldots, \mathbf{z}_J) = \sum_{j=1}^{J} (\mathbf{x}_j - \mathbf{z}_j)^\mathsf{T} \mathbf{\Sigma}_j^{-1} (\mathbf{x}_j - \mathbf{z}_j), \tag{4.49}$$

$$C = \prod_{j=1}^{J} \frac{1}{2\pi\sqrt{\det \mathbf{\Sigma}_j}}.$$

Diese Likelihood wird nur für Modellpunkte betrachtet, die auf der jeweiligen Geraden liegen. Die Geradenparameter $\mathbf{p}$ gehen somit über die Bedingungen $\mathbf{n}(\alpha)^\mathsf{T}\mathbf{z}_j = d$ in die Anpassung ein. Der Strichpunkt in der Likelihood trennt die zu schätzenden Größen von den feststehenden Beobachtungsdaten.

Die Likelihood ist die gemeinsame Wahrscheinlichkeitsdichte, ausgewertet an den beobachteten Messpunkten und als Funktion der zu schätzenden Größen betrachtet. *Maximieren* bedeutet hier: Wir suchen Geradenparameter und zugehörige Modellpunkte, für die dieser Dichtewert möglichst groß ist.

Die Daten selbst werden dabei nicht verändert oder vergrößert.

Weil die Kovarianzmatrizen fest vorgegeben sind, ist auch der Vorfaktor $C$ konstant. Die Likelihood wird daher genau dann maximal, wenn die gewichtete Residuenquadratsumme $W$ minimal wird. Die gemeinsame Anpassungsaufgabe lautet damit

$$\min_{\substack{\alpha,d,\,\mathbf{z}_1,\ldots,\mathbf{z}_J \\ \mathbf{n}(\alpha)^\mathsf{T}\mathbf{z}_j=d \text{ für alle } j}} W(\mathbf{z}_1,\ldots,\mathbf{z}_J). \tag{4.50}$$

Zum Verständnis zerlegen wir diese Aufgabe in zwei Schritte: Zuerst bestimmen wir die zugehörigen Modellpunkte für eine vorgegebene Gerade; danach vergleichen wir verschiedene Geraden.

**Erster Schritt: Modellpunkte für ein festes $(\alpha, d)$-Paar.** Stellen wir uns eine bestimmte Gerade vor, deren Winkel $\alpha$ und Abstand $d$ festgehalten werden. Für jeden Messpunkt wird nun derjenige Punkt auf dieser Geraden gesucht, der den gewichteten quadratischen Abstand minimiert:

$$\mathbf{z}_j^*(\mathbf{p}) = \operatorname*{arg\,min}_{\mathbf{z}:\,\mathbf{n}(\alpha)^\mathsf{T}\mathbf{z}=d} (\mathbf{x}_j-\mathbf{z})^\mathsf{T}\boldsymbol{\Sigma}_j^{-1}(\mathbf{x}_j-\mathbf{z}). \tag{4.51}$$

arg min bezeichnet den Punkt, an dem der Ausdruck sein Minimum annimmt, nicht den Wert dieses Minimums. **Verändert wird dabei z, nicht der beobachtete Messpunkt $\mathbf{x}_j$.**

Der Stern kennzeichnet den bereits abstandsminimierenden Punkt auf der *jeweils vorgegebenen* Geraden. Er bezeichnet keinen beliebigen Zwischenstand eines numerischen Iterationsverfahrens. Die Anpassung der Geradenparameter ist damit aber noch nicht abgeschlossen. Bei einem anderen $(\alpha, d)$-Paar liegen die zugehörigen Punkte $\mathbf{z}_j^*(\mathbf{p})$ im Allgemeinen an anderen Stellen. Das Argument $\mathbf{p}$ macht diese Abhängigkeit sichtbar.

Der zugehörige Residuenvektor ist $\boldsymbol{\varepsilon}_j^*(\mathbf{p}) = \mathbf{x}_j - \mathbf{z}_j^*(\mathbf{p})$. Der skalare senkrechte Abstand $\varepsilon_j(\mathbf{p})$ aus Gl. (4.46) ist von diesem zweidimensionalen Vektor zu unterscheiden. Weil $\mathbf{z}_j^*$ auf der Geraden liegt, gilt

$$\mathbf{n}^\mathsf{T}\boldsymbol{\varepsilon}_j^* = \mathbf{n}^\mathsf{T}\mathbf{x}_j - d = \varepsilon_j.$$

Die Minimierung des gewichteten quadratischen Abstands unter dieser Bedingung liefert

$$\boldsymbol{\varepsilon}_j^* = \mathbf{x}_j - \mathbf{z}_j^* = \frac{\varepsilon_j \boldsymbol{\Sigma}_j \mathbf{n}}{\mathbf{n}^\mathsf{T}\boldsymbol{\Sigma}_j\mathbf{n}}, \qquad Q_j = \frac{\varepsilon_j^2}{\mathbf{n}^\mathsf{T}\boldsymbol{\Sigma}_j\mathbf{n}}. \tag{4.52}$$

Hier haben wir die Argumente $\mathbf{p}$ bzw. $\alpha$ zur Verkürzung weggelassen. $Q_j$ ist der kleinste erreichbare Kostenbeitrag des $j$-ten Messpunkts für die vorgegebene Gerade. Die zugehörigen Modellpunkte lassen sich unmittelbar berechnen:

$$\mathbf{z}_j^*(\mathbf{p}) = \mathbf{x}_j - \frac{\varepsilon_j(\mathbf{p})\boldsymbol{\Sigma}_j\mathbf{n}(\alpha)}{\mathbf{n}(\alpha)^\mathsf{T}\boldsymbol{\Sigma}_j\mathbf{n}(\alpha)}.$$

Für diesen ersten Schritt ist daher kein iteratives Suchverfahren nötig.

Bei unterschiedlichen Koordinatenvarianzen oder einer Korrelation zwischen den Koordinaten ist $\boldsymbol{\varepsilon}_j^*$ im Allgemeinen nicht parallel zu $\mathbf{n}$. Die gewichtete Projektion steht dann im ursprünglichen Koordinatensystem nicht senkrecht zur Geraden. Abbildung 4.2 zeigt den Unterschied.

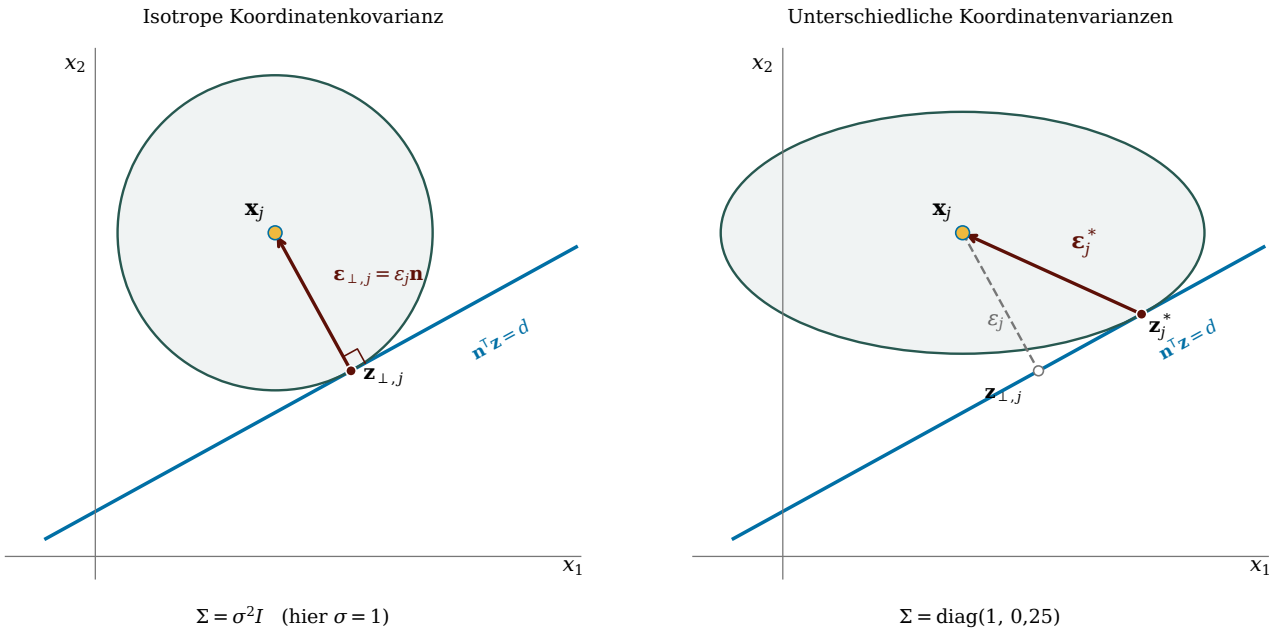



Abbildung 4.2: Euklidische und gewichtete Projektion eines Messpunkts auf dieselbe vorgegebene Gerade. Links: Bei isotroper Kovarianz der Messabweichungen $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$ gilt $\boldsymbol{\varepsilon}_\perp = \varepsilon \mathbf{n}$. Rechts: Bei unterschiedlichen Varianzen wird der Mahalanobis-Abstand minimiert; $\boldsymbol{\varepsilon}^*$ steht im Allgemeinen nicht senkrecht zur Geraden. Die Konturen erfüllen $(\mathbf{x}-\mathbf{z})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\mathbf{z}) = c$; $c$ ist ein festes Konturenniveau, keine Wahrscheinlichkeit. Die Konturen sind keine angegebenen Überdeckungsbereiche.

**Zweiter Schritt: Anpassung von Winkel und Abstand der Geraden.** Nun werden verschiedene Geraden miteinander verglichen. Für jedes $(\alpha, d)$-Paar verwenden wir die zuvor bestimmten zugehörigen Punkte $\mathbf{z}_j^*(\mathbf{p})$. Durch Einsetzen dieser Punkte in $W$ entsteht eine Kostenfunktion, die nur noch von den beiden Geradenparametern abhängt:

$$Q(\alpha, d) = \sum_{j=1}^{J} \big(\boldsymbol{\varepsilon}_j^*(\mathbf{p})\big)^\top \boldsymbol{\Sigma}_j^{-1} \boldsymbol{\varepsilon}_j^*(\mathbf{p}) = \sum_{j=1}^{J} \frac{\varepsilon_j(\alpha, d)^2}{\mathbf{n}(\alpha)^\top \boldsymbol{\Sigma}_j \mathbf{n}(\alpha)}. \tag{4.53}$$

Die endgültigen Schätzwerte ergeben sich durch Minimierung über Winkel und Abstand:

$$\widehat{\mathbf{p}} = \begin{pmatrix} \widehat{\alpha} \\ \widehat{d} \end{pmatrix} = \underset{\mathbf{p}=(\alpha,d)^\top}{\arg\min}\, Q(\alpha, d). \tag{4.54}$$

Erst nach dieser Anpassung bezeichnen wir die zugehörigen geschätzten Modellpunkte und Residuen mit einem Dach:

$$\widehat{\mathbf{z}}_j = \mathbf{z}_j^*(\widehat{\mathbf{p}}), \qquad \widehat{\boldsymbol{\varepsilon}}_j = \mathbf{x}_j - \widehat{\mathbf{z}}_j = \boldsymbol{\varepsilon}_j^*(\widehat{\mathbf{p}}). \tag{4.55}$$

Der Stern unterscheidet somit die Anpassung der Punkte für eine vorgegebene Gerade von den endgültigen Schätzwerten nach der Anpassung der Geraden. Die beiden Schritte beschreiben die mathematische Aufgabe. Ein numerisches Verfahren kann die Geradenparameter und die Punkte auch gemeinsam unter den Geradenbedingungen optimieren.

Sind die Messabweichungen in den beiden Koordinaten unkorreliert und gelten für alle Messpunkte

dieselben Varianzen $\sigma_1^2$ und $\sigma_2^2$, vereinfacht sich die Kostenfunktion zu

$$Q(\alpha, d) = \sum_{j=1}^{J} \frac{\varepsilon_j(\alpha, d)^2}{\sigma_1^2 \sin^2\alpha + \sigma_2^2 \cos^2\alpha}. \tag{4.56}$$

Für eine gemeinsame Kovarianz $\sigma_{12}$ kommt im Nenner der Term $-2\sigma_{12}\sin\alpha\cos\alpha$ hinzu. Man darf also nicht zuerst euklidisch projizieren und anschließend die Komponenten dieses Residuenvektors mit unterschiedlichen Varianzen gewichten. Bereits die Auswahl des Modellpunkts muss die Kovarianz berücksichtigen.

Bei einer gemeinsamen bekannten, positiv definiten Kovarianz kann man die Koordinaten so transformieren, dass die transformierten Messabweichungen unkorreliert sind und Einheitsvarianz besitzen. Die Geradenanpassung lässt sich dann durch eine Eigenwert- oder Singulärwertzerlegung lösen. Die trigonometrischen Funktionen in der Winkeldarstellung erzwingen somit nicht in jedem Fall eine allgemeine iterative nichtlineare Optimierung.

**Warum hier kein zusätzlicher Logarithmusterm entsteht.** Für jedes $(\alpha, d)$-Paar haben wir die Likelihood bezüglich der zugehörigen Modellpunkte maximiert. Das Einsetzen dieser Punkte in die ursprüngliche Likelihood heißt *Profilierung*; die entstehende Funktion heißt *Profil-Likelihood*:

$$l_{\text{prof}}(\mathbf{p}; \mathbf{x}_1, \ldots, \mathbf{x}_J) = C \exp\left[-\frac{1}{2} Q(\alpha, d)\right]. \tag{4.57}$$

Der Vorfaktor $C$ aus Gl. (4.48) bleibt dabei unverändert, weil alle $\mathbf{\Sigma}_j$ fest vorgegeben sind. Deshalb gilt

$$-2\ln l_{\text{prof}} = -2\ln C + Q(\alpha, d).$$

Der erste Summand ist konstant. Die Maximierung dieser Likelihood ist daher gleichbedeutend mit der Minimierung von $Q$.

Der Ausdruck $\mathbf{n}(\alpha)^{\mathsf{T}}\mathbf{\Sigma}_j\mathbf{n}(\alpha)$ im Nenner von $Q$ hängt zwar vom Winkel ab. Er entsteht jedoch durch das Einsetzen der für die jeweilige Gerade abstandsminimierenden Punkte in die ursprüngliche Quadratsumme. Er ist *kein neuer Normierungsfaktor* der Likelihood. Deshalb wird der Kostenfunktion kein zusätzlicher Logarithmus dieses Ausdrucks hinzugefügt.

## 4.8 Bayesische Auswertung: vom Vorwissen zur Parameterverteilung

Bislang wurden Verteilungen möglicher Beobachtungen (von direkten Messgrößen) und daraus berechneter Schätzwerte von Modellparamtern (von indirekten Messgrößen) betrachtet. Eine Likelihood ließ sich auswerten und maximieren, ohne den festen Parametern selbst Wahrscheinlichkeiten zuzuordnen. Nun ergänzen wir das Beobachtungsmodell um eine Beschreibung des Kenntnisstands über die zu schätzenden Modellparameter.

Im *bayesischen Ansatz* lässt sich die Unsicherheit über den Wert einer indirekten Messgröße, die durch einen Modellparameter beschrieben wird, durch eine *Wahrscheinlichkeitsverteilung* beschreiben. Ausgangspunkt ist die Frage: Welche Werte kommen nach unserem gegenwärtigen Kenntnisstand für den

gesuchten Parameter infrage, und wie plausibel sind sie? Dazu werden Wertebereichen Wahrscheinlichkeiten zugeordnet. Eine Wahrscheinlichkeit von beispielsweise 90 % für einen bestimmten Bereich drückt aus, wie stark die verfügbare Information unter den getroffenen Annahmen dafür spricht, dass der unbekannte Wert in diesem Bereich liegt.

Betrachten wir als Beispiel die indirekte Messgröße Widerstand $R$ eines Bauteils bei festgelegten Umgebungsbedingungen. Aus einer früheren Kalibrierung und unserem Wissen über die Stabilität des Bauteils erwarten wir einen Wert nahe 100 Ω. Dieses Vorwissen könnte durch eine Verteilung beschrieben werden, die dem Bereich von 99 Ω bis 101 Ω eine Wahrscheinlichkeit von 90 % zuordnet. Auf die Werte außerhalb dieses Bereichs entfallen dann zusammen die übrigen 10 %. Diese Zahlen dienen nur der Veranschaulichung; in einer konkreten Aufgabe muss die Verteilung aus der verfügbaren Information begründet werden. Die Angabe eines einzigen Bereichs und seiner Wahrscheinlichkeit legt die gesamte Verteilung noch nicht fest.

Für die hier betrachteten kontinuierlichen Parameter beschreiben wir solche Verteilungen durch eine *Dichtekurve*. Die Fläche unter der Kurve über einem Wertebereich gibt dessen Wahrscheinlichkeit an; die gesamte Fläche beträgt 1, entsprechend 100 %. Eine starke Konzentration der Fläche in der Nähe von 100 Ω würde ausdrücken, dass wir den Widerstand dort mit hoher Wahrscheinlichkeit vermuten. Eine stärker um denselben Wert gestreute Verteilung würde eine größere Unsicherheit über seinen Wert ausdrücken. Dabei kann der Widerstand selbst während der Messung konstant sein: Die Verteilung beschreibt hier unseren unvollständigen Kenntnisstand über diesen festen Wert.

Die Verteilung, die unseren Kenntnisstand **vor Einbeziehung der jetzt betrachteten Daten** beschreibt, heißt *Priorverteilung* oder kurz *Prior*. Das Wort *prior* bedeutet hier *vorhergehend*. „A priori“ bedeutet in diesem Zusammenhang somit nicht „vor jeder experimentellen Erfahrung“. Eine Priorverteilung kann gerade auf früheren Messungen beruhen. Beispielsweise kann die Parameterverteilung aus einer früheren bayesischen Auswertung als Prior für eine neue Auswertung dienen, sofern die damalige Information auf die aktuelle Messaufgabe übertragbar ist.

Weitere Grundlagen können physikalische Zusammenhänge oder begründete Angaben über mögliche Wertebereiche sein. Die Information legt nicht immer eine einzige Verteilung eindeutig fest. Die Wahl der Prior gehört deshalb zu den Annahmen der Auswertung und muss offengelegt und begründet werden. Auch eine sehr breite Verteilung ist eine solche Annahme; sie bedeutet nicht automatisch, dass keinerlei Vorwissen eingebracht wird. Eine Verteilung wird dabei nicht allein deshalb zur Prior, weil sie vor dem Experiment bekannt ist: Eine bekannte Verteilung der Streuung künftiger Beobachtungen gehört zunächst zum Beobachtungsmodell. Eine Prior beschreibt dagegen den Kenntnisstand über die Werte der zu schätzenden Modellparameter.

### 4.8.1 Aktualisierung durch die Bayes-Regel

Wir fassen alle zu schätzenden Modellparameter in $\boldsymbol{\theta}$ zusammen. Dieser Vektor kann beispielsweise die Modellparameter $\mathbf{p}$ und eine unbekannte Beobachtungsstreuung $\sigma$ enthalten. Sei $p_0(\boldsymbol{\theta})$ die Prior

vor Einbeziehung der aktuellen Daten $\mathbf{x}$. Die Bayes-Regel lautet für Dichten

$$p_1(\boldsymbol{\theta} \mid \mathbf{x}) = \frac{l(\boldsymbol{\theta}; \mathbf{x})\, p_0(\boldsymbol{\theta})}{\displaystyle\int_\Theta l(\boldsymbol{\theta}'; \mathbf{x})\, p_0(\boldsymbol{\theta}')\, \mathrm{d}\boldsymbol{\theta}'}. \tag{4.58}$$

Der Nenner integriert über alle zulässigen Parameterwerte $\boldsymbol{\theta}' \in \Theta$. Er ist bei gegebenen Daten eine Konstante und sorgt dafür, dass die resultierende Dichte die Gesamtwahrscheinlichkeit 1 besitzt. Wir setzen voraus, dass dieses Integral positiv und endlich ist. Die Verteilung $p_1$ heißt *Posteriorverteilung* oder kurz *Posterior*. Sie beschreibt den aktualisierten Kenntnisstand **nach** Einbeziehung der Daten.

Bei gegebenem Beobachtungsmodell verstärkt die Multiplikation mit der Likelihood diejenigen Parameterbereiche relativ zu anderen, die besser mit den neuen Daten vereinbar sind. Die Prior trägt die zuvor verfügbare Information bei. Erst ihre Verknüpfung und die Normierung liefern die hier verwendete Parameterdichte.

Aus der Posteriorverteilung lassen sich beispielsweise ein Erwartungswert als Schätzwert und eine Standardabweichung als Unsicherheitsmaß berechnen, sofern diese Größen existieren. Diese Standardabweichung beschreibt die verbleibende Unsicherheit über den Parameter bei gegebenen Daten. Allgemeiner bestimmt man zu einer vorgegebenen Wahrscheinlichkeit $1 - \alpha$ die Integrationsgrenzen der Posterior, um das Überdeckungsintervall zu erhalten. Dazu kommen wir dann etwas später.

Frequentistisch wird die Standardunsicherheit der geschätzten Modellparameter aus der Streuung der Parameterschätzwerte bestimmt, die das Beobachtungsmodell und das Schätzverfahren gemeinsam ergeben. Die genauen Integrale und ein Beispiel folgen in Abschnitt 4.9.

### 4.8.2 Frühere Messungen: gemeinsame Auswertung oder Aktualisierung

Auch frequentistische Verfahren können physikalisches Vorwissen und Ergebnisse früherer Messungen berücksichtigen. Physikalisches Vorwissen kann beispielsweise in die Modellgleichungen oder in Einschränkungen des zulässigen Parameterbereichs eingehen. Frühere und aktuelle Messergebnisse lassen sich gemeinsam auswerten, wenn ein statistisches Modell ihren Zusammenhang mit den gesuchten Parametern beschreibt. Dabei müssen auch mögliche Änderungen der Messgröße und Abhängigkeiten zwischen den Messungen berücksichtigt werden.

Wir betrachten zur Vereinfachung einen einzelnen Parameter $\theta$. Bezeichnen $\mathbf{x}^{(1)}$ frühere und $\mathbf{x}^{(2)}$ aktuelle Messdaten und sind beide Datensätze bei gegebenem $\theta$ unabhängig, so ist die gemeinsame Likelihood

$$l_{\text{gesamt}}(\theta; \mathbf{x}^{(1)}, \mathbf{x}^{(2)}) = l_1(\theta; \mathbf{x}^{(1)})\, l_2(\theta; \mathbf{x}^{(2)}).$$

Die einzelnen Likelihoods dürfen unterschiedliche Formen besitzen, beispielsweise aufgrund verschiedener Messverfahren oder unterschiedlich großer Streuungen. Bei abhängigen Datensätzen muss ihre gemeinsame Beobachtungsverteilung verwendet werden; das einfache Produkt der einzelnen Likelihoods ist dann im Allgemeinen nicht zulässig.

**Auch frequentistisch wird also das Produkt von Likelihoods verwendet.** Bei der Maximum-Likelihood-Methode wählt man als Schätzwert den Parameterwert, bei dem die gemeinsame Likelihood

am größten ist. Die Fläche unter der Likelihood über einem Parameterbereich wird dabei nicht als Wahrscheinlichkeit dafür interpretiert, dass der feste Parameterwert in diesem Bereich liegt.

Bayesisch können dieselben Datensätze gemeinsam nach Gl. (4.58) oder nacheinander ausgewertet werden. Dabei bezeichnet $p_0(\theta)$ jetzt den Kenntnisstand **vor beiden Datensätzen**:

$$p_1(\theta \mid \mathbf{x}^{(1)}) \propto l_1(\theta; \mathbf{x}^{(1)})\, p_0(\theta),$$
$$p_2(\theta \mid \mathbf{x}^{(1)}, \mathbf{x}^{(2)}) \propto l_2(\theta; \mathbf{x}^{(2)})\, p_1(\theta \mid \mathbf{x}^{(1)}).$$

Das Zeichen $\propto$ bedeutet „proportional zu“; der jeweils noch fehlende Faktor normiert die Dichte auf die Gesamtfläche 1. Die Indizes 0, 1 und 2 kennzeichnen die aufeinanderfolgenden Kenntnisstände. Die erste Posteriorverteilung $p_1$ übernimmt bei der zweiten Auswertung die Rolle der Prior. **Bereits in dieser Prior enthaltene Messdaten dürfen nicht nochmals als zusätzliche Daten in die Likelihood eingehen.** Bei abhängigen Datensätzen muss die Likelihood der aktuellen Daten zusätzlich die früheren Daten als Bedingung berücksichtigen.

### 4.8.3 Wann beide Ansätze dieselben Zahlen liefern

Wenn $p_0(\theta)$ im betrachteten Parameterbereich konstant ist, gilt

$$p_1(\theta \mid \mathbf{x}^{(1)}) \propto l_1(\theta; \mathbf{x}^{(1)}).$$

Dann hat die aus der ersten Auswertung gewonnene Prior für die zweite Auswertung dieselbe Form wie der frühere Likelihood-Beitrag. Auch $p_2$ ist dann proportional zur gemeinsamen Likelihood. Eine konstante Prior auf einem unbeschränkten Parameterbereich ist allerdings nicht zu einer Dichte normierbar. Sie kann als formaler Ansatz verwendet werden, wenn daraus eine normierbare Posteriorverteilung entsteht; sie ist nicht mit dem Verzicht auf Annahmen gleichzusetzen.

Unter geeigneten Voraussetzungen können beide Ansätze dieselben Schätzwerte, numerisch gleiche Standardunsicherheiten der geschätzten Modellparameter und dieselben Intervallgrenzen liefern. Die Standardunsicherheiten werden dabei frequentistisch aus der Streuung der Parameterschätzer und bayesisch aus der Posteriorverteilung bestimmt. Das ist jedoch keine allgemeine Eigenschaft. Schon eine andere Prior kann die Ergebnisse verändern. Auch aus proportionalen Kurven allein folgt keine allgemeine Übereinstimmung aller Schätz- und Intervallverfahren.

Ein einfaches Zahlenbeispiel verdeutlicht diese mögliche Übereinstimmung. Eine frühere Messung desselben konstanten Widerstands habe $m_0 = 100\,\Omega$ ergeben, eine aktuelle Messreihe den Mittelwert $\overline{x} = 102\,\Omega$. Das Beobachtungsmodell nimmt an, dass die möglichen Ergebnisse der früheren Messung und der aktuellen Messreihe unabhängig voneinander sind. Beide Ergebnisse werden als normalverteilt mit demselben Erwartungswert $R$, dem Wert des gesuchten Widerstands, und jeweils einer Standardabweichung von $1\,\Omega$ beschrieben. Frequentistisch werden die beiden Ergebnisse wegen ihrer gleichen Präzision gleich gewichtet:

$$\widehat{R} = \frac{m_0 + \overline{x}}{2} = 101\,\Omega.$$

Die Standardunsicherheit des zusammengefassten Ergebnisses berechnen wir durch Unsicherheitsfort-

pflanzung. Da die beiden Messergebnisse als unabhängig angenommen werden, ist die Varianz ihrer Summe gleich der Summe ihrer einzelnen Varianzen, hier also $(1\,\Omega)^2 + (1\,\Omega)^2$. Für den Mittelwert wird diese Summe durch 2 geteilt. Bei der Unsicherheitsfortpflanzung geht dieser Faktor quadratisch ein: Die Varianz des Mittelwerts ist daher die Varianz der Summe geteilt durch $2^2 = 4$. Die Wurzel daraus ergibt die Standardunsicherheit des gemeinsam geschätzten Widerstands:

$$u(\widehat{R}) = \sqrt{\frac{(1\,\Omega)^2 + (1\,\Omega)^2}{4}} = \frac{1}{\sqrt{2}}\,\Omega \approx 0{,}707\,\Omega.$$

Bayesisch kann die Information aus der früheren Messung durch eine Normalverteilung für den Widerstand $R$ mit Erwartungswert $100\,\Omega$ und Standardabweichung $1\,\Omega$ beschrieben werden. Diese Verteilung dient als Priorverteilung für die Auswertung der aktuellen Messreihe.

Sie ergibt sich beispielsweise, wenn man die frühere Messung mit normalverteilten zufälligen Abweichungen und bekannter Standardabweichung $1\,\Omega$ auswertet und davor eine formal konstante Priordichte auf der gesamten reellen Achse ansetzt. Eine solche konstante Funktion ist selbst keine normierte Wahrscheinlichkeitsdichte, weil ihr Integral über die reelle Achse unendlich ist. Nach Einbeziehung der früheren Messung lässt sich das Produkt aus dieser Funktion und der Likelihood jedoch normieren; es ergibt die genannte Normalverteilung.

Die Verknüpfung dieser Priorverteilung mit der Likelihood der aktuellen Messreihe liefert eine ebenfalls normalverteilte Posteriorverteilung mit Erwartungswert $101\,\Omega$ und Standardabweichung $1/\sqrt{2}\,\Omega \approx 0{,}707\,\Omega$.

Die hier verwendeten Normalverteilungen für $R$ berücksichtigen die physikalische Einschränkung $R > 0$ nicht ausdrücklich. Bei den gewählten Zahlen ist die Wahrscheinlichkeit, die sie negativen Widerstandswerten zuordnen, jedoch vernachlässigbar klein.

Beide Auswertungen liefern somit denselben geschätzten Widerstand und numerisch dieselbe Standardunsicherheit. Frequentistisch beschreibt diese Standardunsicherheit die Streuung der möglichen Schätzwerte unter dem Beobachtungsmodell. Bayesisch beschreibt sie die Breite der Posteriorverteilung und damit die verbleibende Unsicherheit über den Widerstand bei den vorliegenden Daten.

Auch bei identischen Zahlen bleiben die Aussagen verschieden: Die frequentistisch bestimmte Standardunsicherheit der geschätzten Modellparameter beschreibt die Streuung möglicher Schätzwerte unter dem Beobachtungsmodell. Die bayesisch bestimmte Standardunsicherheit wird aus der Streuung der Posteriorverteilung der indirekten Messgröße beziehungsweise des Modellparameters bei gegebenen Daten ermittelt. Entsprechend sind Konfidenz- und Kredibilitätsintervalle zu unterscheiden. Dies wird im folgenden Lehrbeispiel an den tatsächlich berechneten Intervallen erläutert.

## 4.9 Vollständiges Lehrbeispiel: Widerstand und unbekannte Streuung

Im vorigen Beispiel waren die Standardunsicherheiten der beiden Ausgangsschätzwerte bekannt; beide Ansätze lieferten dieselben Zahlen. Nun betrachten wir einen anderen, eigens festgelegten Lehrdatensatz. Neben dem Widerstand $\mu$ ist hier auch die Standardabweichung $\sigma$ der Einzelbeobachtungen

unbekannt. Das Beispiel führt von den Daten über die gemeinsame Posteriorverteilung bis zur Ergebnisangabe und zum Vergleich der Intervalle.

### 4.9.1 Daten, Beobachtungsmodell und Priorverteilungen

Die sieben beobachteten Widerstandswerte lauten

$$\mathbf{x} = (32, 38, 41, 45, 48, 53, 58)\,\Omega. \tag{4.59}$$

Wir verwenden das Normalmodell aus Gl. (4.22). Die Likelihood ist der Spezialfall von Gl. (4.18) mit $f_j(\mathbf{p}) = \mu$:

$$l(\mu, \sigma; \mathbf{x}) = \frac{1}{(\sqrt{2\pi}\sigma)^J} \exp\left[-\frac{1}{2\sigma^2}\sum_{j=1}^{J}(x_j - \mu)^2\right], \qquad J = 7, \quad \sigma > 0. \tag{4.60}$$

Die Prior-Dichte für $\mu$ sei eine Normaldichte mit $y_0 = 44\,\Omega$ und $u_0 = 5\,\Omega$:

$$p_0(\mu) = \frac{1}{\sqrt{2\pi}\,u_0} \exp\left[-\frac{(\mu - y_0)^2}{2u_0^2}\right]. \tag{4.61}$$

Für $\sigma$ setzen wir unabhängig davon eine Gleichverteilung an:

$$p_0(\sigma) = \begin{cases} \dfrac{1}{18\,\Omega}, & 2\,\Omega \le \sigma \le 20\,\Omega, \\ 0, & \text{sonst.} \end{cases} \tag{4.62}$$

Gleich lange Teilintervalle innerhalb dieser Grenzen haben damit dieselbe Priorwahrscheinlichkeit. Die Grenzen und die Unabhängigkeit sind *für dieses Lehrbeispiel gesetzte Annahmen*. In einer realen Auswertung wären sie aus vorab verfügbarer Information zu begründen; sie werden hier nicht aus den sieben neuen Beobachtungen geschätzt. Die Gleichverteilung ist keine allgemeine Beschreibung fehlenden Wissens. Die Normalprior für den positiven Widerstand ist hier eine Näherung, deren Wahrscheinlichkeit für negative Werte vernachlässigbar klein ist.

Aus den Daten erhalten wir $\overline{x} = 45{,}000\,\Omega$ und $s \approx 8{,}907\,\Omega$.

### 4.9.2 Gemeinsame Posteriorverteilung

Aufgrund der angenommenen Unabhängigkeit in der Prior gilt $p_0(\mu, \sigma) = p_0(\mu)p_0(\sigma)$. Die Bayes-Regel ergibt

$$p_1(\mu, \sigma \mid \mathbf{x}) = C\, l(\mu, \sigma; \mathbf{x})\, p_0(\mu)p_0(\sigma), \tag{4.63}$$

wobei die Normierungskonstante durch

$$C^{-1} = \int_{-\infty}^{\infty}\int_{0}^{\infty} l(\mu', \sigma'; \mathbf{x})\, p_0(\mu')p_0(\sigma')\,\mathrm{d}\sigma'\,\mathrm{d}\mu'$$

bestimmt wird. Außerhalb des vorgegebenen Bereichs für $\sigma$ verschwindet der Integrand. Der Index 1 bezeichnet hier die Aktualisierung durch diesen einen Lehrdatensatz.

Abb. 4.3 zeigt sie als Funktion von $\mu$ und $\sigma$. Ihre Farbe stellt eine *Dichte* dar; eine Wahrscheinlichkeit entsteht erst durch Integration über einen Bereich der Parameterfläche. Die Unabhängigkeit in der Priorverteilung muss in der Posteriorverteilung nicht erhalten bleiben.

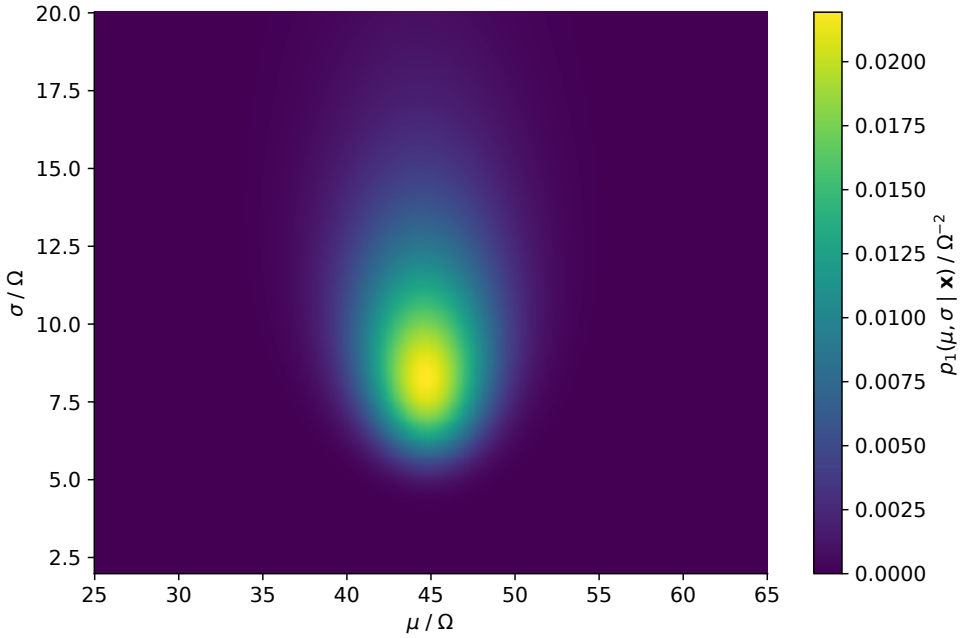



Abbildung 4.3: Gemeinsame Posterior-Dichte für den Lehrdatensatz aus Gl. (4.59) und die angegebenen Priorverteilungen. $\mu$ ist der gesuchte Erwartungswert, $\sigma$ die unbekannte Standardabweichung der Beobachtungen. Die Dichte hat die Einheit $\Omega^{-2}$.

### 4.9.3 Randverteilung, Schätzwert und Standardunsicherheit

Uns interessiert vor allem der Widerstand $\mu$. Die unbekannte Beobachtungsstreuung $\sigma$ darf dabei nicht einfach weggelassen werden. Für jeden Wert von $\mu$ integrieren wir die gemeinsame Dichte über alle möglichen Werte von $\sigma$:

$$p_1(\mu \mid \mathbf{x}) = \int_0^\infty p_1(\mu, \sigma' \mid \mathbf{x})\, \mathrm{d}\sigma'. \tag{4.64}$$

Dieses Vorgehen heißt *Marginalisierung*; das Ergebnis heißt *Randdichte* oder *Marginaldichte* von $\mu$. Die Unsicherheit über $\sigma$ wird dadurch berücksichtigt. Das Einsetzen nur eines Schätzwerts für $\sigma$ ist im Allgemeinen nicht gleichwertig. Die Randdichte ist in Abb. 4.4 links dargestellt.

Als Schätzwert und Standardunsicherheit verwenden wir den Posteriorerwartungswert $y_1$ und die Posteriorstandardabweichung $u_1$:

$$y_1 = \int_{-\infty}^\infty \mu'\, p_1(\mu' \mid \mathbf{x})\, \mathrm{d}\mu', \tag{4.65}$$

$$u_1^2 = \int_{-\infty}^\infty (\mu' - y_1)^2 p_1(\mu' \mid \mathbf{x})\, \mathrm{d}\mu'. \tag{4.66}$$

Der Strich kennzeichnet jeweils die laufende Integrationsvariable.

### 4.9.4 Kredibilitätsintervall und Vergleich mit dem Konfidenzintervall

Ein *Kredibilitätsintervall*, auch *Glaubwürdigkeitsintervall* genannt, mit Wahrscheinlichkeit $1-\alpha$ erfüllt

$$\int_{\mu_{\min}}^{\mu_{\max}} p_1(\mu' \mid \mathbf{x})\,\mathrm{d}\mu' = 1-\alpha.$$

Diese Bedingung allein legt die Grenzen noch nicht eindeutig fest. Wir wählen hier ein zentrales Intervall, bei dem unterhalb und oberhalb jeweils die Wahrscheinlichkeit $\alpha/2$ verbleibt. Die zugehörige kumulative Verteilungsfunktion ist

$$P_1(m) = \int_{-\infty}^{m} p_1(\mu' \mid \mathbf{x})\,\mathrm{d}\mu'.$$

$m$ bezeichnet hier einen möglichen Grenzwert für den Parameter. Die Kleinschreibung $p_1$ bezeichnet die Dichte, die Großschreibung $P_1$ die aufintegrierte, d.h. kumulierte, Wahrscheinlichkeit bis zu diesem Grenzwert. Für die hier stetige, streng monoton steigende Verteilungsfunktion erhalten wir

$$\mu_{\min} = P_1^{-1}(\alpha/2), \qquad \mu_{\max} = P_1^{-1}(1-\alpha/2).$$

$P_1^{-1}$ ist die Umkehrfunktion, nicht der Kehrwert: Sie ordnet einer Wahrscheinlichkeit den zugehörigen Quantilwert zu und wird deshalb auch *Quantilfunktion* genannt. Für 95 % sind die Wahrscheinlichkeiten 0.025 und 0.975 einzusetzen. Die numerische Integration liefert

$$y_1 \approx 44.626\,\Omega, \qquad u_1 \approx 3.059\,\Omega, \qquad [\mu_{\min}, \mu_{\max}] \approx [38.489,\ 50.642]\,\Omega. \tag{4.67}$$

Das Intervall enthält 95 % der Posteriorwahrscheinlichkeit. Die Verteilungsfunktion rechts in Abb. 4.4 zeigt, wie die beiden Grenzen aus den Wahrscheinlichkeiten 0.025 und 0.975 gewonnen werden.

Zum Vergleich ergibt Gl. (4.27) ohne die genannten Priorannahmen das frequentistische 95 %-Konfidenzintervall

$$\overline{x} \pm t_{0.975,6}\frac{s}{\sqrt{7}} \approx [36.762,\ 53.238]\,\Omega. \tag{4.68}$$

Die unterschiedlich breiten Intervalle beruhen auf unterschiedlichen Informationsgrundlagen: Nur die bayesische Rechnung verwendet hier zusätzlich die festgelegten Priorverteilungen. Das schmalere Intervall belegt deshalb keine allgemeine Überlegenheit des Verfahrens.

Auch die Wahrscheinlichkeitsaussagen unterscheiden sich: Das Konfidenzniveau beschreibt die Überdeckung durch das wiederholt angewandte Verfahren aus Abschnitt 4.5.1. Das Kredibilitätsintervall enthält dagegen 95 % der posterioren Wahrscheinlichkeit bei den vorliegenden Daten und den getroffenen Modell- und Priorannahmen. Es muss nicht für jeden festen Parameterwert zugleich eine frequentistische Überdeckungswahrscheinlichkeit von 95 % besitzen. Die Breite eines solchen Intervalls ist außerdem nicht mit der Standardunsicherheit $u_1$ gleichzusetzen.

Die rote Kurve ist ausdrücklich nur eine Darstellungshilfe für den Vergleich der Intervallgrenzen. Mit $a = s/\sqrt{J}$ ist sie definiert als

$$g_t(m) = \frac{1}{a} p_{t,J-1}\left(\frac{m-\overline{x}}{a}\right), \tag{4.69}$$

wobei $p_{t,J-1}$ die Dichte der Student-$t$-Verteilung mit $J-1$ Freiheitsgraden ist. Diese Verteilung be-

schreibt unter den angenommenen Beobachtungsbedingungen die Zufallsgröße

$$T = \frac{\overline{X} - \mu}{S/\sqrt{J}}$$

aus Gl. (4.25).

Für die rote Kurve wird diese Dichte entlang der horizontalen Achse mit dem Faktor $a = s/\sqrt{J}$ skaliert und um den beobachteten Mittelwert $\overline{x}$ verschoben. Der Vorfaktor $1/a$ stellt sicher, dass die Fläche unter der Kurve weiterhin 1 beträgt. Die Quantile zu den Wahrscheinlichkeiten 0.025 und 0.975 liegen dann genau an den Grenzen des 95 %-Konfidenzintervalls. Diese Übereinstimmung dient dem grafischen Vergleich; sie ordnet dem festen Parameter $\mu$ im frequentistischen Ansatz keine Wahrscheinlichkeitsverteilung zu.

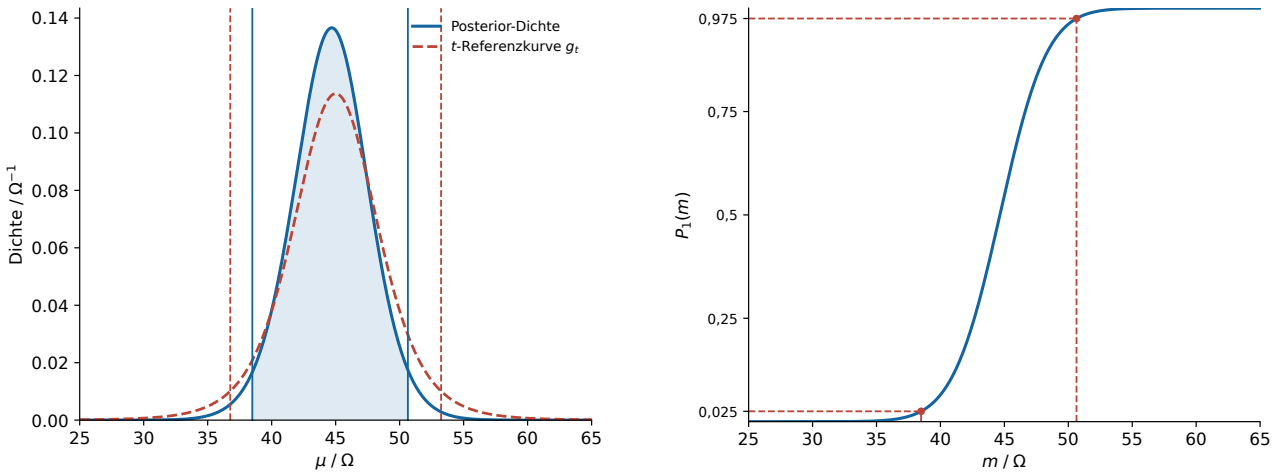



Abbildung 4.4: Links: Marginale Posterior-Dichte von $\mu$ mit ihrem zentralen 95 %-Kredibilitätsintervall (blau). Die rote Referenzkurve stellt zum Vergleich die verschobene und skalierte $t$-Dichte $g_t$ dar; die roten Grenzen sind die des frequentistischen Konfidenzintervalls. Rechts: Posterior-Verteilungsfunktion mit den Quantilen zu 0.025 und 0.975.

## 4.10 Einordnung, Nutzen und Grenzen

Ein wesentlicher Vorteil des bayesischen Ansatzes ist die gemeinsame Posteriorverteilung für die zu schätzenden Modellparameter. Sie erlaubt es, bei den vorliegenden Daten und den getroffenen Modell- und Priorannahmen Wahrscheinlichkeiten für Parameterbereiche anzugeben. Bei mehreren Parametern beschreibt sie auch deren Abhängigkeiten. Dabei können asymmetrische Verteilungen oder mehrere getrennte Bereiche hoher Dichte dargestellt werden. Aus der gemeinsamen Posteriorverteilung lassen sich außerdem Verteilungen für abgeleitete Messgrößen berechnen.

Begründetes Vorwissen kann insbesondere dann hilfreich sein, wenn nur wenige Messdaten vorliegen. Es kann auch helfen, wenn sich deutlich unterschiedliche Modellparameterwerte ähnlich gut mit den Messdaten vereinbaren lassen. Die betreffenden Parameterwerte lassen sich dann allein aus diesen Daten nur mit großer Unsicherheit schätzen; sie sind durch die Daten nur schwach bestimmt.

Eine geeignete Priorverteilung kann zusätzliche Information darüber einbringen, welche dieser Werte

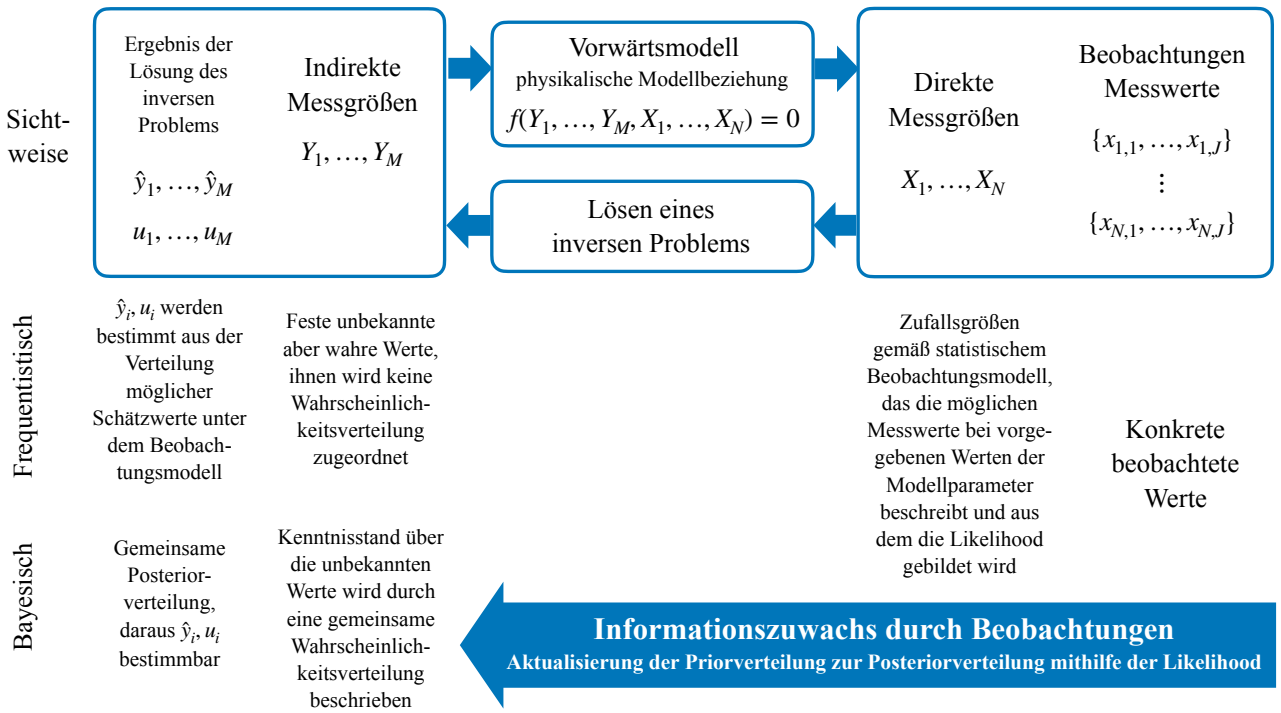



Abbildung 4.5: Frequentistische und bayesische Sichtweise bei der Bestimmung indirekter Messgrößen aus beobachteten Messwerten: statistische Beschreibung der beteiligten Größen und Interpretation der zugehörigen Unsicherheiten.

nach dem bisherigen Kenntnisstand plausibel sind. Wenn die Daten selbst wenig Information über einen Parameter liefern, kann die Wahl der Priorverteilung das Ergebnis entsprechend stark beeinflussen.

Bayesische Verfahren sind deshalb nicht grundsätzlich genauer als frequentistische. Eine unzutreffende oder zu enge Priorverteilung kann zu einer zu klein ausgewiesenen Unsicherheit führen. Die Berechnung komplexer Posteriorverteilungen kann zudem einen erheblichen Rechenaufwand erfordern.

Frequentistische Verfahren können ebenfalls Vorwissen berücksichtigen, komplexe Unsicherheiten untersuchen und Unsicherheiten auf abgeleitete Größen übertragen. Ihre Beurteilung richtet sich dabei nach den Eigenschaften der Verfahren unter dem jeweiligen Beobachtungsmodell, beispielsweise nach der Streuung der möglichen Schätzwerte oder der Überdeckungswahrscheinlichkeit eines Intervallschätzverfahrens. Gedachte Wiederholungen veranschaulichen diese Eigenschaften; sie sind kein zusätzlicher Schritt der Optimierung oder Unsicherheitsberechnung.

Die Unterscheidung lautet somit nicht „Optimierung oder Verteilung“: Beide Ansätze können Optimierungsverfahren verwenden, und beide benötigen ein Wahrscheinlichkeitsmodell der Beobachtungen. Die Likelihood und ihre Maximierung sind für sich genommen nicht auf die frequentistische Sichtweise beschränkt. **Frequentistisch werden Wahrscheinlichkeitsaussagen über mögliche Beobachtungen und die daraus berechneten Schätzer getroffen. Bayesisch wird zusätzlich eine Verteilung für die Werte der zu schätzenden Modellparameter bei gegebener Information verwendet und aktualisiert.** Abbildung 4.5 stellt die frequentistische und bayesische Sichtweise bei der Bestimmung indirekter Messgrößen aus beobachteten Messwerten gegenüber.

Für eine metrologische Ergebnisangabe müssen zusätzlich die Messgröße, die Bedingungen und die berücksichtigten Unsicherheitsbeiträge klar sein. Eine Auswertung der Wiederholstreuung allein erfasst

nicht automatisch alle relevanten Beiträge. Die frequentistische Intervallschätzung und die Verwendung der $t$- und $\chi^2$-Verteilung werden in den folgenden Vorlesungen vertieft und anhand weiterer Beispiele geübt; sie sind klausurrelevant.

# Kapitel 5

# Wahrscheinlichkeiten und Hypothesentests

## 5.1 Konzept der statistischen Erwartung

Das *Signifikanzniveau* $\alpha$ und das dazugehörige *Vertrauensniveau* $1-\alpha$ spielen eine zentrale Rolle bei der Bewertung von Messergebnissen. Als wir in Kapitel bzw. Vorlesung 4 die Konzepte der statistischen Auswertung behandelt hatten, haben wir diese beiden Begriffe gemeinsam mit dem des *Vertrauensintervalls* (oder Konfidenzintervall bzw. des *Glaubwürdigkeitsintervalls* (oder Kredibilitätsintervall, engl. *credible interval*) eingeführt. Diese beiden Intervallarten dürfen jedoch nicht gleichgesetzt werden: Ein frequentistisches Vertrauensintervall ist ein Zufallsintervall, dessen Überdeckungswahrscheinlichkeit für den unbekannten Parameter bei wiederholter Anwendung $1-\alpha$ beträgt. Ein bayessches Glaubwürdigkeitsintervall enthält den Parameter dagegen, bedingt auf die Daten und das Modell, mit posteriorer Wahrscheinlichkeit $1-\alpha$. Die Aussage bezieht sich daher nicht allgemein auf den Anteil der beobachteten Werte, der im Intervall liegt.

Die Idee hinter dem Begriff des *Vertrauensintervalls* oder des *Glaubwürdigkeitsintervalls* ist, dass beim Bestimmen einer physikalischen Größe $X$ eine Vorstellung (eine Erwartung) darüber existiert, wie die gemessenen oder beobachteten Werte verteilt sind. Das schließt die Erwartung von Position und Breite des Bereichs, in dem die Werte liegen sollten, ein. Diese Erwartung wird quantifiziert mit einer Angabe über die Wahrscheinlichkeit, dass die zu messende Größe diesen oder jenen Wert annimmt, eher noch in welchem Bereich (Intervall) der Wert zu erwarten ist. Wir *vertrauen* also darauf, dass wir einen Wert messen, der innerhalb eines gewissen Intervalls liegen müsste, oder sagen, dass es plausibel oder *glaubwürdig* (engl. *credible*) ist, dass die Beobachtungen in dem Intervall liegen. Statt zu sagen, dass wir *eine Vorstellung haben*, können wir auch sagen, dass wir *eine Hypothese aufstellen*.

Die Normalverteilung (Gaußverteilung) ist ein wichtiges Modell für kontinuierliche Zufallsgrößen. Sie eignet sich insbesondere dann als Näherung, wenn sich eine beobachtete Größe aus vielen annähernd unabhängigen kleinen zufälligen Einflüssen zusammensetzt, die durch Zufallsgrößen modelliert werden. Dies können beispielsweise verschiedene Stör- oder Fehlerquellen sein.

Nicht jeder Zufallsprozess ist normalverteilt: Zerfallsereignisse werden häufig durch Poissonverteilungen beschrieben, während Wartezeiten durch Exponentialverteilungen modelliert werden können. Unter geeigneten Voraussetzungen können auch Diffusionsprozesse normalverteilte Größen liefern. Die Wahrscheinlichkeitsdichteverteilung der Normalverteilung lautet

$$p(X) \;=\; \frac{1}{\sqrt{2\pi}\,\sigma}\, e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}. \tag{5.1}$$

Je nach Art eines Zufallsprozesses folgt die entsprechende Zufallsgröße aber auch einer ganz anderen Art von Verteilungsfunktion. Ist die Zufallsgröße beispielsweise die Anzahl der guten Bauteile bei der Gut-/Schlecht-Prüfung in der Qualitätssicherung, so ist die Binomialverteilung möglicherweise die Verteilungsfunktion, mit der die Wahrscheinlichkeit hierfür zu beschreiben ist. Ein anderes Beispiel ist die Anzahl der in einem Zeitintervall von einer Millisekunde mit Zählrohr detektierter Gammaquanten, bei dem die Wahrscheinlichkeitsverteilung für die Anzahl Gammaquanten mit einer Poissonverteilung beschrieben werden kann. Wird das Zeitintervall vergrößert oder werden viele derartige Messungen durchgeführt und dann über mehrere Zeitintervalle integriert, so dass die Anzahl der Gammaquanten entsprechend vergrößert wird, nähert sich die Poissonverteilung der Gaußverteilung an.

Je nach Prozess bedeuten viele Messkampagnen oder viele Stichprobenentnahmen, deren Ergebnisse anschließend addiert werden oder höhere Integrationszeiten die Summation vieler unabhängiger, identisch verteilter Zufallsgrößen. Eine zentrierte und durch ihre Standardabweichung normierte Summe vieler unabhängiger, identisch verteilter Zufallsgrößen mit endlicher, positiver Varianz ist approximativ standardnormalverteilt.

In der Wahrscheinlichkeitstheorie wird diese Tatsache exakt formuliert und ist der *zentrale Grenzwertsatz* (engl. *central limit theorem*) CLT. In einfacheren Worten können wir sagen:

> Die zentrierte und normierte Summe einer großen Anzahl unabhängiger Zufallsgrößen folgt unter geeigneten Voraussetzungen asymptotisch der Standardnormalverteilung.

Bei endlicher und positiver Varianz der Zufallsgrößen ist ihre Summe annähernd normalverteilt, was die Sonderstellung der Normalverteilung erklärt.

Betrachten wir eine Stichprobe als Folge von Zufallsgrößen und sind die Elemente der betrachteten Stichprobe Zufallsgrößen, die *unabhängig und identisch verteilt* (Abkürzung: u.i.v.) sind, so ist auch ihre Summe eine Zufallsgröße, die für genügend großen Stichprobenumfang annähernd normalverteilt ist; exakt normalverteilt ist sie im Allgemeinen nicht. In der englischsprachigen Literatur ist *unabhängig und identisch verteilt* unter dem Begriff *independent and identically distributed*, kurz i.i.d., zu finden.

Liegt nun eine Einzelbeobachtung innerhalb der flachen Ausläufer (*tails*) der Wahrscheinlichkeitsdichteverteilung, also außerhalb des Vertrauensintervalls, so spricht man dann davon, dass der Wert (die Einzelbeobachtung) signifikant von dem abweicht, was unter der *Nullhypothese* zu erwarten wäre. Eine solche Beobachtung ist jedoch nicht automatisch ein Beleg für ein Problem. *Hypothesentests* quantifizieren vielmehr, wie ungewöhnlich die Beobachtung unter einer *Nullhypothese* ist. Da die Normalverteilung lange Ausläufer hat, gibt es eine kleine Wahrscheinlichkeit $\alpha$ dafür, dass es weiter abseits liegende Werte gibt. Deshalb gilt es zu untersuchen, ob solch ein Wert in der Tat im Rahmen der Normalverteilung weiter weg liegt oder aber ob er auf Basis eines anderen Effektes gewonnen wurde, ob er - statistisch formuliert - zu einer anderen Grundgesamtheit gehören könnte.

Die *Kolmogorow-Smirnow-* und *Lilliefors-Tests* dienen der Prüfung, ob aus Beobachtungen empirisch ermittelte Verteilungen zu einer für die statistische Analyse der Beobachtungen zugrundegelegten (erwarteten) Wahrscheinlichkeitsdichtefunktion passen, oder zu einer empirisch ermittelten Verteilung einer anderen Stichprobe.

## 5.2 Kolmogorow-Smirnow- und Lilliefors-Tests

Das in Abb. 5.1 dargestellte Beispiel zeigt dieselben Diagramme und Daten, die wir in Abschnitt 3.8 bereits zur Veranschaulichung robuster Schätzverfahren behandelt hatten. Den robusten Schätzverfahren liegt die im folgenden erläuterte statistische Betrachtung zugrunde: Es liegt eine Annahme (Hypothese) darüber vor, welcher Gestalt die Wahrscheinlichkeitsverteilung der Beobachtungen ist und ob eine Reihe von Beobachtungen zu einer gemeinsamen Verteilung gehören oder zu unterschiedlichen Verteilungen. Technisch gesehen stellen sich die Fragen, die statistisch formuliert lauten „ge-

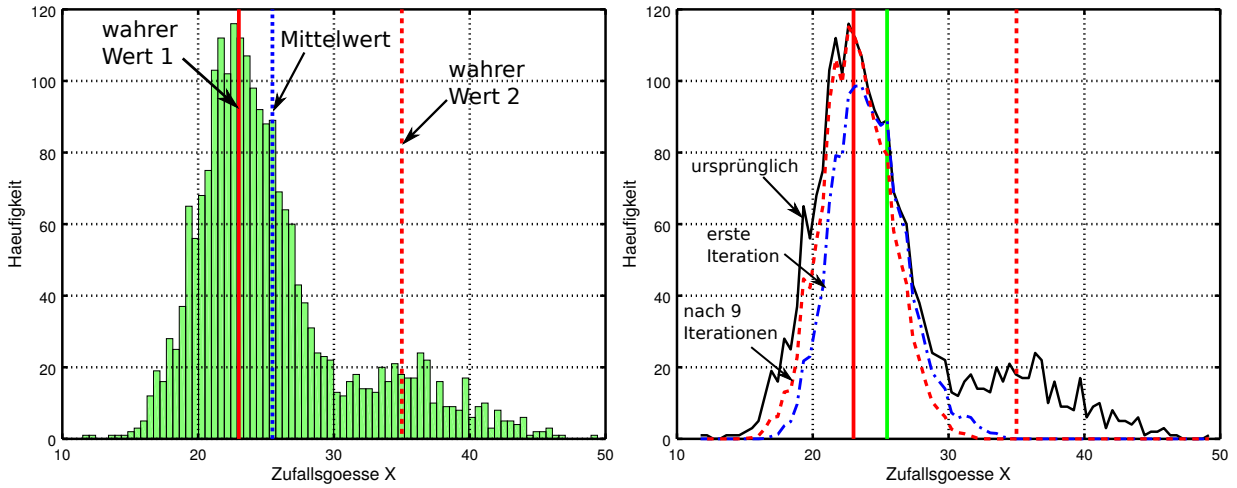



Abbildung 5.1: Beispiel für nicht erwartungsgemäße Beobachtungen (*rechts*) und Umgewichten um die Verteilungform der Normalverteilung anzupassen *links*

hören Beobachtungen zu einer Verteilung“ oder „gehören Beobachtungen zu mehreren verschiedenen Verteilungen“, als

- „stammen die Messwerte aus einem Prozess“ oder „aus unterschiedlichen Prozessen“,
- „werden alle Messwerte von demselben Effekt beeinflusst “ oder „gibt es für verschiedene Gruppen aus der Messreihe unterschiedliche beeinflussende Effekte“.

Die Annahmen bzw. Hypothesen bezüglich der Verteilungen zur Wahrscheinlichkeit von Beobachtungswerten werden geprüft. Diese Art der Prüfung wird *Hypothesentest* genannt. Es gibt unterschiedliche Typen von Hypothesentests, einer davon ist der Test auf die Wahrscheinlichkeitsverteilung, der *Kolmogorow-Smirnow-Test* bei bekannten Parametern der Verteilung und der *Lilliefors-Test*, wenn die Parameter der Verteilung aus der Stichprobe geschätzt werden. Diese Tests prüfen die Übereinstimmung einer empirischen Verteilung aus den Stichprobenwerten selbst mit einer vorgegebenen stetigen Verteilung (*Einstichproben-KS-Test*). Ferner gibt es Tests zum Vergleich zweier empirischer Verteilungen, der *Zweistichproben-KS-Test*.

Der Test zum Vergleich mit einer vorgegebenen stetigen Verteilung $p(X)$ verwendet die kumulierten Wahrscheinlichkeitsfunktionen

$$P(X) \;=\; \int_{-\infty}^{X} p(X')\,\mathrm{d}X'. \tag{5.2}$$

Das hat den Vorteil, dass die Verteilung der empirischen Häufigkeiten ohne Histogrammierung, d.h. ohne Einteilung in Klassen, erfolgen kann.

Wir wollen damit prüfen, ob die Beobachtungen des in Abschnitt 3.8 zur robusten Schätzung betrachteten Beispiels der Annahme folgt, zu der Grundgesamtheit *genau einer* Zufallsgröße $X_1$ zu gehören. Ferner nehmen wir an, dass ihre Ausprägungen (Beobachtungswerte) unabhängig und identisch der Normalverteilung folgen.

Die Nullhypothese lautet:

Die Beobachtungen zu $X_1$ gehören zu einer normalverteilten Grundgesamtheit.

Wir prüfen, ob die Beobachtungen $X_{1,1}, \ldots, X_{1,J}$ mit einer vollständig spezifizierten Normalverteilung vereinbar sind:

Für eine vollständig spezifizierte Normalverteilung mit bekanntem Erwartungswert $\mu_0$ und bekannter Standardabweichung $\sigma_0$ ist die zu vergleichende Verteilungsfunktion

$$F_0(X) \;=\; \frac{1}{\sqrt{2\pi}\sigma_0} \int\limits_{-\infty}^{X} e^{-\frac{1}{2}\left(\frac{X'-\mu_0}{\sigma_0}\right)^2} \,\mathrm{d}X'. \tag{5.3}$$

Wenn der Erwartungswert und die Standardabweichung aus der zu prüfenden Stichprobe geschätzt werden, d.h. wenn der empirische Mittelwert $y = J^{-1}\sum_{j=1}^{J} X_{1,j}$ (Stichprobenmittelwert) und die empirische Varianz $s^2 = (J-1)^{-1}\sum_{j=1}^{J}(X_{1,j}-y)^2$ (Stichprobenvarianz) als Parameter der Verteilung eingesetzt werden, dann verwendet man beispielsweise den Lilliefors-Test, einen parametrischen Bootstrap oder einen dafür angepassten Normalitätstest wie Anderson-Darling oder Shapiro-Wilk.

Hierfür ist die zu vergleichende Verteilungsfunktion

$$F_0(X) \;=\; \frac{1}{\sqrt{2\pi}s} \int\limits_{-\infty}^{X} e^{-\frac{1}{2}\left(\frac{X'-y}{s}\right)^2} \,\mathrm{d}X'. \tag{5.4}$$

Beim Lilliefors-Test wird somit eine Normalverteilung mit dem Stichprobenmittelwert und der Stichprobenstandardabweichung mit der empirischen Verteilung aus der Stichprobe verglichen.

Der Unterschied zwischen dem Lillierfors-Test, dem Zweistichproben-KS-Test und dem Einstichproben-KS-Test liegt in den verschiedenen Grenzwerten für die Entscheidung.

Die kumulierte Gaußverteilung entspricht im wesentlichen der Fehlerfunktion erf, englisch *Error Function*.

$$\mathrm{erf}(X) \;:=\; \frac{2}{\sqrt{\pi}} \int\limits_{0}^{X} e^{-X'^2} \,\mathrm{d}X'. \tag{5.5}$$

Die unterschiedlichen Definitionen für die kumulierte Gaußverteilung und die Fehlerfunktion führen zu unterschiedlichen Wertebereichen. Während die kumulierte Gaußverteilung einen Wertebereich von 0 bis 1 hat, ist die Fehlerfunktion so definiert, dass sie einen Wertebereich von $-1$ bis 1 hat. Sie lassen sich wie folgt ineinander überführen

$$F_0(X) \;=\; \frac{1}{2}\left(1 \,+\, \mathrm{erf}\left(\frac{X-\mu_0}{\sqrt{2}\,\sigma_0}\right)\right). \tag{5.6}$$

Für standardnormalverteilte Zufallszahlen $Z = \frac{X-\mu}{\sigma}$ oder $Z = \frac{X-y}{s}$ wird für die kumulierte Gaußverteilung der Bezeichner $\Phi$ verwendet

$$\Phi(Z) := \frac{1}{\sqrt{2\pi}} \int\limits_{-\infty}^{Z} e^{-\frac{1}{2}Z'^2} \,\mathrm{d}Z' \quad \Rightarrow \quad \Phi(Z) \;=\; \frac{1}{2}\left(1 \,+\, \mathrm{erf}\left(\frac{Z}{\sqrt{2}}\right)\right). \tag{5.7}$$

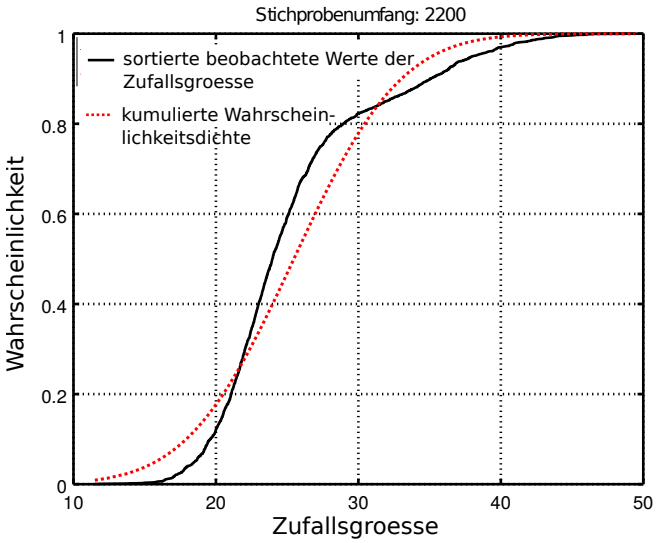



Abbildung 5.2: Vergleich der Wahrscheinlichkeiten (kumulierte Verteilungsdichten) aus der empirische gewonnenen Häufigkeit der beobachteten Werte der Zufallsgröße (schwarze, durchgezogene Kurve) mit der kumulierten Normalverteilung, die sich auf die empirischen Erwartungswerte, den Mittelwert und die empirische Varianz, bezieht (rote, gestrichelte Kurve).

Die Kenntnis dieser unterschiedlichen Definitionen und ihrer Umrechnung ist nützlich. Statistische Bibliotheken stellen jedoch meist sowohl die Fehlerfunktion als auch direkt die kumulierte Normalverteilung bereit, beispielsweise `normcdf` in Matlab/Octave und `scipy.stats.norm.cdf` in Python.

Die kumulierte Verteilung der relativen Häufigkeiten gewinnen wir darüber, dass wir die Werte der Stichprobe in aufsteigender Reihenfolge sortieren

$$X_{1,k_1} \leq X_{1,k_2} \leq \ldots \leq X_{1,k_J} \tag{5.8}$$

Die Teilstichprobe mit der Beobachtung mit dem kleinsten Wert ($X_{1,k_1}$) hat die relative kumulierte Häufigkeit $\frac{1}{J}$, die Teilstichprobe mit den zwei kleinsten Beobachtungen ($X_{1,k_1}, X_{1,k_2}$) hat die relative kumulierte Häufigkeit $\frac{2}{J}$. Die Teilstichprobe mit den $j$ kleinsten Beobachtungen

$$(X_{1,k_1}, X_{1,k_2}, \ldots, X_{1,k_j}) \quad \text{hat die relative kumulierte Häufigkeit} \quad H(X_{1,k_j}) = \frac{j}{J} \tag{5.9}$$

Abb. 5.2 stellt zum Vergleich die Wahrscheinlichkeitsfunktion (kumulierte Verteilungsfunktion) $F_0(X)$ gemäß Gl. (5.3) als rote, gestrichelte Kurve und die kumulierte, relative Häufigkeit $H(X_{1,k_j}) = \frac{j}{J}$ als schwarze, durchgezogen gezeichnete Kurve in einem Diagramm dar.

Für eine stetige, vollständig spezifizierte Nullverteilung $F_0$ ist die Prüfgröße des Einstichproben-*Kolmogorow-Smirnow*-Tests

$$D = \sup_X |H_J(X) - F_0(X)| = \max_{1 \leq j \leq J} \left\{ \max \left[ \frac{j}{J} - F_0(X_{1,k_j}),\, F_0(X_{1,k_j}) - \frac{j-1}{J} \right] \right\}. \tag{5.10}$$

Dabei steht sup für Supremum, also die kleinste obere Schranke. Die beiden Terme berücksichtigen die

Abweichung direkt an einer Stufe der empirischen Verteilungsfunktion und unmittelbar davor. Für eine nichtklassierte, sortierte Stichprobe werden daher beide Seiten benötigt; die einseitige Betrachtung nur von $\left|H(X_{1,k_j}) - F_0(X_{1,k_j})\right|$ kann den maximalen Abstand unterschätzen.

Das Signifikanzniveau $\alpha$ ist beim Test die maximal zulässige Wahrscheinlichkeit, die Nullhypothese zu verwerfen, obwohl sie wahr ist. Es ist nicht allgemein gleich der Wahrscheinlichkeit, dass eine einzelne Beobachtung in den Ausläufern der Dichte liegt.

Beim einseitigen Kolmogorow-Smirnow-Test wird die Nullhypothese $H_0$ verworfen, wenn die Prüfgröße einen kritischen Wert, Grenzwert, überschreitet, der vom Signifikanzniveau $\alpha$ und dem Stichprobenumfang $J$ abhängt

$$D \; > \; K_{\alpha,J} \tag{5.11}$$

wobei der asymptotische kritische Wert für große $J$ näherungsweise durch folgende Gleichung gegeben ist:

$$K_{\alpha,J} \; \approx \; \sqrt{-\frac{1}{2\,J}\,\ln(\frac{\alpha}{2})} \tag{5.12}$$

Beim Lilliefors-Test sind die Grenzwerte für die Entscheidung bei größeren Stichprobenumfängen (etwa $J > 30$) folgende

$$c^{\mathrm{L}}_{\alpha,J} \approx \frac{k_\alpha}{\sqrt{J}} \tag{5.13}$$

wobei $k_\alpha$ folgende Werte hat:

| $\alpha$ | 0.10 | 0.05 | 0.01 |
|---|---|---|---|
| $k_\alpha$ | 0.805 | 0.886 | 1.031 |

Beim Zweistichproben-Kolmogorow-Smirnow-Test, also dem Vergleich zweier unabhängiger Stichproben mit empirischen Verteilungsfunktionen $H_{J_1}(x)$ und $G_{J_2}(x)$ und Sichprobenumfängen $J_1$ und $J_2$ ist Prüfgröße

$$D_{J_1,J_2} = \sup_x \left|H_{J_1}(x) - G_{J_2}(x)\right|. \tag{5.14}$$

Für größere Stichprobenumfänge wird die Entscheidung meist über

$$D_{J_1,J_2} > c_\alpha \sqrt{\frac{J_1 + J_2}{J_1 J_2}} \tag{5.15}$$

getroffen mit näherungsweise folgenden Werten für $c_\alpha$:

| $\alpha$ | 0.10 | 0.05 | 0.01 |
|---|---|---|---|
| $c_\alpha$ | 1.22 | 1.36 | 1.63 |

## 5.3 Wahrscheinlichkeitsdichtefunktionen und ihre Parameter

Für eine Bewertung von gemessenen Werten einer Größe, d.h. von Beobachtungen, werden statistische Modelle zugrunde gelegt. Ein statistisches Modell zu beobachtbaren Größen umfasst die Vorstellung von Zufallsgrößen und der Verteilung ihrer Beobachtungswerte. Bisher haben wir uns mit Zufallsgrößen befasst, die kontinuierlich sind und die Werte von minus Unendlich bis plus unendlich einnehmen können. Die Streuung solcher Messgrößen haben wir dazu als normalverteilt betrachtet; denn wie wir bereits zu Beginn dieses Kapitels betont haben ist die Normalverteilung ein wichtiges Modell für viele zufällige Prozesse. Es sei in diesem Zusammenhang an das zentrale Grenzwerttheorem in Abschnitt 5.1 erinnert.

Für das Hintergrundverständnis der Behandlung von Stichproben mit einer relativ kleinen Anzahl $J$ von Beobachtungen werden hier kurz die Binomialverteilung, die Poissonverteilung, die Gammaverteilung und die $\chi^2$-Verteilung eingeführt.

Zufallsgrößen sind nicht immer gaußverteilt. Wir haben bisher reellwerte Messgrößen als Zufallsgröße betrachtet, die direkt das Zufallereignis darstellen. Ein Zufallsereignis[1] kann aber auch gezählt werden. Die gewonnene Anzahl wird dabei als die Zufallsgröße, deren Wahrscheinlichkeit untersucht wird, betrachtet. Dabei wird die Häufigkeit oder Anzahl des Auftretens bestimmter Ereignisse in spezifizierten Zeitabschnitten oder an bestimmten Orten als Zufallsgröße $X$ analysiert. Dies kann beispielsweise die Anzahl von Gammaquanten in einem Zählrohr pro Zeitintervall sein. Bei diesem Beispiel kann die Verteilung der Wahrscheinlichkeit $p(X)$, dass $X$ Gammaquanten innerhalb von 100 ms vom Zählrohr detektiert werden, als Poissonverteilung angenommen werden.

Wir unterscheiden, ob eine Zufallsgröße reellwertig, d.h. $X \in \mathbb{R}$, oder ob sie positive, ganze Zahlenwerte einnehmen, also $X \in \mathbb{N}_0$.

Für die Beschreibung der Wahrscheinlichkeitsdichteverteilung von (Ko-)Varianzen, die nur positive Zahlenwerte annehmen, d.h. $X \in \mathbb{R}_{>0}$, werden wir eine schiefsymmetrische Verteilung kennen lernen, die $\chi^2$-Verteilung.

Bevor wir auf die unterschiedlichen Verteilungsdichtefunktionen, Binomialverteilung, Poissonverteilung, Gammaverteilung und $\chi^2$-Verteilung, genauer eingehen, führen wir die Parameter ein, mit denen Verteilungsdichtefunktionen charakterisiert werden. Für das Verständnis dafür, wie Zufallsgrößen streuen, wie sie sich verteilen, interessiert,

- um welchen Wert sie sich häufen, also welcher Wert am ehesten zu erwarten ist oder in dessen Nähe die Werte erwartet werden. Das ist der *Erwartungswert*.
- Der Parameter, der ein Maß dafür ist wie weit beobachtete Werte einer Zufallsgröße auseinander liegen, also wie stark die Zufallsgröße streut, ist die *Varianz*.
- Oft interessiert noch, ob die streuenden Beobachtungen sich asymmetrisch weiter zu Werten, die kleiner oder die größer als der Erwartungswert sind, verteilen. Das Maß dafür ist die *Schiefe*

[1] *Ereignis* ist der in der Statistik verwendete allgemeinere Begriff, der im Speziellen hier eine Beobachtung, also das Annehmen eines Wertes einer Messgröße/ einer physikalischen Größe, ist. Ein Ereignis kann auch die Augenzahl eines geworfenen Würfels oder Farbe und Zahl einer gelandeten Kugel im Roulette sein.

einer Verteilung.

Diese die Wahrscheinlichkeitsdichteverteilungen charakterisierenden Parameter sind die sogenannten *statistischen Momente*.

Der *Erwartungswert einer Zufallsgröße* $X$ ist das erste statistische Moment der Verteilungsdichte $p$ ihrer Grundgesamtheit

$$\mathrm{E}(X) \;=\; \int_{-\infty}^{\infty} X\, p(X)\, \mathrm{d}X \;=:\; \mu^{(1)}(X) \tag{5.16}$$

das ihren Schwerpunkt, also die Lage der Zufallsgröße, angibt. Deshalb wird das erste statistische Moment auch *Lageparameter* (engl. *location parameter*) genannt.

Das zweite (unzentrierte) statistische Moment der Verteilungsdichte $p$ ist definiert durch

$$\int_{-\infty}^{\infty} X^2\, p(X)\; \mathrm{d}\, X \;=:\; \mu^{(2)}(X) \tag{5.17}$$

Die Varianz ist dagegen das zweite zentrale Moment, also das zweite Moment der um den Erwartungswert verschobenen Zufallsgröße,

$$\mathrm{Var}(X) \;=\; \int_{-\infty}^{\infty} (X - \mathrm{E}(X))^2\, p(X)\, \mathrm{d}X \tag{5.18}$$

deren Wurzel

$$\sigma \;=\; \sqrt{\mathrm{Var}(X)} \tag{5.19}$$

ein Maß für die Breite von $p$ darstellt. Wird die Zufallsgröße auf die Streubreite ihrer Verteilung normiert, wird sie dimensionslos. Deshalb wird die Breite auch als *Skalenparameter* (engl. *scale parameter*) eingesetzt.

Die Schiefe einer Verteilungsdichte wird durch das dritte statistische Moment

$$\int_{-\infty}^{\infty} X^3\, p(X)\, \mathrm{d}X \;=:\; \mu^{(3)}(X) \tag{5.20}$$

gewonnen, bei dem die Zufallsgröße um ihren Erwartungswert verschoben und auf die Wurzel ihrer Varianz normiert

$$\mathrm{Skew}(X) \;=\; \int_{-\infty}^{\infty} \left(\frac{X - \mathrm{E}(X)}{\sigma}\right)^3 p(X)\; \mathrm{d}\, X \tag{5.21}$$

wird. Das dritte statistische Moment der normierten Zufallsgröße heißt *Skewness*. So sind beispielsweise die Poissonverteilung, die die Verteilung ganzzahlenwertiger Zufallsgrößen beschreibt, und die $\chi^2$-Verteilung, die die Verteilung positiver reellwertiger Zufallsgrößen beschreibt, schiefsymmetrisch.

Ein Maß für die Überhöhung oder Abflachung relativ zur Normalverteilung wird durch das vierte

statistische Moment

$$\int_{-\infty}^{\infty} X^4\, p(X)\,\mathrm{d}X \;=:\; \mu^{(4)}(X) \tag{5.22}$$

gewonnen, bei dem die Zufallsgröße um ihren Erwartungswert verschoben und auf die Wurzel ihrer Varianz normiert

$$\mathrm{Kurt}(X) \;=\; \int_{-\infty}^{\infty} \left(\frac{X-\mathrm{E}(X)}{\sigma}\right)^4 p(X)\;\mathrm{d}\,X \tag{5.23}$$

wird. Das vierte statistische Moment der normierten Zufallsgröße heißt *Kurtosis*.

Im Folgenden sei nun konkretisiert, wie die bereits genannten Verteilungsfunktionen definiert sind.

Der Beschreibung von binärwertigen Zufallsereignissen dient die **Binomialverteilung**. Dabei ist mit binärwertigem Zufallsereignis gemeint, dass nur zwei mögliche Beobachtungen/ Entscheidungen angenommen werden können, also entweder *ja* oder *nein*, bzw. *gut* oder *schlecht*, bzw. *wahr* oder *falsch*. Die Binomialverteilung beschreibt die Anzahl der *ja*-Stimmen, bzw. in der Qualitätssicherung die Anzahl der *guten* Teile. Die Wahrscheinlichkeit für ein erfolgreiches Ereignis wird mit $p$ bezeichnet; die Anzahl der Erfolge ist die Zufallsgröße $k$. Hier bedeutet das $p$ ohne Index einen Wert in $[0, 1]$ und keine Funktion. Die Funktion für die binomiale Wahrscheinlichkeitsverteilung schreiben wir mit dem Index B für Binomial oder für Bernoulli, weil es sich bei solchen Prozessen um Bernoulli-Prozesse handelt.

$$p_{\mathrm{B}}(k,p,J) \;=\; \begin{cases} \binom{J}{k} p^k\,(1-p)^{J-k} & \text{falls } k \in \{0,1,\ldots,J\} \\ 0 & \text{sonst} \end{cases} \tag{5.24}$$

wobei $J$ die Gesamtzahl der Beobachtungen / Ziehungen/ Versuche ist und $k$ die Anzahl der erfolgreichen Ziehungen. Also wenn $J$ Teile geprüft wurden, dann ist $k$ die Anzahl der Teile, die gut waren.

$\binom{J}{k}$ ist der Binomialkoeffizient, der folgendes bedeutet:

$$\binom{J}{k} \;=\; \frac{J}{1}\cdot\frac{J-1}{2}\cdot\ldots\cdot\frac{J-(k-1)}{k} \;=\; \frac{J!}{k!\cdot(J-k)!}$$

für $k = 0$ gilt $\binom{J}{k} = 1$

Wenn $J$ groß und $p$ klein ist, während das Produkt $\lambda = J\,p$ konstant bleibt, konvergiert die Binomialverteilung gegen die **Poissonverteilung**. Wir stellen uns also vor, dass der Zeitraum, in dem produzierte Teile auf gut/schlecht geprüft werden im Vergleich zum Durchsatz bei der Teileprüfung so groß ist, dass $\lambda = J\,p$ als Erwartungswert und Varianz verwendet werden kann. Dann wird nicht mehr das Ereignis „Bauteil ist gut“ oder „Bauteil ist schlecht“ als Zufallsereignis, sondern die Anzahl $k$ von den $J$ in einem Zeitraum geprüften Bauteile als Zufallszahl bzw. Zufallsgröße $X$ betrachtet. Die Wahrscheinlichkeitsverteilung, die die Zufallsgröße „Anzahl $k = X$ von in einem Zeitraum als Gut geprüfter Teile“ beschreibt, ist also die Poissonverteilung.

Weitere typische Beispiele für poissonverteilte Zufallsgrößen sind

- die Anzahl $X$ von $\alpha$-Teilchen, die von einer radioaktiven Probe pro Sekunde (also in einem Zeitinervall von einer Sekunde) emittieren;

- die Anzahl $X$ von Mutationen, die in einer DNA-Sequenz vorkommen;
- die Anzahl $X$ der Fahrgäste, die in einem ausgewählten Zeitintervall, z. B. zwischen 6 und 9 Uhr vormittags, eine gewisse Buslinie nutzen;
- die Anzahl $X$ der Streuprozesse pro Streckenabschnitt, die ein Teilchen beim Propagieren durch Materie entlang seines Weges erfährt.

Die **Poissonverteilung** $p_{\mathrm{P}}$ (der Index P steht für Poisson) wird also für die Beschreibung der Anzahl (Häufigkeit) $X$ für das Eintreten eines Ereignisses in einem gewissen Bereich eingesetzt. Der Bereich ist oftmals ein Zeitbereich bzw. Zeitintervall, muss es aber nicht sein.

Bei der Anzahl von Teilchen, Mutationen oder Fahrgästen handelt es sich jeweils um eine diskrete Zufallsgröße mit einem Wertebereich von positiven, diskreten Werten einschließlich der Null, also eine Zufallsgröße $X \in \mathbb{N}_0$, d.h. mit natürlichen Zahlenwerten $X = 0, 1, 2, 3, \ldots$.

Die Poissonverteilung sieht wie folgt aus

$$p_{\mathrm{P}}(X, \lambda) \;=\; \frac{\lambda^X}{X!}\, e^{-\lambda} \tag{5.25}$$

siehe https://www.itl.nist.gov/div898/handbook/eda/section3/eda366j.htm

Dabei bedeutet das Ausrufezeichen die mathematische Operation Fakultät mit

$$X! = \prod_{j=1}^{X} X = 1 \cdot 2 \cdot \ldots \cdot X$$

also wenn beispielsweise $X = 3$ dann ist $3! = 1 \cdot 2 \cdot 3 = 6$. Ferner wird definiert, dass $0! = 1$. Der Parameter $\lambda$

- beschreibt die erwartete Anzahl von Ereignissen im betrachteten Bereich. Er ist eine positive von Null verschiedene, reelle Zahl, d.h. $\lambda \in \mathbb{R}_{>0}$;
- bestimmt den Erwartungswert und die Varianz von $p_{\mathrm{P}}(X, \lambda)$.

Der Erwartungswert $\lambda$ ist der Lageparameter der Verteilung. Im Fall der Poissonverteilung ist er gleichzeitig auch der Skalenparameter.

Bei Wahrscheinlichkeitsdichteverteilungen deren Lage- und Skalenparameter voneinander verschieden sind, wie wir es bei der Gaußverteilung kennen, werden die Symbole $\mu$ für den Lageparameter verwendet und $\beta$ für den Skalenparameter. Im Falle der Gaußverteilung ist $\beta = \sigma$.

Die Poissonverteilung ist eindeutig durch einen Parameter charakterisiert, der sowohl die Lage als auch die Skalierung bestimmt, die Gaußverteilung durch zwei Parameter, die Lage und die Skalierung. Allgemein gibt es aber Verteilungen, die darüber hinaus einen weiteren Parameter brauchen, der ihre Form charakterisiert, also nicht nur die Breite als reine Skalierung, sondern höhere statistische Momente, die das Maß für höhere Ableitungen wie die Krümmung etc. bestimmen.

Die Poissonverteilung beschreibt diskrete Zufallsgrößen $X = k \in \mathbb{N}_0$. Die **Gammaverteilung** ist dagegen eine kontinuierliche Verteilung auf der positiven Halbachse. Sie beschreibt beispielsweise Wartezeiten oder Summen unabhängiger exponentiell verteilter Zufallsgrößen; sie entsteht nicht einfach durch Ersetzen der diskreten Poissonvariablen durch eine reelle Variable.

$$p_\Gamma(X, \mu, \beta, \gamma) \;=\; \frac{\left(\frac{X-\mu}{\beta}\right)^{\gamma-1}}{\beta\,\Gamma(\gamma)}\, e^{-\left(\frac{X-\mu}{\beta}\right)} \quad \text{für} \quad X \geq \mu \quad \text{und} \quad \beta, \gamma > 0 \tag{5.26}$$

wobei $\gamma$ der *Formparameter* (engl. *shape parameter*) ist und mit der Gammafunktion

$$\Gamma(\gamma) \;=\; \int_0^\infty t^{\gamma-1}\, e^{-t}\, \mathrm{d}t$$

siehe https://www.itl.nist.gov/div898/handbook/eda/section3/eda366b.htm

Für positive, ganzzahlige Argumente $n \in \mathbb{N}$ ist die Gammafunktion gleich der Fakultät

$$\Gamma(n) \;=\; (n-1)!$$

Ist $X_1, \ldots, X_J$ eine unabhängige Stichprobe aus $\mathcal{N}(\mu, \sigma^2)$, dann ist

$$Q = \sum_{j=1}^{J} \left(\frac{X_j - \mu}{\sigma}\right)^2$$

$\chi^2$-quadrat-verteilt mit $\nu = J$ Freiheitsgraden, sofern $\mu$ und $\sigma$ bekannt sind, und $\nu = J - 1$ falls $\mu$ der aus der Stichprobe gewonnene Mittelwert ist. Die $\chi^2$-Verteilung ist eine Gammaverteilung mit Formparameter $\nu/2$ und Skalenparameter 2. Ihre Dichte lautet

$$p_{\chi^2}(Q, \nu) \;=\; \frac{Q^{\frac{\nu}{2}-1}\, e^{-\frac{Q}{2}}}{2^{\frac{\nu}{2}}\,\Gamma(\frac{\nu}{2})} \tag{5.27}$$

wobei $\nu$ die Anzahl der Freiheitsgrade, also der Stichprobenumfang abzüglich der Anzahl der Modellparameter ist.

## 5.4 Verteilung für kleine Stichproben: t-Verteilung

In der Praxis wird man vielfach damit konfrontiert, dass Prüfprozesse, also die Entnahme von Stichproben relativ aufwendig ist, so dass nur eine kleine Anzahl von Beobachtungen vorliegt. Was passiert dabei mit der Verteilung der Werte und wie aussagekräftig sind diese?

Für kleine Stichprobenumfänge wird eine der Normalverteilung ähnliche Verteilung herangezogen, die je kleiner der Stichprobenumfang ist, um so stärker ausgeprägte Ausläufer (*Tails*) hat, die $t$-Verteilung.

Wenn wir aus einer sehr großen Stichprobe, die einer Grundgesamtheit entnommen wurde, disjunkte Teilstichproben von kleinerem Umfang ($J < 100$) in Grüppchen unterteilen, so können wir beobachten, dass sowohl die Mittelwerte streuen als auch die Varianzen. Diese Grüppchen oder Teilstichproben

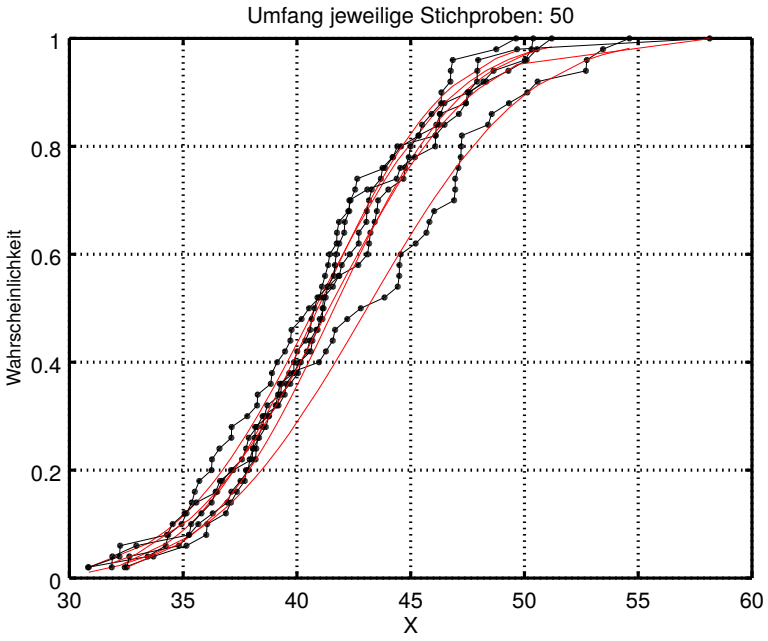



Abbildung 5.3: Kumulative relative Wahrscheinlichkeitsfunktionen und relative Summenhäufigkeiten von verschiedenen Stichproben mit jeweils $J = 50$ Werten, entnommen aus einer Grundgesamtheit mit $\mu = 42$ und $\sigma = 5$.

können wir als mehrere Stichproben aus einer normalverteilten Grundgesamtheit ansehen. Abb. 5.3 illustriert wie unterschiedlich die Verteilungsfunktionen von Stichproben mit relativ kleinem Umfang ($J = 50$) aussehen können, obwohl sie zu derselben Grundgesamtheit gehören. Dieses Beispiel wurde wie folgt mit Gnu-octave generiert:

```
function example_t()
  J1 = 50;
  mu1 = 42;
  sigma1 = 5;
  samples = [];
  for kappa = 1:5
    samples = [samples  (mu1 + sigma1*randn(J1,1))];
  end
  figure(3000); hold on;
  [J1, nS] = size(samples);
  for kappa = 1:5
    [P, H, xsort, xbar, s] = cumulatives(samples(:,kappa));
    plot( xsort, H, 'k.-');
    plot( xsort, P, 'r-');
  end
  xlabel('X', 'fontsize', 14);
  ylabel('Wahrscheinlichkeit', 'fontsize', 12);
  title(['Umfang jeweilige Stichproben: ' num2str(J1)], 'fontsize', 14);
  grid on;
  set(gca, 'fontsize', 14, 'linewidth', 2);
  hold off;
```

```
22 end
23 function [P, H, xsort, xbar, s] = cumulatives(x)
24   xbar = mean(x);
25   s = std(x);
26   J1 = length(x);
27   [xsort, isort] = sort(x, 'ascend');
28   H = [1:J1]'/J1;
29   P = normcdf( xsort, xbar, s);
30 end
```

Zur Bewertung der Flachheit bzw. Ausgeprägtheit der Ausläufer einer Verteilung berechnen wir ihre *Kurtosis*. Die *Kurtosis* der Normalverteilung hat den Wert 3.

Die empirischen Schätzer für den Erwartungswert, die Varianz, die Skewness und Kurtosis berechnen wir aus einer Stichprobe mit Beobachtungswerten $X_{1,1}, \ldots, X_{1,J}$ wie folgt:

Der Mittelwert wird berechnet mit

$$y = \frac{1}{J} \sum_{j=1}^{J} X_{1,j}. \tag{5.28}$$

Die empirische Standardabweichung wird berechnet mit

$$s = \sqrt{\frac{1}{J-1} \sum_{j=1}^{J} (X_{1,j} - y)^2}. \tag{5.29}$$

Zu bemerken ist, dass jetzt durch $J-1$ und nicht durch $J$ geteilt wird, weil das $y$ aus den Werten der Stichprobe $X_{1,1}, \ldots, X_{1,J}$ gewonnen wurde und somit die Anzahl der Freiheitsgrade $\nu$ um Eins verringert wird, also $\nu = J - 1$.

Die empirische Skewness wird berechnet mit

$$\text{skew} = \frac{1}{J} \sum_{j=1}^{J} \left( \frac{X_{1,j} - y}{s} \right)^3. \tag{5.30}$$

Die empirische Kurtosis wird berechnet mit

$$\text{kurt} = \frac{1}{J} \sum_{j=1}^{J} \left( \frac{X_{1,j} - y}{s} \right)^4. \tag{5.31}$$

Bei dem in Abb. 5.3 gezeigten Beispiel mit mehreren Stichprobenentnahmen aus einer Grundgesamtheit erhalten wir die in Tabelle 5.1 aufgeführten aus den Momenten abgeleiteten empirischen Parameter der Verteilungen.

Man kann der Beschreibung einer kleinen Stichprobe besser gerecht werden, wenn die Verteilung flacher ist als eine Standardnormalverteilung. Das bedeutet, dass ihre Ausläufer ausgeprägter sind.

Tabelle 5.1: Aus statistischen Momenten abgeleitete empirische Parameter der Verteilungen

| Einzelstichproben, Umfang jeweils $J = 50$ | | | | |
|---|---|---|---|---|
| lfd. Nr. | $y$ | $s$ | skew | kurt |
| 1 | 40.79 | 4.83 | 0.33 | 2.50 |
| 2 | 43.08 | 5.52 | 0.16 | 2.16 |
| 3 | 40.92 | 4.38 | -0.26 | 2.57 |
| 4 | 41.64 | 4.46 | 0.09 | 2.44 |
| 5 | 41.41 | 4.98 | 0.59 | 4.16 |
| alle Stichproben zusammen, Umfang $J = 5 \cdot 50 = 250$ | | | | |
| | 41.57 | 4.88 | 0.28 | 2.89 |
| wahre Grundgesamtheit | | | | |
| | $\mu$ | $\sigma$ | Skew | Kurt |
| Normalvert. | 42.00 | 5.00 | 0.00 | 3.00 |

Eine Verteilungsdichtefunktion, die der Gaußverteilung ähnlich ist, aber unter Berücksichtigung des begrenzten Stichprobenumfangs entsprechend ausgeprägtere Tails hat, ist die im folgenden dargestellte *Student-t*-Verteilung genannt, kurz auch einfach $t$-Verteilung.

Diese Wahrscheinlichkeitsdichteverteilung wurde Anfang des 20. Jahrhunderts von William Sealy Gosset entwickelt. Sie wird der Tatsache gerecht, dass die Varianz der $t$-Verteilung mit abnehmender Zahl der Freiheitsgrade zunimmt, sofern sie existiert. Gosset veröffentlichte 1908 erstmals zu dem Thema während er als Chemiker für die Guinness-Brauerei in Dublin arbeitete. Er entwickelte einen Test zum Vergleich von Mittelwerten einzelner Stichproben als eine billige Art und Weise, die Qualität des Stout zu überwachen. Dieser Test wird entsprechend der zugrunde gelegten Wahrscheinlichkeitsdichtefunktion $t$-Test genannt. Da sein Arbeitgeber die Veröffentlichung nicht gestattete, veröffentlichte Gosset sie unter dem Pseudonym Student. Die zugehörige Theorie wurde erst durch die Arbeiten von R. A. Fisher belegt, der die Verteilung *Student*-Verteilung (engl. *Student's distribution*) nannte.

Die $t$-Verteilung entsteht aus einer standardnormalverteilten Zufallsgröße $Z = (X-\mu)/\sigma$ und einer von ihr unabhängigen Zufallsgröße $Q \sim p_{\chi^2}(\nu)$. Die Schreibweise $Q \sim p_{\chi^2}(\nu)$ bedeutet „$Q$ ist $\chi^2$-verteilt".

Dann ist

$$\frac{Z}{\sqrt{\frac{1}{\nu}Q}} \quad \text{t-verteilt mit } \nu \text{ Freiheitsgraden.} \tag{5.32}$$

Die $t$-Verteilung sieht wie folgt aus:

$$p_{\mathrm{t}}(Z,\nu) \;=\; \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1+\frac{Z^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \tag{5.33}$$

mit $\nu$ für die Anzahl der Freiheitsgrade. Die Gammafunktion ist dabei die allgemeine Gammafunktion; für ganzzahlige Argumente gilt insbesondere $\Gamma(n) = (n-1)!$. Wir werden auf den theoretischen Hintergrund aus der Wahrscheinlichkeitstheorie nicht genau eingehen, also ist die Definition dieser Verteilung auch kein Klausurstoff. Für die Klausur werden die dazugehörigen Quantiltabellen zur Verfügung gestellt, d.h. den Aufgabenstellungen beigefügt.

Je kleiner der Stichprobenumfang ist desto flacher wird die Verteilung, mit entsprechend längeren

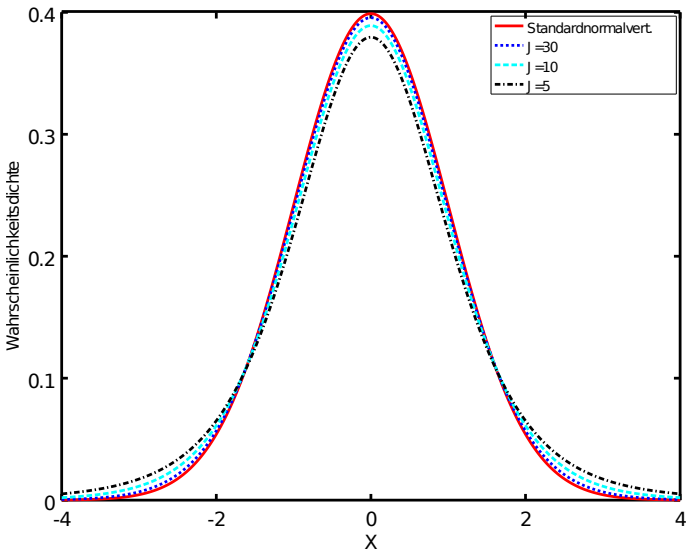



Abbildung 5.4: *Student-t*-Verteilungen für unterschiedliche Stichprobenumfänge.

Ausläufern, *Tails*, siehe Abb. 5.4. Um zu verdeutlichen, wie sich die Gaußverteilung und die *Student-t*-Verteilung hinsichtlich Breite und lange Ausläufer unterscheiden, haben wir hier dies im Vergleich berechnet. Dabei haben wir bewusst sehr wenige Freiheitsgrade gewählt, nämlich nur 5. Wir verwenden jetzt mal den empirischen Mittelwert und die empirische Standardabweichung, die wir aus der Gesamtheit aller Stichproben gewonnen hatten, also $y = 41.57$ und $s = 4.88$. Daraus rechnen wir sowohl die Normalverteilung als auch die *Student-t*-Verteilung für fünf Freiheitsgrade. Für eine $t$-Verteilung mit $\nu = 5$ sind Varianz und Kurtosis endlich und betragen, bezogen auf den Skalenparameter, $\nu/(\nu-2) = 5/3$ bzw. $3(\nu-2)/(\nu-4) = 9$:

| Verteilung | $\sigma$ | Kurt |
|---|---|---|
| Gauß-/Normalverteilung | 4.88 | 3.00 |
| Student-$t$-Verteilung | 6.30 | 9.00 |

Dementsprechend sind auch die Quantile größer.

Für die $t$-Verteilung existiert die Varianz nur für $\nu > 2$ und die Kurtosis nur für $\nu > 4$. Soweit sie existiert, nimmt die Kurtosis mit abnehmender Zahl der Freiheitsgrade zu; für $\nu \leq 4$ ist sie nicht definiert.

Das Vertrauensintervall für den Erwartungswert einer normalverteilten Grundgesamtheit mit unbekannter Varianz wird bei endlichem Stichprobenumfang $J$ mit dem Quantil der *Student-t*-Verteilung bestimmt. Die Anzahl der Freiheitsgrade entspricht dem Stichprobenumfang abzüglich der Anzahl der zu schätzenden Modellparameter, was in diesem Fall einer ist, also $\nu = J - 1$.

Während für die Standardnormalverteilung das Quantil $z_{0.975} = 1.96$ beträgt, haben wir aus der *Student-t*-Verteilung zu demselben Vertrauensniveau für $\nu = 50$ Freiheitsgrade $t_{0.975,50} = 2.01$ und für $\nu = 5$ Freiheitsgrade $t_{0.975,5} = 2.57$.

Für das zweiseitige, symmetrische Intervall verwenden wir das Quantil $t_{1-\alpha/2,\nu}$, so dass wir folgendes

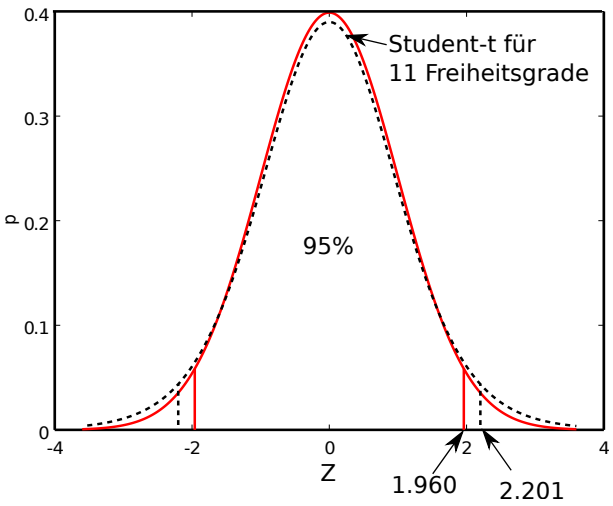



Abbildung 5.5: Vergleich der Vertrauensintervalle für die Standardnormalverteilung (rote Kurve) und die *Student-t*-Verteilung für $\nu = 11$ Freiheitsgrade (schwarze gestrichelte Kurve).

Vertrauensintervall erhalten:

$$\left[ y - t_{1-\alpha/2,\nu} \frac{s}{\sqrt{J}}, y + t_{1-\alpha/2,\nu} \frac{s}{\sqrt{J}} \right]$$

Die Breite wird durch die Anzahl der Freiheitsgrade beeinflusst; je kleiner die Anzahl der Freiheitsgrade ist, desto breiter wird das Intervall. Die beiden Abbn. 5.4 und 5.5 zeigen, dass die *Tails* einer *Student-t*-Verteilung für wenige Freiheitsgrade deutlich breiter sind als bei der Standardnormalverteilung, folglich auch das Vertrauensintervall breiter ist. In Abb. 5.5 sind die Quantile für ein Vertrauensniveau von $1 - \alpha = 0.95$ eingezeichnet.

Das *(vollständige) Messergebnis* geben wir an als Schätzwert zur Größe $Y$ gemeinsam mit dem Vertrauensintervall. Eine gebräuchliche Schreibweise ist

$$Y \;=\; y \pm t_{1-\alpha/2,\nu} \frac{s}{\sqrt{J}}. \tag{5.34}$$

Als nächstes befassen wir uns damit, wie der $\sqrt{J}$-Term im Vertrauensintervall zustande kommt.

Dazu betrachten wir ein Beispiel, bei dem aus einer Grundgesamtheit mit den wahren Werten $Y = 42$ und $\sigma = 7$ mehrere Stichproben genommen werden, beispielsweise $K = 15$, wobei jede Stichprobe einen Umfang von $J = 25$ habe. Zu jeder der Stichproben $k = 1 \ldots K$ berechnen wir den Mittelwert $y_k$ und die empirische Standardabweichung $s_k$.

| $k$ | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
|---|---|---|---|---|---|---|---|---|
| $y_k$ | 41.813 | 41.854 | 39.084 | 42.117 | 41.532 | 40.428 | 42.717 | 39.727 |
| $s_k$ | 6.476 | 7.706 | 6.996 | 7.729 | 6.431 | 7.516 | 7.505 | 7.439 |

| $k$ | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
|---|---|---|---|---|---|---|---|
| $y_k$ | 40.858 | 39.670 | 44.351 | 42.011 | 41.935 | 44.509 | 39.921 |
| $s_k$ | 8.568 | 7.649 | 6.082 | 7.661 | 7.084 | 7.878 | 7.084 |

Der Mittelwert $\bar{y}$ der Mittelwerte liefert dann

$$\bar{y} \;=\; \frac{1}{K}\sum_{k=1}^{K} y_k \;=\; 41.502$$

und die empirische Standardabweichung der Mittelwerte $y_k$ liefert

$$\bar{s} \;=\; \sqrt{\frac{1}{K-1}\sum_{k=1}^{K}(y_k \,-\, \bar{y})^2} \;=\; 1.606$$

Das wiederholte Ziehen von Stichproben kann für so manche Anwendung kostspielig sein, so dass es gilt die empirische Standardabweichung des Mittelwerts aus nur einer Stichprobe abzuschätzen. Dazu betrachten wir die Likelihood

$$l(Y,\sigma|\{X_{1,1},\ldots,X_{1,J}\}) \;=\; \prod_{j=1}^{J}\frac{1}{\sqrt{2\pi}\,\sigma}e^{-\frac{1}{2}\left(\frac{(X_{1,j}-Y)}{\sigma}\right)^2} \tag{5.35}$$

und setzten den Schätzer $y$ der Größe $Y$ als nahrhafte Null ein

$$l(Y,\sigma|\{X_{1,1},\ldots,X_{1,J}\}) \;=\; \prod_{j=1}^{J}\frac{1}{\sqrt{2\pi}\,\sigma}e^{-\frac{1}{2}\left(\frac{(X_{1,j}-y)-(Y-y)}{\sigma}\right)^2} \tag{5.36}$$

d.h.

$$l(Y,\sigma|\{X_{1,1},\ldots,X_{1,J}\}) \;=\; \frac{1}{(\sqrt{2\pi}\,\sigma)^J}e^{-\frac{1}{2}\sum\limits_{j=1}^{J}\left(\frac{(X_{1,j}-y)-(Y-y)}{\sigma}\right)^2}. \tag{5.37}$$

mit folgender Nebenrechnung für die Summe im Exponenten

$$\sum_{j=1}^{J}[(X_{1,j}-y)-(Y-y)]^2 = \sum_{j=1}^{J}(X_{1,j}-y)^2 + J(Y-y)^2,$$

$$\text{da}\;\sum_{j=1}^{J}(X_{1,j}-y)=0.$$

und $\sum_{j=1}^{J}(X_{1,j}-y)(Y-y)=0$ wegen $Jy=\sum_{j=1}^{J}X_{1,j}$. Der erste Summand ist unabhängig von $Y$ und wird in der folgenden Proportionalität weggelassen:

$$l(Y,\sigma|\{X_{1,1},\ldots,X_{1,J}\}) \;\propto\; e^{-\frac{1}{2}J\left(\frac{(Y-y)}{\sigma}\right)^2} \tag{5.38}$$

und wir definieren folgende Größe

$$\bar{\sigma}^2 \;:=\; \frac{\sigma^2}{J} \tag{5.39}$$

als *Varianz des Mittelwertes*.

Damit lässt sich Gl. (5.38) umschreiben in

$$l(Y,\sigma|\{X_{1,1},\ldots,X_{1,J}\}) \;\propto\; e^{-\frac{1}{2}\left(\frac{(Y-y)}{\bar{\sigma}}\right)^2}. \tag{5.40}$$

Nun setzen wir in die Definitionsgleichung der Varianz des Mittelwertes Gl. (5.39) bzw. die Wurzel

daraus die empirisch ermittelten Werte unseres Beispiels ein:

$$\bar{s} \;=\; \frac{s}{\sqrt{J}} \tag{5.41}$$

| $k$ | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
|---|---|---|---|---|---|---|---|---|
| $\bar{s}_k$ | 1.295 | 1.541 | 1.399 | 1.546 | 1.286 | 1.503 | 1.501 | 1.488 |

| $k$ | 9 | 10 | 11 | 12 | 13 | 14 | 15 |
|---|---|---|---|---|---|---|---|
| $\bar{s}_k$ | 1.714 | 1.530 | 1.216 | 1.532 | 1.417 | 1.576 | 1.417 |

Jede einzelne Stichprobe liefert eine etwas unterschiedliche Abschätzung für die Standardabweichung des Mittelwertes. Die Werte für $\bar{s}_k = s_k/\sqrt{J}$ liegen ungefähr zwischen 1.2 und 1.7 und streuen damit um die erwartete Standardabweichung des Mittelwertes von $\bar{s} = 1.6$.

Das *Vertrauensintervall* ist

$$[\bar{y} - t_{1-\alpha/2,\nu}\bar{s}, \bar{y} + t_{1-\alpha/2,\nu}\bar{s}]$$

und in der Schreibweise als *vollständiges Messergebnis*

$$Y \;=\; \bar{y} \pm t_{1-\alpha/2,K-1}\bar{s}. \tag{5.42}$$

In Kapitel 10 werden wir weiter die Themen „Standardunsicherheit“ und „Vertrauensintervall“ diskutieren. An dieser Stelle soll der Unterschied zwischem einem Skalenparameter einer Verteilung und der Standardabweichung, also der Wurzel der Varianz, von t-Verteilungen verdeutlicht werden.

Der GUM Supplement 1 [GUMS1] verwendet die Standardabweichung der t-Verteilung als Standardunsicherheit und weist in Abschnitt 6.4.9.4, Anmerkung 1, ausdrücklich auf den Unterschied zum klassischen GUM [GUM95] hin.

Die t-Quantile jedoch beziehen sich auf den Skalenparameter der t-Verteilung $\bar{s}$ und nicht auf die Standardabweichung der t-Verteilung. Für t-verteilte Größen ist

- die Standardunsicherheit $u = \bar{s}\sqrt{\frac{\nu}{\nu-2}}$,
- die erweiterte Unsicherheit aber $U = t_{1-\alpha/2,\nu}\bar{s}$.

**Skalenparameter und Standardabweichung der Student-$t$-Verteilung** Ein Skalenparameter beschreibt, um welchen Faktor eine Verteilung gestreckt wird. Die Standardabweichung beschreibt dagegen ihre Streuung um den Erwartungswert. Sie ist die Wurzel des zweiten zentralen Moments:

$$\sqrt{\mathrm{Var}(X)} = \sqrt{\mathrm{E}\Big[\big(X - \mathrm{E}(X)\big)^2\Big]}. \tag{5.43}$$

Dass Skalenparameter und Standardabweichung bei der Normalverteilung übereinstimmen, ist eine Eigenschaft ihrer üblichen Parametrisierung. Für andere Verteilungsfamilien gilt dies nicht grundsätzlich.

Wir verschieben und skalieren die Zufallsgröße und damit dann auch ihre Verteilung

$$X = x + aZ_\nu, \qquad a > 0, \tag{5.44}$$

wobei $Z_\nu$ eine Zufallsgröße mit zentraler[2] Student-$t$-Verteilung mit $\nu$ Freiheitsgraden bezeichnet. Die Parameter $x$ und $a$ sind fest. Der Lageparameter $x$ verschiebt die Verteilung, der Skalenparameter $a$ streckt alle Abstände von $x$. Bei festem $\nu$ bleibt die Verteilungsform dabei erhalten.

Für die Standardabweichung folgt

$$\sqrt{\mathrm{Var}(X)} = a\sqrt{\mathrm{Var}(Z_\nu)}. \tag{5.45}$$

Nur wenn die Ausgangsverteilung von $Z_\nu$ die Standardabweichung eins hat, ist $a$ zugleich die Standardabweichung von $X$.

Die übliche Student-$t$-Verteilung hat den Lageparameter null und den Skalenparameter eins. Für ihre Momente gilt jedoch

$$\mathrm{E}(Z_\nu) = 0 \quad \text{für } \nu > 1, \qquad \mathrm{Var}(Z_\nu) = \frac{\nu}{\nu - 2} \quad \text{für } \nu > 2. \tag{5.46}$$

Ihre Streuung hängt somit zusätzlich von den Freiheitsgraden $\nu$ ab. Insbesondere bedeutet ein Skalenparameter von eins hier nicht, dass auch die Standardabweichung eins beträgt.

**Entstehung der zusätzlichen Streuung.** Warum die Varianz größer als eins ist, lässt sich aus der Entstehung der Student-$t$-Verteilung verstehen. Wir betrachten $J$ unabhängige, identisch normalverteilte Beobachtungen mit Mittelwert $\mu$ und Varianz $\sigma^2$. Für den Stichprobenmittelwert gilt bei Division durch seine wahre Standardabweichung

$$Z_\mathrm{N} = \frac{\overline{X} - \mu}{\sigma/\sqrt{J}} \sim \mathcal{N}(0, 1). \tag{5.47}$$

Ersetzen wir $\sigma$ durch die aus der Stichprobe geschätzte Größe $S$, erhalten wir

$$Z_\nu = \frac{\overline{X} - \mu}{S/\sqrt{J}} = \frac{Z_\mathrm{N}}{S/\sigma}, \qquad \nu = J - 1. \tag{5.48}$$

Nun schwankt auch der Nenner von Stichprobe zu Stichprobe. Fällt $S$ klein aus, kann der Quotient besonders große Beträge annehmen. Dadurch entstehen die stärker besetzten Ausläufer (*tails*) der Student-$t$-Verteilung.

Für das normalverteilte Beobachtungsmodell gilt

$$Q = \frac{\nu S^2}{\sigma^2} \sim \chi^2_\nu. \tag{5.49}$$

[2]Damit ist gemeint, dass die Verteilung in den Koordinatenursprung zentriert ist.

Außerdem sind $Z_\mathrm{N}$ und $Q$ unabhängig. Damit können wir schreiben

$$Z_\nu = \frac{Z_\mathrm{N}}{\sqrt{Q/\nu}} \sim t_\nu. \tag{5.50}$$

Diese Quotientendarstellung führt zur üblichen Student-$t$-Verteilung.

Für $\nu > 2$ gilt

$$\mathrm{E}\left(\frac{1}{Q}\right) = \frac{1}{\nu - 2}. \tag{5.51}$$

Mit der Unabhängigkeit von $Z_\mathrm{N}$ und $Q$ folgt

$$\begin{aligned} \mathrm{Var}(Z_\nu) &= \mathrm{E}(Z_\nu^2) && (5.52)\\ &= \mathrm{E}\left(Z_\mathrm{N}^2 \frac{\nu}{Q}\right) && (5.53)\\ &= \underbrace{\mathrm{E}(Z_\mathrm{N}^2)}_{=1} \mathrm{E}\left(\frac{\nu}{Q}\right) = \frac{\nu}{\nu - 2}. && (5.54) \end{aligned}$$

Obwohl $\mathrm{E}(Q/\nu) = 1$ gilt, ist der Erwartungswert seines Kehrwerts also größer als eins. Die zufällige Division vergrößert damit das zweite Moment.

**Folgerung für den Skalenparameter.** Für die verschobene und skalierte Größe $X = x + aZ_\nu$ ergibt sich

$$\boxed{\sqrt{\mathrm{Var}(X)} = a\sqrt{\frac{\nu}{\nu - 2}}, \qquad \nu > 2.} \tag{5.55}$$

Beispielsweise beträgt bei $\nu = 4$ und Skalenparameter $a = 1$ die Standardabweichung $\sqrt{2}$.

Für eine große Anzahl von Freiheitsgraden nähert sich die Student-$t$-Verteilung der Standardnormalverteilung an. Entsprechend gilt

$$\lim_{\nu\to\infty} \frac{\nu}{\nu - 2} = 1. \tag{5.56}$$

Dann nähert sich auch die Standardabweichung von $X$ dem Skalenparameter $a$ an.

Für $\nu > 2$ könnten wir die Student-$t$-verteilte Größe auf Varianz eins normieren:

$$W_\nu = \sqrt{\frac{\nu - 2}{\nu}}\, Z_\nu, \qquad \mathrm{E}(W_\nu) = 0, \qquad \mathrm{Var}(W_\nu) = 1. \tag{5.57}$$

Die Quantile müssten dann mit demselben Faktor umgerechnet werden. Die üblichen Tabellen und Formeln beziehen sich jedoch auf $Z_\nu$ mit Skalenparameter eins und Varianz $\nu/(\nu - 2)$.

## 5.5 *t*-Test - Mittelwerttest

Nicht nur um die Qualität von schwarzem Bier (Stout) zu überprüfen, sondern ganz allgemein, wird der $t$-Test eingesetzt, um zu testen, ob

1. eine Stichprobe zu einer Grundgesamtheit gehört, deren Erwartungswert bekannt ist;

2. zwei Stichproben zur gleichen Grundgesamtheit gehören, deren Erwartungswert nicht bekannt ist, sondern die beiden Mittelwerte der jeweiligen Stichproben miteinander verglichen werden.

Die Nullhypothese $H_0$ für den Test (1.), ob der Erwartungswert $\mu_1$ einer Stichprobe zu einer Grundgesamtheit gehört und damit dem Erwartungswert der Grundgesamtheit, deren Erwartungswert $\mu_0$ bekannt ist, entspricht lautet: Der Erwartungswert $\mu_1$ der Stichprobe ist gleich dem Erwartungswert $\mu_0$ der Grundgesamtheit, $\mu_1 = \mu_0$. Die Alternativhypothese $H_\mathrm{a}$ lautet, dass sie einen anderen Erwartungswert hat, also $\mu_1 \neq \mu_0$.

Der Test auf Vergleich des Erwartungswerts einer Stichprobe, der Einstichproben-$t$-Test, wird wie folgt formuliert:

| | | |
|---|---|---|
| $H_0$ | $\mu_1 = \mu_0$ | die Stichprobe hat den gleichen Erwartungswert wie die Grundgesamtheit |
| $H_\mathrm{a}$ | $\mu_1 \neq \mu_0$ | die Stichprobe hat einen anderen Erwartungswert und gehört somit nicht zur Grundgesamtheit |

Die Prüfgröße ist die Differenz zwischen empirisch berechnetem Mittelwert der Stichprobe und Erwartungswert der Grundgesamtheit normiert auf die Standardabweichung des Mittelwerts $\bar{s}$ der Stichprobe. Mit $y$ für den Mittelwert der Stichprobe ist $y = \frac{1}{J}\sum_{j=1}^{J} X_{1,j}$ und mit der Varianz des Mittelwerts

$$\bar{s}^2 \;=\; \frac{1}{J(J-1)}\sum_{j=1}^{J}(X_{1,j}-y)^2 \tag{5.58}$$

ist die Prüfgröße des Einstichproben-$t$-Tests wie folgt definiert

$$T \;=\; \frac{y-\mu_0}{\bar{s}} \tag{5.59}$$

Die Nullhypothese wird mit einem Signifikanzniveau von $\alpha = 0.05$ abgelehnt, wenn der Betrag der Prüfgröße größer als das entsprechende Quantil der $t$-Verteilung ist

$$|T| \;>\; t_{1-\frac{1}{2}\alpha,\,\nu} \qquad \Rightarrow \qquad H_0 \text{ ablehnen} \tag{5.60}$$

wobei $\nu$ die Anzahl der Freiheitsgrade der Stichprobe ist, $\nu = J - 1$.

Der Test (2.) prüft, ob sich die Erwartungswerte zweier Stichproben unterscheiden. Er erlaubt allein keine Aussage darüber, ob die Stichproben aus derselben Grundgesamtheit stammen: Sei $\mu_1$ der Erwartungswert der Grundgesamtheit zu Stichprobe 1 mit Beobachtungen $(X_{1,1}, \ldots, X_{1,J_1})$ und sei $\mu_2$ der Erwartungswert der zu Stichprobe 2 mit Beobachtungen $(X_{2,1}, \ldots, X_{2,J_2})$. Die Nullhypothese $H_0$ lautet, dass beide denselben Erwartungswert haben, was soviel bedeutet wie $\mu_1 = \mu_2$. Die Alternativhypothese $H_\mathrm{a}$ lautet, dass sie unterschiedliche Erwartungswerte haben, also $\mu_1 \neq \mu_2$.

Auch gleiche Erwartungswerte beweisen daher nicht, dass beide Stichproben derselben Grundgesamtheit entstammen. Weitere Verteilungsmerkmale müssen deshalb separat betrachtet werden, beispielsweise mit dem $\chi^2$-Test (Abschnitt 5.6) für eine Varianz oder dem Fischer-Test (Abschnitt 5.7) für den Vergleich zweier Varianzen.

Der Test auf Erwartungswerte, der $t$-Test, wird wie folgt formuliert:

| | | |
|---|---|---|
| $H_0$ | $\mu_1 = \mu_2$ | beide Stichproben haben den gleichen Erwartungswert |
| $H_a$ | $\mu_1 \neq \mu_2$ | die Stichproben haben unterschiedliche Erwartungswerte |

Die Prüfgröße ist die Differenz der empirisch berechneten Mittelwerte, normiert auf die geschätzten Standardunsicherheit ihrer Differenz. Mit Gl. (5.29) wird die empirische Standardabweichung einer Stichprobe berechnet. Für die beiden Mittelwerte gilt

$$\bar{s}_i^2 \;=\; \frac{s_i^2}{J_i} \;=\; \frac{1}{J_i(J_i-1)} \sum_{j=1}^{J_i} (X_{i,j} - y_i)^2. \tag{5.61}$$

Für den $t$-Test mit zwei Stichproben unterscheidet man zwischen *gepoolten* und *nicht gepoolten* Stichproben. Der englische Begriff *pooled* bedeutet hier sinngemäß „zusammengeführt“ oder „gemeinsam ausgewertet“. Er bezieht sich auf das Zusammenführen der Varianzschätzungen. In der Statistik bedeutet *pooled* allgemein „zu einer gemeinsamen Schätzung zusammengeführt“.

Für **nicht gepoolte** Stichproben (Welch-$t$-Test) lautet die Prüfgröße

$$T \;=\; \frac{y_1 \,-\, y_2}{\sqrt{\bar{s}_1^2 + \bar{s}_2^2}} \tag{5.62}$$

mit den Freiheitsgraden

$$\nu \;=\; \frac{\left(\frac{s_1^2}{J_1} + \frac{s_2^2}{J_2}\right)^2}{\frac{\left(\frac{s_1^2}{J_1}\right)^2}{J_1-1} + \frac{\left(\frac{s_2^2}{J_2}\right)^2}{J_2-1}}. \tag{5.63}$$

Die Herleitung zur Berechnung der Anzahl der Freiheitsgrade für nicht gepoolte Stichproben wird in Kapitel 10 dargelegt. Gl. (5.63) wird auch Satterthwaite-Gleichung genannt.

Beim **gepoolten Test** wird vorausgesetzt, dass die Varianzen als gleich betrachtet werden können und es wird entsprechend die gepoolte Varianz verwendet

$$s_\mathrm{p}^2 \;=\; \frac{(J_1-1)s_1^2 + (J_2-1)s_2^2}{J_1 + J_2 - 2} \tag{5.64}$$

und

$$T \;=\; \frac{y_1 - y_2}{s_\mathrm{p}\sqrt{1/J_1 + 1/J_2}}. \tag{5.65}$$

mit

$$y_i \;=\; \frac{1}{J_i} \sum_{j=1}^{J_i} X_{i,j} \qquad \text{mit} \qquad i = 1, 2 \tag{5.66}$$

Die gemeinsame Anzahl der Freiheitsgrade für *gepoolte* Stichproben, die für die Wahl des $t$-Quantils gebraucht wird, ist

$$\nu \;=\; J_1 + J_2 - 2 \tag{5.67}$$

https://www.itl.nist.gov/div898/software/dataplot/refman1/ch3/t_test.pdf

Die Nullhypothese wird mit einem Signifikanzniveau von $\alpha = 0.05$ abgelehnt, wenn der Betrag der

Prüfgröße größer als das entsprechende Quantil der $t$-Verteilung ist

$$|T| > t_{1-\frac{1}{2}\alpha,\nu} \qquad \Rightarrow \qquad H_0 \text{ ablehnen} \tag{5.68}$$

Der Vergleich der ersten mit der zweiten Stichprobe aus Tabelle 5.1 sieht wie folgt aus: $J_1 = J_2 = 50$. Mit $J_1 = J_2$ reduziert sich die gepoolte Varianz zu

$$s_{\mathrm{p}}^2 = \frac{s_1^2 + s_2^2}{2}$$

so dass

$$T = \frac{y_1 - y_2}{\sqrt{\frac{s_1^2+s_2^2}{J}}} \tag{5.69}$$

Mit $\nu = 98$ Freiheitsgraden bei dem hier betrachteten Beispiel hat das Quantil den Wert $t_{1-\frac{1}{2}\alpha,\nu} = t_{0.975,98} = 1.985$. Für die Prüfgröße gilt dann

$$|T| = \frac{|40.79 - 43.08|}{\sqrt{\frac{(4.83)^2+(5.52)^2}{50}}} = 2.21 > 1.99$$

was zeigt, dass die Mittelwerte der beiden Stichproben signifikant, auf einem Signifikanzniveau von $\alpha = 0.05$, von einander abweichen und die Nullhypothese verworfen wird.

Betrachtet man jedoch ein höheres Vertrauensniveau, also anstelle von 95% ein Niveau von 98%, wird das Intervall breiter und der Verwerfungsbereich kleiner, so wird die Nullhypothese nicht verworfen. Auf einem Signifikanzniveau von nur $\alpha = 0.02$ hat das Vertrauensintervall die Grenzen $-t_{1-\frac{1}{2}\alpha,\nu} = -t_{0.99,98} = -2.365$ und $t_{1-\frac{1}{2}\alpha,\nu} = t_{0.99,98} = 2.365$. Die Nullhypothese wird für diese Wahl des Signifikanzniveaus nicht verworfen, weil die Prüfgröße innerhalb des breiteren Intervalls mit $|T| = 2.21 < 2.37$ liegt.

`http://www.itl.nist.gov/div898/handbook/eda/section3/eda353.htm`

## 5.6 $\chi^2$-Verteilung und Test einer Varianz

In Abschnitt 5.3 wurden verschiedene Verteilungsdichtefunktion vorgestellt. Dort wurde bereits die $\chi^2$-Verteilung, gesprochen *Chi-Quadrat*-Verteilung, eingeführt, die Verteilung der Quadrate einer normierten Zufallsgröße $Z$, also die Verteilung der Varianzen einer Zufallsgröße $X$, beschreibt.

Bisher haben wir uns damit befasst, wie eine Zufallsgröße $X$ streut. Jetzt betrachten wir, wie die Streuung ihrerseits streut. Wir betrachten eine Zufallsgröße, die zu einer normalverteilten Grundgesamtheit gehört.

$X$ sei eine normalverteilte Zufallsgröße mit Erwartungswert $\mu$ und Varianz $\sigma^2$

d.h.

$$X \sim \mathcal{N}(\mu, \sigma^2). \tag{5.70}$$

Werden einzelne kleinere Stichproben $X_i$ aus der Grundgesamtheit von $X$ entnommen, die jeweils einen Stichprobenumfang $J_i$ haben und werden die jeweiligen Mittelwerte und empirischen Varianzen berechnet

$$y_i \;=\; \frac{1}{J_i}\sum_{j=1}^{J_i} X_{i,j} \qquad s_i^2 \;=\; \frac{1}{J_i-1}\sum_{j=1}^{J_i}(X_{i,j}\;-\;y_i)^2 \tag{5.71}$$

so haben wir anhand der zuvor behandelten Beispiele festgestellt, dass nicht nur die Mittelwerte $y_i$ sondern auch die Varianzen $s_i^2$ streuen. Die Charakteristik der Verteilungsdichte der Varianzen hängt vom Stichprobenumfang $J_i$ ab. Wenn der Mittelwert aus der Stichprobe geschätzt wird, entspricht die Zahl der Freiheitsgrade $J_i - 1$; ist der Mittelwert bekannt, sind es $J_i$.

Gegeben sei eine Stichprobe $Z_1, \ldots, Z_J$ unabhängiger Beobachtungen einer standardnormalverteilten Zufallsgröße $Z \sim \mathcal{N}(0,1)$: Dann ist die Summe der Quadrate der Beobachtungen $Q$

$$Q \;=\; \sum_{j=1}^{J} Z_j^2 \tag{5.72}$$

gemäß der in Abschnitt 5.3, Gl. (5.27), eingeführten Wahrscheinlichkeitsdichtefunktion verteilt

$$p_{\chi^2}(Q,\nu) \;=\; \frac{Q^{\frac{\nu}{2}-1}\,e^{-\frac{Q}{2}}}{2^{\frac{\nu}{2}}\,\Gamma(\frac{\nu}{2})} \qquad Q>0$$

mit $\nu$ für die Anzahl der Freiheitsgrade und $\Gamma$ für die Gammafunktion.

Eine Schreibweise für die Aussage

$Q$ ist $\chi^2$-verteilt

ist

$$Q \;\sim\; p_{\chi^2}(\nu). \tag{5.73}$$

Wir verwenden die Schreibweise $p_{\chi^2}(\nu)$ für die $\chi^2$-Verteilungsdichtefunktion und $\chi^2_{\nu,\alpha}$ für die Quantile (Integrationsgrenzen). In der Literatur findet man häufig die Schreibweise $\chi^2(\nu)$ für die Verteilungsdichtefunktion, also $Q \;\sim\; \chi^2(\nu)$ für die Aussage „$Q$ ist $\chi^2$-verteilt“.

Die Definition der $\chi^2$-Verteilungsdichtefunktion braucht nicht auswendig gelernt zu werden. Der Umgang mit den Quantiltabellen ist aber zu üben. Wichtig zu wissen ist, dass die $\chi^2$-Verteilungsdichtefunktion für einen positiven Wertebereich gilt. Ihr Erwartungswert ist $\nu$ und ihr Maximum liegt für $\nu \geq 2$ bei $Q = \nu - 2$; sie ist umso schiefer und breiter, je kleiner $\nu$ ist. Die Verteilungsdichte der Varianzen

$$s_{\mu,i}^2 \;=\; \frac{1}{J_i}\sum_{j=1}^{J_i}(X_{i,j}\;-\;\mu)^2 \tag{5.74}$$

$$s_\mu^2 \;=\; \frac{1}{J}Q\,\sigma^2 \qquad \Leftrightarrow \qquad Q \;=\; J\left(\frac{s_\mu}{\sigma}\right)^2 \tag{5.75}$$

liefert. Was in der Praxis hinsichtlich des Statistiktests, dem $\chi^2$-Test, gebraucht wird, ist das Verständnis wie die Tabellen verwendet werden und für Methoden der bayesischen Statistik erforderlichenfalls auch wie die Funktionen der jeweils eingesetzten Numerik-/Statistikbibliotheken zu benutzen sind.

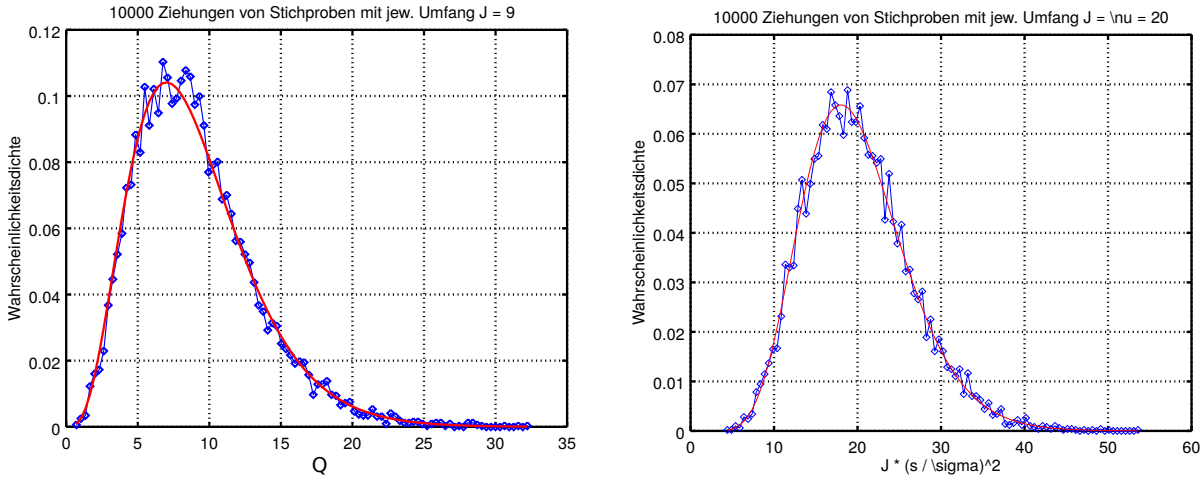



Abbildung 5.6: $\chi^2$-Verteilung der normierten Zufallsgröße $Q = J\left(\frac{s_\mu}{\sigma}\right)^2$ für $s_\mu^2 = \frac{1}{J}\sum_{j=1}^{J}(X_{\cdot,j}-\mu)^2$ für $J = 9$ (*links*) und $J = 20$ (*rechts*).

Abb. 5.6 zeigt zwei Beispiele für die Verteilungsdichte der Varianzen, zum einen für $J = 9$ und zum anderen für $J = 20$. Mit der Matlab/Gnu-Octave-Funktion `understandchi2`

```
function understandchi2()
  Jz = 9;
  nbin = 100;
  n = 10000;
  d = zeros(n,1);
  for k=1:n
    x = randn(Jz,1);
    d(k) = sum(x.^2);
  end
  [haeuf, bin] = hist(d,nbin);
  Deltabin = bin(2)-bin(1);
  figure(1000);
  plot(bin,haeuf/(n*Deltabin),'bd-',bin,chi2pdf(bin,Jz),'r-');
  xlabel('J * (s / \sigma)^2', 'fontsize', 14);
  ylabel('Wahrscheinlichkeitsdichte', 'fontsize', 14);
  title([num2str(n) 'Stichprobenumfang J = \nu = ' num2str(Jz)], 'fontsize', 14);
  grid on;
  set(gca, 'fontsize', 14, 'linewidth', 2);
  print(1000,['understandchi2_df' num2str(Jz) '_solid.svg'],'-dsvg');
end
```

wurden die Diagramme erzeugt. Die Verteilung der Grundgesamtheit ist die Standardnormalverteilung mit $\mu = 0$ und $\sigma = 1$. Eine Stichprobenentnahme wird mit `x = randn(Jz,1);` simuliert.

Wie bei anderen Verteilungen ist das Quantil der $\chi^2$-Verteilung die obere Integrationsgrenze zur Gewinnung des Flächeninhalts der Verteilungsdichte. Dies quantifiziert die Wahrscheinlichkeit, mit der für die Größe $Q$ Werte beobachtet werden, die kleiner sind als das Quantil. Hier ist die untere Integra-

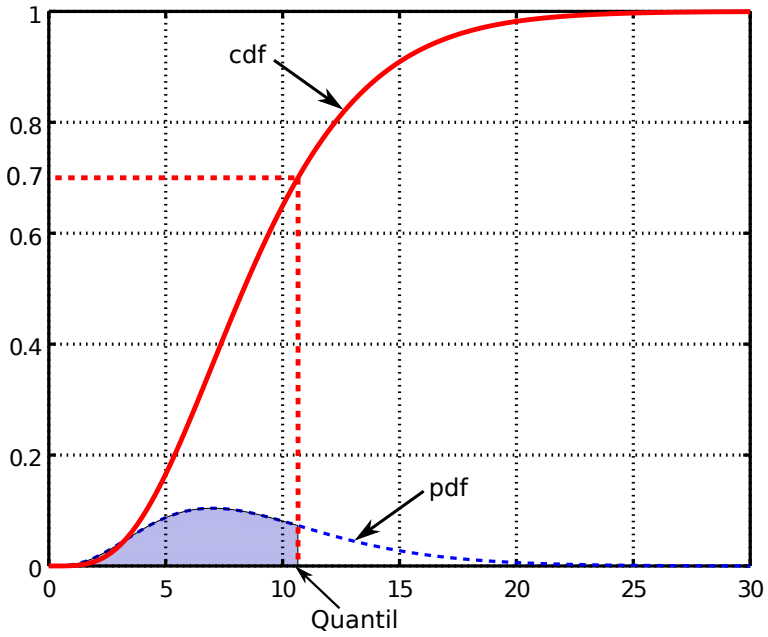



Abbildung 5.7: Wahrscheinlichkeitsverteilungsdichte (pdf) und kumulierte Wahrscheinlichkeitsfunktion (cdf) der normierten Varianzen, das Quantil wird $\chi^2$ genannt. Hier für $\nu = 9$ Freiheitsgrade und $1 - \alpha = 0.7$, somit $\chi^2_{\nu,1-\alpha} = 10.66$ dargestellt.

tionsgrenze Null und nicht minus Unendlich, weil $Q$ per definitionem nur nichtnegative Werte haben kann, siehe Abb. 5.7.

$$P(Q) \;=\; \int_0^{\chi^2_{1-\alpha,\nu}} p(Q',\nu)\;\mathrm{d}\,Q' \;=\; 1 \,-\, \alpha \tag{5.76}$$

Bei dem $\chi^2$-Test wird die empirische Varianz einer Stichprobe

$$s^2_{\mu,i} \;=\; \frac{1}{J_i}\sum_{j=1}^{J_i}(X_{i,j} \,-\, \mu)^2 \;\approx\; \frac{1}{J_i - 1}\sum_{j=1}^{J_i}(X_{i,j} \,-\, y_i)^2 \;=\; s_i^2 \tag{5.77}$$

mit der bekannten Varianz einer Grundgesamtheit verglichen.

```
1  for k=1:n
2    x = randn(Jz,1);
3    y = mean(x);
4    d(k) = sum((x-y).^2);
5  end
```

Dann ist die Anzahl der Freiheitsgrade $\nu = J - 1$ um einen vermindert, weil der Mittelwert $y_i$ von den Werten $X_{i,j}$ abhängt. Die $\chi^2$-Verteilung ist mit der Anzahl der Freiheitsgrade und nicht mit dem Stichprobenumfang zu verwenden

$$s^2 \;=\; \frac{1}{\nu} Q\,\sigma^2 \qquad \Leftrightarrow \qquad Q \;=\; \nu\left(\frac{s}{\sigma}\right)^2, \tag{5.78}$$

so dass die $\chi^2$-Verteilungsdichte für $\nu = J - 1$ zu verwenden ist, in Gnu-Octave beispielsweise mit dem Funktionsaufruf `chi2pdf`:

```
[haeuf, bin] = hist(d,nbin);
Deltabin = bin(2)-bin(1);
plot(bin,haeuf/(n*Deltabin),'bd-',bin,chi2pdf(bin,Jz-1),'r-');
xlabel('(J-1) * (s / \sigma)^2', 'fontsize', 14);
```

Beim $\chi^2$-Test wird geprüft, ob die Varianz einer Stichprobe gleich einer spezifizierten Varianz $\sigma_0^2$ ist. Wir formulieren die Hypothesen

| | | |
|---|---|---|
| $H_0$ | $\sigma^2 = \sigma_0^2$ | die Stichprobe gehört zu einer Grundgesamtheit mit der Varianz $\sigma_0^2$ |
| $H_a$ | $\sigma^2 \neq \sigma_0^2$ | die Stichprobe gehört nicht zu einer Grundgesamtheit mit der Varianz $\sigma_0^2$ |

Die Testgröße ist

$$T = \nu \left(\frac{s}{\sigma_0}\right)^2. \tag{5.79}$$

Die Nullhypothese wird mit einem Signifikanzniveau von $\alpha$ verworfen, falls die Testgröße außerhalb des Intervalls liegt, das durch die in Gl. (5.76) definierten Quantile begrenzt wird, d.h.

$$T < \chi^2_{\alpha/2,\nu} \qquad \text{oder} \qquad T > \chi^2_{1-\alpha/2,\nu}. \tag{5.80}$$

Es ist zu beachten, dass beim zweiseitigen Test für jede Seite die Hälfte des Signifikanzniveaus verwendet wird, also $\alpha/2$.

`http://www.itl.nist.gov/div898/handbook/eda/section3/eda358.htm`

## 5.7 Fisherverteilung und Vergleich zweier empirischer Varianzen

Der Fall, bei dem zu überprüfen ist, ob die Varianzen zweier Stichproben zur gleichen Grundgesamtheit gehören müssten, bzw. ob diese im wesentlichen übereinstimmen, wird als Hypothesentest wie folgt formuliert:

| | | |
|---|---|---|
| $H_0$ | $\sigma_1^2 = \sigma_2^2$ | die beiden Stichproben haben die gleichen Varianzen |
| $H_a$ | $\sigma_1^2 \neq \sigma_2^2$ | die Stichproben haben unterschiedliche Varianzen |

Die Testgröße ist

$$T = \left(\frac{s_1}{s_2}\right)^2. \tag{5.81}$$

Sie wird verglichen mit den beiden Quantilen, dem linksseitigen und dem rechtsseitigen, der Fisherverteilung. Der Test wird in der Literatur Fisher-Test oder kurz F-Test genannt.

Die Fisherverteilung ist die Verteilung des Quotienten zweier unabhängiger, geeignet normierter $\chi^2$-verteilter Zufallsgrößen $Q_1$ und $Q_2$.

$$p_F(R,\nu_1,\nu_2) = \int_0^\infty p_{\chi^2}\left(\frac{\nu_1}{\nu_2}RQ_2,\nu_1\right) p_{\chi^2}(Q_2,\nu_2)\,\frac{\nu_1}{\nu_2}Q_2\,\mathrm{d}Q_2 \tag{5.82}$$

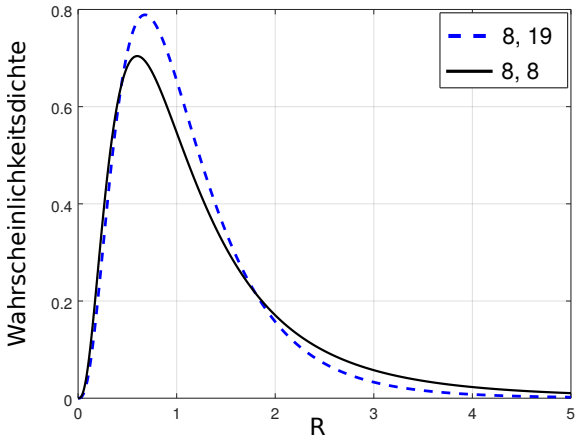



Abbildung 5.8: Fisherverteilung des Quotienten $R$ zweier $\chi^2$-verteilter Zufallsgrößen $Q_1$ und $Q_2$, also $R = \frac{\frac{1}{\nu_1}Q_1}{\frac{1}{\nu_2}Q_2} = \frac{s_1^2}{s_2^2}$ mit jeweils der Anzahl der Freiheitsgrade $\nu_1$ und $\nu_2$. Die beiden Kurven zeigen zwei Beispiele, die blau gestrichelte für $\nu_1 = 8$ und $\nu_2 = 19$ und die schwarze durchgezogene für $\nu_1 = \nu_2 = 8$ Freiheitsgrade.

mit

$$R = \frac{\frac{1}{\nu_1}Q_1}{\frac{1}{\nu_2}Q_2}. \tag{5.83}$$

Dabei ist der Faktor $\frac{\nu_1}{\nu_2}Q_2$ die Funktionaldeterminante aus der Transformation $(Q_1, Q_2) \to (R, Q_2)$, um aus der Wahrscheinlichkeitsdichtefunktion der beiden $\chi^2$-verteilten Zufallszahlen

$$p_{\chi^2}(Q_1, \nu_1)\, p_{\chi^2}(Q_2, \nu_2)$$

die Fisherverteilung zu berechnen. Nach Einsetzen der Gleichung für die $\chi^2$-Verteilung, Gl. (5.27), und Ausführen der Integration in Gl. (5.82), sieht die Fisherverteilung wie folgt aus

$$p_{\mathrm{F}}(R, \nu_1, \nu_2) = \nu_1^{\frac{\nu_1}{2}}\, \nu_2^{\frac{\nu_2}{2}}\, \frac{\Gamma\left(\frac{\nu_1+\nu_2}{2}\right)}{\Gamma\left(\frac{\nu_1}{2}\right)\Gamma\left(\frac{\nu_2}{2}\right)}\, \frac{R^{\frac{\nu_1}{2}-1}}{(\nu_1 R + \nu_2)^{\frac{\nu_1+\nu_2}{2}}}. \tag{5.84}$$

Abb. 5.8 zeigt beispielhaft zwei Fisherverteilungen, die mit blau gestrichelter Kurve dargestellte für $\nu_1 = 8$ und $\nu_2 = 19$ und die mit schwarz durchgezogener Kurve für $\nu_1 = \nu_2 = 8$ Freiheitsgrade.

Die Nullhypothese wird mit einem Signifikanzniveau von $\alpha$ verworfen, falls die Testgröße außerhalb des Intervalls liegt, das durch die Quantile der Fisherverteilung begrenzt wird. Quantile werden in der Literatur auch *kritische Werte* genannt, wenn sie die Grenzen für eine Bewertung darstellen.

$$T < F_{\alpha/2,\nu_1,\nu_2} \qquad \text{oder} \qquad T > F_{1-\alpha/2,\nu_1,\nu_2}. \tag{5.85}$$

Dabei ist $\nu_1$ der Freiheitsgrad des Zählers und $\nu_2$ derjenige des Nenners. Die Reihenfolge entspricht der Definition in Gl. (5.83) und der üblichen Notation der F-Verteilung.

Wenn beispielsweise die Anzahl der Beobachtungen der Stichprobe, aus der die Varianz im Zähler steht, $J_1 = 9$, die der Varianz, die im Nenner steht, $J_2 = 15$ ist, dann kann man in Python die Quantile folgendermaßen erhalten:

```
1 import scipy.stats as stats
```

```
2
3  # Freiheitsgrade festlegen
4  df1 = 9   # Stichprobe 1 im Zaehler (10 - 1)
5  df2 = 14  # Stichprobe 2 im Nenner (15 - 1)
6  alpha = 0.05
7
8  # Oberer kritischer Wert (Rechter Ablehnungsbereich bei 1 - alpha/2)
9  critical_value_upper = stats.f.ppf(1 - alpha / 2, df1, df2)
10
11 # Unterer kritischer Wert (Linker Ablehnungsbereich bei alpha/2)
12 critical_value_lower = stats.f.ppf(alpha / 2, df1, df2)
13
14 print(f"Oberer kritischer Wert: {critical_value_upper:.4f}")  # 3.2093
15 print(f"Unterer kritischer Wert: {critical_value_lower:.4f}")  # 0.2633
```

Beispiel: Der *General Social Survey (GSS)* hatte in den USA im Jahr 2000 anhand einer zufallsgenerierten Teilstichprobe mit $J = 652$ Erwachsenen Menschen untersucht, wie sich die Nutzungsdauer $t$ in Stunden/Woche der Internetnutzung nach Geschlecht unterscheidet.

| Geschlecht | $J_i$ | $t_i$ | $s_i$ |
|---|---|---|---|
| männlich | 305 | 5.48 | 7.80 |
| weiblich | 347 | 3.84 | 5.86 |

mit $J_i$ für die Stichprobenumfänge und $s_i$ für die Standardabweichungen mit $i = 1, 2$. Die Nutzungsdauer beträgt bei den Männern $t_1 = 5.48$ Stunden/Woche mit einer Standardabweichung von $s_1 = 7.80$ Stunden/Woche und bei den Frauen $t_2 = 3.84$ Stunden/Woche mit einer Standardabweichung von $s_2 = 5.86$ Stunden/Woche. Der F-Test überprüft, ob der Unterschied der Varianzen $s_1^2$ und $s_2^2$ signifikant ist. Im vorliegenden Beispiel beträgt der Zählerfreiheitsgrad $\nu_1 = J_1 - 1 = 305 - 1 = 304$ und der Nennerfreiheitsgrad $\nu_2 = J_2 - 1 = 347 - 1 = 346$.

```
1  import numpy as np
2  import scipy.stats
3  alpha = 0.05
4  s1 = 7.80
5  s2 = 5.86
6  J1 = 305
7  J2 = 347
8  nu1 = J1-1
9  nu2 = J2-1
10 Tpruef = (s1/s2)**2
11 critical_value_lower = scipy.stats.f.ppf(alpha/2, nu1, nu2)
12 critical_value_upper = scipy.stats.f.ppf(1-alpha/2, nu1, nu2)
13 print(critical_value_lower, Tpruef, critical_value_upper)
```

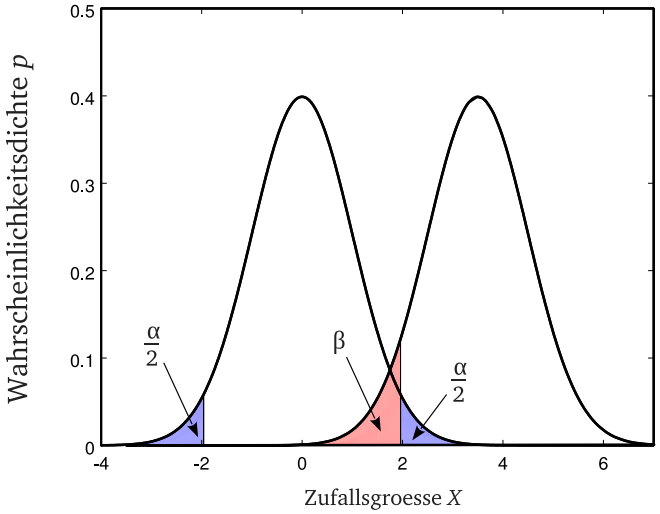



Abbildung 5.9: Die Ereignisse (beobachtete Werte) aus der linken Wahrscheinlichkeitsdichteverteilung, die im Verwerfungsbereich liegen, werden mit einem Signifikanzniveau von $\alpha$ verworfen. Die Ereignisse (beobachtete Werte) aus der rechten Wahrscheinlichkeitsdichteverteilung, die in dessen linkem *Tail* liegen, werden mit Wahrscheinlichkeit $\beta$ nicht verworfen.

$T = 1.772$ und $F_{\alpha/2,\nu_1,\nu_2} = 0.803$ sowie $F_{1-\alpha/2,\nu_1,\nu_2} = 1.243$. Mit $T = 1.772 > F_{1-\alpha/2,\nu_1,\nu_2} = 1.243$ liegt die Prüfgröße signifikant höher als der rechte kritische Wert. Die Nullhypothese wird daher auf dem Signifikanzniveau von 5 % verworfen; die Daten liefern statistische Evidenz für unterschiedliche Varianzen. Daraus folgt nicht automatisch, dass die beiden Stichproben unterschiedlichen Grundgesamtheiten entstammen.

## 5.8 Anwendung von Hypothesentests

Anwendung finden die Hypothesentests im Bereich der Qualitätssicherung in der Produktion (siehe beispielsweise zur Prüfung des Stout in der Guinnessbrauerei schon vor 100 Jahren), oder im Bereich der Naturwissenschaften (Biologie, Chemie, Pharmazie, Medizin) zum Nachweis von Substanzen. Es geht darum, zu bewerten, ob Daten mit einer statistischen Modellannahme vereinbar sind. Einer Entscheidung liegen Regeln zugrunde. Mit dem $t$-Test haben wir die Regeln kennengelernt, über die wir entscheiden, ob zwei Datensätze den gleichen Erwartungswert haben.

Als nächstes wollen wir untersuchen, welche Fehler mit welcher Wahrscheinlichkeit dabei entstehen können. Anschließend wollen wir uns ansehen, wie eine Stichprobe mit einer Toleranzvorgabe verglichen wird. Die Toleranzvorgabe liefert ein Intervall, dessen Lage mit der Lage der Wahrscheinlichkeitsverteilung der zu untersuchenden Stichprobe verglichen wird.

### 5.8.1 Entscheidung bei Vergleich zweier Stichproben

Den Hypothesentests, die wir uns angesehen haben, ist gemeinsam, dass

1. eine Nullhypothese $H_0$ (evtl. auch eine Alternativhypothese $H_a$) aufgestellt wurde,
2. ein Signifikanzniveau $\alpha$ spezifiziert wurde,
3. eine Stichprobe mit einer Anzahl Freiheitsgrade $\nu$ genommen wurde (oder zwei Stichproben mit ihren jeweiligen Freiheitsgradanzahlen) und
4. anhand der vorher aufgestellten Entscheidungsregeln (Vergleich einer Prüfgröße mit dem Quantil einer Wahrscheinlichkeitsdichteverteilung) die Hypothese verworfen oder angenommen wurde.

In der Entscheidungsregel werden durch Vorgabe eines Signifikanzniveaus Verwerfungsbereich und Nichtverwerfungsbereich festgelegt. Das Signifikanzniveau ist die Wahrscheinlichkeit für einen Fehler erster Art, also dafür, die Nullhypothese zu verwerfen, obwohl sie wahr ist. Es ist nicht die Wahrscheinlichkeit, dass die Nullhypothese wahr ist. Bei einem zugehörigen Vertrauensintervall wird häufig das Niveau $1 - \alpha$ verwendet.

Die möglichen Fehlentscheidungen eines Hypothesentests werden in zwei Klassen eingeteilt, den $\alpha$-Fehler oder den $\beta$-Fehler

| | $H_0$ nicht verwerfen | $H_0$ verwerfen |
|---|---|---|
| $H_0$ ist wahr | richtige Entscheidung, Wahrscheinlichkeit: $1 - \alpha$ | Fehler 1. Art, Wahrscheinlichkeit $\alpha$ |
| $H_0$ ist falsch | Fehler 2. Art, Wahrscheinlichkeit: $\beta$ | richtige Entscheidung, Wahrscheinlichkeit: $1 - \beta$ |

Abb. 5.9 soll illustrieren, dass Beobachtungswerte, die zu einer Grundgesamtheit mit einer Wahrscheinlichkeitsdichteverteilung mit Erwartungswert $\mu_a = 3.5$ gehören, per Hypothesentest einer Grundgesamtheit mit $\mu_0 = 0$ nicht verworfen werden. Die Wahrscheinlichkeit für dieses Ereignis ist dann $\beta$. Das Diagramm wurde mit folgendem Octave-Skript erzeugt

```
function plot_entscheidungsfehler()
  dz = 0.02;
  lim = 7;
  z = [-lim:dz:lim];
  p1 = normpdf(z,0,1);
  t = 1.96;
  zleft = [-lim:dz:-t];
  pleft = normpdf(zleft,0,1);
  zright = [t:dz:lim];
  pright = normpdf(zright,0,1);
  mu2 = 3.5;
  p2 = normpdf(z+mu2,mu2,1);
  zbeta = [-t:dz:t];
  pbeta = normpdf(zbeta,mu2,1);
  figure(200); hold on;
  area( zleft, pleft, 'Facecolor', [0.5 0.5 1]);
```

```
  area( zright, pright, 'Facecolor', [0.5 0.5 1]);
  area( zbeta, pbeta, 'Facecolor', [1 0.5 0.5]);
  plot( z, p1, 'k-', 'linewidth', 2);
  plot( z+mu2, p2, 'k--', 'linewidth', 2);
  xlabel('X', 'fontsize', 14);
  ylabel('p', 'fontsize', 14);
  axis([-4 7 0 0.5]);
  set(gca, 'fontsize', 14);
  hold off;
  print(200, 'entscheidungsfehler.svg', '-dsvg');
end
```

## 5.9 Übungsaufgaben zum Selbststudium

**Aufgabe 1**

Probieren Sie anhand von Beobachtungen, die Sie mit Hilfe eines Generators, der normalverteilte Zufallszahlen liefert, den Lilliefors-Test aus.

In Python könnten Sie die Stichprobe unter Verwendung eines festen Startwertes (*seed*) des Pseudorandomgenerators reproduzierbar erzeugen mit

```
rng = np.random.default_rng(1234)
```

Die Stichprobengenerierung lässt sich beispielsweise wie folgt realisieren:

```

# Erwartungswert und Standardabw. der Zufallsgroesse
mu1 = 23.0
s1 = 3.0
#
J1 = 200

# Zufallszahlen aus N(mu1, s1^2) erzeugen
Xarray = rng.normal(loc=mu1, scale=s1, size=J1)
```

Das Sortieren können Sie mit

```
# Stichprobe sortieren: x_1, ..., x_J
x_sortiert = np.sort(x)
```

und die relative Häufigkeiten als Wahrscheinlichkeiten mit

```
# Empirische kumulierte relative Haeufigkeit H(x_j) = j/J
rang = np.arange(1, J + 1)
H = rang / J
```

berechnen.

1. Verwenden Sie nicht die à priori eingesetzten Erwartungswerte, sondern Mittelwert `y = mean(Xarray)` und empirische Standardabweichung `s = std(Xarray)`, um die Verteilungsfunktion zu approximieren. Berechnen Sie die Prüfgröße $D$ gemäß der im Text angegebenen Formel, Gl. (5.10). Berechnen Sie die relativen Häufigkeiten $H$ gemäß Gl. (5.9), sowie den Lillifors-Grenzwert Grenzwert, Gl. (5.13)

   $$c^{\mathrm{L}}_{\alpha,J}$$

   zu einem Signifikanzniveau von $\alpha = 0.05$, wobei $J$ der Stichprobenumfang ist. Führen Sie den Test mit den von Ihnen erzeugten Zufallswerten durch.

2. Erzeugen Sie einen zusätzlichen Satz von Zufallszahlen, beispielsweise mit den Werten `mu2 = 35` und `s2 = 5`. Wählen Sie für diesen einen deutlich kleineren Stichprobenumfang von $J_2 = 31$. Führen Sie den KS-Test für die vereinigten Zufallszahlenarrays durch und tun Sie so, als ob Sie nicht wüssten, dass dies keine gemeinsame Grundgesamtheit ist. Verwenden Sie die vorgegebenen Werte $\mu_1 = 23$ und $s_1 = 3$ dem Einstichproben-KS-Grenzwert gemäß Gl. (5.12)

   $$K_{\alpha,J}$$

   zu einem Signifikanzniveau von $\alpha = 0.05$.

**Aufgabe 2**

Gegeben seien zwei Stichproben

Stichprobe 1:

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| 53 | 69 | 63 | 47 | 49 | 44 | 47 | 44 | 38 |

Stichprobe 2:

| | | | | |
|---|---|---|---|---|
| 21 | 33 | 19 | 39 | 7 |

a) Geben Sie zu jeder der beiden Stichproben die Mittelwerte und Standardabweichungen an.

b) Prüfen Sie, ob die Stichproben gepoolt sind (F-Test).

c) Prüfen Sie auf einem Signifikanzniveau von $\alpha = 0.05$ die Hypothese $H_0$, ob beide Stichproben zu einer Grundgesamtheit mit demselben Erwartungswert $\mu$ gehören. Geben Sie dazu die Formel und den Wert der Testgröße an und vergleichen Sie diese mit dem entsprechenden Quantil der für diesen Test zu verwendenden Verteilung. Mit welcher Verteilung ist dieser Test durchzuführen?

d) Prüfen Sie auf einem Signifikanzniveau von $\alpha = 0.05$ die Hypothese $H_0$, ob die zweite Stichprobe zu einer Grundgesamtheit mit der Standardabweichung $\sigma_0 = 6$ gehört. Geben Sie dazu die Formel und den Wert der Testgröße an und vergleichen Sie diese mit dem entsprechenden Quantil der für diesen Test zu verwendenden Verteilung. Mit welcher Verteilung ist dieser Test durchzuführen? Führen Sie nur den einseitigen Test durch, das heißt prüfen Sie nur bezüglich des rechten *Tail* der Verteilungsdichte.

e) Führen Sie denselben Test wie in (d) durch, aber dieses Mal für $\sigma_0 = 9$.

Verwenden Sie die Quantiltabellen aus dem Anhang Kapitel 13.

## 5.10 Anhang: Erwartungswerte zur $\chi^2$-Verteilung

Die $\chi^2$-Verteilung ist definiert durch

$$p(Q,\nu) \;:=\; \frac{Q^{\frac{\nu}{2}-1}\, e^{-\frac{Q}{2}}}{\Gamma\left(\frac{\nu}{2}\right)\, 2^{\frac{\nu}{2}}} \qquad \nu \in I\!N \tag{5.86}$$

mit der Gammafunktion $\Gamma$. Für ganzzahlige Argumente gilt insbesondere $\Gamma(n) = (n-1)!$; eine allgemeine Fallunterscheidung nach geraden und ungeraden Argumenten ist für die folgenden Rechnungen nicht erforderlich. Der Erwartungswert für die Zufallsgröße $Q$ ist

$$\mathrm{E}(Q) \;=\; \int_0^\infty Q'\, p(Q',\nu)\, \mathrm{d}\, Q' \tag{5.87}$$

und nach Integration mit Computeralgebrasoftware (beispielsweise Maxima)

$$\mathrm{E}(Q) \;=\; \frac{2\Gamma\left(\frac{\nu}{2}+1\right)}{\Gamma\left(\frac{\nu}{2}\right)} \tag{5.88}$$

und mit

$$\Gamma\left(\frac{\nu}{2}+1\right) = \Gamma\left(\frac{\nu}{2}+\frac{2}{2}\right) = \Gamma\left(\frac{\nu+2}{2}\right)$$

erhalten wir mit der Rekursionsformel $\Gamma(z+1) = z\Gamma(z)$

$$\begin{aligned} 2\frac{\Gamma(\nu/2+1)}{\Gamma(\nu/2)} &= 2\frac{\frac{\nu}{2}\Gamma(\nu/2)}{\Gamma(\nu/2)} \\ &= \nu \end{aligned} \tag{5.89}$$

Die Varianz $\mathrm{Var}(Q)$ der Zufallsgröße $Q$ ist

$$\mathrm{Var}(Q) \;=\; \int_0^\infty (Q'-\nu)^2\, p(Q',\nu)\, \mathrm{d}\, Q' \tag{5.90}$$

und nach Integration mit dem Computeralgebraprogramm Maxima

$$\mathrm{Var}(Q) \;=\; \nu^2 \;-\; 2\nu\frac{\Gamma(\nu/2+1)}{\Gamma(\nu/2)} \;+\; 2\frac{\Gamma(\nu/2+2)}{\Gamma(\nu/2)} \tag{5.91}$$

d.h.

$$\mathrm{Var}(Q) \;=\; \nu^2 \;-\; 2\nu^2 \;+\; \nu(\nu+2) \;=\; 2\nu \tag{5.92}$$

# Kapitel 6

# Konformitätsbewertung

## 6.1 Toleranz und Konformität

Nachdem wir gesehen haben wie wir zwei Hypothesen über die Lage zweier Wahrscheinlichkeitsdichteverteilungen verglichen haben, befassen wir uns jetzt mit dem Vergleich von Grenzen, den Toleranzgrenzen, mit einer Wahrscheinlichkeitsdichteverteilung. Für die Fertigung werden in den Konstruktionszeichnungen zu den Merkmalen von Bauteilen die Toleranzgrenzen eingetragen, innerhalb derer die Merkmale des Werkstücks liegen müssen. Wie nun bewertet man nach Fertigstellung des Werkstücks, ob ein Merkmal innerhalb einer Toleranzvorgabe liegt? Ein Merkmal wird durch einen Messvorgang geprüft. Der Messvorgang liefert ein Ergebnis: Einen Zahlenwert für das Merkmal und ein Überdeckungsintervall zusammen mit einem Vertrauensniveau. Anstelle von Überdeckungsintervall und Vertrauensniveau kann auch direkt eine Wahrscheinlichkeitsdichteverteilung angegeben werden, ist aber sehr unüblich in der industriellen Praxis. Für die Bewertung, ob das gefertigte Werkstück mit der Vorgabe der Konstruktion übereinstimmt, ob es konform ist, werden Messergebnis und Toleranzvorgabe verglichen.

Als Ergänzung (*Supplement*) zum „Guide of Uncertainty“ gibt es das Dokument *Evaluation of measurement data - The role of measurement uncertainty in conformity assessment*, das darlegt, wie Konformitätsbewertungen vorzunehmen sind.

`https://www.bipm.org/documents/20126/2071204/JCGM_106_2012_E.pdf`

Dort heißt es in Paragraph 7.1.1

> An item conforms to a specified requirement, if the true value of its associated property $Y$ lies in the tolerance interval. Knowledge of $Y$ is conveyed by a probability density function $p(y|X_1, \ldots, X_J)$ so that a statement of conformity is always an inference, with some probability of being true. Denoting the set of permissible (conforming) values $Y$ by $C$, the conformance probability, denoted by $P_c$, is given by
>
> $$P_c = P(Y \in C|X_1, \ldots, X_J) = \int_C p(y|X_1, \ldots, X_J)\mathrm{d}y. \tag{6.1}$$

Im Originaldokument werden Sie eine etwas andere Schreibweise für die Bezeichner in der Formel vorfinden. Hier ist es so aufgeschrieben, wie es zu der Notation innerhalb dieses Vorlesungsskriptes, insbesondere zu Kapitel 4, passt. Für die Toleranz wird in der Richtlinie zur Konformitätsbewertung zur Wahrung der Allgemeingültigkeit eine Menge $C$ angegeben. Falls die Größe $Y$ eine skalarwertige Größe ist wie bei dem Beispiel, anhand dessen wir in Kapitel 4 das Prinzip der bayesischen Statistik illustriert haben, so steht $C$ für ein Intervall $C = [T_L, T_U]$ im Falle der zweiseitigen Grenzen, $C = [-\infty, T_U]$ für den Fall, dass es eine Obergrenze gibt, $C = [T_L, \infty]$, dass es eine Untergrenze gibt. Dabei sollen der Index L für „lower limit“ und der Index U für „upper limit“ stehen. Der Bezeichner $T$ ist in der Normung das üblicherweise für Toleranzgrenzen verwendete Symbol und bedeutet an dieser Stelle nicht Testgröße! Er unterscheidet sich von den Testgrößen durch seine Indizes.

Die Wahrscheinlichkeit $P_c$, dass die Beobachtungen $X_1, \ldots, X_J$ innerhalb des Toleranzintervalls $C =$

$[T_\mathrm{L}, T_\mathrm{U}]$ liegen, ist

$$P_\mathrm{c} = \int_{T_\mathrm{L}}^{T_\mathrm{U}} p(y|X_1, \ldots, X_J)\mathrm{d}y. \tag{6.2}$$

Für den Fall, dass von einer normalverteilten Stichprobe ausgegangen werden kann und dass eine Einzelgröße vorliegt, wird aus der Stichprobe $\{X_1, \ldots, X_J\}$ der Schätzer $\bar{y}$ aus einfacher Mittelwertbildung gewonnen ($\bar{y} = \frac{1}{J}\sum_{j=1}^{J} X_j$) und die Varianz als empirische Varianz $s^2 = \frac{1}{J-1}\sum_{j=1}^{J}(X_j - \bar{y})^2$ berechnet und für die Wahrscheinlichkeitsdichte $p$ die Gaußverteilung verwendet

$$P_\mathrm{c} = \frac{1}{\sqrt{2\pi}s}\int_{T_\mathrm{L}}^{T_\mathrm{U}} e^{-\frac{1}{2}\left(\frac{y-\bar{y}}{s}\right)^2}\mathrm{d}y. \tag{6.3}$$

Die Größe $\frac{y-\bar{y}}{s}$ ist eine normierte Zufallsgröße. Die Integrationsgrenzen können gleichfalls normiert werden: $z = \frac{y-\bar{y}}{s}$, $z_\mathrm{L} = \frac{T_\mathrm{L}-\bar{y}}{s}$ und $z_\mathrm{U} = \frac{T_\mathrm{U}-\bar{y}}{s}$, so dass die Tabellenwerke für die kumulative standardnormalverteilte Gaußfunktion oder die Bibliotheksfunktion für die gauß'sche Fehlerfunktion (*error function*) wie folgt verwendet werden kann:

$$P_\mathrm{c} = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{z_\mathrm{U}} e^{-\frac{1}{2}z^2}\mathrm{d}z - \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{z_\mathrm{L}} e^{-\frac{1}{2}z^2}\mathrm{d}z \tag{6.4}$$

d.h.

$$P_\mathrm{c} = \Phi(z_\mathrm{U}) - \Phi(z_\mathrm{L}) \tag{6.5}$$

mit $\Phi(z) = \frac{1}{2}\left(1 + \mathrm{erf}\left(\frac{z}{\sqrt{2}}\right)\right)$. Die Fehlerfunktion ist definiert als

$$\mathrm{erf}(z) = \frac{2}{\sqrt{\pi}}\int_0^z e^{-t^2}\mathrm{d}t \tag{6.6}$$

Die Standardnormalverteilung $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ haben wir mit $\Phi(z)$ bezeichnet. Sie ist wie folgt gegeben:

$$\Phi(z) = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{z} e^{-\frac{1}{2}t^2}\mathrm{d}t \tag{6.7}$$

Mit Hilfe der Toleranzintervalle unterscheidet man zwischen Werten, die mit Vorgaben beispielsweise der Konstruktion konform sind, und nicht konformen Werten. Im Toleranzintervall liegen die konformen Werte. Außerhalb des Toleranzintervalls liegen die nicht konformen Werte. Man kann prinzipiell drei Fälle unterscheiden:

(a) einseitiges Toleranzintervall mit einer unteren (engl. *lower*) Toleranzgrenze $T_\mathrm{L}$;

(b) einseitiges Toleranzintervall mit einer oberen (engl. *upper*) Toleranzgrenze $T_\mathrm{U}$;

(c) zweiseitiges Toleranzintervall mit einer unteren und einer oberen Toleranzgrenze. Die Differenz $T_\mathrm{U} - T_\mathrm{L}$ bezeichnet man als Toleranz.

In Abb. 6.1 sind diese drei Fälle dargestellt.

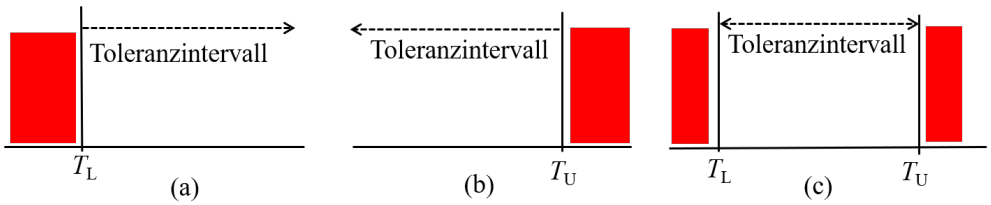



Abbildung 6.1: Toleranzintervalle
(a) einseitiges Toleranzband mit unterer Toleranzgrenze, (b) einseitiges Toleranzintervall mit oberer Toleranzgrenze (c) zweiseitiges Toleranzintervall

**Beispiel: Geschwindigkeitsmessung**

*Aufgabe:* Berechnen Sie die Konformitätswahrscheinlichkeit $P_c$ bei einer Geschwindigkeitsmessung. Die zulässige Geschwindigkeit sei 50 km/h. Der gemessene Wert des Autos liegt bei 52 km/h. Die Geschwindigkeitsmessung sei normalverteilt mit einer Standardunsicherheit $u_y = 1$ km/h. Berechnen Sie die Konformitätswahrscheinlichkeit $P_c$, d.h. die Wahrscheinlichkeit, dass das Auto innerhalb der zugelassenen Geschwindigkeit gefahren ist.

*Lösung:*

Geschwindigkeitsbegrenzung: $T_U = 50$ km/h

Gemessener Wert: $\bar{y} = 52$ km/h

Standardmessunsicherheit: $u_y = 1$ km/h

Die Konformitätswahrscheinlichkeit ergibt sich dann zu:

$$P_c = \Phi\left(\frac{T_U - \bar{y}}{u_y}\right) = \Phi(-2) = 0.023$$

Der gemessene Wert von 52 km/h liegt mit einer Wahrscheinlichkeit von 2,3 % innerhalb des Toleranzintervalls, siehe Abb. 6.2

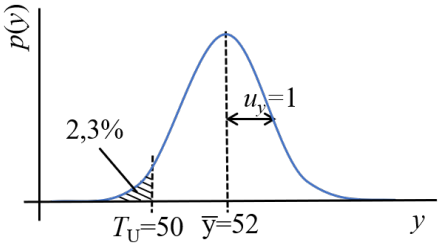



Abbildung 6.2: Beispiel: Konformitätswahrscheinlichkeit bei einer Geschwindigkeitsmessung

## 6.2 Konformitätswahrscheinlichkeit und Risiko

Die wahrscheinlichkeitsbasierte Betrachtung der Konformität ermöglicht die *Quantifizierung des Risikos einer Fehlbewertung*. Werden beispielsweise bei der Produktion von Widerständen die Widerstandswerte gemessen, so kann ein Toleranzintervall $[T_L, T_U]$ definiert werden, in denen die Widerstände noch ok sind und somit auf den Markt gebracht werden. Für den Fall eines einseitigen Toleranzinter-

valls ist dies in Abb. 6.3 schematisch dargestellt. Das Risiko einer Fehlbewertung ist dann gegeben durch $1 - P_c$.

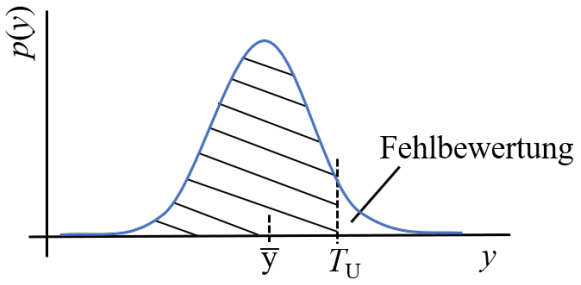



Abbildung 6.3: Beispiel einer Messung bei einseitigem Toleranzintervall. Der schraffierte Bereich zeigt die Konformitätswahrscheinlichkeit $P_c$. Das Risiko einer Fehlbewertung ist gegeben durch $1 - P_c$

Durch Einführen von Akzeptanzgrenzen und Sicherheitsabständen lässt sich das Risiko einer Fehlbewertung steuern.

Eine Fehlbewertung kann sowohl eine fälschliche Annahme als auch eine fälschliche Ablehnung sein. Das im folgenden dargestellte Konzept stammt aus dem Dokument [JCGM106]. Es werden – neben den **Toleranzgrenzen** $T_L$ und $T_U$ – unterere und oberere **Akzeptanzgrenzen** $A_L$, $A_U$ eingeführt. In folgender Abb. 6.4 ist dies schematisch verdeutlicht. Die Differenz zwischen Toleranzgrenze und

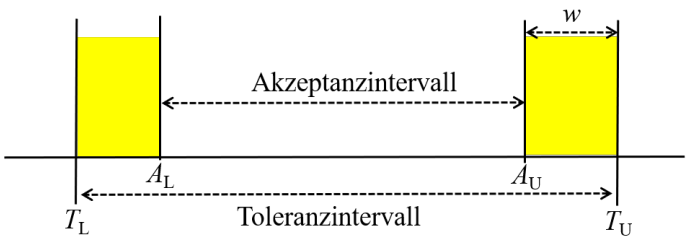



Abbildung 6.4: Toleranz- und Akzeptanzintervall. Die Differenz zwischen Toleranzgrenze und Akzeptanzgrenze wird als Sicherheitsabstand / Sicherheitsband bezeichnet.

Akzeptanzgrenze definiert einen Längenparameter und wird Sicherheitsabstand $w$ genannt:

$$w = T_U - A_U \tag{6.8}$$

In vielen Anwendungen wird dieser Längenparameter als ein Vielfaches der erweiterten Messunsicherheit $U$ angenommen [JCGM106]. Mit der Wahl der Lage des Akzeptanzintervalls wird das Risiko einer Fehlentscheidung der jeweiligen Situation angemessen ausbalanciert. Es gibt 4 mögliche Resultate einer Konformitätsbewertung. Da wir den tatsächlichen („wahren“) Wert nicht kennen, können wir nur auf Grund der Messung entscheiden. Da die Messung jedoch mit einer Messunsicherheit verbunden ist, erhält man bei der Messung eben nicht den wahren Wert. Es kann dadurch bspw. der Fall eintreten, dass ein Produkt eigentlich innerhalb der zulässigen Toleranzen liegt, jedoch durch die Messung ausgesondert wird. In Abb. 6.5 sind die 4 Resultate einer Konformitätsbewertung dargestellt.

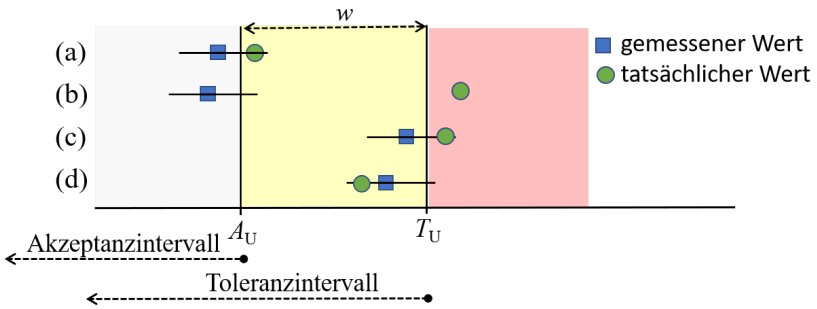



Abbildung 6.5: Resultate der Konformitätsbewertung am Beispiel einseitiger Akzeptanz- und Toleranzgrenzen. (a) Korrekte Annahme, (b) Falsche Annahme -> Konsumentenrisiko, (c) Korrekte Rückweisung, (d) Falsche Rückweisung -> Produzentenrisiko

(a) **Korrekte Annahme / Akzeptanz**: In diesem Fall liegen gemessener und tatsächlicher Wert innerhalb des Toleranzbandes. Dies ist eine richtige Entscheidung.

(b) **Falsche Annahme / Akzeptanz**: Der gemessene Wert liegt innerhalb des Akzeptanzbandes, der tatsächliche Wert jedoch außerhalb des Toleranzbandes. Hier wurde bspw. das Produkt angenommen, obwohl es außerhalb der Spezifikationen ist. Dieses Produkt würde auf den Markt gebracht werden, obwohl es nicht innerhalb der Toleranzen ist. Der Konsument hat ein gewisses Risiko, dass das Produkt, das er erhält, nicht konform ist, obwohl es bei einem Inspektionsprozess als konform bewertet wurde. Man spricht hier deshalb auch vom **Konsumentenrisiko**.

(c) **Korrekte Rückweisung**: In diesem Fall liegt der gemessene Wert noch im Toleranzintervall. Das Produkt wird trotzdem verworfen, da es außerhalb des Akzeptanzintervalls liegt. Da der tatsächliche Wert hier außerhalb des Toleranzintervalls liegt, handelt es sich um eine richtige Entscheidung.

(d) **Falsche Rückweisung**: Hier liegen gemessener und tatsächlicher Wert außerhalb des Akzeptanzbandes, jedoch noch innerhalb des Toleranzbandes. Das Produkt wird hier, da es außerhalb des Akzeptanzbandes liegt, fälschlicherweise als Ausschuss deklariert. Der Produzent hat stets ein gewisses Risiko, dass ein Produkt durch den Inspektionsprozess fälschlicherweise als Ausschuss deklariert wird. Deshalb spricht man hier vom **Produzentenrisiko**.

Im einfachsten Fall werden die Akzeptanzgrenzen und die Toleranzgrenzen gleichgesetzt. Es werden also Messwerte akzeptiert, die auf der Toleranzgrenze sind. Der (wahre) Wert findet sich somit mit 50%-iger Wahrscheinlichkeit innerhalb, aber auch genauso wahrscheinlich außerhalb des zulässigen Toleranzbereichs. Da in einem solchen Fall eine fifty-fifty-Chance besteht, die richtige oder falsche Konformitätsentscheidung zu treffen, wird dieses Verfahren als das **shared-risk**-Verfahren bezeichnet (geteiltes Risiko).

Um das Risiko umzuverteilen wird ein Sicherheitsband zwischen Akzeptanz- und Toleranzgrenze eingeführt. Die Länge des Sicherheitsbandes bestimmt das Risiko. Man unterscheidet hier zwischen **überwachte Annahme** (*guarded acceptance*) und **überwachte Ablehnung** (*guarded rejection*). Bei der überwachten Annahme wird das Risiko minimiert, fälschlicherweise ein nicht konformes Produkt für gut zu befinden. Hierzu wird die Akzeptanzgrenze tief in das Toleranzintervall hineingelegt, so dass

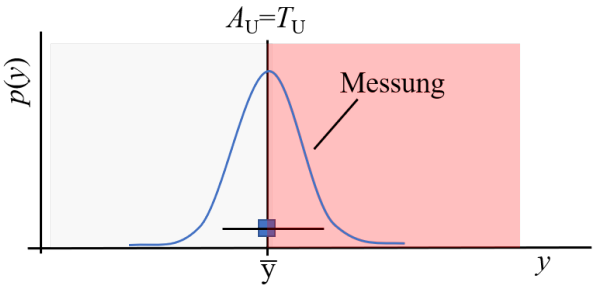



Abbildung 6.6: Beispiel für *shared risk*: Die Akzeptanzgrenze ist gleich der Toleranzgrenze und der Messwert liegt auf dieser Grenze.

nur solche Messwerte akzeptiert werden, deren zugehörige Unsicherheitsverteilung darauf schließen lassen, den (wahren) Wert mit großer Wahrscheinlichkeit innerhalb des Toleranzbandes zu finden. Der Sicherheitsabstand $w = T_U - A_U$ ist größer als Null. Die überwachte Annahme spielt bspw. bei Produkten, die man in den Verkehr bringen will, eine Rolle. Man will, dass die Produkte konform mit den Spezifikationen sind.

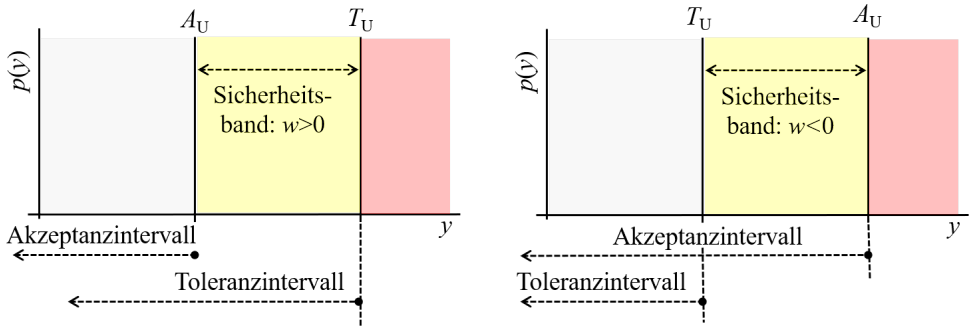



Abbildung 6.7:
Beispiele für überwachte Annahme (links) und überwachte Rückweisung / Ablehnung (rechts).

Bei der überwachten Ablehnung wird das Risiko, dass man zu Unrecht eine Übertretung des Toleranzbandes festgestellt hat, minimiert. Der Sicherheitsabstand $w = T_U - A_U$ ist kleiner als Null. Dies findet bspw. Anwendung bei der Geschwindigkeitsüberwachung im Straßenverkehr und entspricht der juristischen Entscheidungsregel „in dubio pro reo“ (lat. für „im Zweifel für den Angeklagten“).

Mit Hilfe der Konformitätswahrscheinlichkeiten $P_c$ können das **spezifische Konsumentenrisiko** und das **spezifische Produzentenrisiko** berechnet werden. Unter dem spezifischen Konsumentenrisiko versteht man die Wahrscheinlichkeit, dass ein einzelner akzeptierter Gegenstand oder ein Produkt angenommen / akzeptiert wird, obwohl er/es nicht konform ist, d.h. nicht innerhalb der Toleranzgrenzen liegt (siehe oben, Fall (b)). Das spezifische Konsumentenrisiko berechnet sich zu $1-P_c$. Das spezifische Produzentenrisiko ist definiert als die Wahrscheinlichkeit, dass ein einzelner abgelehnter Gegenstand oder ein Produkt konform gewesen wäre. Die Wahrscheinlichkeit, dass ein abgelehnter Gegenstand/-Produkt doch konform gewesen wäre, entspricht der Konformitätswahrscheinlichkeit $P_c$. Die beiden spezifischen Risiken hängen u.a.vom Messwert und Sicherheitsabstand ab. Die Risiken sind maximal, wenn der Messwert $\bar{y} = A_U$ ist. Ein positiver Sicherheitsabstand beeinflusst die beiden Risiken in komplementärer Weise. Ein positiver Sicherheitsabstand verkleinert das Konsumentenrisiko und er-

höht das Produzentenrisiko. Ein negativer Sicherheitsabstand verkleinert das Produzentenrisiko und erhöht das Konsumentenrisiko. Für den Fall „kein Sicherheitsabstand“ haben wir wieder den Grenzfall „geteiltes Risiko“.

Neben den spezifischen Risiken werden im [JCGM106] auch die globalen Risiken definiert. Sie geben bspw. die mittlere Wahrscheinlichkeit der Fehleinschätzung basierend auf einem Messprozess an oder die mittlere Wahrscheinlichkeit einer Fehlbewertung über eine große Anzahl durchgeführter Messungen oder die mittlere Wahrscheinlichkeit der Fehlbewertung durch eine zukünftige Messung an. Das globale Risiko ist wichtig für die Planung und hat globale Auswirkungen. Man unterscheidet auch hier zwischen globalem Konsumentenrisiko und globalem Produzentenrisiko. Gegeben sei das Priorwissen $p_0(y)$ über die Messgröße $Y$ sowie die durchgeführte Messung mit den Messwerten $X_1, \ldots, X_J$. Die durchgeführte Messung wird durch die Wahrscheinlichkeitsdichtefunktion $p(x|y)$ beschrieben. Mit Hilfe des Bayes-Theorems ergibt sich die PDF der Posterior proportional zu $p_0(y) \cdot p(x|y)$. Für das **globale Konsumentenrisiko** $R_\mathrm{C}$ wird über das Akzeptanzintervall $A$ und über den Bereich außerhalb des Toleranzintervalls $\tilde{C}$ integriert:

$$R_\mathrm{C} = \int_{\tilde{C}} \int_{A} p_0(y) \cdot p(x|y) \, \mathrm{d}x \, \mathrm{d}y. \tag{6.9}$$

Für das **globale Produzentenrisiko** $R_\mathrm{P}$ wird über den Bereich außerhalb des Akzeptanzintervalls $\tilde{A}$ und über das Toleranzintervall $C$ integriert

$$R_\mathrm{P} = \int_{C} \int_{\tilde{A}} p_0(y) \cdot p(x|y) \, \mathrm{d}x \, \mathrm{d}y. \tag{6.10}$$

Ein aus der Richtlinie zur Konformitätsprüfung [JCGM106] entnommenes Beispiel zeigt sehr anschaulich, wie durch eine dem Produktionsprozess nachgeschaltete Qualitätsprüfung das Risiko signifikant minimiert, Ausschuss auszuliefern.

Es sollen Widerstände mit einem nominalen Widerstandswert $y_0 = 1500\ \Omega$ produziert werden (Vorgabe/ Zielwert). Die Toleranzgrenzen sind wie folgt spezifiziert:

$$T_\mathrm{L} = 1499.80\ \Omega \quad \text{und} \quad T_\mathrm{U} = 1500.20\ \Omega$$

Der Erwartungswert des Widerstands sowie die Streuung der Widerstandswerte durch den Herstellungsprozess sind dem Menschen nicht bekannt, aber wir betrachten dies für die Abschätzung der Risiken, als wüssten wir diese. Wir verwenden als *wahren* Erwartungswert den Wert der Zielvorgabe ein und als *wahre* Streuung den Wert

$$\sigma_0 = 0.12\ \Omega,$$

der daraus gewonnen wurde, dass sich der Hersteller bei Einführung der Produktionslinie ein ultrapräzises Ohmmeter ausgeliehen hatte, dessen Unsicherheit kleiner ist als 0.001 Ω. Die Wahrscheinlichkeitsdichteverteilung der produzierten Widerstandswerte ist der Prior $p_0(y)$ mit

$$p_0(y) \;=\; \frac{1}{\sqrt{2\pi}\,\sigma_0} e^{-\frac{1}{2}\left(\frac{y-y_0}{\sigma_0}\right)^2} \;=\; \frac{1}{\sqrt{2\pi}\cdot 0.12} e^{-\frac{1}{2}\left(\frac{y-1500}{0.12}\right)^2}. \tag{6.11}$$

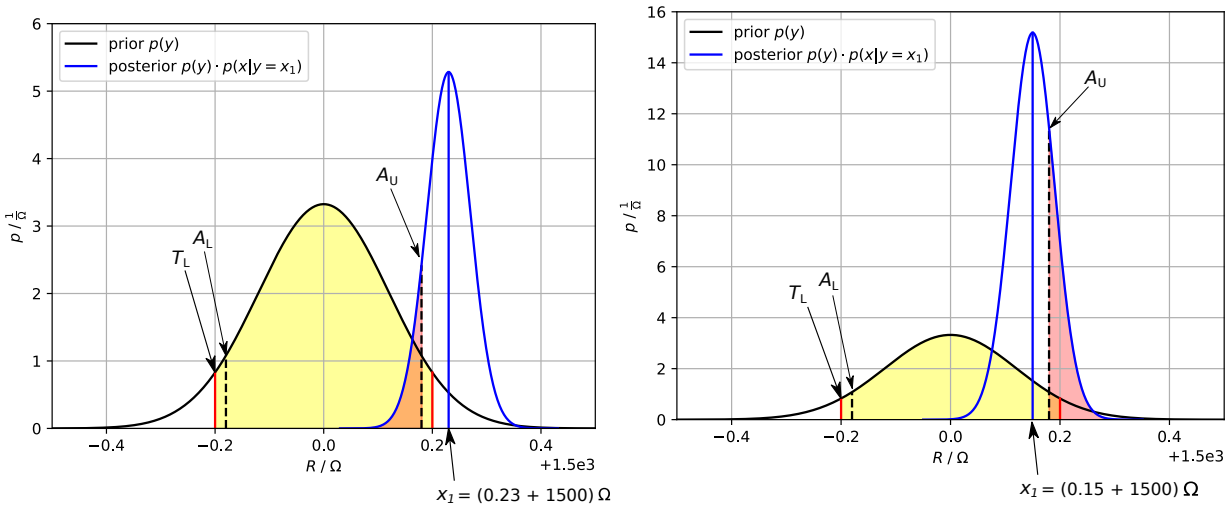



Abbildung 6.8: Veranschaulichung zur Berechnung der globalen Risiken, *links:* des Konsumenten bzw. Käufers, (*rechts*) des Produzenten bzw. Herstellers

Wegen der Unsicherheit des Messvorgangs mit dem herstellereigenen Ohmmeter, das er in seiner Qualitätsprüfung, also bei der Inspektion, einsetzt, ist nicht sichergestellt, dass wenn ein Widerstand als außerhalb der Fertigungstoleranz liegend, also außerhalb der Intervalls $[T_L, T_U]$ gemessen wird, dass er wirklich außerhalb liegt. Das in diesem Beispiel in der Qualitätsprüfung verwendete Ohmmeter hat eine Unsicherheit $u$ von

$$\sigma = 0.04\ \Omega,\ \text{d.h.}\quad u = 0.04\ \Omega\quad \text{bzw.}\quad U(k=2) = 0.08\ \Omega$$

Es kann zum Nachteil des Käufers eines Widerstands passieren, dass der *wahre* Wert $x_1$ eines einzelnen Bauteils außerhalb der Toleranzgrenzen liegt, dass aber das Ohmmeter der Qualitätsprüfung einen Wert misst, der innerhalb des Akzeptanzintervalls liegt. Abb. 6.8, *links*, zeigt ein Beispiel, bei dem der *wahre* Widerstandswert $y = x_1 = 1500.23\,\Omega$ beträgt. Die Wahrscheinlichkeitsdichteverteilung für die Werte, die das Ohmmeter für das Bauteil mit $x_1 = 1500.23\,\Omega$ anzeigt, ist

$$p(x|y = x_1) \;=\; \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{1}{2}\left(\frac{x-x_1}{\sigma}\right)^2} \;=\; \frac{1}{\sqrt{2\pi}\cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-1500.23}{0.04}\right)^2}. \tag{6.12}$$

Das Produkt

$$p(x|y = x_1)\cdot p_0(y = x_1) \;=\; \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{1}{2}\left(\frac{x-x_1}{\sigma}\right)^2} \frac{1}{\sqrt{2\pi}\,\sigma_0}\, e^{-\frac{1}{2}\left(\frac{x_1-y_0}{\sigma_0}\right)^2} \tag{6.13}$$

mit Einsetzen der Zahlenwerte also

$$p(x|y = x_1)\cdot p_0(y = x_1) \;=\; \frac{1}{\sqrt{2\pi}\cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-1500.23}{0.04}\right)^2} \frac{1}{\sqrt{2\pi}\cdot 0.12} e^{-\frac{1}{2}\left(\frac{1500.23-1500}{0.12}\right)^2}$$

ist als blaue Kurve dargestellt, während der Prior als schwarze Kurve in dem Diagramm in Abb. 6.8, *links*, eingezeichnet ist.

Es kann zum Nachteil des Herstellers passieren, dass der *wahre* Wert eines einzelnen Bauteils $x_1$ innerhalb der Toleranzgrenzen - sogar innerhalb des Akzeptanzintervalls - liegt, dass aber das Ohmmeter der Qualitätsprüfung einen Wert misst, der außerhalb des Akzeptanzintervalls liegt. Abb. 6.8, *rechts*,

zeigt ein Beispiel, bei dem der *wahre* Widerstandswert $y = x_1 = 1500.15\,\Omega$ beträgt. Hier sind das Produkt

$$p(x|y = x_1) \cdot p_0(y = x_1) \;=\; \frac{1}{\sqrt{2\pi} \cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-1500.15}{0.04}\right)^2} \frac{1}{\sqrt{2\pi} \cdot 0.12} e^{-\frac{1}{2}\left(\frac{1500.15-1500}{0.12}\right)^2}$$

wieder als blaue Kurve und der Prior als schwarze Kurve zu sehen.

Die roten Flächen unter den Kurven der beiden Diagramme in Abb. 6.8 zeigen jeweils die Wahrscheinlichkeit dafür, dass im Falle *links* mit $y = x_1 = 1500.23\,\Omega$ der schlechte Widerstand mit einen Wert innerhalb des Akzeptanzintervalls gemessen wird, folglich als gut verkauft wird, und dass im Falle *rechts* mit $y = x_1 = 1500.15\,\Omega$ der gute Widerstand mit einen Wert außerhalb des Akzeptanzintervalls gemessen wird, folglich als schlecht verworfen wird.

Berechnet man für alle Werte $x_1$, die außerhalb des Toleranzintervalls die roten Flächen der Teile solcher Produktkurven $p(x|y = x_1) \cdot p_0(y = x_1)$ d.h. integriert man $x$ über diesen Bereich wie im linken Diagramm, um die Wahrscheinlichkeiten, dass schlechte Widerstände als gut gemessen und somit verkauft werden, zu bestimmen und integriert dann noch über alle diese Werte $x_1$, so erhält man die Wahrscheinlichkeit des Risikos, dass der Käufer / Konsument trotz Qualitätsprüfung Ausschussware erhält. Diese Wahrscheinlichkeit heißt **globales Konsumentenrisiko**.

Berechnet man für alle Werte $x_1$, die innerhalb des Toleranzintervalls die roten Flächen der Teile solcher Produktkurven $p(x|y = x_1) \cdot p_0(y = x_1)$ d.h. integriert man $x$ über diesen Bereich wie im rechten Diagramm, um die Wahrscheinlichkeiten, dass gute Widerstände als schlecht gemessen und somit als Ausschuss verworfen werden, zu bestimmen und integriert dann noch über alle diese Werte $x_1$, so erhält man die Wahrscheinlichkeit des Herstellers trotz Qualitätsprüfung gute Ware vernichtet. Diese Wahrscheinlichkeit heißt **globales Produzentenrisiko**.

Dieses Beispiel zeigt, dass der Aufwand lohnt, in einen Qualitätssicherungsprozess zu investieren.

Die Konformitätswahrscheinlichkeit $P_c$, Gl. (6.3), liegt in diesem Beispiel bei

$$P_c = \frac{1}{\sqrt{2\pi}s} \int_{T_L}^{T_U} e^{-\frac{1}{2}\left(\frac{y-\bar{y}}{s}\right)^2} \mathrm{d}y = \frac{1}{\sqrt{2\pi} \cdot 0.12} \int_{T_L=1499.80}^{T_U=1500.20} e^{-\frac{1}{2}\left(\frac{y-1500}{0.12}\right)^2} \mathrm{d}y \approx 0.905$$

was bedeutet, dass im Rahmen des Produktionsprozesses etwa 90% der Widerstände konform sind, jedoch 10% der Widerstände, die auf den Markt gebracht würden, nicht konform wären. Das Konsumentenrisiko liegt somit bei 10% Ausschussware.

Die Akzeptanzgrenzen werden innerhalb des Toleranzintervalls gewählt, um das Konsumentenrisiko zu reduzieren:

$$A_L = 1499.82\ \Omega \quad \text{und} \quad A_U = 1500.18\ \Omega$$

Das Sicherheitsband beträgt $w = (1500.20 - 1500.18)\ \Omega = 0.02\ \Omega = 0.25 \cdot U$

Im Vergleich zu den 10 % Ausschuss liefert

- das globale Konsumentenrisiko, Gl.(6.9),

$$R_{\mathrm{C}} = \int_{\tilde{C}} \int_{A} p_0(y)\; p(x|y)\; \mathrm{d}x\; \mathrm{d}y \tag{6.14}$$

d.h.

$$R_{\mathrm{C}} = \int\limits_{-\infty}^{T_{\mathrm{L}}} \mathrm{d}y\; p_0(y) \int\limits_{A_{\mathrm{L}}}^{A_{\mathrm{U}}} \mathrm{d}x\; p(x|y) \;+\; \int\limits_{T_{\mathrm{U}}}^{\infty} \mathrm{d}y\; p_0(y) \int\limits_{A_{\mathrm{L}}}^{A_{\mathrm{U}}} \mathrm{d}x\; p(x|y)$$

mit

$$p(x|y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-y}{\sigma}\right)^2} = \frac{1}{\sqrt{2\pi}\cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-y}{0.04}\right)^2} \tag{6.15}$$

und nach Einsetzen der Zahlenwerte

$$R_{\mathrm{C}} = \int\limits_{-\infty}^{T_{\mathrm{L}}} \mathrm{d}y\; \frac{1}{\sqrt{2\pi}\cdot 0.12} e^{-\frac{1}{2}\left(\frac{y-1500}{0.12}\right)^2} \int\limits_{A_{\mathrm{L}}}^{A_{\mathrm{U}}} \mathrm{d}x\; \frac{1}{\sqrt{2\pi}\cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-y}{0.04}\right)^2}$$

$$+ \int\limits_{T_{\mathrm{U}}}^{\infty} \mathrm{d}y\; \frac{1}{\sqrt{2\pi}\cdot 0.12} e^{-\frac{1}{2}\left(\frac{y-1500}{0.12}\right)^2} \int\limits_{A_{\mathrm{L}}}^{A_{\mathrm{U}}} \mathrm{d}x\; \frac{1}{\sqrt{2\pi}\cdot 0.04} e^{-\frac{1}{2}\left(\frac{x-y}{0.04}\right)^2} \;\approx\; 1\ \%$$

- Das globale Produzentenrisiko berechnet sich mit Gl.(6.10) zu

$$R_{\mathrm{P}} = \int_{C} \int_{\tilde{A}} p_0(y)\; p(x|y)\; \mathrm{d}x\; \mathrm{d}y \tag{6.16}$$

$$= \int\limits_{T_{\mathrm{L}}}^{T_{\mathrm{U}}} \mathrm{d}y\; p_0(y) \left( \int\limits_{-\infty}^{A_{\mathrm{L}}} \mathrm{d}x\; p(x|y) + \int\limits_{A_{\mathrm{U}}}^{\infty} \mathrm{d}x\; p(x|y) \right) \approx 7\ \%$$

Die beiden Integrale Gl. (6.14) und Gl. (6.16) werden numerisch gelöst, siehe auch [JCGM106].

Die Wahrscheinlichkeitsaussagen liefen Größenordnungen, über die man sich vorstellen kann, dass beispielsweise von 100 produzierten Widerständen um die 90 Bauteile im Produktionsprozess 90 innerhalb der Toleranzen liegen und damit in etwa so 10 Bauteile Ausschuss sind. Wenn es einen Inspektionsprozess zur Qualitätssicherung gibt, so kann es passieren, dass von 90 guten, innerhalb der Toleranz liegenden Bauteilen vielleicht um die 7 fälschlicherweise als nicht konform ausgemustert. Umgekehrt kann es passieren, dass von 10 Ausschussteilen eines fälschlicherweise akzeptiert und somit an einen Kunden verkauft wird.

Dieses Beispiel veranschaulicht, dass sie eine Qualitätsprüfung lohnt: Durch sie wurde das Risiko des Käufers, Ausschussware geliefert zu bekommen, in diesem Beispiel von knapp 10% auf ungefähr 1% reduziert, und damit das Problem von Reklamation und Regressansprüchen signifikant reduziert.

Matlab/Octave-Code zur numerischen Berechnung des Konsumenten- und Produktionsrisikos:

```
1  function konform_example_R()
2  step = 0.0002;
3  perc = '%';
4
```

```
  gaussian = @(x, mu, sigma) exp(-0.5*((x - mu) / sigma).^2) / (sigma * sqrt(2*pi));

% -----
  y0 = 1500;
  s0 = 0.12;
  T_L = 1499.80;
  T_U = 1500.20;
  A_L = 1499.82;
  A_U = 1500.18;
  mininf = T_L - 3*s0;
  maxinf = T_U + 3*s0;

  y = [A_L:step:A_U];
  prior = step * gaussian(y, y0, s0);
  P_c = sum(prior);
  printf('spezifisches Konsumentenrisiko bzgl A ..................: %3.0f %c\n', ...
    100 - 100*P_c, perc);

  y = [T_L:step:T_U];
  prior = step * gaussian(y, y0, s0);
  P_c = sum(prior);
  printf('spezifisches Konsumentenrisiko bzgl T Gl (21) in JCGM106: %3.0f %c\n', ...
    100 - 100*P_c, perc);

% inspection device - instrument uncertainty
  s_insp = 0.04;

% -------
% global producer risk:
  x_L = [mininf:step:A_L]'; %'
  x_U = [A_U:step:maxinf]'; %'

  n_y = length(y);
  n_xL = length(x_L);
  n_xU = length(x_U);

  px_giveny_L = step * gaussian(x_L * ones(1,n_y), ones(n_xL,1) * y, s_insp);
  px_giveny_U = step * gaussian(x_U * ones(1,n_y), ones(n_xU,1) * y, s_insp);

  posterior_L = (ones(n_xL,1)*prior) .* px_giveny_L;
  posterior_U = (ones(n_xU,1)*prior) .* px_giveny_U;
  R_p = sum(posterior_L(:)) + sum(posterior_U(:));
  printf('globales Produzentenrisiko: %3.0f %c\n', 100*R_p, perc);

```

```
%-------
% global consumer risk

  x = [A_L:step:A_U]'; %'
  y_L = [mininf:step:T_L];
  y_U = [T_U:step:maxinf];

  n_x = length(x);
  n_yL = length(y_L);
  n_yU = length(y_U);
  prior_L = step * ones(n_x,1) * gaussian(y_L, y0, s0);
  prior_U = step * ones(n_x,1) * gaussian(y_U, y0, s0);
  px_giveny_L = step * gaussian(x * ones(1,n_yL), ones(n_x,1) * y_L, s_insp);
  px_giveny_U = step * gaussian(x * ones(1,n_yU), ones(n_x,1) * y_U, s_insp);
  posterior_L = prior_L .* px_giveny_L;
  posterior_U = prior_U .* px_giveny_U;
  R_c = sum(posterior_L(:)) + sum(posterior_U(:));
  printf('globales Konsumentenrisiko: %3.0f %c\n', 100*R_c, perc);
end
```

## 6.3 ISO 17025, Entscheidungsregeln für die Konformitätsbewertung

Die Norm ISO/IEC 17025:2017 (Allgemeine Anforderungen an die Kompetenz von Prüf- und Kalibrierlaboratorien) fordert Entscheidungsregeln (engl. decision rules) für Konformitätsaussagen. In Kapitel 3.7 der Norm ist der Begriff **Entscheidungsregel** definiert: **Regel, die beschreibt, wie die Messunsicherheit berücksichtigt wird, wenn Aussagen zur Konformität mit einer festgelegten Anforderung getätigt werden**. In Kapitel 7.8.6.1 steht dann: *Wenn eine Aussage zur Konformität zu einer Spezifikation oder Norm gemacht wird, muss das Laboratorium die angewandte Entscheidungsregel dokumentieren. Dabei ist das Risiko (z.B. eine falsche Annahme, eine falsche Zurückweisung oder falsche statistische Annahmen), das mit der angewandten Entscheidungsregel verbunden ist, zu berücksichtigen und die Entscheidungsregel anzuwenden.*
Somit muss eine Konformitätsbewertung das **Risiko berücksichtigen und Messunsicherheiten miteinbeziehen**. Wie wir bereits gesehen haben, muss bei der Konfirmitätsbewertung eine Entscheidung getroffen werden, ob das Produkt die Anforderungen (Toleranzintervalle) unter Berücksichtigung der MU erfüllt.
Abb. 6.9 zeigt drei mögliche Situationen von Messergebnissen und deren Unsicherheiten innerhalb eines Konformitätsintervalls, auf die eine Entscheidungsregel angewendet werden muss. In Abb. 6.9 können wir feststellen, dass der Fall A als konform zu bewerten ist, der Fall C als nicht konform zu bewerten ist. Im Fall B haben wir jedoch eine undefinierte Situation, die ein formales Kriterium (Entscheidungsregel) benötigt, um über die Konformität zu entscheiden.

Entsprechend dem JCGM 106 Dokument unterscheidet man bei der Risikobewertung Fehler Typ I und Typ II. Bei der Durchführung der Konformitätsbewertung gibt es Wahrscheinlichkeiten in Bezug

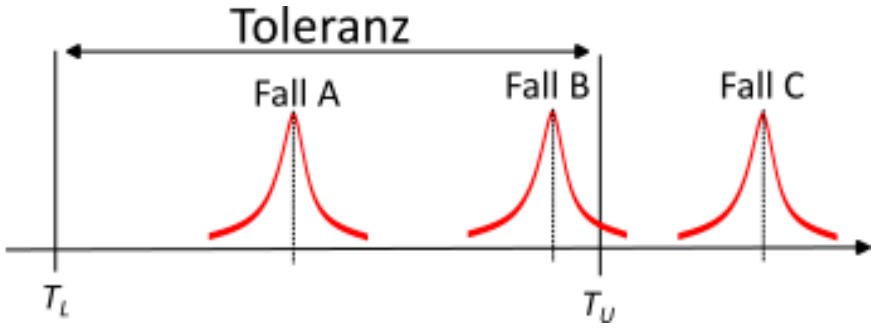



Abbildung 6.9: Konformitätsbewertung - 3 verschiedene Fälle, Fall A: Produkt ist als konform zu bewerten, Fall B: Produkt kann je nach Messung innerhalb oder außerhalb der Toleranz liegen, benötigt eine Entscheidungsregel, Fall C: Produkt ist als nicht konform zu bewerten

Tabelle 6.1: Konformitätswahrscheinlichkeiten in Bezug auf eine richtige oder falsche Entscheidung, Typ-I-Fehler ($\alpha$) ist das Produzentenrisiko und Typ-II-Fehler ($\beta$) ist das Konsumentenrisiko

| | Entscheidung | |
|---|---|---|
| | Annahme von H0 | Rückweisung von H0 |
| $H_0$ (wahr) | korrekte Entscheidung | Typ I Fehler ($\alpha$) |
| $H_0$ (falsch) | Typ II Fehler ($\beta$) | korrekte Entscheidung |

auf zwei Arten von Fehlentscheidungen, eine für den Produzenten Typ I oder $\alpha$ und eine für den Verbraucher Typ II oder mit $\beta$ gekennzeichnet, die als prozentuales Risiko definiert sind. In diesem Rahmen kann die Entscheidungsmatrix wie folgt ausgedrückt werden:

$$P = \begin{bmatrix} (1-\alpha) & \alpha \\ \beta & (1-\beta) \end{bmatrix} \tag{6.17}$$

Die Wahrscheinlichkeiten richtiger Entscheidungen stehen in den Diagonalelementen $(1-\alpha)$ und $(1-\beta)$ und die Risiken falscher Entscheidungen in den Off-Diagonalelementen $\alpha$ und $\beta$ zu finden sind. Diese Fehler sind auch als Fehler vom Typ I ($\alpha$) und Typ II ($\beta$) benannt, was bedeutet, dass konforme Produkte fälschlicherweise zurückgewiesen (Produzentenrisiko) oder nicht konforme Produkte fälschlicherweise akzeptiert werden (Konsumentenrisiko). Die Tabelle 6.1 zeigt eine mögliche Darstellung dieser Fehler, ihre Wahrscheinlichkeiten und ihre Beziehung zur Entscheidung. $H_0$ ist die Nullhypothese, die aufgestellt wird. Abb. 6.10 ist ein Beispiel für ein Akzeptanzintervall, das definiert wurde, um das Konsumentenrisiko ($\beta$) zu minimieren. In anderen Fällen ist es wichtig, das Produzentenrisiko ($\alpha$) zu minimieren, z.B. auch bei Gerichtsverfahren wegen Verletzung von Grenzwerten (siehe Beispiel mit der Geschwindigkeitsmessung). Dieser Ansatz ist in Abb. 6.11 dargestellt. Während im ersten Fall die Sicherheitsgrenzen innerhalb der Toleranzintervalls liegen, befinden sie sich im zweiten Fall die Sicherheitsgrenzen außerhalb des Toleranzintervalls. In Abb. 6.10 liegt der Schwerpunkt also auf einer hohen Sicherheit der korrekten Annahme (überwachte Annahme) und in Abb. 6.11 auf einer hohen Sicherheit der korrekten Ablehnung (überwachte Rückweisung).

In den Fällen, in denen Sicherheitsbänder verwendet werden, die besonders für Messergebnisse mit fester Unsicherheit geeignet sind, besteht eine einfache Strategie zur Festlegung einer Entscheidungsregel

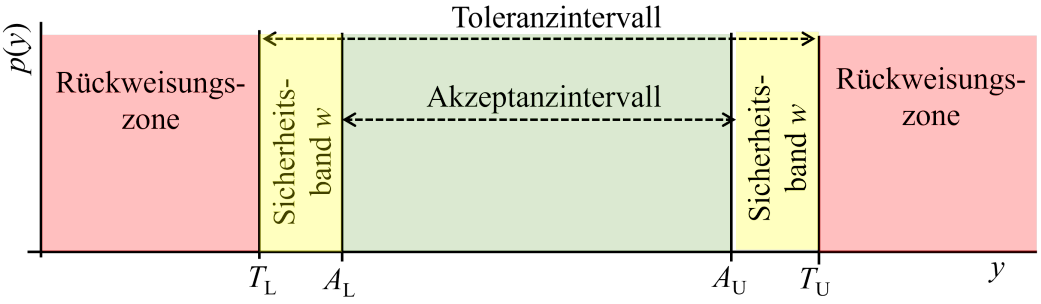



Abbildung 6.10: Beispiel für Bereiche, die für ein Toleranzintervall definiert wurden, um das Konsumentenrisiko $\beta$ zu minimieren

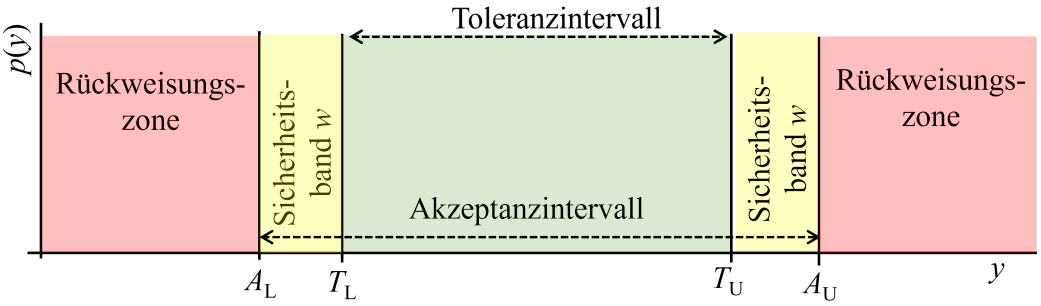



Abbildung 6.11: Beispiel für Bereiche, die für ein Toleranzintervall definiert wurden, um das Produzentenrisiko $\alpha$ zu minimieren

darin, die Messergebnisse mit den Grenzwerten des Akzeptanzintervalls zu vergleichen, wobei sie als konform (akzeptiert) gelten, wenn der gemessene Wert innerhalb dieser Akzeptanzintervalls liegt, und andernfalls als nicht konform (abgelehnt). Wenn die Messergebnisse variable Werte der Unsicherheit aufweisen können, wird ein anderer Ansatz ohne Berücksichtigung von Sicherheitsbändern empfohlen, der idealerweise auf der Definition eines Hypothesentests als Unterstützung für die Entscheidungsregel basiert. Im folgenden stellen wir Entscheidungsregel vor. Voraussetzung hier bei allen Regeln ist, dass die Messung normalverteilt ist.

**(i) Entscheidungsregel für die Konformitätsbewertung mit einer einzigen oberen Toleranzgrenze $T_U$ und ohne ein Sicherheitsband**

Gegeben sei eine einzige obere Toleranzgrenze $T_U$, der Erwartungswert der Messung $\bar{y}$ mit einer Standardmessunsicherheit $u_y$.

Die **Entscheidungsregel** kann dann wie folgt lauten

(Hinweis: $(1-\alpha)$ : Vertrauensniveau, $\alpha$ : Signifikanzniveau)

Annahme, wenn die Hypothese $H_0$ : $P(y \leq T_U) \geq (1-\alpha)$ wahr ist.

Rückweisung, wenn die Hypothese $H_0$ falsch ist, d. h. $P(y \leq T_U) < (1-\alpha)$

Bestimmung der Konformitätswahrscheinlichkeit: $P_C = P(y \leq T_U) = \Phi\left(\frac{T_U - \bar{y}}{u_y}\right)$

Beispiel:

Gegeben ist der Erwartungswert der Messung mit $\bar{y} = 2.7$ mm und einer Standardunsicherheit von $u_y = 0.2$ mm. Als einzelne obere Toleranzgrenze sei $T_U = 3.0$ mm. Es soll eine Konformitätswahrscheinlichkeit $(1-\alpha)$ von mindestens $0.95 = 95\%$ erreicht werden, bzw. der Typ I Fehler $\alpha$ soll kleiner als 5% sein.

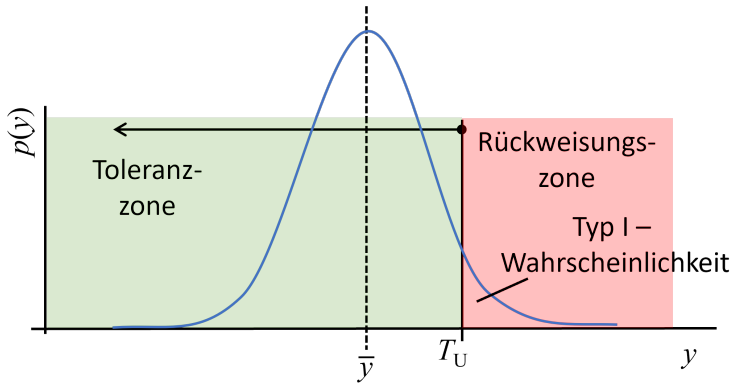



Abbildung 6.12: Beispiel mit einer oberen Toleranzgrenze

Lösung:
Nullhypothese lautet: $H_0: \ P(y \leq 3.0 \text{ mm}) \geq 0.95$ ist wahr

$$P_C = P(y \leq T_U) = \Phi\left(\frac{T_U - \bar{y}}{u_y}\right)$$

$$P_C = \Phi\left(\frac{3.0 - 2.7}{0.2}\right) = \Phi(1.5) \approx 0.933 < 0.95$$

Die Hypothese $H_0$ ist falsch und damit lautet die Entscheidung auf Nicht-Konformität.

**(ii) Entscheidungsregel für die Konformitätsbewertung mit einer einzigen unteren Toleranzgrenze $T_L$ und ohne ein Sicherheitsband**

Gegeben ist eine einzelne untere Toleranzgrenze $T_L$, der Schätzwert der Messung $\bar{y}$ in Kombination

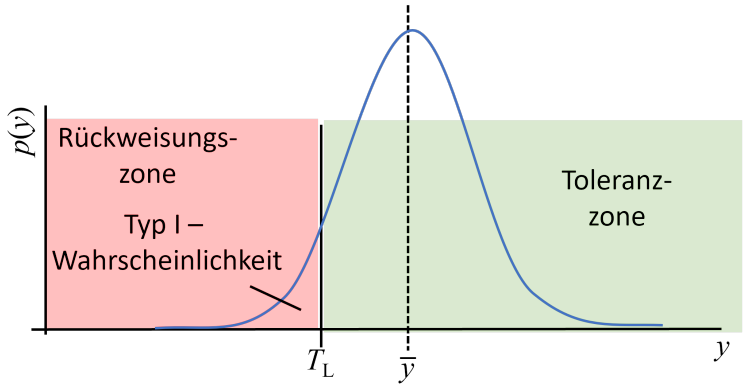



Abbildung 6.13: Beispiel mit einer unteren Toleranzgrenze

mit einer Standardmessunsicherheit $u_y$. Eine Entscheidungsregel mit dem Signifikanzniveau $\alpha$ lautet wie folgt:

Annahme, wenn die Hypothese $H_0: \ P(y \geq T_L) \geq (1 - \alpha)$ wahr ist.
Rückweisung, wenn die Hypothese $H_0$ falsch ist, d. h. $P(y \geq T_L) < (1 - \alpha)$
Testgröße: $P_C = P(y \geq T_L) = 1 - P(y \leq T_L) = 1 - \Phi\left(\frac{T_L - \bar{y}}{u_y}\right) = \Phi\left(\frac{\bar{y} - T_L}{u_y}\right)$

Beispiel:
Gegeben ist ein Schätzwert der Messung $\bar{y} = 0.012$ g mit einer Standardunsicherheit von $u_y = 0.001$ g und eine einzelne untere Toleranzgrenze $T_L = 0.010$g. Es soll auf eine Konformität $(1 - \alpha) = 0.99$

geprüft werden, d.h. der Typ I Fehler $\alpha$ sollte kleiner als 1%
Lösung:
Annahme, wenn die Hypothese $H_0: \ P(y \geq 0.010 \text{ g}) \geq 0.99$ wahr ist.
Die Konformitätswahrscheinlichkeit ergibt sich dann zu:

$$P_C = \Phi\left(\frac{\bar{y} - T_L}{u_y}\right) = \Phi\left(\frac{0.012 - 0.010}{0.001}\right) = \Phi(2.0) \approx 0.977 < 0.99$$

Die Hypothese $H_0$ ist falsch und somit ist das Produkt nicht konform.
**(iii) Entscheidungsregel für die Konformitätsbewertung mit einer einzigen Toleranzgrenze $T_L$ und einem Sicherheitsband $w$**
In diesem Fall kann die Messung $\bar{y} \pm u_y$ mit dem Sicherheitsband bzw. Akzeptanzintervall verknüpft werden, siehe Abb. 6.14.
Für den Fall einer einzelnen oberen Toleranzgrenze $T_U$ bei gegebener Standardunsicherheit $u_y$ und

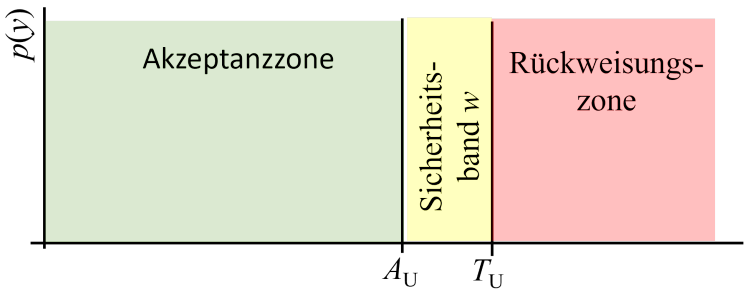



Abbildung 6.14: Sicherheitsband zwischen Akzeptanzgrenze $A_U$ und Toleranzgrenze $T_U$

einer Wahrscheinlichkeit vom Typ I Fehler ($\alpha$), kann die untere Grenze des Sicherheitsbandes (=obere Akzeptanzgrenze) $A_U$ berechnet werden. Unter der Verwendung der Normalverteilung ergibt sich:

$$\Phi\left(\frac{T_U - A_U}{u_y}\right) = 1 - \alpha$$

$$\left(\frac{T_U - A_U}{u_y}\right) = \Phi^{-1}(1 - \alpha)$$

$$A_U = T_U - u_y \cdot [\Phi^{-1}(1 - \alpha)]$$

Beispiel:
Gegeben ist ein Schätzwert der Messung $\bar{y} = 18.9°\text{C}$ mit einer Standardunsicherheit von $u_y = 0.3°\text{C}$, eine obere Toleranzgrenze $T_U = 20.0°\text{C}$. Es soll eine Konformität $(1 - \alpha)$ von 0.95 erreicht werden, d.h. der Fehler vom Typ I ($\alpha$) soll kleiner als 5% sein. Berechne die obere Akzeptanzgrenze $A_U$
Lösung:

$$A_U = T_U - u_y \cdot [\Phi^{-1}(1 - \alpha)] = 20 - 0.3 \cdot [\Phi^{-1}(0.95)] = 20 - 0.3 \cdot 1.64 \approx 19.5°\text{C}$$

Ist Schätzwert der Messung $\bar{y}$ größer als $A_U$, so ist das Produkt nicht konform.
In der Praxis wird das Sicherheitsband häufig mit der Breite der erweiterten Messunsicherheit $U_{95}$ gewählt. Für das obige Beispiel wäre das dann:

$$U_y(k_{95}) = k_{95} \cdot u_y = 2.00 \cdot 0.3°\text{C} = 0.6°\text{C}$$

Damit ergibt sich die Akzeptanzgrenze zu (siehe Abbildung)

$$A_U = T_U - U_y(k_{95}) = 20.0°\text{C} - 0.6°\text{C} = 19.4°\text{C}$$

Im Fall der überwachten Rückweisung berechnet sich die obere Akzeptanzgrenze $A_U$ dann zu:

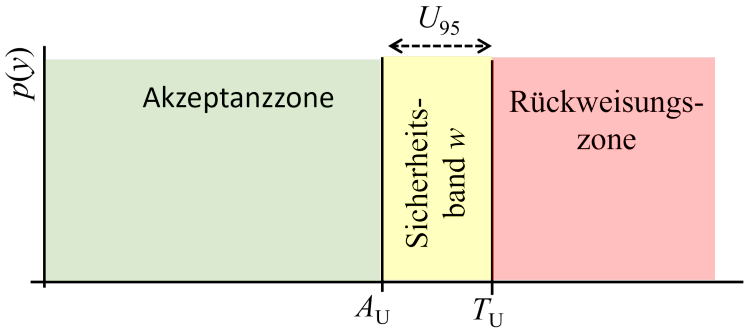



Abbildung 6.15: Sicherheitsband mit einer Breite von $w = U_{95}$ für den Fall der überwachten Annahme.

$$A_U = T_U + u_y \cdot [\Phi^{-1}(1-\alpha)]$$

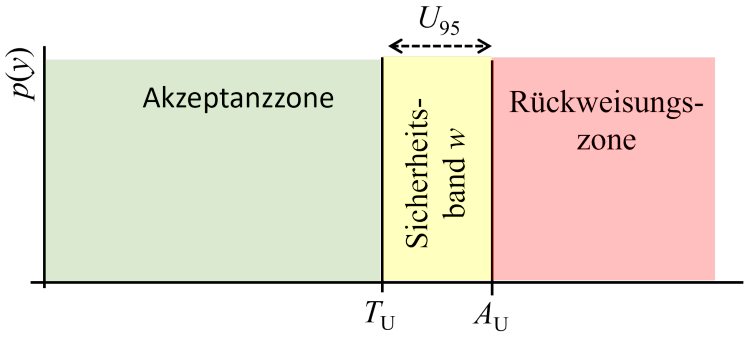



Abbildung 6.16: Sicherheitsband mit einer Breite von $w = U_{95}$ bei einer überwachten Rückweisung

Beispiel:
Zur Überwachung von Geschwindigkeitsbegrenzungen kann die Geschwindigkeit eines Fahrzeugs mit einem Doppler-Radar gemessen werden. Diese Messung kann mit einer relativen Standardunsicherheit u(v)/v von 2 % im Bereich von 50 km/h bis 150 km/h durchgeführt werden. Die Höchstgeschwindigkeit auf einer Autobahn sei auf 100 km/h festgelegt werden. Aufgrund des Grundsatzes "in dubio pro reo" (lateinisch "im Zweifelsfall für den Angeklagten") wird ein Vertrauensniveau von $(1-\alpha) = 0.999$ gefordert. Berechne die obere Akzeptanzgrenze $A_U$.
Lösung:

$$A_U = 100 + 2 \cdot [\Phi^{-1}(0.999)] = 100 + 2 \cdot 3.09 \approx 107 \text{ km/h}$$

Das Sicherheitsband beträgt [100 km/h $\leq v \leq$ 107 km/h]. Liegt der gemessene Wert bei 107 km/h oder darüber, beträgt die Wahrscheinlichkeit, dass die Höchstgeschwindigkeit überschritten wurde,

mindestens 99.9 %.

**(iv) Entscheidungsregel für die Konformitätsbewertung mit Toleranzintervall ohne Sicherheitsband** $w$

Gegeben ist ein Toleranzintervall mit einer unteren Grenze $T_L$ und mit einer oberen Grenze $T_U$, der Schätzwert der Messung $\bar{y}$ mit einer Standardunsicherheit $u_y$. Eine Entscheidungsregel sollte die Konformitätswahrscheinlichkeit $P_C$ unter der Annahme einer Fehlerwahrscheinlichkeit vom Typ I ($\alpha$) definieren. Entscheidungsregel:

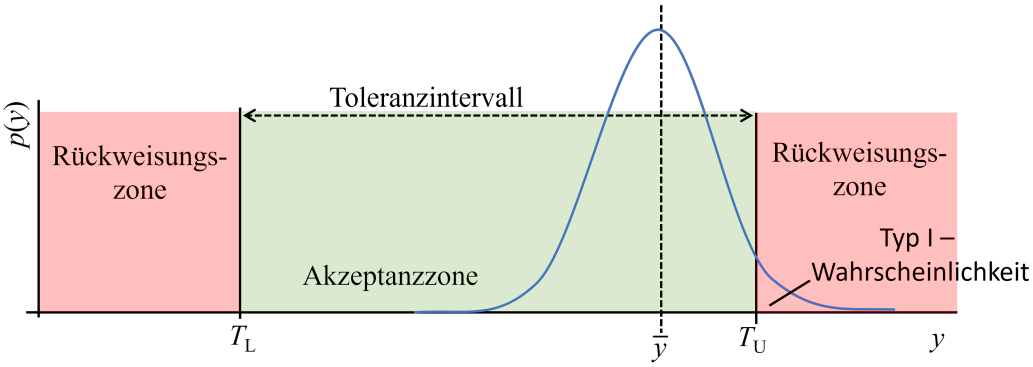



Abbildung 6.17: Beispiel eines Toleranzbandes

Annahme, wenn die Hypothese $H_0: \ P(T_L \leq y \leq T_U) \geq (1-\alpha)$ wahr ist.
Rückweisung, wenn die Hypothese $H_0$ falsch ist, d. h. $P(T_L \leq y \leq T_U) < (1-\alpha)$
Bestimmung der Konformitätswahrscheinlichkeit: $P_C = P(T_L \leq y \leq T_U) = \Phi\left(\frac{T_U-\bar{y}}{u_y}\right) - \Phi\left(\frac{T_L-\bar{y}}{u_y}\right)$

Beispiel:
Gegeben ist der Schätzwert der Messung $\bar{y} = 23.5$ kN verbunden mit einer Standardunsicherheit von $u_y = 0.5$ kN, ein Toleranzintervall von $[20\text{ kN}, 25\text{ kN}]$ und ein Konformitätsvertrauensniveau $(1-\alpha)$ von 0,95 (95%), bzw. ein Signifikanzniveau eines Typ-I-Fehlers $\alpha = 0.05(5\%)$ erreicht werden.
Lösung:
Es wird folgende Annahme getroffen:
Akzeptanz, wenn die Hypothese $H_0: \ P(22 \leq y \leq 25) \geq 0.95$ wahr ist.
Die Konformitätswahrscheinlichkeit $P_C$ ergibt sich zu:

$$P_C = P(T_L \leq y \leq T_U) = \Phi\left(\frac{T_U - \bar{y}}{u_y}\right) - \Phi\left(\frac{T_L - \bar{y}}{u_y}\right)$$

$$P_C = \Phi\left(\frac{25 - 23.5}{0.5}\right) - \Phi\left(\frac{22 - 23.5}{0.5}\right) = \Phi(3.0) - \Phi(-3.0) = 0.9987 - 0.0013 \approx 0.997$$

Da die Konformitätswahrscheinlichkeit mit 99.7 % größer als die geforderten 95 %. Damit ist die Entscheidung konform.

**(v) Entscheidungsregel für die Konformitätsbewertung mit Toleranzintervall und Sicherheitsband** $w$

Die auf ein Toleranzintervall angewandte Konformitätsbewertung kann für den Fall mit Sicherheitsbänder angepasst werden. Für ein Vertrauensniveau $(1-\alpha)$ können wir den Fehler $\alpha$ je zur Hälfte

$(\alpha/2)$ auf links und rechts aufteilen. Ein allgemeiner Ansatz für eine überwachte Annahme lautet:

$$A_U = T_U - U_y \quad \text{und} \quad A_L = T_L + U_y$$

mit $U_y$ ist die erweiterte MU der Messung.

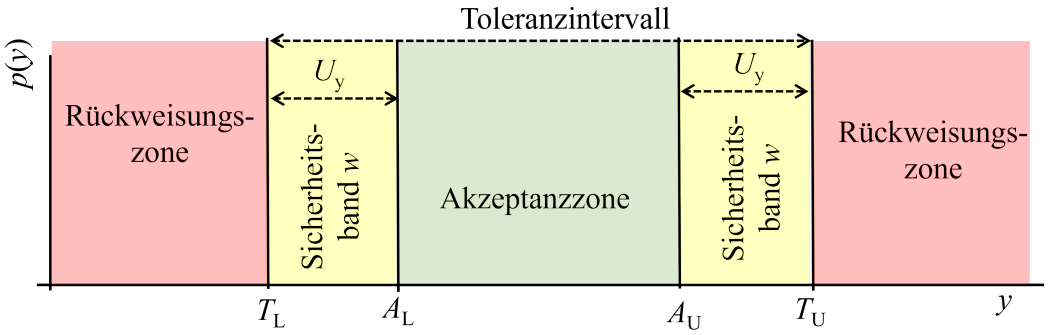



Abbildung 6.18: Beispiel eines Toleranzbandes mit Sicherheitsband $w$ im Falle der überwachten Annahme

Für die überwachte Ablehnung können die Akzeptanzgrenzen wie folgt berechnet werden:

$$A_U = T_U + U_y \quad \text{und} \quad A_L = T_L - U_y$$

# Kapitel 7

# Auswertung von Mess- und Ringvergleichen

## 7.1 Auswertung von Messvergleichen mit Referenzlabor

In dieser Vorlesung wird die Anwendung des t-Tests und des Chi2-Tests auf eines der zentralen Themen der Metrologie gezeigt, welches die Durchführung von Ringvergleichen ist. Wesen der Metrologie ist, dass Messgrößen auf die SI-Einheiten zurückgeführt werden, damit sie weltweit vergleichbar sind. Um die Vergleichbarkeit von Ergebnissen unterschiedlicher gesetzlich geprüfter Laboratorien, seien dies Staatsinstitute verschiedener Länder oder Kalibrierlaboratorien innerhalb eines Landes, zu gewährleisten, werden Ringvergleiche durchgeführt. Dazu wird beispielsweise ein Messobjekt (Prüfkörper) rumgeschickt und jedes beteiligte Labor misst an demselben Objekt eine genau spezifizierte Messgröße nach einem vorgegebenen Verfahren. Um die Ergebnisse miteinander zu vergleichen, werden die statistischen Verfahren der Hypothesentests auf Gleichheit der Mittelwerte und der Standardabweichungen eingesetzt.

Es wird bei der Verwendung des t-Tests danach unterschieden, ob die Nullhypothese getestet wird, dass Mittelwerte der Laboratorien mit einem Erwartungswert (dem Referenzwert) übereinstimmen. Der Referenzwert wird beispielsweise von einem Referenzlabor zur Verfügung gestellt, das die Möglichkeit hatte, mit deutlich mehr Aufwand und genaueren Geräten, messen zu können. Für den Vergleich wird die zu vergleichende Messgröße normiert, wie wir es in der letzten Vorlesung schon kennengelernt hatten.

Wir betrachten die Messergebnisse mit Größenwerten $x_i$ für $i = 1, \ldots, N$ und Unsicherheiten $u_i$ von $N$ Laboratorien (Partner des Ringvergleichs).

Die standardnormalverteilen Zufallsgrößen, die die Differenz zwischen dem Ergebnis eines Labors bezogen auf den Referenzwert repräsentieren, werden auch Z-Scores oder Z-Werte genannt. Sie werden genutzt, wenn z. B. das Messergebnis eines Partners $i$ mit dem Referenzwert (Erwartungswert) verglichen werden soll. Liegt das Messergebnis des Partners $i$ oberhalb des Referenzwertes, so ist der Z-Wert positiv. Liegt das Messergebnis unterhalb des Erwartungswertes, so ist der Z-Wert negativ. Um den Z-Wert zu bestimmen, müssen der Erwartungswert $\mu$ und die Standardabweichung $\sigma$ der zu Grunde liegenden Verteilung bekannt sein. Es reicht nicht aus nur die empirischen Werte (empirischer Erwartungswert, d.h. Mittelwert, und empirische Standardabweichung) aus den Stichproben zu schätzen. Ist $X$ eine Zufallsvariable mit dem Erwartungswert $\mathrm{E}(X) = \mu$ und der Varianz $\mathrm{Var}(X) = \sigma^2$ erhält man die zugehörige normierte Zufallsgröße $Z$ durch:

$$Z = \frac{X - \mu}{\sigma} \tag{7.1}$$

Für den Erwartungswert und die Varianz von $Z$ gilt:

- $\mathrm{E}(Z) = \mathrm{E}\left(\frac{X-\mu}{\sigma}\right) = \frac{1}{\sigma}(\mathrm{E}(X) - \mu) = 0$
- $\mathrm{Var}(Z) = \mathrm{Var}\left(\frac{X-\mu}{\sigma}\right) = \mathrm{Var}\left(\frac{X-\mu}{\sigma}\right) = \frac{1}{\sigma^2}\mathrm{Var}(X) = 1$

In Abb.7.1 ist eine Standardnormalverteilung mit den Z-Scores (Z-Werten) dargestellt. Z-Scores können nur berechnet werden, wenn die zugrunde liegende Verteilung bekannt ist. Im Falle von t-Tests haben wir hingegen auch die Möglichkeit auf die aus der Stichproben geschätzten Parameter für den Erwartungswert und die Varianz zurückzugreifen. In Abb.7.1 ist zusätzlich zu der Größe Z-Score ein

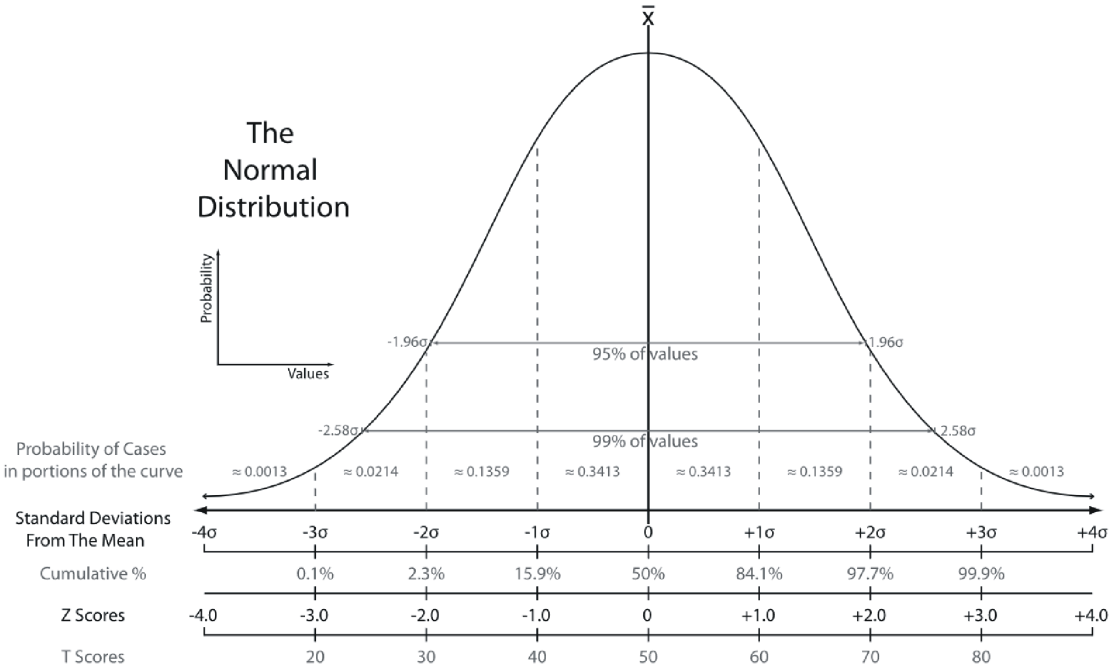



Abbildung 7.1: Die Standard-Normalverteilung $\mathcal{N}(0, \sigma^2)$ mit den entsprechenden Z-Werten. Quelle: https://en.wikipedia.org/wiki/Standard_score

weitere Größe aufgetragen: T-Score. Diese ist direkt proportional zu den Z-Scores nur mit einer anderen Normierung, derart skaliert, dass ihr Erwartungswert 50 ist und die Standardabweichung den Wert 10 annimmt.

Entsprechend der internationalen Norm [ISO13528] kann der Z-Wert für den Vergleich eines Messwertes $x_i$ eines Labors $i$ mit dem Referenzwert $x_{\text{ref}}$, der eine Standardabweichung (Standardunsicherheit) $\sigma_{\text{ref}}$ hat, verglichen werden. Es wird folgender Z-Score berechnet und anschließend bewertet:

$$z_i = \frac{x_i - x_{\text{ref}}}{\sigma_{\text{ref}}} \tag{7.2}$$

Nach [ISO13528] gibt es die folgende übliche Interpretation für die Bewertung:

- Ein Ergebnis mit $|z_i| \leq 2.0$ ist noch akzeptabel.
- Ein Ergebnis mit $2.0 < |z_i| < 3.0$ gibt ein Warnsignal.
- Ein Ergebnis mit $|z_i| \geq 3.0$ wird als nicht akzeptierbar bewertet.

Sind die erweiterten Unsicherheiten sowohl des Referenzlabors $U_{\text{ref}}$ als auch des Teilnehmerlabors des $i$-ten Partners $U_i$ für das Überdeckungsintervall $[-2u; 2u]$ zum 95,45% Vertrauensniveau bekannt, so kann der sogenannte **En-Wert** berechnet werden.

In der vorigen Vorlesung hatten wir die Prüfgröße $T = \frac{x_1 - x_2}{\sqrt{\bar{s}_1^2 + \bar{s}_2^2}}$, die prüft ob zwei Stichproben mit ihren Erwartungswerten $x_1$ und $x_2$ zur selben Grundgesamtheit gehören. Dieser Hypothesentest prüft diese Größe auf $|T| > k$. Der Parameter $k$ steht hier allgemein für das Quantil, also für $z_{1-\alpha/2}$ im Falle

der Verwendung der Standardnormalverteilung wie sie hier in Abb. 7.1 dargestellt ist. Er steht für das Quantil $t_{1-\alpha/2,\nu}$ im Falle der Verwendung der t-Verteilung ($\alpha$: Signifikanzniveau, $\nu$: Freiheitsgrad). Ferner steht der Parameter $k$ auch für das Quantil einer Posteriorverteilung, also den Faktor eines *Credible* Intervalls, weshalb er allgemein *Erweiterungsfaktor* genannt wird.

Wenn wir eine Unsicherheit $u_i$ eines Labors vorliegen haben, die beispielsweise $\bar{s}_i$, d.h. die Standardabweichung eines Mittelwerts, sein kann, und haben wir ein symmetrisches Überdeckungsintervall, wie es bei normalverteilten oder t-verteilten Zufallsgrößen der Fall ist, so ist die halbe Breite des Überdeckungsintervalls $U_i = ku_i$. Dabei wird $U_i$ die *erweiterte Messunsicherheit* genannt.

Jetzt dividieren wir die Prüfgröße $T$ durch das Quantil bzw. den Erweiterungsfaktor $k$

$$\frac{T}{k} = \frac{x_1 - x_2}{k\sqrt{\bar{s}_1^2 + \bar{s}_2^2}} = \frac{x_1 - x_2}{\sqrt{(k\bar{s}_1)^2 + (k\bar{s}_2)^2}}$$

und führen die bei Ringvergleichen allgemein verwendete Bezeichnung $E_n := T/k$ ein, so dass die Prüfgröße mit $U_i = ku_i$ bzw. $U_i = k\bar{s}_i$ wie folgt aussieht:

$$E_\mathrm{n} = \frac{x_i - x_\mathrm{ref}}{\sqrt{U_i^2 + U_\mathrm{ref}^2}} \tag{7.3}$$

Der **En-Wert** gibt an, wie gut der Laborwert $x_i$ mit dem Referenzwert $x_\mathrm{ref}$ übereinstimmt. Es werden hier die erweiterten Messunsicherheiten $U$ für $k = 2$ kombiniert. Da hier mit den erweiterten Unsicherheiten gerechnet wird, liegen die Grenzen der akzeptablen Werte nicht bei 2 sondern bei 1. $|E_n|$ ist gemäß t-Test zu bewerten (siehe auch [ISO13528]):

- $|E_\mathrm{n}| \leq 1$: Die Nullhypothese wird angenommen und gilt als Indikator für eine gute Übereinstimmung
- $|E_\mathrm{n}| > 1$: Die Nullhypothese wird abgelehnt und gilt als Indikator, dass die Messdaten nicht konsistent zueinander sind.

## 7.2 Auswertung von Ringvergleichen ohne Referenzlabor

### 7.2.1 Vorgehensweise

Ringvergleiche zwischen den NMIs (*National Metrology Institutes*), sog. **Key-Comparisons** dienen u.a. dazu einen Referenzwert (KCRV: *key comparison reference value*) mit einer zugeordneten Unsicherheit festzulegen. Der Grad der Übereinstimmung der Messdaten von teilnehmenden Instituts $i$ zum Referenzwert ist hier gesucht. Es gibt keinen Referenzwert, weil man a priori nicht davon ausgehen kann, dass es ein Staatsinstitut gibt, das signifikant besser messen kann als alle anderen. Ein mögliches Auswerteverfahren, das häufig Anwendung findet, ist bei [Cox02] beschrieben. Bei diesem Auswerteverfahren müssen folgende 3 Voraussetzungen erfüllt sein:

- Jeder teilnehmende Partner $i$ ($i = 1, \ldots, N$) stellt Messdaten $x_i$ mit beigeordneter Messunsicherheit $u(x_i)$ eines Prüflings bereit. Der Prüfling muss eine gute Stabilität - auch während des

Transportes - aufweisen.

- Jeder Partner stellt Messdaten zur Verfügung, die statistisch unabhängig von den anderen Partnern sind. D.h. es darf keine Messung eines Partners $i$ von einem anderen Partner $j$ mit $i \neq j$ abhängen.

- Die Messdaten jedes Partners (Instituts) sind normalverteilt.

Gegeben sind $N$ teilnehmende Institutionen mit $i = 1, \ldots, N$. Jeder Partner/Institut $i$ stellt ein Messergebnis der Messgröße zur Verfügung, also einen Schätzwert $x_i$ und eine zugeordnete Standardmessunsicherheit $u(x_i)$. Der Ablauf der Auswertung sieht wie folgt aus:

- **Schritt 1:**
  Da kein Referenzwert vorliegt, wird in diesem Fall ein gewichteter Mittelwert $\tilde{x}$ aus den Messergebnissen aller Partner bestimmt. Benutze dazu das inverse der Quadrate der zugeordneten Standardmessunsicherheiten als Gewichte:

$$\tilde{x} = \frac{x_1/u^2(x_1) + \cdots + x_N/u^2(x_N)}{1/u^2(x_1) + \cdots 1/u^2(x_N)} = \frac{\sum\limits_{i=1}^{N} x_i/u^2(x_i)}{\sum\limits_{i=1}^{N} u^{-2}(x_i)} \tag{7.4}$$

- **Schritt 2:**
  Bestimme die Standardabweichung des gewichteten Mittelwertes $u(\tilde{x}) = \sigma(\tilde{x})$:

$$\frac{1}{u^2(\tilde{x})} = \frac{1}{u^2(x_1)} + \cdots + \frac{1}{u^2(x_N)} \tag{7.5}$$

- **Schritt 3:**
  Führe einen Konsistenzcheck durch, ob die angegeben Messergebnisse konsistent zueinander sind. Führe dazu den $\chi^2$-Test durch mit der $\chi^2$-Variablen (Testgröße $T$):

$$T := \chi^2_{\text{obs}} = \frac{(x_1 - \tilde{x})^2}{u^2(x_1)} + \cdots + \frac{(x_n - \tilde{x})^2}{u^2(x_N)} \tag{7.6}$$

  Diese Testgröße weist eher einen kleinen Wert auf, wenn alle Partner recht dicht am Mittelpartner liegen und natürlich umgekehrt. Vergleiche diese Testgröße mit dem Quantil der $\chi^2(\nu)$ -Verteilung mit Freiheitsgrad $\nu = N-1$ ($N$ Anzahl der Partner), die am Messvergleich teilgenommen haben. Der Konsistenzcheck **schlägt fehl**, wenn die folgende Bedingung erfüllt ist:

$$\Pr\left(\chi^2(\nu) > T\right) < 0.05 \tag{7.7}$$

  „Pr“ steht für „Probability (Wahrscheinlichkeit)“. Der $\chi^2$-Test verlangt als Voraussetzung, dass die Messergebnisse normalverteilt sind.

- **Schritt 4:**
  Falls der Konsistenzcheck nicht fehlschlägt, wird der Wert $\tilde{x}$ als Referenzwert (KCRV: key comparison reference value) $x_{\text{ref}}$ akzeptiert mit der Unsicherheit $u(x_{\text{ref}}) = u(\tilde{x})$. Nun kann der **Grad**

**der Übereinstimmung** $d_i = x_i - x_{\text{ref}}$ der Partner $i = 1, \ldots, N$ mit dem Referenzwert $x_{\text{ref}}$ wie folgt bestimmt werden. Wir definieren die normierten Gewichte $\tilde{w}_i$

$$\tilde{w}_i := \frac{u^2(x_{\text{ref}})}{u^2(x_i)} \tag{7.8}$$

mit

$$\sum_{i=1}^{N} \tilde{w}_i = 1. \tag{7.9}$$

Der Referenzwert $x_{\text{ref}} \equiv \tilde{x}$ aus Gl. (7.4) ergibt sich wie folgt:

$$x_{\text{ref}} = \sum_{i=1}^{N} \tilde{w}_i \, x_i \tag{7.10}$$

Für den Grad der Übereinstimmung erhalten wir:

$$d_i = x_i - x_{\text{ref}} = x_i - \sum_{j=1}^{N} \tilde{w}_j x_j = x_i - \tilde{w}_i x_i - \sum_{\substack{j=1 \\ j\neq i}}^{N} \tilde{w}_j x_j = (1 - \tilde{w}_i) x_i - \sum_{\substack{j=1 \\ j\neq i}}^{N} \tilde{w}_j x_j \tag{7.11}$$

Wenn die Messungen nicht gegenseitig voneinander abhängen, so kann zur Berechnung der Unsicherheit von $d_i$ das Gesetz der Fortpflanzung der Unsicherheiten angewendet werden. (Hinweis: Sind ein Modell mit $y = f(x_1, x_2)$ und die dazugehören Unsicherheiten $u(x_1)$ sowie $u_(x_2)$ gegeben, so ergibt sich die Unsicherheit von $y$ bei Nichtkorrelation von $x_1$ und $x_2$ nach dem Gesetz der Fehlerfortpflanzung zu: $u^2(y) = \left(\frac{\partial f}{\partial x_1}\right) u^2(x_1) + \left(\frac{\partial f}{\partial x_2}\right) u^2(x_2))$

Für die Unsicherheit der Differenz $d_i$ ergibt sich somit:

$$u^2(d_i) = \left(\frac{\partial d_i}{\partial x_i}\right)^2 \cdot u^2(x_i) + \sum_{\substack{j=1 \\ j\neq i}}^{N} \left(\frac{\partial d_i}{\partial x_j}\right)^2 \cdot u^2(x_j) \tag{7.12}$$

$$= (1 - \tilde{w}_i)^2 u^2(x_i) + \sum_{\substack{j=1 \\ j\neq i}}^{N} \tilde{w}_j^2 u^2(x_j) \tag{7.13}$$

$$= ((1 - \tilde{w}_i^2) - \tilde{w}_i^2) u^2(x_i) + \sum_{j=1}^{N} \tilde{w}_j^2 u^2(x_j) \tag{7.14}$$

Mit Gl.(7.8) ergibt sich:

$$u^2(d_i) = (1 - 2\tilde{w}_i^2) u^2(x_i) + \sum_{j=1}^{N} \tilde{w}_j u^2(x_{\text{ref}}) \tag{7.15}$$

Mit Gl.(7.8) und Gl.(7.9) ergibt sich daraus:

$$u^2(d_i) = u^2(x_i) - 2u^2(x_{\text{ref}}) + u^2(x_{\text{ref}}) \sum_{j=1}^{N} \tilde{w}_j$$

$$= u^2(x_i) - u^2(x_{\text{ref}}) \tag{7.16}$$

Auch hier kann nun wieder ein En-Wert angeben werden. Da alle Größen normalverteilt sind, sind die erweiterten Unsicherheiten für einen Erweiterungsfaktor von $k = 2$, $U(x_i) = k \cdot u(x_i) = 2 \cdot u(x_i)$. Damit lässt sich der En-Wert mit Gl.(7.3) bestimmen, der den Grad der Übereinstimmung des beteiligten Partners $i$ mit dem Referenzwert angibt.

$$E_{\mathrm{n}}(x_i) = \frac{d_i}{2\sqrt{u^2(d_i)}} \tag{7.17}$$

Es gelten wieder die Aussagen von Kapitel 1:

- $|E_{\mathrm{n}}| \leq 1$ ist ein Indikator für eine gute Übereinstimmung.
- $|E_{\mathrm{n}}| > 1$ ist ein Indikator, dass die Messdaten nicht konsistent zueinander sind.

### 7.2.2 Beispiel

5 Partner messen ein Massestück von ca. 100 g. Die Ergebnisse der Partner sind wie folgt (alle Angaben sind in g):

| $i$ | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| $x_i$/g | 99.82 | 99.05 | 99.17 | 99.20 | 99.38 |
| $u(x_i)$/g | 0.80 | 0.63 | 0.86 | 0.82 | 0.98 |

Als Ergebnis erhalten wir: $x_{\mathrm{ref}} = 99.29$ und $u_{\mathrm{ref}} = 0.35$. Mit der Testgröße $T = 0.6239$ ergibt sich die Wahrscheinlichkeit $\Pr\{\chi^2(\nu) > T\} = 0.9604$. Da die Wahrscheinlichkeit größer als 0.05 ist, schlägt der Konsistenzcheck nicht fehl, d.h. die Daten der 5 Messpartner sind konsistent.

Für die Abweichungen $d_i$ mit $i = 1 \ldots 5$ erhalten wir:

$$[0.5274 \quad -0.2426 \quad -0.1226 \quad -0.0926 \quad 0.0874].$$

Für die Unsicherheiten $u_d(i)$ mit $i = 1 \ldots 5$ erhalten wir:

$$[0.7172 \quad 0.5209 \quad 0.7836 \quad 0.7395 \quad 0.9137].$$

Für die En-Werte erhalten wir:

$$[0.3676 \quad -0.2329 \quad -0.0783 \quad -0.0626 \quad 0.0478].$$

Das heisst der Partner 5 ist in bester Übereinstimmung mit dem Referenzwert.
Der Octave-/Matlab-Code dazu lautet (Hinweis zu Octave: Evtl. ist die Funktion `chi2pdf` in Octave noch nicht vorhanden. Dann zuerst das Paket statistics installieren, `pkg install -forge package_name` mit `package_name = statistics` und evtl. den Pfad hinzufügen):

```
% addpath('C:\Octave\Octave-4.2.1\share\octave\packages');
% clear all;
```

```
x = [99.82, 99.05, 99.17 , 99.20 ,99.38];
u_x = [0.80 0.63, 0.86, 0.82, 0.98];
U_x = 2*u_x;

% Anzahl der Freiheitsgrade
nu = 4;

% Schritt 1:
x_ref = sum(x./(u_x).^2) ./ sum(1./(u_x).^2)

% Schritt 2:
u_ref = sqrt(1./sum(1./(u_x).^2))

% Schritt 3:
T = sum((x-x_ref).^2./(u_x.^2))

% Bestimme die Wahrscheinlichkeit Pr der Chi^2-Verteilung fuer Chi^2(\nu) > T:
Pr = 1 - chi2cdf(T,nu)

% Schritt 4: Grad der Uebereinstimmung
d = x-x_ref;
u_d = sqrt(u_x.^2 - u_ref.^2)
En = d./(2*sqrt(u_d.^2))
```

### 7.2.3 Identifikation von Ausreißern und Konsistenzcheck

Wir wollen uns hier noch etwas genauer anschauen, wie man feststellt, ob die Messdaten eines Ringvergleiches konsistent sind und wie man mit Inkonsistenten umgeht. Als **Ausreißer** werden häufig Messwerte deklariert, deren Abweichungen größer als 3 mal die erweiterte Messunsicherheit des Referenzwertes [GuideKey] sind. Diese Ausreißer werden in Abstimmung mit dem Partner gelöscht. Anschließend werden die verbliebenen Daten auf statistische Konsistenz überprüft. Wir haben dazu bereits in Gl.(7.6) und Gl.(7.7) eine Formel angegeben, mit der überprüft werden kann, ob die angegebenen Messergebnisse (Messwerte mit Unsicherheiten) konsistent zu dem Referenzwert und dessen Unsicherheit ist. Die Testgröße $T$ basiert auf dem Birge-Test, welche ebenso ein Test auf die Konsistenz der Messdaten in einem Ringvergleich ist. Der Birge-Test ist wie der $\chi^2$-Test nur unter folgenden Bedingungen gültig:

- Die gemessenen Messwerte $x_i$ der $N$ Institute sind unkorreliert
- Man benötigt Kenntnis über die Verteilungsdichtefunktionen. Es wird vorausgesetzt, dass die Größen normalverteilt mit den Unsicherheiten $u(x_i)$ bzw. den Varianzen $\sigma_i$ sind.

Das Birge-Verhältnis ist -bis auf die Anzahl der Freiheitsgrade- die Prüfgröße des Chi2-Tests (siehe vorherige Vorlesung) Es wird folgendes geprüft ($H_0$: Nullhypothese, $H_a$: Alternativhypothese):

| | |
|---|---|
| $H_0$ | $u^2_{\text{partner}} = u^2_{\text{ref}}$: Die Stichprobe gehört zu einer Grundgesamtheit mit Varianz $u^2_{\text{ref}}$ |
| $H_a$ | $u^2_{\text{partner}} \neq u^2_{\text{ref}}$: Die Stichprobe gehört nicht zu einer Grundgesamtheit mit Varianz $u^2_{\text{ref}}$ |

Das **Birge-Verhältnis** ist definiert als das Verhältnis der Streuungen der Unsicherheiten aller Partner (bezeichnen wir mit $u_{\text{partner}}$) zu der Unsicherheit des Referenzwertes $u_{\text{ref}}$. Es wird analog der Testgröße des $\chi^2$-Tests, $T = \nu \left(\frac{s}{\sigma_0}\right)^2$ Gl. 5.79, wie folgt definiert:

$$R_{\text{B}} := \frac{u_{\text{partner}}}{u_{\text{ref}}} \quad \text{mit} \quad \frac{u^2_{\text{partner}}}{u^2_{\text{ref}}} \propto \nu \left(\frac{s}{\sigma_0}\right)^2. \tag{7.18}$$

Die Varianz aller $N$ Partner ist wie folgt definiert:

$$u^2_{\text{partner}} := \frac{\frac{1}{N-1} \sum\limits_{i=1}^{N} w_i \left(x_i - x_{\text{ref}}\right)^2}{\sum\limits_{i=1}^{N} w_i} \quad \text{mit} \quad w_i = \frac{1}{u^2(x_i)}. \tag{7.19}$$

Entsprechend Gl.(7.5) ist die Unsicherheit des Referenzwertes wie folgt gegeben

$$u_{\text{ref}} = \left(\frac{1}{u^2(x_1)} + \cdots + \frac{1}{u^2(x_N)}\right)^{-\frac{1}{2}}, \tag{7.20}$$

so dass für das Birge-Verhältnis gilt

$$R_{\text{B}} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} \left(\frac{x_i - x_{\text{ref}}}{u(x_i)}\right)^2}. \tag{7.21}$$

Vergleicht man das Birge-Verhältnis mit der Testgröße $T = \nu \left(\frac{s}{\sigma_0}\right)^2$ in Gl.(7.6) so ergibt sich der Zusammenhang:

$$R^2_{\text{B}} = \frac{1}{N-1} T \tag{7.22}$$

Bei dem Konsistenzcheck mit dem Birge-Verhältnis wird untersucht, ob

- $R_{\text{B}} \leq 1$: Konsistenzcheck ok.
- $R_{\text{B}} > 1$: Konsistenzcheck schlägt fehl.

Wenn $R_{\text{B}} > 1$ ist, bedeutet dies, dass entsprechend Gl.(7.21) die Unsicherheiten der Partner $u(x_i)$ nicht zu der Unsicherheit des Referenzwertes $u(x_{\text{ref}})$ passen. Die gemessenen Daten $x_i$ der Partner sind inkonsistent. Für unser Beispiel Abschnitt 7.2.2 erhalten wir $R_{\text{B}} = 0.39494$. Damit schlägt der Birge-Test nicht fehl und die Daten sind danach konsistent. Für die Auswertung eines Ringvergleichs ist es empfehlenswert sowohl das Birge-Verhältnis als auch den $\chi^2$-Test (siehe Gl.(7.7)) durchzuführen und zu prüfen, ob beide Tests ok sind.

Häufig wird das Birge-Verhältnis in Gl.(7.21) umgeschrieben und in folgender Form dargestellt:

$$R_{\mathrm{B}}^2 = \sum_{i=1}^{N} \frac{w_i (x_i - x_{\mathrm{ref}})^2}{N-1} \tag{7.23}$$

mit den Gewichten $w_i = 1/\sigma_i^2$ für $i = 1, 2, \ldots, N$ und dem Referenzwert (gewichteten Mittelwert) $x_{ref} = \sum_i w_i x_i / \sum_i w_i$. Der Birge Test kann auch bei korrelierten Messdaten $x_1, \ldots, x_N$, wenn die Kovarianzen $\sigma_{12}, \ldots, \sigma_{(N-1)N}$ gegeben sind, durchgeführt werden, siehe [Kac08].

### 7.2.4 Paule-Mandel Methode zur Anpassung von Gewichtsfaktoren

Bei Ringvergleichen kommt es auch mal vor, dass die Messmethoden nicht immer genau die gleichen sind und der Einfluss der verschiedenen Methoden des Vergleichs unterschätzt wird. Wenn sich herausstellt, dass sich Gruppen von Ergebnissen ausbilden, so kann eine Zwischengruppenvarianz ermittelt werden. Dies kann beispielsweise mit der Paule-Mandel Methode erfolgen.

Es kann bei Ringvergleichen vorkommen, dass jeder am Vergleich beteiligte Partner eine Unsicherheit $U$ angibt, die kleiner ist als der Abstand des Messwertes zu anderen Partnern, so dass sich ein En-Wert bzw. des Birge-Verhältnisses unter Verwendung der Gewichte gemäß Gl. (7.8) größer als Eins ergibt. Durch eine Anpassung der Gewichtsfaktoren durch Hinzufügen einer zusätzlichen Komponente, die sich aus der Streuung der Ergebnisse von Partner zu Partner ergibt, kann eine bessere Konsistenz erzielt werden.

Der Leitfaden zum Erstellen eines *Key Comparison Reports* [GuideKey] empfiehlt als Anpassungsverfahren die **Paule-Mandel Methode**, bei der die Varianzen durch Additions einer Streuung zwischen Laboratorien erhöht werden. Dadurch werden die Gewichtsfaktoren $w_i$ verkleinert und damit Referenzwert $x_{\mathrm{ref}}$ so angepasst, so dass das Birge-Verhältnis kleiner als Eins werden kann. Ein Beispiel dazu ist im Anhang B der Richtlinie für Ringvergleiche [GuideKey] zu finden.

Im Folgenden schauen wir uns das Prinzip von Mandel und Paule an, das in der Publikation [Pau82] zu finden. Es werden zwei eher künstliche Beispiele gewählt, um das Prinzip besser zu verstehen. In Beispiel I wird eine Messgröße mit zwei verschiedenen Methoden (bzw. von zwei verschiedenen Partnern) A und B gemessen. Die gemessenen Einzelwerte von jedem der beiden Partner sind in Tab. 7.1 angegeben.

Tabelle 7.1: Messdaten des Beispiels I

| Methode/Partner | A | | | B | | |
|---|---|---|---|---|---|---|
| Gemessener Wert $x_i$ | 1.1 | 1.9 | 1.5 | 16 | 25 | 3 |

Der gleichgewichtete Mittelwert $\bar{x}_I$ über alle Werte beider Partner ist:

$$\bar{x}_I = \frac{1}{N} \sum_{i=1}^{N} x_i = \frac{1}{6} (1.1 + 1.9 + 1.5 + 16 + 25 + 3) \approx 8.1 \tag{7.24}$$

Intuitiv würden wir jedoch sagen, dass wir den Messdaten mit der Methode A mehr vertrauen schenken

würden, als den Messdaten mit der Methode B, da die Messdaten der Methode A weniger streuen als die Messdaten mit der Methode B.

Als zweites Beispiel betrachten wir, dass die Methoden (bzw. Partner) A und B ähnlich genau messen, jedoch werden von Partner A einen größeren Stichprobenumfang als von Partner B:

Tabelle 7.2: Messdaten des Beispiels II

| Methode/Partner | A | | | | | | B | |
|---|---|---|---|---|---|---|---|---|
| Gemessener Wert $x_i$ | 2.0 | 1.0 | 1.5 | 1.8 | 1.2 | 1.7 | 16.3 | 16.8 |

Für den gleichgewichteten Mittelwert über alle Werte erhalten wir:

$$\bar{x}_{II} = \frac{1}{N}\sum_{i=1}^{N} x_i = \frac{1}{8}\left(2.0 + 1.0 + 1.5 + 1.8 + 1.2 + 1.7 + 16.3 + 16.8\right) = 5.2875 \tag{7.25}$$

Es fällt auf, dass die beiden Werte von Partner B zueinander passen, sich aber deutlich von denen von Partner A unterscheiden.

Die beiden Mittelwerte der jeweiligen Partner A und B sind

$$\bar{x}_{II,A} = \frac{1}{6}\left(2.0 + 1.0 + 1.5 + 1.8 + 1.2 + 1.7\right) = 1.533, \quad \bar{x}_{II,B} = \frac{1}{2}\left(16.3 + 16.8\right) = 16.550 \tag{7.26}$$

Wir haben im Laufe dieser Vorlesungsreihe bereits gesehen, dass Messergebnisse mit größerer Unsicherheit sinnvollerweise mit geringerer Wichtung zu berücksichtigen sind, so dass Gewichte deshalb aus dem Kehrwert der Varianzen bestimmt werden. Der Grund dafür liegt darin, dass die Varianz des gewichteten Mittelwertes $x_{\mathrm{ref}}$ minimiert wird, wenn die Gewichte als Reziprokwert der Varianzen der Einzelwerte berechnet werden. In Gl. (7.10) haben wir deshalb zur Ermittlung des Referenzwertes $x_{\mathrm{ref}}$ beim Ringvergleich mit gleichwertigen Partnern gerechnet mit

$$w_i = \frac{1}{u_i^2}$$

und

$$x_{\mathrm{ref}} = \frac{\sum_{i=1}^{N} w_i x_i}{\sum_{i=1}^{N} w_i}.$$

Wenn die Varianzen der Methode A und B ähnlich sind, so kann eine gemeinsame (gepoolte) Varianz der beiden Methoden berechnet werden (siehe 5. Vorlesung):

$$\mathrm{Var}(x_{ref}) = \frac{\sum_{i=1}^{6}\left(x_{A,i} - \bar{x}_A\right)^2 + \sum_{i=1}^{2}\left(x_{B,i} - \bar{x}_B\right)^2}{(6-1) + (2-1)} = 0.1397 \tag{7.27}$$

Da es sich um den Vergleich der Mittelwerte der beiden Stichproben A und B handelt, verwenden wir

für die Unsicherheit $u_i$ die Varianz des Mittelwertes, also $u_i = \mathrm{Var}(\bar{x}_i)$. Sie ist definiert als

$$\mathrm{Var}(\bar{x}_i) = \frac{\mathrm{Var}(x_i)}{N_i}$$

mit $N_i$ den Anzahl der Wiederholungen für den Mittelwert $\bar{x}_i$.

Für Beispiel II erhalten wir dann folgende Werte:

$$\mathrm{Var}(\bar{x}_{II,A}) = \frac{1}{6(6-1)} \sum_{k=1}^{6} (x_{II,k} - \bar{x}_{II,A})^2 = 0.023778 \quad \text{d.h.} \quad \bar{s}_A = \sqrt{\mathrm{Var}(\bar{x}_{II,A})} = 0.154$$

und

$$\mathrm{Var}(\bar{x}_{II,B}) = \frac{1}{2(2-1)} \sum_{k=7}^{8} (x_{II,k} - \bar{x}_{II,B})^2 = 0.062500 \quad \text{d.h.} \quad \bar{s}_B = \sqrt{\mathrm{Var}(\bar{x}_{II,B})} = 0.250$$

so erhalten wir für die beiden Gewichte $w_A = 42.056$ und $w_B = 16.000$. Der gewichtete Mittelwert, der als Referenzwert für En-Tests und das Birge-Verhältnis genutzt wird, ist damit

$$x_{\mathrm{ref}} \;=\; \frac{42.056 \cdot 1.533 \;+\; 16.000 \cdot 16.550}{42.056 + 16.000} \;=\; 5.6716$$

Nach Gl. (7.21) das Birge-Verhältnis hierfür

$$R_{\mathrm{B}}^2 \;=\; \frac{1}{N-1} \sum_{i=1}^{N} \left( \frac{x_i - x_{\mathrm{ref}}}{u(x_i)} \right)^2 \;=\; \frac{1}{2-1} \left( \frac{(1.5333 - 5.6716)^2}{0.023778} + \frac{(16.550 - 5.6716)^2}{0.0625} \right) = 2613.7$$

also

$$R_{\mathrm{B}} \;=\; \sqrt{2613.7} \;=\; 51.1 \gg 1$$

Wir sehen, dass die Varianzen der Mittelwerte der beiden Partner A und B im Verhältnis zur Differenz zwischen den beiden Partnern sehr klein ist, oder umgekehrt gesagt liegen die Mittelwerte der Methoden A und B sehr weit auseinander im Verhältnis zu den Varianzen. Die Varianzen $\mathrm{Var}(\bar{x}_A)$ und $\mathrm{Var}(\bar{x}_A)$ beschreiben nur die interne Streuung, also nur die Streuung der jeweiligen Stichproben A und B. Die Wahrscheinlichkeitsverteilungen werden durch die beiden Parameter Erwartungswert, also hier Mittelwert und Varianz charakterisiert und wir hatten bei den Hypothesentests gelernt, auf beides zu prüfen. Wir haben gesehen, dass Stichproben einer gemeinsamen Grundgesamtheit angehören, wenn beides, Mittelwert und Varianz zueinander passen.

Bei den Ringvergleichen, bei denen von verschiedenen Laboratorien oder Instituten mit unterschiedlichen Methoden oder jedenfalls unabhängigen experimentellen Aufbauten die Ergebnisse verglichen werden, kann beobachtet werden, dass entweder die Schätzer (empirischen Erwartungswerte) oder die empirischen Varianzen oder sogar beides nicht zusammen passen. In der Praxis kommt es vor, dass die jeweiligen Labore oder Institute ihre Methode immer weiter optimiert haben und ihre Genauigkeit erhöht haben, dass jedoch verbleibende, unerkannte systematische Effekte vorhanden sind. Dass es Unterschiede gibt, tritt erst bei dem Vergleich zutage und es lässt sich im Rahmen der gesetzten Zeit für das Projekt des Vergleichens nicht aufklären. In solchen Fällen lebt man dann damit, dass es auch zwischen den unterschiedlichen Methoden bzw. Laboren eine Streuung gibt.

Statistisch wird dies damit ausgedrückt, dass die Stichproben aus den verschiedenen Laboren zu verschiedenen Grundgesamtheiten gehören. Konkret bedeutet das, dass für die Gewichte zusätzlich zur Varianz des Mittelwerts zur jeweiligen Methode/ des jeweiligen Laboratoriums (Streuung innerhalb einer Gruppe, *within group variability*) auch eine Varianz der Methoden/Laboratorien (Streuung zwischen Gruppen, *between group variability*) eingeführt wird. Die Streuung zwischen den Gruppen, die Varianz $s_\mathrm{b}^2$ wird iterativ geschätzt. Für die verschiedenen Partner oder Stichproben $A$ und $B$ verwenden wir jetzt die Notation $S_i$, hier also $S_1 = A$ und $S_2 = B$, um die Gleichungen allgemein aufschreiben zu können.

$$\mathrm{Var}(\bar{x}_{S_i,\mathrm{c}}) \;=\; \mathrm{Var}(\bar{x}_{S_i}) \;+\; s_\mathrm{b}^2 \;=\; \frac{1}{M_i(M_i-1)} \sum_{k \in S_i} (x_k - \bar{x}_{S_i})^2 \;+\; s_\mathrm{b}^2$$

mit $M_i$ für den Stichprobenumfang zu $S_i$ - oder kürzer aufgeschrieben mit $i$ als Index für die Nummerierung der Partner und für die Varianzen der Mittelwerte bzw. Messergebnisse der Partner $u_i^2 = \bar{s}_i^2 = \mathrm{Var}(\bar{x}_{S_i})$ bzw. für die Konsensusvarianzen $\bar{s}_{i,\mathrm{c}}^2 = \mathrm{Var}(\bar{x}_{S_i,\mathrm{c}})$

$$\bar{s}_{i,\mathrm{c}}^2 \;=\; \bar{s}_i^2 \;+\; s_\mathrm{b}^2 \quad i = 1, 2 \tag{7.28}$$

wobei der Index b für *between* und c für *consensus* stehen. Auch die Mittelwerte bzw. allgemein die Messergebnisse der jeweiligen Partner schreiben wir jetzt in der Form $\bar{x}_{S_i} = \bar{x}_i$.

Die Gewichte für den *Consensus Value*, dem besser übereinstimmenden Wert für die Messgröße, sind damit dann

$$w_{i,\mathrm{c}} \;=\; \frac{1}{\mathrm{Var}(\bar{x}_{S_i,\mathrm{c}})} \;=\; \left( \frac{1}{M_i(M_i-1)} \sum_{k \in S_i} (x_k - \bar{x}_{S_i})^2 \;+\; s_\mathrm{b}^2 \right)^{-1}$$

mit $M_i$ für den Stichprobenumfang zu $S_i$ und dasselbe in der kürzeren Notation geschrieben

$$w_{i,\mathrm{c}} \;=\; \frac{1}{\bar{s}_{i,\mathrm{c}}^2} \;=\; \frac{1}{\bar{s}_j^2 \;+\; s_\mathrm{b}^2}. \tag{7.29}$$

Der Konsenzreferenzwert aus den Werten aller $N$ Partner ist dann

$$x_{\mathrm{ref,c}} \;=\; \frac{\sum\limits_{i=1}^{N} w_{i,\mathrm{c}} x_i}{\sum\limits_{i=1}^{N} w_{i,\mathrm{c}}}. \tag{7.30}$$

Das Birge-Verhältnis für diese Konsensuswerte ist somit

$$R_\mathrm{B} \;=\; \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} \frac{1}{\bar{s}_i^2 \;+\; s_\mathrm{b}^2} \; (\bar{x}_i - x_{\mathrm{ref,c}})^2}. \tag{7.31}$$

**Schätzen der Zwischengruppenvarianz $s_\mathrm{b}^2$**

Geschätzt wird die Zwischengruppenvarianz $s_\mathrm{b}^2$ gemäß Paule und Mandel [Pau82] als diejenige Varianz, für die die Ergebnisse der Partner konsistent sein sollen, also für die das Birge-Verhältnis gegen Eins streben soll: $R_\mathrm{B} \to 1$.

Die Optimierungsaufgabe formulieren wir für das Quadrat des Birge-Verhältnisses, um eine Kosten-

funktion zu haben, die sich einfacher linearisieren lässt. Dies geht ganz gut, weil $1^2 = 1$ ist, also $R_{\mathrm{B}}^2 \to 1$, d.h.

$$\frac{1}{N-1} \sum_{i=1}^{N} \frac{1}{\bar{s}_i^2 \; + \; s_{\mathrm{b}}^2} \; (\bar{x}_i - x_{\mathrm{ref,c}})^2 \to 1$$

oder genauer ausgedrückt

$$\min_{s_{\mathrm{b}}^2} \left\{ \frac{1}{N-1} \left( \sum_{i=1}^{N} \frac{1}{\bar{s}_i^2 \; + \; s_{\mathrm{b}}^2} \; (\bar{x}_i - x_{\mathrm{ref,c}})^2 \right) \; - \; 1 \right\}. \tag{7.32}$$

Diese Optimierungsaufgabe hat eine Kostenfunktion $Q(s_{\mathrm{b}}^2) = \frac{1}{N-1} \left( \sum_{i=1}^{N} \frac{1}{\bar{s}_i^2 + s_{\mathrm{b}}^2} \; (\bar{x}_i - x_{\mathrm{ref,c}})^2 \right) - 1$ die von dem zu schätzenden Parameter, der Zwischengruppenvarianz $v := s_{\mathrm{b}}^2$ nicht-linear abhängt, so dass sie iterativ zu lösen ist, es handelt sich also nichtlineare Optimierung wie wir es in Kapitel 3 besprochen haben.

Wir entwickeln die Kostenfunktion in eine Taylorreihe bis zum linearen Term

$$Q(v_0 + \mathrm{d}\, v_0) \approx Q_0 + \left( \frac{\partial Q}{\partial v} \right) \Big|_{v=v_0} \mathrm{d}\, v_0 \tag{7.33}$$

Mit $Q(v) \to 0$ setzen wir für den ersten Iterationsschritt

$$Q_0 + \left( \frac{\partial Q}{\partial v} \right) \Big|_{v=v_0} \mathrm{d}\, v_0 = 0 \tag{7.34}$$

und lösen dies nach $\mathrm{d}\, v_0$ auf zu

$$\mathrm{d}\, v_0 = - \left( \frac{Q_0}{\frac{\partial Q}{\partial v}} \right) \Big|_{v=v_0} \tag{7.35}$$

Wir beginnen mit dem Startwert für $v_0$, indem wir ihn auf $v_0 = 0$ setzten, so dass wir mit dem sehr großen Birge-Verhältnis beginnen und iterativ die Zwischengruppenvarianz erhöhen, um das Birge-Verhältnis solange zu reduzieren bis es Eins wird. Im nächsten Schritt setzen wir $v_1 = v_0 + \mathrm{d}\, v_0$. Dies setzten wir fort mit

$$v_{k+1} = v_k + \mathrm{d}\, v_k \tag{7.36}$$

bis $Q$ zu einem Minimum möglichst nahe bei Null konvergiert.

Die Ableitung der Kostenfunktion $Q$ nach der Zwischengruppenvarianz ist

$$\frac{\partial Q}{\partial v} = \frac{1}{N-1} \left( \sum_{i=1}^{N} \frac{\partial}{\partial v} \frac{1}{\bar{s}_i^2 \; + \; v} \; (\bar{x}_i - x_{\mathrm{ref,c}})^2 \right) \; - \; 0$$

d.h.

$$\frac{\partial Q}{\partial v} = \frac{1}{N-1} \sum_{j=1}^{N} (\bar{x}_j - x_{\mathrm{ref,c}})^2 \, \frac{\partial}{\partial v} \frac{1}{\bar{s}_i^2 \; + \; v}$$

d.h.

$$\frac{\partial Q}{\partial v} = \frac{1}{N-1} \sum_{i=1}^{N} (\bar{x}_i - x_{\mathrm{ref,c}})^2 \, \frac{-1}{\left( \bar{s}_i^2 \; + \; v \right)^2} \tag{7.37}$$

Die Iterationen laufen, solange $R_\mathrm{B}$ größer als Eins ist und eine maximale Anzahl Iterationsschritte einen Wert von 50 nicht überschreitet. In dem hier behandelten Beispiel werden 17 Iterationsschritte gebraucht, bis die Optimierung konvergiert und folgendes Ergebnis für die Zwischengruppenvarianz $v = s_\mathrm{b}^2$ liefert.

$$v = 112.707 \quad \text{d.h.} \quad s_\mathrm{b} = 10.6$$

Die Konsensusvarianz für den Referenzwert können wir dann wie folgt berechnen:

$$\mathrm{Var}(x_\mathrm{ref}) = \left( \sum_{i=1}^{N} \frac{1}{\bar{s}_i^2 \; + \; s_\mathrm{b}^2} \right)^{-1} = 56.375; \quad s_\mathrm{ref} = \sqrt{\mathrm{Var}(x_\mathrm{ref})} = 7.5$$

Als Ergebnis ergibt sich damit:

$$x_\mathrm{ref} = 9.040 \quad \text{mit} \quad s_\mathrm{ref} = 7.5 \tag{7.38}$$

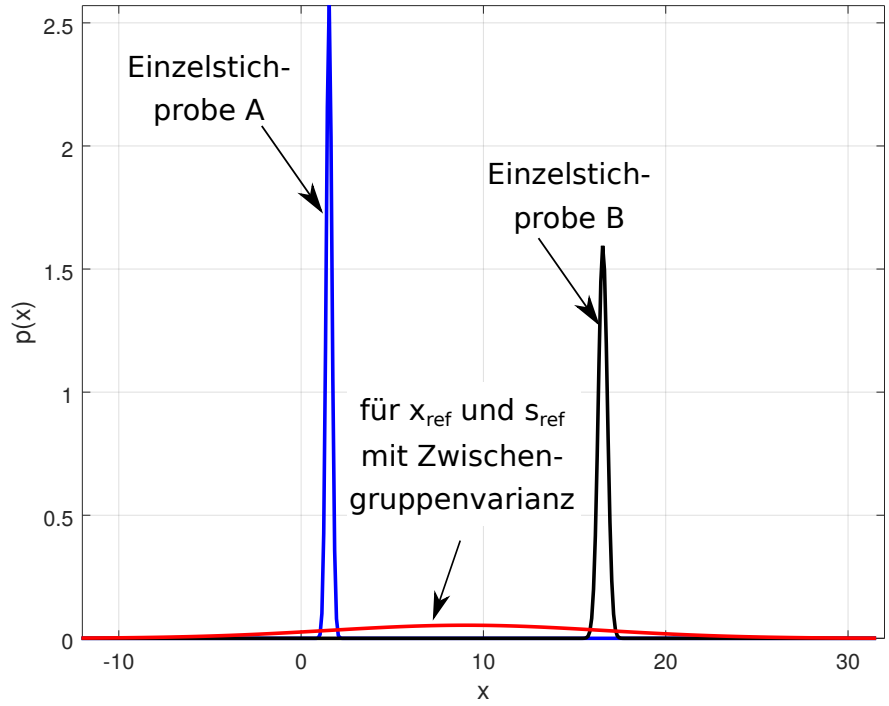



Abbildung 7.2: Wahrscheinlichkeitsdichteverteilungen als Normalverteilungen zu Beispiel II mit blauer Kurve für die Einzelstichprobe A mit $\bar{x}_{II,A} = 1.533$ und $\bar{s}_A = 0.1542$, schwarzer Kurve für die Einzelstichprobe B mit $\bar{x}_{II,B} = 16.550$ und $\bar{s}_B = 0.2500$, sowie die gemeinsame Verteilung nach Hinzufügen der Zwischengruppenvarianz mit $x_\mathrm{ref} = 9.040$ und $\sqrt{\mathrm{Var}(x_\mathrm{ref})} = 7.5$ als sehr viel breitere und flachere Gaußverteilung dargestellt als rote Kurve.

Der dazu gehörige Quellcode für Gnu-Octave/Matlab sieht wie folgt aus:

```
1 function consensus_fit()
2 % Programm laeuft unter Matlab und Gnu-Octave
3 x_A = [2.0,1.0,1.5,1.8,1.2,1.7];
4 N_A = length(x_A);
5 x_B = [16.3,16.8];
```

```
N_B = length(x_B);

bar_x_A = mean(x_A);
bar_x_B = mean(x_B);
fprintf('Mittelwerte: %f und %f \n', bar_x_A, bar_x_B);

% Varianzen der Mittelwerte
Var_A_mittel = var(x_A)/N_A;
Var_B_mittel = var(x_B)/N_B;
fprintf('Varianzen der Mittelwerte innerhalb jeder Stichprobe: \n %f und %f \n'...
,  Var_A_mittel, Var_B_mittel);

% Anzahl der Methoden/ Partner M
M = 2;
% Startwert fuer Zwischengruppenvarianz
v_0 = 0;

% Berechnung des Birge ratio fuer den Startwert
w_A = 1/Var_A_mittel;
w_B = 1/Var_B_mittel;
x_ref = (w_A*bar_x_A + w_B*bar_x_B ) / (w_A + w_B);
RB = sqrt( (1/(M-1))*(w_A * (bar_x_A - x_ref)^2 + ...
w_B * (bar_x_B - x_ref)^2));
fprintf('Birge-Verhaeltnis fuer den Startwert %f\n\n',RB)
%
max_num_iterations = 50;
v = v_0;
k = 0;
while (RB > 1) && (k < max_num_iterations)
w_A = 1/(Var_A_mittel + v);
w_B = 1/(Var_B_mittel + v);

x_ref = (w_A*bar_x_A + w_B*bar_x_B ) / (w_A + w_B);
RBsq = (1/(M-1))*(w_A * (bar_x_A - x_ref)^2 + ...
w_B * (bar_x_B - x_ref)^2);
RB = sqrt(RBsq);
Q = RBsq - 1;
dQ_dv = (-1/(M-1))*(w_A^2 * (bar_x_A - x_ref)^2 + ...
w_B^2 * (bar_x_B - x_ref)^2);
dv = -Q / dQ_dv;
v = v + dv;
k = k + 1;
fprintf('x_ref: %f, RB: %.3f, dv: %e --> v: %.3f\n', x_ref, sqrt(RBsq), dv,v);
end
```

```
fprintf('\n s_b = %f bei Anzahl Iterationen %d\n', ...
sqrt(v_dv), k);
end
```

mit dem Output:

```
>> consensus_fit
Mittelwerte: 1.533333 und 16.550000
Varianzen der Mittelwerte innerhalb jeder Stichprobe:
0.023778 und 0.062500
Birge_Verhaeltnis fuer den Startwert 51.123910

x_ref: 5.671861, RB: 51.124, dv: 4.312238e_02 ___> v: 0.043
x_ref: 7.356441, RB: 36.154, dv: 8.619528e_02 ___> v: 0.129
x_ref: 8.198732, RB: 25.569, dv: 1.721928e_01 ___> v: 0.302
x_ref: 8.619877, RB: 18.087, dv: 3.435958e_01 ___> v: 0.645
x_ref: 8.830449, RB: 12.799, dv: 6.840440e_01 ___> v: 1.329
x_ref: 8.935734, RB: 9.064, dv: 1.355587e+00 ___> v: 2.685
x_ref: 8.988376, RB: 6.429, dv: 2.661878e+00 ___> v: 5.347
x_ref: 9.014695, RB: 4.574, dv: 5.132109e+00 ___> v: 10.479
x_ref: 9.027851, RB: 3.273, dv: 9.539961e+00 ___> v: 20.019
x_ref: 9.034421, RB: 2.371, dv: 1.649219e+01 ___> v: 36.511
x_ref: 9.037690, RB: 1.756, dv: 2.470307e+01 ___> v: 61.214
x_ref: 9.039294, RB: 1.357, dv: 2.797615e+01 ___> v: 89.190
x_ref: 9.040038, RB: 1.124, dv: 1.861186e+01 ___> v: 107.802
x_ref: 9.040319, RB: 1.022, dv: 4.691663e+00 ___> v: 112.494
x_ref: 9.040375, RB: 1.001, dv: 2.129841e_01 ___> v: 112.707
x_ref: 9.040377, RB: 1.000, dv: 4.038510e_04 ___> v: 112.707
x_ref: 9.040377, RB: 1.000, dv: 1.446530e_09 ___> v: 112.707
x_ref: 9.040377, RB: 1.000, dv: 0.000000e+00 ___> v: 112.707

s_b = 10.616355 bei Anzahl Iterationen 18
```

# Kapitel 8

# Infrastrukturen der Metrologie

## 8.1 Internationale Metrologieorganisationen (BIPM,NMIs)

...

## 8.2 Akkreditierung, Zertifzierung, DAkkS

### 8.2.1 Messen, Prüfen, Lehren

**Messen:** Ermittlung von Werten einer Messgröße i. Allg. unter festgelegten Bedingungen (Messbedingungen), siehe z. B. auch die Definition von *Messung* im [VIM08]

**Prüfen:** Ermittlung von Eigenschaften (quantitative, qualitativ) eines Objektes nach einem vorgegebenen Verfahren - häufig auch einschl. Vergleich mit vorgegebenen Spezifikationen (*Konformität*) Prüfen bedeutet nach DIN 1319 das Feststellen, inwieweit ein Prüfobjekt eine Forderung erfüllt [DIN1319]. Wird nur mit dem menschlichen Sinnen – ohne Hilfsmittel – geprüft, spricht man vom subjektiven Prüfen. Die Prüfergebnisse sind nur schlecht miteinander vergleichbar. Werden Hilfsmittel – sogenannte Prüfmittel – verwendet, so spricht man vom objektiven Prüfen.

**Lehren:** Objektive Prüfverfahren werden in die Arten Messen und Lehren unterteilt. Beim Messen wird eine physikalische Größe mit einem Messgerät erfasst und ein Messwert ermittelt. Der Messwert setzt sich aus Zahlenwert mit Einheit, welche die physikalische Größe repräsentiert, zusammen. Beim Lehren wird festgestellt, ob das zu prüfende Objekt innerhalb vorgegebener Grenzen liegt oder nicht. Das *Prüfergebnis ist kein Zahlenwert, sondern eine Gut- / Schlecht-Aussage.* Oft lässt sich beim Lehren erkennen, in welche Richtung die Grenze überschritten wurde.

### 8.2.2 Akkreditierung (Wirtschaft)

Die Anforderungen an die Qualität von Waren und Dienstleistungen nehmen angesichts der Liberalisierung des Welthandels sowie der steigenden Ansprüche von Verbrauchern, Unternehmen und Gesetzgebern stetig zu. Ob im Umweltschutz, in der Lebensmittel- oder Elektroindustrie, im Gesundheitswesen oder im Bereich Erneuerbarer Energien – in diesen wie in vielen anderen Wirtschaftsbereichen sind objektive Prüfungen, Kalibrierungen, Inspektionen oder Zertifizierungen daher von großer Bedeutung [Wiki03].

Diese Bewertungen stellen sicher, dass die überprüften Produkte, Verfahren, Dienstleistungen oder Systeme hinsichtlich ihrer Qualität und Sicherheit *verlässlich* sind, sie einem technischen Mindestniveau entsprechen und mit den Vorgaben entsprechender Normen, Richtlinien und Gesetze konform sind. Daher werden diese objektiven Bestätigungen auch als Konformitätsbewertung bezeichnet. Vertrauen durch Akkreditierung

Das Vertrauen in Zertifikate, Inspektionen, Prüfungen oder Kalibrierungen steht und fällt jedoch mit der Kompetenz desjenigen, der die Bewertungsleistung erbringt. Viele dieser sogenannten **Konformitätsbewertungsstellen** belegen die Qualität ihrer eigenen Arbeit daher durch eine Akkreditierung.

In diesem Verfahren weisen sie gegenüber einer unabhängigen Akkreditierungsstelle nach, dass sie ihre Tätigkeiten fachlich kompetent, unter Beachtung gesetzlicher sowie normativer Anforderungen und auf international vergleichbarem Niveau erbringen. Die Akkreditierungsstelle begutachtet und überwacht dabei das Managementsystem und die Kompetenz des eingesetzten Personals der Konformitätsbewertungsstelle.

Akkreditierungen tragen deshalb somit entscheidend dazu bei, die Vergleichbarkeit von Konformitätsbewertungsergebnissen zu gewährleisten und *Vertrauen in die Qualität und Sicherheit von Produkten und Dienstleistungen zu erzeugen.*

Der Begriff „Akkreditierung " (Latein: „accredere", Glauben schenken) wird in verschiedenen Bereichen benutzt, um den Umstand zu beschreiben, dass eine allgemein anerkannte Instanz einer anderen das Erfüllen einer besonderen (nützlichen) Eigenschaft bescheinigt.

Akkreditierung im hier gemeinten Sinne ist gemäß DIN EN ISO/IEC 17011 - 2018-03 (Konformitätsbewertung - Anforderungen an Akkreditierungsstellen, die Konformitätsbewertungsstellen akkreditieren) definiert. Sie ist die Bestätigung durch eine dritte Stelle, die formal darlegt, dass eine Konformitätsbewertungsstelle (z.B. Laboratorien, Inspektions- und Zertifizierungsstellen) die Kompetenz besitzt, bestimmte Konformitätsbewertungsaufgaben durchzuführen.

Konformitätsbewertungsstellen sind Organisationen, die folgende Dienstleistungen zur Konformitätsbewertung bereitstellen: Prüfung, Inspektion, Zertifizierung von Managementsystemen, Personen Personenzertifizierung im Sinne eines Qualifikationsnachweises und Produkten. **Kalibrierlabors** werden ebenfalls dem Begriff Konformitätsbewertungsstellen untergeordnet (obwohl sie nicht in erster Linie eine Konformität bewerten).

Eine **Zertifizierungsstelle** ist akkreditiert, wenn eine Akkreditierungsstelle formell bestätigt, dass die Zertifizierungsstelle die z.B. in der Normenreihe EN 45011–45013 aufgeführten Voraussetzungen zur Durchführung von Bewertungen von Managementsystemen (zum Beispiel Qualitätsmanagement oder Umweltmanagement), Produkten oder Personen erfüllt. Ein **Prüf- bzw. Kalibrierlaboratorium** ist akkreditiert, wenn es die z. B. Anforderungen der Norm DIN EN ISO/IEC 17025:2018 (Allgemeine Anforderungen an die Kompetenz von Prüf- und Kalibrierlaboratorien) erfüllt, die den Qualitätsstandard (DIN EN ISO 9001:2008) einschließt und darüber hinausgehende Anforderungen enthält. Hierzu wird das Labor durch eine **Expertengruppe** einer unabhängigen Akkreditierungsstelle, welche die Norm DIN EN ISO/IEC 17011 erfüllt, begutachtet und durch meist jährliche Begehungen überwacht. Eine **Konformitätsbewertungsstelle** ist akkreditiert, wenn sie den Anforderungen z. B. der Norm ISO/IEC 17021 (vormals ISO/IEC 45012) entspricht und eine Akkreditierungsstelle dies formell bestätigt. Eine **Inspektionsstelle** ist akkreditiert, wenn sie die Anforderungen der Norm z. B. ISO/IEC 17020 erfüllt und eine Akkreditierungsstelle dies formell bestätigt.

In Deutschland ist seit dem 1. Januar 2010 ausschließlich die Deutsche Akkreditierungsstelle GmbH (DAkkS) für die Erteilung und Aufrechterhaltung von Akkreditierungen zuständig. Die Errichtung einer nationalen Akkreditierungsstelle erfolgte nach der Vorgabe der Verordnung (EG) Nr. 765/2008 und nach Maßgabe des deutschen Akkreditierungsstellengesetzes. Gesellschafter der DAkkS sind zu gleichen Teilen die Bundesrepublik Deutschland, die Bundesländer und die durch den Bundesverband der Deutschen Industrie (BDI) vertretene Wirtschaft (siehe [DAkkS]). Die DAkkS ist ein zentraler Baustein der Qualitätsinfrastruktur und erteilen Akkreditierungen im Bereich der Konformitätsbe-

wertung. Sie hat einen gesetzlichen Auftrag und handelt im Interesse des Staates, der Wirtschaft sowie zum Schutz von Gesellschaft und Umwelt. Mit einer Akkreditierung wird bestätigt die DAkkS, das Organisationen wie Prüf-, Inspektions-, und Zertifizierungsstellen ihre Tätigkeiten nach international gültigen Maßstäben kompetent erbringen können. Für die Durchführung von Akkreditierungen greift die DAkkS auf eine breite Basis von Experten zurück (Gutachter und Fachexperten). DAkkS muss *unabhängig* und *unparteilich* sein. Die DAkkS selbst hat ca. 190 Mitarbeiter in 49 Fachbereichen und hat ca. 4250 gültige Akkreditierungen im Bestand. Jährlich werden ca. 4000 Begutachtungen durchgeführt. Sie wurde entsprechend ISO/IEC 17011:2017 (Conformity assessment – Requirements for accreditation bodies accrediting conformity assessment bodies) umstrukturiert. Die DAkkS wurde dementsprechend angepasst. **Aktuell werden alle akkreditierten Stellen auf die DIN EN ISO/IEC 17025:2018 (Allgemeine Anforderungen an die Kompetenz von Prüf- und Kalibrierlaboratorien) umgestellt.** Im Vergleich zur Ausgabe aus dem Jahr 2005, sind die wesentlichen Änderungen von ISO/IEC 17025 folgende: Die Hinzunahme eines risikobasierten Ansatzes, größere Flexibilität bei den Anforderungen für Prozesse, Verfahren, dokumentierte Informationen und organisatorische Verantwortlichkeiten sowie die Einführung von Definitionen. Die dreijährige Übergangsfrist endet im November 2020. Akkreditierungen auf Basis der alten DIN EN ISO/IEC 17025:2005 verlieren Ende 2020 ihre Gültigkeit.

Beispiel: Die Akkreditierung von TÜV, DEKRA und Co
Die TÜV-Gesellschaften, DEKRA und Co bekommen für ihre Arbeit eine sogenannte Akkreditierung von einer staatlichen Stelle namens DAkkS (Deutsche Akkreditierungsstelle), die bestätigt, dass die Messungen korrekt durchgeführt werden. Es kann durchaus mal passieren wie im Jahre 2015, dass diese Akkreditierung bei Vorliegen von Fehlverhalten (hier: keine vollständige Dokumentation) die Akkreditierung entzogen werden kann (siehe z. B. Artikel: https://www.autobild.de/artikel/tuev-dekra-und-co-ohne-zulassung–8471909.html)

**Wer kann sich akkreditieren lassen?**

Die DAkkS akkreditiert Konformitätsbewertungsstellen (KBS). Als solche Stellen gelten Laboratorien, Zertifizierungs- und Inspektionsstellen, Anbieter von Eignungsprüfungen und Referenzmaterialhersteller (siehe Abb.8.1). Die Akkreditierung einer KBS durch die DAkkS ist möglich, wenn diese die Anforderungen der entsprechenden internationalen Normen erfüllt.

Seit 1. September 2019 sind Akkreditierungen von Biobanken auf Basis der ISO 20387 möglich, da diese eine zunehmende Relevanz spielen und es eine hohe Nachfrage gibt. In Biodatenbanken werden DNA-, Blut- oder Gewebeproben zusammen mit Hintergrundinformationen gespeichert. Bislang konnten nur spezifische Teile der Tätigkeit von Biobanken akkreditiert werden. Nun kann der gesamte Prozess - von der Entnahme der Probe bis zur Verteilung der Materialien inklusive der assoziierten Daten akkreditiert werden.

Das Regelwerk ist zu finden unter: https://www.dakks.de/de/regelwerk.html

Die internationale Harmonisierung dieser Normen gewährleistet, dass die Akkreditierung weltweit nach gleichen Voraussetzungen erfolgt. Durch diese harmonisierten Normen und dank internationaler Abkommen werden die Bewertungsleistungen der in Deutschland akkreditierten Stellen in vielen anderen Ländern Europas und der Welt anerkannt.

**Typen von Konformitätsbewertungsstellen**

| | |
|---|---|
| **Laboratorien** | **Prüf- und Kalibrierlaboratorien**<br>DIN EN ISO/IEC 17025 |
| | **Medizinische Laboratorien**<br>DIN EN ISO 15189 |
| **Inspektionsstellen** | DIN EN ISO/IEC 17020 |
| **Zertifizierungsstellen** | **für Personen**<br>DIN EN ISO/IEC 17024 |
| | **für Managementsysteme**<br>DIN EN ISO/IEC 17021-1 |
| | **für Produkte, Prozesse und Dienstleistungen**<br>DIN EN ISO/IEC 17065 |
| **Validierungs- und Verifizierungsstellen** | DIN EN ISO 14065 |
| **Anbieter von Eignungsprüfungen** | DIN EN ISO/IEC 17043 |
| **Referenzmaterialhersteller** | ISO Guide 34<br>i.V.m. DIN EN ISO/IEC 17025 |

Abbildung 8.1: Typen von Konformitätsstellen, Quelle:[DAkkS]

Diese Überwindung technischer Handelshemmnisse erleichtert den Handel über Grenzen hinweg und stellt sicher, dass die Ergebnisse von Konformitätsbewertungen ohne eine erneute Überprüfung *international akzeptiert* werden.

**Vorteile von Akkreditierungen**
Für Unternehmen:

- Höhere Akzeptanz von Produkten und Dienstleistungen erleichtert den Marktzugang bzw. ermöglicht diesen erst
- Einmal geprüft, überall akzeptiert: Internationale Vergleichbarkeit und Anerkennung von Zertifikaten, Inspektionen, Prüfungen oder Kalibrierungen vermeidet Kosten durch mehrfache Bewertungen
- Kompetenznachweis erleichtert die Auswahl eines passenden Dienstleisters für die Konformitätsbewertung von Waren und Dienstleistungen

Für akkreditierte Stellen:

- objektiver Beleg für die Güte und Kompetenz der Tätigkeit einer Konformitätsbewertungsstelle nach internationalen Standards
- Wettbewerbsvorteile gegenüber nicht akkreditierten Marktteilnehmern

Für Verbraucher:

- größeres Vertrauen der Verbraucher in die Qualität von Produkten und Dienstleistungen – trotz eines komplexen Weltmarkts
- weniger Produktfehler oder Rückrufaktionen

Für den Gesetzgeber:

- verbesserte Wettbewerbsfähigkeit der Wirtschaft durch den Abbau
- technischer Handelshemnisse

**Akkreditierungsprozess**

- Antragsphase
  Der Akkreditierungsprozess beginnt mit der Einsendung des Akkreditierungsantrages und der fachspezifischen Anlagen an die Zentrale Antragsbearbeitung (ZAB) der DAkkS in Berlin. Optional können sich Kunden auch vorab in einem Vorgespräch in den Geschäftsstellen der DAkkS über ihre angestrebte Akkreditierung oder das Akkreditierungsverfahren im konkreten Fall informieren. Die ZAB überprüft in Abstimmung mit der zuständigen Fachabteilung der DAkkS den Antrag. Dabei wird auch geprüft, ob eine Befugnis erteilende Behörde (BeB) in das Akkreditierungsverfahren eingebunden werden muss. Nach einer erfolgreichen Antragsprüfung informiert der zugeteilte Verfahrensmanager die antragstellende Konformitätsbewertungsstelle (KBS) über das weitere Vorgehen.

- Begutachtungsphase
  In der zweiten Phase des Akkreditierungsprozesses begutachtet die DAkkS durch ein Begutachterteam die technische Kompetenz und das Managementsystem der KBS. Zunächst prüfen die Begutachter die eingereichten Dokumente, dann findet zum vereinbarten Termin die Begehung vor Ort statt. Der Umfang und die Dauer der Begutachtung sind von der Größe der KBS, dem beauftragten Geltungsbereich (Scope) der Akkreditierung und der Komplexität des Verfahrens abhängig. Die Ergebnisse werden in einem Begutachtungsbericht dokumentiert. Festgestellte Abweichungen kann der Kunde durch entsprechende Korrekturmaßnahmen im Anschluss an den Begutachtungstermin innerhalb von zwei Monaten beheben. Diese werden nochmals überprüft und bewertet.

- Akkreditierungsphase
  In dieser Phase bewertet ein Akkreditierungsausschuss (AkA) die Begutachtungsergebnisse und entscheidet über die Erteilung der Akkreditierung. Die DAkkS bescheinigt den erfolgreichen Abschluss der Akkreditierungsphase durch den Akkreditierungsbescheid und die Akkreditierungsurkunde. Damit bestätigt die DAkkS der überprüften KBS die Erfüllung der entsprechenden Normen, Standards oder Gesetzen im Hinblick auf ihre Konformitätbewertungstätigkeiten – und damit ihre technische Kompetenz. Die Akkreditierung wird anschließend im Verzeichnis der akkreditierten Stellen gelistet.

- Überwachungsphase
  Eine Akkreditierung wird in gewissen zeitlichen Abständen überwacht, um die Kompetenz sicherzustellen. Je nachdem, ob es sich um ein Laboratorium, eine Inspektions-, Zertifizierungs- oder Verifizierungsstelle handelt, gibt es unterschiedliche Zeitintervalle. Der Akkreditierungszyklus endet in der Regel spätestens nach fünf Jahren und bedarf dann einer Reakkreditierung.

**Akkreditierungssymbol**

Auf Antrag gestattet die DAkkS einer akkreditierten Stelle die Verwendung des DAkkS-Akkreditierungssymbols (siehe Abb.8.2). Zusammen mit der eindeutigen Registrierungsnummer weist es auf die erfolgreiche Akkreditierung hin. Durch die genehmigte Verwendung des Symbols können akkreditierte Stellen ihren Kunden die nachgewiesene Kompetenz signalisieren.




Abbildung 8.2: Muster des Akkreditierungssymbols der DAkkS für akkreditierte Stellen, Quelle:[DAkkS]

**Kosten der Akkreditierung**

Als Deutschlands nationale Akkreditierungsstelle handelt die DAkkS zum Wohle des Staates, der Wirtschaft und der Verbraucher: Sie arbeitet im hoheitlichen Bereich kostendeckend, aber nicht gewinnorientiert.

**Gültigkeit von Akkreditierungen**
Akkreditierungen sind üblicherweise fünf Jahre lang gültig, müssen jedoch in regelmäßigen Abständen durch die DAkkS überwacht werden.

### 8.2.3 Zertifizierung

Als „Zertifizierung “ (von lat. „certe“ = bestimmt, gewiss, sicher und „facere“ = machen, schaffen, verfertigen) bezeichnet man ein Verfahren, mit dessen Hilfe die Einhaltung bestimmter Anforderungen nachgewiesen wird.

Zertifizierung ist ein Teilprozess der Konformitätsbewertung. Zertifizierungen werden oft zeitlich befristet von unabhängigen Zertifizierungsstellen wie z. B. DQS, TÜV oder DEKRA vergeben und die Standards unabhängig kontrolliert.

Anforderungsbereiche
Die Bereiche, in denen Anforderungen gestellt werden, die zertifiziert werden können, umfassen im Allgemeinen:

- Produkte und Dienstleistungen und ihre jeweiligen Herstellungsverfahren einschließlich der Handelsbeziehungen
- Personen
- Systeme
- Unternehmen

**Arten der Zertifizierung**

- Nachweis von Ausbildungsstandards oder besonders ausgearbeiteten Fachnormen bei Personenzertifizierungen.
- Nachweis von Ausbildungsstandards bei der Anerkennung von Ausbildungsinstituten, wie er beispielsweise durch Berufsverband|Berufsverbände durchgeführt wird (bei nichtuniversitären Ausbildungen wird teils von „zertifizierten“ Ausbildungsinstituten, teils von „akkreditierten“ Ausbildungsinstituten gesprochen, wobei Letztere zugleich befugt sind, Personenzertifikationen oder Teile davon durchzuführen).
- International anerkannter Nachweis der persönlichen Befähigung, zum Beispiel als PMP (Project Management Professional) durch das PMI (Project Management Institute) IPMA-Zertifikate Level D-A für Projektmanager.
- Zertifizierung eines Managementsystems (zum Beispiel nach ISO 9001, ISO 14001).
- Zertifizierung von Produkten oder Dienstleistungen. Für Zertifizierungsstellen, die Zertifizierungssysteme für Produkte oder Dienstleistungen betreiben, besteht die EN ISO/IEC 17065 (früher EN 45011 bzw. ISO/IEC Guide 65).

- Zertifizierung der Herkunftsregion eines Produktes (DOC).
- Zertifizierung der Informationssicherheit nach BS 7799 oder ISO 27001|ISO/IEC 27001.
- Zertifizierung zum Nachweis der Einhaltung von Umwelt- und Sozialstandards, zum Beispiel bei der Zertifizierung von nachhaltig erzeugtem Holz (siehe Zertifizierung (Forstwirtschaft)|FSC) oder von Produkten aus Entwicklungsländern, die bessere Konditionen für die dortigen Produzenten garantieren nach Fairer Handel|Fair-Trade-Kriterien.
- Zertifizierung zum Nachweis der Einhaltung von Anforderungen an den Arbeitssicherheit, Arbeits- und Umweltschutz gem. Occupational Safety and Health Administration|OHSAS bzw. ISO 14001
- Zertifizierung zum Nachweis von Arbeitsbedingungen gemäß SA8000 und ähnlichen Regelwerken (Beispiele: Sedex und Business Social Compliance Initiative|BSCI).
- In der Software-Industrie ist die Zertifizierung insbesondere im Hinblick auf die Computersicherheit wichtig:
- Zertifizierung der Mitarbeiter zur Dokumentation von Fähigkeiten, Qualifikation und Kompetenz. Siehe dazu Liste der IT-Zertifikate.
- Zertifizierung von Softwareprodukten in Hinblick auf Funktionalität und Qualität. Besonders wichtig sind hier der amerikanische TCSEC- und der Europäische Information Technology Security Evaluation Criteria-Standard sowie im Hinblick auf die internationale Anerkennung die Common Criteria (CC). In Deutschland erfolgt die Zertifizierung durch das Bundesamt für Sicherheit in der Informationstechnik|BSI.
- Zertifizierung der IT-Umgebung nach IT-Grundschutz. Um in einem Unternehmen einen solchen Prozess zu begleiten, werden vom BSI Grundschutz-Auditoren lizenziert. Diese sind autorisiert, Testate als Vorbereitung auf die Zertifizierung auszugeben. Die eigentliche Zertifizierung erfolgt durch das BSI.
- Im Bereich Linux und freie Software ist ein wichtiges zertifizierendes Institut das kanadische Linux Professional Institute|LPI.
- In der Lebensmittelindustrie gibt es heute verschiedene Normen, angelehnt an die weltweit bekannte ISO 9001. Diese wurden zugeschnitten auf die Bedürfnisse der Lebensmittelindustrie. Weit verbreitete Standards sind zum Beispiel der International Food Standard (IFS), die Anforderungen des British Retail Consortium, Good Manufacturing Practice|GMP, Hazard Analysis and Critical Control Points und die ISO 22000. Zunehmender Akzeptanz erfreut sich für Fische auch der MSC-Standard des Marine Stewardship Council.
- Packmittelhersteller, die Packmittel für den direkten Kontakt mit Lebensmitteln (Primärpackmittel) herstellen, sind zunehmend nach der Norm BRC-IoP zertifiziert.
- Zertifizierung von Altersvorsorgeprodukten, z. B. Riesterrente.
- Zertifizierung von Energiemanagementsystemen gemäß ISO 50001.
- Nachhaltigkeitszertifizierung von Biomasse und Biokraftstoffen.

- Unternehmenszertifizierung, z.B. für den Bereich Nachhaltigkeit. Hier werden Standards vom Standardgeber vorgeschrieben. In diesem Fall wird vom Standardgeber definiert, was Nachhaltigkeit im unternehmerischen Kontext bedeutet. Das gesamte Unternehmen (Management, Lieferketten, Produkte usw.) wird im Zertifizierungsprozess überprüft.

### 8.2.4 Konfirmitätsbewertung

„Konformitätsbewertung“ ist in der internationalen Norm ISO/IEC 17000:2004 „Konformitätsbewertung – Begriffe und allgemeine Grundlagen“definiert als „ Darlegung, dass festgelegte Anforderungen bezogen auf ein Produkt, einen Prozess, ein System, eine Person oder eine Stelle erfüllt sind“.

Konformitätsbewertung ist ein Überbegriff für Tätigkeiten des Auswählens, Ermittelns (von Eigenschaften), Bewertens (etwa auf Einhaltung vorgegebener oder allgemeiner Anforderungen) und Bestätigens (etwa durch Konformitätserklärung|Erklärung des Herstellers, oder ein Zertifizierung|Zertifikat einer Zertifizierungsstelle, dass ein Produkt bestimmte Normen einhält). Solche Tätigkeiten sind beispielsweise Stichprobennahme, Prüfen, Inspizieren, Erklären, Zertifizieren, Akkreditieren. Die Objekte der Konformitätsbewertung sind nicht eingeschränkt.

Konformitätsbewertung findet auf vielfältige Weise und allen Ebenen statt:

- im Betrieb (etwa Endprüfung, Auditierung eines Qualitätsmanagementsystems durch eigene Auditoren):
- durch Stellen / Personen des Kunden oder Abnehmers:
- durch kommerzielle, vom Auftraggeber unabhängige Konformitätsbewertungsstellen (etwa Laboratorien; Zertifizierungsstellen; Inspektionsstellen; Akkreditierung (Wirtschaft), Akkreditierungsstellen):

EU-Konformitätsbewertung

Eine besondere Bedeutung hat die Konformitätsbewertung durch Benannte Stellen bei der Bewertung von Produkten auf ihre Übereinstimmung mit den Anforderungen einer Richtlinie (EU)|EU-Richtlinie. EU-Richtlinien gemäß Art. 95 EG-Vertrag für den Europäischer Binnenmarkt|Europäischen Binnenmarkt legen für zahlreiche Produkte Mindestanforderungen an die Sicherheit fest, die vom Hersteller erfüllt werden müssen.

Durch ein „Konformitätsbewertungsverfahren“ muss der Hersteller nachweisen, dass er die in der Richtlinie oder den Richtlinien enthaltenen grundlegenden Sicherheitsanforderungen eingehalten hat. Das Konformitätsbewertungsverfahren muss vom Hersteller für jedes Produkt vor dem erstmaligen Inverkehrbringen durchgeführt werden. Am Ende des Konformitätsbewertungsverfahrens stellt der Hersteller eine EU-Konformitätserklärung für sein Produkt aus, in der er erklärt, dass das Produkt zu den Anforderungen der entsprechenden Richtlinie(n) konform ist. Am Produkt bringt der Hersteller dann die CE-Kennzeichnung an, falls die angewandte Richtlinie dies vorsieht.

Nur im Sektor „Medizinprodukte“ besteht die Besonderheit, dass im Rahmen der Konformitätsbewertung nicht nur die Produktsicherheit nachgewiesen werden muss, sondern zusätzlich auch die

medizinisch-technische Leistungsfähigkeit von Medizinprodukten, so wie sie vom Hersteller in der Produktkennzeichnung einschließlich der Werbung als medizinische Indikation ausgelobt ist. Das entsprechende Nachweisverfahren nennt sich klinische Bewertung. Erst der (je nach der Produktklasse) extern durch Benannte Stelle zertifizierte Nachweis der Produktsicherheit und der Leistungsfähigkeit berechtigt Hersteller von Medizinprodukten zur Anbringung der **CE-Kennzeichnung**.

In den Anhängen der Richtlinien werden verschiedene Module für die Durchführung eines Konformitätsbewertungsverfahrens genannt. Welche Module gewählt werden können, hängt von der Klassifizierung des Produktes ab. Für Produkte mit höherem Risiko ist die Einbeziehung einer Benannten Stelle bei der Durchführung des Konformitätsbewertungsverfahrens obligatorisch. Beispiele für Module:

- Modul A2: Interne Fertigungskontrolle durch den Hersteller und Überwachung der Abnahme durch benannte Stelle
- Modul B *Baumusterprüfung* EG-Baumusterprüfung (Feststellung der Übereinstimmung mit den einschlägigen internationalen und nationalen Fachnormen (DIN, EN, ISO, IEC etc.), IMO-Resolutionen und SOLAS-Bestimmungen)
- Modul D : Qualitätssicherung Produktion (Darlegung der Qualitätssicherungsmaßnahmen vor, während und nach der Produktion einschließlich deren Häufigkeit)
- Modul E : Qualitätssicherung Produkt (Darlegung der Qualitätssicherungsmaßnahmen nach der Produktion einschließlich deren Häufigkeit (Endabnahme und Prüfung))
- Modul F : Prüfung der Produkte (Prüfung der Produkte auf Übereinstimmung mit dem Baumuster entweder durch statistische Kontrollen oder Prüfung jedes einzelnen Produkts durch die Benannte Stelle)
- Modul G : Einzelprüfung (anwendbar auf Produkte, die nicht in Serie produziert werden)

Je höher das Gefahrenpotential eines Produktes ist, umso mehr Prüfungsumfang muss auf eine „Benannte Stelle“ übertragen werden. Diese wird durch eine vierstellige Kennziffer hinter der CE-Kennzeichnung angegeben. Die Konformitätsbewertung für Produkte mit einem sehr geringen Gefährdungspotenzial kann der Hersteller ohne Einschaltung einer Benannten Stelle selbst durchführen.

In jedem Fall - also auch bei Einschaltung einer Drittstelle - muss eine EU-Konformitätserklärung (in der Regel) durch den Hersteller ausgestellt werden. Dies unterstreicht dessen alleinige Verantwortung (= Haftung) für das Produkt.

Bei der Konformitätsbewertung müssen die Sicherheitsanforderungen der EU-Richtlinien eingehalten werden.

### 8.2.5 Audit

Ein „Audit“ untersucht, ob Geschäftsprozesse, Anforderungen und Richtlinien die geforderten Standards erfüllen. Ein solches Untersuchungsverfahren erfolgt häufig im Rahmen eines Qualitätsmanagements. Die Audits werden von einem speziell hierfür geschulten Auditor durchgeführt.

Innerhalb des Qualitätsmanagements werden zwei Arten von Audits unterschieden: Im Bereich des Qualitätssicherung, statischen Qualitätsmanagements haben die Audits Prüfungscharakter, da sie Nachweise über vertragsmäßige Vereinbarungen liefern. Sie werden daher pro Überprüfungszyklus nur einmalig durchgeführt. In der Qualitätssicherung, dynamischen Qualitätssicherung (oder Qualitätsmanagement) kommt den Audits eine erweiterte Bedeutung zu: Sie dienen der Erfassung von Entwicklungstrends und geben den Initiatoren von Veränderungen wichtige Rückmeldungen über die Wirksamkeit ihrer eingeleiteten Maßnahmen. Die Aussagekraft dieser begleitenden Audits steigt mit der Wiederholungsrate, mit der der identische Fragenkatalog der identischen Betroffenengruppe zum identischen Thema vorgelegt wird. Vorgaben macht die „DIN/ISO 19011, Leitfaden zur Auditierung von Managementsystemen“.

### 8.2.6 DAkkS

Wie bereits oben erwähnt ist die die „Deutsche Akkreditierungsstelle GmbH“ („DAkkS“) zuständig für Akkreditierungen. Sie ist die nationale Akkreditierungsstelle mit Sitz in Berlin.

Gründungsgeschichte
Im Zuge der europäischen Verordnung (EG) Nr. 765/2008 (Artikel 4 Absatz 1) müssen alle EU-Mitgliedstaaten ab 1. Januar 2010 eine einzige nationale Akkreditierungsstelle benennen. Hierzu musste die Dachorganisation Deutscher Akkreditierungsrat (DAR) mit den folgenden vier Fachgesellschaften für bestimmte Gebiete zur DAkkS fusionieren:

- Deutsche Akkreditierungsstelle Chemie (DACH)
- Deutscher Kalibrierdienst (DKD)
- Deutsches Akkreditierungssystem Prüfwesen (DAP)
- Trägergemeinschaft für Akkreditierung (TGA) Über eine vorweggenommene Fusion enthält die TGA auch die Deutsche Akkreditierungsstelle Technik (DATech)

Organisation
Die DAkkS ist eine privatwirtschaftliche Organisation, die beliehene hoheitliche Aufgaben wahrnimmt.

Die GmbH-Anteilseigner der DAkkS sind jeweils zu einem Drittel:

- die Bundesländer, vertreten durch die Länder Bayern, Hamburg, Niedersachsen, Nordrhein-Westfalen und Sachsen-Anhalt.
- die Bundesrepublik Deutschland, vertretend durch das Bundesministerium für Wirtschaft und Energie
- die Deutsche Wirtschaft, vertretend durch den Bundesverband der Deutschen Industrie (BDI).

Die Bundesländer wurden primär beteiligt, um die bestehenden Organisationen der Länder leichter in die DAkkS zu überführen, „wodurch parallele Strukturen und Aktivitäten auf Landesebene verzichtbar werden“.

Kritik an der DAkkS: *In einer gemeinsamen Erklärung kritisierten Eurolab-D, der Verband der Materialprüfungsanstalten (VMPA) e.V. und der Deutsche Verband Unabhängiger Prüflaboratorien (VUP) die vom Bundeswirtschaftsministerium (BMWi) vorgelegte Reform der Gebührenverordnung für die Akkreditierungsstelle. Die Preissteigerungsrate schade dem Mittelstand und somit dem Wirtschaftsstandort Deutschland.*

# Kapitel 9

# Messunsicherheitsfortpflanzung: Konzepte und Methoden

## 9.1 Konzepte der Messunsicherheitsfortpflanzung: GUM-Reihe

Ein Messergebnis besteht aus einem Messwert und der Angabe seiner Messunsicherheit. Die Messunsicherheit beschreibt, welche Werte der Messgröße aufgrund der verfügbaren Informationen in Betracht kommen und wie stark diese Werte streuen. Sie betrifft deshalb sowohl die Auswertung wiederholter Beobachtungen als auch Informationen aus Kalibrierungen, Gerätespezifikationen und der Modellierung des Messverfahrens.

Für eine internationale Vergleichbarkeit und den internationalen Handel ist es erforderlich, dass die Verfahren zur Bestimmung von Messergebnissen möglichst einheitlich sind. Für das gesetzliche Messwesen beschreibt die international übereingekommene Richtlinienreihe zur Bestimmung von Messunsicherheiten einen gemeinsamen Rahmen. Diese Reihe von Richtlinien ist der *Guide to the expression of uncertainty in measurement* (GUM) mit seinen Ergänzungsdokumenten (*Supplements*). Sie ist für das gesetzliche Messwesen bindend.

Bei einer indirekten Messung wird die gesuchte Ausgangsgröße mithilfe eines Messmodells aus Eingangsgrößen bestimmt. Beispielsweise wird ein elektrischer Widerstand aus Spannung und Stromstärke berechnet. Da die Werte dieser Eingangsgrößen nur mit einer gewissen Unsicherheit bekannt sind, ist auch der daraus berechnete Widerstand unsicher.

Als *Messunsicherheitsfortpflanzung* bezeichnet man die Bestimmung der Unsicherheit einer Ausgangsgröße aus der Unsicherheitsbeschreibung ihrer Eingangsgrößen mithilfe des Messmodells. Anschaulich werden die Unsicherheiten der Eingangsgrößen über die Modellbeziehung an die Ausgangsgröße weitergegeben. Außerdem ist zu berücksichtigen, ob die Eingangsgrößen gemeinsame unsichere Einflüsse enthalten, beispielsweise durch dieselbe Referenz oder Kalibrierung. Die dadurch verbundenen Unsicherheitsbeiträge können sich je nach Modellbeziehung verstärken oder teilweise beziehungsweise vollständig aufheben.

Dieses Kapitel gibt einen Überblick über die Modelle, die benötigten Informationen und die möglichen Ergebnisangaben. Kapitel 10 behandelt die lineare und linearisierte Unsicherheitsfortpflanzung im Detail. Kapitel 11 wird die Fortpflanzung von Verteilungen mit der Monte-Carlo-Methode nach GUM Supplement 1 vertiefen.

### 9.1.1 Messmodell, Eingangsgrößen und Ausgangsgrößen

Die gesuchte Messgröße wird im Messmodell als *Ausgangsgröße* $Y$ bezeichnet. Die Größen, von denen sie abhängt, heißen *Eingangsgrößen* $X_1, \ldots, X_N$. Ein explizites Modell hat die Form

$$Y = f(\mathbf{X}), \qquad \mathbf{X} = (X_1, \ldots, X_N)^{\mathsf{T}}. \tag{9.1}$$

Eingangsgrößen können unmittelbar beobachtete Größen sein. Sie können aber auch aus einer früheren Auswertung stammen, etwa als Kalibrierfaktor oder als geschätzter Regressionsparameter. Die Begriffe „Eingangsgröße“ und „Ausgangsgröße“ beziehen sich auf die jeweilige Stufe der Auswertung und sind deshalb allgemeiner als „direkte“ und „indirekte Messgröße“.

Ein Messmodell muss alle relevanten Einflüsse berücksichtigen, damit die Messunsicherheit realistisch bewertet werden kann. Werden wesentliche Unsicherheitsbeiträge vernachlässigt, kann dies zu einer Unterschätzung der Messunsicherheit führen. Dazu gehören gegebenenfalls Korrekturen für bekannte systematische Abweichungen, Einflüsse der Temperatur oder Unsicherheiten eines Referenzwerts. Auch einer Korrektur mit dem Schätzwert null kann eine von null verschiedene Standardunsicherheit zugeordnet sein. Eine bekannte relevante Abweichung wird korrigiert; die Unsicherheit dieser Korrektur geht in das Unsicherheitsbudget ein.

Die physikalische Modellgleichung beschreibt, wie die Größen zusammenhängen. Zusätzlich benötigen wir Informationen über die Unsicherheiten der Eingangsgrößen und über Abhängigkeiten zwischen den Eingangsgrößen. Die Messunsicherheit ist dabei nicht auf die zufällige Streuung eines physikalischen Prozesses beschränkt: Auch unvollständige Kenntnisse über eine feste Einflussgröße werden durch geeignete Wahrscheinlichkeitsverteilungen oder deren Kenngrößen beschrieben.

Wir unterscheiden die Modellgleichungen danach, ob die Darstellung der Ausgangsgröße, der indirekten Messgröße, *explizit* oder *implizit* ist. Bei einem *expliziten* Modell können wir die Ausgangsgrößen unmittelbar aus den Eingangsgrößen berechnen. Ein *implizites* Modell gibt dagegen Gleichungen vor, die für die Ausgangsgrößen gelöst werden müssen.

| | Eine Ausgangsgröße | Mehrere Ausgangsgrößen |
|---|---|---|
| Explizit | $Y = f(\mathbf{X})$ | $\mathbf{Y} = \mathbf{f}(\mathbf{X})$ |
| Implizit | $h(Y, \mathbf{X}) = 0$ | $\mathbf{h}(\mathbf{Y}, \mathbf{X}) = \mathbf{0}$ |

Dabei ist $\mathbf{Y} = (Y_1, \ldots, Y_M)^\mathsf{T}$ der Vektor mehrerer Ausgangsgrößen. Im impliziten Fall nehmen wir hier $M$ Gleichungen für $M$ Ausgangsgrößen an. Damit die Auswertung eindeutig ist, muss eine geeignete Lösung existieren und im relevanten Bereich eindeutig ausgewählt werden können.

„Univariat“ bedeutet im Zusammenhang mit der Unsicherheitsfortpflanzung, dass *eine Ausgangsgröße* bestimmt wird. „Multivariat“ bedeutet, dass *mehrere Ausgangsgrößen* gemeinsam bestimmt werden. Die Anzahl der Eingangsgrößen kann in beiden Fällen größer als eins sein.

Eine Geradenanpassung liefert beispielsweise den Achsenabschnitt $\theta_0$ und die Steigung $\theta_1$. Obwohl die Regression nur einen Regressanden hat, ist ihre Unsicherheitsbewertung bezüglich der beiden Parameter multivariat. Als Ausgangsgrößen können wir $\mathbf{Y} = \mathbf{p} = (\theta_0, \theta_1)^\mathsf{T}$ wählen. Die beobachteten Werte bilden die Eingangsgrößen. Die Gleichungen

$$\nabla_{\mathbf{p}} Q(\mathbf{p}; \mathbf{X}) = \mathbf{0} \tag{9.2}$$

für das Minimum der Kostenfunktion sind eine implizite Darstellung der Auswertung. Die einzelnen Residuen sind dabei nicht sämtlich null. Bei einer linearen Regression mit vorgegebenen Regressorwerten lässt sich die Parameterschätzung auch explizit als Funktion der Beobachtungswerte schreiben, siehe Kapitel 2 Gl. (2.65). Für eine vorgegebene Regressormatrix $\mathbf{X}$ lässt sich die Lösung schreiben als

$$\hat{\boldsymbol{\theta}} = \underbrace{(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}}_{\mathbf{B}}\,\mathbf{Y}. \tag{9.3}$$

Die Matrix $\mathbf{B}$ ist dann fest vorgegeben. Die geschätzten Parameter ergeben sich explizit als lineare Funktion der beobachteten Regressandenwerte $\mathbf{Y}$.

Die Einordnung als explizit oder implizit hängt somit auch von der gewählten Darstellung des Auswerteverfahrens ab.

In dieser Vorlesung verwenden wir Großbuchstaben $X_i$ und $Y$ für die Größen, die im Wahrscheinlichkeitsmodell durch Zufallsvariablen repräsentiert werden. Kleinbuchstaben $x_i$ und $y$ bezeichnen ihre Schätzwerte sowie, im Fall der Eingangsgrößen, einzelne Beobachtungs- bzw. Messwerte. Als Schätzwert $x_i$ kann beispielsweise ein Mittelwert $\bar{x}_i$ oder ein einzelner Messwert verwendet werden.

Für die lineare Unsicherheitsfortpflanzung benötigen wir

- die Schätzwerte $x_i$,
- die zugeordneten Standardunsicherheiten $u(x_i)$ und
- gegebenenfalls die Kovarianzen $u(x_i, x_k)$ beziehungsweise die Korrelationskoeffizienten $\rho_{ik}$.

Die Standardunsicherheit wird als Standardabweichung ausgedrückt. Die Kovarianz hat dagegen die Einheit des Produkts der beiden Größen:

$$u(x_i, x_k) = \rho_{ik}\, u(x_i)u(x_k), \qquad u(x_i, x_i) = u^2(x_i). \tag{9.4}$$

In der Verteilungsbeschreibung gelten, sofern die Momente existieren, $x_i = \mathrm{E}(X_i)$ und $u^2(x_i) = \mathrm{Var}(X_i)$. Im GUM werden diese Kenngrößen aus den verfügbaren Informationen bewertet; sie sind im Allgemeinen selbst nicht exakt bekannt.

### 9.1.2 Modelle zur Unsicherheit direkter Messgrößen

Einer Bestimmung oder Abschätzung von Messunsicherheiten liegen unterschiedliche Modelle und Methoden zugrunde. Dabei ist zu unterscheiden, auf welcher Informationsgrundlage die Eingangsunsicherheiten bewertet werden, wie Wahrscheinlichkeiten interpretiert werden und ob vollständige Wahrscheinlichkeitsverteilungen oder Varianzen und Kovarianzen durch das Messmodell fortgepflanzt werden.

Der GUM unterscheidet bei der Bewertung von Standardunsicherheiten zwei *Kategorien* [GUM95]:

- *Typ A*: Bewertung durch statistische Auswertung einer Reihe von Beobachtungen;
- *Typ B*: Bewertung anhand anderer verfügbarer Informationen, beispielsweise aus Spezifikationen, Kalibrierscheinen oder bekannten Grenzen einer Eingangsgröße.

Diese Einteilung trifft weder eine Unterscheidung zwischen zufälligen und systematischen Abweichungen noch zwischen bestimmten Formen von Wahrscheinlichkeitsverteilungen.

Bei einer Bewertung nach Typ A wird die Standardunsicherheit durch statistische Auswertung einer Beobachtungsreihe bestimmt. Grundlage ist ein statistisches Beobachtungsmodell. Die Parameterschätzung kann beispielsweise durch Maximierung einer Likelihood erfolgen. Beim gaußverteilten Beobachtungsmodell ergibt sich der Stichprobenmittelwert $\bar{x}$ als Maximum-Likelihood-Schätzer des Erwartungswerts. Die Standardunsicherheit dieses Mittelwerts wird dann durch $s/\sqrt{J}$ geschätzt, wobei $s$ die Stichprobenstandardabweichung der $J$ Einzelbeobachtungen ist.

Bei einer Bewertung nach Typ B wird die Unsicherheit dagegen nicht aus einer solchen Beobachtungsreihe ermittelt, sondern aus anderen verfügbaren Informationen abgeleitet oder als bereits bewertete Unsicherheit übernommen. Die zugrunde liegende Information kann ihrerseits aus einer statistischen Auswertung stammen. Dies betrifft auch direkte Messgrößen, für die keine entsprechenden Stichprobendaten vorliegen. Das in einem Kalibrierschein angegebene Ergebnis stellt beispielsweise eine Information dar, die als bereits bewertete Unsicherheit übernommen werden kann. In einem Kalibrierschein liegt eine sorgfältig bestimmte Unsicherheitsangabe vor, die zu Typ B gezählt wird.

Unter Typ B werden aber auch Größen mit sehr begrenzt verfügbarer Information: Möglicherweise sind nur die Grenzen eines Intervalls, in dem die Werte diese Größe erwartet werden, bekannt, ohne Angaben darüber, welche Werte innerhalb dieses Intervalls häufiger oder seltener zu erwarten sind. Um daraus eine Standardunsicherheit abzuleiten, muss eine Wahrscheinlichkeitsverteilung *angesetzt* werden. Diese Verteilung beschreibt die Information über die möglichen Werte der Größe. Sie muss keine beobachtete Häufigkeitsverteilung wiedergeben, sondern sie kann auf einem heuristischen Erfahrungswissen beruhen.

Ein Beispiel ist die Temperatur bei einer Längenmessung. Es sei nur bekannt, dass die Temperatur $T$ während der Messung im Intervall $[T_\mathrm{M} - a, T_\mathrm{M} + a]$ liegt. Eine statistisch auswertbare Reihe von Temperaturbeobachtungen liege nicht vor. Werden aufgrund dieser begrenzten Information alle Werte innerhalb des Intervalls als – grob gesenen – gleich plausibel angesetzt, ergibt sich das Modell

$$T \sim \mathcal{U}(T_\mathrm{M} - a, T_\mathrm{M} + a), \qquad \mathrm{E}(T) = T_\mathrm{M}, \qquad u(T) = \frac{a}{\sqrt{3}}. \tag{9.5}$$

Die Rechteckverteilung ist dabei eine Modellannahme. Sie folgt nicht allein aus der Kenntnis der Intervallgrenzen.

Die Temperatur geht beispielsweise über den Faktor

$$K = 1 + \alpha(T - T_0) \tag{9.6}$$

in das Modell der thermischen Längenänderung ein. Hier bezeichnet $\alpha$ den linearen Wärmeausdehnungskoeffizienten und $T_0$ die Referenztemperatur. Mit

$$L(T) = KL_0 \tag{9.7}$$

ergibt sich die auf $T_0$ bezogene Länge als $L_0 = L(T)/K$. Wird $\alpha$ zunächst als bekannt behandelt, folgen

$$k = 1 + \alpha(T_\mathrm{M} - T_0), \qquad u(K) = |\alpha|\, u(T) = \frac{|\alpha| a}{\sqrt{3}}. \tag{9.8}$$

Die Unsicherheit des Faktors entsteht somit aus der unvollständigen Kenntnis der Temperatur. Ist

auch $\alpha$ unsicher, muss dessen Unsicherheit zusätzlich im Messmodell berücksichtigt werden.

Eine solche Wahrscheinlichkeitsverteilung bedeutet nicht, dass eine während der Messreihe konstante Temperatur bei jeder Wiederholung einen neuen zufälligen Wert annimmt. Sie kann auch die Unkenntnis dieses konstanten Temperaturwerts beschreiben. Wiederholte Längenmessungen verringern diese Unkenntnis nicht automatisch.

Typ B ist jedoch nicht grundsätzlich eine Bewertung bei unzureichender Information. Auch die Übernahme einer sorgfältig bestimmten Unsicherheitsangabe aus einem Kalibrierschein gehört zu Typ B.

Typ B umfasst auch die Übernahme bereits bewerteter Unsicherheiten aus einem Kalibrierschein. Ist dort die Standardunsicherheit angegeben, kann sie unmittelbar übernommen werden. Ist eine erweiterte Unsicherheit $U$ mit dem Erweiterungsfaktor $k$ angegeben, ergibt sich die Standardunsicherheit als $u = U/k$. Dafür ist keine neue Verteilungsannahme erforderlich.

Der GUM ordnet diesen Bewertungsweg Typ B zu, obwohl die zugrunde liegende Kalibrierung auf umfangreichen statistischen Auswertungen beruhen kann. Typ B bezeichnet daher nicht grundsätzlich eine Bewertung bei geringer oder unzureichender Information.

Typ B ist die Sammelkategorie für Verfahren, bei denen die Standardunsicherheit nicht durch statistische Auswertung einer Beobachtungsreihe bestimmt wird. Stattdessen wird sie aus anderen verfügbaren Informationen abgeleitet oder als bereits bewertete Standardunsicherheit übernommen.

Die Unsicherheit einer Korrektur für einen systematischen Einfluss kann sowohl nach Typ B bewertet werden als auch – falls dafür geeignete Beobachtungsdaten (Stichproben) statistisch ausgewertet werden – nach Typ A.

Beide Bewertungsverfahren liefern Varianzen beziehungsweise Standardunsicherheiten, die unter den jeweiligen Modellannahmen in die Unsicherheitsfortpflanzung eingehen. Die Kennzeichnung als Typ A oder Typ B begründet jedoch weder eine Normalverteilung noch die Verwendung von $t$-Quantilen zur Bestimmung eines Überdeckungsintervalls.

Für $J$ unabhängige Wiederholungen unter unveränderten Bedingungen ist die Standardunsicherheit des Mittelwerts

$$u(\bar{x}) = \frac{s}{\sqrt{J}}, \qquad s^2 = \frac{1}{J-1}\sum_{j=1}^{J}(x_j - \bar{x})^2. \tag{9.9}$$

$s$ beschreibt die Streuung einzelner Beobachtungswerte. $s/\sqrt{J}$ beschreibt die Unsicherheit des aus dieser Messreihe bestimmten Mittelwerts. Gemeinsame Einflüsse, etwa die Unsicherheit eines Kalibrierfaktors, werden nicht durch diese Mittelung verkleinert.

Liegt zu einer Einflussgröße nur die Information vor, dass ihre Werte in $[x - a, x + a]$ liegen, kann bei gleich plausiblen Werten eine Rechteckverteilung angesetzt werden. Ihre Standardunsicherheit ist $a/\sqrt{3}$. Die Gleichverteilung ist eine begründungsbedürftige Modellzuweisung; die Intervallgrenzen allein erzwingen sie mathematisch nicht. GUM Supplement 1 begründet diese Zuweisung in Abschnitt 6.4.2 über das Prinzip der maximalen Entropie. Für mehrere Eingangsgrößen muss zusätzlich das gemeinsame statistische Modell beschrieben werden. Eine solche Verteilung wird durch die verfügbare Information begründet und nicht allein durch die Einteilung in Typ B.

Auch muss bei gleichverteilter Eingangsgröße bei der Linearisierung genauer aufgepasst werden, aber dazu später, wenn wir uns das Konzept der Sensitivitäten für die Unsicherheitsfortpflanzung anschauen. Ebenfalls ist besonders dann mit Gleichverteilungsansätzen Vorsicht geboten, wenn bei der Abschätzung eines Erweiterungsfaktors für das Überdeckungsintervall $t$-Quantile und die Welch-Satterthwaite-Näherung zur Bestimmung von Freiheitsgraden verwendet werden, da diesen ein normalverteiltes Beobachtungsmodell zugrunde liegt.

### 9.1.3 Ansätze zur Unsicherheitsfortpfanzung im GUM

Die drei zentralen Dokumente der Richtlinienreihe zur Messunsicherheitsfortpflanzung unterscheiden sich vor allem darin, welche Informationen fortgepflanzt werden und ob eine oder mehrere Ausgangsgrößen betrachtet werden. Um für eine Unsicherheitsbestimmung den geeignetsten Ansatz auszuwählen, müssen die Unsicherheiten der verschiedenen Eingangs- und Einflussgrößen bewertet werden. Dazu muss ein Messmodell gefunden werden, sowie eine dem Messmodell angemessene Methode zu Fortpflanzung der Unsicherheiten gefunden.

Die Bewertung lässt sich in drei Schritte gliedern:

1. *Formulieren*: Messgröße und Messmodell festlegen; Informationen über die Eingangsgrößen einschließlich ihrer Abhängigkeiten bewerten.
2. *Fortpflanzen*: Aus den Unsicherheiten oder Verteilungen der Eingangsgrößen die entsprechende Unsicherheit bzw. Wahrscheinlichkeitsverteilung der Ausgangsgrößen berechnen.
3. *Zusammenfassen*: Schätzwerte, Standardunsicherheiten und gegebenenfalls Überdeckungsintervalle oder gemeinsame Überdeckungsbereiche angeben.

Die drei zentralen GUM-Dokumente sind folgende

1. JCGM 100:2008 GUM 1995 with minor corrections *Evaluation of measurement data - Guide to the expression of uncertainty in measurement* [GUM95]; oftmals einfach mit „GUM“ bezeichnet, betrifft univariate und explizite Modelle,

   `https://www.bipm.org/documents/20126/2071204/JCGM_100_2008_E.pdf`

   Das Amendment aus dem Jahr 2026, *JCGM 100:2008/Amd.1:2026*, besagt, dass bei erheblicher Nichtlinearität die Berechnung des Ausgangsschätzwerts um höhere Taylorterme zu ergänzen ist, oder dass die Monte-Carlo-Methode nach Supplement 1 angewandt werden.

   `https://doi.org/10.59161/PPDI3267`

   In der nächsten Vorlesung, Kapitel 10 werden wir im Detail auf die Unsicherheitsfortpflanzung für linearisierbare Modelle eingehen, sowie auf die Bestimmung eines Überdeckungsintervalls für statistische Beobachtungsmodelle, die im wesentlichen auf Normalverteilungen beruhen.

2. JCGM 101:2008 *Evaluation of measurement data - Supplement 1 to the Guide to the expression of uncertainty in measurement - Propagation of distributions using a Monte Carlo method* [GUMS1]; kurz mit „GUM - Supplement 1“ bezeichnet, betrifft explizite und implizite, univariate Modelle des physikalischen Zusammenhangs,

- die sich nicht einfach linearisieren lassen
- und/oder die sich nicht in einer geschlossenen analytischen Form darstellen lassen
- und/oder wenn zu den Beobachtungsmodellen, d.h. den statistischen Verteilungen der direkten Messgrößen, die Bestimmung eines Erweiterungsfaktors problematisch ist.

In Supplement 1 wird zu jeder direkten Messgröße eine Wahrscheinlichkeitsdichteverteilung vorgegeben.

Dieses Verfahren wird Kapitel 11 genauer dargelegt.

`https://www.bipm.org/documents/20126/2071204/JCGM_101_2008_E.pdf`

3. JCGM 102:2011 *Evaluation of measurement data – Supplement 2 to the Guide to the expression of uncertainty in measurement - Extension to any number of output quantities* liefert die Verallgemeinerung der beiden Richtliniendokumente JCGM 100 und JCGM 101 für den multivariaten Fall mit mehreren $M > 1$ indirekten Größen, also einem Größenvektor $\mathbf{Y}$, sowie die Fortpflanzung von Kovarianzen.

   `https://www.bipm.org/documents/20126/2071204/JCGM_102_2011_E.pdf`

Im folgenden fassen wir die wesentlichen Inhalte der zentralen GUM-Dokumente zusammen:

GUM: Fortpflanzung von Standardunsicherheiten

*JCGM 100:2008*, üblicherweise als GUM bezeichnet, beschreibt unter anderem die Bewertung der Eingangsunsicherheiten, deren Kombination und die Angabe einer erweiterten Messunsicherheit [GUM95]. Die Grundform der Fortpflanzungsrechnung betrachtet eine skalare Ausgangsgröße. Für ein lineares Modell mit einem konstanten additiven Term

$$Y = c_0 + \sum_{i=1}^{N} c_i X_i \tag{9.10}$$

mit festen Koeffizienten ist die Varianzfortpflanzung exakt, da der konstante Term $c_0$ den Erwartungswert nur verschiebt, aber die Varianz nicht beeinflusst:

$$u_{\mathrm{c}}^2(y) = \sum_{i=1}^{N} \sum_{k=1}^{N} c_i c_k \, u(x_i, x_k). \tag{9.11}$$

$u_{\mathrm{c}}(y)$ heißt *kombinierte Standardunsicherheit*. Die Formel folgt aus den Rechenregeln für Kovarianzen und setzt keine Normalverteilung der Eingangsgrößen voraus.

Für ein nichtlineares Modell wird häufig die Taylorentwicklung erster Ordnung am Punkt $\mathbf{x} = (x_1, \ldots, x_N)^{\mathsf{T}}$ verwendet:

$$Y = f(\mathbf{X}) \approx f(\mathbf{x}) + \sum_{i=1}^{N} c_i (X_i - x_i), \qquad c_i = \left.\frac{\partial f}{\partial X_i}\right|_{\mathbf{X}=\mathbf{x}}. \tag{9.12}$$

Die $c_i$ heißen *Sensitivitätskoeffizienten*. Mit ihnen wird Gl. (9.11) auf das linearisierte Modell angewandt. Die resultierende Standardunsicherheit ist dann eine Näherung für diejenige des ursprünglichen Modells.

Die Angemessenheit der linearen Unsicherheitsfortpflanzung hängt gemeinsam von der Krümmung des Modells sowie von der Breite und der Form der Eingangsverteilungen ab. Die Abweichungen zwischen Modellfunktion und linearisiertem Modell werden bei der Berechnung von Erwartungswert und Varianz mit der gemeinsamen Wahrscheinlichkeitsverteilung der Eingangsgrößen gewichtet. Deshalb ist zu prüfen, wie gut die Linearisierung in den Bereichen ist, die wesentlich zu diesen Größen beitragen. Die bloße Existenz von Ableitungen garantiert noch keine ausreichende Linearisierung.

Bei einer Rechteckverteilung erhalten gleich breite Teilintervalle dieselbe Wahrscheinlichkeit. Daher können auch randnahe Bereiche, in denen die Modellfunktion stärker von der Tangente abweicht, einen wesentlichen Beitrag leisten. Bei einer symmetrischen Dreiecksverteilung oder Normalverteilung auf demselben Intervall mit dem Maximum am Entwicklungspunkt erhalten diese Bereiche ein geringeres Gewicht. Eine zum Rand hin abfallende Dichte kann die Linearisierung somit begünstigen. Die Breite der Verteilung und der Verlauf der Modellfunktion sind gemeinsam zu berücksichtigen. GUM Supplement 1 behandelt in Abschnitt 5.8.1 die Voraussetzung, dass die nicht berücksichtigten Taylorterme vernachlässigbar sind.

Besonders deutlich wird der Einfluss der Verteilungsform bei einer U-förmigen Arkussinusverteilung, die GUM Supplement 1 in Abschnitt 6.4.6 beschreibt. Sie ergibt sich beispielsweise für eine sinusförmig schwingende Eingangsgröße, deren Phase als gleichverteilt angesetzt wird. Da die Schwingung länger nahe ihren Umkehrpunkten verweilt, erhalten randnahe Bereiche eine höhere Wahrscheinlichkeit als bei einer Rechteckverteilung auf demselben Intervall. Wenn dort die Modellfunktion stärker von der Tangente am Entwicklungspunkt abweicht, können die vernachlässigten nichtlinearen Beiträge entsprechend stärker ins Gewicht fallen. Die Linearisierung ist dann besonders sorgfältig zu prüfen.

Bei relevanter Nichtlinearität kann außerdem die Schätzung $y = f(\mathbf{x})$ vom Erwartungswert $\mathrm{E}[f(\mathbf{X})]$ abweichen. Das Amendment *JCGM 100:2008/Amd.1:2026* hebt diesen Punkt ausdrücklich hervor: Bei erheblicher Nichtlinearität ist auch die Berechnung des Ausgangsschätzwerts um höhere Taylorterme zu ergänzen, oder es kann die Monte-Carlo-Methode nach Supplement 1 angewandt werden.[1]

Für die Berechnung eines Überdeckungsintervalls sind zusätzliche Informationen über die Form der Ausgangsverteilung erforderlich. Normal- und $t$-Approximationen spielen dabei eine wichtige Rolle.

Diese Approximationen sind von der Varianzfortpflanzung selbst zu unterscheiden: Während die Varianzfortpflanzung bei einem linearen Modell keine Normalverteilung der Eingangsgrößen voraussetzt, lässt sich jedoch aus der kombinierten Standardunsicherheit allein kein Überdeckungsintervall mit vorgegebener Überdeckungswahrscheinlichkeit bestimmen.

Die Welch-Satterthwaite-Näherung, die noch in Abschnitt 10.4 hergeleitet wird, setzt ein gaußverteiltes statistisches Beobachtungsmodell und unabhängige Varianzschätzer voraus. Für Stichprobenvarianzen aus unabhängigen normalverteilten Beobachtungen sind die normierten Varianzschätzer $\chi^2$-verteilt. Auf dieser Eigenschaft beruht die Bestimmung der effektiven Freiheitsgrade.

Werden die Eingangsgrößen durch die zugehörigen Stichprobenmittelwerte geschätzt und durch ein lineares Modell kombiniert, ist der Ausgangsschätzer normalverteilt. Seine mit der geschätzten kombinierten Standardunsicherheit normierte Abweichung vom wahren Wert wird näherungsweise durch eine $t$-Verteilung mit den effektiven Freiheitsgraden beschrieben. Die Berücksichtigung der Unsicherheit der

[1] *JCGM 100:2008/Amd.1:2026, Nonlinearity in measurement models*: `https://doi.org/10.59161/PPDI3267`.

Varianzschätzung ist insbesondere bei kleinen Stichprobenumfängen bedeutsam.

Für nichtnormalverteilte Beobachtungen gilt die $\chi^2$-Verteilung der normierten Stichprobenvarianzen im Allgemeinen nicht. Es ist daher für solche Beobachtungsmodelle weder die übliche Welch-Satterthwaite-Formel mit $\nu_i = J_i - 1$ noch die daraus abgeleitete Verwendung von $t$-Quantilen gerechtfertigt. Die Fortpflanzung von Wahrscheinlichkeitsdichteverteilung bietet dafür einen Ausweg.

GUM – Supplement 1: Fortpflanzung von Verteilungen

*JCGM 101:2008*, Supplement 1 zum GUM, behandelt die Fortpflanzung von Wahrscheinlichkeitsverteilungen für eine Ausgangsgröße mit einer Monte-Carlo-Methode [GUMS1].[2] Sie ist insbesondere hilfreich, wenn die Linearisierung nicht ausreicht oder wenn sich die Ausgangsverteilung nicht geeignet durch eine Normal- oder $t$-Approximation beschreiben lässt. Sie kann auch bei linearen Modellen verwendet werden.

Für die Fortpflanzung vollständiger Verteilungen benötigen wir eine *gemeinsame Wahrscheinlichkeitsverteilung* der Eingangsgrößen, bei stetigen Größen beschrieben durch $p_{\mathbf{X}}(\mathbf{X}')$. Bei unabhängigen Eingangsgrößen ist

$$p_{\mathbf{X}}(\mathbf{X}') = \prod_{i=1}^{N} p_{X_i}(X_i'). \tag{9.13}$$

Die Striche kennzeichnen hier die Integrations- beziehungsweise Funktionsargumente und keine zusätzlichen Messgrößen.

Unkorreliertheit allein genügt nicht für diese Produktdarstellung. Der in dieser Vorlesungsreihe verwendete Pearson-Korrelationskoeffizient $\rho$ beschreibt die Stärke und Richtung eines linearen statistischen Zusammenhangs. Ein Korrelationskoeffizient von null bedeutet deshalb nicht, dass die Größen statistisch unabhängig sind: Nichtlineare Abhängigkeiten können weiterhin bestehen.

Für die Darstellung der gemeinsamen Wahrscheinlichkeitsdichte als Produkt der einzelnen Dichten müssen die Eingangsgrößen gemeinsam statistisch unabhängig sein. Die Kenntnis der Werte anderer Eingangsgrößen darf dann die Wahrscheinlichkeitsverteilung einer Eingangsgröße nicht verändern. Diese Voraussetzung geht über das Verschwinden aller paarweisen Korrelationskoeffizienten hinaus.

Abhängigkeiten können aus gemeinsam verwendeten Referenzwerten, Kalibrierungen oder Umwelteinflüssen entstehen. Sie können auch dann bestehen, wenn die Eingangsgrößen in getrennten Messreihen bestimmt wurden. Umgekehrt sind gleichzeitig beobachtete Größen nicht zwangsläufig korreliert; sie können jedoch trotz eines Korrelationskoeffizienten von null statistisch abhängig sein.

Die Grundidee der Monte-Carlo-Simulation zur Fortpflanzung vollständiger Verteilungen ist: Wir erzeugen viele mögliche Wertekombinationen der Eingangsgrößen und berechnen für jede Kombination die Ausgangsgröße [Cox06]. Mit $K$ für die Anzahl der Monte-Carlo-Durchläufe schreiben wir

$$\mathbf{x}^{(r)} \sim p_{\mathbf{X}}, \qquad y^{(r)} = f(\mathbf{x}^{(r)}), \qquad r = 1, \ldots, K. \tag{9.14}$$

Bei abhängigen Eingangsgrößen müssen die Ziehungen diese Abhängigkeit wiedergeben. Unabhängiges

[2] `https://doi.org/10.59161/JCGM101-2008`.

Ziehen aus den einzelnen Randverteilungen würde im Allgemeinen eine andere Ausgangsverteilung liefern.

Die Werte $y^{(r)}$ bilden eine numerische Darstellung der Ausgangsverteilung. Ihr Mittelwert und ihre Standardabweichung liefern Näherungen für den Erwartungswert und die Standardunsicherheit von $Y$. Die empirische Verteilungsfunktion liefert Näherungen für Quantile und damit für Überdeckungsintervalle. Ein Histogramm kann die Verteilung veranschaulichen; seine Klassenwahl ist für die Berechnung dieser Kenngrößen nicht erforderlich.

Die Monte-Carlo-Durchläufe sind keine zusätzlichen experimentellen Beobachtungen. Eine größere Anzahl $K$ verbessert die numerische Genauigkeit der berechneten Kenngrößen, verringert aber nicht die Messunsicherheit. Details zur Verteilungszuordnung, zur numerischen Stabilität und zu Abbruchkriterien folgen in Kapitel 11.

GUM – Supplement 2: Mehrere Ausgangsgrößen

*JCGM 102:2011*, Supplement 2 zum GUM, erweitert die Betrachtung auf mehrere Ausgangsgrößen.[3] Es behandelt sowohl die Fortpflanzung von Kovarianzmatrizen als auch die Monte-Carlo-Fortpflanzung gemeinsamer Verteilungen. Explizite und implizite Modelle werden berücksichtigt.

Bei mehreren Ausgangsgrößen beschreiben deren einzelne Standardunsicherheiten noch nicht die Zusammenhänge zwischen ihren Unsicherheiten. Die Ausgangsgrößen können beispielsweise korreliert sein, weil sie aus denselben Eingangsgrößen berechnet werden. Die gemeinsame Beschreibung durch Varianzen und Kovarianzen erfolgt mithilfe der Kovarianzmatrix der Ausgangsgrößen.

Für ein implizites Messmodell

$$\mathbf{h}(\mathbf{Y}, \mathbf{X}) = \mathbf{0} \tag{9.15}$$

mit $M$ Ausgangsgrößen und $N$ Eingangsgrößen werden zunächst die Ausgangsschätzwerte $\hat{\mathbf{y}}$ durch Lösen des Gleichungssystems

$$\mathbf{h}(\hat{\mathbf{y}}, \mathbf{x}) = \mathbf{0} \tag{9.16}$$

bestimmt. Dabei enthält $\mathbf{x}$ die Beobachtungswerte beziehungsweise Schätzwerte der Eingangsgrößen.

Wir entwickeln das implizite Modell um den Punkt $(\hat{\mathbf{y}}, \mathbf{x})$ und berücksichtigen die Taylorentwicklung bis zur ersten Ordnung. Da sowohl die Größen selbst als auch ihre am Entwicklungspunkt eingesetzten Schätzwerte die Modellgleichung erfüllen, sind $\mathbf{h}(\mathbf{Y}, \mathbf{X})$ und $\mathbf{h}(\hat{\mathbf{y}}, \mathbf{x})$ gleich null. Damit ergibt sich eine näherungsweise lineare Beziehung zwischen den Änderungen der Eingangs- und Ausgangsgrößen:

$$\mathbf{C}_y(\mathbf{Y} - \hat{\mathbf{y}}) + \mathbf{C}_x(\mathbf{X} - \mathbf{x}) \approx \mathbf{0}. \tag{9.17}$$

[3] *Extension to any number of output quantities*, `https://doi.org/10.59161/JCGM102-2011`.

Die Sensitivitätsmatrizen sind

$$\begin{aligned}\mathbf{C}_y &= \left.\frac{\partial \mathbf{h}}{\partial \mathbf{Y}}\right|_{\mathbf{Y}=\hat{\mathbf{y}},\,\mathbf{X}=\mathbf{x}} = \left.\left(\frac{\partial h_j}{\partial Y_m}\right)_{j,m=1}^{M}\right|_{\mathbf{Y}=\hat{\mathbf{y}},\,\mathbf{X}=\mathbf{x}},\\ \mathbf{C}_x &= \left.\frac{\partial \mathbf{h}}{\partial \mathbf{X}}\right|_{\mathbf{Y}=\hat{\mathbf{y}},\,\mathbf{X}=\mathbf{x}} = \left.\left(\frac{\partial h_j}{\partial X_i}\right)_{\substack{j=1,\ldots,M\\ i=1,\ldots,N}}\right|_{\mathbf{Y}=\hat{\mathbf{y}},\,\mathbf{X}=\mathbf{x}}.\end{aligned} \tag{9.18}$$

$\mathbf{C}_y$ besitzt $M$ Zeilen und $M$ Spalten, $\mathbf{C}_x$ besitzt $M$ Zeilen und $N$ Spalten.

Aus dem linearisierten Modell folgt die Kovarianzfortpflanzung

$$\mathbf{C}_y\ \mathrm{Cov}(\mathbf{Y})\,\mathbf{C}_y^{\mathsf{T}} \approx \mathbf{C}_x\ \mathrm{Cov}(\mathbf{X})\,\mathbf{C}_x^{\mathsf{T}}. \tag{9.19}$$

Ist $\mathbf{C}_y$ invertierbar, können die Ausgangsgrößen lokal als Funktionen der Eingangsgrößen beschrieben werden. Die zugehörige Sensitivitätsmatrix lautet

$$\mathbf{C} = -\mathbf{C}_y^{-1}\mathbf{C}_x. \tag{9.20}$$

Damit ergibt sich

$$\mathrm{Cov}(\mathbf{Y}) \approx \mathbf{C}\ \mathrm{Cov}(\mathbf{X})\,\mathbf{C}^{\mathsf{T}}. \tag{9.21}$$

Die Matrix $\mathbf{C}$ beschreibt, wie Änderungen der Eingangsgrößen in erster Ordnung auf die Ausgangsgrößen wirken.

Die Elemente der Ausgangskovarianzmatrix werden mit

$$\mathrm{Cov}(\mathbf{Y}) = \big(u(\hat{y}_l, \hat{y}_m)\big)_{l,m=1}^{M} \tag{9.22}$$

bezeichnet. Ihre Diagonale enthält die Varianzen $u^2(\hat{y}_l)$, also die quadrierten Standardunsicherheiten. Die Elemente außerhalb der Diagonale sind die Kovarianzen zwischen je zwei Ausgangsgrößen.

Für ein explizites Messmodell

$$\mathbf{Y} = \mathbf{f}(\mathbf{X}) \tag{9.23}$$

kann die Sensitivitätsmatrix unmittelbar berechnet werden:

$$\mathbf{C} = \left.\frac{\partial \mathbf{f}}{\partial \mathbf{X}}\right|_{\mathbf{X}=\mathbf{x}}, \qquad C_{l,i} = \left.\frac{\partial f_l}{\partial X_i}\right|_{\mathbf{X}=\mathbf{x}}. \tag{9.24}$$

Sie ist die Jacobi-Matrix der Modellfunktion mit $M$ Zeilen und $N$ Spalten. Auch hier erfolgt die Kovarianzfortpflanzung nach Gl. (9.21).

Für ein Modell, das linear in den Eingangsgrößen ist und einen konstanten additiven Term enthalten kann, gilt diese Beziehung exakt. Für nichtlineare Modelle ist sie eine Näherung, deren Angemessenheit von der Güte der Linearisierung im relevanten Unsicherheitsbereich abhängt.

Bei einer Monte-Carlo-Auswertung eines impliziten Modells wird das Gleichungssystem für jede aus der gemeinsamen Eingangsverteilung gezogene Kombination von Eingangswerten gelöst. Aus den erhaltenen Ausgangswerten werden anschließend die Standardunsicherheiten und Kovarianzen bestimmt.

Für die Fortpflanzung vollständiger Verteilungen benötigen wir eine *gemeinsame Wahrscheinlichkeitsverteilung* der Eingangsgrößen, bei stetigen Größen beschrieben durch $p_{\mathbf{X}}(\mathbf{X}')$. Bei unabhängigen Eingangsgrößen ist

$$p_{\mathbf{X}}(\mathbf{X}') = \prod_{i=1}^{N} p_{X_i}(X_i'). \tag{9.25}$$

Die Striche kennzeichnen hier die Integrations- beziehungsweise Funktionsargumente und keine zusätzlichen Messgrößen.

Unkorreliertheit allein genügt nicht für diese Produktdarstellung. Der in dieser Vorlesungsreihe verwendete Pearson-Korrelationskoeffizient $\rho$ beschreibt die Stärke und Richtung eines linearen statistischen Zusammenhangs. Ein Korrelationskoeffizient von null bedeutet deshalb nicht, dass die Größen statistisch unabhängig sind: Nichtlineare Abhängigkeiten können weiterhin bestehen.

Für die Darstellung der gemeinsamen Wahrscheinlichkeitsdichte als Produkt der einzelnen Dichten müssen die Eingangsgrößen gemeinsam statistisch unabhängig sein. Die Kenntnis der Werte anderer Eingangsgrößen darf dann die Wahrscheinlichkeitsverteilung einer Eingangsgröße nicht verändern. Diese Voraussetzung geht über das Verschwinden aller paarweisen Korrelationskoeffizienten hinaus.

Abhängigkeiten können aus gemeinsam verwendeten Referenzwerten, Kalibrierungen oder Umwelteinflüssen entstehen. Sie können auch dann bestehen, wenn die Eingangsgrößen in getrennten Messreihen bestimmt wurden. Umgekehrt sind gleichzeitig beobachtete Größen nicht zwangsläufig korreliert; sie können jedoch trotz eines Korrelationskoeffizienten von null statistisch abhängig sein.

Ein *gemeinsamer Überdeckungsbereich* soll den gesamten Größenvektor mit vorgegebener Wahrscheinlichkeit enthalten. Für zwei Ausgangsgrößen kann ein solcher Bereich beispielsweise eine Ellipse sein. Zwei einzelne 95 %-Intervalle bilden hingegen nicht automatisch einen gemeinsamen 95 %-Bereich. Für zwei unabhängige Ausgangsgrößen beträgt die gemeinsame Wahrscheinlichkeit des aus diesen Intervallen gebildeten Rechtecks $0.95^2 = 0.9025$, also nur 90.25 %.

In einer vollständigen Verteilungsbeschreibung sind der Schätzwert und die Standardunsicherheit, sofern die Momente existieren,

$$y = \int_{-\infty}^{\infty} Y'\, p_Y(Y')\,\mathrm{d}Y', \qquad u^2(y) = \int_{-\infty}^{\infty} (Y'-y)^2 p_Y(Y')\,\mathrm{d}Y'. \tag{9.26}$$

Diese beiden Kenngrößen legen die Form der Verteilung im Allgemeinen nicht fest. Insbesondere lässt sich aus einer Standardunsicherheit allein keine bestimmte Überdeckungswahrscheinlichkeit ableiten.

Wir verwenden $P = 1 - \alpha$ für die gewünschte *Überdeckungswahrscheinlichkeit* und

$$F_Y(z) = \Pr(Y \le z) \tag{9.27}$$

für die Verteilungsfunktion. Ein zweiseitiges Intervall mit gleich großen Wahrscheinlichkeiten in den beiden äußeren Bereichen ist

$$[y_{\mathrm{low}}, y_{\mathrm{high}}] = \left[F_Y^{-1}(\alpha/2), F_Y^{-1}(1-\alpha/2)\right]. \tag{9.28}$$

Bei einer schiefen Verteilung liegt der Erwartungswert im Allgemeinen nicht in der Mitte dieses Quan-

tilintervalls. Unterhalb seiner unteren Grenze und oberhalb seiner oberen Grenze liegt jeweils die Wahrscheinlichkeit $\alpha/2$.

Ein kürzestes Überdeckungsintervall wird dagegen so gewählt, dass es bei derselben Überdeckungswahrscheinlichkeit $P$ die kleinste Breite hat. Die außerhalb des Intervalls verbleibende Wahrscheinlichkeit $\alpha$ muss dabei nicht zu gleichen Teilen unterhalb und oberhalb des Intervalls liegen. Deshalb können seine Grenzen von denen des Quantilintervalls nach Gl. (9.28) abweichen.

Lässt sich hingegen ein geeignetes Intervall symmetrisch um $y$ darstellen, schreibt man häufig

$$[y - U, y + U], \qquad U = k\, u_\mathrm{c}(y). \tag{9.29}$$

$U$ heißt *erweiterte Messunsicherheit*, $k$ heißt *Erweiterungsfaktor*. Ein Quantil hat die Einheit der Größe, deren Verteilung betrachtet wird; ein Erweiterungsfaktor ist dimensionslos. Für eine Normalverteilung ist bei $P = 0.95$ der Faktor $k \approx 1.96$. Die häufige Wahl $k = 2$ ergibt dann etwa 95.45 %. Für andere Verteilungen können andere Faktoren oder asymmetrische Intervallgrenzen erforderlich sein.

Die Interpretation dessen, was ein Überdeckungsintervall ist, hängt vom statistischen Rahmen ab. Ein frequentistisches Vertrauensintervall besitzt eine Überdeckungswahrscheinlichkeit bezüglich wiederholter Datenerhebung. Ein bayesisches *Credible Interval* bezieht sich auf die dem Parameter nach der Beobachtung zugeordnete Verteilung. Bei der Verteilungsfortpflanzung wird die zugeordnete Eingangsverteilung durch das Messmodell in eine Ausgangsverteilung überführt. Diese kann auf bayesisch gewonnenen Eingangsverteilungen beruhen; die Fortpflanzung ist aber kein neuer Bayes-Schritt mit einer zusätzlichen Likelihood für dieselbe deterministische Modellgleichung.

Als grobe Orientierung zur Verwendung der drei Hauptdokumente des GUM und damit des geeigneten Ansatzes zur Unsicherheitsfortpflanzung lässt sich zusammenfassen:

| | Standardunsicherheiten und Kovarianzen | Vollständige Wahrscheinlichkeitsverteilungen |
|---|---|---|
| Eine Ausgangsgröße | GUM: linear oder linearisiert | GUM-S 1: Monte-Carlo |
| Mehrere Ausgangsgrößen | GUM-S 2: Kovarianzmatrix | GUM-S 2: Monte-Carlo |

Für die Wahl sind folgende Fragen maßgeblich:

1. Welche Einflüsse und Abhängigkeiten muss das Messmodell berücksichtigen?
2. Genügt eine lokale Linearisierung im relevanten Unsicherheitsbereich?
3. Wird eine Standardunsicherheit benötigt oder auch ein Intervall mit festgelegter Überdeckungswahrscheinlichkeit?
4. Ist die angenommene Form der Ausgangsverteilung für dieses Intervall geeignet?
5. Müssen mehrere Ausgangsgrößen einschließlich ihrer Kovarianzen und eines gemeinsamen Überdeckungsbereichs angegeben werden?

Eine Monte-Carlo-Auswertung kann die linearisierte Rechnung überprüfen. Die Probleme, die durch ein unvollständiges Messmodell oder ungeeignete Annahmen über die Eingangsverteilungen entstehen, werden dadurch jedoch nicht behoben.

### 9.1.4 Weitere Dokumente der GUM-Reihe

Bisher standen der GUM und seine Supplements 1 und 2 im Mittelpunkt. Die folgenden Dokumente ergänzen die dort dargestellten Grundlagen und unterstützen deren Anwendung, insbesondere bei der Modellbildung und der Konformitätsprüfung. Die aktuellen Dokumente stellt das BIPM bereit.[4]

- *JCGM GUM-1:2023 – Introduction* führt in die Konzepte und die Dokumentenreihe ein und ersetzt JCGM 104:2009.
- *JCGM GUM-6:2020 – Developing and using measurement models* behandelt die Entwicklung und Verwendung geeigneter Messmodelle.
- *JCGM GUM-5:2026 – Examples* enthält Anwendungsbeispiele.
- *JCGM 106:2012 – The role of measurement uncertainty in conformity assessment*

Die GUM-Dokumente sind internationale Leitfäden. Welche Anforderungen in einer konkreten Anwendung verbindlich sind, ergibt sich aus den dort maßgeblichen Regelungen, Normen oder Vereinbarungen.

- JCGM GUM-6:2020 (endgültige Fassung der ehemaligen Entwurfsfassung JCGM 103 von 2018-10-04) *Guide to the expression of uncertainty in measurement - Developing and using measurement models* behandelt in umfassender Weise die Problematik der Modellentwicklung. Es gibt den Bereich physikalischer, deterministischer Prozesse, den Bereich der nicht-deterministischen, physikalischen oder biologischen oder soziologischen Prozesse. Ferner gibt es den Bereich der statistischen Modelle, die dazu dienen, nicht-deterministische Anteile von Prozessen zu behandeln. Hier werden diese Dinge konzeptionell für die Metrologie beleuchtet.

  `https://www.bipm.org/documents/20126/2071204/JCGM_GUM_6_2020.pdf`

- JCGM 104:2009 *Guide to the expression of uncertainty in measurement - An introduction to the Guide to the expression of uncertainty in measurement and related documents* liefert die Konzepte und Hintergründe zur Unsicherheitsbestimmung. Dieses Dokument soll ein Verständnis für die Konzepte der Wahrscheinlichkeitsdichteverteilungen im Zusammenhang mit der Bestimmung von Messunsicherheiten liefern.
- JCGM 106:2012 *Evaluation of measurement data - The role of measurement uncertainty in conformity assessment* behandelt die Rolle der Messunsicherheit bei der Entscheidung, ob vorgegebene Anforderungen erfüllt sind. Im Rahmen der Vorlesungen zu Hypothesentests und Ringvergleichen haben wir bereits gelernt, dass Messergebnisse zu vergleichen sind, und wie dies gehandhabt wird. In der Qualitätssicherung ist die zentrale Aufgabe, gefertigte Bauteile mit

[4] Stand der Publikationsübersicht: Oktober 2026; `https://www.bipm.org/en/committees/jc/jcgm/publications`.

> den vorgegebenen Daten der technischen Konstruktionszeichnung zu vergleichen hinsichtlich der Übereinstimmung, also der Einhaltung von Toleranzgrenzen. Dies wird Konformitätsbewertung genannt und wird im JCGM 106-Dokument behandelt.

Im Zusammenhang mit der Bewertung von Unsicherheiten und den Ansätzen zur Bestimmung der Unsicherheit indirekter Messgrößen haben wir gelernt, dass das Messmodell eine zentrale Rolle spielt. Wichtige Punkte, die bei der Modellbildung zu beachten sind sind die Güte und die numerische Zuverlässigkeit eines Modells. Das Dokument *JCGM GUM-6:2020 – Developing and using measurement models* liefert Anhaltspunkte für die Entwicklung und Verwendung geeigneter Messmodelle.

Ein Modell vereinfacht den physikalischen Sachverhalt. Die Vereinfachung muss für die gewünschte Unsicherheit geeignet sein. Eine relevante verbleibende Modellabweichung kann durch eine zusätzliche Korrektur- oder Einflussgröße mit begründeter Unsicherheit berücksichtigt werden. Ein kleiner Fitrest allein belegt nicht, dass alle relevanten Modellabweichungen erfasst sind.

Die Begrenztheit der Modellbildung kann zu folgenden Abweichungen und Unsicherheiten führen:

- Vereinfachungen (Parsimonie = „Sparsamkeit“) und Grenzen durch Rechenkapazität zeitlich (Rechenzeit/Rechenleistung) und kostenmäßig (Speicherkapazität und Maschinengenauigkeit, numerische Stabilität, numerische Zuverlässigkeit),
- Vereinfachungen mangels Kenntniss über quantitative Details zu Einflussgrößen oder genaueren Details der Physik innerhalb des betreffenden physikalischen Effektes,
- mangels Informationen zu genaueren Werten von Einflussgrößen der physikalischen Prozesse.

Davon zu unterscheiden ist die numerische Berechnung. Eine schlecht konditionierte Auswertung reagiert stark auf kleine Änderungen ihrer Eingangsdaten. Ein numerisch instabiler Algorithmus kann zusätzlich Rundungsabweichungen verstärken.

> Doing floating point operations is like moving piles of sand: every time you move a pile, you lose a little sand and pick up a little dirt!

Eine geeignete Skalierung, stabile Lösungsverfahren und die Prüfung der Konvergenz helfen, solche Recheneffekte zu begrenzen. Eine größere physikalische Parameterunsicherheit lässt sich dabei nicht allein aus unterschiedlichen Einheiten oder Skalierungen der Parameter ableiten.

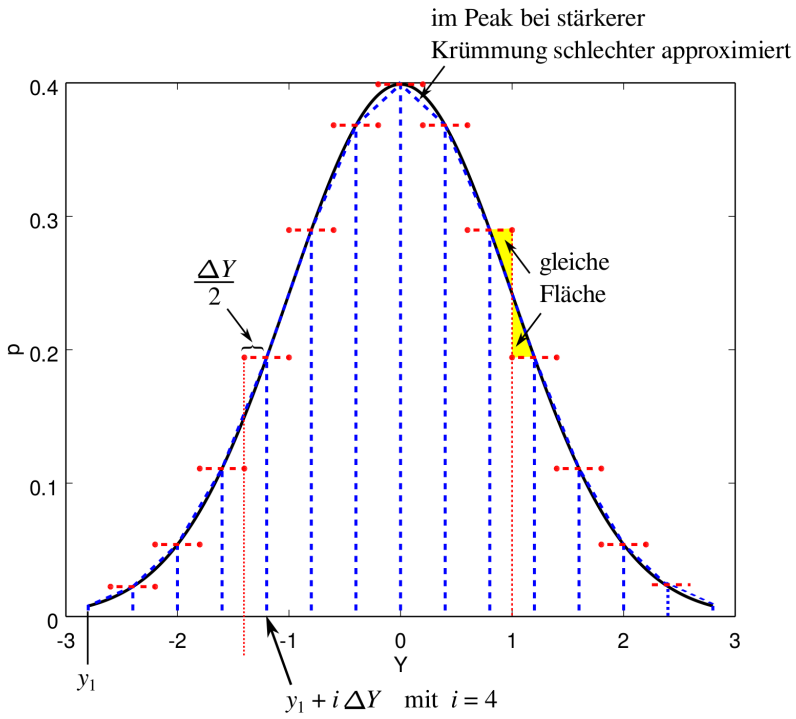



Abbildung 9.1: Trapezapproximation für die Berechnung der Fläche unter einer Kurve zur numerischen Integration.

## 9.2 Numerische Werkzeuge für Messunsicherheitsberechnungen

### 9.2.1 Numerische Integrationsverfahren

Sei $p$ eine Funktion $p\colon Y \to p(Y)$, die numerisch über ein Intervall $[y_1, y_2]$ integriert werden soll.

$$P(y_1, y_2) \;=\; \int_{y_1}^{y_2} p(Y)\;\mathrm{d}\,Y \tag{9.30}$$

Integrieren bedeutet, die Fläche unter der Kurve zu berechnen. Wir approximieren die Fläche unter der Kurve durch Rechtecke einer festen Breite $\Delta Y$ und einer Höhe $p(Y_i)$ in der in Abb. 9.1 dargestellten Weise. Die Flächen der mit rot, gestrichpunkteter Linie gekennzeichneten Rechtecke sind genauso groß wie die mit blau gestrichelter Umrandung markierten Trapezstücke. Diese Flächen werden summiert, um näherungsweise die Fläche unter der Kurve zu bestimmen. Das erste und das letzte Flächenstückchen sind nur halb so groß. Das Integrationsintervall wird in $n$ Flächen unterteilt, so dass für die Breite der Flächenstücke gelte

$$\Delta Y \;=\; \frac{y_2 - y_1}{n}. \tag{9.31}$$

Es wird nun so aufgeteilt, dass $n-1$ Stücke betrachtet werden gemäß den rot gestrichpunkteten Rechtecken mit der Breite $\Delta Y$ und zwei weitere Stücken je der Hälfte dieser Breite und je eines ganz am Anfang und das andere als letztes Stückchen ganz am Ende. Das erste Stückchen hat die halbe

Breite und die Fläche

$$\underbrace{\frac{\Delta Y}{2}\,p(y_1)}_{\text{Rechteck}} + \underbrace{\frac{\Delta Y}{4}\,(p(y_1+\frac{\Delta Y}{2})-p(y_1))}_{\text{Dreieck}} = \frac{\Delta Y}{4}\,(p(y_1+\frac{\Delta Y}{2})+p(y_1))$$

das letzte Stückchen analog

$$\frac{\Delta Y}{4}\,(p(y_2-\frac{\Delta Y}{2})+p(y_2))$$

so dass für die gesamte Fläche gilt

$$P(y_1,y_2) = \varepsilon + \frac{\Delta Y}{4}\left(p(y_1+\frac{\Delta Y}{2})+p(y_1)+p(y_2-\frac{\Delta Y}{2})+p(y_2)\right) + \sum_{i=1}^{n-1} p(y_1+i\,\Delta Y)\,\Delta Y \quad (9.32)$$

mit $\varepsilon$ für die Abweichung von der Fläche, die unter der Kurve liegt. Dabei gilt es eine geeignete Wahl für die Breite $\Delta Y$ der Intervalle oder andersrum ausgedrückt für die Anzahl $n$ der Intervalle zu treffen.

Eine Möglichkeit ist, sich iterativ zu einer sinnvollen Anzahl von Intervallen vorzuarbeiten, indem die Intervallbreite $\Delta Y$ mit jedem Iterationsschritt halbiert wird. Dabei arbeitet man sich solange vor bis sich die approximierte Fläche durch weiteres Halbieren der Intervallbreiten nicht mehr signifikant ändert. Diese Methode wird *Romberg*-Verfahren genannt. Werner Romberg war ein in Berlin geborener Mathematiker, der in Heidelberg und München studierte und promovierte. Kurz nach dem Rigorosum im Jahr 1933 musste er als Kritiker des Nazionalsozialismus Deutschland verlassen. 1949 wurde Werner Romberg Dozent für Physik am Norwegian Institute of Technology (NTH) in Trondheim und richtete dort den Studiengang für Mathematische Physik ein. 1955 publizierte er dieses numerische Integrationsverfahren.

Ein Quellcode-Beispiel in C ist auf der Wikipediaseite zum Romberg-Verfahren zu finden:

`https://en.wikipedia.org/wiki/Romberg%27s_method`

Bei jedem Iterationsschritt wird $\Delta Y$ halbiert. Der Iterationsschritt $n = 1$ bedeutet $\Delta Y_1 = y_2 - y_1$, Schritt $n = 2$ bedeutet $\Delta Y_2 = (y_2 - y_1)/2 = \Delta Y_1/2$ etc.

$$P_n(y_1,y_2) = \frac{\Delta Y_n}{4}\,(p(y_1+\frac{\Delta Y_n}{2})+p(y_1)+p(y_2-\frac{\Delta Y_n}{2})+p(y_2)) + \sum_{i=1}^{n-1} p(y_1 + i\,\Delta Y_n)\,\Delta Y_n \quad (9.33)$$

mit

$$\Delta Y_n = \frac{1}{2}\Delta Y_{n-1}.$$

Die Iteration endet, sobald der Betrag der Differenz der approximierten Flächen

$$|\,P_n(y_1,y_2) - P_{n-1}(y_1,y_2)\,| < \varepsilon_P \quad (9.34)$$

einen Wert annimmt, der kleiner als ein zuvor definierter sehr kleiner Wert $\varepsilon_P$ ist.

Dabei werden die Flächenstücke durch Halbierung der Intervallbreite gleichförmig schmaler gemacht. Die einzelnen Abweichungen zu jedem der Intervalle können für unterschiedlich stark gekrümmte Segmente der unterschiedlichen Stückchen verschieden groß sein, so dass für manche Anwendungen dadurch Rechenzeit gesparen werden, dass nur ausgewählte Bereiche verfeinert werden. Hier ist mehr

Aufwand bei der Implementierung der Verästelung des Baumes, der für unterschiedlichen Integrationsbereiche unterschiedliche Iterationstiefen verwaltet, erforderlich. Wir nennen die Grenzen der Flächenstückchen, die bei Romberg gleichförmig die Positionen

$$Y_i \;=\; y_1 \;+\; (i-1)\Delta Y$$

annehmen, *Samples*, für die im allgemeinen gelten kann

$$Y_{i+1} - Y_i \;\neq\; Y_{k+1} - Y_k \quad \text{für} \quad i \neq k. \tag{9.35}$$

Insbesondere bei der Integration mehrdimensionaler Funktionen, wie wir sie in unseren Bespielen hatten, bevor wir die Marginalverteilung erworben hatten, also soetwas wie bei folgender Integration

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p(Y, X_1, \ldots, X_N | \{X_{i,1}, \ldots, X_{i,J_i}\}, \bar{x}_k, s_k, \ldots)\, \mathrm{d}\, X_1 \ldots \mathrm{d}\, X_N$$

gilt es die *Samples* für die Hypervolumenstückchengrenzen optimal zu wählen. Die Berechnungen sollen in minimaler Zeit fertig werden und dennoch soll das gesamte Hypervolumen möglichst genau approximiert werden.

Betrachten wir konkret die Aufgabe, Wahrscheinlichkeitsdichteverteilungen $p$ integrieren zu wollen, welche dadurch gekennzeichnet sind, dass ihre Funktionswerte positiv sind und dass sie aus einem oder vielleicht auch ganz wenig mehr als einem breiteren *Peak* (Glocke) bestehen. Diese Glocke muss dabei nicht unbedingt so schön symmetrisch sein wie bei der Normalverteilung oder bei der Student-t-Verteilung, sondern kann eine gewisse Schiefe haben wie beispielsweise bei der $\chi^2$-Verteilung für wenige Freiheitsgrade. Wenn wir Abb. 9.1 genauer anschauen, sehen wir, dass die Sekanten im Zentrum des *Peaks*, der Glocke, stärker von der Kurve der Glocke abweichen als in den *Tails*. Die Sample-Stützstellen wollen wir also im Bereich des Glockenmaximums, bzw. in den Bereichen der Glockenmaxima, enger legen als in den *Tails*. Dies ist äquivalent zu dem, die Dichte der Stützstellen gemäß der Verteilung $p$ selbst zu samplen. Mit anderen Worten, es wird eine nach $p$ verteilte Stichprobe der Größen $X_i$ entnommen. Die Verteilung $p$ wird verwendet, um gleichverteilte Pseudozufallszahlen auf nach $p$ verteilte Zahlen abzubilden. Dieser Ansatz liegt den sogenannten *Importance Sampling*-Algorithmen zugrunde.

Wenn eine Verteilung $p$ stark fluktuiert, also innerhalb eines Intervalls (des $i$-ten Intervalls) auf der $X$-Achse sehr unterschiedliche Funktionswerte $p(X_i)$ annimmt, so bedeutet das, dass $p(X_i)$ eine große Varianz hat.

$$\mathrm{Var}(p(X_i)) \;=\; \frac{1}{J-1} \sum_{j=1}^{J} \left(p(X_{i,j}) - \bar{p}(X_i)\right)^2. \tag{9.36}$$

Die Varianz bezüglich unterschiedlicher Intervalle, bzw. Regionen, wird als Maß verwendet, das der Entscheidung zugrunde gelegt wird, ob weitere Stützstellen in dieser Region gesampelt werden, die Region in kleinere Regionen zu unterteilen, um je Region kleinere Varianzen zu erhalten. Das Sampeln innerhalb der verschiedenen Regionen geschieht dabei voneinander unabhängig. Die Regionen werden auch Gruppen oder Schichten genannt. Ein nach diesem Verfahren gebildetes Sample heißt *geschichtete Zufallsstichprobe* oder *stratifizierte Zufallsstichprobe* (engl. *stratified Sample*).

### 9.2.2 Zufallszahlen und Wahrscheinlichkeitsverteilungen

Die Thematik des Samplings nach Methoden, bei denen Zufallszahlen verwendet werden, ist ein weites Feld in der Statistik. Große Bedeutung haben zufallszahlenbasierte Integrationsmethoden, die auf Erkenntnissen aus der Thermodynamik, d.h. der statistischen Physik beruhen. Sie wurden aus Beobachtung der brown'schen Molekularbewegung abgeleitet, also aus der Zufälligkeit und Art und Weise der Bewegung von Molekülen eines Fluids. Der zurückgelegte Pfad eines Moleküls, *Random Walk*, ändert zufällig die Richtung.

Die Abfolge der Transformationen, die eine aktuelle Position eines Gegenstands oder den aktuellen Zustand eines Prozesses in die nachfolgende Position bzw. den nachfolgenden Zustand überführt, und daraus die danach nachfolgende Position (den daraus folgenden Zustand) und so weiter, heißt *Markow-Kette*. Kennzeichen einer Markow-Kette ist, dass die Positionsänderung des Moleküls nur von der aktuellen Position, nicht aber von den Positionen davor, abhängt. Allgemein lassen sich viele statistische Prozesse, nicht nur Pfade von Fluidpartikeln oder Abfolgen der Werte von Zufallssampeln, mit Hilfe von Markow-Ketten beschreiben und es gilt:

> Der zukünftige Zustand des Prozesses ist nur durch den aktuellen Zustand bedingt und wird nicht durch vergangene Zustände beeinflusst.

Um rechentechnisch mit Zufallszahlen zu arbeiten, müssen diese synthetisch generiert werden. Synthetisch gerechnete Zufallszahlen beruhen auf definierten Algorithmen und sind deshalb nicht wirklich zufällig, sondern deterministisch. Sie werden deshalb *Pseudozufallszahlen* genannt. Ein deterministischer Algorithmus berechnet eine Zahlenfolge, die nur den Anschein hat, dass die Zahlenwerte zufällig verteilt sind und nicht deterministisch.

Prinzipiell ist ein solcher Algorithmus, oftmals Zufallszahlengenerator genannt, wie folgt aufgebaut.

1. Setzen eines Startwertes, der *Seed* genannt wird, was ein englischsprachiger Begriff ist und Saat, Samenkorn heißt.
2. Wechselweise Multiplikationen und Restklassenoperationen mit sehr großen natürlichen Zahlen, wobei bei der Restklassenoperation als Teiler eine möglichst große Primzahl, beispielsweise 16807, zum Einsatz kommt.

Mit Restklassenoperation ist hier gemeint, dass eine Division mit natürlichen Zahlen durchgeführt wird, deren Rest als Ergebnis in die weiteren Berechnungsschritte eingeht.

Die heutigen Bibliotheken für Compiler und Programmiertools wie Matlab bieten nicht nur Zufallszahlengeneratoren, die gleichverteilte Zahlenfolgen liefern. Sie stellen schon fertige, schnelle, effektive Algorithmen zur Verfügung, die die Transformation auf die üblichen Verteilungsdichtefunktionen $p$ zur Verfügung stellen. So ist `randn` der Name der Funktion in Matlab und Gnu-Octave zur Erzeugung von normalverteilten Zufallszahlen. `rande` liefert exponentiell verteilte Zufallszahlen, `randg` Zufallszahlen, die nach der Gammafunktion verteilt sind und `randp` poissonverteilte Zufallszahlen. In Python sind diese in der zu `numpy` gehörenden Biblothek `random` zu finden. Mit `randn` werden standardnormalverteilte Zufallszahlen erzeugt:

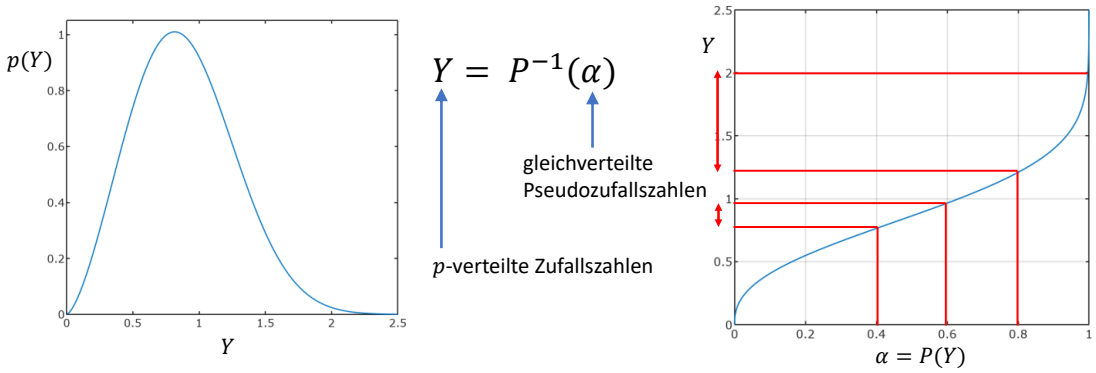



Abbildung 9.2: Eine gleichverteilte Größe wie beispielsweise eine Wahrscheinlichkeit $\alpha$ wird über die inverse Funktion $P^{-1}$ der kumulierten Wahrscheinlichkeitsverteilung $P$, also der aufintegrierten Verteilung der Wahrscheinlichkeitsdichte $p$, abgebildet auf die Größe $Y$, die dann $p$-verteilt ist.

```
1 import numpy as np
2 nrow = 5
3 ncol = 20
4 a = np.random.randn(nrow, ncol)
```

Mit `rand` werden gleichverteilte Zufallszahlen $R \in [0, 1)$ erzeugt.

Wir können aber auch selber gleichverteilte Zufallszahlen abbilden auf eine andere Verteilung $p$, wenn wir die Umkehrfunktion der kumulierten Verteilung $P^{-1}$, auch *Quantilfunktion* genannt, dazu zur Verfügung haben. Sei $R = \{R_1, \ldots, R_J\}$ ein Sample, eine Stichprobe, gleichverteilter Zufallszahlen mit $R \in [0, 1)$, so ist die Menge der mit $P^{-1}$ transformierten Zufallszahlen

$$Z = P^{-1}(R)$$

gemäß $p$ verteilt, siehe Abb. **??**.

Als Beispiel wollen wir in Python 1000 Zufallszahlen generieren, die verteilt sind gemäß einer $t$-Verteilung für 45 Freiheitsgrade:

```
1 import numpy as np
2 import scipy
3 from scipy import stats
4 Jz = 1000
5 nu = 45
6 R = np.random.rand(1, Jz)
7 Z = scipy.stats.t.ppf(R[0], nu)
```

# Kapitel 10

# Messunsicherheit – linearisierbare, explizite Modelle

In Kapitel 9 haben wir den gemeinsamen Rahmen des GUM und seiner Supplements kennengelernt. In diesem Kapitel betrachten wir ein explizites Messmodell $Y = f(\mathbf{X})$ mit einer skalaren Ausgangsgröße $Y$ und einem Vektor von Eingangsgrößen $\mathbf{X}$. Wir leiten das Gesetz zur Fortpflanzung von Standardunsicherheiten her, untersuchen die Rolle von Korrelationen und bestimmen anschließend eine erweiterte Messunsicherheit.

Da die Verwendung der Begriffe Schätzwert (*estimate*) einer Messgröße und Beobachtungswert nicht immer eindeutig ist, betrachten wir hier genauer, wie diese in den GUM-Dokumenten verstanden werden. Dort wird der beste verfügbare Schätzwert (*best estimate*) im Sinne eines Ergebnisses einer Messung und ihrer Auswertung spezifiziert mit *the result of the measurement is the best estimate of, attributable to, the value of the measurand.* Ein Schätzwert wird gemäß Abschnitt 3.1.2 des GUM (JCGM 100) für ein Messergebnis verwendet, dort heißt es

> *In general, the result of a measurement is only an approximation or estimate of the value of the measurand and thus is complete only when accompanied by a statement of the uncertainty of that estimate.*

Großbuchstaben bezeichnen die Größen im Wahrscheinlichkeitsmodell, Kleinbuchstaben ihre Schätzwerte. Ein Schätzwert $x_i$ kann ein Stichprobenmittelwert $\bar{x}_i$ sein oder aus anderen Informationen stammen. $u(x_i)$ ist die dem Schätzwert $x_i$ zugeordnete Standardunsicherheit; $u_\mathrm{c}(y)$ ist die kombinierte Standardunsicherheit der Ausgangsgröße.

Im statistischen Beobachtungsmodell wird der mögliche Ausgang der $k$-ten Einzelbeobachtung einer Größe durch eine Zufallsgröße[1] $X_{i,k}$ beschrieben. Der tatsächlich erhaltene Größenwert ist eine Realisierung dieser Zufallsgröße und wird als Beobachtungswert (*observed value*) bezeichnet.

Um Zufallsgröße und Realisierung eindeutig zu unterscheiden, bezeichnen wir in dieser Vorlesung den konkreten Beobachtungswert mit $x_{i,k}$. Der GUM verwendet hierfür in Abschnitt 4.1.1, Anmerkung 2, dagegen ebenfalls den Großbuchstaben $X_{i,k}$. Die Groß- und Kleinschreibung allein unterscheidet diese beiden Bedeutungen im GUM somit nicht durchgehend.

Aus den Beobachtungswerten können Schätzwerte bestimmt werden, beispielsweise der Mittelwert $\bar{x}_i$ einer Messreihe. Ein Schätzwert $x_i$ kann jedoch auch aus einem Fitverfahren, einem Kalibrierschein oder anderen verfügbaren Informationen stammen.

In Abschnitt 4.1.1 vom GUM heißt es

> In most cases, a measurand $Y$ is not measured directly, but is determined from $N$ other quantities $X_1, X_2, \ldots, X_N$ through a functional relationship $f$:
>
> $$Y = f(X_1, X_2, \ldots, X_N)$$
>
> NOTE 1 For economy of notation, in this Guide the same symbol is used for the physical quantity (the measurand) and for the random variable (see 4.2.1) that represents the possible outcome of an observation of that quantity. When it is stated that $X_i$

[1] Zufallsgrößen werden in der Mathematik auch Zufallsvariablen genannt

> has a particular probability distribution, the symbol is used in the latter sense; it is assumed that the physical quantity itself can be characterized by an essentially unique value (see 1.2 and 3.1.3).
>
> NOTE 2 In a series of observations, the $k$-th observed value of $X_i$ is denoted by $X_{i,k}$; hence if $R$ denotes the resistance of a resistor, the $k$-th observed value of the resistance is denoted by $R_k$.
>
> NOTE 3 The estimate of $X_i$ (strictly speaking, of its expectation) is denoted by $x_i$.

GUM Supplement 2 (JCGM 102) erläutert in Abschnitt 4.1 ausdrücklich die unterschiedlichen Bedeutungen derselben Großbuchstaben und in den Abschnitten 4.9 und 4.10 die Verwendung der Kleinbuchstaben $x_i$ für einen Größenwert (*quantity value*), den wir in dieser Vorlesung als Wert einer Größe bezeichnen, und $\mathbf{x}$ für Schätzwerte der Eingangsgrößen (*estimates of the input quantities*) oder Schätzwertevektor der Eingangsgrößen.

In Abschnitt 4.1.4 vom GUM (JCGM 100) wird deutlich dass, die Kleinbuchstaben für die Schätzwerte von Messgrößen verwendet werden, sowohl für indirekte Größen, die über ein Messmodell ermittelt werden ($y$ sind Ausgangsschätzwerte, *output estimates*), als auch für Eingangsgrößen:

> An estimate of the measurand $Y$, denoted by $y$, is obtained from $Y = f(X_1, X_2, \ldots, X_N)$ using *input estimates* $x_1, x_2, \ldots, x_N$ for the values of the $N$ quantities $X_1, X_2, \ldots, X_N$. Thus the *output estimate* $y$, which is the result of the measurement, is given by
>
> $$y = f(x_1, x_2, \ldots, x_N)$$

Wir betrachten den Fall, dass die Eingangsgrößen aus unterschiedlichen Messvorgängen ermittelt wurden. Es kann beispielsweise eine der Größen ein Mittelwert $\bar{x}_1$ aus einer Stichprobe von Einzelbeobachtungen und eine andere der Größen aus der Lösung eines inversen Problems $\hat{x}_2$ geschätzt worden sein, eine weitere eine Herstellerangabe $x_3$ aus einen Datenblatt sein. Diese Werte, alle als Schätzwerte (*estimator*) bezeichnet, werden entsprechend in die Modellgleichung eingesetzt, um den Schätzwert der Ausgangsgröße zu erhalten

$$y = f(\bar{x}_1, \hat{x}_2, x_3).$$

Dass als Schätzwerte nicht nur aus den Einzelbeobachtugnen eines aktuellen Prozesses von Messungen ermittelte Schätzwerte gemeint sind, wird im Abschnitt 4.3.1 vom GUM explizit gesagt:

> For an estimate $x_i$ of an input quantity $X_i$ that has not been obtained from repeated observations, the associated estimated variance $u^2(x_i)$ or the standard uncertainty $u(x_i)$ is evaluated by scientific judgement based on all of the available information on the possible variability of $X_i$. The pool of information may include
>
> - previous measurement data;
> - experience with or general knowledge of the behaviour and properties of
> - relevant materials and instruments;

- manufacturer's specifications;
- data provided in calibration and other certificates;
- uncertainties assigned to reference data taken from handbooks.

## 10.1 Exakte Fortpflanzung für lineare Modelle

Wir beginnen mit einem linearen Modell, das einen konstanten additiven Term enthalten kann:

$$Y = c_0 + \sum_{i=1}^{N} c_i X_i. \tag{10.1}$$

Die Koeffizienten $c_i$ und $c_0$ sind hier feste, als bekannt behandelte Zahlen. Falls ein Koeffizient selbst unsicher ist, wird er als zusätzliche Eingangsgröße in das Modell aufgenommen; dann ist die Abhängigkeit von allen Eingangsgrößen im Allgemeinen nicht mehr linear.

Mit $\mu_i = \mathrm{E}(X_i)$ ergibt sich

$$\mu_Y = \mathrm{E}(Y) = c_0 + \sum_{i=1}^{N} c_i \mu_i, \qquad Y - \mu_Y = \sum_{i=1}^{N} c_i (X_i - \mu_i). \tag{10.2}$$

Der konstante Term $c_0$ beeinflusst den Erwartungswert, aber nicht die Varianz. Wir quadrieren die Abweichung vom Erwartungswert und bilden deren Erwartungswert:

$$\begin{aligned} \mathrm{Var}(Y) &= \mathrm{E}\left( \left[ \sum_{i=1}^{N} c_i (X_i - \mu_i) \right]^2 \right) \\ &= \sum_{i=1}^{N} \sum_{k=1}^{N} c_i c_k \, \mathrm{E}\big( (X_i - \mu_i)(X_k - \mu_k) \big) \\ &= \sum_{i=1}^{N} \sum_{k=1}^{N} c_i c_k \, \mathrm{Cov}(X_i, X_k). \end{aligned} \tag{10.3}$$

Diese Herleitung setzt nur voraus, dass die benötigten zweiten Momente existieren. Weder Normalverteilung noch Unabhängigkeit sind erforderlich. Für $i = k$ steht in der Summe die Varianz der Eingangsgröße. Für $i \neq k$ stehen darin die Kovarianzen zweier verschiedener Eingangsgrößen.

Da $\mathrm{Cov}(X_i, X_k) = \mathrm{Cov}(X_k, X_i)$ gilt, können wir die Summe auch schreiben als

$$\mathrm{Var}(Y) = \sum_{i=1}^{N} c_i^2 \, \mathrm{Var}(X_i) + 2 \sum_{i=1}^{N-1} \sum_{k=i+1}^{N} c_i c_k \, \mathrm{Cov}(X_i, X_k). \tag{10.4}$$

Der Faktor 2 entsteht, weil jedes Paar verschiedener Größen in der Doppelsumme zweimal vorkommt.

Wir übertragen die Beziehung auf die den Schätzwerten zugeordneten Standardunsicherheiten und Kovarianzen:

$$\boxed{u_\mathrm{c}^2(y) = \sum_{i=1}^{N} c_i^2 u^2(x_i) + 2 \sum_{i=1}^{N-1} \sum_{k=i+1}^{N} c_i c_k \, u(x_i, x_k).} \tag{10.5}$$

Dabei bezeichnet $x_i$ die Eingangsschätzwerte, die Mittelwerte aus einer Messreihe (Stichprobe, Einzelbeobachtungen) derselben Eingangsgröße sein können, oder einzelne Werte, die aus Kalibrierungen, Modellanpassungen, Herstellerangaben oder anderen verfügbaren Informationen bestimmt wurden.

Mit den Korrelationskoeffizienten $\rho_{ik}$ wird daraus

$$u_\mathrm{c}^2(y) = \sum_{i=1}^{N} c_i^2 u^2(x_i) + 2 \sum_{i=1}^{N-1} \sum_{k=i+1}^{N} c_i c_k \rho_{ik} u(x_i) u(x_k). \tag{10.6}$$

Der GUM unterscheidet auch bei dem Symbol für den Korrelationskoeffizienten zwischem dem für die eingesetzten Eingangsschätzwerte (Formelsymbol $r$ mit $r(x_i, x_k)$) und dem Symbol $\rho$ für die Größen $\rho(X_i, X_k)$, siehe Anhang C 3.6 in GUM [GUM95]. In dieser Vorlesungsreihe verzichten wir auf das separate Symbol $r$, machen diese Unterscheidung nur über die Argumente $(x_i, x_k)$ im Unterschied zu $(X_i, X_k)$ und verwenden durchgängig nur $\rho$.

Mit $u(x_i, x_k)$, also $u$ mit *zwei* Argumenten, bezeichnet eine Kovarianz und keine Standardunsicherheit. Ihre physikalische Dimension ist das Produkt der Dimensionen der beiden Eingangsgrößen:

$$\dim\big(u(x_i, x_k)\big) = \dim X_i \, \dim X_k. \tag{10.7}$$

Entsprechend wird die Kovarianz in der Produkteinheit der beiden Eingangsgrößen angegeben. Beispielsweise hat die Kovarianz zweier Längen die Dimension $\mathsf{L}^2$ und bei Angabe der Längen in Metern die Einheit $\mathrm{m}^2$. Insbesondere gilt $u(x_i, x_i) = u^2(x_i)$.

Für unkorrelierte Eingangsgrößen verschwinden die Mischterme:

$$u_\mathrm{c}(y) = \sqrt{\sum_{i=1}^{N} [c_i u(x_i)]^2}. \tag{10.8}$$

Die positive Quadratwurzel der kombinierten Varianz heißt *kombinierte Standardunsicherheit*. Diese Bezeichnung gilt sowohl mit als auch ohne Kovarianzbeiträge.

Für unkorrelierte Eingangsgrößen verschwinden die Mischterme. Die Varianzen der mit den Sensitivitätskoeffizienten gewichteten Beiträge addieren sich dann. Daraus folgt die quadratische Addition der Standardunsicherheitsbeiträge.

Zur Bestimmung der Messunsicherheit benötigen wir ein Messmodell. Bei der Modellbildung müssen wir beschreiben, wie die Eingangsgrößen auf die Ausgangsgröße wirken und welche physikalischen Zusammenhänge oder gemeinsamen Einflüsse zwischen den Eingangsgrößen bestehen. Relevante gemeinsame Einflüsse, beispielsweise dieselbe Temperatur oder derselbe Referenzwert, müssen bei der Bestimmung der Messunsicherheit berücksichtigt werden. Sie sollten nach Möglichkeit ausdrücklich als gemeinsame Einflussgrößen in das Messmodell aufgenommen werden. Ihre Auswirkungen können jedoch auch durch entsprechend bestimmte Kovarianzen zwischen den Eingangsgrößen berücksichtigt werden.

Auch bei einem linearen Messmodell können zwischen den Eingangsgrößen nichtlineare statistische Abhängigkeiten bestehen. Für die Varianzfortpflanzung eines linearen Modells genügen jedoch die Varianzen und Kovarianzen der Eingangsgrößen. Die Kovarianzen lassen sich, wie zuvor gezeigt, als

Produkt des Korrelationskoeffizienten und der beiden Standardunsicherheiten ausdrücken.

Korrelationen können beispielsweise entstehen, wenn mehrere Ergebnisse auf demselben Referenzwert beruhen oder durch dieselbe Temperaturänderung beeinflusst werden. Für zwei Eingangsgrößen und das Messmodell $Y = X_1 - X_2$ lautet die Fortpflanzung

$$u_c^2(y) = u^2(x_1) + u^2(x_2) - 2\rho_{1,2}u(x_1)u(x_2). \tag{10.9}$$

Bei positiver Korrelation ist die Standardunsicherheit der Differenz kleiner als bei einer Rechnung, die diese Korrelation vernachlässigt. Bei einer Summe $Y = X_1 + X_2$ steht dagegen ein Pluszeichen vor dem Mischterm. Positive Korrelation führt dann zu einer größeren Standardunsicherheit als bei Vernachlässigung der Korrelation.

Ein gemeinsamer additiver Einfluss $B$ lässt sich direkt modellieren:

$$X_1 = A_1 + B, \qquad X_2 = A_2 + B. \tag{10.10}$$

Sind $A_1$, $A_2$ und $B$ unabhängig und existieren ihre Varianzen, gilt

$$\mathrm{Cov}(X_1, X_2) = \mathrm{Var}(B). \tag{10.11}$$

In der Differenz

$$X_1 - X_2 = A_1 - A_2 \tag{10.12}$$

fällt $B$ vollständig heraus. In der Summe

$$X_1 + X_2 = A_1 + A_2 + 2B \tag{10.13}$$

geht derselbe Einfluss dagegen mit dem Faktor 2 ein; sein Varianzbeitrag beträgt daher $4\,\mathrm{Var}(B)$.

Eine Modellierung mit gemeinsamen Einflussgrößen macht solche Zusammenhänge oft deutlicher als die bloße Vorgabe eines Korrelationskoeffizienten.

Die Unsicherheitsfortpflanzung lässt sich in kompakter Weise in Matrixschreibweise formulieren. Diese Matrixschreibweise ist gleichwertig zur Summenform der Unsicherheitsfortpflanzung in Abschnitt 5.2.2, Gl. (13), des GUM [GUM95]. Die Kovarianzmatrix wird dort in Anmerkung 2 von Abschnitt 5.2.2 und in Anhang C.3.5 beschrieben. In Anhang C.3.5 wird sie mit dem Symbol $\mathbf{V}$ verwendet, während wir das Symbol $\mathbf{U}$ passend zu den Matrixelementen $u$ für die Kovarianzen und zu dem GUM Supplement 2 verwenden. Bevor Gl. (10.5) in Matrixschreibweise gezeigt wird, gehen wir zunächst genauer darauf ein, wie der GUM die Kovarianzen versteht.

Für die Matrixschreibweise fassen wir die Eingangsschätzwerte im Spaltenvektor

$$\mathbf{x} = (x_1, \ldots, x_N)^{\mathsf{T}} \tag{10.14}$$

zusammen. Dieser Vektor enthält für jede Eingangsgröße den konkreten Wert, der in das Messmodell eingesetzt wird, beispielsweise einen Mittelwert aus einer Messreihe oder einen Wert aus einem Kalibrierschein.

Für diese Eingangsschätzwerte bestimmen wir die Standardunsicherheiten und die Kovarianzen auf Grundlage der verfügbaren Informationen. Die Ergebnisse dieser Unsicherheitsbewertung fassen wir in der Matrix

$$\mathbf{U}_\mathbf{x} = \big(u(x_i, x_k)\big)_{i,k=1}^{N} \tag{10.15}$$

zusammen. Ihre Diagonale enthält die quadrierten Standardunsicherheiten $u^2(x_i)$; die übrigen Elemente enthalten die Kovarianzen. In einer konkreten Auswertung enthält diese Matrix somit die Zahlenwerte der Varianzen und Kovarianzen, die wir für die Unsicherheitsfortpflanzung verwenden. Sie können aus Messreihen berechnet, aus Kalibrierunterlagen übernommen oder anhand weiterer Informationen und Modellannahmen bestimmt worden sein.

Unsere bisherige Schreibweise $\mathrm{Cov}(\mathbf{X})$ bezeichnet mathematisch die Kovarianzmatrix eines Zufallsvektors. Für die lineare Varianzfortpflanzung benötigen wir dessen Varianzen und Kovarianzen. Die vollständige gemeinsame Wahrscheinlichkeitsverteilung muss dafür *nicht* bekannt sein.

Die Matrix $\mathbf{U}_\mathbf{x}$ enthält die für die konkrete Auswertung verwendeten Werte der Varianzen und Kovarianzen. Die GUM-Schreibweise $\mathbf{U}_\mathbf{x}$ bezeichnet die für die Unsicherheitsfortpflanzung verwendete Matrix.

Um den Unterschied zwischen der theoretischen Kovarianzmatrix der Beobachtung von Eingangsgrößen und ihrer Schätzung aus konkreten Messwerten zu verdeutlichen, betrachten wir folgendes Beispiel: „Zwei Eingangsgrößen mit wiederholten Beobachtungen“.

Das Messmodell lautet

$$Y = \theta_1 X_1 + \theta_2 X_2 \tag{10.16}$$

mit bekannten, festen Koeffizienten $\theta_1$ und $\theta_2$. Zu den beiden Eingangsgrößen liegen jeweils $J$ Beobachtungen vor:

$$\mathrm{x}_1 = (x_{11}, \ldots, x_{1J})^\mathsf{T}, \qquad \mathrm{x}_2 = (x_{21}, \ldots, x_{2J})^\mathsf{T}. \tag{10.17}$$

Die beiden Beobachtungsvektoren enthalten die vollständigen Messreihen. Als Eingangsschätzwerte verwenden wir deren Mittelwerte:

$$x_1 = \bar{x}_1, \qquad x_2 = \bar{x}_2, \qquad \bar{x}_i = \frac{1}{J}\sum_{j=1}^{J} x_{i,j}. \tag{10.18}$$

Der Vektor der Eingangsschätzwerte enthält daher nur zwei Werte:

$$\mathbf{x} = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \end{pmatrix}. \tag{10.19}$$

Der Ausgangsschätzwert ist

$$y = \theta_1 \bar{x}_1 + \theta_2 \bar{x}_2. \tag{10.20}$$

Wir unterscheiden dabei die theoretischen Varianzen und Kovarianzen der zufälligen Mittelwertschätzer von den aus den beobachteten Messdaten berechneten Schätzungen dieser Varianzen und Kovarianzen.

Ferner nehmen wir an, dass jeweils $x_{1j}$ und $x_{2j}$ ein zusammengehöriges Beobachtungspaar bilden. Die Paare seien untereinander unabhängig und unter gleichen Messbedingungen aus derselben gemein-

samen Beobachtungsverteilung gewonnen. Innerhalb eines Paares können die beiden Beobachtungen korreliert sein.

Die empirischen Varianzen und Kovarianzen der einzelnen Beobachtungen berechnen wir mit

$$s_{ik} = \frac{1}{J-1}\sum_{j=1}^{J}(x_{ij} - \bar{x}_i)(x_{kj} - \bar{x}_k), \qquad i,k \in \{1,2\}. \tag{10.21}$$

Dabei sind $s_{11}$ und $s_{22}$ die empirischen Varianzen und $s_{12} = s_{21}$ die empirische Kovarianz.

Für die Mittelwertschätzer ergeben sich dagegen folgende Schätzungen der Varianzen und der Kovarianz:

$$u^2(\bar{x}_1) = \frac{s_{11}}{J}, \qquad u^2(\bar{x}_2) = \frac{s_{22}}{J}, \qquad u(\bar{x}_1, \bar{x}_2) = \frac{s_{12}}{J}. \tag{10.22}$$

Der Faktor $1/J$ entsteht, weil im Messmodell die Mittelwerte verwendet werden. Die entsprechende Schätzung der Kovarianz zweier Mittelwerte ist in Abschnitt 5.2.3 des GUM, Gl. (17), angegeben [GUM95]. Damit lautet die hier aus den Messreihen bestimmte Kovarianzmatrix

$$\boxed{\mathbf{U}_\mathbf{x} = \begin{pmatrix} u^2(\bar{x}_1) & u(\bar{x}_1,\bar{x}_2) \\ u(\bar{x}_1,\bar{x}_2) & u^2(\bar{x}_2) \end{pmatrix} = \frac{1}{J}\begin{pmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{pmatrix}.} \tag{10.23}$$

In dem Beispiel, Gl. (10.16), bestimmen wir die Kovarianzmatrix gemäß der Typ-A-Einordnung aus den beobachteten Messreihen. Wir verwenden hierfür die empirisch geschätzte Kovarianzmatrix der Mittelwertschätzer:

$$\mathbf{U}_\mathbf{x} = \widehat{\mathrm{Cov}}\left(\begin{pmatrix} \bar{X}_1 \\ \bar{X}_2 \end{pmatrix}\right), \qquad \bar{X}_i = \frac{1}{J}\sum_{j=1}^{J} X_{i,j}. \tag{10.24}$$

Hier bezeichnet $X_{ij}$ eine *mögliche* Beobachtung im statistischen Beobachtungsmodell; $x_{ij}$ ist ihr konkret (real) beobachteter Wert. Die Großbuchstaben $\bar{X}_i$ bezeichnen die zufälligen Mittelwertschätzwerte, die Kleinbuchstaben $\bar{x}_i$ deren aus den Daten *berechneten* Schätzwerte. Das Dach über Cov kennzeichnet die Schätzung der Kovarianzmatrix aus diesen Daten, d.h. die *empirische Kovarianzmatrix*.

Mit den Sensitivitäten, die in unserem Beispiel gleich den konstanten Koeffizienten sind, $\mathbf{c} = (\theta_1, \theta_2)^\mathsf{T}$, ergibt sich somit zusammen mit den empirischen Varianzen und der empirischen Kovarianz für das Quadrat der kombinierten Unsicherheit

$$u_\mathrm{c}^2(y) = \frac{1}{J}\left(\theta_1^2 s_{11} + 2\theta_1\theta_2 s_{12} + \theta_2^2 s_{22}\right). \tag{10.25}$$

Nachdem wir gesehen haben, wie der GUM die Kovarianzmatrizen definiert, können wir verstehen wie der GUM mit Supplement 2 die Unsicherheitsfortpflanzung in der Matrixschreibweise darstellt.

Mit dem Spaltenvektor der Sensitivitätskoeffizienten $\mathbf{c} = (c_1, \ldots, c_N)^\mathsf{T}$ lautet die Varianzfortpflanzung für das lineare Modell

$$\boxed{u_\mathrm{c}^2(y) = \mathbf{c}^\mathsf{T}\mathbf{U}_\mathbf{x}\mathbf{c}.} \tag{10.26}$$

Die Matrixform ist die skalare Form der in Supplement 2 beschriebenen Kovarianzfortpflanzung. Für

ein lineares Modell mit festen Koeffizienten gilt die Varianzbeziehung exakt. Bei einem linearisierten nichtlinearen Modell ist sie eine Näherung.

GUM Supplement 2 liefert die Erweiterung für die Fortpflanzung auf mehrere Ausgangsgrößen, wofür die Matrixschreibweise ausdrücklich verwendet wird. Die in Gl. (10.26) dargestellte Beziehung ist deren skalarer Spezialfall. GUM Supplement 2 verwendet den Zusatz $\mathbf{x}$ für Matrix $\mathbf{U_x}$ um zu kennzeichnen, dass sie die Unsicherheitsbewertung der Beobachtungswerte der Eingangsgrößen enthält. Entsprechend bezeichnet $\mathbf{U_y}$ die Matrix für die Ausgangsschätzwerte.

Für ein explizites, multivariates Modell $\mathbf{Y} = \mathbf{f}(\mathbf{X})$ werden die Kovarianzen gemäß GUM Supplement 2, Abschnitt 6.2, mit

$$\mathbf{Y} = \mathbf{C_x}\,\mathbf{U_x}\,\mathbf{C_x^T} \tag{10.27}$$

fortgepflanzt, wobei $\mathbf{C_x}$ die Sensitivitätsmatrix ist mit

$$\mathbf{C_x} = \left.\begin{pmatrix} \frac{\partial f_1}{\partial X_1} & \cdots & \frac{\partial f_1}{\partial X_N} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_M}{\partial X_1} & \cdots & \frac{\partial f_M}{\partial X_N} \end{pmatrix}\right|_{\mathbf{X}=\mathbf{x}} \tag{10.28}$$

Für ein implizites, multivariates Messmodell $\mathbf{h}(\mathbf{Y}, \mathbf{X}) = \mathbf{0}$ bestimmen wir zunächst die Ausgangsschätzwerte $\mathbf{y}$ aus dem Gleichungssystem

$$\mathbf{h}(\mathbf{y}, \mathbf{x}) = \mathbf{0}. \tag{10.29}$$

Gemäß GUM Supplement 2, Abschnitt 6.3, erfolgt die Kovarianzfortpflanzung auf Grundlage der am Punkt $(\mathbf{y}, \mathbf{x})$ linearisierten Modellbeziehung. Für diese gilt

$$\mathbf{C_y U_y C_y^T} = \mathbf{C_x U_x C_x^T}. \tag{10.30}$$

Die Sensitivitätsmatrizen werden beide am selben Punkt ausgewertet:

$$\mathbf{C_x} = \left.\begin{pmatrix} \frac{\partial h_1}{\partial X_1} & \cdots & \frac{\partial h_1}{\partial X_N} \\ \vdots & \ddots & \vdots \\ \frac{\partial h_M}{\partial X_1} & \cdots & \frac{\partial h_M}{\partial X_N} \end{pmatrix}\right|_{\mathbf{Y}=\mathbf{y},\,\mathbf{X}=\mathbf{x}} \quad \text{und} \quad \mathbf{C_y} = \left.\begin{pmatrix} \frac{\partial h_1}{\partial Y_1} & \cdots & \frac{\partial h_1}{\partial Y_M} \\ \vdots & \ddots & \vdots \\ \frac{\partial h_M}{\partial Y_1} & \cdots & \frac{\partial h_M}{\partial Y_M} \end{pmatrix}\right|_{\mathbf{Y}=\mathbf{y},\,\mathbf{X}=\mathbf{x}}. \tag{10.31}$$

Dabei hat $\mathbf{C_x}$ die Dimension $M \times N$ und $\mathbf{C_y}$ die Dimension $M \times M$.

Ist $\mathbf{C_y}$ invertierbar, lässt sich Gl. (10.30) nach $\mathbf{U_y}$ auflösen:

$$\begin{aligned} \mathbf{U_y} &= \mathbf{C_y^{-1}} \mathbf{C_x} \mathbf{U_x} \mathbf{C_x^T} \left(\mathbf{C_y^{-1}}\right)^\mathsf{T} \\ &= \mathbf{C} \mathbf{U_x} \mathbf{C}^\mathsf{T}, \qquad \mathbf{C} = \mathbf{C_y^{-1}} \mathbf{C_x}. \end{aligned} \tag{10.32}$$

Hierbei verwenden wir

$$\mathbf{C}^\mathsf{T} = \left(\mathbf{C_y^{-1}} \mathbf{C_x}\right)^\mathsf{T} = \mathbf{C_x^T} \left(\mathbf{C_y^{-1}}\right)^\mathsf{T}. \tag{10.33}$$

Auch im multivariaten Fall gilt, dass bei nichtlinearen Modellgleichungen die so berechnete Kovari-

anzmatrix eine Näherung für diejenige des ursprünglichen Modells ist und nur für lineare Modellgleichungen mit festen Koeffizienten und gegebenenfalls konstanten additiven Termen exakt gilt.

Eine Kovarianzmatrix muss positiv semidefinit sein. Das bedeutet, dass $\mathbf{a}^\mathsf{T}\mathbf{U}_\mathbf{x}\mathbf{a} \geq 0$ für jeden reellen Vektor $\mathbf{a}$ gilt. Damit kann auch die fortgepflanzte Varianz nicht negativ werden. Für mehr als zwei Eingangsgrößen genügt es nicht, beliebige Korrelationskoeffizienten einzeln im Bereich $[-1, 1]$ zu wählen: Sie müssen zusammen eine gültige Korrelationsmatrix bilden.

## 10.2 Linearisierung eines nichtlinearen Modells

Für ein differenzierbares Modell $Y = f(\mathbf{X})$ entwickeln wir die Modellfunktion um den Vektor der Beobachtungswerte $\mathbf{x} = (x_1, \ldots, x_N)^\mathsf{T}$. Die Taylorentwicklung bis zum linearen Term lautet

$$Y = f(\mathbf{X}) = f(\mathbf{x}) + \sum_{i=1}^{N} c_i(X_i - x_i) + R(\mathbf{X}), \qquad c_i = \left.\frac{\partial f(\mathbf{X})}{\partial X_i}\right|_{\mathbf{X}=\mathbf{x}}. \tag{10.34}$$

Die Beobachtungswerte $x_i$ legen somit den Entwicklungspunkt fest. Der Restterm $R(\mathbf{X})$ beschreibt die Abweichung der vollständigen Modellfunktion von ihrer linearen Näherung.

Die Sensitivitätskoeffizienten bilden den Spaltenvektor

$$\mathbf{c} = \nabla f(\mathbf{X})|_{\mathbf{X}=\mathbf{x}} = \left.\begin{pmatrix} \frac{\partial f(\mathbf{X})}{\partial X_1} \\ \vdots \\ \frac{\partial f(\mathbf{X})}{\partial X_N} \end{pmatrix}\right|_{\mathbf{X}=\mathbf{x}}. \tag{10.35}$$

Dieser Vektor ist der Gradient der Modellfunktion am Entwicklungspunkt $\mathbf{x}$. Das Symbol $\nabla$ bezeichnet den Nablaoperator, der hier als Spaltenvektor der partiellen Ableitungsoperatoren geschrieben wird:

$$\nabla = \begin{pmatrix} \frac{\partial}{\partial X_1} \\ \vdots \\ \frac{\partial}{\partial X_N} \end{pmatrix}. \tag{10.36}$$

Damit lässt sich der lineare Term als Produkt des Zeilenvektors $\mathbf{c}^\mathsf{T}$ mit dem Spaltenvektor $\mathbf{X} - \mathbf{x}$ ausdrücken:

$$\sum_{i=1}^{N} c_i(X_i - x_i) = \mathbf{c}^\mathsf{T}(\mathbf{X} - \mathbf{x}). \tag{10.37}$$

Ist der Restterm $R(\mathbf{X})$ im relevanten Unsicherheitsbereich vernachlässigbar, verwenden wir das linearisierte Modell

$$Y_\mathrm{lin} = f(\mathbf{x}) + \mathbf{c}^\mathsf{T}(\mathbf{X} - \mathbf{x}). \tag{10.38}$$

Jeder Sensitivitätskoeffizient $c_i$ beschreibt, wie stark sich die Ausgangsgröße bei einer kleinen Änderung der Eingangsgröße $X_i$ am Entwicklungspunkt verändert, während die übrigen Eingangsgrößen

festgehalten werden. Seine physikalische Dimension ist

$$\dim c_i = \frac{\dim Y}{\dim X_i}. \tag{10.39}$$

Die Produkte $c_i u(x_i)$ haben daher die Dimension der Ausgangsgröße und werden bei konsistenter Verwendung der Einheiten in deren Einheit angegeben.

Wenn $x_i = \mathrm{E}(X_i)$ gilt, folgt

$$\mathrm{E}(Y_{\mathrm{lin}}) = f(\mathbf{x}), \qquad \mathrm{Var}(Y_{\mathrm{lin}}) = \sum_{i=1}^{N}\sum_{k=1}^{N} c_i c_k \,\mathrm{Cov}(X_i, X_k). \tag{10.40}$$

Für das ursprüngliche nichtlineare Modell erhalten wir damit

$$y = f(\mathbf{x}) \approx \mathrm{E}(Y), \qquad u_{\mathrm{c}}^2(y) \approx \mathrm{Var}(Y) \approx \sum_{i=1}^{N} c_i^2 u^2(x_i) + 2\sum_{i=1}^{N-1}\sum_{k=i+1}^{N} c_i c_k u(x_i, x_k). \tag{10.41}$$

Die Fortpflanzungsformel gilt exakt für das linearisierte Modell; ihre Anwendung auf das ursprüngliche Modell ist eine Näherung.

Die im GUM verwendete Kurzschreibweise $\partial f/\partial x_i$ bezeichnet hier die partielle Ableitung der Modellfunktion, ausgewertet an den Eingangsschätzwerten. In diesem Skript schreiben wir die Auswertung explizit dazu, um Funktionsargument und Schätzwert zu unterscheiden.

**Beispiel: Produkt zweier Eingangsgrößen** Für

$$Y = X_1 X_2 \tag{10.42}$$

sind die Sensitivitätskoeffizienten $c_1 = x_2$ und $c_2 = x_1$. Für unabhängige Eingangsgrößen folgt in erster Ordnung

$$y = x_1 x_2, \qquad u_{\mathrm{c}}^2(y) = x_2^2 u^2(x_1) + x_1^2 u^2(x_2). \tag{10.43}$$

Wenn $x_1, x_2 \neq 0$ sind, ist die relative Form

$$\left[\frac{u_{\mathrm{c}}(y)}{|y|}\right]^2 = \left[\frac{u(x_1)}{|x_1|}\right]^2 + \left[\frac{u(x_2)}{|x_2|}\right]^2. \tag{10.44}$$

Werden die beiden Eingangsgrößen durch Mittelwerte aus unabhängigen Messreihen geschätzt, setzen wir deren Standardunsicherheiten $s_1/\sqrt{J_1}$ und $s_2/\sqrt{J_2}$ ein.

Für das Produkt unabhängiger Größen lassen sich die Momente auch exakt berechnen. Mit $x_i = \mathrm{E}(X_i)$ gilt

$$\begin{aligned} \mathrm{E}(X_1 X_2) &= x_1 x_2, \\ \mathrm{Var}(X_1 X_2) &= x_2^2 u^2(x_1) + x_1^2 u^2(x_2) + u^2(x_1) u^2(x_2). \end{aligned} \tag{10.45}$$

Die linearisierte Rechnung lässt den letzten Term weg. Dieser Vergleich zeigt unmittelbar, wann die Näherung für die Varianz ausreicht. Bei korrelierten Eingangsgrößen gilt außerdem $\mathrm{E}(X_1 X_2) = x_1 x_2 + \mathrm{Cov}(X_1, X_2)$.

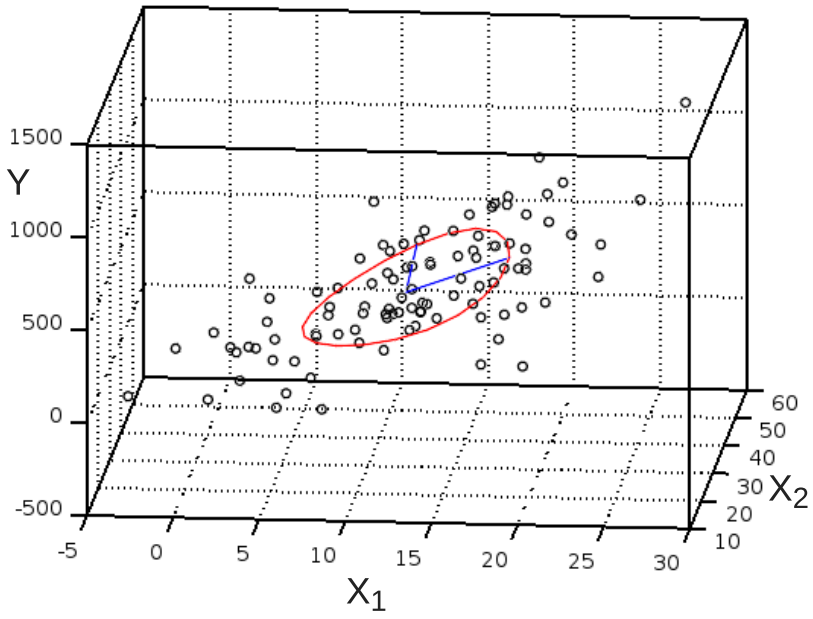



Abbildung 10.1: Veranschaulichung einer gemeinsamen Streuung der Eingangsgrößen $X_1$ und $X_2$ und der daraus berechneten Ausgangsgröße $Y$. Die rote Ellipse und die blauen Strecken illustrieren die geometrische Darstellung der Streuung. Ohne Angabe ihrer Skalierung ist die Ellipse kein Überdeckungsbereich mit festgelegter Wahrscheinlichkeit.

## 10.3 Grenzen des Linearisierungsansatzes

Die lineare Unsicherheitsfortpflanzung ersetzt die Modellfunktion im relevanten Unsicherheitsbereich durch ihre Tangente beziehungsweise, bei mehreren Eingangsgrößen, durch ihre Tangentialebene. Bei einem gekrümmten Modell kann diese Näherung sowohl den Ausgangsschätzwert als auch die berechnete Standardunsicherheit beeinflussen.

Setzen wir die Eingangsschätzwerte in das Messmodell ein, erhalten wir $y = f(\mathbf{x})$. Wird dagegen die vollständige Eingangsverteilung fortgepflanzt und der Erwartungswert der Ausgangsgröße als Schätzwert verwendet, erhalten wir $y = \mathrm{E}[f(\mathbf{X})]$. Bei einem nichtlinearen Modell müssen diese beiden Werte nicht übereinstimmen: Das Einsetzen der Erwartungswerte in die Modellfunktion und das Bilden des Erwartungswerts der Modellwerte sind unterschiedliche Rechenschritte.

Um diesen Unterschied zu untersuchen, nehmen wir zunächst an, dass der Entwicklungspunkt dem Erwartungswertvektor der Eingangsgrößen entspricht:

$$\mathbf{x} = \mathrm{E}(\mathbf{X}). \tag{10.46}$$

Für die Abweichungen $\Delta X_i = X_i - x_i$ gilt dann $\mathrm{E}(\Delta X_i) = 0$. Die Taylorentwicklung bis zu den quadratischen Termen lautet

$$f(\mathbf{X}) \approx f(\mathbf{x}) + \sum_{i=1}^{N} c_i \Delta X_i + \frac{1}{2} \sum_{i=1}^{N} \sum_{k=1}^{N} \left. \frac{\partial^2 f}{\partial X_i \partial X_k} \right|_{\mathbf{X}=\mathbf{x}} \Delta X_i \Delta X_k. \tag{10.47}$$

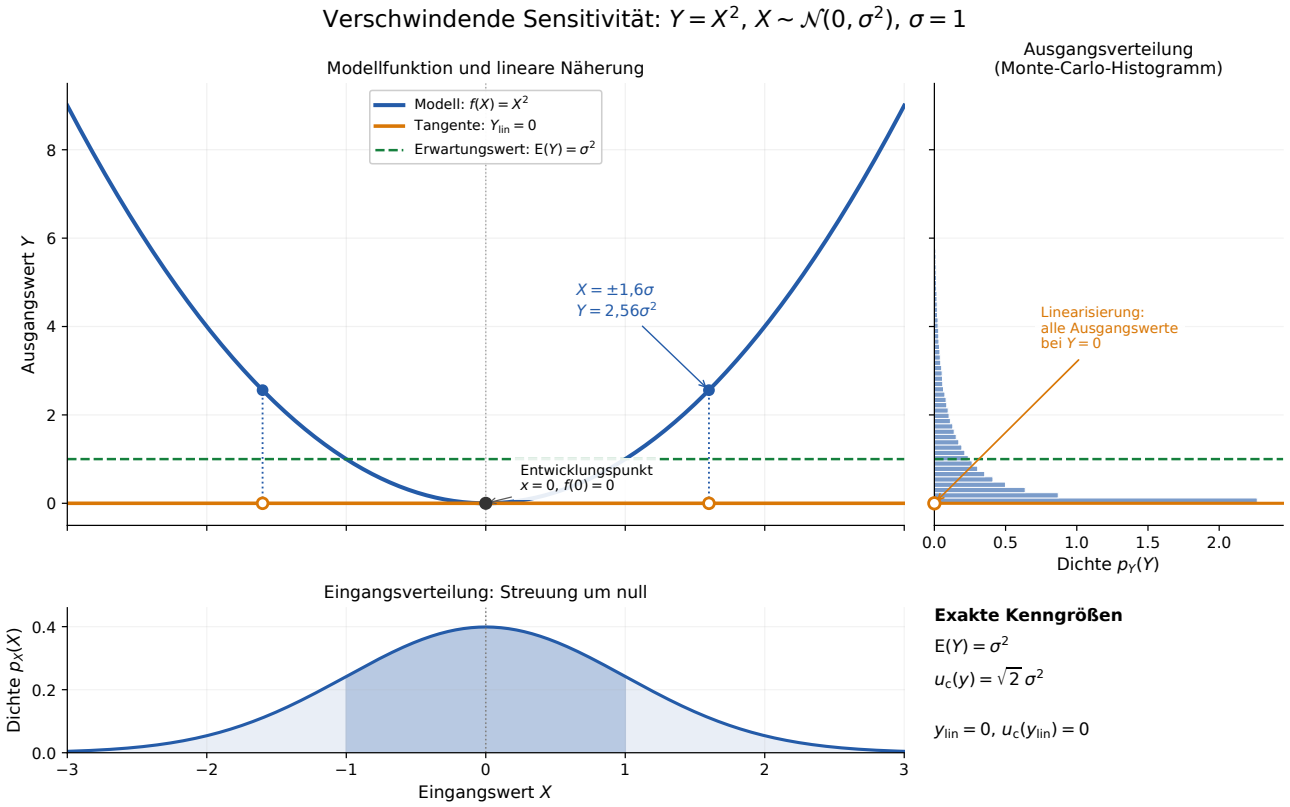



Abbildung 10.2: Einfluss der Modellkrümmung auf den Erwartungswert einer Ausgangsgröße.

Beim Bilden des Erwartungswerts verschwindet der lineare Term, weil die Abweichungen $\Delta X_i$ den Erwartungswert null haben. Die quadratischen Terme verschwinden dagegen im Allgemeinen nicht, denn

$$\mathrm{E}(\Delta X_i \Delta X_k) = \mathrm{Cov}(X_i, X_k). \tag{10.48}$$

Ersetzen wir diese Kovarianzen durch die für die Auswertung bestimmten oder geschätzten Werte $u(x_i, x_k)$, erhalten wir

$$\mathrm{E}[f(\mathbf{X})] \approx f(\mathbf{x}) + \frac{1}{2} \sum_{i=1}^{N} \sum_{k=1}^{N} \left. \frac{\partial^2 f}{\partial X_i \partial X_k} \right|_{\mathbf{X}=\mathbf{x}} u(x_i, x_k). \tag{10.49}$$

Die zweiten Ableitungen beschreiben die Modellkrümmung. Zusammen mit den Varianzen und Kovarianzen bestimmen sie den hier berechneten Korrekturterm zum Erwartungswert. Die Näherung setzt voraus, dass die erforderlichen Momente existieren und der Erwartungswert des verbleibenden Taylorrestterms vernachlässigbar ist.

Das in Abb. 10.2 dargestellte Beispiel einer Parabel als Messmodell mit Eingangsschätzwert im Minimum veranschaulicht, dass bei Tangentensteigung null gar keine Unsicherheit approximiert werden kann.

Wir betrachten das Modell

$$Y = f(X) = X^2, \qquad X \sim \mathcal{N}(0, \sigma^2). \tag{10.50}$$

Die Eingangsgröße hat den Erwartungswert $x = 0$.

Setzen wir diesen Wert in das Modell ein, erhalten wir $f(0) = 0$. Die erste Ableitung ist

$$f'(X) = 2X, \qquad c = f'(0) = 0. \tag{10.51}$$

Die Tangente an die Parabel ist an diesem Punkt horizontal. Das linearisierte Modell lautet daher

$$Y_{\mathrm{lin}} = f(0) + c(X - 0) = 0. \tag{10.52}$$

Es liefert für jeden Eingangswert denselben Ausgangswert null. Folglich ergibt die linearisierte Rechnung

$$y_{\mathrm{lin}} = 0, \qquad u_{\mathrm{c}}(y_{\mathrm{lin}}) = 0. \tag{10.53}$$

Die ursprüngliche Modellfunktion verhält sich jedoch anders: Sowohl positive als auch negative Eingangswerte werden durch das Quadrieren auf positive Ausgangswerte abgebildet. Obwohl die Eingangsverteilung symmetrisch um null liegt, liegen die Ausgangswerte somit auf der nichtnegativen Seite und sind nicht alle gleich null.

Der Erwartungswert der Ausgangsgröße ist

$$\mathrm{E}(Y) = \mathrm{E}(X^2) = \sigma^2. \tag{10.54}$$

Auch die Näherung zweiter Ordnung liefert hier dieses Ergebnis: Wegen $f''(X) = 2$ ist der Korrekturterm $\frac{1}{2} f''(0)\sigma^2 = \sigma^2$. Da das Modell selbst quadratisch ist, gibt es in diesem Beispiel keine weiteren Taylorterme.

Für die Varianz der Ausgangsgröße benötigen wir zusätzlich das vierte Moment der Eingangsverteilung:

$$\mathrm{Var}(Y) = \mathrm{E}(X^4) - \left[\mathrm{E}(X^2)\right]^2. \tag{10.55}$$

Für die hier verwendete Normalverteilung gilt $\mathrm{E}(X^4) = 3\sigma^4$. Damit folgen

$$\mathrm{Var}(Y) = 2\sigma^4, \qquad u_{\mathrm{c}}(y) = \sqrt{2}\,\sigma^2. \tag{10.56}$$

Die verschwindende Sensitivität erster Ordnung bedeutet hier also lediglich, dass die Tangente keine Änderung des Ausgangswerts beschreibt. Die tatsächliche Modellfunktion besitzt jedoch eine Krümmung, durch die sowohl ein positiver Erwartungswert als auch eine von null verschiedene Streuung entstehen.

**Folgerungen für die Unsicherheitsfortpflanzung.** Das Beispiel zeigt, warum die erste Ableitung allein nicht immer ausreicht. Für die Berechnung der Varianz einer quadratischen Taylor-Näherung werden im Allgemeinen auch Momente dritter und vierter Ordnung benötigt. Die Varianzen und Kovarianzen der Eingangsgrößen allein genügen dafür im Allgemeinen nicht.

Ob die Linearisierung ausreicht, muss deshalb anhand des Modellverlaufs und der Eingangsunsicherheit untersucht werden. Bei Unstetigkeiten oder in der Nähe einer Singularität muss darüber hinaus geprüft werden, ob das Modell im relevanten Unsicherheitsbereich anwendbar ist.

Die Verteilungsfortpflanzung nach GUM Supplement 1 bietet einen anderen Rechenweg: Bei einer Monte-Carlo-Auswertung werden Eingangskombinationen aus den festgelegten Eingangsverteilungen gezogen und jeweils in die ursprüngliche Modellfunktion eingesetzt. Aus den so erhaltenen Ausgangswerten können Erwartungswert und Standardunsicherheit bestimmt werden, sofern diese Momente existieren. Die Modellfunktion wird dabei nicht durch ihre lineare Näherung ersetzt.

## 10.4 Von der Standardunsicherheit zum Überdeckungsintervall

Die Standardunsicherheit beschreibt eine Streuung. Für ein Intervall mit der Überdeckungswahrscheinlichkeit $P = 1-\alpha$ brauchen wir zusätzlich eine begründete Beschreibung der Ausgangsverteilung. Wenn die Verteilung der Ausgangsgröße ausreichend gut durch eine Normalverteilung angenähert werden kann, schreiben wir

$$[y - U, y + U], \qquad U = k\, u_\mathrm{c}(y), \qquad k = z_{1-\alpha/2}, \tag{10.57}$$

wobei $z_q$ das Quantil der Standardnormalverteilung ist. Für $P = 0.95$ gilt $k \approx 1.96$; $k = 2$ entspricht bei einer Normalverteilung etwa 95.45 %.

Die Näherung mit normalverteilter Ausgangsgröße ist nur dann bei einer Summe vieler unabhängiger Beiträge angemessen, wenn kein einzelner nichtnormalverteilter Beitrag überwiegt und die weiteren Voraussetzungen des zentralen Grenzwertsatzes hinreichend erfüllt sind. Sie folgt nicht allein daraus, dass das Messmodell linear ist.

Wird die Varianz aus einer begrenzten Anzahl normalverteilter Beobachtungen geschätzt, ist bei der Intervallbestimmung zusätzlich die Unsicherheit dieser Varianzschätzung zu berücksichtigen. Hierzu verwenden wir die Student-$t$-Verteilung, deren Ausläufer (*tails*) insbesondere bei kleinen Stichprobenumfängen stärker besetzt sind als die der Standardnormalverteilung. Wir betrachten zunächst eine einzelne Messreihe und anschließend die Kombination mehrerer Unsicherheitsbeiträge. Für diese werden unter geeigneten Voraussetzungen mithilfe der Welch-Satterthwaite-Näherung effektive Freiheitsgrade bestimmt.

**Eine einzelne Messreihe und das $t$-Quantil:** Wir betrachten $J$ unabhängige, identisch normalverteilte Beobachtungen mit festem, unbekanntem Mittelwert $\mu$ und unbekannter Varianz $\sigma^2$. Im statistischen Beobachtungsmodell werden die möglichen Einzelbeobachtungen durch die Zufallsgrößen $X_1, \ldots, X_J$ beschrieben. Der daraus gebildete Stichprobenmittelwert $\overline{X}$ und die Stichprobenvarianz $S^2$ sind damit ebenfalls Zufallsgrößen. Sie dienen als Schätzer für $\mu$ beziehungsweise $\sigma^2$. Nach Einsetzen der beobachteten Werte $x_1, \ldots, x_J$ erhalten wir die konkreten Schätzwerte $\bar{x}$ und $s^2$.

$$\overline{X} = \frac{1}{J}\sum_{j=1}^{J} X_j, \qquad S^2 = \frac{1}{J-1}\sum_{j=1}^{J}(X_j - \overline{X})^2. \tag{10.58}$$

Für die Größe

$$Z = \frac{\overline{X} - \mu}{S/\sqrt{J}} \tag{10.59}$$

gilt

$$Z \sim t_{J-1}. \tag{10.60}$$

Entscheidend ist, dass im Nenner die Zufallsgröße $S$ steht, mit der die Standardabweichung $\sigma$ aus der Stichprobe geschätzt wird. Bei Division durch die wahre Standardabweichung $\sigma$ wäre die resultierende Größe dagegen standardnormalverteilt:

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{J}} \sim \mathcal{N}(0,1). \tag{10.61}$$

Nach der Datenerhebung liegen die berechneten Werte $\bar{x}$ und $s$ vor. Das frequentistische Vertrauensintervall für $\mu$ lautet

$$\left[\bar{x} - t_{1-\alpha/2,J-1}\frac{s}{\sqrt{J}},\quad \bar{x} + t_{1-\alpha/2,J-1}\frac{s}{\sqrt{J}}\right]. \tag{10.62}$$

Dabei bezeichnet $t_{p,\nu}$ das Quantil der Student-$t$-Verteilung mit $\nu$ Freiheitsgraden. Bei kleinen Freiheitsgraden ist $t_{1-\alpha/2,\nu}$ größer als das entsprechende Quantil der Normalverteilung. Die Überdeckungswahrscheinlichkeit $1-\alpha$ bezieht sich auf das Verfahren: Bei wiederholter Durchführung enthalten die so konstruierten Intervalle den festen Mittelwert $\mu$ mit dieser Wahrscheinlichkeit. Dem Parameter $\mu$ wird dadurch selbst keine Wahrscheinlichkeitsverteilung zugeordnet.

Für die spätere Verteilungsfortpflanzung müssen wir zwei Fragen unterscheiden: Wie stark streuen die möglichen Stichprobenmittelwerte bei wiederholter Messung? Und welche Verteilung beschreibt nach der Datenauswertung die Unsicherheit über den unbekannten Mittelwert? Dabei tritt der Ausdruck $s/\sqrt{J}$ in unterschiedlichen Rollen auf.

**Streuung der Stichprobenmittelwerte im Beobachtungsmodell.** Wir betrachten $J$ unabhängige, identisch normalverteilte Beobachtungen mit festem, unbekanntem Mittelwert $\mu$ und unbekannter Varianz $\sigma^2$:

$$X_j \sim \mathcal{N}(\mu, \sigma^2), \qquad j = 1, \ldots, J. \tag{10.63}$$

Denken wir uns die gesamte Messreihe wiederholt durchgeführt, liefert jede Wiederholung einen anderen Stichprobenmittelwert. Die möglichen Mittelwerte werden durch die Zufallsgröße $\overline{X}$ beschrieben. Für sie gilt

$$\overline{X} = \frac{1}{J}\sum_{j=1}^{J} X_j, \qquad \overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{J}\right). \tag{10.64}$$

Ihre tatsächliche Standardabweichung beträgt somit

$$\sqrt{\mathrm{Var}(\overline{X})} = \frac{\sigma}{\sqrt{J}}. \tag{10.65}$$

Diese Größe beschreibt die Streuung der möglichen Stichprobenmittelwerte um den festen Parameter $\mu$.

Da $\sigma$ unbekannt ist, schätzen wir diese Standardabweichung aus den beobachteten Daten durch

$$u(\bar{x}) = \frac{s}{\sqrt{J}}. \tag{10.66}$$

Dies ist die im klassischen GUM verwendete Standardunsicherheit des Mittelwerts.

Die Verwendung von Student-$t$-Quantilen bei der Konstruktion eines Vertrauensintervalls ändert die Verteilung von $\overline{X}$ nicht. Die Student-$t$-Verteilung betrifft dort den Quotienten

$$Z_{J-1} = \frac{\overline{X} - \mu}{S/\sqrt{J}} \sim t_{J-1}, \tag{10.67}$$

während $\overline{X}$ selbst weiterhin normalverteilt ist. Im Nenner steht die Zufallsgröße $S$, mit der die Standardabweichung $\sigma$ aus der Stichprobe geschätzt wird.

**Skalenparameter einer Student-$t$-Verteilung.** Bevor wir die zweite Fragestellung betrachten, unterscheiden wir den Skalenparameter einer Student-$t$-Verteilung von ihrer Standardabweichung. Dazu verwenden wir die allgemeine Darstellung

$$X = x + aZ_\nu, \qquad a > 0, \tag{10.68}$$

wobei $x$ ein fester Lageparameter und $a$ ein fester Skalenparameter ist. $Z_\nu$ bezeichnet eine Zufallsgröße mit zentraler Student-$t$-Verteilung mit $\nu$ Freiheitsgraden, also mit Lageparameter null und Skalenparameter eins.

Der Faktor $a$ streckt alle Abstände vom Lageparameter $x$. Die Standardabweichung wird deshalb ebenfalls mit $a$ multipliziert:

$$\sqrt{\mathrm{Var}(X)} = a\sqrt{\mathrm{Var}(Z_\nu)}. \tag{10.69}$$

Der Skalenparameter $a$ wäre nur dann zugleich die Standardabweichung von $X$, wenn $Z_\nu$ die Standardabweichung eins hätte. Für die übliche Student-$t$-Verteilung gilt jedoch

$$\mathrm{E}(Z_\nu) = 0 \quad \text{für } \nu > 1, \qquad \mathrm{Var}(Z_\nu) = \frac{\nu}{\nu - 2} \quad \text{für } \nu > 2. \tag{10.70}$$

Für die verschobene und skalierte Größe $X$ folgt daraus

$$\mathrm{E}(X) = x \quad \text{für } \nu > 1, \qquad \sqrt{\mathrm{Var}(X)} = a\sqrt{\frac{\nu}{\nu - 2}} \quad \text{für } \nu > 2. \tag{10.71}$$

Der Skalenparameter $a$ hat dieselbe Einheit wie $X$, ist aber nicht deren Standardabweichung. Wir verwenden deshalb hier nicht die Bezeichnung „standardisiert“ im Sinne einer Zufallsgröße mit Erwartungswert null und Varianz eins.

**Verteilungsbeschreibung nach der Datenauswertung.** Eine andere Fragestellung besteht darin, wie man *nach* der Datenauswertung eine Wahrscheinlichkeitsverteilung festlegt, die das Wissen über den unbekannten Mittelwert $\mu$ beschreibt. Nun liegen die beobachteten Daten und die daraus berechneten Werte $\bar{x}$ und $s$ als feste Zahlen vor. Eine solche Verteilung erhalten wir durch eine bayesische Auswertung.

In einer bayesischen Auswertung beschreibt die Priorverteilung die Information über die unbekannten Parameter, *bevor* die betrachteten Messdaten berücksichtigt werden. Sie muss nicht aus früheren Messungen stammen. Auch allgemeine Annahmen über mögliche Parameterwerte können durch eine

Priorverteilung ausgedrückt werden.

Eine sogenannte *nichtinformative Priorverteilung* wird mit dem Ziel gewählt, möglichst wenig zusätzliche Information über die Parameter einzubringen. Die Schlussfolgerungen sollen vor allem durch die Messdaten bestimmt werden. Die Bezeichnung bedeutet jedoch nicht, dass überhaupt keine Annahmen getroffen werden oder dass die Priorwahl ohne Einfluss auf das Ergebnis bleibt.

Ein einfaches Beispiel ist eine konstante Priordichte innerhalb eines vorgegebenen Intervalls. Sie ordnet gleich breiten Teilintervallen dieselbe Wahrscheinlichkeit zu und bevorzugt innerhalb dieses Bereichs keine bestimmte Lage. Bereits die Wahl der Intervallgrenzen stellt allerdings eine Information dar. Außerdem ist eine konstante Dichte für einen positiven Parameter $\theta$ etwas anderes als eine konstante Dichte für $\log\theta$: Im ersten Fall werden gleich große additive Intervalle gleich behandelt, im zweiten Fall gleich große Verhältnisse.

Eine allgemein eindeutige Priorverteilung, die völlige Unkenntnis ausdrückt, gibt es daher nicht. Nichtinformative Priorverteilungen werden nach bestimmten formalen Regeln konstruiert; die konkrete Wahl gehört zum statistischen Modell.

Bei unserer normalverteilten Messreihe benötigen wir eine gemeinsame Priorverteilung für den unbekannten Mittelwert $\mu$ und die unbekannte Varianz $\sigma^2$. Nach Berücksichtigung der Messdaten $\mathbf{x} = (x_1, \ldots, x_J)^\mathsf{T}$ gilt nach dem Satz von Bayes

$$p(\mu, \sigma^2 \mid \mathbf{x}) \propto L(\mu, \sigma^2; \mathbf{x})\, p(\mu, \sigma^2). \tag{10.72}$$

Die gemeinsame Posteriorverteilung entsteht somit aus dem Produkt der Likelihood und der gemeinsamen Priorverteilung.

Interessieren wir uns für den unbekannten Mittelwert, integrieren wir anschließend über die möglichen Werte der unbekannten Varianz:

$$p(\mu \mid \mathbf{x}) = \int_0^\infty p(\mu, \sigma^2 \mid \mathbf{x})\, \mathrm{d}\sigma^2. \tag{10.73}$$

Die Unsicherheit über die Varianz wird dabei mitberücksichtigt.

**Die Student-$t$-Verteilung in Supplement 1.** Mit der in GUM Supplement 1, Abschnitt 6.4.9, zugrunde gelegten nichtinformativen Priorwahl ergibt sich für den unbekannten Mittelwert eine verschobene und skalierte Student-$t$-Verteilung.

Zur Unterscheidung von den Einzelbeobachtungen $X_j$ und dem Stichprobenmittelwert $\overline{X}$ bezeichnen wir die Zufallsgröße, die die Unsicherheit über den unbekannten Mittelwert $\mu$ beschreibt, mit $X_\mu$. Ihre Darstellung lautet

$$X_\mu = \bar{x} + \frac{s}{\sqrt{J}}\, Z_{J-1}. \tag{10.74}$$

Die Verteilung von $X_\mu$ beschreibt das Wissen über $\mu$ nach Kenntnis der vorliegenden Daten. Sie ist weder die Verteilung einer Einzelbeobachtung noch die Verteilung der Stichprobenmittelwerte bei wiederholter Messung. Die Verteilung von $X_\mu$ beschreibt vielmehr das Wissen über den unbekannten Mittelwert nach Kenntnis der vorliegenden Daten. Die Werte $\bar{x}$ und $s$ sind in dieser Darstellung fest.

Vergleichen wir dies mit der allgemeinen Darstellung $X = x + aZ_\nu$, erkennen wir die Zuordnung

$$x = \bar{x}, \qquad a = \frac{s}{\sqrt{J}}, \qquad \nu = J - 1. \tag{10.75}$$

Der Ausdruck $s/\sqrt{J}$ ist hier also der *Skalenparameter* der zugeordneten Student-$t$-Verteilung. Ihre *Standardabweichung* hingegen beträgt dagegen

$$\sqrt{\mathrm{Var}(X_\mu)} = \frac{s}{\sqrt{J}}\sqrt{\frac{\nu}{\nu-2}} = \frac{s}{\sqrt{J}}\sqrt{\frac{J-1}{J-3}}, \qquad J > 3. \tag{10.76}$$

Der Erwartungswert ist $\mathrm{E}(X_\mu) = \bar{x}$ für $J > 2$.

**GUM Supplement 1 verwendet die Standardabweichung dieser zugeordneten Verteilung als Standardunsicherheit und weist in Abschnitt 6.4.9.4, Anmerkung 1, ausdrücklich auf den Unterschied zum klassischen GUM hin.**

**Zahlenbeispiel mit fünf Beobachtungen.** Für eine Messreihe mit

$$J = 5, \qquad s = 2\,\Omega \tag{10.77}$$

ergibt sich im klassischen Ansatz

$$u_{\mathrm{klassisch}}(\bar{x}) = \frac{s}{\sqrt{J}} = \frac{2}{\sqrt{5}}\,\Omega \approx 0{,}894\,\Omega. \tag{10.78}$$

Dies ist die aus der Messreihe geschätzte Standardabweichung der möglichen Stichprobenmittelwerte.

Für die Verteilungsbeschreibung nach GUM Supplement 1 gilt dagegen

$$X_\mu = \bar{x} + \frac{2}{\sqrt{5}}\,\Omega\, Z_4. \tag{10.79}$$

Diese Student-$t$-Verteilung hat den Skalenparameter $2/\sqrt{5}\,\Omega$, aber wegen

$$\mathrm{Var}(Z_4) = \frac{4}{4-2} = 2 \tag{10.80}$$

die Standardabweichung

$$u_{\mathrm{GUM-S1}}(\bar{x}) = \sqrt{\mathrm{Var}(X_\mu)} = \frac{2}{\sqrt{5}}\sqrt{2}\,\Omega \approx 1{,}265\,\Omega. \tag{10.81}$$

Die beiden Zahlen beschreiben unterschiedliche statistische Betrachtungen. Im klassischen Ansatz wird aus den Daten geschätzt, wie stark die möglichen Stichprobenmittelwerte bei wiederholter Messung um den festen Parameter $\mu$ streuen. Im bayesischen Ansatz wird die Standardabweichung einer Verteilung bestimmt, die nach Kenntnis der Daten die Unsicherheit über $\mu$ beschreibt.

Die Verteilung nach Supplement 1 ist somit ein Ergebnis aus dem Beobachtungsmodell, den Messdaten und der Priorwahl. Sie folgt nicht allein aus der Konstruktion des frequentistischen Vertrauensintervalls. Diese Unterscheidung wird bei der Verteilungsfortpflanzung in Kapitel 11 relevant.

**Effektive Freiheitsgrade für die kombinierte Unsicherheit:** Bei mehreren unabhängig bewerteten Unsicherheitsbeiträgen ist deren Zuverlässigkeit im Allgemeinen verschieden. Die Welch–Satterthwaite-Näherung ordnet der kombinierten Standardunsicherheit eine *effektive Anzahl von Freiheitsgraden* zu. Für unkorrelierte Eingangsgrößen ist

$$\boxed{\nu_{\text{eff}} = \frac{u_{\text{c}}^4(y)}{\displaystyle\sum_{i=1}^{N} \frac{[c_i u(x_i)]^4}{\nu_i}}.} \tag{10.82}$$

Hier sind die $c_i$ als fest behandelt. $\nu_i$ charakterisiert die Bewertung des jeweiligen Varianzbeitrags, etwa $J_i - 1$ bei einer unabhängigen Messreihe. Bei einem als hinreichend zuverlässig bekannten Typ-B-Beitrag kann $\nu_i \to \infty$ angesetzt werden. Ein Typ-B-Beitrag hat jedoch nicht allein aufgrund seiner Bezeichnung automatisch unendlich viele Freiheitsgrade.

Unter den Voraussetzungen für die Approximation eine $t$-Verteilung anzusetzen wird

$$k \approx t_{1-\alpha/2,\nu_{\text{eff}}}, \qquad U = k\, u_{\text{c}}(y). \tag{10.83}$$

Die effektiven Freiheitsgrade sind kein neuer Stichprobenumfang und müssen nicht ganzzahlig sein. Für eine Tabelle kann konservativ auf die nächstkleinere ganze Zahl abgerundet werden; numerisch lässt sich das Quantil auch für nichtganzzahlige Freiheitsgrade berechnen.

Die Formel für $\nu_{\text{eff}}$ ist eine Näherung. Sie ist in dieser Form nicht allgemein für korrelierte Beiträge anwendbar und rechtfertigt auch bei großen effektiven Freiheitsgraden nicht automatisch eine Approximation, dass die Größen als normalverteilt angenommen werden. Dominiert beispielsweise ein rechteckverteilter Beitrag, kann die Form der Ausgangsverteilung weiterhin wesentlich von der Normalverteilung abweichen.

**Herleitung der Welch–Satterthwaite-Näherung** Die Idee besteht darin, die Unsicherheit der *Varianzbewertung* selbst zu betrachten. Für eine normalverteilte Messreihe mit wahrer Varianz $\sigma_i^2$ und $\nu_i = J_i - 1$ gilt

$$Q_i = \frac{\nu_i S_i^2}{\sigma_i^2} \sim \chi^2_{\nu_i}. \tag{10.84}$$

Für diese Verteilung gilt

$$\mathrm{E}(Q_i) = \nu_i, \tag{10.85}$$

$$\mathrm{Var}(Q_i) = 2\nu_i. \tag{10.86}$$

Daraus folgen

$$\mathrm{E}(S_i^2) = \sigma_i^2, \qquad \mathrm{Var}(S_i^2) = \frac{2\sigma_i^4}{\nu_i}. \tag{10.87}$$

Die Großbuchstaben $S_i^2$ kennzeichnen hier den Varianzschätzer vor der Datenerhebung; $s_i^2$ ist der aus den beobachteten Daten berechnete Schätzwert.

Für die Varianzbewertung eines Mittelwerts ist $V_i = S_i^2/J_i$ mit Erwartungswert $v_i = \sigma_i^2/J_i$. Auch

hierfür ist $\mathrm{Var}(V_i) = 2v_i^2/\nu_i$. Sind die $V_i$ unabhängig und ist $V = \sum_i c_i^2 V_i$, gilt

$$\mathrm{Var}(V) = \sum_{i=1}^{N} c_i^4 \,\mathrm{Var}(V_i) = 2\sum_{i=1}^{N} \frac{c_i^4 v_i^2}{\nu_i}. \tag{10.88}$$

Wir approximieren $V$ durch eine skalierte $\chi^2$-Verteilung mit Erwartungswert $v = \sum_i c_i^2 v_i$ und wählen deren Freiheitsgrade so, dass die Varianz übereinstimmt:

$$\frac{2v^2}{\nu_{\mathrm{eff}}} = 2\sum_{i=1}^{N} \frac{c_i^4 v_i^2}{\nu_i}. \tag{10.89}$$

Nach Kürzen des Faktors 2 und Ersetzen der unbekannten $v_i$ durch die bewerteten Varianzen $u^2(x_i)$ ergibt sich Gl. (10.82). Für zwei Beiträge ist dies

$$\nu_{\mathrm{eff}} = \frac{u_{\mathrm{c}}^4(y)}{[c_1 u(x_1)]^4/\nu_1 + [c_2 u(x_2)]^4/\nu_2}. \tag{10.90}$$

**Überdeckungsintervall und Erweiterungsfaktor der zugeordneten Student-$t$-Verteilung.** Für die Bestimmung eines Überdeckungsintervalls müssen wir beachten, dass sich die üblichen Student-$t$-Quantile auf eine Verteilung mit Skalenparameter eins beziehen. Wir bezeichnen den aus der Messreihe berechneten Ausdruck $s/\sqrt{J}$ im Folgenden kurz mit

$$\bar{s} = \frac{s}{\sqrt{J}}. \tag{10.91}$$

Die nach Supplement 1 zugeordnete Verteilung lautet damit

$$X_\mu = \bar{x} + \bar{s}\, Z_\nu, \qquad \nu = J - 1. \tag{10.92}$$

Dabei ist $\bar{s}$ der Skalenparameter dieser Verteilung.

Für die zentrale Student-$t$-Verteilung gilt

$$\Pr\bigl(-t_{1-\alpha/2,\nu} \le Z_\nu \le t_{1-\alpha/2,\nu}\bigr) = 1 - \alpha. \tag{10.93}$$

Durch Multiplikation mit dem positiven Skalenparameter $\bar{s}$ und Addition des Lageparameters $\bar{x}$ erhalten wir daher das Überdeckungsintervall

$$\boxed{\left[\bar{x} - t_{1-\alpha/2,\nu}\bar{s},\quad \bar{x} + t_{1-\alpha/2,\nu}\bar{s}\right].} \tag{10.94}$$

Seine Halbbreite beträgt

$$U = t_{1-\alpha/2,\nu}\bar{s}. \tag{10.95}$$

Die stärker besetzten Ausläufer der Student-$t$-Verteilung sind bereits im Quantil berücksichtigt. Der Faktor $\sqrt{\nu/(\nu-2)}$ wird deshalb bei dieser Intervallberechnung nicht zusätzlich angebracht, siehe Abschnitt 5.4.

Dieser Faktor wird benötigt, wenn wir aus dem Skalenparameter die Standardabweichung der zuge-

ordneten Verteilung bestimmen:

$$u_{\mathrm{S1}}(\bar{x}) = \sqrt{\mathrm{Var}(X_\mu)} = \bar{s}\sqrt{\frac{\nu}{\nu-2}}, \qquad \nu > 2. \tag{10.96}$$

Möchten wir die Intervallhalbbreite als Produkt eines Erweiterungsfaktors und dieser Standardunsicherheit schreiben, müssen wir entsprechend umrechnen:

$$\bar{s} = u_{\mathrm{S1}}(\bar{x})\sqrt{\frac{\nu-2}{\nu}}. \tag{10.97}$$

Damit ergibt sich

$$U = t_{1-\alpha/2,\nu}\bar{s} = k_{\mathrm{S1}}\, u_{\mathrm{S1}}(\bar{x}) \tag{10.98}$$

mit

$$\boxed{k_{\mathrm{S1}} = t_{1-\alpha/2,\nu}\sqrt{\frac{\nu-2}{\nu}}, \qquad \nu > 2.} \tag{10.99}$$

Das übliche Student-$t$-Quantil multipliziert somit den *Skalenparameter*. Wird stattdessen die *Standardabweichung* der zugeordneten Student-$t$-Verteilung verwendet, gehört dazu der umgerechnete Erweiterungsfaktor $k_{\mathrm{S1}}$.

**Fortsetzung des Zahlenbeispiels.** Für $J = 5$ Beobachtungen und $s = 2\,\Omega$ gilt

$$\nu = 4, \qquad \bar{s} = \frac{2}{\sqrt{5}}\,\Omega \approx 0{,}8944\,\Omega, \qquad u_{\mathrm{S1}}(\bar{x}) = \bar{s}\sqrt{2} \approx 1{,}2649\,\Omega. \tag{10.100}$$

Für eine Überdeckungswahrscheinlichkeit von 0,95 beträgt das Student-$t$-Quantil

$$t_{0{,}975,4} \approx 2{,}7764. \tag{10.101}$$

Die Intervallhalbbreite ergibt sich direkt aus dem Skalenparameter:

$$U = t_{0{,}975,4}\bar{s} \approx 2{,}483\,\Omega. \tag{10.102}$$

Verwenden wir die Standardabweichung der zugeordneten Verteilung, lautet der zugehörige Erweiterungsfaktor

$$k_{\mathrm{S1}} = t_{0{,}975,4}\sqrt{\frac{4-2}{4}} \approx 1{,}9632. \tag{10.103}$$

Damit erhalten wir dieselbe Intervallhalbbreite:

$$U = k_{\mathrm{S1}}\, u_{\mathrm{S1}}(\bar{x}) \approx 2{,}483\,\Omega. \tag{10.104}$$

Beide Schreibweisen liefern also dasselbe Überdeckungsintervall. Eine Multiplikation von $u_{\mathrm{S1}}(\bar{x})$ mit dem unveränderten Student-$t$-Quantil würde dagegen ein zu breites Intervall ergeben.

**Grenzen der symmetrischen Ergebnisangabe** Eine erweiterte Messunsicherheit wird zusammen mit dem Erweiterungsfaktor und der zugrunde gelegten Überdeckungswahrscheinlichkeit angegeben. Bei einer schiefen Ausgangsverteilung kann ein symmetrisches Intervall um den Schätzwert ungeeignet

sein. Dann werden die beiden Intervallgrenzen direkt aus der Ausgangsverteilung bestimmt, beispielsweise als $[F_Y^{-1}(\alpha/2), F_Y^{-1}(1-\alpha/2)]$.

Die Fortpflanzung einer deterministischen Beziehung $Y = f(\mathbf{X})$ benötigt keine zusätzliche Likelihood, die $Y - f(\mathbf{X})$ als zufälligen Rest beschreibt. Falls tatsächlich eine weitere Modellabweichung vorliegt, muss sie als zusätzliche Einflussgröße begründet und in das Messmodell aufgenommen werden. Die Monte-Carlo-Fortpflanzung und die bayesische Schätzung von Eingangsverteilungen werden in Kapitel 11 auseinandergehalten.

**Vom Messunsicherheitsbudget zur Ergebnisangabe** Die bisher erläuterten Schritte werden für eine konkrete Messaufgabe in einem *Messunsicherheitsbudget* zusammengeführt. Darunter verstehen wir die nachvollziehbare Zusammenstellung der Messunsicherheitsbeiträge, ihrer Bestimmung und ihrer Kombination mithilfe des Messmodells. Das Budget dokumentiert damit, aus welchen Informationen und Annahmen die angegebene Messunsicherheit hervorgeht.

Üblicherweise werden die Eingangsgrößen mit ihren Schätzwerten $x_i$, den zugehörigen Standardunsicherheiten $u(x_i)$ und den Sensitivitätskoeffizienten $c_i$ tabellarisch aufgeführt. Hinzu kommen Angaben zur Herkunft der Unsicherheiten, zu den verwendeten Verteilungsannahmen und zu den Freiheitsgraden. Die Produkte $c_i u(x_i)$ beschreiben die mit der jeweiligen Sensitivität gewichteten Standardunsicherheiten und haben die Einheit der Ausgangsgröße. Bei unkorrelierten Eingangsgrößen werden ihre Quadrate zur Ausgangsvarianz addiert. Bei korrelierten Eingangsgrößen müssen zusätzlich die Kovarianzbeiträge berücksichtigt und dokumentiert werden. So wird ersichtlich, welche Einflüsse die Ausgangsunsicherheit wesentlich bestimmen.

Für die zusammenfassende Ergebnisangabe bezeichnen wir den aus dem Messmodell berechneten Ausgangsschätzwert mit

$$y = f(\mathbf{x}) \tag{10.105}$$

und seine kombinierte Standardunsicherheit kurz mit $u_\mathrm{c}(y)$.

Sind die zuvor erläuterten Voraussetzungen für die Verwendung des Student-$t$-Quantils und der Welch-Satterthwaite-Näherung erfüllt, wählen wir für $P = 1 - \alpha$ den Erweiterungsfaktor

$$k = t_{1-\alpha/2,\nu_\mathrm{eff}}. \tag{10.106}$$

Mit den effektiven Freiheitsgraden $\nu_\mathrm{eff}$ ergibt sich die erweiterte Messunsicherheit

$$U = k\, u_\mathrm{c}(y) = t_{1-\alpha/2,\nu_\mathrm{eff}}\, u_\mathrm{c}(y). \tag{10.107}$$

Das zugehörige Intervall lautet

$$\boxed{\left[y - t_{1-\alpha/2,\nu_\mathrm{eff}}\, u_\mathrm{c}(y),\quad y + t_{1-\alpha/2,\nu_\mathrm{eff}}\, u_\mathrm{c}(y)\right].} \tag{10.108}$$

Im frequentistischen Beobachtungsmodell ist dies ein näherungsweises Vertrauensintervall zum Vertrauensniveau $1-\alpha$. Die Ergebnisangabe umfasst daher neben $y$ und $U$ auch den verwendeten Erweiterungsfaktor $k$ und das zugehörige Niveau $P$.

Im folgenden Beispiel zur Fraunhoferbeugung stellen wir ein solches Messunsicherheitsbudget auf und führen die Rechnung von den Eingangsgrößen bis zur Ergebnisangabe durch.

## 10.5 Beispiel: Beugung am Spalt im Fernfeld

Wir bestimmen die Spaltbreite aus der Lage eines Minimums im Beugungsbild. Das Beispiel zeigt ein mehrstufiges Messmodell: Zunächst wird aus den Detektordaten die Minimumsposition bestimmt; anschließend wird aus dieser Position die Spaltbreite berechnet.

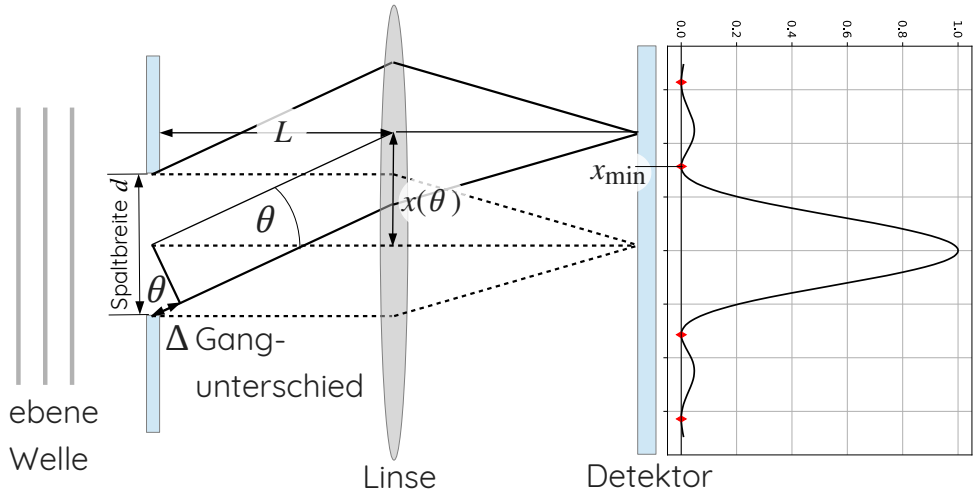



Abbildung 10.3: Schematische Erzeugung eines Fernfeld-Beugungsbildes eines Spalts mit einer Linse. Für die quantitative Auswertung muss die Zuordnung zwischen Beugungswinkel und Detektorposition zum tatsächlichen optischen Aufbau passen. Insbesondere ist der eingezeichnete Abstand zwischen Spalt und Linse nicht allgemein die für diese Zuordnung maßgebliche Länge.

### 10.5.1 Messmodell und Näherungen

Für einen gleichmäßig und senkrecht beleuchteten Spalt der Breite $D$ lautet die Intensitätsverteilung in der Fraunhofer-Näherung

$$I(\theta) = I_0 \left( \frac{\sin \beta}{\beta} \right)^2, \qquad \beta = \frac{\pi D \sin \theta}{\Lambda}. \tag{10.109}$$

$\Lambda$ ist die Wellenlänge. Für $\beta = 0$ wird der stetige Grenzwert $I(0) = I_0$ verwendet. Die Minima liegen bei $D \sin \theta_n = n\Lambda$ mit $n = \pm 1, \pm 2, \ldots$.

Wir betrachten zunächst eine Beobachtungsebene im Fernfeld ohne abbildende Linse. Für ihren Abstand $L$ vom Spalt und die positive Entfernung $X_{\min}$ des ersten Minimums vom Hauptmaximum ist

$$X_{\min} = L \tan \theta_1, \qquad D = \frac{\Lambda}{\sin[\arctan(X_{\min}/L)]} = \frac{\Lambda \sqrt{L^2 + X_{\min}^2}}{X_{\min}}. \tag{10.110}$$

Diese Formel ist innerhalb dieses geometrischen Modells genauer als die Kleinwinkelnäherung

$$D \approx \frac{\Lambda L}{X_{\min}}. \tag{10.111}$$

Für einen Linsenaufbau wie in der Skizze wird das Fernfeld-Beugungsbild in der hinteren Brennebene beobachtet. In der paraxialen Näherung tritt die Brennweite beziehungsweise eine kalibrierte effektive Länge an die Stelle von $L$. Die geometrische Beziehung aus Gl. (10.110) darf auf einen realen Linsenaufbau nur übertragen werden, wenn dessen Winkel-Positions-Zuordnung entsprechend bekannt ist. In dieser Vorlesung geht es nicht darum, ein physikalisch exaktes Messmodell aufzustellen, sondern nur darum, eine Unsicherheitsbetrachtung zu zeigen.

Wir verwenden im folgenden Budget die einfache Modellfunktion aus Gl. (10.111). Die Länge $L$ wird dabei als bekannte geometrische oder passend kalibrierte effektive Länge verstanden. Die Gültigkeit dieser Modellwahl wird anschließend geprüft.

### 10.5.2 Erste Stufe: Minimumsposition aus Detektordaten

Der Detektor liefert Grauwerte $g_j$ an Positionen $x_j$. Nach geeigneter Berücksichtigung von Untergrund und Detektorantwort beschreiben diese die Intensitätsverteilung. Eine lokale quadratische Anpassung um das Minimum,

$$g(x) = a_0 + a_1 x + a_2 x^2, \qquad a_2 > 0, \tag{10.112}$$

liefert die Position $x_v = -a_1/(2a_2)$ des Scheitelpunkts. Die Kovarianz zwischen den Regressionsparametern muss bei der Berechnung von $u(x_v)$ berücksichtigt werden. Falls die Position des Hauptmaximums $x_0$ ebenfalls unsicher ist, geht auch diese Unsicherheit in die Entfernung $x_{\min} = |x_v - x_0|$ ein.

Die Kovarianzmatrix der Fitparameter allein erfasst nicht automatisch Unsicherheiten der Positionsskala, Pixelgeometrie, Detektorantwort oder lokalen Modellwahl. Diese Einflüsse müssen zusätzlich berücksichtigt werden, soweit sie relevant sind. Aus der ersten Stufe erhalten wir den Schätzwert $x_{\min}$ und die zugeordnete Standardunsicherheit $u(x_{\min})$.

Für die zweite Stufe ist die Minimumsentfernung eine *Eingangsgröße*. Sie wird dadurch nicht zu einer unmittelbar beobachteten Größe. Mehrstufenmodelle müssen auch Kovarianzen zwischen den Zwischenergebnissen und weiteren Eingangsgrößen erhalten, wenn gemeinsame Einflüsse bestehen. Alternativ kann das gesamte Beugungsprofil angepasst werden; dabei wären unter anderem die Spaltbreite, der Untergrund und die Lage des Hauptmaximums Modellparameter.

### 10.5.3 Zweite Stufe: Sensitivitäten und Unsicherheitsbudget

Für die Schätzwerte $\lambda$, $L$ und $x_{\min}$ ist $d = \lambda L/x_{\min}$. Die Sensitivitätskoeffizienten sind

$$\begin{aligned} c_L &= \left.\frac{\partial D}{\partial L}\right|_{\mathbf{x}} = \frac{\lambda}{x_{\min}}, \\ c_\lambda &= \left.\frac{\partial D}{\partial \Lambda}\right|_{\mathbf{x}} = \frac{L}{x_{\min}}, \\ c_x &= \left.\frac{\partial D}{\partial X_{\min}}\right|_{\mathbf{x}} = -\frac{\lambda L}{x_{\min}^2}. \end{aligned} \tag{10.113}$$

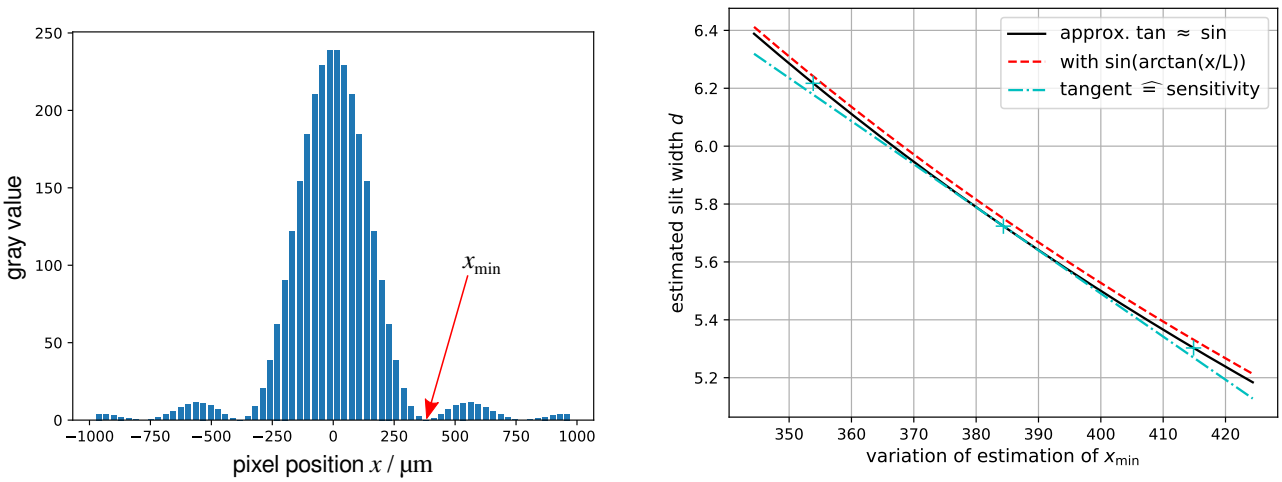



Abbildung 10.4: Links: diskret erfasstes Beugungsprofil mit markiertem erstem Minimum. Rechts: Spaltbreite als Funktion der Minimumsentfernung; Kleinwinkelnäherung, geometrische Beziehung mit $\sin[\arctan(x/L)]$ und lokale Tangente. Die Tangente beschreibt die Sensitivität erster Ordnung.

Das negative Vorzeichen von $c_x$ bedeutet: Eine größere Minimumsentfernung führt zu einer kleineren berechneten Spaltbreite. Bei unkorrelierten Eingangsgrößen wird

$$u_c^2(d) = [c_L u(L)]^2 + [c_\lambda u(\lambda)]^2 + [c_x u(x_{\min})]^2. \tag{10.114}$$

Für korrelierte Eingangsgrößen sind die Mischterme zu ergänzen.

Das folgende *Unsicherheitsbudget* verwendet die Eingangsdaten des Beispiels. Alle Längen werden in Mikrometer angegeben; die Sensitivitätskoeffizienten sind deshalb hier dimensionslos.

| Eingangsgröße | Schätzwert | $u$ | $c_i$ | $\lvert c_i u\rvert$ |
|---|---|---|---|---|
| | µm | µm | | µm |
| $L$ | 4000 | 20 | 0.00142376 | 0.02848 |
| $\Lambda$ | 0.550 | 0.002 | 10.35465 | 0.02071 |
| $X_{\min}$ | 386.3 | 5.9 | −0.01474257 | 0.08698 |

Daraus folgen

$$d = 5.69506\,\mu\text{m}, \qquad u_c(d) = 0.09384\,\mu\text{m}. \tag{10.115}$$

Die Minimumsentfernung liefert etwa 85.9 % der kombinierten Varianz, die Länge $L$ etwa 9.2 % und die Wellenlänge etwa 4.9 %. Dies sind Anteile an der *Varianz*, nicht an der Standardunsicherheit.

Bei der vorgegebenen Wahl $k = 2$ ist $U = 0.18767\,\mu$m. Mit aufgerundeter erweiterter Unsicherheit und passend gerundetem Messwert kann das Ergebnis angegeben werden als

$$d = (5.70 \pm 0.19)\,\mu\text{m}, \qquad k = 2. \tag{10.116}$$

Die Zuordnung zu etwa 95 % setzt eine ausreichend gute Normalapproximation der Ausgangsverteilung beziehungsweise eine passende Begründung des Erweiterungsfaktors voraus. Die Eingangsdaten dieses Budgets allein legen keine genaue Überdeckungswahrscheinlichkeit fest.

### 10.5.4 Zwei verschiedene Näherungen prüfen

Hier werden zwei Näherungen verwendet, die getrennt zu beurteilen sind:

1. Die *Kleinwinkelnäherung* vereinfacht die physikalische Modellfunktion.

2. Die *Linearisierung* vereinfacht die Fortpflanzung der Eingangsunsicherheiten durch diese Modellfunktion.

Für die Kleinwinkelnäherung ist $x_{\min}/L = 0.096575$. Die geometrische Beziehung aus Gl. (10.110) liefert mit denselben Zahlen

$$d_{\text{geom}} = 5.72155\,\mu\text{m}. \tag{10.117}$$

Sie liegt um $0.02650\,\mu$m über dem Ergebnis der Kleinwinkelnäherung. Ob diese Abweichung vernachlässigt werden darf, entscheidet sich anhand der Anforderungen an das Ergebnis. Für die hier betrachtete ebene Beobachtungsebene ist es zweckmäßig, die genauer bekannte geometrische Beziehung direkt zu verwenden, wenn die Abweichung relevant ist.

Für diese Beziehung sind die Sensitivitäten

$$\begin{aligned} c_L &= \frac{\lambda L}{x_{\min}\sqrt{L^2 + x_{\min}^2}}, \\ c_\lambda &= \frac{\sqrt{L^2 + x_{\min}^2}}{x_{\min}}, \\ c_x &= -\frac{\lambda L^2}{x_{\min}^2\sqrt{L^2 + x_{\min}^2}}. \end{aligned} \tag{10.118}$$

Damit ergeben sich in erster Ordnung $u_{\text{c}}(d_{\text{geom}}) = 0.09345\,\mu$m und $U = 0.18689\,\mu$m für $k = 2$. Der Vergleich betrifft das genannte geometrische Modell, nicht die unbekannte Abbildungsfunktion einer realen Linse.

Für die Linearisierung der hyperbolischen Abhängigkeit $D \propto 1/X_{\min}$ ist dagegen das Verhältnis

$$\frac{u(x_{\min})}{x_{\min}} = \frac{5.9}{386.3} \approx 0.0153 \tag{10.119}$$

maßgeblich. Der quadratische Taylorterm der Kehrwertfunktion hat bei einer Abweichung von einer Standardunsicherheit ungefähr 1.5 % der Größe des linearen Terms. Dies ist ein lokaler Hinweis auf geringe Krümmung im betrachteten Bereich; für eine vollständige Prüfung ist auch die zugeordnete Verteilung einschließlich ihrer Randbereiche zu betrachten. Der Pixelabstand allein ist kein Kriterium für die Gültigkeit der Linearisierung.

In Kapitel 11 werden wir die beiden Fortpflanzungsrechnungen mit einer Monte-Carlo-Auswertung vergleichen. Dabei werden wir auch die unterschiedlichen Verteilungen der Eingangsgrößen diskutieren, insbesonderen der Größe $L$, mit einer U-förmigen Verteilung.

## 10.6 Aufgabe zum Selbststudium: Kalibrierung eines Wegaufnehmers

Ein induktiver Wegaufnehmer wandelt die Auslenkung seines Kerns in ein Spannungssignal um. Im relevanten Messbereich sei der Zusammenhang linear. Gemessen werden Spannungsdifferenzen zwischen zwei Höhenlagen; ein konstanter Nullpunkt fällt dabei heraus. Das Bezugsnormal ist eine kalibrierte Stufenhöhe $D$.

Der Kalibrierschein nennt

$$d = (4.997 \pm 0.011)\,\mu\text{m}, \qquad k = 2.1, \quad \nu_d = 26. \tag{10.120}$$

Die Angabe $0.011\,\mu$m ist die erweiterte Unsicherheit. Für die Spannungsdifferenz am Bezugsnormal und am Werkstück wurden die folgenden unabhängigen Wiederholungen unter unveränderten Bedingungen erfasst. Die Spannungen werden mit $V$ bezeichnet, damit keine Verwechslung mit der erweiterten Messunsicherheit $U$ entsteht.

| | | | | | | |
|---|---|---|---|---|---|---|
| Bezugsnormal: $v_{\mathrm{B},j}$/mV | 201.3 | 187.3 | 196.5 | 200.4 | 193.6 | 174.2 |
| Fortsetzung | 197.2 | 185.4 | 194.4 | 202.5 | 205.2 | |
| Werkstück: $v_{\mathrm{W},j}$/mV | 176.5 | 184.1 | 180.5 | 193.6 | 176.0 | 194.5 |
| Fortsetzung | 160.9 | | | | | |

Gesucht ist die konstante Höhe am Werkstück. Ihre Eingangsschätzwerte sind die beiden Mittelwerte $\bar{v}_{\mathrm{B}}$ und $\bar{v}_{\mathrm{W}}$. Das Messmodell lautet

$$D_{\mathrm{W}} = D\frac{V_{\mathrm{W}}}{V_{\mathrm{B}}}, \qquad d_{\mathrm{W}} = d\frac{\bar{v}_{\mathrm{W}}}{\bar{v}_{\mathrm{B}}}. \tag{10.121}$$

Für diese Aufgabe werden die drei Eingangsgrößen als unkorreliert behandelt. Zusätzliche Unsicherheiten aus Drift, Nichtlinearität und Spannungskalibrierung werden hier als vernachlässigbar angenommen. Die lokale Linearisierung und die GUM-$t$-Approximation sollen verwendet werden.

a) Bestimmen Sie aus dem Kalibrierschein die Standardunsicherheit $u(d)$.

b) Berechnen Sie die Mittelwerte $\bar{v}_{\mathrm{B}}$ und $\bar{v}_{\mathrm{W}}$ sowie die empirischen Standardabweichungen $s_{\mathrm{B}}$ und $s_{\mathrm{W}}$. Bestimmen Sie anschließend die Standardunsicherheiten der *Mittelwerte*.

c) Leiten Sie die Sensitivitätskoeffizienten nach $D$, $V_{\mathrm{B}}$ und $V_{\mathrm{W}}$ her und werten Sie sie an den Eingangsschätzwerten aus.

d) Berechnen Sie den Schätzwert $d_{\mathrm{W}}$ und die kombinierte Standardunsicherheit $u_{\mathrm{c}}(d_{\mathrm{W}})$.

e) Bestimmen Sie die effektiven Freiheitsgrade. Verwenden Sie $\nu_d = 26$, $\nu_{\mathrm{B}} = J_{\mathrm{B}} - 1$ und $\nu_{\mathrm{W}} = J_{\mathrm{W}} - 1$.

f) Bestimmen Sie für $P = 0.95 = 95\,\%$ den Erweiterungsfaktor $k = t_{0.975,\nu_{\mathrm{eff}}}$ und die erweiterte Messunsicherheit.

g) Geben Sie das gerundete Messergebnis einschließlich Erweiterungsfaktor und näherungsweiser Überdeckungswahrscheinlichkeit an. Erklären Sie, warum die Verwendung von $s_\mathrm{B}$ und $s_\mathrm{W}$ anstelle der Standardunsicherheiten ihrer Mittelwerte hier nicht der Aufgabenstellung entsprechen würde.

### 10.6.1 Lösungshinweise und Kontrollwerte

Aus dem Kalibrierschein folgt

$$u(d) = \frac{0.011}{2.1}\,\mu\mathrm{m} = 0.0052381\,\mu\mathrm{m}. \tag{10.122}$$

Die Messreihen liefern

| | Bezugsnormal | Werkstück |
|---|---|---|
| Stichprobenumfang $J$ | 11 | 7 |
| Mittelwert $\bar{v}/\mathrm{mV}$ | 194.36364 | 180.87143 |
| Standardabweichung $s/\mathrm{mV}$ | 9.04536 | 11.54711 |
| Standardunsicherheit $u(\bar{v})/\mathrm{mV}$ | 2.72728 | 4.36440 |
| Freiheitsgrade $\nu$ | 10 | 6 |

Die Sensitivitäten sind

$$\begin{aligned} c_d &= \frac{\bar{v}_\mathrm{W}}{\bar{v}_\mathrm{B}} = 0.930583, \\ c_\mathrm{B} &= -\frac{d\bar{v}_\mathrm{W}}{\bar{v}_\mathrm{B}^2} = -0.0239249\,\mu\mathrm{m/mV}, \\ c_\mathrm{W} &= \frac{d}{\bar{v}_\mathrm{B}} = 0.0257095\,\mu\mathrm{m/mV}. \end{aligned} \tag{10.123}$$

Daraus ergeben sich die Beträge der Standardunsicherheitsbeiträge $0.0048745\,\mu$m, $0.0652497\,\mu$m und $0.1122066\,\mu$m sowie

$$\begin{aligned} d_\mathrm{W} &= 4.65012\,\mu\mathrm{m}, \\ u_\mathrm{c}(d_\mathrm{W}) &= 0.129891\,\mu\mathrm{m}, \\ \nu_\mathrm{eff} &= 10.0826, \\ k = t_{0.975,\nu_\mathrm{eff}} &\approx 2.22567, \\ U &\approx 0.28909\,\mu\mathrm{m}. \end{aligned} \tag{10.124}$$

Mit aufgerundeter erweiterter Unsicherheit lautet die Ergebnisangabe

$$d_\mathrm{W} = (4.65 \pm 0.29)\,\mu\mathrm{m}, \qquad k \approx 2.23, \qquad P \approx 95\,\%. \tag{10.125}$$

$s_\mathrm{B}$ und $s_\mathrm{W}$ beschreiben die Streuung einzelner Spannungsbeobachtungen. Die konstante Werkstückhöhe wird hier aus den Mittelwerten bestimmt, weshalb deren Standardunsicherheiten fortgepflanzt werden. Die Unsicherheit des Bezugsnormals wird durch die Wiederholungen nicht verkleinert.

## 10.7 Übergang zu Supplement 1

Die linearisierte Rechnung benötigt Eingangsschätzwerte, Standardunsicherheiten und Kovarianzen. Für ein Überdeckungsintervall kommt eine Annahme über die Ausgangsverteilung hinzu. In Kapitel 11 werden stattdessen die gemeinsamen Eingangsverteilungen durch das Messmodell fortgepflanzt. So lassen sich die Wirkung der Nichtlinearität und die Form der Ausgangsverteilung unmittelbar untersuchen und Intervallgrenzen aus deren Quantilen bestimmen.

Beide Verfahren setzen eine begründete Modellierung der Eingangsgrößen voraus. Bei der Gegenüberstellung ist insbesondere auf dieselben Informationen und auf die Unterscheidung zwischen Standardabweichung und Skalenparameter einer $t$-Verteilung zu achten. Numerische Übereinstimmung ist deshalb bei endlichen Freiheitsgraden nicht allein durch die Verwendung desselben Werts $s/\sqrt{J}$ garantiert.

# Kapitel 11

# Monte-Carlo Methoden für M.U.-Berechnungen

## 11.1 Fortpflanzung durch Kombination der Verteilungen

Im vorherigen Kapitel haben wir die Varianzen und Kovarianzen der Eingangsgrößen mithilfe der Sensitivitätskoeffizienten fortgepflanzt. Bei einem linearen Modell mit festen Koeffizienten ist diese Varianzfortpflanzung exakt. Bei einem nichtlinearen Modell liefert sie eine Näherung, wenn die Taylorentwicklung nach dem linearen Term abgebrochen werden kann. Für die Varianzfortpflanzung eines linearen Modells müssen die Varianzen und Kovarianzen existieren; die vollständige gemeinsame Wahrscheinlichkeitsverteilung muss dafür nicht bekannt sein. Eine Normalverteilung der Eingangsgrößen ist dabei nicht erforderlich. Die Voraussetzungen für eine Intervallangabe mithilfe von Normal- oder Student-$t$-Quantilen sind davon jedoch zu unterscheiden. Vertrauensintervalle lassen sich nicht mehr ermitteln, wenn die Verteilung Ausgangsgröße erkennbar von einer $t$- oder Gaußverteilung abweicht. Werden die Verteilungen jedoch direkt fortgepflanzt, lässt sich aus der kombinierten Wahrscheinlichkeitsdichteverteilung ein Überdeckungsintervall ermitteln. Dann spielt die Art der Verteilungen der Eingangsgrößen keine Rolle mehr.

In dieser Vorlesung wird die *Fortpflanzung von Verteilungen* dargelegt. Aus einer gemeinsamen Wahrscheinlichkeitsverteilung der Eingangsgrößen wird mithilfe des Messmodells die Verteilung der Ausgangsgröße bestimmt. Dieser Ansatz liegt GUM Supplement 1 zugrunde; Supplement 2 erweitert die Betrachtung auf mehrere Ausgangsgrößen. Hier beschränken wir uns zunächst auf eine skalare Ausgangsgröße.

Die Modellfunktion wird dabei in ihrer ursprünglichen Form verwendet. Die Fortpflanzung setzt somit keine Linearisierung voraus und kann unterschiedliche Verteilungsformen berücksichtigen, beispielsweise Normal-, Student-$t$-, Rechteck- oder Arkussinusverteilungen. Voraussetzung ist, dass eine geeignete gemeinsame Eingangsverteilung festgelegt wird und das Modell den Eingangskombinationen in deren relevantem Wertebereich einen eindeutigen Ausgangswert zuordnet. Eine geschlossene analytische Darstellung der Modellfunktion ist dafür nicht notwendig.

### 11.1.1 Gemeinsame Verteilung der Eingangsgrößen

Wir fassen die Eingangsgrößen im Zufallsvektor

$$\mathbf{X} = (X_1, \ldots, X_N)^\mathsf{T} \tag{11.1}$$

zusammen. Ihre gemeinsame Wahrscheinlichkeitsdichte bezeichnen wir mit $p_{\mathbf{X}}(\mathbf{X}')$. Der Vektor $\mathbf{X}' = (X_1', \ldots, X_N')^\mathsf{T}$ enthält mögliche Wertekombinationen der Eingangsgrößen und dient als Integrationsvariable. Er ist vom Vektor $\mathbf{x}$ der festen Eingangsschätzwerte zu unterscheiden. Die Eingangsverteilung beschreibt die Unsicherheit auf Grundlage der für die Auswertung verfügbaren Informationen. Diese können beispielsweise aus Messreihen, Kalibrierscheinen oder begründeten Annahmen über Wertebereiche stammen.

Für kontinuierlich verteilte Größen ist der Wert einer Wahrscheinlichkeitsdichte an einem einzelnen Punkt keine Wahrscheinlichkeit. Die Wahrscheinlichkeit, dass die Eingangswerte in einem Bereich $A$

liegen, erhalten wir durch Integration:

$$\Pr(\mathbf{X} \in A) = \int_A p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}', \qquad \mathrm{d}^N\mathbf{X}' = \mathrm{d}X_1' \cdots \mathrm{d}X_N'. \tag{11.2}$$

Das Integral addiert die Wahrscheinlichkeitsbeiträge aus allen Teilen dieses Bereichs.

Die Menge der reellen Zahlen wird mit $\mathbb{R}$ bezeichnet. Entsprechend ist $\mathbb{R}^N$ die Menge aller Vektoren mit $N$ reellen Komponenten. Sie umfasst damit alle reellen Wertekombinationen der $N$ Eingangsgrößen. Der physikalisch zulässige Wertebereich kann jedoch auf eine Teilmenge davon beschränkt sein. Außerhalb dieses zulässigen Bereichs ist die Dichte null.

Über den gesamten Raum $\mathbb{R}^N$ gilt die Normierung

$$\int_{\mathbb{R}^N} p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}' = 1. \tag{11.3}$$

Die Wahrscheinlichkeit, dass die Eingangsgrößen irgendeine der zulässigen Wertekombinationen annehmen, beträgt somit eins.

Sind die Eingangsgrößen statistisch unabhängig, zerfällt die gemeinsame Dichte in das Produkt der Einzeldichten:

$$p_{\mathbf{X}}(\mathbf{X}') = \prod_{i=1}^{N} p_{X_i}(X_i'). \tag{11.4}$$

Unkorreliertheit allein genügt hierfür nicht. Bei Abhängigkeiten muss die gemeinsame Verteilung diese berücksichtigen; die Kenntnis der Einzeldichten reicht dann im Allgemeinen nicht aus. Die gemeinsame Verteilung ist für abhängige wie für unabhängige Eingangsgrößen definiert. Nur die Produktdarstellung setzt Unabhängigkeit voraus.

### 11.1.2 Vom Eingangsbereich zum Ausgangsintervall

Das Messmodell sei

$$Y = f(\mathbf{X}). \tag{11.5}$$

Jede mögliche Eingangskombination $\mathbf{X}'$ wird durch das Modell auf den Ausgangswert $f(\mathbf{X}')$ abgebildet. Verschiedene Eingangskombinationen können dabei denselben Ausgangswert ergeben.

Wir fragen zunächst nach der Wahrscheinlichkeit, dass die Ausgangsgröße in einem Intervall $[a, b]$ liegt. Dazu betrachten wir alle Eingangskombinationen, deren Modellwerte in dieses Intervall fallen. Sie bilden den Bereich

$$A_{[a,b]} = \big\{\mathbf{X}' \in \mathbb{R}^N : a \le f(\mathbf{X}') \le b\big\}. \tag{11.6}$$

Die gesuchte Wahrscheinlichkeit ist die gesamte Eingangswahrscheinlichkeit in diesem Bereich:

$$\boxed{\Pr(a \le Y \le b) = \int_{A_{[a,b]}} p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}'.} \tag{11.7}$$

Die Wahrscheinlichkeiten werden also mithilfe des Modells den entsprechenden Ausgangswerten zu-

geordnet und dort zusammengefasst. Die Ausgangsverteilung ist deshalb nicht die gemeinsame Eingangsverteilung selbst, sondern die durch das Modell daraus entstehende Verteilung.

Entsprechend erhalten wir die Verteilungsfunktion, die kumulative Wahrscheinlichkeitsverteilung, der Ausgangsgröße:

$$P_Y(z) = \Pr(Y \le z) = \int\limits_{\{\mathbf{X}' : f(\mathbf{X}') \le z\}} p_{\mathbf{X}}(\mathbf{X}') \, \mathrm{d}^N\mathbf{X}'. \tag{11.8}$$

Diese Beziehung beschreibt die Verteilungsfortpflanzung, ohne bereits ein Verfahren zur Berechnung des Integrals festzulegen.

Ein Integral über einen vorgegebenen Bereich $A$ lässt sich auch als Integral über den gesamten Raum schreiben. Dazu multiplizieren wir den Integranden mit einer *Indikatorfunktion*, die als Fensterfunktion wirkt:

$$w_A(\mathbf{X}') = \begin{cases} 1 & \text{falls } \mathbf{X}' \in A, \\ 0 & \text{sonst.} \end{cases} \tag{11.9}$$

Damit gilt

$$\int\limits_A p_{\mathbf{X}}(\mathbf{X}') \, \mathrm{d}^N\mathbf{X}' = \int\limits_{\mathbb{R}^N} w_A(\mathbf{X}') \, p_{\mathbf{X}}(\mathbf{X}') \, \mathrm{d}^N\mathbf{X}'. \tag{11.10}$$

Die Fensterfunktion lässt die Beiträge innerhalb von $A$ unverändert und setzt alle Beiträge außerhalb von $A$ auf null. Der Bereich $A$ muss dabei nicht beschränkt sein.

Für die kumulative Verteilungsfunktion $P_Y(z) = \Pr(Y \le z)$ sollen genau die Eingangskombinationen berücksichtigt werden, für die $f(\mathbf{X}') \le z$ gilt. Das zugehörige Fenster lässt sich mithilfe der *Heaviside-Sprungfunktion*

$$H(u) = \begin{cases} 0 & \text{für } u < 0, \\ 1 & \text{für } u \ge 0 \end{cases} \tag{11.11}$$

darstellen. Denn $H(z - f(\mathbf{X}'))$ ist genau dann eins, wenn der Modellwert höchstens $z$ beträgt. Damit erhalten wir

$$P_Y(z) = \int\limits_{\mathbb{R}^N} H\big(z - f(\mathbf{X}')\big) \; p_{\mathbf{X}}(\mathbf{X}') \, \mathrm{d}^N\mathbf{X}'. \tag{11.12}$$

Dies ist dieselbe Verteilungsfunktion wie in Gl. (11.8) – lediglich die Darstellung des Integrationsbereichs wurde geändert.

Nun gehen wir von der kumulativen Verteilungsfunktion zur *Wahrscheinlichkeitsdichte* der Ausgangsgröße über. Besitzt die Ausgangsverteilung eine Dichte, erhalten wir diese durch Ableiten der Verteilungsfunktion, wobei die Beziehung im Allgemeinen fast überall gilt:

$$p_Y(Y') = \left. \frac{\mathrm{d}P_Y(z)}{\mathrm{d}z} \right|_{z=Y'}. \tag{11.13}$$

Die Ableitung der Heaviside-Sprungfunktion ist im Sinne der mathematischen Distributionen die *Dirac-Deltafunktion*:

$$\frac{\mathrm{d}H(u)}{\mathrm{d}u} = \delta(u). \tag{11.14}$$

Formales Ableiten der Integraldarstellung von $P_Y$ führt deshalb zu

$$p_Y(Y') = \int_{\mathbb{R}^N} \delta\big(Y' - f(\mathbf{X}')\big)\; p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}'. \tag{11.15}$$

Die Deltafunktion ersetzt hier also nicht unmittelbar die Fensterfunktion eines endlichen Ausgangsintervalls. Sie tritt beim Übergang von der kumulierten Wahrscheinlichkeit zur Wahrscheinlichkeitsdichte der Ausgangsgröße auf.

Die Dirac-Deltafunktion ist keine gewöhnliche Funktion, sondern eine *Distribution* im mathematischen Sinn. Die verschobene Deltafunktion $\delta(Y' - v)$ konzentriert ihr gesamtes Gewicht eins auf die Stelle $Y' = v$. Wird sie unter einem Integral mit einer geeigneten stetigen Funktion $\varphi$ multipliziert, liefert das Integral genau deren Funktionswert an dieser Stelle:

$$\int_{-\infty}^{\infty} \varphi(Y')\,\delta(Y' - v)\,\mathrm{d}Y' = \varphi(v). \tag{11.16}$$

Diese Wirkung wird als *Auswahleigenschaft* bezeichnet: Das Integral wählt aus der Funktion $\varphi$ den Wert $\varphi(v)$ aus.

Insbesondere gilt die Normierung

$$\int_{-\infty}^{\infty} \delta(Y' - v)\,\mathrm{d}Y' = 1. \tag{11.17}$$

Sie beschreibt somit eine auf den Wert $v$ konzentrierte Wahrscheinlichkeit mit Gesamtgewicht eins.

Bei einer festgehaltenen Kombination von Werten der Eingangsgrößen $\mathbf{X}' = (X_1', \ldots, X_N')^{\mathsf{T}}$ legt das Messmodell den zugehörigen Ausgangswert $f(\mathbf{X}')$ eindeutig fest. Die bedingte Verteilung von $Y$ ist dann auf $f(\mathbf{X}')$ konzentriert. Formal schreiben wir

$$p_{Y|\mathbf{X}}(Y' \mid \mathbf{X}') = \delta\big(Y' - f(\mathbf{X}')\big)\,. \tag{11.18}$$

Die Deltafunktion drückt hier aus, dass bei festgehaltenen Eingangsgrößen im Modell keine weitere zufällige Variation der Ausgangsgröße vorgesehen ist. Sie belegt nicht, dass das physikalische Messmodell vollständig ist. Relevante verbleibende Einflüsse müssen in der Modellierung berücksichtigt werden.

Die Wahrscheinlichkeitsdichte der Ausgangsgröße entsteht, indem diese bedingten Verteilungen mit der gemeinsamen Eingangsdichte gewichtet und über alle Eingangskombinationen[1] integriert werden:

$$\begin{aligned} p_Y(Y') &= \int_{\mathbb{R}^N} p_{Y|\mathbf{X}}(Y' \mid \mathbf{X}')\, p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}' \\ &= \int_{\mathbb{R}^N} \delta\big(Y' - f(\mathbf{X}')\big)\; p_{\mathbf{X}}(\mathbf{X}')\,\mathrm{d}^N\mathbf{X}'. \end{aligned} \tag{11.19}$$

Dies ist die in GUM Supplement 1, Abschnitt 5.2, angegebene formale Darstellung der Verteilungsfortpflanzung. $Y'$ ist hier der festgehaltene Ausgangswert, für den die Dichte berechnet wird; integriert wird über die möglichen Eingangswerte. Bei unabhängigen Eingangsgrößen nimmt das Integral die

[1] Kombinationen von Werten der Eingangsgrößen

Form

$$p_Y(Y') = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \delta\big(Y' - f(X'_1, \ldots, X'_N)\big) \prod_{i=1}^{N} p_{X_i}(X'_i)\,\mathrm{d}X'_1 \cdots \mathrm{d}X'_N \tag{11.20}$$

an. Wird $p_Y$ anschließend über ein gewähltes Intervall $[a, b]$ von Werten der Ausgangsgröße integriert, liefert die Deltafunktion für eine festgehaltene Kombination der Eingangswerte genau dann einen Beitrag, wenn der zugehörige Modellwert $f(\mathbf{X}')$ in diesem Intervall liegt. Damit ergibt sich wieder Gl. (11.7).

Für ein implizites Modell $h(Y, \mathbf{X}) = 0$ ist zunächst festzulegen, welche eindeutig bestimmte Lösung $Y$ zu einer Eingangskombination gehört. Diese Zuordnung übernimmt dann die Rolle von $f$.

Dies soll nun anhand eines einfachen Beispiels illustriert werden, dazu betrachten wir die Summe zweier Größen.

Für zwei unabhängige Eingangsgrößen und das Modell

$$Y = X_1 + X_2 \tag{11.21}$$

lautet das Integral aus Gl. (11.20)

$$p_Y(Y') = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \delta(Y' - X'_1 - X'_2)\, p_{X_1}(X'_1) p_{X_2}(X'_2)\,\mathrm{d}X'_2\,\mathrm{d}X'_1. \tag{11.22}$$

Zu einem festgehaltenen Ausgangswert $Y'$ tragen diejenigen Eingangskombinationen bei, für die $X'_2 = Y' - X'_1$ gilt. Die Auswahleigenschaft der Deltafunktion führt deshalb zu

$$p_Y(Y') = \int_{-\infty}^{\infty} p_{X_1}(X'_1)\, p_{X_2}(Y' - X'_1)\,\mathrm{d}X'_1. \tag{11.23}$$

Dieses Integral heißt *Faltung* der beiden Eingangsverteilungen. Es fasst die Beiträge aller Wertepaare zusammen, deren Summe $Y'$ ergibt. Die Faltung ist damit ein Spezialfall der Verteilungsfortpflanzung für ein additives Modell.

### 11.1.3 Anwendung auf die Spaltbreitenmessung

Wir betrachten erneut das Anschauungsbeispiel *Beugung am Spalt im Fernfeld* aus Abschnitt 10.5. In der Kleinwinkelnäherung lautet die Modellbeziehung

$$D = \frac{\Lambda L}{X_{\min}}. \tag{11.24}$$

Hier bezeichnet $D$ die gesuchte Spaltbreite, $\Lambda$ die Wellenlänge und $X_{\min}$ den positiven Abstand des ersten Intensitätsminimums von der Beugungsmitte. $L$ ist die im Messmodell verwendete geometrische oder passend kalibrierte effektive Länge. Die Großbuchstaben kennzeichnen die Größen im Wahrscheinlichkeitsmodell; $d$, $\lambda$ und $x_{\min}$ sind die zugehörigen Schätzwerte.

Für die gemeinsame Eingangsverteilung schreiben wir $p_{\Lambda,L,X_{\min}}(\lambda', \ell', q')$. Die Variablen $\lambda'$, $\ell'$ und $q'$

laufen über mögliche Werte der drei Eingangsgrößen. Damit lautet die Ausgangsdichte

$$p_D(D') = \iiint \delta\left(D' - \frac{\lambda'\ell'}{q'}\right) p_{\Lambda,L,X_{\min}}(\lambda', \ell', q')\,\mathrm{d}\lambda'\,\mathrm{d}\ell'\,\mathrm{d}q'. \tag{11.25}$$

Die Integration erstreckt sich über den Eingangsbereich, auf dem die Modellbeziehung definiert ist. Insbesondere wird vorausgesetzt, dass $q'$ im betrachteten Bereich positiv ist. Sind die drei Eingangsgrößen statistisch unabhängig, lässt sich ihre gemeinsame Wahrscheinlichkeitsdichte faktorisieren:

$$p_{\Lambda,L,X_{\min}}(\lambda', \ell', q') = p_\Lambda(\lambda')\, p_L(\ell')\, p_{X_{\min}}(q'). \tag{11.26}$$

Die Zuordnung konkreter Verteilungen muss sich auf die verfügbaren Informationen über diese Eingangsgrößen stützen.

Für ein Spaltbreitenintervall $[d_a, d_b]$ müssen wir beispielsweise alle Eingangskombinationen berücksichtigen, für die

$$d_a \le \frac{\lambda'\ell'}{q'} \le d_b \tag{11.27}$$

gilt. Die gemeinsame Eingangsdichte wird über genau diesen Bereich integriert. So lässt sich die Bedeutung des Integrals auch ohne Verwendung der Deltafunktion beschreiben.

**Schätzwert, Standardunsicherheit und Überdeckungsintervall aus der Ausgangsverteilung ermitteln:** Aus der Wahrscheinlichkeitsdichteverteilung der indirekten Messgröße (Ausgangsgröße) bestimmen wir, sofern die entsprechenden Momente existieren, den Schätzwert und die Standardunsicherheit:

$$y = \mathrm{E}(Y) = \int_{-\infty}^{\infty} Y'\, p_Y(Y')\,\mathrm{d}Y', \qquad u^2(y) = \int_{-\infty}^{\infty} (Y' - y)^2 p_Y(Y')\,\mathrm{d}Y'. \tag{11.28}$$

Die Standardunsicherheit $u(y)$ ist die positive Wurzel dieser Varianz. Bei einem nichtlinearen Modell muss der Erwartungswert $\mathrm{E}[f(\mathbf{X})]$ nicht mit $f(\mathbf{x})$ übereinstimmen. Die Verteilungsfortpflanzung berücksichtigt die Modellbeziehung, ohne sie durch ihre Tangente am Entwicklungspunkt zu ersetzen.

Ein Intervall mit gleichen Wahrscheinlichkeiten in den beiden äußeren Bereichen erhalten wir für $P = 1 - \alpha$ aus den Quantilen:

$$[y_{\mathrm{low}}, y_{\mathrm{high}}] = \left[P_Y^{-1}(\alpha/2),\, P_Y^{-1}(1 - \alpha/2)\right]. \tag{11.29}$$

Die Grenzen werden hier unmittelbar aus der Ausgangsverteilung bestimmt. Ein Normal- oder Student-$t$-Erweiterungsfaktor wird dafür nicht vorausgesetzt.

Bis hierher ist festgelegt, welche Wahrscheinlichkeiten und Kenngrößen zu berechnen sind. Wie die Integrale ausgewertet werden, ist noch offen. Im nächsten Abschnitt veranschaulichen wir die Integration in Gleichung (11.20) zunächst durch eine grobe Einteilung in Klassen und das Summieren der zugehörigen Wahrscheinlichkeitsbeiträge. Im daran anschließenden Abschnitt behandeln wir die Monte-Carlo-Methode zur Realisierung der Integration.

In beiden Abschnitten verwenden wir das Beispiel mit der Beugung am Spalt in der Fraunhofer- und

Kleinwinkelapproximation, für das wir folgende Werte und Modelle der Wahrscheinlichkeitsverteilungen der Eingangsgrößen ansetzen:

Die Wellenlänge der nicht ideal monochromatischen, ebenen Welle, deren Abweichung als Gaußspektrum modelliert wird, ist

$$\lambda_0 = 0.550\,\mu\text{m} \quad \sigma_{\lambda,\text{spec}} = 0.0014\,\mu\text{m}.$$

Für die Verteilung der Wellenlänge wird die Beleuchtung als Gauß'sches Spektrum, das eine Funktion der Wellenzahl ist, modelliert

$$S(k) = \frac{1}{2\sqrt{\pi}\,\sigma_k}\, e^{-\left(\frac{k-k_0}{2\sigma_k}\right)^2}$$

wobei $k$ die Wellenzahl ist mit $k = \frac{2\pi}{\lambda}$, das Maximum der spektralen Verteilung $k_0 = \frac{2\pi}{\lambda_0}$ ist und die Bandbreite $\sigma_k = \frac{2\pi}{\lambda_0}\sigma_{\lambda,\text{spec}}$ Wenn man für die Wellenzahlen die Wellenlängen einsetzt, wir dies zu

$$S(\lambda) = \frac{\lambda_0^2}{4\sqrt{\pi}^3\sigma_{\lambda,\text{spec}}}\, e^{-\left(\frac{(\lambda_0-\lambda)\lambda_0}{2\lambda\,\sigma_{\lambda,\text{spec}}}\right)^2}$$

Wenn wir unser Zahlenbeispiel $\lambda_0 = 0.5500\,\mu\text{m}$ und $\sigma_{\lambda,\text{spec}} = 0.0014\,\mu\text{m}$ einsetzen und dann eine einfache Gaußglocke an das Spektrum anpassen, bekommen wir die Näherungsgleichung

$$S(\lambda) \approx a\, e^{-\frac{1}{2}\left(\frac{(\lambda_0-\lambda)}{\sigma_{\lambda,\text{g}}}\right)^2} \tag{11.30}$$

mit $\sigma_{\lambda,\text{g}} = 0.002\,\mu\text{m}$.

Der Abstand des ersten Beugungsminimums vom Hauptmaximum wird mit einer gaußverteilten Streuung angesetzt mit den Werten

$$x_{\text{min},0} = 386.3\,\mu\text{m}, \quad \sigma_{\text{xmin}} = 5.9\,\mu\text{m}$$

Der Abstand zwischen Spalt (Messobjekt) und Objektiv ist $L$. Die Unsicherheit dieses Abstands soll in unserem Modell durch störende Vibrationen verursacht werden, so dass $L$ sinusförmig mit einer Amplitude $a_L$ variiert

$$L_0 = 4000\,\mu\text{m}, \quad a_L = 20\,\mu\text{m}.$$

## 11.2 Integration der Wahrscheinlichkeitsdichte mittels Klassierung

Wir nähern das Integral Gl. Gleichung (11.20) durch eine endliche Summe an: Dazu teilen wir die Wertebereiche der Eingangsgrößen in Klassen ein, ordnen jeder Klasse ihre Wahrscheinlichkeit zu und verwenden für jede Klasse einen repräsentativen Wert. Anschließend berechnen wir die Modellwerte für alle Kombinationen dieser Repräsentanten und fassen deren Wahrscheinlichkeitsbeiträge zusammen.

Wir betrachten weiterhin das Messmodell der Spaltbreitenmessung in der Kleinwinkelnäherung:

$$D = \frac{\Lambda L}{X_{\text{min}}}. \tag{11.31}$$

Dabei bezeichnet $D$ die Spaltbreite, $\Lambda$ die Wellenlänge, $L$ die im Modell verwendete geometrische oder kalibrierte effektive Länge und $X_{\min}$ den positiven Abstand des ersten Intensitätsminimums von der Beugungsmitte. Die Kleinwinkelnäherung verwendet $\sin\theta \approx \tan\theta \approx \theta$ für kleine Winkel $\theta$ im Bogenmaß. Für das folgende Beispiel werden die drei Eingangsgrößen als statistisch unabhängig angenommen.

**Klassenwahrscheinlichkeiten und Repräsentanten:** Für eine Eingangsgröße $X_i$ mit Verteilungsfunktion $P_i$ bilden die Grenzen $b_{i,0}, \ldots, b_{i,K_i}$ die Klassen. Die Wahrscheinlichkeit der $k$-ten Klasse ist

$$w_{i,k} = \Pr(b_{i,k-1} < X_i \le b_{i,k}) = P_i(b_{i,k}) - P_i(b_{i,k-1}). \tag{11.32}$$

Diese Wahrscheinlichkeit ist dimensionslos. Sie ist vom Wert der Wahrscheinlichkeitsdichte an einem einzelnen Punkt zu unterscheiden. Aus der Dichte könnte sie auch durch Integration über die Klasse bestimmt werden. Die Näherung

$$w_{i,k} \approx p_{X_i}(x'_{i,k})\,(b_{i,k} - b_{i,k-1}) \tag{11.33}$$

mit einem Repräsentanten $x'_{i,k}$ ist nur für eine endliche Klassenbreite sinnvoll und setzt voraus, dass die Dichte innerhalb dieser Klasse ausreichend gut durch diesen Dichtewert beschrieben wird. Wenn die Verteilungsfunktion verfügbar ist, können wir die Klassenwahrscheinlichkeit stattdessen unmittelbar als Differenz nach Gl. (11.32) bestimmen.

Hier wählen wir *gleich wahrscheinliche Klassen*. Wir unterteilen dazu die Wahrscheinlichkeitsachse $[0, 1]$ in $K_i$ gleich große Intervalle mit Grenzen

$$r_{i,k} = \frac{k}{K_i}, \qquad k = 0, \ldots, K_i. \tag{11.34}$$

Die zugehörigen Grenzen im Wertebereich erhalten wir aus der Quantilfunktion, also der inversen Verteilungsfunktion:

$$b_{i,k} = P_i^{-1}(r_{i,k}), \qquad w_{i,k} = \frac{1}{K_i}. \tag{11.35}$$

Die Klassen sind damit gleich wahrscheinlich, haben im Allgemeinen aber unterschiedliche Breiten im Wertebereich. Wo die Dichte groß ist, genügen schmale Klassen; wo sie klein ist, werden die Klassen breiter.

Als Repräsentanten verwenden wir die Quantile in der Mitte der jeweiligen Wahrscheinlichkeitsintervalle:

$$x'_{i,k} = P_i^{-1}\left(\frac{k - \frac{1}{2}}{K_i}\right), \qquad k = 1, \ldots, K_i. \tag{11.36}$$

Diese Werte liegen im Allgemeinen nicht in der arithmetischen Mitte der Klassen im Wertebereich. Sie dienen der numerischen Integration. Für eine unbeschränkte Verteilung können die äußeren Klassengrenzen unendlich sein. Die Repräsentanten werden jedoch nur für Wahrscheinlichkeiten strikt zwischen null und eins berechnet und sind bei den hier verwendeten Verteilungen endlich. Die gesamte Wahrscheinlichkeit wird berücksichtigt; die Verteilung wird nicht an einem willkürlich gewählten Rand abgeschnitten. Die Darstellung einer ganzen Klasse durch einen einzigen Wert bleibt allerdings eine Näherung, insbesondere in den Ausläufern.

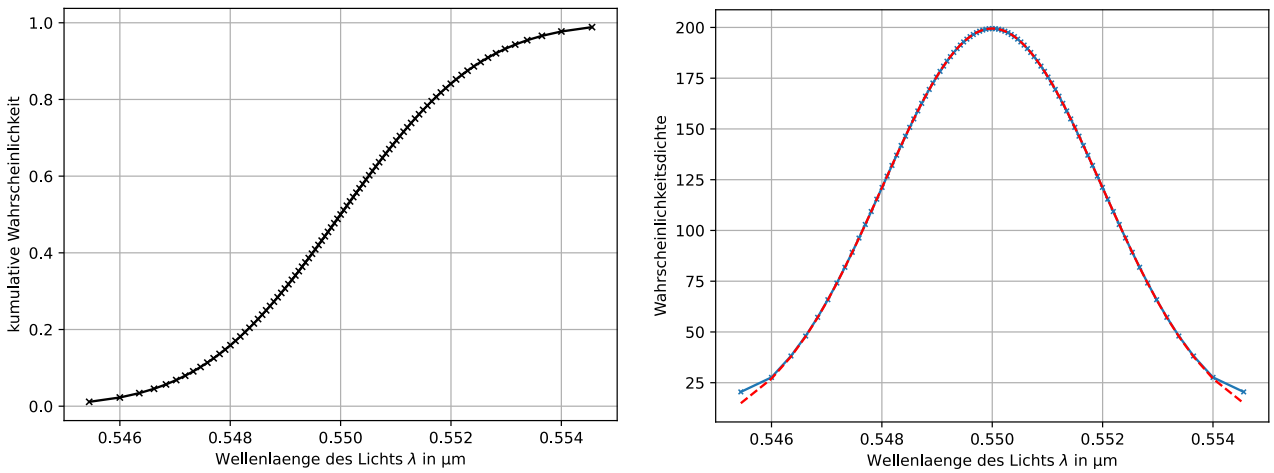



Abbildung 11.1: Klassierung der Wellenlänge. Links: Verteilungsfunktion mit Stützstellen in gleich großen Wahrscheinlichkeitsschritten. Rechts: Analytische Normaldichte (rot gestrichelt) und ihre numerische Näherung durch Differenzenquotienten der Verteilungsfunktion (blau mit Kreuzen).

Für eine Funktion $g$ ergibt sich so die Integrationsregel

$$\int_{-\infty}^{\infty} g(X_i')\, p_{X_i}(X_i')\, \mathrm{d}X_i' \approx \sum_{k=1}^{K_i} w_{i,k}\, g(x_{i,k}'). \tag{11.37}$$

Hier werden feste Repräsentanten systematisch verwendet. Es werden keine Zufallszahlen gezogen.

**Anwendung der Klassierung der drei Eingangsverteilungen unseres Beispiels:** Für die Wellenlänge verwenden wir in diesem Beispiel die das Spektrum approximierende Normalverteilung aus Gl. (11.30), mit den oben angegebenen Werten

$$\lambda_0 = 0.5500\,\mu\mathrm{m}, \qquad \sigma_{\lambda,\mathrm{g}} = 0.0020\,\mu\mathrm{m}.$$

Ihre Verteilungsfunktion und deren Umkehrfunktion lauten

$$\begin{aligned} P_\Lambda(\lambda') &= \frac{1}{2}\left[1 + \mathrm{erf}\left(\frac{\lambda' - \lambda_0}{\sqrt{2}\,\sigma_{\lambda,\mathrm{g}}}\right)\right], \\ P_\Lambda^{-1}(r) &= \lambda_0 + \sqrt{2}\,\sigma_{\lambda,\mathrm{g}}\ \mathrm{erf}^{-1}(2r-1), \qquad 0 < r < 1. \end{aligned} \tag{11.38}$$

Dabei ist erf die Fehlerfunktion und $\mathrm{erf}^{-1}$ ihre Umkehrfunktion. Mit $K_\Lambda$ Klassen erhalten wir die Repräsentanten

$$\lambda_j = P_\Lambda^{-1}\left(\frac{j - \frac{1}{2}}{K_\Lambda}\right), \qquad j = 1, \ldots, K_\Lambda. \tag{11.39}$$

In gleicher Weise wird die Umkehrfunktion, Gl. (11.39), für den Abstand des Beugungsminimums vom Hauptmaximum verwendet mit den zuvor genannten Werten

$$x_{\mathrm{min},0} = 386.3\,\mu\mathrm{m}, \quad \sigma_{\mathrm{xmin}} = 5.9\,\mu\mathrm{m}$$

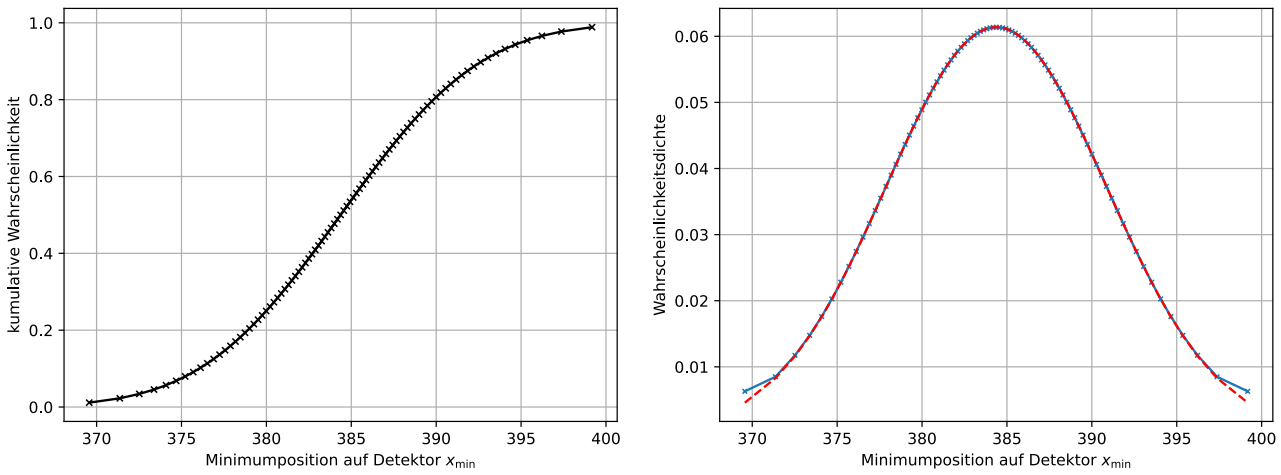



Abbildung 11.2: Klassierung der Minimumsposition. Links: Verteilungsfunktion mit Stützstellen in gleich großen Wahrscheinlichkeitsschritten. Rechts: Analytische Normaldichte (rot gestrichelt) und ihre numerische Näherung durch Differenzenquotienten (blau mit Kreuzen). Die dargestellte Verteilung ist die für die Eingangsgröße $X_{\min}$ verwendete Unsicherheitsbeschreibung.

Die beiden Abbildungen 11.1 und 11.2 veranschaulichen die Normalerteilung und die Einteilung entlang der Wahrscheinlichkeitsachse.

Für die vibrationsbedingte Variation von $L$ verwenden wir eine Arkussinusverteilung im Intervall $[L_0 - a_L, L_0 + a_L]$ mit

$$L_0 = 4000\,\mu\text{m}, \qquad a_L = 20\,\mu\text{m}. \tag{11.40}$$

Diese Verteilung entsteht bei einer sinusförmigen Variation mit gleichverteilter Phase. Ihre Quantilfunktion lautet

$$P_L^{-1}(r) = L_0 - a_L \cos(\pi r), \qquad 0 \le r \le 1. \tag{11.41}$$

Die Repräsentanten sind somit

$$\ell_k = L_0 - a_L \cos\left(\pi \frac{k - \frac{1}{2}}{K_L}\right), \qquad k = 1, \ldots, K_L. \tag{11.42}$$

Die hohe Dichte in der Nähe der beiden Intervallgrenzen führt dort zu besonders schmalen Klassen, siehe Abb. 11.3.

Die Repräsentanten $q_l$ für $X_{\min}$ bestimmen wir entsprechend aus der zugeordneten Verteilungsfunktion:

$$q_l = P_{X_{\min}}^{-1}\left(\frac{l - \frac{1}{2}}{K_x}\right), \qquad l = 1, \ldots, K_x. \tag{11.43}$$

In der vorhandenen Darstellung wird hierfür eine Normalverteilung verwendet, siehe Abb. 11.2. Ihre Parameter müssen aus der Unsicherheitsbeschreibung der Minimumsposition stammen. Es ist insbesondere zu unterscheiden, ob die Streuung einzelner Positionsbestimmungen oder die Unsicherheit einer daraus geschätzten Position in das Modell eingeht. Im relevanten Wertebereich muss $X_{\min}$ positiv und ausreichend von null entfernt sein. Falls eine unbeschränkte Normalverteilung diese physikalische Bedingung nicht angemessen beschreibt, ist eine geeignete Verteilung mit positivem Wertebereich zu verwenden.

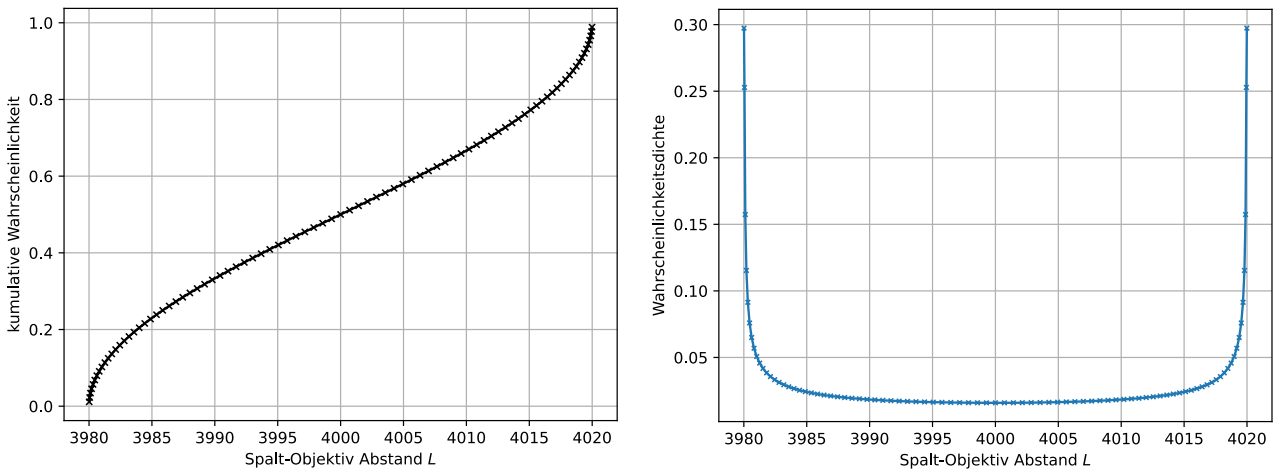



Abbildung 11.3: Klassierung der vibrationsbedingten Abstandsvariation. Links: Verteilungsfunktion der Arkussinusverteilung mit Stützstellen in gleich großen Wahrscheinlichkeitsschritten. Rechts: Numerisch angenäherte Dichte. Die Dichte ist an den Rändern besonders groß; die exakte Arkussinusdichte wird dort unbeschränkt, bleibt aber integrierbar. Die endlichen Werte der gezeichneten Näherung hängen von der Klassierung ab.

**Kombination der Eingangsklassen und Ausgangsklassierung:** Wir kombinieren jeden Wellenlängenrepräsentanten $\lambda_j$ mit jedem Längenrepräsentanten $\ell_k$ und jeder Minimumsposition $q_l$. Für jede Kombination berechnen wir

$$d_{jkl} = \frac{\lambda_j \ell_k}{q_l}. \tag{11.44}$$

Wegen der angenommenen Unabhängigkeit ist die Wahrscheinlichkeit der zugehörigen Kombination von Eingangsklassen

$$w_{jkl} = w_{\Lambda,j}\, w_{L,k}\, w_{x,l}. \tag{11.45}$$

Bei gleich wahrscheinlichen Klassen folgt

$$w_{jkl} = \frac{1}{K_\Lambda K_L K_x}. \tag{11.46}$$

Die Größen $w_{jkl}$ sind die Wahrscheinlichkeiten der Eingangsklassen, deren Beiträge durch die Modellwerte $d_{jkl}$ repräsentiert werden. Bei abhängigen Eingangsgrößen dürften diese Gewichte nicht als Produkt gebildet werden; sie müssten aus der gemeinsamen Eingangsverteilung bestimmt werden.

Für die Darstellung der Ausgangsverteilung, also der Verteilung der Spaltbreiten $D$, wählen wir zusätzlich Klassen $I_\nu = [d_{\nu-1}, d_\nu)$ mit Breiten $\Delta d_\nu = d_\nu - d_{\nu-1}$. Die letzte Klasse schließt ihre rechte Grenze ein. Die Fensterfunktion

$$W_\nu(D') = \begin{cases} 1 & \text{falls } D' \in I_\nu, \\ 0 & \text{sonst} \end{cases} \tag{11.47}$$

wählt die Modellwerte innerhalb der jeweiligen Klasse der Ausgangsgröße Spaltbreite aus. Die Verbindung zur Dirac-Darstellung ist

$$\int_{I_\nu} \delta(D' - f(\mathbf{X}'))\, \mathrm{d}D' = W_\nu(f(\mathbf{X}')), \tag{11.48}$$

wobei die Zuordnung von Werten genau auf einer Klassengrenze einheitlich festgelegt wird. Für eine stetige Ausgangsverteilung ändert diese Randkonvention die Klassenwahrscheinlichkeit nicht.

Wir nähern also zunächst die *Wahrscheinlichkeit einer Ausgangsklasse* an, indem wir die Gewichte aller zugehörigen Modellwerte addieren:

$$\boxed{\pi_\nu = \sum_{j=1}^{K_\Lambda} \sum_{k=1}^{K_L} \sum_{l=1}^{K_x} W_\nu(d_{jkl})\, w_{jkl}.} \tag{11.49}$$

Hier und im Folgenden bezeichnet $\pi_\nu$ den durch die Summe berechneten Näherungswert für $\Pr(D \in I_\nu)$. Die Ausgangsklassen werden so gewählt, dass sie alle berechneten Modellwerte enthalten. Dann gilt bis auf Rundungsabweichungen

$$\sum_\nu \pi_\nu = \sum_{j,k,l} w_{jkl} = 1. \tag{11.50}$$

Die Klassenwahrscheinlichkeit $\pi_\nu$ ist noch kein Dichtewert. Eine innerhalb der Klasse konstante Dichte erhalten wir durch Division durch die Klassenbreite:

$$p_D(D') \approx \frac{\pi_\nu}{\Delta d_\nu} \qquad \text{für } D' \in I_\nu. \tag{11.51}$$

Die Höhe dieses Rechtecks ist ein Dichtewert, seine Fläche ist die Klassenwahrscheinlichkeit. Bei Angabe der Spaltbreite in $\mu$m hat die Dichte die Einheit $\mu\mathrm{m}^{-1}$.

**Schätzwert, Standardunsicherheit und Intervallgrenzen:** Den Erwartungswert und die Varianz nähern wir unmittelbar aus den gewichteten Modellwerten an:

$$\widehat{d} = \sum_{j,k,l} w_{jkl}\, d_{jkl}, \qquad u^2(\widehat{d}) = \sum_{j,k,l} w_{jkl}(d_{jkl} - \widehat{d})^2. \tag{11.52}$$

Diese Ausdrücke sind numerische Näherungen für die Momente der Ausgangsverteilung, sofern diese existieren. Es handelt sich nicht um die Auswertung einer zufällig gezogenen Stichprobe. Ein Korrekturfaktor mit einer um eins verminderten Anzahl von Modellwerten wird deshalb nicht verwendet. Die Standardunsicherheit $u(\widehat{d})$ ist die positive Wurzel der fortgepflanzten Varianz. Sie wird nicht durch die Wurzel aus der Anzahl der Klassenkombinationen geteilt.

Für die Verteilungsfunktion addieren wir die *Klassenwahrscheinlichkeiten* kumulativ:

$$C_0 = 0, \qquad C_\nu = \sum_{m=1}^{\nu} \pi_m \approx P_D(d_\nu). \tag{11.53}$$

Bei der rechteckförmigen Dichtenäherung steigt die Verteilungsfunktion innerhalb jeder Klasse linear an. Liegt eine gesuchte Wahrscheinlichkeit $r$ zwischen $C_{\nu-1}$ und $C_\nu$ und ist $\pi_\nu > 0$, erhalten wir das zugehörige Quantil durch lineare Interpolation:

$$P_D^{-1}(r) \approx d_{\nu-1} + \Delta d_\nu \frac{r - C_{\nu-1}}{\pi_\nu}. \tag{11.54}$$

Ein Intervall mit gleichen Wahrscheinlichkeiten in den beiden äußeren Bereichen ergibt sich für $P = 1 - \alpha$ aus

$$[d_{\text{low}}, d_{\text{high}}] = \left[P_D^{-1}(\alpha/2),\ P_D^{-1}(1-\alpha/2)\right]. \tag{11.55}$$

Die Interpolation verbessert die Ablesung innerhalb der Ausgangsklassen. Sie beseitigt nicht den Näherungseinfluss einer zu groben Eingangsklassierung.

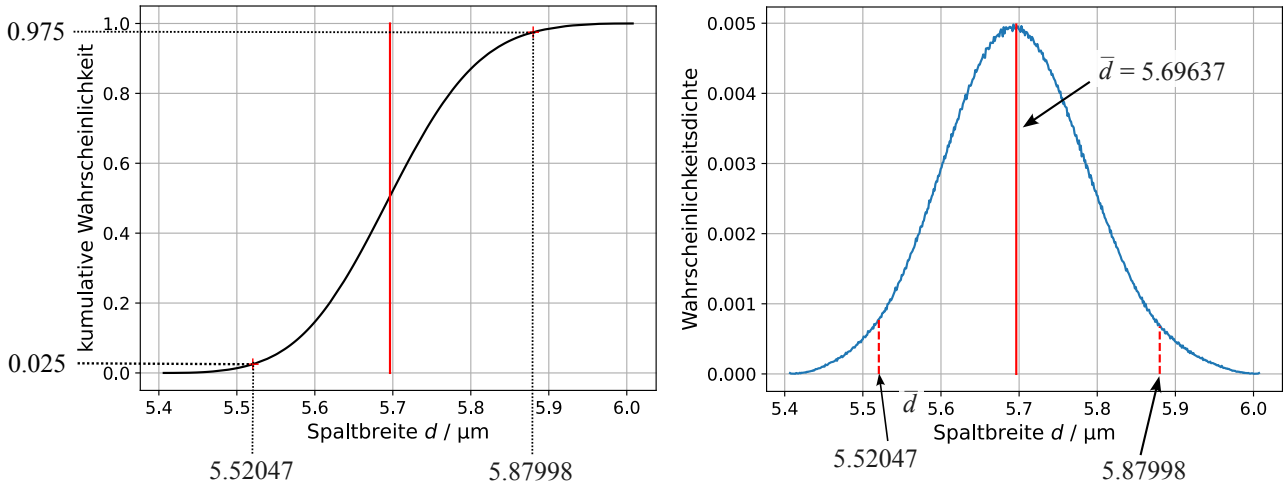



Abbildung 11.4: Vorhandene numerische Darstellung der Ausgangsverteilung der Spaltbreite. Links: Verteilungsfunktion mit Markierungen für die Wahrscheinlichkeiten 0.025 und 0.975. Rechts: Ausgangsdichte und eingezeichneter Schätzwert. Die eingetragenen Zahlen gehören zur dargestellten Auswertung; eine andere Klassierung kann geringfügig andere Näherungswerte liefern.

Die Verteilungen der Wellenlänge und des Abstands beschreiben bereits vor der aktuellen Spaltmessung verfügbare Informationen. Die Bestimmung der zugehörigen Standardunsicherheiten wird im klassischen GUM als Typ B eingeordnet. In der bayes'schen Interpretation nach Kacker und Jones [Kac03] können diese Verteilungen für die aktuelle Auswertung als Priorverteilungen aufgefasst werden.

Für die Minimumposition verwenden wir den aus den aktuellen Messdaten bestimmten Schätzwert und die zugehörige, durch statistische Auswertung ermittelte Standardunsicherheit $u(x_{\min})$. Ihre Bestimmung wird im klassischen GUM als Typ A eingeordnet. Für die Verteilungsfortpflanzung setzen wir zusätzlich eine Normalverteilung mit diesem Schätzwert als Erwartungswert und dieser Standardunsicherheit als Standardabweichung an. Die Wahl der Verteilungsform ist eine zusätzliche Modellannahme; sie folgt nicht allein aus der Einordnung als Typ A.

Die gemeinsame Fortpflanzung der drei Eingangsverteilungen durch das Messmodell liefert die Wahrscheinlichkeitsverteilung der Spaltbreite auf Grundlage der aktuellen Messdaten, der übernommenen Informationen und der getroffenen Modellannahmen. Solange wir offenlassen, wie die für die Minimumposition angesetzte Wahrscheinlichkeitsdichte zustande gekommen ist, bezeichnen wir die resultierende Verteilung der Spaltbreite allgemein als Ausgangsverteilung.

Beschreibt die angesetzte Normalverteilung die auf die unbekannte Minimumposition bezogene, normierte Likelihood, so kann sie unter der zusätzlichen Annahme einer konstanten Priordichte für diese Position als Posteriorverteilung interpretiert werden. Zusammen mit den Priorverteilungen der Wellenlänge und des Abstands ergibt ihre Fortpflanzung durch das Messmodell innerhalb dieser bayes'schen Beschreibung eine Posteriorverteilung der Spaltbreite.

**Pythonbeispiel:** Die Funktion in folgendem Quellcode setzt diese Rechnung für die drei unabhängigen Eingangsgrößen um. Alle Längen werden in $\mu$m angegeben. Die übrigen Vorgabewerte entsprechen dem beschriebenen Beispiel. Die Funktion verwendet für jede Eingangsgröße $K$ Klassen.

```
def klassierung_spalt(K=86, xmin_0=386.3, sigma_xmin = 5.9,
                      n_bins=200, alpha=0.05,
                      lambda_0=0.5500, sigma_lambda=0.0020,
                      L_0=4000.0, a_L=20.0):
    # Quantile in der Mitte der Wahrscheinlichkeitsklassen
    r = (np.arange(K) + 0.5) / K
    z = norm.ppf(r)
    lambda_rep = lambda_0 + sigma_lambda * z
    L_rep = L_0 - a_L * np.cos(np.pi * r)
    xmin_rep = xmin_0 + sigma_xmin * z
    if np.any(xmin_rep <= 0.0):
        raise ValueError("Positive Minimumspositionen erforderlich")

    # Alle K**3 Kombinationen, keine Zufallsziehung
    # berechne alle Produkte von lambda und L
    numerator = lambda_rep[:, None] * L_rep[None, :]
    # und alle Produkte von numerator und xmin_rep
    # diese sortieren fuer die kumulative Verteilung
    d_all = np.sort((numerator[:, :, None]
             / xmin_rep[None, None, :]).ravel())

    # erzeuge ein Array von derselben Groesse n wie d_all,
    # in dem alle Arrayelemente denselben Wert haben,
    # hier also 1/n
    # in diesem Fall ist weights schon so gewaehlt,
    # dass die Summe ueber alle weights schon 1 ist
    weights = np.full(d_all.size, 1.0 / d_all.size)

    # Momente direkt aus den gewichteten Modellwerten
    d_est = np.sum(weights * d_all)
    u_d = np.sqrt(np.sum(weights * (d_all - d_est)**2))

    N_d = len(d_all)
    cdf_slit = (np.arange(N_d) + 0.5) / N_d

    def quantile(probability):
        # Finde die Stelle, in deren Naehe das gesuchte Quantil liegt.
        i = np.searchsorted(
            cdf_slit[0:-1], probability, side="left"
        )

```

```
42          # lineare Interpolation zwischen 2 Stuetzstellen
43          probability_before = cdf_slit[i]
44          probability_after = cdf_slit[i+1]
45          fraction = (
46              (probability - probability_before)
47              / (probability_after - probability_before)
48          )
49          value = d_all[i] + fraction * (d_all[i+1] - d_all[i])
50
51          return float(value)
52
53      interval = (quantile(alpha / 2.0),
54                  quantile(1.0 - alpha / 2.0))
55      at50percent = quantile(0.5)
56      return {"d": d_est, "u": u_d, "interval": interval,
57              "d_all": d_all, "d_cdf": cdf_slit,
58              "at50percent": at50percent}
59
60  if __name__ == "__main__":
61      result = klassierung_spalt()
62      print(result["d"], 'pm', result["u"])
63      print(result["d"]-1.96*result["u"], result["d"]+1.96*result["u"])
64      print(result["interval"])
65      print('d at 50% probability', result["at50percent"])
66      print((result["d"]-result["interval"][0])/result["u"])
67      print((result["interval"][1]-result["d"])/result["u"])
```

## 11.3 Monte-Carlo Integration

Bei einer Monte-Carlo-Simulation werden die Funktionsargumente der Verteilungsfunktionen nicht in diskrete Klassen eingeteilt. Statt dessen werden die Werte des Funktionsarguments einer Wahrscheinlichkeitsdichteverteilung ausgewürfelt, sofern die Verteilung des Beobachtungsmodell als Bibliotheksfunktion vorliegt. Andernfalls kann die inverse kumulative Wahrscheinlichkeitsverteilung (Quantilfunktion) verwendet werden.

Für den Fall unabhängiger Eingangsgrößen wird üblicherweise je Eingangsgröße eine Stichprobe mit einem sehr großen Umfang $J_R$ gezogen und über das Messmodell $J_R$ Kombinationen berechnet [Cox06], wie in Abb. (11.5) symbolhaft skizziert.

Wir zeigen für unser Beugung-am-Spalt-Beispiel $J_R = 10000$ Ziehungen. Die Eingangsgrößen Wellenlänge $\lambda$ und Abstand $L$ sind Größen mit vorgegebenen Resultaten und mit Typ B Unsicherheit und den Zahlenwerten wie oben. Die Lichtwellenlänge $\lambda$ gilt wie bei der Methode mit der Klassierung als gaußverteilt und der Abstand $L$ wieder als Arcussinus-verteilt durch Vibrationen. Mit den

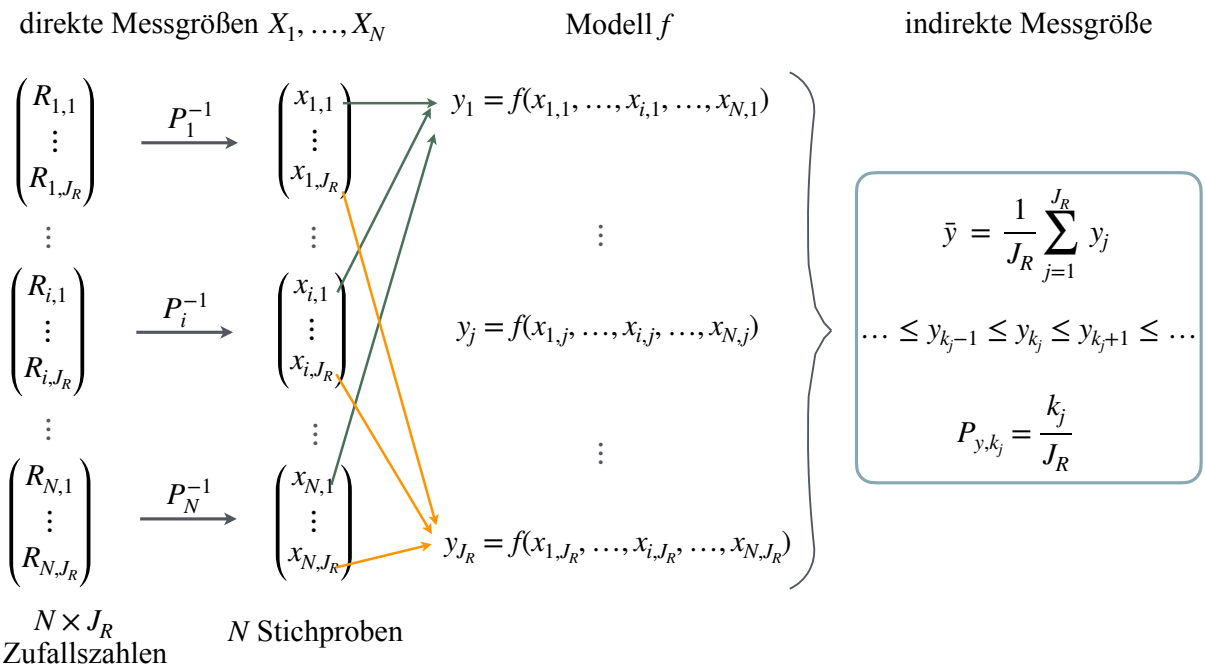



Abbildung 11.5: Monte-Carlo-Simulation mit $N \times J_R$ Stichproben für $N$ direkte Messgrößen, für die jeweils Stichproben mit jeweiligem Umfang von $J_R$ gewürfelten Beobachtungen generiert werden. Jedes Beobachtungstupel $(x_{1,j}, \ldots, x_{N,j})$ mit $j = 1, \ldots, J_R$ wird in das Modell eingefügt, so dass eine Stichprobe $(y_1, \ldots, y_{J_R})$ gewonnen wird.

10000 Ziehungen erhalten wir die in den Abbildungen 11.6 für den Abstand $L$ und 11.7, *rechts*, für die Wellenlänge $\lambda$ dargestellten Verteilungen.

Die Eingangsverteilung für den mittleren Minimumabstand $X_{\min}$, Abstand der ersten Minima vom Hauptmaximum, wird aus fünf Wiederholungsmessungen bestimmt. Für das betrachtete Messszenario wird der Spalt vor jeder Messung erneut auf dem Probenhalter positioniert. Dadurch kann sich die Position des Hauptmaximums auf dem Detektor zwischen den Messungen verschieben.

Der Zeilendetektor besitzt 64 Pixel und ist 2 mm lang. Aus jedem der fünf gemessenen Intensitätsprofile bestimmen wir einen Schätzwert für die Positionen der ersten Minima.

Unter Verwendung der Spaltfunktion der Fraunhoferbeugung beschreiben wir das kontinuierliche Intensitätsprofil durch

$$I(x; A, x_0, q) = A \left[ \operatorname{sinc} \left( \frac{x - x_0}{q} \right) \right]^2, \tag{11.56}$$

wobei wir entsprechend der NumPy-Funktion `np.sinc` die normierte Definition

$$\operatorname{sinc}(z) = \frac{\sin(\pi z)}{\pi z}, \qquad \operatorname{sinc}(0) = 1 \tag{11.57}$$

verwenden. Hier bezeichnet $x$ die Koordinate entlang des Detektors, $A$ einen Intensitätsfaktor und $x_0$ die Position des Hauptmaximums.

Die registrierten Pixelwerte beziehungsweise Grauwerte sind proportional zur über die sensitive Pixelfläche integrierten Intensität. Es werden deshalb die Parameter $A$, $x_0$ und $q$ der Modellfunktion Gl. (11.56) an das jeweils gemessene Pixelsignal angepasst.

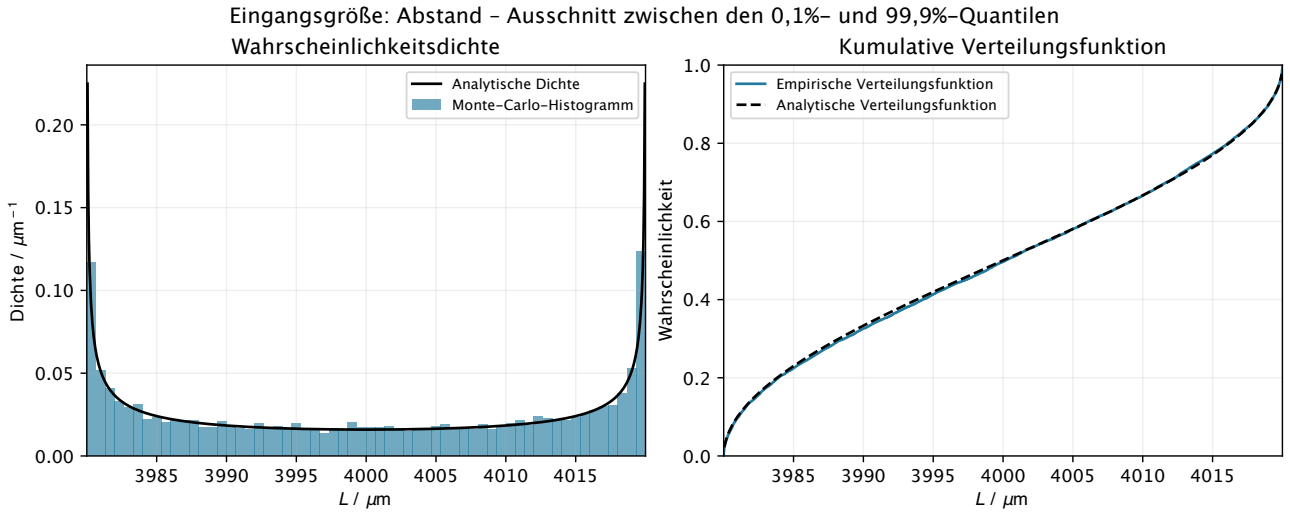



Abbildung 11.6: Monte-Carlo-Simulation der Schwankung des Abstands $L$ zwischen Spalt und Objektiv durch Vibrationen als Funktion der Zeit für die große Stichprobe.

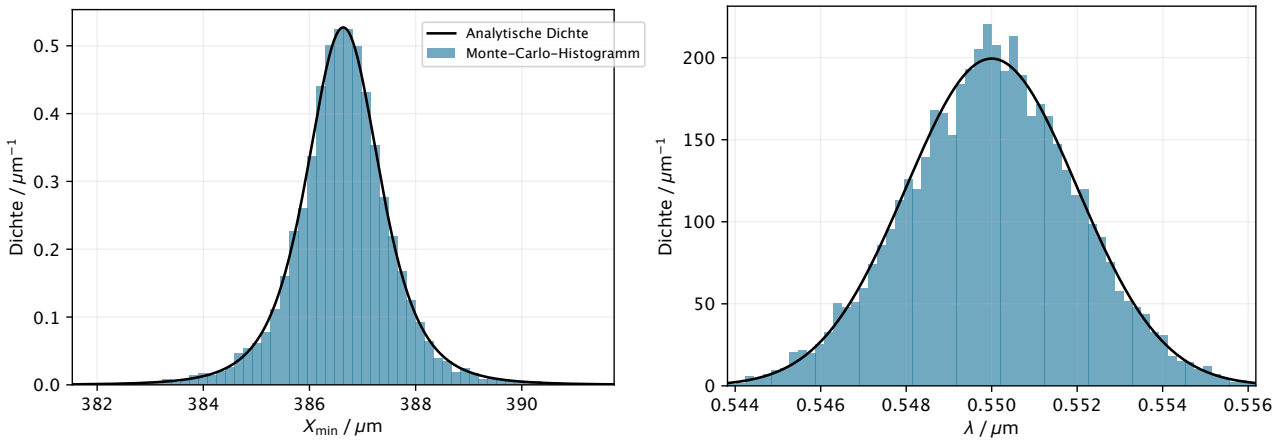



Abbildung 11.7: Histogramme der Minimumposition des Beugungsbildes $x_{\min}$ und der Lichtwellenlänge $\lambda$, die als große Stichproben per Monte-Carlo-Simulation generiert wurden.

Die fünf Schätzwerte von $q$ ergeben

$$x_{\min,j} = \hat{q}_j, \qquad j = 1, \ldots, 5. \tag{11.58}$$

Für die betrachteten Messreihen erhalten wir:

| Messung $j$ | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| $x_{\min,j}/\mu\mathrm{m}$ | 384.090764 | 388.313261 | 386.368012 | 387.446657 | 386.959645 |

Für die folgende Zuordnung einer Student-$t$-Verteilung behandeln wir diese Werte als unabhängige Beobachtungen derselben konstanten Größe mit näherungsweise normalverteilten Abweichungen. Wir berechnen den Mittelwert und die Stichprobenstandardabweichung:

$$\bar{x}_{\min} = \frac{1}{5}\sum_{j=1}^{5} x_{\min,j}, \qquad s = \sqrt{\frac{1}{4}\sum_{j=1}^{5}(x_{\min,j} - \bar{x}_{\min})^2}. \tag{11.59}$$

Der Skalenparameter der dem unbekannten Mittelwert zugeordneten Student-$t$-Verteilung lautet

$$a = \frac{s}{\sqrt{5}}, \qquad \nu = 5 - 1 = 4. \tag{11.60}$$

Für die Monte-Carlo-Ziehungen wird zunächst ein Pseudozufallszahlengenerator initialisiert. Die Funktion `np.random.default_rng` erzeugt eine Instanz `rng` der Klasse `numpy.random.Generator`:

```
1  import numpy as np
2
3  SEED = 19273
4  rng = np.random.default_rng(SEED)
```

`SEED` legt die Initialisierung des Pseudozufallszahlengenerators fest. Ein anderer Seed liefert andere Zufallswerte und damit eine andere Monte-Carlo-Stichprobe; die zugrunde gelegte Wahrscheinlichkeitsverteilung bleibt unverändert. Bei gleichem Seed, gleicher Softwareumgebung und unveränderter Folge der Generatoraufrufe werden dieselben Zufallswerte reproduziert.

Die Monte-Carlo-Stichprobe mit Umfang $J_R = 10000$ wird anschließend wie folgt erzeugt:

```
1  N_MC = 10000
2  J = len(xmin)
3  nu = J - 1
4
5  xmin_mittel = np.mean(xmin)
6  scale = np.std(xmin, ddof=1) / np.sqrt(J)
7
8  xmin_samples = (
9      xmin_mittel + scale * rng.standard_t(nu, N_MC)
10 )
```

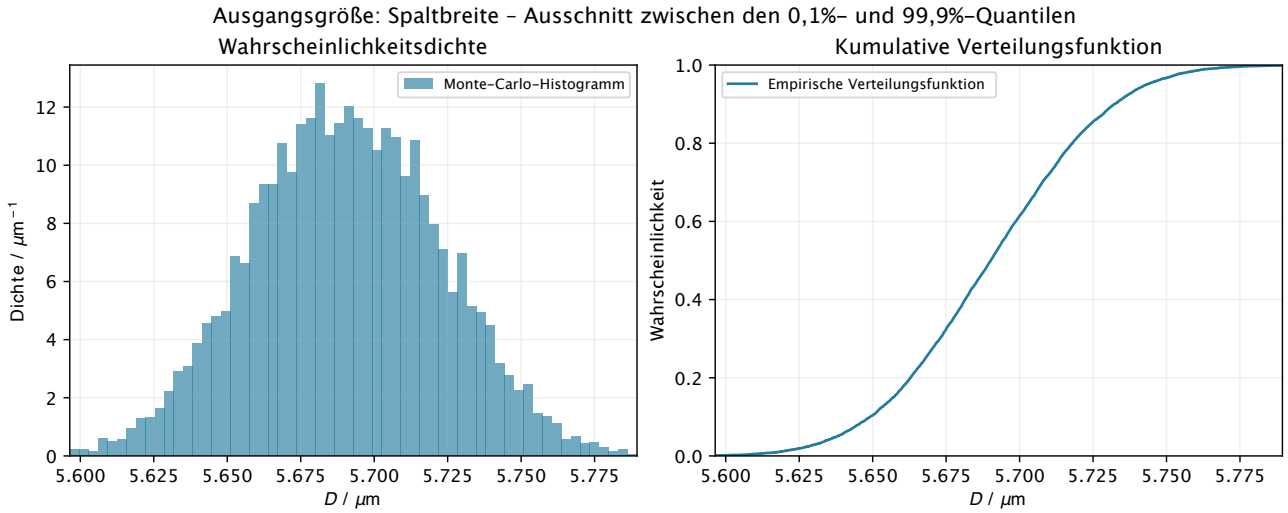



Abbildung 11.8: *Links:* Wahrscheinlichkeitsdichteverteilung der aus der Monte-Carlo-Rechnung gewonnenen Spaltbreiten-Stichprobe mit $J_R = 10000$, *rechts:* die kumulative Verteilung dazu.

Die Methode `standard_t` erzeugt hier Werte aus einer zentralen Student-$t$-Verteilung mit vier Freiheitsgraden und Skalenparameter eins. Durch Multiplikation mit `scale` und Addition von `xmin_mittel` erhalten wir die gewünschte verschobene und skalierte Verteilung.

Es bleibt noch zu diskutieren, ob wie in GUM Supplement 1 eine normalverteilte Stichprobe in dieser Weise aus der Student-$t$-Verteilung zu erzeugen ist, siehe GUM-S1 Abschnitt 6.4.9.3, oder ob die Ziehung mittels Normalverteilung mit der Standardabweichung der $t$-Verteilung Gl. 10.71 zu verwenden ist, die in Abschnitt 6.4.9.4 genannt wird. Die Autoren der Vorlesung werden dies im Laufe des WS 2026/27 klären.

Die Spaltbreiten werden mit dem Modell der Kleinwinkelnäherung berechnet. Bei der Monte-Carlo-Simulation liefern die drei Stichproben zu den drei Eingangsgrößen $J_R = 10000$ Tripel, die eingesetzt in die Modellgleichung je eine Spaltbreite liefern:

```
1 d_samples = lambda_samples * L_samples / xmin_samples
```

Abbildung 11.8 stellt die Verteilungen von `d_samples` graphisch dar.

Der Schwerpunkt der Wahrscheinlichkeitsdichteverteilung liefert den Schätzwert der Spaltbreite und aus der kumulativen Verteilung kann dann genauso wie in dem Beispiel mit dem klassierten Integrationsverfahren, das Überdeckungsintervall bestimmt werden.

# Kapitel 12

# M.U.-Berechnung mit bayesischer Statistik

## 12.1 Bayes-Theorem

### 12.1.1 Einleitung: Klassische und Bayessche Statistik

Grob gesagt verwendet die klassische Statistik zum Schätzen von Parametern und zum Testen von Hypothesen nur die Stichprobe; die bayessche stellt zusätzlich in Rechnung, was man sonst noch über das Problem weiß oder annimmt. Dies hängt mit den unterschiedlichen Meinungen darüber zusammen, was Wahrscheinlichkeit bedeutet: relative Häufigkeit in Zufallsexperimenten (die klassiches Sicht) oder einen Ausdruck des Wissens (die bayessche Sicht). Siehe hierzu auch die 2. Vorlesung.

### 12.1.2 Das Bayes-Theorem

(Hinweis: Unter einer *bedingten Wahrscheinlichkeit* $P(A|B)$ versteht man die Wahrscheinlichkeit, dass ein Ereignis $A$ unter der Bedingung eintritt, dass das Eintreten eines Ereignisses $B$ bereits bekannt ist, d.h. Ereignis $B$ bereits eingetreten ist. Im Gegensatz dazu gibt es die *totale Wahrscheinlichkeit* $p(A)$.)
In der Statistik wird der zu schätzende Parameter häufig mit $\theta$ bezeichnet. Deshalb nehmen wir hier auch für den Modellparameter $\theta$ anstatt $Y$. Gegeben sind Messdaten / Beobachtungen einer Messgröße $X$ mit $X_j$, $j = 1...J$. Die dazugehörige bedingte Wahrscheinlichkeitsdichte in Abhängigkeit von dem Parameter $\theta$ ist $p(X|\theta)$. Unter der Annahme, dass $\theta$ eine Wahrscheinlichkeitsdichte $p(\theta)$ besitzt, gibt es nach Bayes folgenden Zusammenhang

$$p(X|\theta) \cdot p(\theta) = p(\theta|X) \cdot p(X) \tag{12.1}$$

Die gesuchte bedingte Wahrscheinlichkeit $p(\theta|X)$ ist dann gegeben durch:

$$p(\theta|X) = \frac{p(X|\theta) \cdot p(\theta)}{p(X)} \tag{12.2}$$

Die totale Wahrscheinlichkeitsdichte erhalten wir durch:

$$p(X) = E(p(X|\theta)) = c^{-1} = \begin{cases} \int p(X|\theta)p(\theta)d\theta & \text{mit} \quad \theta \text{ kontinuierlich} \\ \sum p(X|\theta)p(\theta) & \text{mit} \quad \theta \text{ diskret} \end{cases} \tag{12.3}$$

Das Integral oder die Summe geht über den erlaubten Bereich von $\theta$. $E()$ bezeichnet den Erwartungswert.

Damit können wir die Gl. (12.2) umschreiben:

$$p(\theta|X) = c \cdot p(X|\theta) \cdot p(\theta) \tag{12.4}$$

Gl.(12.2) bzw. Gl.(12.4) wird in der Regel als **Bayes-Theorem** bezeichnet. Wir bezeichnen:

- $p(\theta|X)$: Gesuchte Posterior-Wahrscheinlichkeitsdichte, kurz: **Posterior**

- $p(X|\theta)$: Bedingte Wahrscheinlichkeitsdichte der Messdaten X
- $p(\theta)$: Prior-Wahrscheinlichkeitsdichte von $\theta$, kurz: **Prior**
- $c$: Normierungskonstante, die sicherstellt, dass die Summe bzw. das Integral über die Posterior $p(\theta|X)$ gleich Eins ist.

Da $c$ „nur" eine Normierungskonstante ist wird das Bayes-Theorem auch oft als Proportionalitätsgleichung geschrieben:

$$p(\theta|X) \propto p(X|\theta) \cdot p(\theta) \tag{12.5}$$

**Zusammenhang zwischen Bayes-Theorem und Likelihood-Funktion:**
Die bedingte Wahrscheinlichkeitsdichte $p(X|\theta)$ kann

(a) als Funktion von X gesehen werden

oder

(b) als Funktion von $\theta$, d.h. welches $\theta$ passt am besten zu den gemessenen Daten $X$; dieses bezeichnet man als **Likelihood-Funktion**: $l(\theta|X)$

Somit können wir die Gl.(12.5) auch schreiben als:

$$p(\theta|X) \propto l(\theta|X) \cdot p(\theta) \tag{12.6}$$

Das Bayes-Theorem gibt uns die Wahrscheinlichkeitsfunktion für den Posterior $p(\theta|X)$ durch das Produkt aus der Likelihoodfunktion und der Prior-Funktion $p(\theta)$

$$\text{Posteriorverteilung} \propto \text{Likelihoodfunktion} \quad \text{x} \quad \text{Prior} - \text{Verteilung}$$

Die Likelihood-Fkt. spielt eine entscheidende Rolle bei Bayes, da sie durch Aufnehmen von Messdaten X meine Priorkenntnis über $\theta$ updated.

Eine Konstante bei der Likelihood-Funktion hat keinen Einfluss auf das erweiterte Wissen, da schlussendlich ja die Posterior-Verteilung normiert bleiben muss, d.h. $\int p(\theta|X)d\theta = 1$. Deshalb sind nur die relativen Werte der Likelihood-Funktion von Relevanz.

**Sequentielle Natur von Bayes**
Ein wichtige Eigenschaft des Bayes-Theorems ist, dass Vorwissen mit neuem Wissen kombiniert werden kann. Es gilt bei Aufnahme von zwei Messungen (zwei Beobachtungen) $X_1$ und $X_2$

$$\begin{aligned} p(\theta|X_2, X_1) &\propto p(\theta) \cdot l(\theta|X_1) \cdot l(\theta|X_2) \\ &\propto p(\theta|X_1) \cdot l(\theta|X_2) \end{aligned}$$

D.h. die Posterior $p(\theta|X_1)$ der 1. Beobachtung wird zum Prior für die 2. Beobachtung. Dieser Prozess kann beliebig of wiederholt werden, d.h. wir erhalten:

$$p(\theta|X_1, \ldots, X_J) \propto p(\theta|X_1 \ldots, X_{J-1}) \cdot l(\theta|X_J) \tag{12.7}$$

Diese Gleichung beschreibt den **Prozess des Lernens durch kontinuierliche Updates**. Dies ist auch für Ringvergleiche interessant. Hier messen mehrere Institute denselben Prüfling (siehe 6. Vorlesung „Auswertung von Mess- und Ringvergleichen“). Darüber lässt sich auch herleiten, wie bei einem Ringvergleich (siehe 6. Vorl.) die Erwartungswerte und Varianzen der teilnehmenden Labore zu kombinieren sind.

## 12.2 Parameterschätzung mit Bayesscher Statistik

### 12.2.1 Einführung

Wie in der klassischen Statistik (frequentistische Statistik), so kann man auch in der bayesschen Statistik eine Parameterschätzung durchführen. Eine Schätzung hat zum Ziel einen Wert anzugeben, der dem wahren Wert möglichst nahe kommt. Man gibt zum Schätzwert noch ein Intervall an, indem vermutlich der wahre Wert liegt. Sowohl der Schätzwert $\hat{\theta}$ als auch das dazugehörige Intervall kann aus der Posterior-Verteilungsdichte $p(\theta|X)$ bestimmt werden.

### 12.2.2 Beispiel: Schätzung einer physikalischen Konstante

Dieses etwas fiktive Beispiel soll zeigen, wie sich unterschiedliches Vorwissen oder unterschiedliche Beobachtungen auf die Schätzung einer physikalischen Konstante auswirkt. Wir nehmen an, dass Beobachter A sehr vertraut auf diesem Gebiet ist und großes Vorwissen hat und somit einen guten Schätzwert für den Prior $p_{\mathrm{A}}(\theta)$ angeben kann. Wir nehmen an, dass das Prior-Wissen des Beobachters A durch eine Normalverteilung $\mathcal{N}(\mu = 900, \sigma^2 = 20^2)$ approximiert werden kann. D.h.

$$p_{\mathrm{A}}(\theta) = \frac{1}{\sqrt{(2\,\pi)}20} \exp\left[-\frac{1}{2}\left(\frac{\theta - 900}{20}\right)^2\right]$$

Im Gegensatz dazu nehmen wir an, dass Beobachter B weniger Vorwissen hat, hier beispielweise nur eine Varianz von $\sigma^2 = 80^2$ hat. Wir nehmen für B als Prior eine Normalverteilung $\mathcal{N}(800, 80^2)$ an. D.h.

$$p_{\mathrm{B}}(\theta) = \frac{1}{\sqrt{(2\,\pi)}80} \exp\left[-\frac{1}{2}\left(\frac{\theta - 800}{80}\right)^2\right]$$

Abb.12.1 zeigt die beiden Prior-Verteilungen: Wir nehmen zunächst an, dass die physik. Konstante einmal beobachtet wird mit dem Mittelwert $\theta = 850$ und der Standardabweichung 40, d.h. als Likelihood der Messdaten haben wir eine Normalverteilung $l(\theta|X) \sim \mathcal{N}(850, 40)$. Abb.12.2 zeigt die Wahrscheinlichkeitsdichtefunktion (engl. *probability density function*, kurz pdf) der Likelihood und Abb.12.3 die Posteriorverteilung $p_{\mathrm{A}}(\theta|X)$ für den Beobachter A und die Posterior-Verteilung $p_{\mathrm{B}}(\theta|X)$ für den Beobachter B. Abb. 12.3 zeigt, dass Beobachter A nicht viel gelernt hat, während Beobachter B viel gelernt hat.

Wenn sowohl der Prior $\theta \sim N(\theta_0, \sigma_0^2)$ als auch die Likelihood normalverteilt ist, dann ist auch der

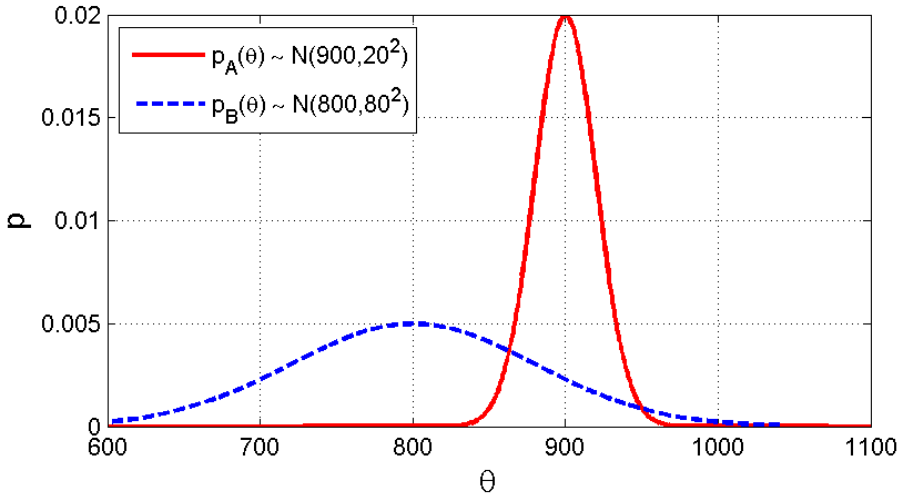



Abbildung 12.1: Prior-Verteilungen für A und B

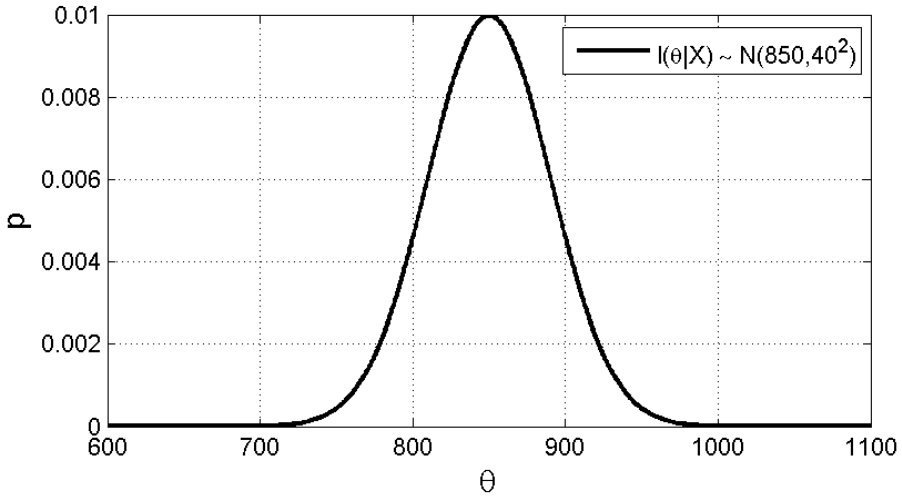



Abbildung 12.2: Standardisierte Likelihood für 1 Beobachtung mit x = 850

Posterior $p(\theta|X)$ normalverteilt mit $\mathcal{N}(\bar{\theta}, \bar{\sigma}^2)$, wobei

$$\bar{\theta} = \frac{1}{w_0 + w_1}(w_0\theta_0 + w_1 x) \quad , \quad \frac{1}{\bar{\sigma}^2} = w_0 + w_1 \tag{12.8}$$

$$\text{mit} \qquad w_0 = \frac{1}{\sigma_0^2} \quad \text{und} \quad w_1 = \frac{1}{\sigma_1^2}$$

Beweis dazu siehe weiter unten.

Mit $\bar{\sigma}^2$ bezeichnen wir hier die Varianz der Posterior und nicht die Varianz des Mittelwertes. D.h. durch die Beobachtung wird meine Varianz upgedatet. Bei $J$ Beobachtungen wäre dann die Varianz $\bar{\sigma}^2$ des Posteriors die Kombination aus der Varianz des Priors $\sigma_0^2$ und den Messungen $\sigma_j^2$:

$$\frac{1}{\bar{\sigma}^2} = \left(\sum_{j=1}^{J} \frac{1}{\sigma_j^2}\right) + \frac{1}{\sigma_0^2}$$

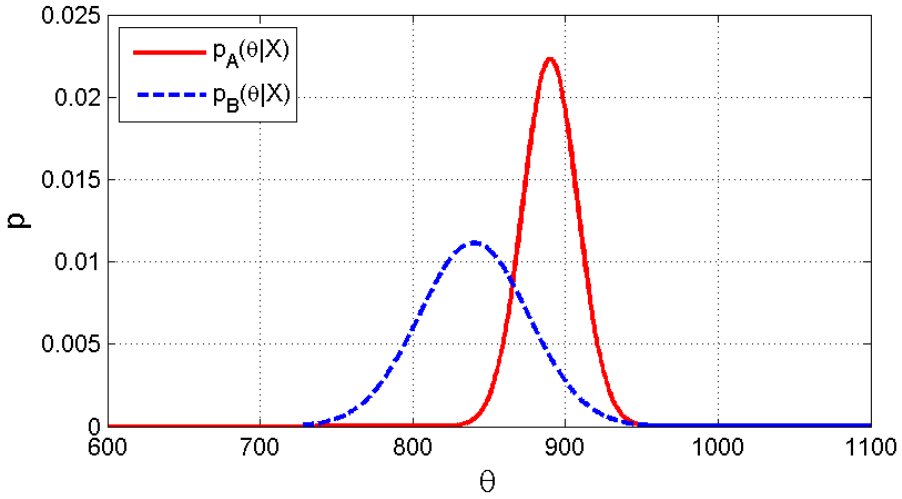



Abbildung 12.3: Posterior Verteilung für A und B nach einer Beobachtung mit $\sigma_A = 17.9$ und $\sigma_B = 35.7$. D.h. A hat wenig gelernt, B hat viel gelernt.

Der Posterior Mittelwert $\bar{\theta}$ ist das gewichtete Mittel des Prior-Mittelwertes und des Mittelwertes $x$ der Beobachtung $X$.

Für den Beobachter A ergibt sich der Mittelwert des Posteriors zu:

$$\bar{\theta}_{\mathrm{A}} = \frac{1}{1/20^2 + 1/40^2}\left(\frac{1}{20^2}\cdot 900 + \frac{1}{40^2}\cdot 850\right) = 890$$

Die Standardabweichung ergibt sich zu:

$$\frac{1}{\bar{\sigma}_{\mathrm{A}}^2} = \frac{1}{20^2} + \frac{1}{40^2} \Rightarrow \bar{\sigma}_{\mathrm{A}} = 17.9$$

Die Ergebnisse sind in Tab.12.1 zusammengefasst.

Tabelle 12.1: Zusammenfassung der Ergebnisse für Beobachter A und B. A lernt wenig. B lernt viel.

| Prior Verteilung | Likelihood von den Daten | Posterior Verteilung |
|---|---|---|
| A | A | A |
| $\theta \sim N(900, 20^2)$ | $N(850, 40^2)$ | $\theta \sim N(890, 17.9^2)$ |
| B | B | B |
| $\theta \sim N(800, 80^2)$ | $N(850, 40^2)$ | $\theta \sim N(840, 35.7^2)$ |

Nehmen wir jetzt an, dass 99 weitere unabhängige Messungen zur Bestimmung der phys. Konstante gemacht werden mit einem Mittelwert $\bar{x} = 1/100 \cdot \sum_{j=1}^{100}$ für 100 Beobachtungen mit Mittelwert 870. Die Likelihood-Funktion von $\theta$ bei $J$ unabhängigen Beobachtungen, die normalverteilt $N(\theta, \sigma^2)$ sind, ist gegeben durch:

$$l(\theta|X) \propto \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^J \exp\left[-\frac{1}{2\sigma^2}\sum_{j=1}^{J}(X_j - \theta)^2\right]$$

Da

$$\sum_{j=1}^{J}(X_j - \theta)^2 = \sum_{j=1}^{J}(X_j - (\bar{X}))^2 + J(\theta - (\bar{X}))^2$$

und die gegebenen Daten $\sum(X_j - \bar{X})^2$ eine feste Konstante ist, so ist die Likelihood:

$$l(\theta|X) \propto \exp\left[-\frac{1}{2}\left(\frac{\theta - \bar{X}}{\sigma/\sqrt{(J)}}\right)^2\right] \tag{12.9}$$

D.h. dies ist eine Normalverteilung zentriert bei $\bar{X}$ mit Standardabweichung des Mittelwertes $\sigma/\sqrt{J}$. Im gegebenem Beispiel ist die Likelihood die Normalverteilung mit dem Mittelwert $\bar{X} = 870$ und der Standardabweichung des Mittelwertes $\sigma/\sqrt{(J)} = 40/\sqrt{100} = 4$. Dies ist in Abb. 12.4 gezeigt.

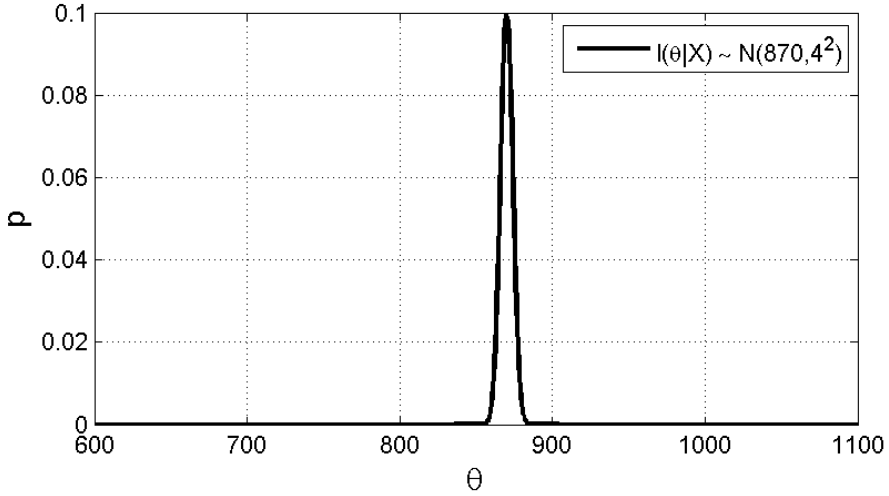



Abbildung 12.4: Standardisierte Likelihood für 100 Beobachtungen mit $\bar{X} = 870$

Mit der Formel in Gl.(12.8) errechnen sich die Posterior-Verteilungen von A und B zu $N(871.2, 3.9^2)$ und $N(869.8, 3.9995^2)$. Diese sind in Abb.12.5 dargestellt.

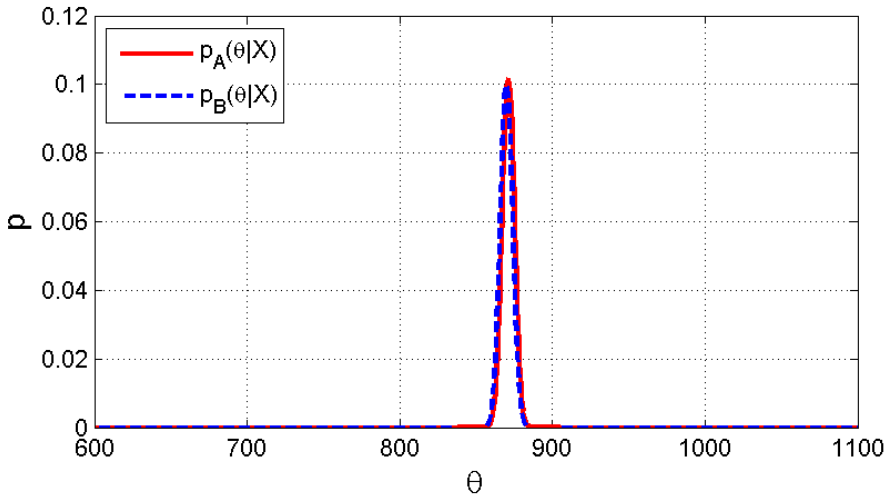



Abbildung 12.5: Posterior-Verteilungen für A und B nach 100 Beobachtungen

Nach 100 Beobachtungen sind die Beobachter A und B fast in Übereinstimmung. Das Prior-Wissen von A und B spielt fast keine Rolle mehr. In Tabelle 12.2 sind die Ergebnisse dargestellt.

**Anhang (a): Herleitung von Gl.(12.8)**

Tabelle 12.2: Zusammenfassung der Ergebnisse für Beobachter A und B bei 100 Beobachtungen. Vorwissen von Beobachter A und B spielt fast keine Rolle mehr

| Prior Verteilung | Likelihood von den Daten | Posterior Verteilung |
|---|---|---|
| A | A | A |
| $\theta \sim N(900, 20^2)$ | $N(870, 4^2)$ | $\theta \sim N(871.2, 3.9^2)$ |
| B | B | B |
| $\theta \sim N(800, 80^2)$ | $N(870, 4^2)$ | $\theta \sim N(869.8, 3.995^2)$ |

Im Folgenden wollen wir noch die Gl.(12.8) herleiten, mit der wir die Posterior berechnen können, wenn die Prior-Verteilung und die Likelihood normalverteilt sind. Wir nehmen an, dass die Prior normalverteilt ist mit:

$$p(\theta) = \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left[ - \frac{1}{2}\left(\frac{\theta - \theta_0}{\sigma_0}\right)^2\right], \quad -\infty < \theta < \infty \tag{12.10}$$

Die Likelihood-Funktion von $\theta$ ist ebenfalls normalverteilt:

$$l(\theta|X) \propto \exp\left[ - \frac{1}{2}\left(\frac{\theta - X}{\sigma_1}\right)^2\right] \tag{12.11}$$

Die Posterior-Verteilung erhalten wir dann:

$$p(\theta|X) = \frac{p(\theta)\ l(\theta|X)}{\int_{-\infty}^{\infty} p(\theta)\ l(\theta|X))d\theta} = \frac{f(\theta|X)}{\int_{-\infty}^{\infty} f(\theta|X)d\theta} \tag{12.12}$$

mit

$$f(\theta|X) = \exp\left\{ - \frac{1}{2}\left[\left(\frac{\theta - \theta_0}{\sigma_0}\right)^2 + \left(\frac{\theta - X}{\sigma_1}\right)^2\right]\right\} \tag{12.13}$$

Unter der Verwendung der Identität

$$A(z-a)^2 + B(z-b)^2 = (A+B)(z-c)^2 + \frac{AB}{A+B}(a-b)^2 \tag{12.14}$$

mit

$$c = \frac{1}{A+B}(A\ a + B\ b) \tag{12.15}$$

können wir den folgenden Ausdruck wie folgt schreiben:

$$\left(\frac{\theta - \theta_0}{\sigma_0}\right)^2 + \left(\frac{\theta - X}{\sigma_1}\right)^2 = (\sigma_0^{-2} + \sigma_1^{-2})\ (\theta - \bar{\theta})^2 + d \tag{12.16}$$

wobei

$$\bar{\theta} = \frac{1}{\sigma_0^{-2} + \sigma_1^{-2}}(\sigma_0^{-2}\theta_0 + \sigma_1^{-2}X)$$

und $d$ ist konstant, d.h. unabhängig von $\theta$. Somit

$$f(\theta|X) = \exp\left(-\frac{d}{2}\right) \exp[-\ 1/2 \cdot (\sigma_0^{-2} + \sigma_1^{-2})(\theta - \bar{\theta})^2] \tag{12.17}$$

so dass

$$\begin{aligned} \int_{-\infty}^{\infty} f(\theta|X)d\theta &= \exp\left(-\tfrac{d}{2}\right) \cdot \int_{-\infty}^{\infty} \exp\left[-\tfrac{1}{2}(\sigma_0^{-2}+\sigma_1^{-2})(\theta-\bar{\theta})^2\right] d\theta \\ &= \sqrt{2\pi}(\sigma_0^{-2}+\sigma_1^{-2})^{-1/2}\exp(-d/2) \end{aligned} \tag{12.18}$$

Es folgt daraus, dass

$$p(\theta|X) = \frac{(\sigma_0^{-2}+\sigma_1^{-2})^{1/2}}{\sqrt{2\pi}} \exp\left[-1/2 \cdot (\sigma_0^{-2}+\sigma_1^{-2})(\theta-\bar{\theta})^2)\right] \tag{12.19}$$

mit der Normalverteilung

$$N\left[\bar{\theta},\ (\sigma_0^{-2}+\sigma_1^{-2})^{-1}\right] \tag{12.20}$$

**Anhang (b): Octave/Matlab-Skript zum Beispiel**

```
% by Ehret, date: 2019-12-10
clear all; close all;
% Beispiel: Bayes for a physical constants

% Definition der X-Werte
X = linspace(600,1100,1000);

% Beispiel
% Prior-Verteilung des Beobachters A
% Normalverteilt mit mu_A = 900 und sigma_a = 20
mu_A = 900;
sigma_A = 20;
DeltaX = X(2)-X(1);
p_A = normpdf(X,mu_A, sigma_A);

% Prior-Verteilung des Beobachters B
% Normalverteilt mit mu_B = 800 und sigma_a = 80
mu_B = 800;
sigma_B = 80;
p_B = normpdf(X,mu_B, sigma_B);

% Plotten der Prior-Verteilungen von A und B
figure(1)
plot(X,p_A,'r-','linewidth',2)
hold on;
plot(X,p_B,'b--','linewidth',2)
grid on;
legend('p_A(\theta) ~ N(900,20^2)','p_B(\theta) ~ N(800,80^2)', ...
'Location','NorthWest')
xlabel('\theta','fontsize',14)
ylabel('p','fontsize',14)

set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 8;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' prior_A_Prior_B.png

% Annahme der Likelihood (Messung) als Normalverteilung mit l ~ N(850,40^2 )
mu_likeli = 850;
sigma_likeli = 40;
likelihood = normpdf(X,mu_likeli, sigma_likeli);

% Plotten der Likelihood
```

```
figure(2)
plot(X,likelihood,'k-','linewidth',2)
grid on;
legend('l(\theta|X) \sim N(850,40^2)')
xlabel('\theta','fontsize',14)
ylabel('p','fontsize',14)

set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 8;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' likelihood_1_Beobachtung.png


% Berechnung der Posterior fuer eine Beobachtung fuer A und B
% Posterior ~ Prior  x Likelihood
p_post_A_1 = p_A .* likelihood;
p_post_B_1 = p_B .* likelihood;

% Normierung des posterior mit Normierungskonstante
% Nicht ganz korrekt, da eigentlich
% von -\inf bis +\inf integriert bzw. summiert werden muesste

const_post_A1 = 1/sum(p_post_A_1*DeltaX);
p_post_A_1 = const_post_A1 * p_post_A_1 ;

const_post_B1 = 1/sum(p_post_B_1*DeltaX);
p_post_B_1 = const_post_B1 * p_post_B_1 ;

% Plotten der Posterior
figure(3)
plot(X,p_post_A_1,'r-','linewidth',2)
hold on;
plot(X,p_post_B_1,'b--','linewidth',2)
grid on;
legend('p_A(\theta|X)','p_B(\theta|X) ', ...
'Location','NorthWest')
xlabel('\theta','fontsize',14)
ylabel('p','fontsize',14)

set(gcf, 'PaperUnits', 'centimeters');
x_width=15 ;y_width= 8;
set(gcf, 'PaperPosition', [0 0 x_width y_width]);
print '-dpng' posterior_A_posterior_B.png

```

```
% Jetzt besteht die Likelihood aus 100 Stichproben
% Bei 100 Stichproben kann die Verteilung schmaler werden
% Wir nehmen eine Normalverteilung N(870, \sigma /sqrt(N)^2) an
N = 100;
sigma_likeli_100 = sigma_likeli / sqrt(N);
mu_likeli_100 = 870;
% Likelihood Funktion fuer 100 Stichproben
likelihood_100 = normpdf(X,mu_likeli_100, sigma_likeli_100);

figure(4)
plot(X,likelihood_100,'k-','linewidth',2)
grid on;
legend('l(\theta|X) ~ N(870,4^2)')
xlabel('\theta','fontsize',14)
ylabel('p','fontsize',14)

% Berechnung der Posterior fuer 100 Beobachtungen fuer A und B
p_post_A_100 = p_A .* likelihood_100;
p_post_B_100 = p_B .* likelihood_100;

% Normierung des posterior mit Normierungskonstante
% Nicht ganz korrekt, da eigentlich
% von -\inf bis +\inf integriert bzw. summiert werden muesste
const_post_A_100 = 1/sum(p_post_A_100*DeltaX);
p_post_A_100 = const_post_A_100 * p_post_A_100 ;

const_post_B_100 = 1/sum(p_post_B_100*DeltaX);
p_post_B_100 = const_post_B_100 * p_post_B_100 ;

figure(5)
plot(X,p_post_A_100,'r-','linewidth',2)
hold on;
plot(X,p_post_B_100,'b--','linewidth',2)
grid on;
legend('p_A(\theta|X)','p_B(\theta|X) ', ...
'Location','NorthWest')
xlabel('\theta','fontsize',14)
ylabel('p','fontsize',14)
```

### 12.2.3 Priorverteilungen

Das Bayes-Theorem verwendet eine Prior-Verteilung, also ein Vorwissen über die zu schätzenden Modellparameter. Für Situationen, in denen es im wesentlichen kein Vorwissen gibt, wird eine einfache Rechteckverteilung als Prior angesetzt, was bedeutet, dass die Wahrscheinlichkeit innerhalb eines vorgegebenen Intervalls $[\theta_{\mathrm{li}}, \theta_{\mathrm{re}}]$ konstant ist:

$$p(\theta) = \begin{cases} const. & \text{falls} \quad \theta \in [\theta_{\mathrm{li}}, \theta_{\mathrm{re}}] \\ 0 & \text{sonst.} \end{cases}$$

Dieser Ansatz ist mit Vorsicht zu verwenden: Die Posterior kann mehrere lokale Maxima, die ähnlich groß sind, aufweisen. Sie kann auch ihrerseits nahezu rechteckverteilt sein. Je nach Modell kann dieser Ansatz mit ungeschickt gewähltem Intervall $[\theta_{\mathrm{li}}, \theta_{\mathrm{re}}]$ zu numerischen Problemen führen. Besonders problematisch ist die Situation, wenn mangels Vorwissen für die Intervallgrenzen oder für eine der beiden Intervallgrenzen der Grenzübergang ins Unendliche vorgenommen wird. Das kann dann dazu führen, dass kein physikalisch oder statistisch sinnvoller Erwartungswert bestimmt werden kann.

Ein Beispiel hierfür ist die Bestimmung der Fläche eine Rechteckes $F = a \cdot b$. Wenn wir kein Wissen über das Verhältnis der Seitenlängen $a$ und $b$ haben, dann würden wir zunächst sagen, dass alle Verhältnisse $R = a/(a+b)$ gleichverteilt sind. Wir können dies auch als $R = 1/(1+b/a))$ umschreiben. Für $b/a \to 0$ ergibt sich für das Verhältnis $R = 1$, für $b/a \to \infty$ ergibt sich für das Verhältnis $R = 0$. Wir können somit anehmen, dass die Verhältnisse zwischen 0 und 1 gleichmäßig verteilt sind, wenn wir keine Vorkenntnisse haben. Umgekehrt,wenn wir nichts über die Fläche wissen, würden wir annehmen, dass alle Flächen gleichverteilt sind. Beide Priors sind in Abb. 12.6 dargestellt.

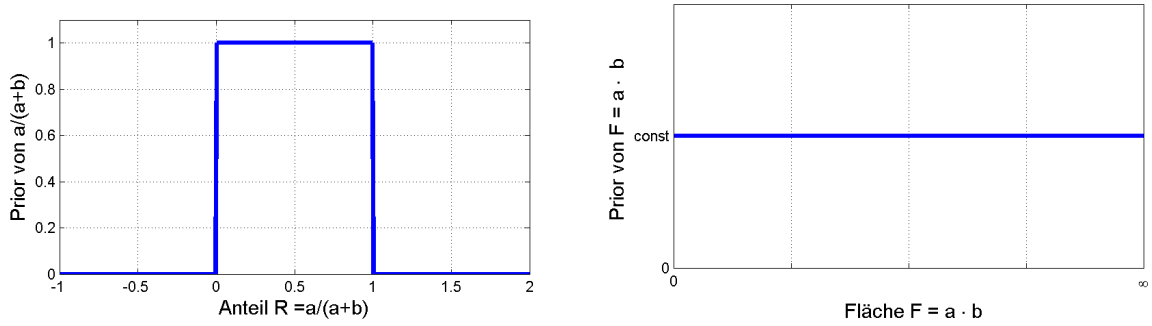



Abbildung 12.6: Plausible Priors für den Anteil $a/(a+b)$ und die Fläche $F = a \cdot b$. Beide Priors sind jedoch nicht konsistent zueinander.

Wenn nun der Anteil $R = 0$ ist, so muss auch die Fläche $F = 0$ sein. Wenn der Anteil $R = 1$ ist, so muss die Fläche $F = \infty$ sein. Bei $a = b$ ergibt sich ein Anteil $R = 0.5$. Wenn wir die Priorverteilung des Anteiles anschauen, so liegt der Anteil zu 50% zwischen 0 und 0.5. Dies würde auch bedeuten, dass 50% der Fläche zwischen $F = 0$ und $F = a^2 = b^2$ liegen müssten. Dies steht jedoch im Widerspruch zu der uniformen Annahme in Abb. 12.6. Hier sind nicht 50% der Fläche zwischen $[0, a^2 = b^2]$ und 50% zwischen $[a^2 = b^2, \infty]$. Somit haben wir hier einen Widerspruch. Deshalb hat sich hier Jeffrey [Hel08] etwas einfallen lassen, er schlägt für den Prior des Anteiles, eine Beta-Verteilung mit $\alpha = \beta = 0.5$ vor, wie sie Abb. 12.7 dargestellt ist. Nun haben wir in Abb.12.7 zwei in sich konsistente Prior-Verteilungen. Unwissenheit kann also nicht grundsätzlich durch eine uniforme Verteilung dargestellt werden [Tsc14].

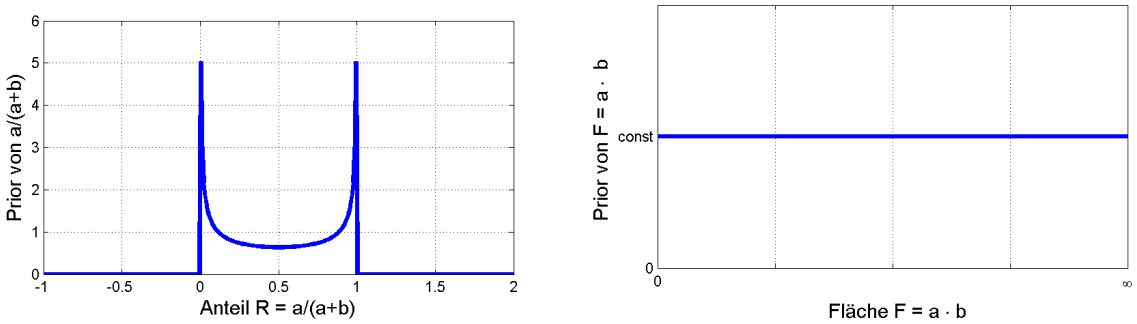



Abbildung 12.7: links: Jeffreys Prior für den Anteil $R = a/(a+b)$, eine Betaverteilung (0,5;0,5), rechts: Jeffreys Prior für den Erwartungswert einer normalverteilten Größe, hier ist dies die Fläche $F = a \cdot b$. Beide Priors sind jetzt konsistent zueinander.

Die Betaverteilung ist eine stetige Wahrscheinlichkeitsverteilung über dem Intervall $(0, 1)$. Die Beta-Verteilungsdichte ist definiert durch (siehe z.B. Wikipedia):

$$p(X) = \frac{1}{B(\alpha, \beta)} X^{\alpha-1}(1-X)^{\beta-1}.$$

Außerhalb des Intervalls $(0, 1)$ wird sie durch $p(X) = 0$ fortgesetzt. Für $\alpha, \beta \geq 1$ lässt sich $(0, 1)$ durch $[0, 1]$ ersetzen. Die Betaverteilung besitzt die reellen Parameter $\alpha$ und $\beta$. Um ihre Normierbarkeit zu garantieren, wird $\alpha, \beta > 0$ gefordert.

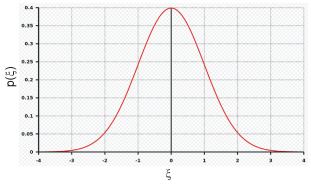
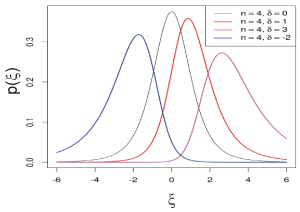
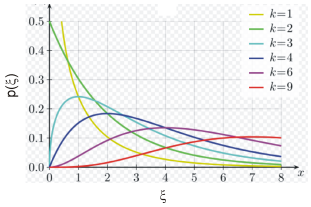
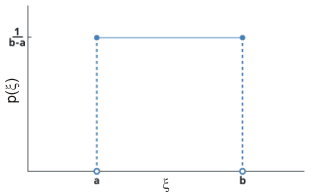
Der Vorfaktor $1/B(\alpha, \beta)$ dient der korrekten Normierung. Der Ausdruck

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \int_0^1 u^{\alpha-1}(1-u)^{\beta-1}\,\mathrm{d}u$$

steht für die Betafunktion, nach der die Verteilung benannt ist. Dabei bezeichnet $\Gamma$ die Gammafunktion.

Einige nützliche Priors sind beispielhaft in Tab.12.3 dargestellt.

Tabelle 12.3: Häufig verwendete Priors.

| Vorhandenes Vorwissen | PDF und Illustration | $x$ und $u(x)$ |
|---|---|---|
| Schätzwert $x$ und Standardunsicherheit $u(x)$ | Normal: $\mathcal{N}(x, u(x)^2)$  | $x$, $u(x)$ |
| Es sind schon vorhandene (historische) Werte bekannt. Der Erwartungswert und die Varianz ist jedoch unbekannt. | Skalierte und verschobene t-Verteilung $t_{n-1}(\bar{\xi}, s^2/n)$  | $x = \bar{\xi}$, $u(x) = \sqrt{\frac{n-1}{n-3}}\frac{s}{\sqrt{n}}$ |
| Kenntnisse über die Varianzen sind bekannt | $\mathcal{X}^2$  | $x$, $u(x)$ |
| Obere und untere Grenzen $a$, $b$ sind bekannt | Rechteck: $\mathcal{R}(a, b)$  | $x = \frac{a+b}{2}$, $u(x) = \frac{b-a}{\sqrt{12}}$ |

**Hinweise zur skalierten und verschobenen t-Verteilung als Prior**
(Wir bezeichnen hier die Anzahl der Beobachtungen mit $n$ und nicht mit $J$ um mit den Guides zur Bestimmung der Messunsicherheit konsistent zu sein, also statt $\xi_{i,1},\ldots,\xi_{i,J}$ verwenden wir hier $\xi_{i,1},\ldots,\xi_{i,n}$) Wenn angenommmen wird, dass wir aus $n$ Beobachtungen $\xi_{i,1},\ldots,\xi_{i,n}$, die aus einer Gauß- bzw. Normalverteilung (Erwartungswert und Varianz unbekannt) gezogen wurden und diese den Mittelwert $\bar{\xi}$ und die empirische Standardabweichung $s$ besitzt, so können wir eine mit der Varianz des Mittelwertes $s_i^2/n$ skalierte und um den Mittelwert $\bar{\xi}$ verschobene t-Verteilung mit $n-1$ Freiheitsgraden annehmen: $t_{n-1}(\bar{\xi}, s_i^2/n)$.

Der beste Schätzwert für $X$ und die dazugehörige Varianz, die die beste Schätzung für die Unsicherheit darstellt, sind

$$x = \bar{\xi}$$

$$u(x_i) = \left(\frac{n-1}{n-3}\right)^{1/2} \frac{s_i}{\sqrt{n}}$$

mit

$$s_i = \left[\frac{1}{n-1}\sum_{r=1}^{n}(\xi_{i,r} - \bar{\xi}_i)^2\right]^{1/2}$$

Eine Herleitung des Vorfaktors $\sqrt{\frac{n-1}{n-3}}$ ist z. B. in [Kac03] zu finden.

### 12.2.4 Posteriorverteilungen von Modellparametern

Wir geben hier ein paar Beispiele für Posterior-Verteilungen an:

**(a) Priorverteilung ist konstant und die Varianz $\sigma$ der Messdaten $X$ ist bekannt**

$$\text{Priorverteilung}: \qquad p(\theta) \sim U(-\infty, +\infty)$$

$$\text{Likelihood (siehe auch Gl.(12.9))}: \qquad l(\theta|X) \sim N(\bar{X}, \sigma^2/J) \propto \exp\left[-\frac{1}{2}\left(\frac{\theta - \bar{X}}{\sigma/\sqrt{J}}\right)^2\right]$$

$$\text{Posteriorverteilung}: \qquad p(\theta|X) \sim N(\bar{X}, \sigma^2/J)$$

**(b) Priorverteilung ist normalverteilt und die Varianz $\sigma$ der Messdaten $X$ ist bekannt**

$$\text{Priorverteilung}: \qquad p(\theta) \sim N(\theta_0, \sigma_0^2)$$

$$\text{Likelihood (siehe auch Gl.12.9)}: \qquad l(\theta|X) \sim N(\bar{X}, \sigma^2/J) \propto \exp\left[-\frac{1}{2}\left(\frac{\theta - \bar{X}}{\sigma/\sqrt{J}}\right)^2\right]$$

$$\text{Posteriorverteilung}: \qquad p(\theta|X) \sim N(\bar{\theta}, \bar{\sigma}^2)$$

mit dem Erwartungswert

$$\bar{\theta} = \frac{\sigma_0^2 \cdot \bar{X} + \frac{\sigma^2}{J} \cdot \theta_0}{\sigma_0^2 + \frac{\sigma^2}{J}}$$

und der Standardabweichung

$$\bar{\sigma}^2 = \frac{\sigma_0^2 \cdot \frac{\sigma^2}{J}}{\sigma_0^2 + \frac{\sigma^2}{J}}$$

**(a) Priorverteilung ist normalverteilt und die Varianz $\sigma^2$ der Messdaten $X$ ist unbekannt**
Ist die Varianz der Messgröße unbekannt, so muss die Varianz noch geschätzt werden, z. B. über die $\mathcal{X}^2$ -Verteilung.

## 12.3 MU-Bestimmung mittels Posterior aus Bayesansatz

### 12.3.1 Bayessche Intervallschätzung

Wie eine klassische Punktschätzung z.B. mit MLE oder LS, so sagt auch eine bayessche nicht aus, wie nahe der Schätzwert dem wahren Wert kommt. Doch auch hier kann man ein Intervall angeben, die den wahren Wert mit einer gewissen Wahrscheinlichkeit enthalten. Der üblichen Sprachregelung folgend bezeichnen wir die Intervalle der Bayes-Statistik nicht als *Vertrauens-* bzw. *Konfidenz-Intervalle* sondern als *Kredibilitätsintervalle*. (credibility: Glaubwürdigkeit, confidence: Vertrauen). Nicht weil das Wort credibility treffender wäre als das Wort confidence. Beide enstammen der Umgangssprache. Wir wählen den anderen Ausdruck, damit jederzeit klar wird, ob wir ein klassiches oder ein bayessches Intervall meinen. Der ISO-Guide verwendet den Begriff *Überdeckungsintervall, engl. coverage interval*, das das Intervall angibt, das die Menge der wahren Werte einer Messgröße mit einer angegeben Wahrscheinlichkeit enthält, auf der Grundlage der verfügbaren Information [VIM08]. (siehe zu den Begrifflichkeiten: Vertrauens-, Credible- und Überdeckungintervall auch die Ausführungen der 4. Vorlesung) Den Wahrscheinlichkeitswert, den ein credible interval einschließt, bezeichnen wir als Kredibilitätsniveau $\gamma$.

Beispiel: Symmetrische/ nichtsymmetrische Verteilungen

Bei symmetrischen Posterior-Verteilungen wird in der Regel das symmetrische Intervall genommen. So ist in Abb. 12.8 das 95%ige Intervall einer Normalverteilung $N(10, 4^2)$ dargestellt. Die untere und obere Grenze kann hier noch per Hand ausgerechnet werden. Mit $Z = (\theta - \mu)/\sigma$ (Standardisieren, siehe 3. Vorlesung). In der 3. Vorlesung haben die kummulierten Wahrscheinlichkeitsfunktionen mit $P(X) = \int_{-\infty}^{X} p(X')dX'$ bezeichnet. Im Falle der Standardnormalverteilung $\mathcal{N}(0, 1)$ bezeichnen wir diese hier mit $\Phi$. Die Quantile der rechtsseitigen Verteilungsfunktion sind im Anhang in der Tabelle dargestellt. Die gesuchte obere Grenze $\theta_{oG}$ des Intervalls erhalten wir durch:

$$\Phi\left(\frac{\theta_{oG} - \mu}{\sigma}\right) = 0.5 + 0.95/2 = 0.975$$

(Hinweis: beidseitiges Quantil: 95%, einseitiges Quantil 97.5%: )

In einer Quantiltabelle der Normalverteilung (Anhang Kapitel 13) kann der Wert 1.96 abgelesen werden. Wir erhalten damit:

$$\frac{\theta_{oG} - 10}{4} = 1.96 \rightarrow \theta_{oG} = 17.84 \rightarrow \theta_{uG} = 17.84 - 2 \cdot 7.84 = 2.16$$

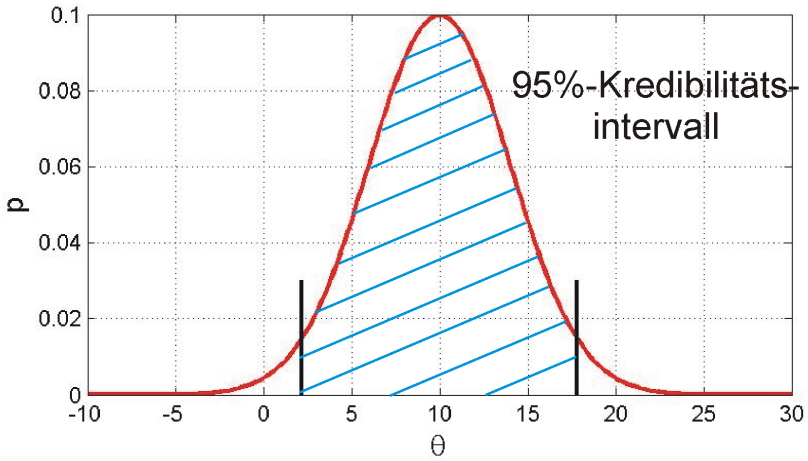



Abbildung 12.8: Bestimmung des Kredibilitätsintervalls der Posterior-Verteilung $N(10, 4^2)$für das Niveau $\gamma = 0.95$, untere Grenze: $\theta_{uG} = 2.16$, obere Grenze $\theta_{oG} = 17.84$

Bei nichtsymmetrischen Intervallen lassen sich unterschiedliche obere und untere Grenzen finden, die zum gleichen Kredibilitätsintervall gehören. Dies ist in Abb. 12.9 schematisch in dem Beispiel mit der $\mathcal{X}^2$-Verteilung mit $N = 10$ Freiheitsgraden dargestellt.

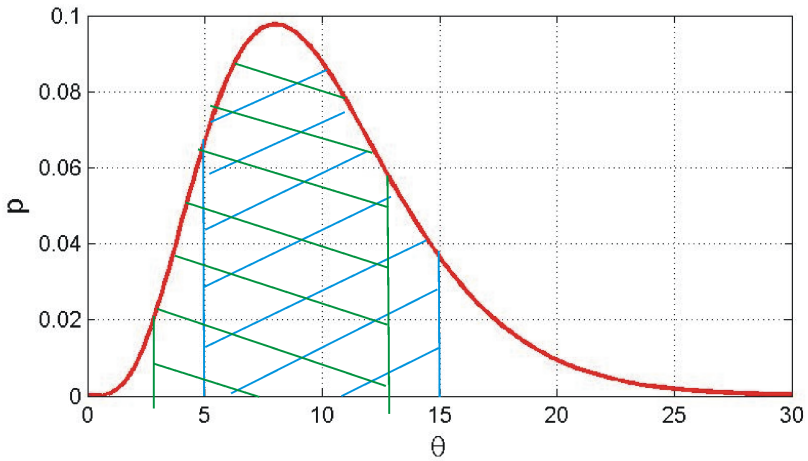



Abbildung 12.9: Bestimmung des Credible-Intervalls einer $\mathcal{X}^2$-Verteilung für $N = 10$ Freiheitsgrade. Der grün und blau schraffierte Bereich hat dasselbe Kredibilitätsniveau.

### 12.3.2 MU-Bestimmung mit der Bayesschen Statisktik

In der 9.Vorlesung werden wir den ISO-Guide 1995/2008 [GUM95] noch näher kennenlernen. Er basiert im Wesentlichen auf der klassischen Statistik und hat folgende Einschränkungen:

- Der ISO Guide verwendet keine Informationen über Wahrscheinlichkeitsverteilungen, die eventuell ja vorhanden sind. Es werden nur die Unsicherheiten fortgepflanzt jedoch keine Wahrscheinlichkeitsverteilungen.
- Das Messergebnis gibt keine vollständige Information wieder, da keine Wahrscheinlichkeitsver-

teilung angegeben wird.

- Die Fehlerfortpflanzung erfordert Sensitivitäten.

Der ISO-Guide ist dennoch heutzutage der Leitfaden zur Angabe der Messunsicherheit z.B. für Angabe der Messunsicherheit auf Kalibrierscheinen. Wenn die pdf der Messgröße $Y$ normalverteilt ist, hat das Überdeckungsintervall $[y \pm 2u(y)]$ eine Überdeckungswahrscheinlichkeit von 95.45% (siehe Tabelle G.2 im ISO-Guide [GUM95]). Bei anderen Verteilungen kann die Überdeckungswahrscheinlichkeit $p$ des Intervalls $[y \pm 2u(y)]$ kleiner oder größer sein. Der ISO-Guide (Abschnitt 2.3.5 und 6.3.2) schreibt, dass ohne Kenntnis der Verteilung auch keine Überdeckungswahrscheinlichkeiten bestimmt werden können. Schlussendlich schlägt der ISO-Guide jedoch dann vor, dass für die Messgröße $Y$ eine Normalverteilung oder eine skalierte und geschiftete Normalverteilung angenommen werden soll. Es wird dann vorgschlagen, dass die erweiterte Messunsicherheit $U_p = k_p u_c(y)$ ($u_c$: Kombinierte Standardunsicherheit) für ein Grad des Vertrauens $p$ (siehe Guide G 6.4) mit Hilfe der Welch-Satterthwaite Formel berechnet werden soll. Diese Formel bietet eine Näherung bei gemischten Verteilungen der Messgrößen $X_i$ (siehe 7. Vorlesung).

In der Bayesschen Statisitk wird die Standard-Unsicherheit vom Typ-A-Fehler nicht mehr als ein Schätzwert sondern als ein Parameter des Kenntnisstandes der pdf betrachtet. Es wird auch das Konzept der effektiven Freiheitsgrade nicht mehr benötigt. Die Typ-A-Unsicherheit wird anders ausgewertet. Es ergibt sich für die Standardunsicherheit $u(x_i) = \sqrt{(n-1)/(n-3)} \cdot s_i/\sqrt{n}$ [Kac03].

Den aktuellen Leitfaden ISO-Guide komplett auf die Bayes-Statistik umzuschreiben und für alle (z.B auch Kalibrierlaboratorien) verpflichtend einzuführen, fand keine Mehrheit. Dennoch ist es in vielen Fällen sinnvoller und richtiger die Messunsicherheitsbestimmung mit der Bayes-Statistik durchzuführen. Ziel der Bayesschen Statsistik ist es die PDF (probability density function) $p(Y|X)$ der Messgröße $Y$ zu bestimmen. Bestimmt man davon den Erwartungwert $y$, erhält man den besten Schätzwert für die Messgröße. Die Standardabweichung von $Y$ ergibt die zugeordnete Standardunsicherheit $u(y)$. Das Überdeckungsintervall (engl. *coverage integral*) wird dann aus der Posterior $p(Y|X)$ bestimmt. Der Erwartungswert der Posterior ist der beste Schätzer für die Messgröße Y:

$$E(Y) = y = \int_{-\infty}^{\infty} Y \; p(Y|X) \; dY$$

Die Varianz ist ein Maß für die Messunsicherheit:

$$u^2(y) =: \mathrm{Var}(Y) = E\left((y - E(Y)^2\right) \tag{12.21}$$

$$= \int_{-\infty}^{\infty} (y - Y)^2 \cdot p(Y|X) dY \tag{12.22}$$

Zur Bestimmung der Posterior kann wiederum das Bayes-Theorem angewendet werden.

$$p(Y|X) \propto l(Y|X) \cdot p(Y) \tag{12.23}$$

Anstelle der Likelihood $l(Y|X)$ wird häufig die bedingte Wahrscheinlichkeitsdichte $p(X|Y)$ geschrieben.

$$p(Y|X) \propto p(X|Y) \cdot p(Y)$$

Wir bezeichnen $p(Y)$ als die Prior-Wahrscheinlichkeit, $l(Y|X)$ Likelihood der Messdaten bzw. $p(X|Y)$ die Wahrscheinlichkeitsdichte der Messdaten und $p(Y|X)$ die gesuchte Posterior-Wahrscheinlichkeitsdichte. Oftmals ist es nicht möglich die Integrale analytisch zu lösen und es kommen numerische Integrationsmethoden zum Einsatz. Bei komplexen Modellen mit vielen Parametern sind numerische Verfahren mit gleichförmigem Raster zu kostspielig /langwierig. Für solche Fälle werden statistische Integrationsmethoden eingesetzt, bei denen die Positionen, an denen die zu integrierende Funktion auszurechnen ist, gewürfelt werden. Solche Methoden nennt man wegen des Auswürfelns, also des Verwendens von Pseudozufallszahlen, in Erinnerung an Spielcasinos Monte-Carlo-Methoden. Es gibt dazu unterschiedliche Strategien wie beispielsweise das Markov-Ketten-Monte-Carlo.

## 12.4 Regression mit Vorkenntnis (Prior)

Wir hatten klassisch die Regressionsrechnung nach der Methode der kleinsten Quadrate (*Least Squares*) berechnet, also Minimierung der Residuenquadrate

$$\min_{\theta} \left\{ \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} \right\} = \min_{\theta} \left\{ \left( \mathbf{Y}^\mathsf{T} \; - \; \boldsymbol{\theta}^\mathsf{T} \mathbf{X}^\mathsf{T} \right) \left( \mathbf{Y} \; - \; \mathbf{X} \boldsymbol{\theta} \right) \right\}$$

was äquivalent dem Maximieren der Likelihood ist

$$\max_{\theta} \left\{ e^{-\frac{1}{2\,\sigma_\varepsilon^2} (\mathbf{Y}^\mathsf{T} - \boldsymbol{\theta}^\mathsf{T} \mathbf{X}^\mathsf{T})(\mathbf{Y} - \mathbf{X}\boldsymbol{\theta})} \right\}. \tag{12.24}$$

Als Lösung erhielten wir:

$$\left( \mathbf{X}^\mathsf{T} \mathbf{X} \right) \hat{\boldsymbol{\theta}} = \mathbf{X}^\mathsf{T} \mathbf{Y}$$

Wir stellen uns vor, dass von einer vorherigen Messkampagne $\kappa - 1$ zu der gleichen Messaufgabe für alle Regressionparameter $\hat{\theta}_l^{(\kappa-1)}$ mit $l = 1, \ldots, M$ schon ein vollständiges Messergebnis mit

$$\begin{aligned} \hat{\theta}_l^{(\kappa-1)} \; = \; \boldsymbol{e}_l^\mathsf{T} \, \hat{\boldsymbol{\theta}}^{(\kappa-1)} \; = \; & \boldsymbol{e}_l^\mathsf{T} \left( \left( \mathbf{X}^{(\kappa-1)} \right)^\mathsf{T} \mathbf{X}^{(\kappa-1)} \right)^{-1} \left( \mathbf{X}^{(\kappa-1)} \right) \mathbf{Y}^{(\kappa-1)} \\ & \pm t_{1-\alpha/2,\nu^{(\kappa-1)}} \, \boldsymbol{e}_l^\mathsf{T} \left( \left( \mathbf{X}^{(\kappa-1)} \right)^\mathsf{T} \mathbf{X}^{(\kappa-1)} \right)^{-1} \boldsymbol{e}_l \; \left( \hat{\sigma}_\varepsilon^{(\kappa-1)} \right)^2 \end{aligned} \tag{12.25}$$

und

$$\rho_{l,m} \; = \; \frac{\left( \hat{\sigma}_\varepsilon^{(\kappa-1)} \right)^2}{\hat{\sigma}_l^{(\kappa-1)} \, \hat{\sigma}_m^{(\kappa-1)}} \, \boldsymbol{e}_l^\mathsf{T} \left( \left( \mathbf{X}^{(\kappa-1)} \right)^\mathsf{T} \mathbf{X}^{(\kappa-1)} \right)^{-1} \boldsymbol{e}_m \tag{12.26}$$

vorliegt, das wir mit neuen Informationen aus unserer neuen Messkampagne $\kappa$ *updaten* wollen.

Die Likelihood mit den Beobachtungen unserer aktuellen Kampagne ist

$$l(\boldsymbol{\theta}, \sigma_\varepsilon | \mathbf{Y}^{(\kappa)}) \; \propto \; e^{-\frac{1}{2\,\sigma_\varepsilon^2} \left( \mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)} \boldsymbol{\theta} \right)^\mathsf{T} \left( \mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)} \boldsymbol{\theta} \right)} \tag{12.27}$$

wobei die Regressanden $\mathbf{Y}^{(\kappa)}$ mit $\sigma_\varepsilon$ streuen, nicht aber die Regressoren $\mathbf{X}^{(\kappa)}$ und wobei die Modellparameter $\boldsymbol{\theta}$ und $\sigma_\varepsilon$ die zu schätzenden Größen sind.

Die Wahrscheinlichkeitsdichteverteilung der vorherigen Messkampagne $\kappa - 1$ ist

$$p_{\kappa-1}(\boldsymbol{\theta}|\hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \;\propto\; e^{-\frac{1}{2}\left(\boldsymbol{\theta}-\hat{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{\mathsf{T}}\left(\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{-1}\left(\boldsymbol{\theta}-\hat{\boldsymbol{\theta}}^{(\kappa-1)}\right)} \tag{12.28}$$

mit

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)} \;=\; \left(\left(\mathbf{X}^{(\kappa-1)}\right)^{\mathsf{T}}\,\mathbf{X}^{(\kappa-1)}\right)^{-1}\,\left(\hat{\sigma}_{\varepsilon}^{(\kappa-1)}\right)^{2}.$$

Die Likelihood wird im folgenden formal so aufgeschrieben, dass zu lesen ist, dass es die Wahrscheinlichkeitsdichteverteilung des Regressanden ist, gegeben die Parameter $\boldsymbol{\theta}$ und $\sigma_\varepsilon$

$$p_{\mathrm{L},\kappa}(\mathbf{Y}^{(\kappa)}|\boldsymbol{\theta}, \sigma_\varepsilon) \;\propto\; e^{-\frac{1}{2\,\sigma_\varepsilon^2}\left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)^{\mathsf{T}}\left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)}. \tag{12.29}$$

Wir sehen, dass dies an der Verteilung selber hier nichts verändert, sondern nur der Interpretation dient, ob man auf die Verteilung des Regressanden (der direkten Messgröße) guckt oder auf die Verteilung der Modellparameter (der indirekten Messgrößen).

Zur Schätzung der Modellparameter $\boldsymbol{\theta}$ und $\sigma_\varepsilon$ berechnen wir die Wahrscheinlichkeitsdichteverteilung als Funktion von $\boldsymbol{\theta}$ und $\sigma_\varepsilon$.

Bei der Methode der kleinsten Quadrate fiel das $\sigma_\varepsilon$ zunächst raus, so dass der Schätzvorgang nur für das $\boldsymbol{\theta}$ durchzuführen war und nach Erhalt der Schätzer $\hat{\boldsymbol{\theta}}$ für die Modellparameter $\boldsymbol{\theta}$ die entsprechende empirische Standardabweichung $\hat{\sigma}_\varepsilon$ ausgerechnet wurde.

Dass für die Likelihood und für die Verteilungsdichte der Parameter der vorherigen Messkampagne $\kappa - 1$ Normalverteilungen angesetzt wurden, bedeutet folgendes: Als à priori-Information wurde in das Modell die Voraussetzung hineingesteckt, dass

$$Y_j \;\sim\; \mathcal{N}(\boldsymbol{\theta}^{\mathsf{T}}\begin{pmatrix} 1 \\ X_{1,j} \\ \vdots \\ X_{M-1,j} \end{pmatrix}, \sigma_\varepsilon) \qquad \Leftrightarrow \qquad \varepsilon_j \;\sim\; \mathcal{N}(0, \sigma_\varepsilon) \tag{12.30}$$

und

$$\boldsymbol{\theta}^{(\kappa-1)} \;\sim\; \mathcal{N}(\hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}). \tag{12.31}$$

Für das $\sigma_\varepsilon$ setzen wir voraus, dass es $\chi^2$-verteilt sei

$$\nu\left(\frac{\sigma_\varepsilon}{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}\right)^2 \;\sim\; \chi^2_\nu \tag{12.32}$$

wobei wir für $\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}$ beispielsweise das Ergebnis für die lineare Regression ohne Berücksichtigung der vorherigen Messkampagne, also gemäß der im vorigen Kapitel beschriebenen Methode, verwenden.

Als Prior-Verteilungen haben wir nun zum einen die Verteilung aus der Erfahrung der vorherigen Messkampagne(n) $\kappa - 1$, Gl. (12.28) und zum anderen die Verteilung für $\sigma_\varepsilon$

$$p_{\chi^2}(\sigma_\varepsilon|\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \nu). \tag{12.33}$$

Die Posterior-Verteilung ist damit

$$\begin{aligned} & p_\kappa(\boldsymbol{\theta}, \boldsymbol{\Sigma}_{\boldsymbol{\theta}} | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \\ & \propto \; p_{\mathrm{L},\kappa}(\mathbf{Y}^{(\kappa)} | \boldsymbol{\theta}, \sigma_\varepsilon)\, p_{\chi^2}(\sigma_\varepsilon | \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \nu)\, p_{\kappa-1}(\boldsymbol{\theta} | \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}). \end{aligned} \tag{12.34}$$

Da in den $\mathbf{Y}^{(\kappa)}$ nur die Regressoren und die $\sigma_\varepsilon$ stecken

$$\boldsymbol{\Sigma}_{\boldsymbol{\theta}} \;=\; \left( \left( \mathbf{X}^{(\kappa)} \right)^{\mathsf{T}} \mathbf{X}^{(\kappa)} \right)^{-1} \sigma_\varepsilon^2$$

brauchen wir nicht das gesamte $\boldsymbol{\Sigma}_{\boldsymbol{\theta}}$ als Funktionsvariable, sondern lediglich $\sigma_\varepsilon$, so dass die Posterior nur noch Funktion von $\boldsymbol{\theta}$ und $\sigma_\varepsilon$ ist

$$\begin{aligned} & p_\kappa(\boldsymbol{\theta}, \sigma_\varepsilon | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \\ & \propto \; p_{\mathrm{L},\kappa}(\mathbf{Y}^{(\kappa)} | \boldsymbol{\theta}, \sigma_\varepsilon)\, p_{\chi^2}(\sigma_\varepsilon | \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \nu)\, p_{\kappa-1}(\boldsymbol{\theta} | \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}). \end{aligned} \tag{12.35}$$

Für das vollständige Messergebnis berechnen wir die Marginalverteilung als Funktion von $\boldsymbol{\theta}$, indem wir über $\sigma_\varepsilon$ integrieren

$$p_\kappa(\boldsymbol{\theta} | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \;=\; \int_0^\infty p_\kappa(\boldsymbol{\theta}, \sigma_\varepsilon | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\; \mathrm{d}\,\sigma_\varepsilon. \tag{12.36}$$

Dies ist eine Funktion von $M$ Variablen $\theta_1, \ldots, \theta_M$. Für die Wahrscheinlichkeitsdichten als Marginalverteilung je eines der Regressionsparameter wird über die anderen (numerisch) integriert

$$\begin{aligned} & p_\kappa(\theta_m | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \;= \\ & \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p_\kappa(\boldsymbol{\theta} | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\, \mathrm{d}\,\theta_1 \ldots \mathrm{d}\,\theta_{m-1}\; \mathrm{d}\,\theta_{m+1} \ldots \mathrm{d}\,\theta_M. \end{aligned} \tag{12.37}$$

Zur Berechnung der Erwartungswertes wird (numerisch) integriert

$$\mathrm{E}(\theta_m) \;=\; \int_{-\infty}^{\infty} \theta_m\, p_\kappa(\theta_m | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\; \mathrm{d}\,\theta_m. \tag{12.38}$$

Das *Credible Interval* wird ebenso mittels numerischer Verfahren berechnet

$$\alpha/2 \;=\; \int_{-\infty}^{\theta_{m,\min}} p_\kappa(\theta_m | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\; \mathrm{d}\,\theta_m \tag{12.39}$$

und

$$1 - \alpha/2 \;=\; \int_{-\infty}^{\theta_{m,\max}} p_\kappa(\theta_m | \mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\; \mathrm{d}\,\theta_m. \tag{12.40}$$

Für die Regressionsanalyse kann auch eine Möglichkeit gefunden werden, eine analytische Lösung zu erhalten, wenn anstelle der $\chi^2$-Verteilung für die $\sigma_\varepsilon$ eine Verteilung gewählt wird, so dass sich das Produkt aus Likelihood und einer alternativen Verteilung $p_\mathrm{a}(\sigma_\varepsilon)$ vereinfachen lässt, wie es in Klauenberg *et al.* dargelegt wird [Kla15].

Da $p_{\kappa-1}$ nicht von $\sigma_\varepsilon$ abhängt, gilt

$$\begin{aligned} & p_\kappa(\boldsymbol{\theta}|\mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \\ & \propto\ p_{\kappa-1}(\boldsymbol{\theta}|\hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}) \int_0^\infty p_{\mathrm{L},\kappa}(\mathbf{Y}^{(\kappa)}|\boldsymbol{\theta}, \sigma_\varepsilon)\ p_\mathrm{a}(\sigma_\varepsilon|\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \nu)\ \mathrm{d}\,\sigma_\varepsilon \end{aligned} \tag{12.41}$$

und mit einer vereinfachten Verteilung $p_\mathrm{a}(\sigma_\varepsilon)$

$$\int_0^\infty p_{\mathrm{L},\kappa}(\mathbf{Y}^{(\kappa)}|\boldsymbol{\theta}, \sigma_\varepsilon)\ p_\mathrm{a}(\sigma_\varepsilon|\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \nu)\ \mathrm{d}\,\sigma_\varepsilon\ \propto\ e^{-\frac{1}{2}\left(\frac{f(\nu)}{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}\right)^2 \left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)^\mathsf{T} \left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)} \tag{12.42}$$

mit $f(\nu)$ eine sich aus $p_\mathrm{a}$ ergebende Funktion der Anzahl der Freiheitsgrade.

Mit Gl. (12.28) bekommen wir

$$\begin{aligned} & p_\kappa(\boldsymbol{\theta}|\mathbf{Y}^{(\kappa)}, \hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}, \hat{\boldsymbol{\theta}}^{(\kappa-1)}, \hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)})\ \propto \\ & e^{-\frac{1}{2}\left(\boldsymbol{\theta}-\hat{\boldsymbol{\theta}}^{(\kappa-1)}\right)^\mathsf{T} \left(\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{-1} \left(\boldsymbol{\theta}-\hat{\boldsymbol{\theta}}^{(\kappa-1)}\right)}\ e^{-\frac{1}{2}\left(\frac{f(\nu)}{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}\right)^2 \left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)^\mathsf{T} \left(\mathbf{Y}^{(\kappa)} - \mathbf{X}^{(\kappa)}\boldsymbol{\theta}\right)} \end{aligned} \tag{12.43}$$

so dass die Schätzer für $\boldsymbol{\theta}$ und $\boldsymbol{\Sigma}_{\boldsymbol{\theta}}$ wie folgt aussehen

$$\begin{aligned} & \hat{\boldsymbol{\theta}}^{(\kappa)}\ = \\ & \left(\left(\frac{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}{f(\nu)}\right)^2 \left(\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{-1} + \left(\mathbf{X}^{(\kappa)}\right)^\mathsf{T} \mathbf{X}^{(\kappa)}\right)^{-1} \left(\left(\frac{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}{f(\nu)}\right)^2 \left(\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{-1} \boldsymbol{\theta}^{(\kappa-1)} + \left(\mathbf{X}^{(\kappa)}\right)^\mathsf{T} \mathbf{Y}^{(\kappa)}\right) \end{aligned} \tag{12.44}$$

und

$$\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa)}\ =\ \left(\left(\hat{\boldsymbol{\Sigma}}_{\boldsymbol{\theta}}^{(\kappa-1)}\right)^{-1} + \left(\mathbf{X}^{(\kappa)}\right)^\mathsf{T} \mathbf{X}^{(\kappa)} \left(\frac{f(\nu)}{\hat{\sigma}_\varepsilon^{(\kappa,\mathrm{R})}}\right)^2\right)^{-1} \tag{12.45}$$

siehe auch das von Kati Klauenberg mitverfasste Tutorial [Els15], das ausführlicher in der Beschreibung ist als ihre Publikation [Kla15] und auch beispielhaft Matlab-Skripte enthält.

## 12.5 Median einer Verteilung

Wir haben bisher den Erwartungswert einer Verteilung (1. statistisches Moment) und höhere Momente von Verteilungen (Varianz, Skewness, Kurtosis) kennengelernt, siehe 5. Vorlesung. Unter den symmetrischen Verteilungen unterscheiden wir:

- die Normalverteilung,
- die t-Verteilung, deren Ausläufer (*Tails*) um so ausgeprägter sind je kleiner die Anzahl der Freiheitsgrade ist,
- die Laplace-Verteilungen, die sehr lange Ausläufer hat. Sie setzt sich aus zwei aneinandergefügten Exponentialverteilungen zusammen, siehe 4. Vorlesung Gl.(6).

Für die Schätzung eines Modellparameters $\theta$ haben wir in der 2. Vorlesung die Methode der Maximum Likelihood kenengelernt („Finde den Parameter $\theta$, sodass die Likelihood maximal wird“). Diese Methode führt bei normalverteilten Größen zum Least Square (Minimierung der Residuen) und wird als *L2-Norm* bezeichnet.

Zuvor hatten wir gesehen wie die Maximierung der Likelihood $l(\theta) \propto e^{-\frac{1}{2}\sum_i \left(\frac{\varepsilon_i(\theta)}{\sigma}\right)^2}$ in die Minimierung der Summe der Quadrate der Residuen übergeht

$$\max_\theta \left\{ e^{-\frac{1}{2}\sum_i \left(\frac{\varepsilon_i(\theta)}{\sigma}\right)^2} \right\} \quad \Rightarrow \quad \min_\theta \left\{ -\log\left( e^{-\frac{1}{2}\sum_i \left(\frac{\varepsilon_i(\theta)}{\sigma}\right)^2} \right) \right\},$$

d.h.

$$\min_\theta \left\{ \sum_i \left( \frac{\varepsilon_i(\theta)}{\sigma} \right)^2 \right\}.$$

Mit $Q(\theta) := \sum_i \varepsilon_i(\theta)^2$ (Q: Qualitätsmaß, siehe Kapitel 2) bedeutet dies, dass das Qualitätsmaß bzw. gleichbedeutend die Varianz der Residuen minimiert wird

$$\min_\theta \left\{ \int_{-\infty}^{\infty} Q(\theta)\, l(\theta)\ \mathrm{d}\,\theta \right\}. \tag{12.46}$$

Analog lässt sich auch das Qualitätsmaß bezüglich der Posterior $p(\theta|X)$ für die bayes'sche Statistik minimieren:

$$\min_\theta \left\{ \int_{-\infty}^{\infty} Q(\theta)\, p(\theta|X)\ \mathrm{d}\,\theta \right\}. \tag{12.47}$$

Betrachte einen skalaren Modellparameter $\theta$ mit Schätzwert $\hat{\theta}$ und $\varepsilon = \theta - \hat{\theta}$, so dass

$$\min_\theta \left\{ \int_{-\infty}^{\infty} \varepsilon^2\, p(\theta|X)\ \mathrm{d}\,\theta \right\}. \tag{12.48}$$

Dabei ist $\int_{-\infty}^{\infty} \varepsilon^2\, p(\theta|X)\ \mathrm{d}\,\theta$ gleich dem Erwartungswert der Residuenquadrate, mit $\varepsilon = \theta - \hat{\theta}$

$$\int_{-\infty}^{\infty} \varepsilon^2\, p(\theta|X)\ \mathrm{d}\,\theta \ = \ E((\theta - \hat{\theta})^2)$$

Die erste Ableitung wird zu Null gesetzt:

$$\frac{\mathrm{d}\,\epsilon}{\mathrm{d}\,\hat{\theta}} = \frac{\mathrm{d}}{\mathrm{d}\,\hat{\theta}} \int_{-\infty}^{\infty} (\hat{\theta} - \theta)^2 p(\theta|X)\, \mathrm{d}\,\theta = 0 \tag{12.49}$$

$$2 \int_{-\infty}^{\infty} (\hat{\theta} - \theta) p(\theta|X)\, \mathrm{d}\,\theta = 0$$

Daraus folgt:

$$\hat{\theta} \int_{-\infty}^{\infty} p(\theta|X)\,\mathrm{d}\,\theta = \int_{-\infty}^{\infty} \theta p(\theta|X)\,\mathrm{d}\,\theta$$

Das linke Integral ist auf Grund der Normierungsbedingung $\int_{-\infty}^{\infty} p(\theta|X)d\theta = 1$. Es folgt somit:

$$\hat{\theta} = \int_{-\infty}^{\infty} \theta p(\theta|X)d\theta = E(p(\theta|X)) \tag{12.50}$$

Der Erwartungswert $E(p(\theta|X))$ der Posterior-Verteilung $p(\theta|X)$ ist derjenige Schätzwert $\hat{\theta}$, der die Residuen minimiert.Der Erwartungswert gibt den Schwerpunkt einer Verteilung an und wird als erstes statisches Moment bezeichnet (s. Kap. 5 im Skript).

Zur Behandlung von Beobachtungen, die nicht rein stochastischer Natur sind, sondern durch andere, nicht weiter modellierbare Einflüsse gegeben sind, wie z.B. mit einer größeren Wahrscheinlichkeit - als bei der Normalverteilung in den Ausläufern, wird beispielsweise auf die Laplaceverteilung zurückgegriffen werden. Die Maximum-Likelihood-Methode für die Laplace-Transformation führt auf die Minimierung der Absolutbeträge der Residuen (siehe 2. Vorlesung), d.h. $\sum |\epsilon| \rightarrow \min$. Man bezeichnet dies als die *L1-Norm*. Sie liefert den *Median*. Er ist definiert als das 0.5-Quantil $Q_{0.5}$. Ein Quantil $Q_\alpha$ ist ein Lagemaß in der Statistik (siehe 5. Vorlesung). So liegen beim 0.5-Quantil 50% der Verteilung unterhalb und 50% der Verteilung oberhalb des Quantils.

Wir schauen uns die Minimierung der Erwartungswert der absoluten Abweichung zwischen $\hat{\theta}$ und $\theta$, d.h.

$$\epsilon(\hat{\theta}) := E(|\hat{\theta} - \theta|) \quad \rightarrow \quad min.$$

mit

$$E(|\hat{\theta} - \theta|) \;=\; \int\limits_{-\infty}^{\infty} |\hat{\theta} - \theta| p(\theta|X)\,\mathrm{d}\,\theta$$

Das Minimum erhalten wir durch Differentiation $\mathrm{d}\,\epsilon / \mathrm{d}\,\hat{\theta} = 0$

$$\begin{aligned}
\frac{\mathrm{d}\,\epsilon}{\mathrm{d}\,\hat{\theta}} &= \frac{\mathrm{d}}{\mathrm{d}\,\hat{\theta}} \int\limits_{-\infty}^{\infty} |\hat{\theta} - \theta| p(\theta|X)\,\mathrm{d}\,\theta \\
&= \frac{\mathrm{d}}{\mathrm{d}\,\hat{\theta}} \left[ \int\limits_{-\infty}^{\hat{\theta}} (\hat{\theta} - \theta) p(\theta|X)\,\mathrm{d}\,\theta + \int\limits_{\hat{\theta}}^{\infty} (\theta - \hat{\theta}) p(\theta|X))d\theta \right] = 0
\end{aligned}$$

Mit der Leibnizschen Regel für Parameterintegrale leiten wir die Gleichung ab und erhalten:

$$\int_{-\infty}^{\hat{\theta}} p(\theta|X)\,\mathrm{d}\,\theta - \int_{\hat{\theta}}^{\infty} p(\theta|X))\,\mathrm{d}\,\theta = 0$$

Die Summe der beiden Integrale ist als Dichte-Integral gleich 1. Daraus folgt:

$$\int_{-\infty}^{\hat{\theta}} p(\theta|X)\,\mathrm{d}\,\theta = \int_{\hat{\theta}}^{\infty} p(\theta|X))\,\mathrm{d}\,\theta = 0.5$$

Somit ist $\hat{\theta}$ der Median bzw. das 50-Prozent-Quantil $Q_{0.5}$. Der Median ist ein gebräuchlicher Lageparameter. Er gibt an, welcher Wert auf der x-Achse die Wahrscheinlichkeitsdichte so trennt, dass links

und rechts des Medians jeweils die Hälfte der Wahrscheinlichkeit anzutreffen ist.

Der Median ist robust gegenüber langen „tails“ und kann für jede beliebige Posterior-Verteilung bestimmt werden.

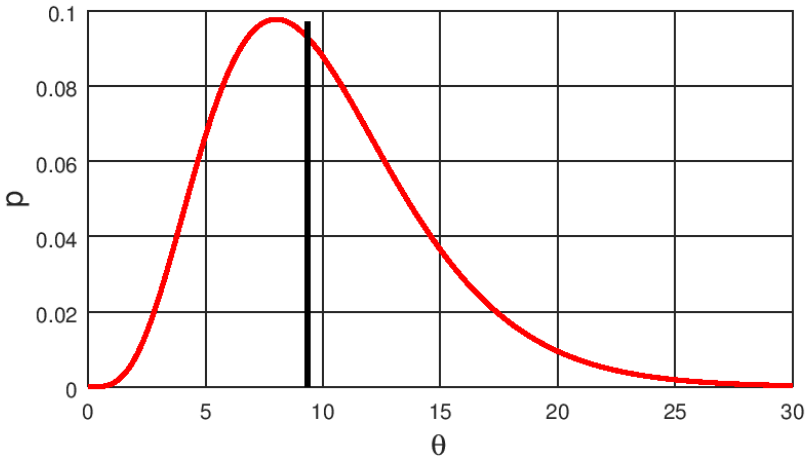



Abbildung 12.10: Beispiel für den Median, er entspricht hier nicht dem Maximum. Der Median ist definiert, so dass 50 % der Fläche unterhalb und 50 % der Fläche oberhalb des Medians liegen

Wesentliche Unterschiede zwischen der L1-und der L2-Norm sind in Tab. 12.4 aufgezählt.

Tabelle 12.4: Unterschiede zwischen L2- und L1-Norm

| **L2-Norm:**<br>**Minimierung der quadr. Abweichungen** | **L1-Norm:**<br>**Minimierung der Beträge** |
|---|---|
| Nicht sehr robust, z.B. gegenüber Ausreißer | robust, z.B. gegenüber langen „tails“ |
| stabile Lösung | instabile Lösung möglich |
| immer nur eine Lösung möglich | mehrere Lösungen möglich |

## 12.6 Übungsaufgaben

**Aufgabe 9-1: Likelihood des Erwartungswertes bei bekannter Varianz**

(a) Bestimmen Sie die Likelihood einer normalverteilten Zufallsgröße $X$, die sich aus $J$ unabhängigen Beobachtungen $X_1, \ldots, X_J$ ergibt. Die Varianz $\sigma^2$ der Zufallsgröße $X$ sei bekannt.

**Lösung zu 9-1(a)**
Die Likelihoodfunktion ist gegeben durch:

$$l(\theta|X) = \prod_{j=1}^{J} l(\theta|X_j)$$

Die Beobachtungen sind normalverteilt mit Erwartungswert $\hat{\theta}$ und Varianz $\sigma$. Es ergibt sich:

$$l(\theta|X) = \prod_{j=1}^{J} \frac{1}{\sqrt{(2\pi)}} e^{-\frac{1}{2}\left(\frac{X_j-\hat{\theta}}{\sigma}\right)^2}$$

Somit erhalten wir:

$$\begin{aligned}
l(\theta|X) &\propto \prod_{j=1}^{J} e^{-\frac{(X_j-\hat{\theta})^2}{2\sigma^2}} \\
&= e^{-\frac{\sum_{j=1}^{J}(X_j-\hat{\theta})^2}{2\sigma^2}} \\
&= e^{-\frac{\sum_{j=1}^{J}(X_j^2-2X_j\hat{\theta}+\hat{\theta}^2)}{2\sigma^2}} \\
&= e^{-\frac{\sum_{j=1}^{J}X_j^2-2(\sum_{j=1}^{J}X_j)\hat{\theta}+J\hat{\theta}^2}{2\sigma^2}} \\
&= e^{-\frac{\bar{X}^2-2\bar{X}\hat{\theta}+\hat{\theta}^2}{2\sigma^2/J}}
\end{aligned}$$

Die empirische Varianz $s^2$ ist gegeben durch:

$$\begin{aligned}
s^2 &= \tfrac{1}{J}\sum_{j=1}^{J}(X_i-\bar{X})^2 \\
&= \tfrac{1}{J}(\textstyle\sum_j X_j^2 - 2\sum_j X_j\bar{X} + \sum_j \bar{X}^2) \\
&= \bar{X}^2 - (\bar{X})^2
\end{aligned}$$

Damit erhalten wir für die Likelihood:

$$\begin{aligned} l(\theta|X) &\propto e^{-\frac{\bar{X}^2 + s^2 - 2\bar{X}\hat{\theta} + \hat{\theta}^2}{2\sigma^2/J}} \\ &= e^{-\frac{\bar{X}^2 - 2\bar{X}\hat{\theta} + \hat{\theta}^2}{2\sigma^2/J}} e^{-\frac{s^2}{2\sigma^2/J}} \\ &= e^{-\frac{(\bar{X} - \hat{\theta})^2}{2\sigma^2/J}} \cdot e^{-\frac{s^2}{2\sigma^2/J}} \end{aligned}$$

Da der Term

$$e^{-\frac{s^2}{2\sigma^2/J}} = \text{const.}$$

ist, geht dieser Term nur in die Normierung ein. Es folgt für die Likelihood der Stichproben:

$$l(\theta|X) = l(\theta|\bar{X}) \propto e^{-\frac{(\bar{X} - \hat{\theta})^2}{2\sigma^2/J}}$$

Der Stichprobenmittelwert $\bar{X}$ ist also normalverteilt mit dem Erwartungwert $\hat{\theta}$ und der Varianz $\sigma^2/J$ Hinweis / Ergänzug: Ist die Varianz von $X$ unbekannt, dann schätzen wir diese durch die empirische Varianz $s^2$ (klassische Statistik) Für annähernd große Stichproben geht die t-Verteilung in die Normalverteilung über und der Stichprobenmittelwert ist normalverteilt mit der Varianz $s^2/J$. Dann erhalten wir analog für die Likelihood des Mittelwertes:

$$l(\theta|\bar{X}) \propto e^{-\frac{(\bar{X} - \hat{\theta})^2}{2s^2/J}}$$

**Aufgabe 9-2: Bestimmung des Credible-Intervalls einer Posterior-Verteilung**
Sie wollen die Temperatur $T$ eines Laborraumes bestimmen. Da hier $T$ der zu bestimmende Parameter ist, bezeichnen wir diesen im Folgenden mit $\theta$. Aus Erfahrung wissen wir (wenn die Klimaanlage gerade nicht ausgefallen ist :-)), dass die Temperatur normalverteilt bei 20°C mit einer Steuung von 2°C ist. D.h. als Prior nehmen wir an $\theta \sim N(\mu = 20, \sigma^2 = 2^2)$. Zur genauen Bestimmung der Labortemperatur verwenden Sie nun einen Temperaturfühler, der einer Normalverteilung mit $N(20.5, 0.5^2)$ folgt.

(a) Bestimmen sie die Posteriorverteilung, wenn eine Stichprobe von 4 Messungen durchgeführt wird.

(b) Bestimmen Sie die obere und untere Grenze des 95%igen Credible-Intervall der Posterior-Verteilung.

**Lösung zu 9-2(a)** In der Vorlesung wurde gezeigt, dass wenn Priorverteilung und die Likelihood normalverteilt sind, auch die Posteriorverteilung normalverteilt ist. Die Likelihood bei 16 Stichproben ist normalverteilt mit $\sigma/\sqrt{(J)} = 0.5/\sqrt{4} = 0.25$

$$w_0 = \frac{1}{\sigma_0^2} = 1/2^2 = 0.25; w_1 = \frac{1}{\sigma_0^2/J} = 1/0.25^2 = 16;$$

$$\bar{\sigma}^2 = 1/(w_0 + w_1) = 0.062 \rightarrow \bar{\sigma} = 0.25$$

$$\bar{\theta} = \frac{1}{w_0 + w_1}(w_0\theta_0 + w_1 x) = \frac{1}{0.25 + 16}(0.25 \cdot 20 + 16 \cdot 20.5) = 20.49$$

Die Posterior ist also eine Normalverteilung mit $N(\bar{\theta} = 20.49, \bar{\sigma}^2 = 0.25^2)$. Das Vorwissen hat hier fast keinen Einfluss mehr auf die Posterior.

**Lösung zu 9-2(b)**
$N(20.49, 0.25^2)$ ist gegeben.

Mit $Z = (\theta - \mu)/\sigma$ (Standardisieren) und mit der rechtseitigen Verteilungsfunktion $\Phi$ erhält man die obere Grenze $\theta_{oG}$ durch:

$$\Phi\left(\frac{\theta_{oG} - \mu}{\sigma}\right) = 0.5 + 0.95/2 = 0.975$$

In einer Quantiltabelle der Normalverteilung (siehe Anhang Kapitel 13) kann der Wert 1.96 abgelesen werden. Wir erhalten damit:

$$\frac{\theta_{oG} - 20.49}{0.25} = 1.96 \rightarrow \theta_{oG} = 20.98 \rightarrow \theta_{uG} = 20.98 - 2 \cdot (20.98 - 20.49) = 20$$

## 12.7 Vergleich der klassischen mit der bayesischen Methode

Als nächstes wollen wir zeigen, dass für die „gutmütigen“ Fälle, für die das Gesetz der Messunsicherheitsfortpflanzung anwendbar ist, die Berechnung des vollständigen Ergebnisses unter Verwendung der Methode der bayesischen Statistik, deren Konzept wir in Abschnitt **??** vorgestellt haben, im wesentlichen dasselbe Resultat liefert wie unter Verwendung des Fortpflanzungsgesetzes.

Wir betrachten ein Beispiel, bei dem irgendeine physikalische Größe zu messen ist. Dabei werde ein Gerät bzw. Sensor verwendet, dessen Funktionsprinzip auf einem physikalischen Effekt beruht und dadurch die Größe so erfasst, dass als direkte Messgröße eine Spannung in Volt angezeigt wird. Dies kann beispielsweise die Messung einer Temperatur sein, in der das Phänomen, dass sich ein elektrischer Widerstand proportional zur Tempertur verändert und die Widerstandsänderung über die Änderung der elektrischen Spannung, die über dem Widerstand abfällt, bestimmt wird. Dies kann beispielsweise eine Stufenhöhe sein, die mit Hilfe eines induktiven Wegaufnehmers gemessen wird, der auf dem Phänomen beruht, dass sich die Induktivität einer Spule in Abhängigkeit von der Position ihres Ferritkerns verändert. Es sind viele Beispiele denkbar. Sensoren sind oft so konzipiert, dass sie ein physikalisches Phänomen nutzen und zur elektronischen Erfassung der zu messenden Größe als direkte Größe ein Messsignal in Form einer elektrischen Spannung liefern.

Wir wollen im folgenden ganz allgemein die indirekte Messgröße mit $Y$ bezeichnen und uns auf keine physikalische Einheit festlegen, sondern diese allgemein nur „Einheit“ nennen. Das Modell, das wir betrachten, ist wie folgt: Das rohe Messsignal, das als Spannung $U$ bzw. direkte Größe $X_\mathrm{M}$ vorliegt, ist über einen Kalibrierfaktor $K$ bzw. eine direkte Größe $X_\mathrm{K}$ in die physikalische Einheit der indirekten physikalischen Größe $Y$ umzurechnen. Der Index M steht hier für Messung und der Index K für Kalibrierfaktor.

Die indirekte Größe $Y$ habe irgendeine physikalische Einheit E

$$Y \;=\; f(X_\mathrm{K}, X_\mathrm{M}) \;=\; X_\mathrm{K}\, X_\mathrm{M} \tag{12.51}$$

und die beiden direkten Größen $X_\mathrm{M}$ und $X_\mathrm{K}$ sollen die Einheiten Volt V und $\frac{\mathrm{E}}{\mathrm{V}}$ haben.

Die Stichprobe der Beobachtungen zum rohen Messignal habe einen recht kleinen Umfang $J_\mathrm{M} = 9$:

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| $X_\mathrm{M}$/V | 479.58 | 526.47 | 516.77 | 522.01 | 506.61 | 497.99 | 481.71 | 484.90 | 491.41 |

Als vollständiges Messergebnis zum Kalibrierfaktor $X_\mathrm{K}$ liegen uns folgende Angaben vor

$$X_\mathrm{K} \;=\; (K_0 \pm U_\mathrm{K})\,\frac{\mathrm{E}}{\mathrm{V}} \;=\; (0.0925 \pm 0.0180)\,\frac{\mathrm{E}}{\mathrm{V}} \qquad \text{mit} \qquad k = 2 \quad \text{und} \quad \nu_\mathrm{K} = 45$$

Der Erweiterungsfaktor $k = 2$ ist der gerundete Wert für das t-Quantil für 95 % Vertrauensniveau $\nu_\mathrm{K} = 45$ Freiheitsgrade. Der genauere Wert wäre $k = 2.0141$, die Rundung ist hier zulässig.

Wir beleuchten den Fall, dass wir die dem Sensor intrinsische Unsicherheit nicht kennen, aber davon ausgehen, dass die Unsicherheit $\sigma_\mathrm{winzig}$ wesentlich kleiner ist als die Streuung der Messvorgänge beim Erfassen der Rohdaten und der Sensorkalibrierung. Die beruht auf der Annahme das sich der Sensor

linear verhält, also dass Linearitätsabweichungen vernachlässigbar klein sind. Der Ansatz ist

$$p(Y, X_\mathrm{K}, X_\mathrm{M} | (X_{\mathrm{M},1}, \ldots, X_{\mathrm{M},J}), K_0, s_\mathrm{K}) \propto$$
$$\underbrace{e^{-\frac{1}{2}\left(\frac{Y - X_\mathrm{K} X_\mathrm{M}}{\sigma_\mathrm{winzig}}\right)^2}}_{\text{Modellprior}} \underbrace{e^{-\frac{1}{2}\left(\frac{X_\mathrm{K} - K_0}{s_\mathrm{K}}\right)^2}}_{\text{Prior}} \underbrace{\prod_{j=1}^{J} e^{-\frac{1}{2}\left(\frac{X_\mathrm{M} - X_{\mathrm{M},j}}{s_\mathrm{M}}\right)^2}}_{\text{Likelihood}} \tag{12.52}$$

mit $\sigma_\mathrm{winzig} = 0.003 \cdot s_\mathrm{KM}$, mit $s_\mathrm{KM} = K_0\, s_\mathrm{M}$ und mit $s_\mathrm{K} = \frac{U_\mathrm{K}}{2} = 0.0090$. Wir verwenden zur Berechnung der Likelihood die empirische Standardabweichung der Daten zu $X_M$:

$$\bar{x}_\mathrm{M} = \frac{1}{9} \sum_{j=1}^{9} X_{\mathrm{M},j} = 500.83\,\mathrm{V}$$

und

$$s_\mathrm{M} = \sqrt{\frac{1}{\nu_\mathrm{M}} \sum_{j=1}^{9} (X_{\mathrm{M},j} - \bar{x}_\mathrm{M})^2} = 17.8927\,\mathrm{V} \approx 17.89\,\mathrm{V}$$

mit $\nu_\mathrm{M} = 8$ Freiheitsgraden, damit also $K_0\, s_\mathrm{M} = s_\mathrm{KM} = 1.655\,\mathrm{E}$ und entsprechend für $\sigma_\mathrm{winzig} = 0.00497$. Da die Stichprobenwerte der Größe $X_\mathrm{M}$ in der Tabelle mit 2 Nachkommastellen angegeben werden, wird das Ergebnis auch auf 2 Stellen gerundet.

Wir bestimmen den Schätzer und das Überdeckungsintervall im folgenden zum einen aus der Unsicherheitsfortpflanzung gemäß (10.5) und zum anderen aus der Marginalverteilung zu Gl. (12.52):

$$p(Y | (X_{\mathrm{M},1}, \ldots, X_{\mathrm{M},J}), K_0, s_\mathrm{K}) =$$
$$\frac{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}\left(\frac{Y - X_\mathrm{K} X_\mathrm{M}}{\sigma_\mathrm{winzig}}\right)^2} e^{-\frac{1}{2}\left(\frac{X_\mathrm{K} - K_0}{s_\mathrm{K}}\right)^2} \prod_{j=1}^{J} e^{-\frac{1}{2}\left(\frac{X_\mathrm{M} - X_{\mathrm{M},j}}{s_\mathrm{M}}\right)^2} \,\mathrm{d}X_\mathrm{M}\,\mathrm{d}X_\mathrm{K}}{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}\left(\frac{Y - X_\mathrm{K} X_\mathrm{M}}{\sigma_\mathrm{winzig}}\right)^2} e^{-\frac{1}{2}\left(\frac{X_\mathrm{K} - K_0}{s_\mathrm{K}}\right)^2} \prod_{j=1}^{J} e^{-\frac{1}{2}\left(\frac{X_\mathrm{M} - X_{\mathrm{M},j}}{s_\mathrm{M}}\right)^2} \,\mathrm{d}X_\mathrm{M}\,\mathrm{d}X_\mathrm{K}\,\mathrm{d}Y} \tag{12.53}$$

Wir erhalten den Schätzwert $\bar{y}$ aus

$$\bar{y} = \int_{-\infty}^{\infty} Y\, p(Y | (X_{\mathrm{M},1}, \ldots, X_{\mathrm{M},J}), K_0, s_\mathrm{K})\,\mathrm{d}Y \tag{12.54}$$

und für die Bestimmung der Intervallgrenzen $y_1, y_2$ für das Überdeckungsintervall berechnen wir die kumulierte Verteilung

$$P(Y) = \int_{-\infty}^{Y} p(Y' | (X_{\mathrm{M},1}, \ldots, X_{\mathrm{M},J}), K_0, s_\mathrm{K})\,\mathrm{d}Y' \tag{12.55}$$

und dann für 95% Wahrscheinlichkeit

$$P(y_1) = 0.025 \Leftrightarrow y_1 = P^{-1}(0.025) \qquad \text{und} \qquad P(y_2) = 0.975 \Leftrightarrow y_2 = P^{-1}(0.975). \tag{12.56}$$

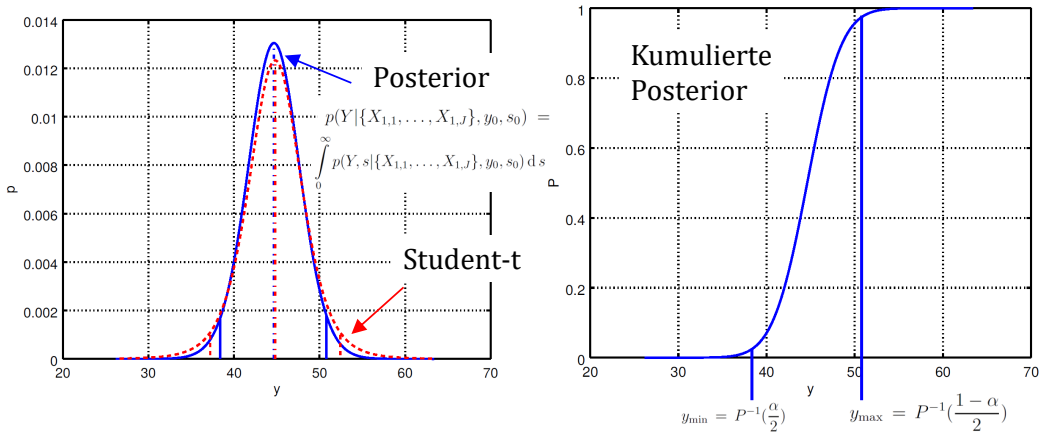



Abbildung 12.11: Wahrscheinlichkeitsdichtefunktionen und kumulierte Posterior für die Bestimmung des Überdeckungsintervalls einer indirekten Messgröße

Durch numerische Integration der Gl. (12.54) erhalten wir

$$\bar{y} \;=\; 46.278\,\mathrm{E}$$

und für das *Credible Interval* durch numerische Integration von Gl. (12.55)

$$[36.855\,\mathrm{E}, 56.185\,\mathrm{E}] \;=\; [\bar{y} - 9.423, \bar{y} + 9.907]\,\mathrm{E}$$

und vergleichen dieses Ergebnis mit dem Ergebnis, das wir auf dem klassischen Wege erhalten. Zunächst berechnen wir das Produkt der beiden Werte $\bar{x}_\mathrm{M} = 500.83\,\mathrm{V}$ und $K_0 = 0.0925\,\frac{\mathrm{E}}{\mathrm{V}}$. Wir erhalten mit

$$\bar{y} \;=\; K_0\,\bar{x}_\mathrm{M} \;=\; 46.327\,\mathrm{E}$$

einen Schätzwert für $Y$, der um einen Wert von $0.049\,\mathrm{E}$ also um 1 Promille von dem aus der bayesischen Berechnung differiert.

In Anhang 12.8 befindet sich das Gnu-Octave/Matlab-Skript, mit dem die Berechnungen zu diesem Beispiel durchgeführt wurden.

Als nächstes vergleichen wir das *Credible Interval* mit dem Vertrauensintervall. Dazu bestimmen wir die Unsicherheit mit dem Fortpflanzungsgesetz für unkorrelierte direkte Messgrößen.

Wir berechnen für $\rho_{\mathrm{M,K}} = 0$

$$u^2(Y) \;=\; \left(\frac{\partial}{\partial X_\mathrm{M}} X_\mathrm{M} X_\mathrm{K}\right)^2_{\bar{x}_\mathrm{M}, K_0} s^2_\mathrm{M} \;+\; \left(\frac{\partial}{\partial X_\mathrm{K}} X_\mathrm{M} X_\mathrm{K}\right)^2_{\bar{x}_\mathrm{M}, K_0} s^2_\mathrm{K}$$

d.h.

$$u(Y) \;=\; \sqrt{K_0^2\,s^2_\mathrm{M} \;+\; \bar{x}^2_\mathrm{M}\,s^2_\mathrm{K}} \;=\; 4.802\,\mathrm{E}.$$

Die Anzahl der Freiheitsgrade berechnen wir gemäß der Satterthwaite'schen Gleichung (10.82), also

$$\frac{u(Y)^4}{\nu_y} \;=\; \frac{K_0^4\, s_{\mathrm{M}}^4}{\nu_{\mathrm{M}}} \;+\; \frac{\bar{x}_{\mathrm{M}}^4\, s_{\mathrm{K}}^4}{\nu_{\mathrm{K}}}$$

d.h. mit $\nu_{\mathrm{K}} = 45$, $\nu_{\mathrm{M}} = 8$ und mit $K_0 = 0.0925\,\frac{\mathrm{E}}{\mathrm{V}}$, $s_{\mathrm{K}} = 0.009\,\frac{\mathrm{E}}{\mathrm{V}}$, $\bar{x}_{\mathrm{M}} = 500.83\,\mathrm{V}$, $s_{\mathrm{M}} = 17.89\,\mathrm{V}$

$$\nu_y \;=\; u(Y)^4 \left( \frac{K_0^4\, s_{\mathrm{M}}^4}{\nu_{\mathrm{M}}} \;+\; \frac{\bar{x}_{\mathrm{M}}^4\, s_{\mathrm{K}}^4}{\nu_{\mathrm{K}}} \right)^{-1} \;=\; 52.58 \;\approx\; 52$$

Die Anzahl der Freiheitsgrade kann auf ganzzahlige Werte abgerundet werden, das heißt die Nachkommastellen unterdrückt werden, siehe GUM JCGM 100:2008, Seite 73:

> NOTE 1 If the value of $\nu_{\mathrm{eff}}$ obtained from Equation (G.2b) is not an integer, which will usually be the case in practice, the corresponding value of $t_{\mathrm{p}}$ may be found from Table G.2 by interpolation or by truncating $\nu_{\mathrm{eff}}$ to the next lower integer.

```
>> tinv(0.975,52)
ans =  2.0066
>> tinv(0.975,52.58)
ans =  2.0061
```

Wir verwenden für das t-Quantil (den Erweiterungsfaktor) den Wert $k = 2.006$, in der Praxis nimmt man dann auch einfach $k = 2$. Gemäß GUM kann die Formel für die effektive Anzahl von Freiheitsgraden also auch wie folgt geschrieben werden

$$\nu_y \;=\; \lfloor u(Y)^4 \left( \sum_{i=1}^{N} \frac{(c_i\, s_i)^4}{\nu_i} \right)^{-1} \rfloor \tag{12.57}$$

wobei die beiden Symbole $\lfloor r \rfloor$ um die Variable $r$ geschrieben heißen, dass die Nachkommastellen von $r$ abzuschneiden sind, was in vielen Programmiersprachen mit der Funktion `floor` erfolgt.

Das Vertrauensintervall wird damit schließlich

$$[36.691\,\mathrm{E}, 55.962\,\mathrm{E}]$$

und das vollständige Messergebnis

$$Y \;=\; (46.327 \pm 9.635)\,\mathrm{E}.$$

Der Wert für die erweiterte Unsicherheit $U = 9.635\,\mathrm{E}$ entspricht also in etwa dem Mittelwert aus den Berechnungen aus dem bayesischen Ansatz $\frac{1}{2}(9.423 + 9.907) = 9.665$. Abb. 12.11 zeigt das Prinzip anhand eines ähnlichen Beispiels, die eingezeichneten Werte liegen weiter auseinander, um die Intervalle besser einzeichnen zu können.

Für Größen, deren Messunsicherheit nicht unmittelbar aus vorliegenden Stichproben gewonnen wurde, so dass Stichprobenumfang und Verteilungen nicht ermittelt werden können, wird auf Basis heuristischer Vorstellungen eine Abschätzung der Anzahl der Freiheitsgrade vorgenommen.

In Fällen, bei denen es um Präzisionsmessungen geht, kann vielfach angenommen werden, dass die Anzahl der Freiheitsgrade gegen unendlich konvergiert.

$$\lim_{\nu_i \to \infty} \left\{ \frac{(c_i\, s_i)^4}{\nu_i} \right\} \;=\; 0 \tag{12.58}$$

Dies ist in Anhang G, Absatz G.4.3 des GUM JCGM 100:2008 nachzulesen. Lässt sich nicht voraussetzen, dass die Anzahl der Freiheitsgrade sehr, sehr groß ist, so wird diese abgeschätzt. Wie bei der Satterthwaite-Gleichung selbst, wird auch hier die Varianz der Varianz

$$\nu \;\sim\; \frac{\sigma_i^2}{\mathrm{Var}(s_i)} \tag{12.59}$$

betrachtet, siehe GUM Anhang G, Absatz G.4.2. Die Zuverlässigkeit der als à-priori Information mitgeteilten Unsicherheit muss abgeschätzt werden mit einem bestimmten Prozentsatz $(1-\alpha)\cdot 100\,\%$. Daraus wird heuristisch in Anlehnung an den Zusammenhang (12.59) die Anzahl der Freiheitsgrade abgeschätzt mit

$$\nu \;\approx\; \frac{1}{2\alpha^2}. \tag{12.60}$$

Der Quotient $\alpha$ wird als relative Unsicherheit $\frac{\Delta u}{u}$ der Unsicherheit $u$ interpretiert.

Nachdem wir gesehen haben, wie handlich die Berechnungen mit der klassischen Fortpflanzung gegenüber den Methoden mit den Wahrscheinlichkeitsdichteverteilungen ist, fragt man sich natürlich, weshalb wir den numerischen Aufwand mit dem Berechnen der Integrale der Wahrscheinlichkeitsdichteverteilungen betreiben. Für dieses kleine, handliche und anschauliche Beispiel ist dies selbstverständlich nicht gerechtfertigt. Es dient lediglich dazu, das Grundprinzip des Verfahrens zu verdeutlichen.

Bei den Aufgaben, für die die Voraussetzungen zur Berechnung der Unsicherheit einer indirekten Messgröße gemäß Gl. (10.5) nicht mehr gegeben sind, werden die Verfahren mit Rechnen mit Wahrscheinlichkeitsdichteverteilungen eingesetzt. Dies sind Verfahren die entweder auf der Multiplikation von Likelihoodverteilungen - letztlich auf Monte-Carlo-Berechnungen gemäß dem JCGM 101-Dokument der GUM-Reihe - oder auf der bayesischen Statistik basieren. Die Multiplikation von Likelihoodverteilungen setzt im Gegensatz zur bayesischen Statistik eine *scharfe* „Verteilung“ für die Modellfunktion ein. Dabei wird hier mit dem Begriff *scharfe* Verteilung eine Wahrscheinlichkeitsdichte bezeichnet, die als Normalverteilung mit dem Grenzübergang für $\sigma_{\mathrm{winzig}} \to 0$ in eine dirac'sche Deltafunktion übergeht. Den Begriff „Verteilung“ setzen wir hier in Anführungsstriche, weil so eine dirac'sche Deltafunktion der Grenzfall ist, bei dem die Verteilung keine Verteilung mehr ist, weil die Werte scharf und nicht mehr verteilt sind.

Bei dem Beispiel (mit Gun-Octave/matalb-Skript in Anhang 12.8) haben wir die numerischen Integrationen in sehr schlichter Weise dadurch realisiert, dass wir die betreffenden Größen in ein Raster äquidistanter Stützstellen diskretisiert haben und dann einfach summiert haben. Es sollte hiermit nur das Grundprinzip der Verfahren der *kolmogoroff'schen Wahrscheinlichkeitsrechnung* aufzeigen, die auch die Basis für die Methoden der *bayesischen Statistik* bildet.

In vielen Fällen ist es aber nicht angesagt, beim numerischen Integrieren so zu verfahren. Das nächste Kapitel soll deshalb einen kurzen Überblick über unterschiedliche Verfahren zur numerischen Integration liefern.

## 12.8 Anhang: Beispiel indirekte Größe aus Produkt zweier direkter Größen

Gnu-Octave Code zu dem Beispiel aus Abschnitt 12.7

```
function bayes_indirect_quantity_product()
%  Kalibrierfaktor
  K_faktor_0 = 0.0925;
  sigma_K = 0.0090;
%
%
  JM = 9;
  sig = 12;
  mue = 500;
  data_M = [479.58; 526.47; 516.77; 522.01; 506.61; 497.99; 481.71; 484.90; 491.41];
%
%
  xK = [-4*sigma_K:0.005:4*sigma_K] + K_faktor_0;
  nK = length(xK)
  xM = [-4*sig:0.05:4*sig] + mue;
  nM = length(xM)
  y = [25:0.005:65];
  nY = length(y)
%
  std_M = std(data_M);
  std_KM = K_faktor_0 * std_M;
  printf('s_M = %1.4f, s_KM = %1.4f\n', std_M, std_KM);
%
% Messungen in Volt
  XM = data_M * ones(1,nM) - ones(JM,1) * xM;
%
% Das Modell: y = f(xK, xM)
% fuer jedes xK und jedes xM kombiniert
% y_{KM,i,j} = xK_i * xM_j fuer alle i=1,..,nK und j=1,..,nM
  y_KM_matrix = xK' * xM;
%  in einen langen Spaltenvektor gebracht
  y_KM = y_KM_matrix(:);
  nKM = length(y_KM);
  delta_y = y_KM * ones(1,nY) - ones(nKM, 1)*y;
%
% direkte Groessen
% Kalibrierfaktor
  p_K = exp(-0.5 * ( (xK - K_faktor_0)/sigma_K ).^2 );
  p_K = p_K / sum(p_K);
```

```
% Messungen: Likelihood
  p_M_matrix = exp(-0.5 * ( XM/std_M ).^2 );
% Summe ueber alle Messungen
  p_M_2 = sum( p_M_matrix );
  p_M_2 = p_M_2 / sum(p_M_2);
%
  p_KM_matrix = p_K' * p_M_2;
%  in einen langen Spaltenvektor gebracht
  p_KM_2 = p_KM_matrix(:);
%
% Modellprior
  p_y2 = exp(-0.5 * ( delta_y/(std_KM*0.003) ).^2 );
% Posterior
  post_matrix = p_y2 .* (p_KM_2 * ones(1,nY));
% Normierung des Posteriors
  sumpost = sum(post_matrix(:));
  post_matrix = post_matrix/sumpost;
%
% Marginalverteilung durch Summation ueber xM, xK
  posterior3 = sum(post_matrix);
%
% kumulative Marginale-PDF also die CDF
  cdf3 = cumsum(posterior3);
%
  figure(200);
  plot( y, cdf3, 'b-', 'linewidth', 2);
  xlabel('indirekte Groesse / Einheit', 'fontsize', 14);
  ylabel('cdf', 'fontsize', 14);
  set(gca, 'fontsize', 12);
%
% Ergebnis
  y_bar = sum( y.*posterior3 );
  [dmy, imin] = min( abs(cdf3-0.025) )
  y1 = y(imin);
  [dmy, imin] = min( abs(cdf3-0.975) )
  y2 = y(imin);
  printf('Credible interval = [%1.4f, %1.4f]\n', y1, y2);
  printf('y_bar = %1.4f + (%1.4f) + (%1.4f)\n', y_bar, y1-y_bar, y2-y_bar);
% ----
% Vergleich mit Fortpflanzungsgesetz
% ----
  xMbar = mean(data_M);
  printf('mean(X_M): %1.4f\n', xMbar);
  printf('s_M = %1.4f, s_KM = %1.4f\n', std_M, std_KM);
```

```
84   u = sqrt((K_faktor_0*std_M)^2 + (xMbar*sigma_K)^2);
85   printf('u(Y) = %1.4f\n',u);
86   hlp = (K_faktor_0*std_M)^4/8 + (xMbar*sigma_K)^4/45;
87   nu_eff = u^4/hlp
88   t = tinv(0.975,floor(nu_eff))
89   printf('U = %1.5f \n', t*u);
90   printf('ymean = %1.3f, [%1.3f,%1.3f]\n', ...
91     K_faktor_0*xMbar, K_faktor_0*xMbar-t*u,K_faktor_0*xMbar+t*u);
92 end
```

Kapitel 13

# Anhang: Quantiltabellen

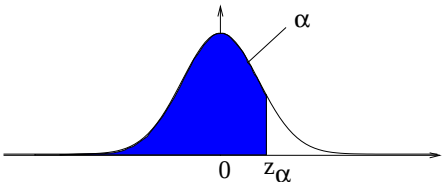
## 13.1 Quantile der Normalverteilung

### Quantile $z_\alpha$ der Standardnormalverteilung $N(0,1)$

Ablesebeispiel: $z_{0.95} = 1.6449$.

Erweiterung der Tafel: $z_{1-\alpha} = -z_\alpha$

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-z^2/2} \mathrm{d}z \quad \text{Verteilungsfunktion}$$




| $\alpha$ | $z_\alpha$ | $\alpha$ | $z_\alpha$ | $\alpha$ | $z_\alpha$ | $\alpha$ | $z_\alpha$ |
|---|---|---|---|---|---|---|---|
| 0.9999 | 3.7190 | 0.9955 | 2.6121 | 0.975 | 1.9600 | 0.780 | 0.7722 |
| 0.9998 | 3.5401 | 0.9950 | 2.5758 | 0.970 | 1.8808 | 0.770 | 0.7388 |
| 0.9997 | 3.4316 | 0.9945 | 2.5427 | 0.965 | 1.8119 | 0.760 | 0.7063 |
| 0.9996 | 3.3528 | 0.9940 | 2.5121 | 0.960 | 1.7507 | 0.750 | 0.6745 |
| 0.9995 | 3.2905 | 0.9935 | 2.4838 | 0.955 | 1.6954 | 0.740 | 0.6433 |
| 0.9994 | 3.2389 | 0.9930 | 2.4573 | 0.950 | 1.6449 | 0.730 | 0.6128 |
| 0.9993 | 3.1946 | 0.9925 | 2.4324 | 0.945 | 1.5982 | 0.720 | 0.5828 |
| 0.9992 | 3.1559 | 0.9920 | 2.4089 | 0.940 | 1.5548 | 0.710 | 0.5534 |
| 0.9991 | 3.1214 | 0.9915 | 2.3867 | 0.935 | 1.5141 | 0.700 | 0.5244 |
| 0.9990 | 3.0902 | 0.9910 | 2.3656 | 0.930 | 1.4758 | 0.690 | 0.4959 |
| 0.9989 | 3.0618 | 0.9905 | 2.3455 | 0.925 | 1.4395 | 0.680 | 0.4677 |
| 0.9988 | 3.0357 | 0.9900 | 2.3263 | 0.920 | 1.4051 | 0.670 | 0.4399 |
| 0.9987 | 3.0115 | 0.9895 | 2.3080 | 0.915 | 1.3722 | 0.660 | 0.4125 |
| 0.9986 | 2.9889 | 0.9890 | 2.2904 | 0.910 | 1.3408 | 0.650 | 0.3853 |
| 0.9985 | 2.9677 | 0.9885 | 2.2734 | 0.905 | 1.3106 | 0.640 | 0.3585 |
| 0.9984 | 2.9478 | 0.9880 | 2.2571 | 0.900 | 1.2816 | 0.630 | 0.3319 |
| 0.9983 | 2.9290 | 0.9875 | 2.2414 | 0.895 | 1.2536 | 0.620 | 0.3055 |
| 0.9982 | 2.9112 | 0.9870 | 2.2262 | 0.890 | 1.2265 | 0.610 | 0.2793 |
| 0.9981 | 2.8943 | 0.9865 | 2.2115 | 0.885 | 1.2004 | 0.600 | 0.2533 |
| 0.9980 | 2.8782 | 0.9860 | 2.1973 | 0.880 | 1.1750 | 0.590 | 0.2275 |
| 0.9979 | 2.8627 | 0.9855 | 2.1835 | 0.875 | 1.1503 | 0.580 | 0.2019 |
| 0.9978 | 2.8480 | 0.9850 | 2.1701 | 0.870 | 1.1264 | 0.570 | 0.1764 |
| 0.9977 | 2.8338 | 0.9845 | 2.1571 | 0.865 | 1.1031 | 0.560 | 0.1510 |
| 0.9976 | 2.8202 | 0.9840 | 2.1444 | 0.860 | 1.0803 | 0.550 | 0.1257 |
| 0.9975 | 2.8070 | 0.9835 | 2.1321 | 0.855 | 1.0581 | 0.540 | 0.1004 |
| 0.9974 | 2.7944 | 0.9830 | 2.1201 | 0.850 | 1.0364 | 0.530 | 0.0753 |
| 0.9973 | 2.7821 | 0.9825 | 2.1084 | 0.845 | 1.0152 | 0.520 | 0.0502 |
| 0.9972 | 2.7703 | 0.9820 | 2.0969 | 0.840 | 0.9945 | 0.510 | 0.0251 |
| 0.9971 | 2.7589 | 0.9815 | 2.0858 | 0.835 | 0.9741 | 0.500 | 0.0000 |
| 0.9970 | 2.7478 | 0.9810 | 2.0749 | 0.830 | 0.9542 | | |
| 0.9969 | 2.7370 | 0.9805 | 2.0642 | 0.825 | 0.9346 | | |
| 0.9968 | 2.7266 | 0.9800 | 2.0537 | 0.820 | 0.9154 | | |
| 0.9967 | 2.7164 | 0.9795 | 2.0435 | 0.815 | 0.8965 | | |
| 0.9966 | 2.7065 | 0.9790 | 2.0335 | 0.810 | 0.8779 | | |
| 0.9965 | 2.6968 | 0.9785 | 2.0237 | 0.805 | 0.8596 | | |
| 0.9964 | 2.6874 | 0.9780 | 2.0141 | 0.800 | 0.8416 | | |
| 0.9963 | 2.6783 | 0.9775 | 2.0047 | 0.795 | 0.8239 | | |
| 0.9962 | 2.6693 | 0.9770 | 1.9954 | 0.790 | 0.8064 | | |
| 0.9961 | 2.6606 | 0.9765 | 1.9863 | 0.785 | 0.7892 | | |
| 0.9960 | 2.6521 | 0.9760 | 1.9774 | 0.780 | 0.7722 | | |

## 13.2 Quantile der t-Verteilung

| d.o.f | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 2 | 9.925 | 6.965 | 4.303 | 2.920 | 1.061 |
| 3 | 5.841 | 4.541 | 3.182 | 2.353 | 0.978 |
| 4 | 4.604 | 3.747 | 2.776 | 2.132 | 0.941 |
| 5 | 4.032 | 3.365 | 2.571 | 2.015 | 0.920 |
| 6 | 3.707 | 3.143 | 2.447 | 1.943 | 0.906 |
| 7 | 3.499 | 2.998 | 2.365 | 1.895 | 0.896 |
| 8 | 3.355 | 2.896 | 2.306 | 1.860 | 0.889 |
| 9 | 3.250 | 2.821 | 2.262 | 1.833 | 0.883 |
| 10 | 3.169 | 2.764 | 2.228 | 1.812 | 0.879 |
| 11 | 3.106 | 2.718 | 2.201 | 1.796 | 0.876 |
| 12 | 3.055 | 2.681 | 2.179 | 1.782 | 0.873 |
| 13 | 3.012 | 2.650 | 2.160 | 1.771 | 0.870 |
| 14 | 2.977 | 2.624 | 2.145 | 1.761 | 0.868 |
| 15 | 2.947 | 2.602 | 2.131 | 1.753 | 0.866 |
| 16 | 2.921 | 2.583 | 2.120 | 1.746 | 0.865 |
| 17 | 2.898 | 2.567 | 2.110 | 1.740 | 0.863 |
| 18 | 2.878 | 2.552 | 2.101 | 1.734 | 0.862 |
| 19 | 2.861 | 2.539 | 2.093 | 1.729 | 0.861 |
| 20 | 2.845 | 2.528 | 2.086 | 1.725 | 0.860 |
| 21 | 2.831 | 2.518 | 2.080 | 1.721 | 0.859 |
| 22 | 2.819 | 2.508 | 2.074 | 1.717 | 0.858 |
| 23 | 2.807 | 2.500 | 2.069 | 1.714 | 0.858 |
| 24 | 2.797 | 2.492 | 2.064 | 1.711 | 0.857 |
| 25 | 2.787 | 2.485 | 2.060 | 1.708 | 0.856 |

| d.o.f | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 26 | 2.779 | 2.479 | 2.056 | 1.706 | 0.856 |
| 27 | 2.771 | 2.473 | 2.052 | 1.703 | 0.855 |
| 28 | 2.763 | 2.467 | 2.048 | 1.701 | 0.855 |
| 29 | 2.756 | 2.462 | 2.045 | 1.699 | 0.854 |
| 30 | 2.750 | 2.457 | 2.042 | 1.697 | 0.854 |
| 31 | 2.744 | 2.453 | 2.040 | 1.696 | 0.853 |
| 32 | 2.738 | 2.449 | 2.037 | 1.694 | 0.853 |
| 33 | 2.733 | 2.445 | 2.035 | 1.692 | 0.853 |
| 34 | 2.728 | 2.441 | 2.032 | 1.691 | 0.852 |
| 35 | 2.724 | 2.438 | 2.030 | 1.690 | 0.852 |
| 36 | 2.719 | 2.434 | 2.028 | 1.688 | 0.852 |
| 37 | 2.715 | 2.431 | 2.026 | 1.687 | 0.851 |
| 38 | 2.712 | 2.429 | 2.024 | 1.686 | 0.851 |
| 39 | 2.708 | 2.426 | 2.023 | 1.685 | 0.851 |
| 40 | 2.704 | 2.423 | 2.021 | 1.684 | 0.851 |
| 41 | 2.701 | 2.421 | 2.020 | 1.683 | 0.850 |
| 42 | 2.698 | 2.418 | 2.018 | 1.682 | 0.850 |
| 43 | 2.695 | 2.416 | 2.017 | 1.681 | 0.850 |
| 44 | 2.692 | 2.414 | 2.015 | 1.680 | 0.850 |
| 45 | 2.690 | 2.412 | 2.014 | 1.679 | 0.850 |
| 46 | 2.687 | 2.410 | 2.013 | 1.679 | 0.850 |
| 47 | 2.685 | 2.408 | 2.012 | 1.678 | 0.849 |
| 48 | 2.682 | 2.407 | 2.011 | 1.677 | 0.849 |
| 49 | 2.680 | 2.405 | 2.010 | 1.677 | 0.849 |
| 50 | 2.678 | 2.403 | 2.009 | 1.676 | 0.849 |

## 13.3 Quantile der $\chi^2$-Verteilung

| | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 2 | 10.597 | 9.210 | 7.378 | 5.991 | 3.219 |
| 3 | 12.838 | 11.345 | 9.348 | 7.815 | 4.642 |
| 4 | 14.860 | 13.277 | 11.143 | 9.488 | 5.989 |
| 5 | 16.750 | 15.086 | 12.833 | 11.070 | 7.289 |
| 6 | 18.548 | 16.812 | 14.449 | 12.592 | 8.558 |
| 7 | 20.278 | 18.475 | 16.013 | 14.067 | 9.803 |
| 8 | 21.955 | 20.090 | 17.535 | 15.507 | 11.030 |
| 9 | 23.589 | 21.666 | 19.023 | 16.919 | 12.242 |
| 10 | 25.188 | 23.209 | 20.483 | 18.307 | 13.442 |
| 11 | 26.757 | 24.725 | 21.920 | 19.675 | 14.631 |
| 12 | 28.300 | 26.217 | 23.337 | 21.026 | 15.812 |
| 13 | 29.819 | 27.688 | 24.736 | 22.362 | 16.985 |
| 14 | 31.319 | 29.141 | 26.119 | 23.685 | 18.151 |
| 15 | 32.801 | 30.578 | 27.488 | 24.996 | 19.311 |
| 16 | 34.267 | 32.000 | 28.845 | 26.296 | 20.465 |
| 17 | 35.718 | 33.409 | 30.191 | 27.587 | 21.615 |
| 18 | 37.156 | 34.805 | 31.526 | 28.869 | 22.760 |
| 19 | 38.582 | 36.191 | 32.852 | 30.144 | 23.900 |
| 20 | 39.997 | 37.566 | 34.170 | 31.410 | 25.038 |
| 21 | 41.401 | 38.932 | 35.479 | 32.671 | 26.171 |
| 22 | 42.796 | 40.289 | 36.781 | 33.924 | 27.301 |
| 23 | 44.181 | 41.638 | 38.076 | 35.172 | 28.429 |
| 24 | 45.559 | 42.980 | 39.364 | 36.415 | 29.553 |
| 25 | 46.928 | 44.314 | 40.646 | 37.652 | 30.675 |

| | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 26 | 48.290 | 45.642 | 41.923 | 38.885 | 31.795 |
| 27 | 49.645 | 46.963 | 43.195 | 40.113 | 32.912 |
| 28 | 50.993 | 48.278 | 44.461 | 41.337 | 34.027 |
| 29 | 52.336 | 49.588 | 45.722 | 42.557 | 35.139 |
| 30 | 53.672 | 50.892 | 46.979 | 43.773 | 36.250 |
| 31 | 55.003 | 52.191 | 48.232 | 44.985 | 37.359 |
| 32 | 56.328 | 53.486 | 49.480 | 46.194 | 38.466 |
| 33 | 57.648 | 54.776 | 50.725 | 47.400 | 39.572 |
| 34 | 58.964 | 56.061 | 51.966 | 48.602 | 40.676 |
| 35 | 60.275 | 57.342 | 53.203 | 49.802 | 41.778 |
| 36 | 61.581 | 58.619 | 54.437 | 50.998 | 42.879 |
| 37 | 62.883 | 59.893 | 55.668 | 52.192 | 43.978 |
| 38 | 64.181 | 61.162 | 56.896 | 53.384 | 45.076 |
| 39 | 65.476 | 62.428 | 58.120 | 54.572 | 46.173 |
| 40 | 66.766 | 63.691 | 59.342 | 55.758 | 47.269 |
| 41 | 68.053 | 64.950 | 60.561 | 56.942 | 48.363 |
| 42 | 69.336 | 66.206 | 61.777 | 58.124 | 49.456 |
| 43 | 70.616 | 67.459 | 62.990 | 59.304 | 50.548 |
| 44 | 71.893 | 68.710 | 64.201 | 60.481 | 51.639 |
| 45 | 73.166 | 69.957 | 65.410 | 61.656 | 52.729 |
| 46 | 74.437 | 71.201 | 66.617 | 62.830 | 53.818 |
| 47 | 75.704 | 72.443 | 67.821 | 64.001 | 54.906 |
| 48 | 76.969 | 73.683 | 69.023 | 65.171 | 55.993 |
| 49 | 78.231 | 74.919 | 70.222 | 66.339 | 57.079 |
| 50 | 79.490 | 76.154 | 71.420 | 67.505 | 58.164 |

## 13.4 Quantile der Fisher-Verteilung für $\alpha = 5\%$

$F_{\alpha/2,\nu_1,\nu_2}$

| $\downarrow \nu_2 \mid \nu_1 \rightarrow$ | 5 | 6 | 7 | 8 | 9 | 10 | 20 | 30 | 40 | 50 | 60 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 3 | 0.129 | 0.152 | 0.170 | 0.185 | 0.197 | 0.207 | 0.259 | 0.279 | 0.289 | 0.295 | 0.299 |
| 4 | 0.135 | 0.161 | 0.181 | 0.198 | 0.212 | 0.224 | 0.285 | 0.308 | 0.320 | 0.327 | 0.332 |
| 5 | 0.140 | 0.167 | 0.189 | 0.208 | 0.223 | 0.236 | 0.304 | 0.330 | 0.344 | 0.353 | 0.359 |
| 6 | 0.143 | 0.172 | 0.195 | 0.215 | 0.231 | 0.246 | 0.320 | 0.349 | 0.364 | 0.374 | 0.381 |
| 7 | 0.146 | 0.176 | 0.200 | 0.221 | 0.238 | 0.253 | 0.333 | 0.364 | 0.381 | 0.392 | 0.399 |
| 8 | 0.148 | 0.179 | 0.204 | 0.226 | 0.244 | 0.259 | 0.343 | 0.377 | 0.395 | 0.407 | 0.415 |
| 9 | 0.150 | 0.181 | 0.207 | 0.230 | 0.248 | 0.265 | 0.353 | 0.388 | 0.408 | 0.420 | 0.428 |
| 10 | 0.151 | 0.183 | 0.210 | 0.233 | 0.252 | 0.269 | 0.361 | 0.398 | 0.419 | 0.432 | 0.440 |
| 20 | 0.158 | 0.193 | 0.224 | 0.250 | 0.273 | 0.293 | 0.406 | 0.456 | 0.484 | 0.502 | 0.514 |
| 30 | 0.161 | 0.197 | 0.229 | 0.257 | 0.281 | 0.302 | 0.426 | 0.482 | 0.515 | 0.536 | 0.551 |
| 40 | 0.162 | 0.200 | 0.232 | 0.260 | 0.285 | 0.307 | 0.437 | 0.498 | 0.533 | 0.557 | 0.573 |
| 50 | 0.163 | 0.201 | 0.234 | 0.263 | 0.288 | 0.310 | 0.445 | 0.508 | 0.546 | 0.571 | 0.589 |
| 60 | 0.163 | 0.202 | 0.235 | 0.264 | 0.290 | 0.313 | 0.450 | 0.515 | 0.555 | 0.581 | 0.600 |

$F_{1-\alpha/2,\nu_1,\nu_2}$

| $\downarrow \nu_2 \mid \nu_1 \rightarrow$ | 5 | 6 | 7 | 8 | 9 | 10 | 20 | 30 | 40 | 50 | 60 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 3 | 14.885 | 14.735 | 14.624 | 14.540 | 14.473 | 14.419 | 14.167 | 14.081 | 14.037 | 14.010 | 13.992 |
| 4 | 9.364 | 9.197 | 9.074 | 8.980 | 8.905 | 8.844 | 8.560 | 8.461 | 8.411 | 8.381 | 8.360 |
| 5 | 7.146 | 6.978 | 6.853 | 6.757 | 6.681 | 6.619 | 6.329 | 6.227 | 6.175 | 6.144 | 6.123 |
| 6 | 5.988 | 5.820 | 5.695 | 5.600 | 5.523 | 5.461 | 5.168 | 5.065 | 5.012 | 4.980 | 4.959 |
| 7 | 5.285 | 5.119 | 4.995 | 4.899 | 4.823 | 4.761 | 4.467 | 4.362 | 4.309 | 4.276 | 4.254 |
| 8 | 4.817 | 4.652 | 4.529 | 4.433 | 4.357 | 4.295 | 3.999 | 3.894 | 3.840 | 3.807 | 3.784 |
| 9 | 4.484 | 4.320 | 4.197 | 4.102 | 4.026 | 3.964 | 3.667 | 3.560 | 3.505 | 3.472 | 3.449 |
| 10 | 4.236 | 4.072 | 3.950 | 3.855 | 3.779 | 3.717 | 3.419 | 3.311 | 3.255 | 3.221 | 3.198 |
| 20 | 3.289 | 3.128 | 3.007 | 2.913 | 2.837 | 2.774 | 2.464 | 2.349 | 2.287 | 2.249 | 2.223 |
| 30 | 3.026 | 2.867 | 2.746 | 2.651 | 2.575 | 2.511 | 2.195 | 2.074 | 2.009 | 1.968 | 1.940 |
| 40 | 2.904 | 2.744 | 2.624 | 2.529 | 2.452 | 2.388 | 2.068 | 1.943 | 1.875 | 1.832 | 1.803 |
| 50 | 2.833 | 2.674 | 2.553 | 2.458 | 2.381 | 2.317 | 1.993 | 1.866 | 1.796 | 1.752 | 1.721 |
| 60 | 2.786 | 2.627 | 2.507 | 2.412 | 2.334 | 2.270 | 1.944 | 1.815 | 1.744 | 1.699 | 1.667 |

## 13.5 Grenzwerte für Lilliefors-Test und Zweistichproben-KS-Test

Beim Lilliefors-Test sind die Grenzwerte für die Entscheidung bei größeren Stichprobenumfängen (etwa $J > 30$) folgende

$$c^{\mathrm{L}}_{\alpha,J} \approx \frac{k_\alpha}{\sqrt{J}}$$

wobei $k_\alpha$ folgende Werte hat:

| $\alpha$ | 0.10 | 0.05 | 0.01 |
|---|---|---|---|
| $k_\alpha$ | 0.805 | 0.886 | 1.031 |

Beim Zweistichproben-KS-Test sind die Grenzwerte für die Entscheidung bei größeren Stichprobenumfängen

$$c_\alpha \sqrt{\frac{J_1 + J_2}{J_1 J_2}} \tag{13.1}$$

wobei $c_\alpha$ mit folgenden Werten approximiert wird:

| $\alpha$ | 0.10 | 0.05 | 0.01 |
|---|---|---|---|
| $c_\alpha$ | 1.22 | 1.36 | 1.63 |

# Kapitel 14

# Lösungen zu den Aufgaben

## 14.1 Lösung zur Aufgabe aus Vorl 1

### 14.1.1 Lösung zum Beispiel zur Methode der der kleinsten Quadrate

aus Abschnitt 1.4

Zu Bestimmen ist ein Ohmscher Widerstand $R$ sowie eine Offsetspannung $U_0$ bei gegebenen Werten einer Präzisionsstromquelle und eines Voltmeters:

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| $I$ in mA | 4.0 | 6.0 | 8.0 | 10.0 | 12.0 | 14.0 | 16.0 | 18.0 | 20.0 |
| $U$ in mV | 62.5 | 51.5 | 96.0 | 140.2 | 138.9 | 195.1 | 225.8 | 207.8 | 223.7 |

Es wird angenommen, dass die Stromstärken ohne Streuung vorliegen (als Regressoren) und die Spannungen normalverteilt streuen (als Regressanden), so dass

$$\min_{R,U_0} \sum_{i=1}^{J} (U_i - R\,I_i - U_0)^2$$

(a) Berechnen Sie den Korrelationskoeffizienten $\rho(I,U)$

$$\rho = \frac{\mathrm{Cov}(U,I)}{\sqrt{\mathrm{Var}(U)}\,\sqrt{\mathrm{Var}(I)}}$$

Für die Ko-Varianzen werden die Mittelwerte gebraucht und die Anzahl der Wertepaare $J = 9$

$$\bar{U} = \frac{1}{J}\sum_{j=1}^{J} U_j =$$

$$= (62.5 + 51.5 + 96.0 + 140.2 + 138.9 + 195.1 + 225.8 + 207.8 + 223.7)/9 = 149.06\,\mathrm{mV}$$

$$\bar{I} = \frac{1}{J}\sum_{j=1}^{J} I_j =$$

$$= (4.0 + 6.0 + 8.0 + 10.0 + 12.0 + 14.0 + 16.0 + 18.0 + 20.0)/9 = 12\,\mathrm{mA}$$

$$\mathrm{Cov}(U,I) = \frac{1}{J-1}\sum_{j=1}^{J}(U_i - \bar{U})(I_i - \bar{I}) =$$

$$= \frac{1}{8}\left((62.5 - 149.06)(4 - 12) + \cdots + (223.7 - 149.06)(20 - 12)\right) = 357.05\,\mathrm{mV}\cdot\mathrm{mA}$$

$$\mathrm{Var}(U) = \frac{1}{J-1}\sum_{j=1}^{J}(U_i - \bar{U})^2 = 4629.7\,(\mathrm{mV})^2$$

$$\sqrt{\mathrm{Var}(U)} = 68.042\,\mathrm{mV}$$

$$\mathrm{Var}(I) = \frac{1}{J-1}\sum_{j=1}^{J}(I_i - \bar{I})^2 = 30\,(\mathrm{mA})^2$$

$$\sqrt{\mathrm{Var}(I)} = 5.4772\,\mathrm{mA}$$

also

$$\rho = \frac{357.05}{68.042 \cdot 5.4772} = 0.958$$

(b) Lösen Sie das Gleichungssystem

$$\begin{pmatrix} \frac{\partial}{\partial R} \\ \frac{\partial}{\partial U_0} \end{pmatrix} \sum_{i=1}^{J} (U_i \,-\, R\,I_i \,-\, U_0)^2 \;=\; \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

d.h.

$$\begin{array}{rcl} \sum_i 2(U_i - RI_i - U_0) \cdot (-I_i) & = & 0 \\ \sum_i \underbrace{2(U_i - RI_i - U_0)}_{\text{aeussere Abl.}} \cdot \underbrace{(-1)}_{\text{innere Abl.}} & = & 0 \end{array}$$

d.h.

$$\begin{array}{rcl} \sum_i U_i I_i & = & \sum_i I_i^2 R \,+\, \sum_i I_i U_0 \\ \sum_i U_i & = & \sum_i I_i R \,+\, \sum_i U_0 \end{array}$$

mit $\sum_i U_0 = U_0 \sum_i 1 = JU_0$

$$\begin{pmatrix} \sum_i I_i^2 & \sum_i I_i \\ \sum_i I_i & J \end{pmatrix} \begin{pmatrix} R \\ U_0 \end{pmatrix} = \begin{pmatrix} \sum_i U_i I_i \\ \sum_i U_i \end{pmatrix}$$

Lösen des Gleichungssystems

$$\begin{pmatrix} R \\ U_0 \end{pmatrix} = \begin{pmatrix} \sum_i I_i^2 & \sum_i I_i \\ \sum_i I_i & J \end{pmatrix}^{-1} \begin{pmatrix} \sum_i U_i I_i \\ \sum_i U_i \end{pmatrix}$$

Für die Inverse einer 2-Matrix gilt

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - cb} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

so dass

$$\begin{pmatrix} R \\ U_0 \end{pmatrix} \;=\; \frac{1}{J(\sum_i I_i^2) - (\sum_i I_i)^2} \begin{pmatrix} J & -\sum_i I_i \\ -\sum_i I_i & \sum_i I_i^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_i U_i I_i \\ \sum_i U_i \end{pmatrix}$$

(c) Berechnen Sie die aus der Lösung des Gleichungssystems aus (b) gewonnen Schätzwerte für $R$ und $U_0$.

$$R = \frac{J(\sum_i U_i I_i) - (\sum_i U_i)(\sum_i I_i)}{J(\sum_i I_i^2) - (\sum_i I_i)^2} = \frac{2.5708 \cdot 10^4\,\mathrm{mV \cdot mA}}{2160\,(\mathrm{mA})^2} = 11.9\,\frac{\mathrm{V}}{\mathrm{A}} = 11.9\,\Omega$$

$$U_0 = \frac{(\sum_i I_i^2)(\sum_i U_i) - (\sum_i I_i)(\sum_i U_i I_i)}{J(\sum_i I_i^2) - (\sum_i I_i)^2} = \frac{1.3469 \cdot 10^4\,(\mathrm{mA})^2 \cdot \mathrm{mV}}{2160\,(\mathrm{mA})^2} = 6.24\,\mathrm{mV}$$

## 14.2 Lösungen zu den Aufgaben aus Vorl 2

### 14.2.1 Lösung zur 1. Aufgabe: Lineare Regression

siehe 2.6.1

zu (a) Stellen Sie das lineare Gleichungssystem auf, das sich durch partielles Ableiten für das Optimierungsproblem

$$\min_{a,c,h} \left\{ \sum_{j=1}^{J_T} \varepsilon_j^2 \right\}$$

ergibt, mit $J_T = 21$.

Die Modellgleichung lautet

$$z_j \;=\; a\, x_j \;+\; c \;+\; h\, \delta_{j\in C} \;+\; \varepsilon_j \tag{14.1}$$

In Vektorschreibweise mit $\boldsymbol{x}$ und $\boldsymbol{z}$ als Spaltenvektoren sieht dies mit allen in der oben aufgeführten Werten wie folgt aus

$$\boldsymbol{x} = \begin{pmatrix} 0 \\ 0.25 \\ 0.50 \\ \vdots \\ 2.25 \\ 2.75 \\ \vdots \\ 5.00 \end{pmatrix} \qquad \boldsymbol{x}_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \qquad \boldsymbol{x}_0 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \qquad \boldsymbol{z} = \begin{pmatrix} -54.08 \\ -55.63 \\ -44.65 \\ \vdots \\ -60.77 \\ 36.85 \\ \vdots \\ 23.19 \end{pmatrix}$$

Für die Realisierung der Kroneckersymbols $\delta_{j\in C}$ wurde der Spaltenvektor $\boldsymbol{x}_1$ definiert, der als erste $J_C = 10$ Vektorkomponenten Einsen enthält und als weitere Vektorkomponenten Nullen. Der Vektor $\boldsymbol{x}_0$ besteht nur aus Einsen.

Als nächstes ist es wichtig, die Größen auf dieselbe Dimension zu bringen, so dass wir eine Steigung berechnen wollen, also rechnen wir die x-Werte auch in Mikrometern

$$\boldsymbol{x}_2 \;=\; 1000\, \boldsymbol{x}$$

Somit sieht die Modellgleichung (14.1) wie folgt aus

$$\boldsymbol{z} \;=\; c\, \boldsymbol{x}_0 \;+\; h\, \boldsymbol{x}_1 \;+\; a\, \boldsymbol{x}_2 \;+\; \boldsymbol{\varepsilon}$$

nun schreiben wir alle Spaltenvektoren mit x in eine gemeinsame Matrix, die dann 3 Spalten hat und $J_T = 21$ Zeilen

$$\boldsymbol{X} \;=\; (\boldsymbol{x}_0\; \boldsymbol{x}_1\; \boldsymbol{x}_2) \tag{14.2}$$

so dass die Modellgleichung wie folgt aussieht

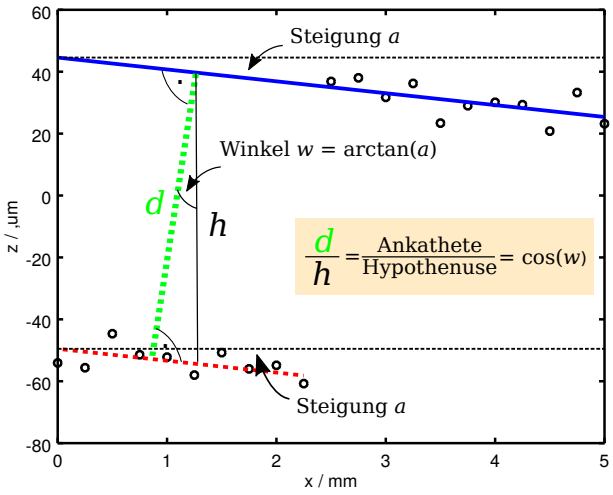
$$\boldsymbol{\varepsilon} \;=\; \boldsymbol{z} \;-\; \boldsymbol{X} \begin{pmatrix} c \\ h \\ a \end{pmatrix}.$$

Wenn man diesen Ansatz in dieser Form hat, kann man einfach Gl. (2.64) verwenden und alles einsetzten. Für die Klausur kommt es also nur darauf an, die Regressormatrix $\boldsymbol{X}$, das ist Gl. (14.2) aufstellen zu können und Gl. (2.64) aus dieser Vorlesung zu kennen:

$$\left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right) \begin{pmatrix} c \\ h \\ a \end{pmatrix} \;=\; \mathbf{X}^{\mathsf{T}}\,\mathbf{z} \tag{14.3}$$

wobei $\boldsymbol{X}^{\mathsf{T}}$ die transponierte Matrix ist, die in der ersten Zeile alles Einsen hat, in der zweiten Zeile an den ersten $J_C = 10$ Spaltenpositionen Einsen und an den letzten 11 Nullen hat und in der dritten und letzten Zeile die Werte 0.00 0.25 0.50 0.75 ... 5.00 aus der Tabelle hat. Hier ist dieser Teil der Aufgabenstellung fertig.

zu (b) Schreiben Sie die Gleichung für die Stufenhöhe $d$ als Funktion von $h$ und $a$ auf.




Aus $d = h\cos(w)$ folgt gemäß trigonometrischer Beziehung $\cos(w) = 1/\sqrt{1+\tan^2(w)}$, die auf dem Satz des Pythagoras basiert,

$$d \;=\; \frac{h}{\sqrt{1+a^2}}. \tag{14.4}$$

Wer zuvor die x-Werte in Millimetern gerechnet hat, muss spätestens hier die Steigung $a$ entsprechend umrechnen und durch 1000 teilen.

zu (c) Schreiben Sie die Formel für die Varianz der Residuen auf.

$$\sigma_\varepsilon^2 \;=\; \frac{1}{J_T - 3}\boldsymbol{\varepsilon}^{\mathsf{T}}\,\boldsymbol{\varepsilon}$$

zu (d) Schreiben Sie die Formel für die Kovarianzmatrix der Modellparameter $a, c, h$ auf.

Wir verwenden dazu Gl. (2.53) dieser Vorlesung

$$\mathbf{\Sigma} = \left(\mathbf{X}^{\mathsf{T}}\,\mathbf{X}\right)^{-1}\,\sigma_{\varepsilon}^{2} \tag{14.5}$$

zu (e) Verwenden Sie eine Programmierumgebung Ihrer Wahl, Matlab, Octave, Python, R, ... die Ihnen einen Solver für lineare Gleichungssysteme zur Verfügung stellt, sowie eine Routine zur Matrixinversion und berechen Sie die Zahlenwerte für die Modellparameter sowie deren Kovarianzmatrix.

```
function Lsg_Uebung_step()
%
% Teil (a)
  x = [0.00  0.25  0.50  0.75  1.00  1.25  1.50 ...
   1.75  2.00  2.25  2.50  2.75  3.00  3.25  3.50 ...
   3.75  4.00  4.25  4.50  4.75  5.00]';
  z = [-54.08 -55.63 -44.65 -51.44 -52.21 -58.01 ...
   -50.76 -56.01 -54.86 -60.77 36.85 38.02 31.71 36.21 ...
   23.39 29.01 30.11 29.35 20.81 33.27 23.19]';
  x2 = 1e3*x;
  J_T = 21;
  J_C = 10;
  x0 = ones(J_T,1);
  x1 = [ones(J_C,1);zeros(J_T-J_C,1)];
  X = [x0 x1 x2];
  XTX = X' * X;
  b = X' * z;
  theta = XTX \ b;
  printf('c = %1.4f um\n', theta(1));
  printf('h = %1.4f um\n', theta(2));
  printf('a = %1.7f um/um\n', theta(3));
%
% Teil (b)
  d = theta(2) / sqrt(1 + theta(3)^2);
  printf('d = %1.4f um\n', d);
%
% Teil (c)
  epsilon = z - X * theta;
  var_eps = (epsilon' * epsilon) / (J_T-3);
%
% Teil (e)
  Kovarianz = inv(XTX) * var_eps;
  printf(' %e %e %e \n', Kovarianz(1,1), Kovarianz(1,2), Kovarianz(1,3));
  printf(' %e %e %e \n', Kovarianz(2,1), Kovarianz(2,2), Kovarianz(2,3));
  printf(' %e %e %e \n', Kovarianz(3,1), Kovarianz(3,2), Kovarianz(3,3));
```

Ergebnisse:

```
c = 44.5660 um
h = -94.0905 um
a = -0.0038377 um/um
d = -94.0899 um
```

$\Sigma =$

```
2.369818e+01 -1.710178e+01 -5.863466e-03
 -1.710178e+01 1.436549e+01 4.104426e-03
 -5.863466e-03 4.104426e-03 1.563591e-06
```

Für die Unermüdlichen, die lieber in C programmieren, hier die Routine zum Lösen des linearen Gleichungssystems, haben wir eine Routine zum Lösen von linearen Gleichungssystemen aus den Numerical Recipes abgedruckt:

B. P. Flannery, W. H. Press, S. A. Teukolsky, W. T. Vetterling. *Numerical Recipes in C*. Cambridge University Press, 2. Auflage (1992-2002)

Wichtig, diese Routine überschreibt den Vektor mit der Inhomogenität des Gleichungssystems mit der Lösung, also den gewünschten Modellparametern und die Matrix `a` mit den Summen aus den Regressoren mit deren Inversen $\mathtt{a}^{-1}$, die Sie dann für die Kovarianz der Modellparameter brauchen.

```
void gaussjordan(double **a, int n, double **b, int m) {
/*
* Linear equation solution by Gauss-Jordan elimination, equation (2.1.1) in
* Numerical Recipes.
* a[0..n-1][0..n-1] is the input matrix. b[0..m-1][0..n-1] is input
* containing the m right-hand side vectors.
* For most applications we have m = 1
* On output, a is replaced by its matrix inverse,
* and b is replaced by the corresponding set of solution vectors.
*/
int *indxc,*indxr,*ipiv;
int i,icol,irow,j,k,l,ll;
double big,tmp,pivinv;

// The integer arrays ipiv, indxr, and indxc are
// used for bookkeeping on the pivoting.
indxc = (int*)calloc( n, sizeof(int));
indxr = (int*)calloc( n, sizeof(int));

ipiv = (int*)calloc( n, sizeof(int));
```

```
/* for (j=1;j<=n;j++) ipiv[j]=0;*/
/* for (j=1;j<=n;j++) ipiv[j]=0;*/
/* calloc initializes to zero:
Allocates a block of memory for an array of num elements,
each of them size bytes long, and initializes all its bits to zero.
*/

/*
* This is the main loop over the columns to be reduced.
*/
for (i=0; i<n; i++) {
big=0.0;

// This is the outer loop of the search for a pivot element.
for (j=0; j<n; j++)
if (ipiv[j] != 1)
for (k=0; k<n; k++) {
if (ipiv[k] == 0) {
if (fabs(a[k][j]) >= big) {
big=fabs(a[k][j]);
irow=j;
icol=k;
}
}
}
++(ipiv[icol]);

/*
* We now have the pivot element, so we interchange rows, if needed,
* to put the pivot element on the diagonal. The columns are not
* physically interchanged, only relabeled:
* indxc[i], the column of the ith pivot element,
*           is the ith column that is reduced, while
* indxr[i] is the row in which that pivot element was originally located.
*          If indxr[i] !=
* indxc[i] there is an implied column interchange.
* With this form of bookkeeping, the solution b-s will end up in the
* correct order, and the inverse matrix will be scrambled by columns.
*/

if (irow != icol) {
for (l=0; l<n; l++) SWAP(a[l][irow],a[l][icol])
for (l=0; l<m; l++) SWAP(b[l][irow],b[l][icol])
}
```

```
/*
* We are now ready to divide the pivot row by the
* pivot element, located at irow and icol.
*/

indxr[i]=irow;
indxc[i]=icol;
if (a[icol][icol] == 0.0) printf("gaussj: Singular Matrix\n");
pivinv=1.0/a[icol][icol];
a[icol][icol]=1.0;
for (l=0; l<n; l++) a[l][icol] *= pivinv;
for (l=0; l<m; l++) b[l][icol] *= pivinv;

/*
* Next, we reduce the rows
* except, if (ll != icol), for the pivot one, of course.
*/
for (ll=0; ll<n; ll++)
if (ll != icol) {
tmp=a[icol][ll];
a[icol][ll]=0.0;
for (l=0; l<n; l++) a[l][ll] -= a[l][icol]*tmp;
for (l=0; l<m; l++) b[l][ll] -= b[l][icol]*tmp;
}
}
/*
* This is the end of the main loop over columns of the reduction.
*/

/*
* It only remains to unscramble the solution in view of the column interchanges.
* We do this by interchanging pairs ofcolumns in the reverse order
* that the permutation was built up.
*/
for (l=n-1; l>=0;l--) {
if (indxr[l] != indxc[l])
for (k=0; k<n; k++) SWAP(a[indxr[l]][k],a[indxc[l]][k]);
}
// And we are done.
free(ipiv);
free(indxr);
free(indxc);
}
```

## 14.3 Hilfe zu den Übungsaufgaben zum Selbststudium

**aus 5.9**

### Hilfestellung Aufgabe 1

Die Lösung der Aufgabe ist die Implementierung folgender Berechnungen

- Erzeugung einer normalverteilten Stichprobe
- Berechnung von Mittelwert, empirischer Standardabweichung und relativen Häufigkeiten
- Berechnung der KS-Prüfgröße $D$
- Lilliefors-Grenzwert
$$c^{\mathrm{L}}_{0.05,J_1} \approx \frac{0.886}{\sqrt{J_1}}, \qquad J_1 = 200$$
- Erzeugung der zweiten Stichprobe mit $\mu_2 = 35$, $s_2 = 5$
- Durchführung des Einstichproben-KS-Tests für das vereinigte Array unter Vorgabe der Parameter $\mu_1 = 23$ und $s_1 = 3$
- Einstichproben-KS-Grenzwert
$$K_{0.05,J_2} \approx \sqrt{-\frac{1}{2\,J_2}\,\ln(\frac{0.05}{2})}, \qquad J_2 = 31$$
- Grafische Vergleiche der empirischen und angepassten Verteilungsfunktion

Die Zufallszahlen werden mit einem festen Startwert erzeugt, sodass die Ergebnisse reproduzierbar sind. Benötigt werden `numpy`, `scipy` und `matplotlib`, die bei einer Neuinstallation von Python oder falls bisher nicht gebraucht mit folgendem Befehl in die Pythonumgebung eingebaut werden können

```
python -m pip install numpy scipy matplotlib
```

```
1  """Einfache Demonstration des KS- und Lilliefors-Tests.
2
3  Benoetigte Pakete:
4      numpy
5      scipy
6      matplotlib
7
8  Installation, falls erforderlich:
9      python -m pip install numpy scipy matplotlib
10 """
11
12 import numpy as np
13 import matplotlib.pyplot as plt
```

```
14 from scipy.stats import norm
15
16
17 def pruefgroesse_D(x, mu=None, sigma=None):
18     """Berechnet D und die Werte der empirischen Verteilungsfunktion.
19
20     Die Daten werden sortiert. Fuer den j-ten sortierten Wert gilt
21
22         H(x_(j)) = j / J.
23
24     Die Funktion verwendet den Mittelwert und die empirische
25     Standardabweichung der Stichprobe, um eine Normalverteilung
26     an die Daten anzupassen.
27     """
28     # Stichprobe sortieren: x_1, ..., x_J
29     x_sortiert = np.sort(x)
30     J = len(x_sortiert)
31
32     # In NumPy muss ddof=1 angegeben werden, damit durch J-1 geteilt wird.
33     mittelwert = np.mean(x_sortiert)
34     standardabweichung = np.std(x_sortiert, ddof=1)
35
36     # Empirische kumulierte relative Haeufigkeit H(x_j) = j/J
37     rang = np.arange(1, J + 1)
38     H = rang / J
39
40     # Angepasste Normalverteilung: F(x) = Phi((x - y) / s)
41     if mu and sigma:
42         print(f"Verwende festgelegte Verteilungsparameter mit  mu2 = {mu}, s2 = {sigma}")
43         F = norm.cdf(x_sortiert, loc=mu, scale=sigma)
44     else:
45         print("Verwende empirisch geschaetzte Parameter der Verteilung")
46         F = norm.cdf(x_sortiert, loc=mittelwert, scale=standardabweichung)
47
48     # Beide Seiten jeder Stufe der empirischen Verteilungsfunktion pruefen.
49     D_plus = np.max(H - F)
50     D_minus = np.max(F - (rang - 1) / J)
51     D = max(D_plus, D_minus)
52
53     return D, x_sortiert, H, F, mittelwert, standardabweichung
54
55
56 def lilliefors_grenzwert(J, alpha=0.05):
57     """Naeherungswert fuer den Lilliefors-Grenzwert.
```

```
58
59      Fuer alpha=0.05 gilt fuer groessere Stichproben naeherungsweise
60
61          c_(alpha,J)^L = 0.886 / sqrt(J).
62
63      Die Formel ist eine Naeherung und sollte hier nur fuer J >= 30
64      verwendet werden. Fuer kleine Stichproben sind tabellierte Werte
65      oder eine Simulation geeigneter.
66      """
67      if alpha != 0.05:
68          raise ValueError("Diese einfache Funktion ist nur fuer alpha=0.05 programmiert.")
69      if J < 30:
70          print(
71              "Hinweis: Fuer J < 30 ist der Lilliefors-Grenzwert "
72              "nur eine grobe Naeherung."
73          )
74      return 0.886 / np.sqrt(J)
75
76
77  def ks_grenzwert(J, alpha=0.05):
78      """Asymptotischer KS-Grenzwert fuer eine vollstaendig festgelegte
79      Verteilung F0, d.h. Erwartungswert und Standardabweichung sind
80      vordefiniert und nicht geschaetzt, ausserdem fuer J >= 30.
81      """
82      return np.sqrt(-np.log(alpha / 2) / (2 * J))
83
84
85  def ergebnis_ausgeben(name, D, grenzwert):
86      """Gibt das Testergebnis aus."""
87      print(f"\n{name}")
88      print("-" * len(name))
89      print(f"Pruefgroesse D = {D:.4f}")
90      print(f"Grenzwert   = {grenzwert:.4f}")
91
92      if D > grenzwert:
93          print("Ergebnis: H0 wird verworfen.")
94      else:
95          print("Ergebnis: H0 wird nicht verworfen.")
96
97
98  # ---------------------------------------------------------------------
99  # Teil 1: Eine normalverteilte Stichprobe
100 # ---------------------------------------------------------------------
101 print("TEIL 1: Eine Stichprobe")
```

```
102
103 alpha = 0.05
104 rng = np.random.default_rng(2026)  # fester Startwert: reproduzierbare Zahlen
105
106 mu1 = 23.0
107 s1 = 3.0
108 J1 = 200
109
110 # Zufallszahlen aus N(mu1, s1^2) erzeugen
111 Xarray = rng.normal(loc=mu1, scale=s1, size=J1)
112
113 D1, Xsortiert, H1, F1, y1, s_emp1 = pruefgroesse_D(Xarray)
114 c_lilliefors = lilliefors_grenzwert(J1, alpha)
115
116 print(f"Parameter zur Erzeugung der ersten Stichprobe: mu2 = {mu1}, s2 = {s1}")
117 print(f"Stichprobenumfang J = {J1}")
118 print(f"Stichprobenmittelwert y = {y1:.3f}")
119 print(f"Empirische Standardabweichung s = {s_emp1:.3f}")
120 print(f"Lilliefors-Grenzwert c_L = {c_lilliefors:.4f}")
121 ergebnis_ausgeben("Lilliefors-Test", D1, c_lilliefors)
122
123 # Abbildung der beiden kumulierten Verteilungen
124 plt.step(Xsortiert, H1, where="post", label="empirische Verteilung H")
125 plt.plot(Xsortiert, F1, label="angepasste Normalverteilung F")
126 plt.xlabel("x")
127 plt.ylabel("kumulierte Hufigkeit bzw. Wahrscheinlichkeit")
128 plt.title("Teil 1: Empirische und angepasste Verteilungsfunktion")
129 plt.grid(True)
130 plt.legend()
131 plt.tight_layout()
132 plt.show()
133
134
135 # ------------------------------------------------------------------------
136 # Teil 2: Zwei erzeugte Stichproben werden zusammengelegt
137 # ------------------------------------------------------------------------
138 print("\nTEIL 2: Vereinigte Stichproben")
139
140 mu2 = 35.0
141 s2 = 5.0
142 J2 = 31  # deutlich kleiner als J1
143
144 Yarray = rng.normal(loc=mu2, scale=s2, size=J2)
145
```

```
146 # Die beiden Stichproben werden zu einem Array vereinigt.
147 gemeinsames_array = np.concatenate((Xarray, Yarray))
148 J_gesamt = len(gemeinsames_array)
149
150 # Die folgende Auswertung behandelt den vereinigten Datensatz so,
151 # als kaeme er aus einer einzigen Grundgesamtheit.
152 D2, Xgesamt_sortiert, H2, F2, y2, s_emp2 = pruefgroesse_D(gemeinsames_array, mu1, s1)
153 K = ks_grenzwert(J_gesamt, alpha)
154
155 print(f"Stichprobenumfaenge: J1 = {J1}, J2 = {J2}, insgesamt J = {J_gesamt}")
156 print(f"Parameter zur Erzeugung der zweiten Stichprobe: mu2 = {mu2}, s2 = {s2}")
157 print(f"Vorgegebene Parameter der ersten Stichprobe fuer den KS-Test: mu1 = {mu1}, s1 = {s1}")
158
159 print(f"Mittelwert der vereinigten Stichproben y = {y2:.3f}")
160 print(f"Standardabweichung der vereinigten Stichproben s = {s_emp2:.3f}")
161 print(
162     "Fuer den geforderten Vergleich wird der "
163     "Standard-KS-Grenzwert verwendet."
164 )
165 ergebnis_ausgeben("Standard-KS-Test fuer die vereinigte Stichprobe", D2, K)
166
167 plt.step(Xgesamt_sortiert, H2, where="post", label="empirische Verteilung H")
168 plt.plot(Xgesamt_sortiert, F2, label="angepasste Normalverteilung F")
169 plt.xlabel("x")
170 plt.ylabel("kumulierte Haeufigkeit bzw. Wahrscheinlichkeit")
171 plt.title("Teil 2: Vereinigte Stichproben")
172 plt.grid(True)
173 plt.legend()
174 plt.tight_layout()
175 plt.show()
```

### Lösung zu Aufgabe 2

Gegeben sind die Stichproben

$$X_1 = (53,\ 69,\ 63,\ 47,\ 49,\ 44,\ 47,\ 44,\ 38),$$
$$X_2 = (21,\ 33,\ 19,\ 39,\ 7).$$

Das Signifikanzniveau beträgt in allen Tests

$$\alpha = 0{,}05.$$

a) **Mittelwerte und Standardabweichungen**

Für die empirische Standardabweichung wird durch $J_i - 1$ geteilt:

$$s_i = \sqrt{\frac{1}{J_i - 1}\sum_{j=1}^{J_i}(x_{i,j} - \overline{x}_i)^2}.$$

Damit erhält man

| Stichprobe | $J_i$ | $\overline{x}_i$ | $s_i$ |
|---|---|---|---|
| 1 | 9 | 50,4444 | 9,8249 |
| 2 | 5 | 23,8000 | 12,5379 |

b) **F-Test auf gleiche Varianzen**

Wir prüfen

$$H_0:\ \sigma_1^2 = \sigma_2^2 \qquad \text{gegen} \qquad H_1:\ \sigma_1^2 \neq \sigma_2^2.$$

Die Prüfgröße wird hier als Quotient in der vorgegebenen Reihenfolge der Stichproben gebildet:

$$F = \frac{s_1^2}{s_2^2}.$$

Unter $H_0$ gilt

$$F \sim F_{\nu_1,\nu_2}, \qquad \nu_1 = J_1 - 1 = 8, \qquad \nu_2 = J_2 - 1 = 4.$$

Mit den empirischen Varianzen ergibt sich

$$s_1^2 = 96{,}5278, \qquad s_2^2 = 157{,}2000, \qquad F = 0{,}6140.$$

Der zweiseitige Annahmebereich lautet

$$F_{\alpha/2;\,8,4} \leq F \leq F_{1-\alpha/2;\,8,4}.$$

Numerisch ist dies

$$0{,}1979 \leq F \leq 8{,}9796.$$

Da der F-Wert im Annahmebereich liegt, werden die Varianzen als gleich angesehen. Damit werden die Stichproben für den folgenden Test gepoolt.

Als Pythoncode:

```
# F-Test.
# F = s1^2 / s2^2, mit nu1=J1-1 und nu2=J2-1
# J1 Stichprobenumfang zu s1
f_value = variance1 / variance2
f_df1 = J1 - 1
f_df2 = J2 - 1
f_lower = stats.f.ppf(alpha / 2, f_df1, f_df2)
f_upper = stats.f.ppf(1 - alpha / 2, f_df1, f_df2)
f_p_value = 2 * min(
    stats.f.cdf(f_value, f_df1, f_df2),
    stats.f.sf(f_value, f_df1, f_df2),
)
```

c) **Test auf gleichen Erwartungswert**

Da der F-Test die Gleichheit der Varianzen nicht verworfen hat, verwenden wir den gepoolten Zweistichproben-t-Test. Die Hypothesen lauten

$$H_0: \ \mu_1 = \mu_2 \qquad \text{gegen} \qquad H_1: \ \mu_1 \neq \mu_2.$$

Die gepoolte Varianz ist

$$s_p^2 = \frac{(J_1 - 1)s_1^2 + (J_2 - 1)s_2^2}{J_1 + J_2 - 2} = 116{,}7519.$$

Die Prüfgröße lautet

$$t = \frac{\overline{x}_1 - \overline{x}_2}{s_p\sqrt{1/J_1 + 1/J_2}} = 4{,}4210.$$

Unter $H_0$ ist diese Prüfgröße t-verteilt mit

$$\nu = J_1 + J_2 - 2 = 12$$

Freiheitsgraden. Für den zweiseitigen Test wird das Quantil

$$t_{1-\alpha/2;\,12} = 2{,}1788$$

verwendet. Da

$$|t| = 4{,}4210 > 2{,}1788,$$

gilt: Die Nullhypothese gleicher Erwartungswerte wird verworfen.

d) **Test der Standardabweichung mit** $\sigma_0 = 6$

Für die zweite Stichprobe prüfen wir einseitig

$$H_0: \ \sigma = \sigma_0 = 6 \qquad \text{gegen} \qquad H_1: \ \sigma > 6.$$

Bei normalverteilten Beobachtungen gilt unter $H_0$

$$Q = \frac{(J_2 - 1)s_2^2}{\sigma_0^2} \sim \chi^2_{J_2-1}.$$

Es handelt sich daher um einen Chi-Quadrat-Test. Für den rechten Rand ist das Quantil

$$\chi^2_{1-\alpha;\,4} = 9{,}4877.$$

Die Prüfgröße beträgt

$$Q = \frac{4 \cdot 157{,}2000}{6^2} = 17{,}4667.$$

Da $Q > \chi^2_{1-\alpha;\,4}$, folgt: Die Nullhypothese wird verworfen.

e) **Test der Standardabweichung mit** $\sigma_0 = 9$

Nun wird geprüft:

$$H_0 : \ \sigma = 9 \qquad \text{gegen} \qquad H_1 : \ \sigma > 9.$$

Die Prüfgröße ist

$$Q = \frac{4 \cdot 157{,}2000}{9^2} = 7{,}7630.$$

Das Quantil der $\chi^2$-Verteilung bleibt unverändert:

$$\chi^2_{1-\alpha;\,4} = 9{,}4877.$$

Damit gilt: Die Nullhypothese wird nicht verworfen.

## 14.4 Lösung

**zu Aufgabe 10.6**

Es sollen Abstände auf einem Werkstück mit Hilfe eines induktiven Wegaufnehmers gemessen werden. Das Messprinzip eines induktiven Wegaufnehmers beruht darauf, dass eine Wechselspannung ein Spulensystem im Sensor anregt. Ein bewegliches ferro-magnetisches Teil am Sensor beeinflusst die Induktivität in den Spulen. Diese - in den Spulenteilen unterschiedliche - Induktivitätsveränderung wird vom Messverstärker ausgewertet und in ein positions-proportionales Gleichspannungssignal umgewandelt.

Um die Abstände in der physikalischen Einheit Mikrometer zu erhalten, muss mit Hilfe eines Bezugsnormals aus dem Spannungssignal ein Weg mit der Dimension einer Länge berechnet werden. Es ist bekannt, dass in dem für die Messung relevanten Messbereich (Hub des Sensors) die Abhängigkeit zwischen Spannungssignal und Auslenkung des ferro-magnetischen Kerns linear ist. Das Bezugsnormal ist eine Stufenhöhe.

Zu dem Bezugsnormal gibt es einen Kalibrierschein, der folgenden Höhenwert für das Normal angibt:

$$d \;=\; (4.997 \pm 0.011)\;\mu\text{m} \qquad \text{mit} \qquad k = 2.1, \nu_d = 26 \tag{14.6}$$

Mit dem induktiven Wegaufnehmer wurden auf dem Bezugsnormal folgende Stufenhöhen in der Dimension der elektrischen Spannung mit der Einheit Millivolt gemessen

Tabelle A5.1:

| $U_\mathrm{B}$/mV | 201.3 | 187.3 | 196.5 | 200.4 | 193.6 | 174.2 | 197.2 | 185.4 | 194.4 | 202.5 | 205.2 |
|---|---|---|---|---|---|---|---|---|---|---|---|

Tabelle A5.2:

| $U_\mathrm{W}$/mV | 176.5 | 184.1 | 180.5 | 193.6 | 176.0 | 194.5 | 160.9 |
|---|---|---|---|---|---|---|---|

Der Zusammenhang zwischen dem Abstand auf dem Werkstück in Mikrometern $d_\mathrm{W}$, der Stufenhöhe des Bezugsnormals gemäß Kalibrierschein $d$, dem gemessenen Spannungssignal an der Stufenhöhe $U_\mathrm{B}$ und dem gemessenen Spannungssignal $U_\mathrm{W}$ am Werkstück ist folgender

$$d_\mathrm{W} \;=\; \frac{d}{U_\mathrm{B}}\,U_\mathrm{W} \tag{14.7}$$

Die Änderungen aufgrund der statistischen Streuung der Spannungswerte $U_\mathrm{B}$ sind so klein, dass für die Sensitivität $c_\mathrm{B}$ von $d_\mathrm{W}$ bezüglich Änderungen von $U_\mathrm{B}$ mit dem hyperbolischen Zusammenhang $d_\mathrm{W} \sim \frac{1}{U_\mathrm{B}}$ die Steigung der Tangenten an die Hyperbel verwendet wird. Es wird die Tangente verwendet, die an dem Punkt, der sich aus den Mittelwerten ergibt, anliegt.

$$c_\mathrm{B} \;=\; \frac{\partial}{\partial U_\mathrm{B}} d_\mathrm{W}\Big|_{\bar{U}_\mathrm{B},\bar{d},\bar{U}_\mathrm{W}} \tag{14.8}$$

Die Sensitivitäten $c_\mathrm{d}$ und $c_\mathrm{W}$ von $d_\mathrm{W}$ bezüglich Änderungen von $d$ und $U_\mathrm{W}$ sind aufgrund des linearen

Zusammenhangs genau

$$c_\mathrm{d} \;=\; \left.\frac{U_\mathrm{W}}{U_\mathrm{B}}\right|_{\bar{U}_\mathrm{B},\bar{U}_\mathrm{W}} \qquad c_\mathrm{W} \;=\; \left.\frac{d}{U_\mathrm{B}}\right|_{\bar{U}_\mathrm{B},\bar{d}} \tag{14.9}$$

definiert. Die kombinierte Varianz unter der Voraussetzung, dass die gemessenen Größen und die Angabe aus dem Kalbrierschein unkorreliert sind, ist

$$s_\mathrm{dW}^2 \;=\; (c_\mathrm{d}\, s_\mathrm{d})^2 \;+\; (c_\mathrm{B}\, s_\mathrm{B})^2 \;+\; (c_\mathrm{W}\, s_\mathrm{W})^2 \tag{14.10}$$

mit $s_\mathrm{B}$ für die Standardabweichung der in Tabelle A5.1 aufgelisteten Werte, $s_\mathrm{W}$ für die Standardabweichung der in Tabelle A5.2 aufgelisteten Werte und $s_\mathrm{d}$ für die Standardabweichung der Angabe aus dem Kalibrierschein.

a) Ermitteln Sie aus den Angaben des Kalibrierscheins (hier Gl. (10.120)) die Standardabweichung $s_\mathrm{d}$, indem Sie den dort genannten Erweiterungsfaktor verwenden.

   Die im Kalibrierschein angegebene erweiterte Messunsicherheit $U(d) = ks_\mathrm{d}$ beträgt 0.011 mum. Um an die Standardabweichung $s_\mathrm{d}$ zu kommen, die in die Unsicherheitsfortpflanzungsformel einzusetzen ist, muss durch den Erweiterungsfaktor $k = 2.1$ geteilt werden:

$$s_\mathrm{d} = \frac{0.011\,\mu\mathrm{m}}{2.1} = 0.00524\;\mu\mathrm{m}$$

b) Ermitteln Sie die beiden Mittelwerte $\bar{U}_\mathrm{B}$ und $\bar{U}_\mathrm{W}$, sowie die beiden empirischen Standardabweichungen $s_\mathrm{B}$ und $s_\mathrm{W}$ aus den beiden Tabellen A5.1 und A5.2.

$$\bar{U}_\mathrm{B} \;=\; \frac{1}{J_\mathrm{B}}\sum_{j=1}^{J_\mathrm{B}} U_{\mathrm{B},j} \;=\; 194.364\;\mathrm{mV}, \quad s_\mathrm{B} = \sqrt{\frac{1}{J_\mathrm{B}-1}\sum_{j=1}^{J_\mathrm{B}}} \;=\; 9.045\;\mathrm{mV}$$

   mit $J_\mathrm{B} = 11$ und

$$\bar{U}_\mathrm{W} \;=\; \frac{1}{J_\mathrm{W}}\sum_{j=1}^{J_\mathrm{W}} U_{\mathrm{W},j} \;=\; 180.871\;\mathrm{mV}, \quad s_\mathrm{W} = 11.547\;\mathrm{mV}$$

   mit $J_\mathrm{B} = 7$.

c) Bestimmen Sie die Sensitivitäten $c_\mathrm{d}$, $c_\mathrm{W}$, $c_\mathrm{B}$ durch Ausführen der partiellen Ableitung. Mit

$$c_\mathrm{d} \;=\; \left.\frac{U_\mathrm{W}}{U_\mathrm{B}}\right|_{\bar{U}_\mathrm{B},\bar{U}_\mathrm{W}} \qquad c_\mathrm{W} \;=\; \left.\frac{d}{U_\mathrm{B}}\right|_{\bar{U}_\mathrm{B},\bar{d}}$$

   gilt

$$c_\mathrm{d} \;=\; \frac{\partial d_\mathrm{W}}{\partial d} \;=\; \frac{\partial}{\partial d}\frac{d}{U_\mathrm{B}}\,U_\mathrm{W} \;=\; \frac{U_\mathrm{W}}{U_\mathrm{B}} \;=\; 0.9306$$

   weil $\frac{U_\mathrm{W}}{U_\mathrm{B}}$ bezüglich der Ableitung nach $d$ Konstanten sind und die Ableitung von $d$ nach $d$ Eins ist. Entsprechend ist der Faktor $\frac{d}{U_\mathrm{B}}$ bzgl der Ableitung nach $U_\mathrm{W}$ eine Konstante und $U_\mathrm{W}$ nach $U_\mathrm{W}$ abgeleitet gleich Eins.

$$c_\mathrm{W} \;=\; \frac{\partial d_\mathrm{W}}{\partial U_\mathrm{W}} \;=\; \frac{d}{U_\mathrm{B}} \;=\; 0.0257\;\frac{\mu\mathrm{m}}{\mathrm{mV}}$$

$$c_\mathrm{B} = \frac{\partial d_\mathrm{W}}{\partial U_\mathrm{B}} = \frac{\partial}{\partial U_\mathrm{B}} \frac{d}{U_\mathrm{B}} U_\mathrm{W} = d\,U_\mathrm{W} \frac{\partial}{\partial U_\mathrm{B}} \frac{1}{U_\mathrm{B}} = -\frac{dU_\mathrm{W}}{U_\mathrm{B}^2} = -0.0239\ \mu\mathrm{m}$$

weil $d\,U_\mathrm{W}$ bzgl der Ableitung nach $U_\mathrm{B}$ eine Konstante und

$$\frac{\partial}{\partial U_\mathrm{B}} U_\mathrm{B}^{-1} = -U_\mathrm{B}^{-2}$$

d) Berechnen Sie die kombinierte empirische Standardabweichung $s_{d,\mathrm{W}}$.

$$s_{\mathrm{d,W}} = \sqrt{(c_\mathrm{d}\,s_\mathrm{d})^2 + (c_\mathrm{W}\,s_\mathrm{W})^2 + (c_\mathrm{B}\,s_\mathrm{B})^2} = 0.3674\ \mu\mathrm{m}$$

e) Berechnen Sie die effektive Anzahl der Freiheitsgrade.

$$\nu_\mathrm{eff} = \frac{s_{\mathrm{d,W}}^4}{(c_\mathrm{d}\,s_\mathrm{d})^4/\nu_\mathrm{d} + (c_\mathrm{W}\,s_\mathrm{W})^4/(J_\mathrm{W}-1) + (c_\mathrm{B}\,s_\mathrm{B})^4/(J_\mathrm{B}-1)} = 12.04$$

f) Berechnen Sie den Erweiterungsfaktor $k$, der hier das t-Quantil für ein zweiseitiges Vertrauensniveau von $1-\alpha = 0.95\%$ ist.

Berechnet mit Gnu-Octave:

```
k=tinv(0.975,nueff) k =  2.1784
```

$$k = t_{0.975,12.04} = 2.178$$

Für Ablesen aus der Quantilatabelle wird die effektive Anzahl der Freiheitsgrade abgerundet auf $\nu_\mathrm{eff} = 12$ und aus der Tabelle abgelesen:

**12.2 Quantile der t-Verteilung**

| d.o.f | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 2 | 9.925 | 6.965 | 4.303 | 2.920 | 1.061 |
| ... | 5.841 | 4.541 | 3.182 | 2.353 | 0.978 |
| 12 | 3.055 | 2.681 | 2.179 | 1.782 | 0.873 |
| 13 | 3.012 | 2.650 | 2.160 | 1.771 | 0.870 |

| d.o.f | Wahrscheinlichkeit | | | | |
|---|---|---|---|---|---|
| $\nu$ | 0.995 | 0.990 | 0.975 | 0.950 | 0.800 |
| 26 | 2.779 | 2.479 | 2.056 | 1.706 | 0.856 |
| 27 | 2.771 | 2.473 | 2.052 | 1.703 | 0.855 |
| ... | | | | | |
| 36 | 2.719 | 2.434 | 2.028 | 1.688 | 0.852 |
| 37 | 2.715 | 2.431 | 2.026 | 1.687 | 0.851 |
| 38 | 2.712 | 2.429 | 2.024 | 1.686 | 0.851 |

so dass dann folgender Wert verwendet wird

$$k = t_{0.975,12.04} = 2.179$$

g) Bestimmen Sie das vollständige Messergebnis.

$$d_\mathrm{W} = \frac{d\,\bar{U}_\mathrm{B}}{\bar{U}_\mathrm{W}} \pm k\,s_{d,\mathrm{W}} = (4.65 \pm 0.80)\ \mu\mathrm{m}$$

Durch Rundung können die hinteren Nachkommastellen bei Verwendung des Taschenrechners und des Quantiltabellenwertes etwas anders aussehen.

# Literaturverzeichnis


[Cox02] M.G. Cox: The evaluation of key comparison data, Metrologia 39, 589-595 (2002)

[Cox06] M.G. Cox, B.R.L. Siebert: The use of a Monte Carlo method for evaluating uncertainty and expanded uncertainty, Metrologie 43, S178-88, (2006), doi: 10.1088/0026-1394/43/4/S03

[Els07] C. Elster: Calculation of uncertainty in the presence of prior knowledge, Metrologia 44, 111-116, (2007)

[Els15] C. Elster, K. Klauenberg, M. Walzel, G. Wübbeler, P. Harris, M. Cox, C. Matthews, I. Smith, L. Wright, A. Allard, N. Fischer, S. Cowen, S. Ellison, P. Wilson, F. Pennecchi, G. Kok, A. van der Veen, L. Pendrill, A Guide to Bayesian Inference for Regression Problems, Deliverable of EMRP project NEW04 "Novel mathematical and statistical approaches to uncertainty evaluation", 2015
www.ptb.de/emrp/fileadmin/documents/nmasatue/NEW04/Papers/BPGWP1.pdf

[Fla02] B.P. Flannery, W.H. Press, S.A. Teukolsky, and W.T. Vetterling. Numerical Recipes in C. Cambridge University Press, 2. edition (1992-2002)

[Hel08] L. Held: Methoden der statistischen Inferenz. Likelihood und Bayes. Spektrum, Heidelberg (2008)

[Kac03] R. Kacker, A. Jones: On use of Bayesian statistics to make the Guide to the Expression of Uncertainty in Measurement consistent, Metrologia, Volume 40, Issue 5, pp. 235-248 (2003).

[Kac08] R.N. Kacker, A.B. Forbes, R. Kessel, K.D. Sommer, Bayesian posterior predictive p-value of statistical consistency in interlaboratory evaluations Metrologia, 45, pp. 512-523 (2008)

[Kla15] K. Klauenberg et al. A tutorial on Bayesian normal linear regression. Metrologia, 52, 2017.

[Pau82] R.C. Paule, J. Mandel: Consensus Values and Weighting Factors, J. Res. NBS, Vol.87, No.5,377-385 (1982)

[Rao09] S.S. Rao: Engineering optimization: theory and practice, John Wiley & Sons, 2009

[Sat41] F.E. Satterthwaite: Synthesis of variance. *Psychometrika*, 6(5), 1941.

[Tsc14] W. Tschirk: Statistik: Klassisch oder Bayes. Zwei Wege im Vergleich, Springer Lehrbuch, (2014).

[Wue08] G. Wübbeler, M. Krystek and C. Elster: Evaluation of measurement uncertainty and its numerical calculation by a Monte Carlo method *Meas. Sci. Technol.*, 19 (084009), 4pp, 2008. doi:10.1088/0957-0233/19/8/084009

[VIM08] VIM International vocabulary of metrology – Basic and general concepts and associated terms (VIM) 3rd edition (2012 - JCGM 200:2008 with minor corrections) https://www.bipm.org/utils/common/documents/jcgm/JCGM_200_2012.pdf

[GUM95] JCGM 100:2008 BIPM, IEC, IFCC, ISO, IUPAC, IUPAP and OIML 1995 Guide to the Expression of Uncertainty in Measurement (GUM) (Geneva, Switzerland: International Organization for Standardization) ISBN 92-67-10188-9

[GUMS1] JCGM 101:2008; Evaluation of measurement data — Supplement 1 to the *Guide to the expression of uncertainty in measurement* - Propagation of distributions using a Monte Carlo method (2008); https://www.bipm.org/utils/common/documents/jcgm/JCGM_101_2008_E.pdf

[JCGM106] JCGM 106:2012; Evaluation of measurement data — Supplement 6 to the *Guide to the expression of uncertainty in measurement* - The role of measurement uncertainty in conformity assessment (2012); https://www.bipm.org/utils/common/documents/jcgm/JCGM_106_2012_E.pdf

[Wiki01] https://en.wikipedia.org/wiki/Non-linear_least_squares

[Wiki02] https://en.wikipedia.org/wiki/Gauss-Newton_algorithm

[Wiki03] https://de.wikipedia.org/wiki/Akkreditierung_(Wirtschaft) Dies wird bei der Klausurkorrektur natürlich berücksichtigt.

[ISO13528] ISO: Statistical methods for use in proficency testing by interlaboratory comparison, Second edition 2015-08-01, corrected version 2016-10-15

[DIN1319] DIN 1319 Teil 1, Ausgabe Januar 1995 Titel: Grundlagen der Messtechnik - Grundbegriffe. Herausgeber: DIN Deutsches Institut für Normung e.V. Beuth-Verlag GmbH, Berlin-Wien-Zürich.

[DAkkS] http://www.dakks.de

[GuideKey] Guidelines for CCPR Key Comparison Report Preparation, https://www.bipm.org/utils/common/pdf/CC/CCPR/CCPR-G2.pdf

[ISO17011] ISO/IEC 17011:2005